

Skala · Maße

nominal: Modus · ordinal: + Median, Quantile · kardinal: + $\bar{x}$, s^2 , r. 1–7-Skala = ordinal. **0/1 = ordinal/binär**: mod, med, $\bar{x}$ =Anteil, $s^2 = \bar{x}(1 - \bar{x})$ od. „nicht sinnvoll“. Anzahl → diskret; Zeit/Gewicht/Geld → stetig.

Stichprobe

einfach zufällig · geschichtet (aus jeder Gruppe) · Klumpen (ganze Gruppen, alle befragen) · Quote (bewusst). Störvariable → Randomisierung.

Häufigkeiten

$f = h/n$, $H_j = \sum_{i \leq j} h_i$, $F = H/n$, $h_j = H_j - H_{j-1}$. $\leq k$: $F(k)$ · $< k$: $F(k-1)$ · $> k$: $1 - F(k)$ · $\geq k$: $1 - F(k-1)$.

Histogramm

Höhe = f_j /Breite; Fläche = Anteil; $\Sigma = 1$. Teilintervall: Σ Breite·Höhe; Anzahl $\times n$. „**Annahme: gleichverteilt in der Klasse**“. Modalklasse = größtes h_j (nicht höchste Säule!).

ECDF $\hat{F}$

0 für $x < a_1$; F_1 für $a_1 \leq x < a_2$; ...; 1 für $x \geq a_{\max}$. Skizze: ● links ○ rechts, Achsen beschriften.

Lage

Median sortiert! n unger.: $x_{((n+1)/2)}$; ger.: $\frac{1}{2}(x_{(n/2)} + x_{(n/2+1)})$. Tabelle: $\bar{x} = \sum a_j f_j$. Klassiert: $\bar{x}_K = \sum f_j m_j$, $s_K^2 = \sum f_j m_j^2 - \bar{x}_K^2$. Gruppen: $\frac{n_1 \bar{x}_1 + n_2 \bar{x}_2}{n_1 + n_2}$. Fehlender Wert: Summe = $n\bar{x}$. rechtsschief: $\bar{x} > x_{med} > x_{mod}$.

Quantil

$n\alpha = \text{Platz!}$ nicht ganz → aufrunden; ganz $k \rightarrow \frac{1}{2}(x_{(k)} + x_{(k+1)})$. IQR = $x_{.75} - x_{.25}$.

Streuung

$s^2 = \frac{\sum x^2}{n} - \bar{x}^2$ (empir., $\tilde{s}^2$) · $s_*^2 = \frac{n}{n-1}s^2$ (keine Wurzell!) · $s = \sqrt{s^2}$. R var/sd = s_* . TR: $\sigma x = s$, $s x = s_*$. $y = a + bx$: $\bar{y} = a + b\bar{x}$, $s_y^2 = b^2 s_x^2$, s_y , $\text{IQR}_y \times |b|$.

Boxplot

Zäune $x_{.25} - 1.5 \text{ IQR}$, $x_{.75} + 1.5 \text{ IQR}$. Außerhalb = Punkt. Whisker bis zum **letzten echten Wert innerhalb**. Box = $x_{.25} \dots x_{.75}$.

Kontingenztafel · χ^2

„A unter B“ = $h(A \cap B)/h(B)$; „aller / und“ → /n. Bedingte Anteile verschieden → Zusammenhang. $\tilde{h} = \frac{\text{Zeile} \cdot \text{Spalte}}{n}$, $\chi^2 = \sum \frac{(h - \tilde{h})^2}{\tilde{h}} \geq 0$; 0 $\Leftrightarrow$ unabh.

Kov · Korr

$s_{xy} = \frac{\sum xy}{n} - \bar{x}\bar{y}$ · $r = \frac{s_{xy}}{\sqrt{s_x^2 s_y^2}}$ · $s_{xy} = r s_x s_y$. $|r|$: $< .3$ schwach, $< .7$ mittel, $\geq .7$ stark. Satz: Stärke + Richtung + **linear** + Merkmale. Tafel: $\overline{xy} = \sum a_j b_k f_{jk}$. $u = a + bx$, $v = c + dy$: $s_{uv} = bd s_{xy}$; r gleich ($bd < 0$: $-r$).

Spearman

Ränge (Bindung = $\emptyset$ -Rang), dann Pearson mit Rängen; $1 - \frac{6 \sum d^2}{n(n^2 - 1)}$. Ränge gleich → 1, umgekehrt → -1. Satz: „monoton“.

Kausalität (2 P)

Nein, nur Zusammenhang · Drittvariable (+ Bsp.) / umgekehrte Richtung · Kausal nur mit randomisiertem Experiment. $r=0$ bei Parabel möglich; unkorreliert $\neq$ unabhängig.

Einlesen

```
setwd(path.expand("~/"))
d <- read.csv("X.csv", sep=";", dec=".", header=TRUE)
head(d); str(d); nrow(d); names(d)
```

str zeigt 1 Variable → sep falsch. chr=character · int/num=numeric · Factor.

Kennzahlen (3 Nachkommast.)

```
round(mean(d$X), 3); round(sd(d$X), 3) # sd,var: n-1
round(var(d$X)*(n-1)/n, 3) # empirisch
median(d$X); IQR(d$X); quantile(d$X, .9)
summary(d$X); max(d$X); which.max(d$X)
mean(d$X, na.rm=TRUE) # bei NA
```

Häufigkeiten · Gruppen · Filter

```
table(d$X); prop.table(table(d$X))
table(d$X, d$Y)
round(prop.table(table(d$X, d$Y), 1), 3) # zeilenw.
tapply(d$Zahl, d$Gruppe, mean)
s <- subset(d, A >= 5 & A < 60) # & und, | oder
sum(d$X > 20); mean(d$X > 20) # Anzahl/Anteil
d[d$X == max(d$X), ]
```

Klassen

```
d$X.3 <- cut(d$X, breaks=c(0,5,60,Inf), right=FALSE)
```

right=FALSE → [a,b) „weniger als“ · TRUE → (a,b] „bis zu/maximal“. Grenzen in Einheit der Variable (1 h = 60 min).

Grafik als PDF (8 P)

```
pdf("Histogramm.pdf")
hist(d$X, breaks=c(0,10,40,100), freq=FALSE,
     right=FALSE, main="Sitz ..., Matr.Nr. ..., Aufgabenteil
e)",
     xlab="Name (Einheit)", ylab="Dichte")
dev.off()
plot(d$X, d$Y, pch=16, main=, xlab=, ylab=)
boxplot(Zahl ~ Gruppe, data=d); barplot(table(d$X))
```

freq=FALSE = normiert. breaks müssen min/max abdecken. PDF im Ordner prüfen + hochladen.

Zusammenhang

```
round(cor(d$X, d$Y), 3)
cor(d$X, d$Y, method="spearman"); cov(d$X, d$Y)
```

ILIAS-Antwort

Kästchen 1: Code + Output. Kästchen 2: ganzer Satz, gerundet: „Das arithmetische Mittel der Variable Muenzen beträgt 22.083.“ Falschen Code löschen.