

R-Formelsammlung · Teil B

Alle Befehle für die ILIAS-Klausur · jeder Befehl mit kurzer Erklärung · Details & echte Outputs: R_Befehle_TeilB.pdf

60 min · 45 Punkte

1 Code schreiben, mit **Strg+Enter** ausführen

2 **Code + Output** → ILIAS-Box

3 Ergebnis `round(..., 3)`

4 2. Box: **ganzer Antwortsatz**

5 Skript oft speichern · Grafiken hochladen

01 Start & Einlesen

`setwd(path.expand("~/"))` Arbeitsverzeichnis setzen (erste Zeile)

`getwd(); list.files()` Ordner / Dateien prüfen

`d <- read.csv("D.csv")` CSV einlesen (sep=",", dec=".")

`read.csv("D.csv", sep=";", dec=",")` deutsches Format; und Komma 3,5

`read.csv2("D.csv")` dasselbe, Kurzform

`read.table("D.txt", header=TRUE)` Textdatei, 1. Zeile = Spaltennamen

`head(d); str(d); summary(d)` erste Zeilen · Struktur/Typen · Überblick

`dim(d); nrow(d); names(d)` Dimension · Anzahl Zeilen · Spaltennamen

Zahlen als chr? → `dec=", "` fehlt.

02 Datentypen

`class(x); typeof(x)` Datentyp: numeric / integer / character / factor

`is.numeric(x); is.character(x)` Typ prüfen (TRUE/FALSE)

`as.numeric(x); as.character(x)` Typ umwandeln

`factor(x); levels(f)` in Faktor umwandeln · Kategorien

`factor(x, levels=c(...), ordered=TRUE)` ordinales Merkmal (geordneter Faktor)

`data.frame(x=c(...), g=c(...))` eigenen Dataframe erstellen

Satz: „Die Variable ... ist vom Typ ...“

03 Zugriff & Filtern

`d$x; d[, ]; d[, "x"]` Spalte · Zeile i · Spalte per Name

`d$x[d$x == "A"]` Werte mit Bedingung (== doppelt!)

`subset(d, g=="A" & x>3)` Teildatensatz (& und, | oder)

`which(x > 3); which.max(x)` Zeilennummern · Position des Maximums

`sort(x); d[order(d$x), ]` sortieren · Datensatz sortieren

`d$new <- ifelse(x>30, "a", "b")` neue Spalte mit Bedingung

`cut(x, breaks=c(...), right=FALSE)` in Klassen einteilen [a,b)

`is.na(x); mean(x, na.rm=TRUE)` fehlende Werte finden · ignorieren

`unique(x); "A" %in% x` verschiedene Werte · enthalten?

04 Rechnen & Mengen

`c(); 1:5; seq(0,1,by=.25); rep(2,3)` Vektor · Folge · Folge mit Schritt · Wiederholung

`sum(x); prod(x); length(x)` Summe · Produkt · Anzahl

`cumsum(x); max(x); min(x)` kumulierte Summe · Maximum · Minimum

`sqrt(x); exp(x); log(x)` Wurzel · e hoch x · **log = ln**

`choose(n,k); factorial(n)` Binomialkoeffizient · Fakultät

`union(A,B); intersect(A,B)` Vereinigung U · Schnitt ∩

`setdiff(A,B); is.element(6,B)` Differenz A\B · Element von?

`matrix(v, nrow=2); colSums(M)` Matrix · Spaltensummen

`apply(M, 1, sum)` Funktion auf jede Zeile (2 = Spalte)

`for (i in 1:n) { ... }` Schleife: wiederhole für i = 1...n

05 Häufigkeiten

`table(x)` absolute Häufigkeiten

`prop.table(table(x))` relative Häufigkeiten (Summe 1)

`cumsum(prop.table(table(x)))` kumulierte rel. Häufigkeiten = empir. Verteilungsfunktion

`Fh <- ecdf(x); Fh(2)` $\hat{F}(2)$ = Anteil „≤ 2“

`table(x, y); addmargins(t)` Kontingenztafel · mit Randsummen

`prop.table(t, margin=1)` bedingte Häufigkeiten je Zeile (2 = Spalte)

06 Lage & Streuung

`mean(x); median(x)` arithmetisches Mittel · Median

`names(which.max(table(x)))` Modus (häufigster Wert)

`var(x); sd(x)` unverzerrte Varianz s^2 , Std.abw. s (**n-1**)

`var(x)*(n-1)/n` empirische Varianz s^2 (durch n)

`quantile(x, c(.25, .5, .75))` Quantile (Vorlesung: type=2)

`IQR(x); range(x)` Interquartilsabstand · Min und Max

`tapply(d$x, d$g, mean)` Mittelwert je Gruppe

`aggregate(x ~ g, data=d, mean)` dasselbe als Tabelle

`var, sd, cov` teilen durch n-1!

07 Zusammenhang

`cov(x, y); cor(x, y)` Kovarianz (n-1) · Korrelation nach Bravais-Pearson

`cor(x, y, method="spearman")` Rangkorrelation nach Spearman

`chisq.test(t)$expected` erwartete Häufigkeiten bei Unabhängigkeit

`chisq.test(t, correct=FALSE)$statistic` χ^2 -Koeffizient

08 Grafiken

`pdf("a.pdf") ... dev.off()` Grafik als PDF speichern (auch png())

`hist(x, breaks=c(...), right=FALSE, freq=FALSE)` Histogramm: Klassengrenzen, links geschlossen, Dichte

`main=, xlab=, ylab=` Titel (Aufgabe + Matrikel-Nr. + Platz), Achsen

`lines(density(x))` Kerndichteschätzer ins Histogramm

`density(x, bw=2, kernel="epanechnikov")` KDE mit Bandweite und Kern

`boxplot(y ~ g, data=d)` Boxplot je Gruppe

`plot(x, y); abline(lm(y ~ x))` Streudiagramm + Regressionsgerade

`barplot(table(x))` Säulendiagramm

`plot(ecdf(x))` empirische Verteilungsfunktion zeichnen

`curve(dexp(x, r), add=TRUE)` theoretische Dichte einzeichnen

`par(mfrow=c(1,2))` zwei Grafiken nebeneinander

09 Verteilungen d · p · q · r

`dbinom(k, n, p)` $P(X = k)$ Binomialverteilung

`pbinom(k, n, p)` $P(X \leq k)$

`1 - pbinom(k-1, n, p)` $P(X \geq k)$ (**k-1!**)

`dpois(k, λ); ppois(k, λ)` Poissonverteilung

`pnorm(x, μ, σ); qnorm(p, μ, σ)` Normalverteilung (σ = Std.abw., nicht Varianz!)

`pexp(x, rate=λ); qexp(p, λ)` Exponentialverteilung, $\lambda = 1/\text{Mittelwert}$

`punif(x, a, b); dgeom(k, p)` Gleichverteilung · geometrische Vert.

`dgamma(x, shape, rate)` Dichte der Gammaverteilung

`qt(.975, df); qchisq(.95, df)` t- und χ^2 -Quantile

`1 - pnorm(z); 1 - pt(t, df)` p-Wert rechtsseitig

`rbinom(N,n,p); rnorm(N,μ,σ)` Zufallszahlen erzeugen

d = Dichte/W'keit · p = Verteilungsfunktion (Σ) · q = Quantil · r = Zufallszahlen

10 Simulation

<code>set.seed(123)</code>	Zufall reproduzierbar machen
<code>sample(1:6, 5, replace=TRUE)</code>	5-mal würfeln (mit Zurücklegen)
<code>mean(x == 3)</code>	relative Häufigkeit $\approx$ Wahrscheinlichkeit

11 Likelihood & ML

<code>prod(dpois(x, λ))</code>	Likelihood = Produkt der Wahrscheinlichkeiten
<code>sum(dpois(x, λ, log=TRUE))</code>	Log-Likelihood = Summe der Logarithmen
<code>sum(log(dgamma(x, a, b)))</code>	bei Produkt = 0 (Underflow) Logs summieren
<code>L <- function(l) prod(dpois(x, l))</code>	Likelihood als Funktion definieren
<code>for (l in 17:23) print(L(l))</code>	Gitter: L für jedes λ (offizielle Lösung)
<code>g <- 17:23; g[which.max(sapply(g, L))]</code>	Gitter: bestes λ in einer Zeile
<code>optimize(f, c(0.1, 5), maximum=TRUE)</code>	numerisches Maximum (1 Parameter)
<code>mean(x); 1/mean(x)</code>	Kontrolle: Poisson $\hat{\lambda} = \bar{x} \cdot \text{Exp } 1/\bar{x}$

Satz: „Das Maximum der Likelihood liegt bei $\lambda = \dots$ “

11b nlm (mehrere Parameter)

<code>nl <- function(tp, x) -sum(log(dgamma(x, exp(tp[1]), exp(tp[2]))))</code>	negative Log-Likelihood; <code>exp()</code> macht Parameter positiv
<code>m <- nlm(nl, p=c(0,0), x=x)</code>	minimieren (Startwerte p)
<code>exp(m\$estimate)</code>	zurücktransformieren $\rightarrow \hat{\alpha}, \hat{\beta}$
<code>-m\$minimum</code>	maximale Log-Likelihood

Warnungen „NA/Inf replaced“ sind normal.

12 Konfidenzintervalle

<code>mean(x)+c(-1,1)*qnorm(.975)*sigma/sqrt(n)</code>	KI für μ , σ bekannt
<code>mean(x)+c(-1,1)*qt(.975,n-1)*sd(x)/sqrt(n)</code>	KI für μ , σ unbekannt
<code>t.test(x, conf.level=.95)\$conf.int</code>	dasselbe automatisch
<code>p+c(-1,1)*qnorm(.975)*sqrt(p*(1-p)/n)</code>	KI für einen Anteil
<code>(n-1)*var(x)/qchisq(c(.975,.025), n-1)</code>	KI für die Varianz

13 Hypothesentests

<code>t.test(x, mu=mu0, alternative="greater")</code>	t-Test, $H_1: \mu > \mu_0$ ("less" <, "two.sided" $\neq$)
<code>t.test(...)\$p.value; \$statistic</code>	p-Wert $\cdot$ Prüfgröße
<code>(mean(x)-mu0)/(sigma/sqrt(n))</code>	Gauß-Test von Hand; $p = 1 - \text{pnorm}(z)$
<code>chisq.test(table(x, y))</code>	χ^2 -Unabhängigkeitstest
<code>chisq.test(table(x), p=c(...))</code>	χ^2 -Anpassungstest
<code>binom.test(k, n, p=.5, alternative="greater")</code>	exakter Binomialtest
<code>qt(.95, df)</code>	kritischer Wert / Ablehnungsbereich
$p \leq \alpha \rightarrow H_0$ ablehnen. „Da der p-Wert ... kleiner als α ist, wird H_0 abgelehnt ...“	

14 Regression

<code>m <- lm(y ~ x, data=d); coef(m)</code>	a (Achsenabschnitt) und b (Steigung)
<code>summary(m)\$r.squared</code>	Bestimmtheitsmaß R^2
<code>summary(m)\$coefficients</code>	Koeffizienten + p-Werte
<code>predict(m, data.frame(x=40))</code>	Prognose für $x = 40$
<code>resid(m)</code>	Residuen $y - \hat{y}$

15 Ausgabe & Runden

<code>round(x, 3)</code>	auf 3 Nachkommastellen runden (immer!)
<code>sprintf("%.20f", x)</code>	feste Anzahl Nachkommastellen ausgeben
<code>z <- "0."; for (i in 1:54) z <- paste0(z, i)</code>	Yennefer-Zahl: 99 Nachkommastellen (Altklausur h)
<code>options(scipen=999)</code>	keine Darstellung wie e-131
<code>paste("a", 1); cat("n=", n)</code>	Text + Zahl verbinden / ausgeben

! Fehlermeldungen

mehr Spalten als Spaltennamen	<code>sep=";", dec=","</code> ergänzen
cannot open file / Datei nicht gefunden	<code>setwd + list.files()</code> prüfen
object not found	Tippfehler / Groß-Klein, Objekt fehlt
could not find function	Befehl falsch geschrieben
Argument nicht numerisch $\rightarrow$ NA	Spalte ist Text: <code>dec / as.numeric</code>
Ergebnis NA	<code>na.rm=TRUE</code>

Antwortsätze (ILIAS)

Typ	„Die Variable x ist vom Typ <i>integer</i> .“
Lage	„Das arithmetische Mittel von x beträgt 30.637.“
Likelihood	„Die Likelihood unter $\lambda = 20$ beträgt 6.938 $\cdot 10^{-131}$.“
ML	„Das Maximum der Likelihood liegt bei $\lambda = 22$; der ML-Schätzer ist 22.“
Test	„Da der p-Wert 0.001 kleiner als $\alpha = 0.05$ ist, wird H_0 abgelehnt. Es ist abgesichert, dass ...“
KI	„Das 95 %-KI lautet [28.935; 32.340].“

Nicht-numerische Antworten immer als **ganzer Satz**.