

Formelsammlung Tag 1 · Alle Regeln

Deskriptive Statistik (V01–V03) + R-Grundlagen. Jede Regel aus Vorlesung, Tutorien 1–3, Testaten 0–2, Probeklausur (inkl. Hinweisblatt) und Abschlusssitzung – mit Quelle. Jede Karte: **Formel** → **Rezept** → **⚠ Falle** → **Satz**.

Quellen: V = Vorlesung · T = Tutorium · Te = Testat · PK = Probeklausur 04.03.2022 · AS = Abschlusssitzung. „Typ ...“ = Musterbeispiel im Lernbuch.

0 · Klausurregeln (gelten für jede Aufgabe)

Form, Runden, Kästchen

PK-Hinweise · AS

- **Runden:** Endergebnis auf **3 Nachkommastellen** (kaufmännisch), Zwischenergebnisse auf **mindestens 4**. Alternativ **vollständig gekürzte Brüche**. Ganze Zahlen und Ausdrücke wie $\log 4$, $\sqrt{2}$ nicht runden. Abweichende Anweisung in der Aufgabe geht vor.
- **Dezimalpunkt** (3.5, nicht 3,5). **Kugelschreiber/Tinte** – Bleistift, Grün und Rot werden nicht gewertet.
- Ins Kästchen nur das **Endergebnis** – außer „Geben Sie Ihren Lösungsweg an“. Alles außerhalb der Kästchen zählt nicht (außer eindeutig markiert). Nebenrechnungen werden nicht korrigiert.
- **Nur eine Lösung** pro Kästchen, nie Alternativen; falsche Versuche durchstreichen. Mehrere Lösungen, ein Kästchen → alle hinein.
- Aufgabe widersprüchlich/unlösbar → „**nicht lösbar**“ ins Kästchen + Begründung ins Feld am Ende.
- Alle Ergebnisse **vereinfachen**. Folgefehler werden berücksichtigt (Teil B ausdrücklich).
- Hilfsmittel: 1 A4-Blatt pro Teil, beidseitig, **handgeschrieben, selbst angefertigt**, nicht zusammengeklebt; Taschenrechner von der Positivliste mit Sticker.
- Zeit Teil A: 100 Min / 75 P → **1 P ≈ 1.3 Min**. Teil B: 60 Min / 45 P.

1 · Grundbegriffe, Merkmale, Skalen, Stichproben (V01, T1)

Grundbegriffe

V01 · T1 A13 · Typ 5

- **Statistische Einheit:** Objekt, an dem Daten erhoben werden (Singular: „ein Mitglied“). Kann auch **abstrakt** sein.
- **Grundgesamtheit (Population):** Menge **aller** für die Fragestellung relevanten Einheiten (Ort + Zeit nennen). Kann **hypothetisch** sein (alle je produzierten Güter; allgemeine Gesetzmäßigkeit).
- **Stichprobe:** Teilmenge der Grundgesamtheit, die untersucht wird.
- **Merkmal** X, Y, Z (groß) = Eigenschaft; **Ausprägung** x, y, z (klein) = konkreter Wert.
- **Deskriptiv** = Daten beschreiben; **induktiv** = von Stichprobe auf Grundgesamtheit schließen **unter Berücksichtigung der Unsicherheit**.
- **Modell** = vereinfachte Beschreibung der Realität (nicht fehlerfrei). **Deterministisch** = keine Unsicherheit im Modell; **stochastisch** = mit Zufall.

⚠ Falle: Nicht die Notation (Ω) wiedergeben, sondern die Eigenschaften erklären (T1 Fehlerquelle).

Diskret · stetig

V01 · T1 A14 · T2 A1

- **Diskret:** endlich **oder abzählbar unendlich** viele Ausprägungen (Anzahl Likes, Autos an der Autobahn). Endlich viele Ausprägungen ⇒ **immer diskret**.
- **Stetig:** überabzählbar viele – jede reelle Zahl in einem Intervall möglich (Größe, Gewinn, BIP). V01: stetige Merkmale heißen auch **metrisch**.
- **Quasi-stetig:** gerundet gemessen, aber als stetig behandelt (Körpergröße in cm, Geld). Dann ist egal, ob Intervallgrenzen dazugehören.
- Quantitative Merkmale können diskret **oder** stetig sein. Stetige Merkmale kann man nachträglich klassieren (Altersklassen).
- Nominale/ordinale Merkmale (Standort, Tarif, Note) sind diskret.

Skala	Bedeutung	Häufigk.	Rangordnung	Differenzen/Quotienten	sinnvolle Lagemaße
nominal	nur Bezeichnungen, keine Ordnung	ja	nein	nein	Modus
ordinal	ordnen ja, Abstände nicht interpretierbar	ja	ja	nein	Modus, Median, Quantile
kardinal (metrisch)	Abstände (meist auch Verhältnisse) interpretierbar	ja	ja	ja	alle; Mittel, Varianz, r

- Beispiele V01: nominal – Partei, Nationalität, Kreditzweck; ordinal – Schulnoten, Kundenzufriedenheit, Rang im Wettkampf; kardinal – Alter, Größe, Einkommen.
- Punkte 0–100** → kardinal (T1-Fehler: wie Noten behandeln). **Skala 1–5 / 1–7** → ordinal (T1-Fehler: Zahlen verleiten zu „kardinal“).
- 0/1-kodiert (binär)**: PK-Musterlösung „ordinalskaliert/binär“. Mittel = Anteil (V02: „auch sinnvoll für binäre Merkmale“). Varianz $\bar{x}(1 - \bar{x})$ **oder** „nicht sinnvoll interpretierbar“ – beides akzeptiert.
- V02: Mittelwert „wird manchmal auch für ordinale Merkmale verwendet“; Modus bei metrischen Merkmalen mit vielen Werten oft nicht sinnvoll.

Satz: „*X ist ein stetiges, kardinal skaliertes Merkmal, da Abstände sinnvoll interpretierbar sind.*“ · „*Der Median ist für X nicht sinnvoll, da sich die Ausprägungen nicht ordnen lassen.*“

Versuchsplanung · Störvariablen

V01 · Typ 6

- Versuchsplanung: Ziel festlegen · Methoden auswählen · Datenerhebung planen · allgemeine Festlegungen.
- Störvariable**: spielt für die untersuchten Größen eine Rolle, ist aber nicht Ziel der Untersuchung (Alter, Vorwissen ...).
- Kontrolle: **Homogenisierung** (Teilgruppen nach Störvariable bilden) · **Randomisierung** (zufällige Zuteilung zu Gruppe mit/ohne Maßnahme) · **statistische Modellierung** (Störvariable in der Analyse berücksichtigen).

Stichprobenverfahren

V01 · T1 A13 · Te1 A2 · Typ 4

Verfahren	Wie?	Vorteil · Voraussetzung
einfache Zufallsstichprobe	ohne Zurücklegen aus der Liste; jedes Element gleiche Chance, jede Stichprobe gleich wahrscheinlich	nur zufällige, keine systematischen Unterschiede
geschichtet	einfache Zufallsstichprobe aus jeder vorab gebildeten Teilgruppe	Gruppen repräsentativ (oder gezielt überrepräsentiert) · Anteile und Zugehörigkeit bekannt
Klumpen	zufällig ganze Klumpen (Region, Schulklasse, Familie), darin alle oder Zufallsauswahl	billiger, einfacher · Klumpen innen heterogen, untereinander homogen
Quote (bewusste Auswahl)	vorab festgelegte Quoten erfüllen, nicht zufällig	

- Repräsentativ** = keine systematischen Unterschiede zur Grundgesamtheit. Probleme: Einheiten außerhalb der Grundgesamtheit in der Stichprobe; nicht alle Einheiten haben eine Chance (Online-Umfrage).
- T1: Schulen **in Göttingen** für alle 10. Klassen in Deutschland → **Klumpen** (nicht geschichtet!). „Repräsentativ bzgl. Bevölkerungsgruppen“ → **Quote oder geschichtet**. Te1: Anteil je Studiengang wie in der Gesamtheit → geschichtet/Quote.
- Kleine Stichprobe ($n = 20$) → Hochrechnung auf die Grundgesamtheit unsicher (T2 A1c).
- Kreislauf der Datenanalyse: Planung → Erhebung → Aufbereitung/Prüfung → Analyse → Interpretation → Publikation (Daten + Code) → Wiederverwendung.

2 · Häufigkeiten, Diagramme, Verteilungsfunktion (V02, T2)

Häufigkeiten und Tabelle

V02 · T2 A2 · Te1 A4 · Typ 7

$$h_j = h(a_j) \quad f_j = \frac{h_j}{n} \quad H_j = h_1 + \dots + h_j \quad F_j = \frac{H_j}{n} \quad h_j = H_j - H_{j-1} \quad n = \sum h_j$$

$a_1 < \dots < a_J$ = verschiedene Ausprägungen ($J \leq n$). Tabelle vervollständigen: vorwärts addieren, rückwärts subtrahieren, $h_j = f_j n$, $H_j = F_j n$; Kontrolle $\sum f = 1$, letztes $F = 1$.

Wort (diskret)	Rechnung	Wort	Rechnung
höchstens / nicht größer als k	$F(k)$	mehr als / größer als k	$1 - F(k)$
weniger als / kleiner als k	$F(k - 1)$	mindestens k	$1 - F(k - 1)$
zwischen a und b (beide inkl.)	$F(b) - F(a - 1)$	genau k	$f(k)$

⚠ **Falle:** „größer als“ oder „größer gleich“? (T2 Fehlerquelle). Beim Kumulieren die vorherigen h mitaddieren. Gegenwahrscheinlichkeit $1 - \dots$ spart Zeit.

Klassen, Säulendiagramm, Histogramm

V02 · T2 A1,3 · T3 A1 · Te1 A7 · Typ 8–10, 13, 14

- **Klassen in der Vorlesung:** $[c_0, c_1], (c_1, c_2], \dots, (c_{J-1}, c_J]$ – rechts geschlossen (wie R-Standard `right = TRUE`). In der Aufgabe angegebene Klammern gehen vor.
- **Säulendiagramm: Höhe** $\propto h_j$ bzw. $f_j \rightarrow$ Bild hängt von der Klassenbreite ab (verzerrt bei ungleichen Breiten).
- **Histogramm: Fläche** $\propto f_j$ (flächenproportional), Gesamtfläche 1, „Goldstandard“ für stetige Merkmale. Die Veranstaltung nutzt nur Histogramme mit **relativen** Häufigkeiten.

$$\text{Höhe (Dichte)} = \frac{f_j}{\text{Breite}} = \frac{h_j}{\text{Breite} \cdot n} \quad \text{Anteil in } [a, b] \approx \int_a^b H_x dx = \sum \text{Breite} \cdot \text{Höhe}$$

- Anteil in einem Intervall: in Stücke je Klasse zerlegen, **Breite des Stücks $\times$ Höhe** (oder $\frac{\text{Stückbreite}}{\text{Klassenbreite}} \cdot f_j$), addieren. **Annahme hinschreiben:** „Werte innerhalb der Klassen gleichmäßig (stetig gleich-) verteilt“.
- Anzahl = Anteil $\times n$. Aus Histogramm-Höhe: $h_j = \text{Höhe} \cdot \text{Breite} \cdot n$.
- **Modalklasse** = Klasse mit größtem h_j / f_j – bei ungleichen Breiten **nicht** immer die höchste Säule (Te1 A7.4: „im Allgemeinen falsch“).
- Meist **äquidistante** Klassen; Anzahl J mit Bedacht wählen (Bias-Variance-Trade-off: zu wenige Klassen glätten zu stark, zu viele sind zu unruhig).
- **Form:** unimodal / bimodal / multimodal; symmetrisch / rechtsschief (linkssteil) / linksschief (rechtssteil).

⚠ **Falle:** Falsche Klassenbreite; bei absoluten Häufigkeiten nicht durch n teilen (T2). Säulendiagramm mit `prob = F` bei ungleichen Breiten $\rightarrow$ verzerrt.

🔑 **Satz:** „Kein Histogramm, sondern ein Säulendiagramm: absolute Häufigkeiten bei ungleichen Klassenbreiten führen zu einer verzerrten Darstellung.“

Empirische Verteilungsfunktion

$\hat{F}(x)$

T2 A2 · PK A2b (6 P) · Typ 11, 12

$$\hat{F}(x) = \frac{\#\{x_i \leq x\}}{n} = \text{Anteil der Beobachtungen } \leq x$$

1. Sortieren, verschiedene Werte mit F_j .
2. Fallunterscheidung: 0 für $x < a_1$; F_1 für $a_1 \leq x < a_2$; ...; 1 für $x \geq a_J$.
3. Skizze: waagerechte Stufen, • am linken Ende, ○ am rechten; Achsen beschriften (x: Merkmal + Einheit, y: 0...1).

PK-Muster: 4.0 (3×), 8.5 (4×), 12 (2×), 15.7 (1×) $\rightarrow$ 0 / 0.3 / 0.7 / 0.9 / 1 mit Grenzen 4, 8.5, 12, 15.7.

⚠ **Falle:** T2-Fehlerquellen: Punkt vergessen · Stufen **nicht senkrecht verbinden** · Andeutung ins Unendliche (Pfeil/Linie nach links bei 0 und nach rechts bei 1) vergessen.

Rückwärts: Sprunghöhe bei $a_j = f_j \rightarrow h_j = f_j n$.

3 · Lagemaße (V02, T2, Te1)

Mittelwert · Median · Modus

V02 · T2 A4,6 · Te1 A4,5 · Typ 15, 16

$$\bar{x} = \frac{1}{n} \sum x_i = \sum_j a_j f_j \quad x_{med} = \begin{cases} x_{((n+1)/2)} & n \text{ ungerade} \\ \in [x_{(n/2)}, x_{(n/2+1)}] & n \text{ gerade (üblich: Mittelwert der beiden)} \end{cases}$$

- $x_{(i)}$ = i-ter Wert der **sortierten** Liste (nicht x_i !). Tabelle: Platz über H_j finden.
- Modus = häufigste Ausprägung (kann mehrdeutig sein). R: `which(table(x) == max(table(x)))`.
- $\sum (x_i - \bar{x}) = 0$: Abweichungen nach links und rechts heben sich auf. Median: mind. 50 % links, mind. 50 % rechts.
- Voraussetzungen: Mittel kardinal (auch 0/1); Median ab ordinal; Modus jede Skala.
- Median **robust** gegen Ausreißer, Mittel nicht (T2 A6: 14 statt 9 → Mittel 8 statt 7, Median bleibt 7).

⚠ **Falle:** R gibt bei geradem n den Mittelwert des Median-Intervalls aus (T3). Median aus der Liste der **verschiedenen** Werte ist falsch.

📌 **Satz:** „Der Median ist robuster gegenüber Ausreißern als das arithmetische Mittel.“

Klassierte Daten · Schichten · Korrekturen

V02 · T2 A5 · PK A2c · Typ 17–19

$$m_j = \frac{c_{j-1} + c_j}{2} \quad \bar{x}_K = \sum f_j m_j \quad s_K^2 = \sum f_j (m_j - \bar{x}_K)^2 = \sum f_j m_j^2 - \bar{x}_K^2 \quad \bar{x} = \frac{1}{n} \sum_{j=1}^r n_j \bar{x}_j$$

- Klassiert = Näherung (alle Werte in der Klassenmitte). PK: 7 Werte in [0,10), 3 in [10,20] → $\frac{7 \cdot 5 + 3 \cdot 15}{10} = 8$ (echtes Mittel 8.57).
- Gesamtmittel aus Schichten = **gewichteter** Durchschnitt (Mietspiegel).
- Fehlender / falscher / neuer Wert: über die Summe $\sum x = n\bar{x}$.

Schiefe · Transformation

V02 · Typ 20, 21

symmetrisch, unimodal	rechtsschief = linkssteil	linksschief = rechtssteil
$\bar{x} \approx x_{med} \approx x_{mod}$	$\bar{x} > x_{med} > x_{mod}$ (langer Schwanz rechts)	$\bar{x} < x_{med} < x_{mod}$

- Linear $y = a + bx$: $\bar{y} = a + b\bar{x}$; Median, Modus, Quantile ebenso.
- Monoton $y = g(x)$ (z. B. log): $y_{med} = g(x_{med})$ – für den Mittelwert gilt das **nicht**.

4 · Quantile, Streuung, Boxplot (V02, T2, T3)

α-Quantil

V02 · T2 A7 · Typ 24

$$x_\alpha = \begin{cases} x_{(\lfloor n\alpha \rfloor + 1)} & n\alpha \notin \mathbb{N} \text{ (aufrunden)} \\ \in [x_{(n\alpha)}, x_{(n\alpha+1)}] & n\alpha \in \mathbb{N} \text{ (üblich: Mittelwert)} \end{cases} \quad 0 \leq \alpha \leq 1$$

- Mindestens $\alpha \cdot 100\%$ der Daten $\leq x_\alpha$, mindestens $(1 - \alpha) \cdot 100\% \geq x_\alpha$. Voraussetzung: mindestens ordinal.
- Median $x_{0.5}$ · Quartile $x_{0.25}, x_{0.5}, x_{0.75}$ · Dezile $x_{0.1}, \dots, x_{0.9}$ · Vintile $x_{0.05}, x_{0.95}$.
- V02-Beispiel $n = 26$: $6.5 \rightarrow x_{(7)}$; $13 \rightarrow \frac{x_{(13)} + x_{(14)}}{2}$; $19.5 \rightarrow x_{(20)}$.

⚠ **Falle:** $n\alpha$ ist die **Platznummer**, nicht der Wert! R (`quantile`) rechnet anders – Teil A: Vorlesungsdefinition.

Varianz · Standardabweichung · IQR

V02 · T2 A4,6 · T3 A1 · Te1 A5 · PK A1,2,5a · Typ 25, 26

$$S^2 = s^2 = \frac{1}{n} \sum (x_i - \bar{x})^2 = \frac{1}{n} \sum x_i^2 - \bar{x}^2 \quad S_*^2 = s_*^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2 = \frac{\sum x_i^2 - n\bar{x}^2}{n-1} = \frac{n}{n-1} s^2$$

$$s = \sqrt{s^2} \quad \text{Tabelle: } s^2 = \sum a_j^2 f_j - \bar{x}^2 \quad \text{IQR} = d_Q = x_{0.75} - x_{0.25} \quad \text{Spannweite} = x_{max} - x_{min}$$

- „**empirische Varianz**“ = $\frac{1}{n}$ (in Musterlösungen auch $\hat{s}^2$, S^2 , „Stichprobenvarianz“). „**unverzerrt / korrigiert** / s_*^2 “ = $\frac{1}{n-1}$ (bessere theoretische Eigenschaften, V09). R: `var`, `sd` = unverzerrt. Umrechnen $s^2 = \frac{n-1}{n} s_*^2$.
- Vorteil s : **gleiche Maßeinheit** wie das Merkmal (Te1 A5.3 – nicht „robust gegen Ausreißer“!).
- s_*^2 ist schon die Varianz – **keine Wurzel**. $s^2 \geq 0$ immer.
- Lineare Transformation $a + bx$: $s^2 \rightarrow b^2 s^2$, $s_*^2 \rightarrow b^2 s_*^2$, $s \rightarrow |b|s$, IQR $\rightarrow |b| \text{IQR}$; a egal (T2 A6: Datensatz $\times 2 \rightarrow$ Varianz $\times 4$).
- Streuung von Schichten vergleichen: kleineres s = homogener (V02 Mietspiegel).

⚠ **Falle:** T2/T3-Fehlerquelle: s_*^2 -Formel benutzt, obwohl s^2 gefragt.

📌 **Satz:** „Die Standardabweichung hat dieselbe Maßeinheit wie das Merkmal.“

- **Fünf-Punkte-Zusammenfassung:** $x_{\min}, x_{0.25}, x_{\text{med}}, x_{0.75}, x_{\max}$. Box = mittlere 50 %.
- **Ausreißer:** mehr als 1.5-IQR von der Box entfernt → einzelne Punkte.

$$x_{RUW} = x_{0.25} - 1.5 \text{ IQR} \quad x_{UW} = \min\{x_i \geq x_{RUW}\} \quad x_{ROW} = x_{0.75} + 1.5 \text{ IQR} \quad x_{OW} = \max\{x_i \leq x_{ROW}\}$$

- Whisker enden am **extremsten echten Wert innerhalb** der Grenzen. Keine Punkte eingezeichnet → **keine Ausreißer** (Te1 A6.3; langer Whisker ist kein Ausreißer).
- Zeigt: Lage, Variabilität, Schiefe (Median nah am unteren Rand + langer oberer Whisker → rechtsschief), Extremwerte. Median genau in Boxmitte ist Zufall (T2 A7c).
- Median-Unterschiede zwischen Gruppen beweisen **keine Kausalität** (Te1 A6.2: nur Korrelation, kausal nur mit Experiment/Kontrolle der Störvariablen).

5 · Zwei Merkmale: Kontingenztafel, χ^2 (V03, T3)

Gemeinsame, Rand- und bedingte Verteilung

V03 · T3 A2 · Te2 A3.6–7 · Typ 31, 32

$$h_{jk} = h(a_j, b_k) \quad f_{jk} = \frac{h_{jk}}{n} \quad h_{j\bullet} = \sum_k h_{jk} \quad h_{\bullet k} = \sum_j h_{jk} \quad f_{j\bullet} = \frac{h_{j\bullet}}{n} \quad f(b_k | a_j) = \frac{h_{jk}}{h_{j\bullet}}$$

- Beobachtungspaare (x_i, y_i) an **denselben** Einheiten. Gemeinsame Verteilung bestimmt die Ränder eindeutig; umgekehrt nur bei **Unabhängigkeit**.
- Bedingte Verteilung = Tafel **zeilen- bzw. spaltenweise normieren**. Nenner = Summe der Gruppe nach „unter / von den / gegeben“; „aller / und“ → n .
- **Unabhängig** ⇔ alle bedingten Verteilungen gleich (= Randverteilung): $\frac{h_{jk}}{h_{j\bullet}} = \frac{h_{\bullet k}}{n}$. Verschieden → Zusammenhang.
- Tafel aus Text: Σ -Zeile/-Spalte zeichnen, Textzahlen eintragen, Rest per Differenz. Prozent „der Frauen“ × Zeilensumme.

⚠ **Falle:** $f(A | B) \neq f(B | A)$.

χ^2 -Koeffizient

V03 · Typ 33–35

$$\tilde{h}_{jk} = \frac{h_{j\bullet} h_{\bullet k}}{n} \quad \chi^2 = \sum_{j=1}^J \sum_{k=1}^K \frac{(h_{jk} - \tilde{h}_{jk})^2}{\tilde{h}_{jk}}$$

1. Erwartete Tafel (nicht runden; Randsummen müssen gleich bleiben).
2. Differenzen (pro Zeile/Spalte Summe 0; bei 2×2 alle ±gleich).
3. Quadrat / **erwartet**, alle Zellen addieren.

$\chi^2 \approx 0$ → (näherungsweise) unabhängig; groß → starker Zusammenhang; nie negativ; hängt von n ab (alle $\times 2$ → $\chi^2 \times 2$); misst keine Richtung/Ursache. V03-Beispiel: $\tilde{h}_{11} = \frac{123 \cdot 324}{447} \approx 89.15$, $\chi^2 \approx 4.51$.

6 · Kovarianz, Korrelation, Kausalität (V03, T3, Te2)

Streudiagramm · Kovarianz

V03 · T3 A3.5 · Te2 A1 · Typ 36–38, 41

- Streudiagramm (zwei metrische Merkmale): gleich- vs. gegengerichtet, linear vs. nicht linear. Achsen beschriften (T3).
- **Konkordant:** $(x_i - \bar{x})(y_i - \bar{y}) > 0$ (rechts oben / links unten); **diskordant:** < 0 .

$$s_{xy} = \widehat{\text{Cov}}(X, Y) = \frac{1}{n} \sum (x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{n} \sum x_i y_i - \bar{x} \bar{y} \quad \text{Tafel: } s_{xy} = \sum_j \sum_k a_j b_k f_{jk} - \bar{x} \bar{y}$$

- $\text{Cov} > 0$ positiver, < 0 negativer, $= 0$ **kein linearer** Zusammenhang (unkorreliert). $\text{Cov}(X, X) = \text{Var}(X)$.
- **Einheit** = Produkt der Einheiten (kg·cm) → Höhe nicht interpretierbar, nur **Vorzeichen**. cm → m: Kovarianz ÷ 100 (T3 A3: beide richtig, aber Einheit der Aufgabe benutzen).
- Te2 A1.1: vereinfachte Form = $\frac{1}{n} \sum x_i y_i - \bar{x} \bar{y}$ (Antwort d).
- Nichtlineare Zusammenhänge werden nicht erkannt.

🔍 **Satz:** „Das positive Vorzeichen deutet auf einen positiven linearen Zusammenhang hin; die Höhe ist nicht interpretierbar, da sie von den Einheiten abhängt.“ (T3 A5)

$$\hat{\rho}_{XY} = r = \frac{s_{xy}}{s_x s_y} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}} \in [-1, 1] \quad s_{xy} = r s_x s_y$$

$ r $	0 bis <0.3	0.3 bis <0.7	0.7 bis 1
Stärke	schwach	mittel	stark

- $r = 0 \Rightarrow$ kein **linearer** Zusammenhang; $|r| = 1 \Rightarrow$ perfekt linear. Dimensionslos $\rightarrow$ gleich bei jeder Skalierung ($u = a + bx$, $v = c + dy$: $s_{uv} = bd s_{xy}$, $r_{uv} = \pm r$).
- Unabhängig $\Rightarrow$ unkorreliert, aber unkorreliert $\nRightarrow$ unabhängig (T3 A6: $y = x^2$ auf $[-1, 1] \rightarrow r \approx 0$).
- Vorgegebene gerundete Werte benutzen (PK A5b). „Wenn nicht berechnet, interpretieren Sie $\rho = 0.2$ “ $\rightarrow$ Ersatzwert deuten.
- $\hat{d}$ = Schätzer aus der Stichprobe; Ergebnis kann auch durch Zufall entstehen (T3 A5).
- Te2 A2 (R/F): $\rho \neq 0 \Rightarrow$ nie unabhängig (R) · $Y = -X^2 \Rightarrow \rho \approx 0$ möglich (R) · $X = Y \Rightarrow \rho = 1$ (R) · $\rho \neq 0 \Rightarrow$ kausal (F) · $\text{Cov} \geq 0.8 \Rightarrow$ stark (F).
- Te2 A1.6: Punktwolke steigend $\Rightarrow$ positiver **stochastischer** (nicht deterministischer) Zusammenhang; „auf jeden Fall mehr Punkte“ ist falsch.

🐞 **Satz:** „ $r = 0.836$: starker positiver linearer Zusammenhang zwischen Gewicht und Größe.“ (Stärke + Richtung + linear + Merkmale)

Rangkorrelation nach Spearman

$$r_{sp} = \frac{\sum rk(x_i)rk(y_i) - n\bar{R}^2}{\sqrt{(\sum rk(x_i)^2 - n\bar{R}^2)(\sum rk(y_i)^2 - n\bar{R}^2)}} \quad \bar{R} = \frac{n+1}{2} \quad \text{ohne Bindungen: } 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$$

- Für **ordinale** Merkmale oder **monotone, auch nichtlineare** Zusammenhänge = Pearson mit den Rängen (kleinster Wert = Rang 1).
- **Bindungen** $\rightarrow$ Durchschnittsränge. Rangsumme $= \frac{n(n+1)}{2}$.
- V03: monoton nicht-linear $\rightarrow$ Pearson 0.48, Spearman 1; nicht monoton $\rightarrow$ beide klein. Ränge identisch $\rightarrow$ 1, umgekehrt $\rightarrow$ -1.

Kausalität · Scheinkorrelation · ökologischer Fehlschluss

- **Kausalität:** Veränderung von X verursacht Veränderung von Y. Nachweis braucht (1) **gezielte Manipulation** von X und (2) **Kontrolle aller weiteren Einflüsse** (z. B. Randomisierung). Statistik liefert i. d. R. nur einen **statistischen Zusammenhang**.
- **Scheinkorrelation:** hohe Korrelation ohne direkten Zusammenhang – **Drittvariable** (Margarine–Scheidung: wirtschaftliche Lage) oder **reiner Zufall** (PKW–Zulassungen–Gefangene).
- **Ökologischer Fehlschluss:** aus aggregierten Gruppendaten (Makroebene, z. B. Stadtbezirke) unzulässig auf Individuen (Mikroebene) schließen; oft fehlen weitere Größen (EHEC: Grünen–Wähler $\leftrightarrow$ Sprossen/Ernährung).
- Cholera London: gemeinsame Verteilung Wasserversorger $\times$ Tote $\rightarrow$ Geburtsstunde der Epidemiologie.

🐞 **Satz:** „Nein. Es liegt nur ein statistischer Zusammenhang vor, keine Kausalität. Er könnte durch eine Drittvariable wie ... oder Zufall entstehen. Für einen Kausalnachweis bräuchte man eine gezielte Manipulation von X und die Kontrolle aller Störvariablen, z. B. durch Randomisierung.“

7 · Mathe-Werkzeug: Summenzeichen (T1, Te0)

Rechenregeln

$$\sum_{i=1}^n c = nc \quad \sum c x_i = c \sum x_i \quad (\text{nur Konstanten ohne Index vorziehen}) \quad \sum (x_i + y_i) = \sum x_i + \sum y_i \quad \sum_{i=1}^n (x_i - \bar{x}) = 0$$

$$\sum_{i=1}^3 x_i + \sum_{i=4}^{10} x_i = \sum_{i=1}^{10} x_i \quad \sum_{k=1}^2 \sum_{j=1}^3 kj = 18 \quad (\text{innen zuerst}) \quad \frac{1}{n} \sum (x_i - \bar{x})^2 = \frac{1}{n} \sum x_i^2 - \bar{x}^2$$

⚠ **Falle:** $\sum \frac{x}{i^2} \neq \frac{1}{i^2} \sum x$ – Terme mit Index dürfen nicht vor das Summenzeichen.

Objekte, Typen, Einlesen

V01-Skript · Te0 A1 · Te2 A3 · PK B a–c

```
setwd(path.expand("~/")); getwd()
d <- read.csv("X.csv", sep = ";", dec = ".", header = TRUE) # oder read.table()
head(d); str(d); names(d); dim(d); nrow(d); ncol(d); summary(d)
typeof(d$X); class(d$X); mode(d$X); is.numeric(d$X); is.factor(d$X)
x <- c(3, 1, 4); 1:20; seq(2, 8, by = 2); rep(0, 5); length(x)
x[1]; x[c(1, 10)]; x[length(x)]; x[x > 10]; which(x == max(x))
f <- factor(v, levels = c("a", "b")); levels(f); as.numeric(f)
d[, 3]; d[d$Tal == "Bergtal", ]; d$neu <- ...; cbind(); data.frame()
```

Typen: chr character · int integer (ganze Zahlen, numerisch) · num/double · Factor · logi logical. Te2: Taverne → character, Kampfzeit → numeric. str() zeigt nur 1 Variable → sep falsch.

Satz: „Die Variable Tal ist ein character-Objekt, die Variable Muenzen ist numerisch vom Typ integer (nur ganze Zahlen).“ (PK-Lösung)

Kennzahlen

V02-Skript · T3 A1 · Te1 A5.2 · PK B d

```
round(mean(d$X), digits = 3); median(d$X); sum(d$X); sort(d$X)
round(sd(d$X), 3) # = sqrt(var(d$X)), unverzerrt (n-1)
var(d$X) * (n - 1) / n # empirische Varianz (1/n)
quantile(d$X, c(.25, .75)); IQR(d$X); min(d$X); max(d$X); range(d$X)
table(d$X); prop.table(table(d$X)); which(table(x) == max(table(x))) # Modus
mean(d$X, na.rm = TRUE); x <- na.omit(x) # NA
tapply(d$Zahl, d$Gruppe, mean); aggregate(d$Zahl, by = list(d$Gruppe), mean)
subset(d, A >= 5 & A < 60); sum(d$X > 20); mean(d$X > 20); unique(x)
```

△ Falle: Te1 A5.2: Standardabweichung = sd(x) und sqrt(var(x)) (beide richtig). R-Median bei geradem n = Mittel des Intervalls; R-Quantile ≠ Vorlesungsdefinition. Immer mit round(..., 3) runden.

Grafiken

T2 A3 · T3 A1,4,6 · Te2 A3.4 · PK B e

```
pdf("Histogramm.pdf") # oder png("x.png", width=2000, height=2000, res=400)
hist(d$X, breaks = c(5, 15, 20, 25, 35), freq = FALSE, # = prob = TRUE
     right = FALSE, main = "Sitz ..., Matr.Nr. ..., Aufgabenteil e)",
     xlab = "Muenzen", ylab = "Dichte")
dev.off()
hist(x, breaks = c(40, 70, 100), plot = F)$counts # Häufigkeiten ohne Grafik
cumsum(h$counts); axis(1, x) # kumuliert; Werte an x-Achse
boxplot(x); boxplot(Zahl ~ Gruppe, data = d); boxplot(x, plot = F)$stats # Whisker/Quartile
plot(x, y, pch = 16, cex = 0.8, main = , xlab = , ylab = , panel.first = grid())
barplot(table(d$X)); par(mfrow = c(3, 1)) # mehrere Plots; dev.off() setzt zurück
```

△ Falle: hist() ohne freq = FALSE zeigt absolute Häufigkeiten. right = TRUE (Standard) → (a, b]; FALSE → [a, b). Titel muss Aufgabenteil, Matrikel- und Sitzplatznummer enthalten; Achsen wie verlangt. PDF im Ordner Dokumente prüfen und hochladen.

Klassen · Kontingenztafel · Zusammenhang

V02/V03-Skript · T3 A5–7 · Te2 A3.5–7

```
d$K.3 <- cut(d$Kampfzeit, breaks = c(0, 5, 60, Inf), right = FALSE) # Factor
d$M.4 <- cut(d$Muenzen, breaks = c(0, 10, 20, 30, Inf), right = TRUE)
Kontingenz.Tafel <- table(d$M.4, d$K.3)
prop.table(table(X, Y)); round(prop.table(table(X, Y), 1), 3) # 1 = zeilenweise, 2 = spaltenweise
round(prop.table(table(subset(d, Kampfzeit >= 5 & Kampfzeit < 60)$M.4), 2)
cor(x, y) # Pearson (Standard); cor(d) = Korrelationsmatrix
cor(x, y, method = "spearman"); cor(rank(x), rank(y)); cov(x, y) # cov mit n-1!
```

„weniger als / bis unter“ → right = FALSE; „bis zu / maximal / mehr als ... aber höchstens“ → right = TRUE. Bei cor(d) gilt der Wert auf der Nebendiagonale.

```
for (i in 1:20) { y[i] <- x[i] * 1.5 }      # einfacher: y <- x * 1.5
ifelse(x > 10, 1, x); if (a > 0) { ... } else { ... }
f <- function(v) { v[v > 10] <- 1; return(v) }
set.seed(5); sample(0:6, 20, replace = TRUE); round(x, 3); sqrt(); exp(); log()
```

ILIAS-Antwortform

PK-B-Hinweise

- Pro Teilaufgabe bis zu 2 Boxen: **R-Code + R-Output** · **inhaltliche Antwort in ganzen Sätzen**, 3 Nachkommastellen, mit R-Befehl gerundet.
- Fehlerhaften Code, der nicht zur Antwort gehört, entfernen; keine widersprüchlichen Mehrfachlösungen.
- Nur im Ordner **Dokumente** arbeiten, Skript regelmäßig speichern. Fehlen Objekte aus früheren Teilen → selbst nachvollziehbar erzeugen. Einlesen klappt nicht → Befehle trotzdem angeben.

🐞 **Satz:** „Das arithmetische Mittel der Variable Muenzen beträgt 22.454. Der unverzerzte Schätzer für die Standardabweichung beträgt 4.610.“

9 · Taschenrechner als Kontrolle

Statistik-Modus

z. B. Casio fx-87DE X / fx-991DE X

- 1 Variable: MENU → Statistik → 1-Variable → Werte (ggf. mit Häufigkeitsspalte) → AC → OPTN → 1-Variablen-Berechnung: $\bar{x}$, $\sum x$, $\sum x^2$, σx , sx .
 - 2 Variablen: MENU → Statistik → $y = a + bx$ → x, y eingeben → OPTN → Regressionsberechnung (r) / 2-Variablen-Berechnung ($\sum xy$).
- $\sigma x = s \cdot (1/n)$ · $sx = s_* \cdot (1/(n-1))$. Tastenwege je Modell verschieden – vorher üben. Lösungsweg trotzdem aufschreiben.

10 · Checkliste vor dem Abgeben

Jede Teilaufgabe

- ☐ Jeden Teil der Frage beantwortet (Semikolons, „und“, „Welche Annahme?“, „Begründen Sie“)?
- ☐ Begründung mit **Zahlen**; Deutung: Stärke + Richtung + „linear/monoton“ + Merkmale.
- ☐ Richtige Varianz ($1/n$ oder $1/(n-1)$)? Richtige Nenner (bedingt / gesamt)?
- ☐ Plausibel: $0 \leq f \leq 1$, $s^2 \geq 0$, $|r| \leq 1$, $\chi^2 \geq 0$, $\sum f = 1$.
- ☐ Einheiten; 3 Nachkommastellen oder gekürzter Bruch; keine falschen Gleichungsketten.
- ☐ Kein Kästchen leer – Formel/Ansatz bringt Teilpunkte; Ersatzwert interpretieren, wenn angeboten.