

# In 5 Tagen zur 1,x in Statistik

Dein Lernbuch zum Mitlesen und Mitdenken – für Klausurteil A (Statistik, schriftlich) und Klausurteil B (R am Computer).  
In einfachem Deutsch, mit Beispielen, Fragen und Lösungen.

## Tag 1

Daten  
beschreiben:  
deskriptive  
Statistik

## Tag 2

Wahrscheinlichkeit  
& Zufallsvariablen

## Tag 3

Verteilungen &  
Maximum-  
Likelihood

## Tag 4

Schätzer,  
Konfidenzintervalle,  
Tests

## Tag 5

R-Klausur (Teil B)  
& Generalprobe

Grundlage: Vorlesungen SDS1-V01 bis V13, Tutorien 1–13, Testate 0–6, Probeklausuren Teil A und Teil B, Übungen zur ML-Schätzung.

Zu jedem Thema: einfache Erklärung → Aufgabentypen mit Musterlösung → Übe selbst → Klausurtraining.

## 0.1 Willkommen! So benutzt du dieses Buch

Hallo! Schön, dass du da bist. In den nächsten fünf Tagen lernen wir zusammen alles, was du für die Statistik-Klausur brauchst. Wir fangen ganz vorne an. Du musst nichts vorher wissen. Wir gehen Schritt für Schritt.

Du lernst nur mit diesem Buch: **lesen, dann selbst rechnen**. Jedes Thema hat vier Stufen:

1. **Erklärung** in einfachem Deutsch, mit Beispielen und – wo es schwierig wird – einer Erklärung auf Türkisch (oranger Kasten).
2. **Aufgabentypen-Katalog** (blaue Kästen „Typ 1“, „Typ 2“ ...): Jede Aufgabenart aus Klausuren, Testaten und Tutorien – mit Erkennungszeichen, Rezept und vollständig gerechnetem Musterbeispiel.
3. **Übe selbst** (gestrichelte Kästen): neue Zahlen, gleicher Typ. Lösungen am Ende des Tages.
4. **Klausurtraining** (grüne Kästen): eine Situation mit Teilaufgaben (a), (b), (c) ... und Punkten – genau wie in der Klausur.

### SO LERNST DU AM BESTEN

1. **Langsam lesen:** Lies jeden Abschnitt einmal ganz. Unterstreiche Formeln und Wörter, die neu sind (Wörterliste am Ende des Tages).
2. **Lösung abdecken:** Bei jedem Musterbeispiel erst selbst rechnen, dann vergleichen. Nur Lesen bringt keine Punkte.
3. **Klausurtraining:** Nach jedem Thema kommt eine Aufgabe im Stil der echten Klausur (grüner Rahmen, Teilaufgaben (a), (b), (c) ... mit Punkten). Dazu kurze Kontrollfragen (lila). Alle Lösungen stehen am Ende des Tages.
4. **R am Computer:** Im Ordner *uebungsdaten* liegt *Taverne.csv*. Damit tippst du jeden R-Befehl selbst.
5. **Rechnen:** Rechne die Klausuraufgaben selbst mit Stift und Taschenrechner. Erst danach schaust du in die Lösung.
6. **Formelblatt:** Schreibe jeden Tag die wichtigen Formeln auf dein eigenes A4-Blatt (siehe Anhang). In der Klausur darfst du ein handgeschriebenes Blatt pro Klausurteil benutzen!

### Die Kästen in diesem Buch

#### MERKE

Das Wichtigste in einem Satz. Unbedingt lernen.

#### FORMEL

Diese Formel kommt auf dein Formelblatt.

#### BEISPIEL

Eine Aufgabe, Schritt für Schritt gerechnet.

#### ACHTUNG – TYPISCHER FEHLER

Hier machen viele Studierende Fehler.

#### KLAUSUR-TIPP

So holst du in der Klausur die Punkte.

#### R-ECKE

Der passende R-Code für Klausurteil B.

#### KONTROLLFRAGEN

Kurze Fragen zum Selbsttest.

#### TÜRKÇE AÇIKLAMA

Zor yerlerde Türkçe açıklama.

### Klausurtraining

### Punkte

Aufgabe im Klausurstil: Situation + Teilaufgaben (a), (b), (c) ...

### Typ 7 Aufgabentyp mit Musterlösung

**So erkennst du ihn:** typische Formulierung aus Klausur/Testat/Tutorium

**Rezept** → **Musterbeispiel** → **Lösung** (erst abdecken und selbst rechnen!)

#### Übe selbst · Zusatzübungen

Neue Zahlen zum gleichen Typ. Lösungen am Ende des Tages.

## 0.2 Die Klausur: Was genau kommt dran?

Die Klausur hat **zwei Teile**. Du schreibst sie am selben Tag, zuerst Teil A, dann Teil B.

|                   | Teil A: Statistik                                                                                                                                                                                 | Teil B: R                                                                                                                                                                                                             |
|-------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Ort               | Hörsaal, auf Papier                                                                                                                                                                               | E-Prüfungsraum, am Computer (ILIAS + RStudio)                                                                                                                                                                         |
| Zeit              | 100 Minuten                                                                                                                                                                                       | 60 Minuten                                                                                                                                                                                                            |
| Punkte            | 75 Punkte                                                                                                                                                                                         | 45 Punkte                                                                                                                                                                                                             |
| Hilfsmittel       | 1 handgeschriebenes A4-Blatt (beidseitig) <b>pro Teil</b> , nicht-programmierbarer Taschenrechner mit Sticker, Kugelschreiber (kein Bleistift, nicht grün/rot)                                    |                                                                                                                                                                                                                       |
| Typische Aufgaben | Skalenniveau, Lage- und Streuungsmaße, Verteilungsfunktion zeichnen, Bayes/totale Wahrscheinlichkeit, Korrelation, ML-Schätzer herleiten, Erwartungstreue prüfen, Hypothesentest, R-Output deuten | Daten einlesen, Objekttypen, Mittelwert/SD, Histogramm als PDF speichern, Likelihood mit <code>dpois / prod</code> , eigene Funktion und for-Schleife, <code>nlm</code> , <code>pgamma / qgamma</code> , Antwortsätze |

### RUNDUNGSREGELN (SEHR WICHTIG FÜR DIE PUNKTE!)

- **Zwischenergebnisse:** mindestens **4** Nachkommastellen.
- **Endergebnisse:** **3** Nachkommastellen (kaufmännisch runden) – oder ein gekürzter Bruch.
- Ausnahmen: ganze Zahlen; „schöne“ Ausdrücke wie  $\sqrt{2}$  oder  $\log 4$ ; andere Anweisung in der Aufgabe.
- Dezimal**punkt** benutzen: 0.125 (nicht 0,125).
- In Teil B immer mit R runden: `round(x, 3)`.

### Wie bekommst du eine 1,x?

Eine sehr gute Note bekommst du, wenn du die **Standardaufgaben sicher und schnell** löst. Die Klausuraufgaben sind jedes Jahr sehr ähnlich. Wenn du die Probeklausuren, die Testate und die Tutorien verstehst, bist du vorbereitet. Genau darauf ist dieses Buch aufgebaut. Für Teil A hast du ungefähr **1,3 Minuten pro Punkt**. Für Teil B hast du ungefähr **1,3 Minuten pro Punkt**. Also: nicht lange an einer Aufgabe hängen bleiben!

## 0.3 Dein 5-Tage-Plan

Jeder Tag hat etwa **7–8 Stunden** Lernzeit mit Pausen. Mache nach 50 Minuten immer 10 Minuten Pause. Schlafe genug – im Schlaf speichert dein Gehirn das Gelernte.

| Tag          | Themen (Vorlesung)                                                                                                                                                                                                                                         | So arbeitest du                                                                                                                                                                                         |
|--------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Tag 1</b> | Grundbegriffe, Skalenniveaus, Stichproben (V01) · Häufigkeiten, Histogramm, Verteilungsfunktion, Lage- und Streuungsmaße, Quantile, Boxplot (V02) · Kontingenztafel, $\chi^2$ -Koeffizient, Kovarianz, Korrelation, Kausalität (V03) · <b>R-Grundlagen</b> | Vormittag: 1.1–1.6 lesen, Aufgabentypen 1–30 rechnen. Nachmittag: 1.7–1.8 (Typ 31–45), R-Kurs 1.9 am Computer (Typ 46–54), Generalprobe K1.                                                             |
| <b>Tag 2</b> | Mengen, Laplace, Kolmogorov, Rechenregeln, bedingte Wahrscheinlichkeit, Unabhängigkeit, totale Wahrscheinlichkeit, Bayes (V04) · Zufallsvariablen, Dichte, Verteilungsfunktion, Erwartungswert, Varianz, Rechenregeln, bivariate Verteilungen (V05, V06)   | Vormittag: Wahrscheinlichkeit (2.1–2.5), Baumdiagramme zeichnen. Nachmittag: Zufallsvariablen (2.6–2.9), Integrale üben, Testat 3 und 4 nachrechnen.                                                    |
| <b>Tag 3</b> | Bernoulli, Binomial, Poisson, Gleich-, Exponential-, Normalverteilung, Standardisieren, zentraler Grenzwertsatz, R-Funktionen d/p/q/r (V07) · <b>Maximum-Likelihood</b> (V08)                                                                              | Vormittag: Verteilungen (3.1–3.5). Nachmittag: ML-Rezept (3.6–3.8) und <b>alle</b> ML-Übungsaufgaben selbst herleiten. ML bringt in Teil A ca. 10 Punkte!                                               |
| <b>Tag 4</b> | Bias, Varianz, MSE, Konsistenz, Histogramm und Kerndichte (V09) · Konfidenzintervalle (V10) · Hypothesentests, p-Wert, z-/t-/ $\chi^2$ -/Binomialtest, Vorzeichentest, $\chi^2$ -Unabhängigkeit, Anpassungstest (V11, V12) · Regression (V13)              | Vormittag: Schätzer + KI (4.1–4.4). Nachmittag: Tests (4.5–4.9). Abends: Testat 5 und 6.                                                                                                                |
| <b>Tag 5</b> | <b>Klausurteil B:</b> kompletter R-Ablauf, Witcher-Klausur, Lungenvolumen-Klausur (nlm) · <b>Generalprobe Teil A</b> (Probeklausur 04.03.2022) · Formelblatt fertig machen                                                                                 | Vormittag: Tag 5 lesen + R-Probeklausuren am Computer (auf Zeit: 60 Min.). Nachmittag: Probeklausur A auf Zeit (100 Min.), danach Korrektur mit Lösungen. Abends: Formelblatt schreiben, früh schlafen. |

### EHRLICH GESAGT

Fünf Tage sind kurz. Das schaffst du nur, wenn du wirklich aktiv arbeitest: selbst rechnen, selbst R-Code tippen. Nur Lesen reicht nicht für eine 1,x. Das Buch erklärt dir alles – aber die Punkte holst du mit dem Stift und an der Tastatur.

## Inhalt

### Tag 1 · Daten beschreiben

1.1 Grundbegriffe · 1.2 Merkmalstypen & Skalen · 1.3 Stichproben · 1.4 Häufigkeiten, Histogramm, Verteilungsfunktion · 1.5 Lagemaße · 1.6 Quantile, Streuung, Boxplot · 1.7 Kontingenztafel &  $\chi^2$  · 1.8 Kovarianz & Korrelation · 1.9 R-Kurs von null an · 1.10 Antworten formulieren · Klausurtraining 1.A–1.H · Generalprobe K1 · Lösungen

### Tag 2 · Wahrscheinlichkeit

2.1 Zufallsexperiment & Mengen · 2.2 Wahrscheinlichkeit & Regeln · 2.3 Bedingte W. & Unabhängigkeit · 2.4 Totale W. & Bayes · 2.5 Zufallsvariablen · 2.6 Dichte & Verteilungsfunktion · 2.7 Erwartungswert & Varianz · 2.8 Zwei Zufallsvariablen · Klausuraufgaben · Lösungen

### Tag 3 · Verteilungen & ML

3.1 Bernoulli & Binomial · 3.2 Poisson · 3.3 Gleich- & Exponentialverteilung · 3.4 Normalverteilung · 3.5 Zentraler Grenzwertsatz & R · 3.6 Idee der Likelihood · 3.7 Das ML-Rezept · 3.8 ML-Training · Klausuraufgaben · Lösungen

### Tag 4 · Inferenz

4.1 Gütekriterien von Schätzern · 4.2 Erwartungstreue prüfen · 4.3 Histogramm & Kerndichte · 4.4 Konfidenzintervalle · 4.5 Testprinzip · 4.6 Tests für  $\mu$  · 4.7 Varianz-, Binomial-, Vorzeichentest · 4.8  $\chi^2$ -Tests · 4.9 R-Output lesen & Regression · Klausuraufgaben · Lösungen

## **Tag 5 · R-Klausur & Generalprobe**

5.1 So läuft Teil B ab · 5.2 Einlesen & Objekttypen · 5.3  
Kennzahlen & Grafiken · 5.4 Likelihood in R · 5.5 Funktionen,  
Schleifen, paste · 5.6 nlm & Transformation · 5.7  
Probeklausur B komplett · 5.8 Generalprobe Teil A · 5.9  
Letzte Tipps

## **Anhang**

Formelblatt-Vorlage Teil A · R-Spickzettel Teil B · Wichtige  
Quantile · Wörterliste Deutsch–Türkçe

# Daten beschreiben: deskriptive Statistik

Heute lernst du die Sprache der Statistik: wie man Daten ordnet, zeichnet und mit wenigen Zahlen beschreibt – für ein Merkmal und für zwei Merkmale zusammen. Danach lernst du R von Anfang an, Befehl für Befehl. Nach jedem Thema kommt ein **Klausurtraining** im Stil der echten Klausur.

Skalenniveau

Stichproben

Histogramm

Verteilungsfunktion

Mittelwert &amp; Median

Quantile

Varianz

Boxplot

Kontingenztafel

Korrelation

R-Kurs

| Zeit        | Was du machst                                                                                                                   |
|-------------|---------------------------------------------------------------------------------------------------------------------------------|
| 08:30–10:30 | <b>Lesen</b> 1.1–1.3 · Musterbeispiele Typ 1–6 mit abgedeckter Lösung nachrechnen · Z1 · Klausurtraining 1.A                    |
| 10:45–13:15 | <b>Lesen</b> 1.4–1.6 · Typ 7–30 (erst selbst rechnen, dann Lösung aufdecken) · Z2–Z4 · Klausurtraining 1.B–1.E                  |
| 14:15–16:15 | <b>Lesen</b> 1.7–1.8 · Typ 31–45 · Z5–Z6 · Klausurtraining 1.F–1.G                                                              |
| 16:30–18:30 | <b>R-Kurs 1.9</b> am Computer: jeden Befehl selbst tippen ( <code>Taverne.csv</code> ) · Typ 46–54 · Z7 · R-Klausurtraining 1.H |
| 18:45–20:00 | Generalprobe K1 auf Zeit · Fehlerliste schreiben · Formelblatt Tag 1                                                            |

## SO ARBEITEST DU MIT DEN AUFGABENTYPEN (BLAUE KÄSTEN „TYP ...“)

Jeder Typ ist eine Aufgabenart, die in Klausur, Testat oder Tutorium schon vorkam. (1) Lies „So erkennst du ihn“ und das **Rezept**. (2) **Decke die Lösung mit einem Blatt ab** und rechne das Musterbeispiel selbst. (3) Vergleiche Schritt für Schritt. (4) Falsch? Schreib den Fehler in deine **Fehlerliste** und rechne das Beispiel am Abend noch einmal. Die gestrichelten Kästen „Übe selbst“ sind neue Zahlen zum gleichen Typ – Lösungen am Ende von Tag 1.

### TÜRKÇE AÇIKLAMA

Bu kitap artık dinlemeden, **okuyarak ve çözererek** çalışmak için tasarlandı. Her konu: açıklama → soru tipleri (Typ) → kendi başına alıştırma (Z) → sınav formatında Klausurtraining. Çözümü okumadan önce **mutlaka** kendin dene; sınavda puanı getiren şey elinle yazdığın çözüm yolu.

## WIE DU MIT DEM KLAUSURTRAINING ARBEITEST

Die grünen Kästen „Klausurtraining“ sind wie echte Klausuraufgaben gebaut: Zuerst kommt eine Situation, dann Teilaufgaben (a), (b), (c) ... mit Punkten. Rechne sie **auf Papier**, mit Lösungsweg, und stoppe die Zeit (1 Punkt ≈ 1.3 Minuten). Alle Lösungen stehen ausführlich am Ende von Tag 1.

## 1.1 Grundbegriffe der Statistik

Statistik beschreibt und analysiert **Daten**. Bevor wir rechnen, brauchen wir ein paar Wörter. Wir lernen sie an zwei Beispielen aus der Vorlesung.

| Begriff                                | Bedeutung                                                  | Beispiel 1: Wahlumfrage                           | Beispiel 2: Politikmaßnahme                                 |
|----------------------------------------|------------------------------------------------------------|---------------------------------------------------|-------------------------------------------------------------|
| <b>statistische Einheit</b>            | das Objekt, an dem wir etwas messen                        | eine wahlberechtigte Person                       | eine Firma                                                  |
| <b>Grundgesamtheit</b><br>(Population) | alle Einheiten, die für die Frage wichtig sind             | alle Wahlberechtigten der nächsten Bundestagswahl | alle Firmen, die von der Maßnahme betroffen sind            |
| <b>Stichprobe</b>                      | der Teil der Grundgesamtheit, den wir wirklich untersuchen | die befragten Personen                            | Firmen, für die wir Emissionsdaten vorher und nachher haben |
| <b>Merkmal</b> (Variable) $X$          | die Eigenschaft, die wir messen (Großbuchstabe)            | Alter, Geschlecht, Partei                         | Emissionen in Tonnen                                        |
| <b>Merkmalsausprägung</b> $x$          | der konkrete Wert bei einer Einheit (Kleinbuchstabe)       | 23 Jahre; SPD                                     | 1250 Tonnen                                                 |

Die Grundgesamtheit kann auch **hypothetisch** sein: zum Beispiel „alle Güter, die eine Firma produziert“ oder „alle Felder, auf denen ein Dünger jemals eingesetzt werden könnte“.

#### Deskriptive Statistik (heute)

Wir **beschreiben** die Daten, die wir haben: Tabellen, Grafiken, Kennzahlen. Keine Aussage über andere Einheiten.

#### Induktive Statistik (Tag 3 + 4)

Wir **schließen** von der Stichprobe auf die Grundgesamtheit und geben die **Unsicherheit** an (Schätzer, Konfidenzintervalle, Tests).

#### MERKE

Meistens kennen wir nur eine **Stichprobe**. Die zentrale Aufgabe der (induktiven) Statistik ist: von der Stichprobe auf die **Grundgesamtheit** schließen – und dabei die **Unsicherheit** berücksichtigen.

## Versuchsplanung und Störvariablen

Eine Studie plant man vorher: Ziel festlegen, statistische Methoden auswählen, Datenerhebung planen, verbindliche Regeln festlegen. **Störvariablen** sind Merkmale, die das Ergebnis auch beeinflussen, die uns aber gerade nicht interessieren.

#### BEISPIEL (V01): NEUE LEHRMETHODE

Wir wollen wissen: Lernen Studierende mit einer neuen didaktischen Maßnahme besser? Der Lernerfolg hängt aber auch von **Alter, Vorwissen, Lernverhalten** ab. Das sind Störvariablen. Drei Wege, sie zu kontrollieren:

- **Homogenisierung:** die Grundgesamtheit in Teilgruppen zerlegen, die durch die Störvariablen festgelegt sind (z. B. nur Erstsemester mit gleichem Vorwissen vergleichen).
- **Randomisierung:** Personen **zufällig** in eine Gruppe mit und eine Gruppe ohne Maßnahme einteilen. Dann sind Vorwissen usw. in beiden Gruppen im Mittel gleich.
- **Statistische Modellierung:** die Störvariablen in der Rechnung berücksichtigen (z. B. Regression).

**Kreislauf der Datenanalyse:** Planung → Datenerhebung → Aufbereitung und Prüfung der Daten → Datenanalyse → Interpretation → Publikation von Daten und Code → Wiederverwendung.

## 1.2 Merkmalstypen und Skalenniveaus

Diese Frage kommt in fast jeder Klausur (Probeklausur A: Aufgabe 1a und 2a = 5 Punkte; Testat 1: Aufgabe 1). Es sind **leichte Punkte** – wenn man die Regeln genau kennt.

### Frage 1: Diskret oder stetig?

**diskret:** endlich viele oder **abzählbar** unendlich viele Werte. „Abzählbar“ heißt: Man kann die Werte durchnummerieren: 0, 1, 2, 3, ...

Beispiele: Anzahl Likes, Anzahl Mensabesuche, Anzahl Geschwister, Partei, Studienfach, Note, Alter in **ganzen** Jahren

**stetig: überabzählbar** viele Werte. Jede reelle Zahl in einem Intervall ist möglich; zwischen zwei Werten gibt es immer noch weitere.

Beispiele: Körpergröße, Gewicht, Zeit, Liter, Temperatur, Einkommen in Euro, Gewinn einer Firma, BIP

In der Praxis ist es nicht immer klar: Stetige Merkmale misst man mit begrenzter Genauigkeit (Körpergröße in ganzen cm), behandelt sie aber trotzdem als **stetig** („quasi-stetig“). Umgekehrt kann man stetige Merkmale in Klassen einteilen (Altersgruppen) – das nennt man **Kategorisierung**.

### Frage 2: Welches Skalenniveau?

| Skala                         | Was kann man machen?                                             | Beispiele                                                                         | Häufigkeiten | Reihenfolge | Differenzen / Quotienten |
|-------------------------------|------------------------------------------------------------------|-----------------------------------------------------------------------------------|--------------|-------------|--------------------------|
| <b>nominal</b>                | nur Namen / Kategorien, keine Ordnung                            | Partei, Nationalität, Mensastandort, Herkunft (BY/NRW), Blutgruppe, Postleitzahl  | ja           | nein        | nein                     |
| <b>ordinal</b>                | man kann sortieren, aber Abstände sind nicht sinnvoll            | Schulnoten, Zufriedenheit 1–7, Hotelsterne, Rang im Wettkampf, Kleidergröße S/M/L | ja           | ja          | nein                     |
| <b>kardinal</b><br>(metrisch) | echte Zahlen mit sinnvollen Abständen (meist auch Verhältnissen) | Alter, Einkommen, Körpergröße, Punkte 0–100, Anzahl, Liter                        | ja           | ja          | ja                       |

#### ENTSCHEIDUNGSWEG IN 3 FRAGEN

- 1 Sind die Werte nur **Namen**, die man nicht sinnvoll sortieren kann? → **nominal**. (Vorsicht: Auch Zahlen können nur Namen sein – eine Postleitzahl ist nominal! „37073 minus 37085“ hat keine Bedeutung.)
- 2 Kann man sortieren, aber ist der **Abstand** zwischen zwei Stufen nicht klar gleich groß? → **ordinal**.
- 3 Kann man sinnvoll **rechnen** („5 mehr“, „doppelt so viel“)? → **kardinal**. Dann noch: Kann man durchzählen? → diskret. Jede Zahl im Intervall möglich? → stetig.

Zusatzwissen: Kardinale Merkmale mit echtem Nullpunkt (Einkommen, Liter) heißen auch **Verhältnisskala** („doppelt so viel“ ist sinnvoll). Die Musterlösung der Probeklausur schreibt bei „Liter Bier“: „metrisch skaliert (Verhältnisskala)“.

#### ACHTUNG – DIE 4 HÄUFIGSTEN FEHLER

- Eine Skala „von 1 bis 5“ oder „von 1 bis 7“ (Zufriedenheit) ist **ordinal**, nicht kardinal – auch wenn es Zahlen sind!
- Punkte in einem Test (0–100) sind **kardinal**: 80 Punkte sind 20 Punkte mehr als 60.
- Ein 0/1-Merkmal (richtig/falsch, ja/nein) ist **nominal** (binär). Den Mittelwert darf man trotzdem berechnen: er ist der **Anteil** der Einsen.
- „Diskret“ heißt nicht „endlich“: Auch abzählbar unendlich viele Werte (0, 1, 2, ... ohne obere Grenze) sind diskret. (Tutorium 1: Autos an der Autobahn zählen – es gibt keine halben Autos.)

### ÜBUNG MIT LÖSUNG: 10 MERKMALE

| Merkmal                                 | Skala                 | diskret/stetig | Begründung                          |
|-----------------------------------------|-----------------------|----------------|-------------------------------------|
| Alter in ganzen Jahren                  | kardinal              | diskret        | Abstände sinnvoll; nur ganze Zahlen |
| Anzahl Mensabesuche letzte Woche        | kardinal              | diskret        | Zählvariable                        |
| Präferierter Mensastandort              | nominal               | diskret        | nur Namen                           |
| Zufriedenheit 1 bis 7                   | ordinal               | diskret        | Reihenfolge ja, Abstände unklar     |
| Monatseinkommen in Euro                 | kardinal              | stetig         | sehr viele Werte, quasi-stetig      |
| Liter Bier (Probeklausur)               | kardinal (Verhältnis) | stetig         | Messwert                            |
| Herkunft BY / NRW (Probeklausur)        | nominal               | diskret        | zwei Kategorien                     |
| Vorhersage korrekt (0/1) (Probeklausur) | nominal (binär)       | diskret        | nur zwei Kategorien                 |
| Schulnote 1–6                           | ordinal               | diskret        | „1 besser als 2“, Abstände unklar   |
| Laufzeit für 7.5 km in Minuten          | kardinal              | stetig         | Zeit                                |

### WARUM IST DAS SKALENNIVEAU SO WICHTIG?

Es bestimmt, **welche Rechnungen erlaubt sind**: Bei nominalen Daten nur Häufigkeiten und Modus; bei ordinalen Daten zusätzlich Median und Quantile; bei kardinalen Daten auch Mittelwert, Varianz, Korrelation. Genau das wird in der Klausur gefragt: „Falls ein Parameter nicht sinnvoll angegeben werden kann, begründen Sie kurz.“

### 1.3 Wie zieht man eine Stichprobe?

Eine gute Stichprobe ist **repräsentativ**: Sie hat keine systematischen Unterschiede zur Grundgesamtheit. Zwei Probleme können passieren: (1) Die Stichprobe enthält Einheiten, die **nicht** zur Grundgesamtheit gehören. (2) Nicht alle Einheiten der Grundgesamtheit haben eine Chance, in die Stichprobe zu kommen (z. B. Online-Umfrage: Menschen ohne Internet fehlen).

| Verfahren                                    | Wie?                                                                                                                    | Vorteil / Voraussetzung                                                                                                         | Bild                                   |
|----------------------------------------------|-------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------|----------------------------------------|
| <b>Einfache Zufallsstichprobe</b>            | Ziehen ohne Zurücklegen aus der Liste aller Einheiten; jede Einheit und jede mögliche Stichprobe hat die gleiche Chance | nur zufällige, keine systematischen Unterschiede; man braucht eine vollständige Liste                                           | Lostopf mit allen Namen                |
| <b>Geschichtete Stichprobe</b>               | Grundgesamtheit in Gruppen (Schichten) teilen, dann in <b>jeder</b> Schicht zufällig ziehen                             | jede Gruppe ist sicher passend vertreten (oder gezielt überrepräsentiert); Anteile und Gruppenzugehörigkeit müssen bekannt sein | ein Lostopf pro Studiengang            |
| <b>Klumpenstichprobe</b>                     | zufällig ganze Klumpen ziehen (Schulklassen, Straßen, Familien, Orte), darin alle oder viele befragen                   | billig und einfach; innerhalb der Klumpen soll das Merkmal stark variieren, die Klumpen untereinander ähnlich sein              | 3 zufällige Schulklassen komplett      |
| <b>Quotenverfahren</b><br>(bewusste Auswahl) | vorher festgelegte Quoten müssen erfüllt sein                                                                           | Umfragen „repräsentativ für Bevölkerungsgruppen“                                                                                | Interviewer sucht 50 Frauen, 50 Männer |

#### GESCHICHTET ODER KLUMPEN? DER WICHTIGE UNTERSCHIED

**Geschichtet**: Wir ziehen aus **allen** Gruppen, aber in jeder Gruppe nur einige Personen. **Klumpen**: Wir ziehen nur **einige** Gruppen, aber in diesen Gruppen (fast) alle Personen. Im Tutorium war der häufige Fehler: „geschichtet“ zu sagen, obwohl nur Göttinger Schulen (= ein Klumpen) getestet wurden.

#### BEISPIELE AUS TUTORIUM 1 UND TESTAT 1

- Leistungen aller Zehntklässler in Deutschland, getestet an Schulen in Göttingen → **Klumpenstichprobe**.
- Öffentlich-rechtliche Sender: Umfrage, die repräsentativ für die Bevölkerungsgruppen sein soll → **Quotenverfahren** oder **geschichtete Stichprobe**. (Fehler: „repräsentativ“ überlesen und „einfache Zufallsstichprobe“ sagen.)
- Der Anteil jedes Studiengangs in der Stichprobe soll dem Anteil an allen Studierenden entsprechen → **geschichtete Stichprobe / Quotenverfahren**.

#### KONTROLLFRAGEN 1.1 – 1.3 (KURZ)

- Was ist der Unterschied zwischen deskriptiver und induktiver Statistik?
- Richtig oder falsch? „Ein diskretes Merkmal kann nur endlich viele Werte annehmen.“ Korrigiere den Satz.
- Eine Studie teilt Personen per Münzwurf in eine Gruppe mit und eine ohne neues Medikament. Wie heißt diese Methode und warum ist sie gut?

#### Aufgabentypen-Katalog 1.1 – 1.3 · So kommen diese Themen in der Klausur vor

Jeder Typ hat: **So erkennst du ihn** (typische Formulierung in der Klausur) → **Rezept** (Schritte) → **Musterbeispiel** (komplett gelöst). Lies das Musterbeispiel, decke dann die Lösung ab und löse es selbst noch einmal.

### Typ 1 Skalenniveau und diskret/stetig bestimmen

**So erkennst du ihn:** „Geben Sie für X und Y an, ob ein diskretes oder stetiges Merkmal vorliegt. Welches Skalenniveau liegt jeweils zugrunde?“ (Probeklausur A 2a, 4 P) · „Wählen Sie das korrekte Skalenniveau aus“ (Testat 1)

**Rezept:** (1) Sind die Werte nur Namen? → nominal. (2) Sortierbar, Abstände unklar? → ordinal. (3) Sinnvoll rechnen („5 mehr“)? → kardinal. (4) Durchzählbar? → diskret; jede Zahl in einem Intervall möglich (Zeit, Geld, Gewicht, Länge, Volumen)? → stetig. (5) Einen kurzen Grund dazuschreiben.

**Musterbeispiel:** Eine Autovermietung erfasst: (a) Kilometerstand, (b) Automarke, (c) Kundenbewertung 1–5 Sterne, (d) Anzahl der Mietvorgänge pro Kunde, (e) Kennzeichen, (f) Tankfüllung in Litern.

| Merkmal                   | Skala    | diskret/stetig | Grund (1 Satz reicht)                                                  |
|---------------------------|----------|----------------|------------------------------------------------------------------------|
| (a) Kilometerstand        | kardinal | stetig         | Strecke kann jeden Wert annehmen, Abstände sinnvoll                    |
| (b) Automarke             | nominal  | diskret        | nur Namen, keine Ordnung                                               |
| (c) Sterne 1–5            | ordinal  | diskret        | sortierbar, Abstände zwischen den Sternen nicht gleich interpretierbar |
| (d) Anzahl Mietvorgänge   | kardinal | diskret        | Zählvariable                                                           |
| (e) Kennzeichen           | nominal  | diskret        | Buchstaben/Zahlen sind nur Namen                                       |
| (f) Tankfüllung in Litern | kardinal | stetig         | Messwert (Volumen)                                                     |

#### TÜRKÇE AÇIKLAMA

Kısa yol: **Sayabiliyorsan** (0, 1, 2 ...) kesikli (diskret), **ölçüyorsan** (süre, para, ağırlık, uzunluk, litre) sürekli (stetig). Rakam olması kardinal olduğu anlamına gelmez: posta kodu, plaka ve hane numarası **nominal**; 1–5 yıldız ya da not **ordinal**.

### Typ 2 Welche Lagemaße / Kennzahlen sind sinnvoll?

**So erkennst du ihn:** „Falls Sie der Meinung sind, dass ein Parameter nicht sinnvoll angegeben werden kann, begründen Sie kurz“ (Probeklausur A 1b) · „Welches Lagemaß kann benutzt werden, um ... zu beschreiben?“ (Testat 1, Aufgabe 3)

**Rezept:** Skalenniveau bestimmen → Tabelle anwenden: nominal: nur Modus · ordinal: Modus, Median, Quantile · kardinal: alles (Mittelwert, Varianz, Korrelation ...). Ausnahme: 0/1-Merkmal → Mittelwert = Anteil ist sinnvoll.

**Musterbeispiel (Testat 1):** Welche Lagemaße beschreiben (1) den präferierten Mensastandort, (2) die Zufriedenheit auf einer Skala 1–7?

**Lösung:** (1) Mensastandort ist nominal → nur der **Modus**. Median und Mittelwert sind nicht sinnvoll, weil sich Standorte nicht ordnen lassen. (2) Zufriedenheit ist ordinal → **Modus und Median**. Der Mittelwert ist streng genommen nicht sinnvoll, weil die Abstände zwischen den Stufen nicht interpretierbar sind.

**Mustersatz für „nicht sinnvoll“:** „Das arithmetische Mittel ist hier nicht sinnvoll, da das Merkmal nominal skaliert ist und sich die Ausprägungen nicht als Zahlen interpretieren lassen.“

### Typ 3 Richtig/falsch zu Grundbegriffen – Sätze korrigieren

**So erkennst du ihn:** „Formulieren Sie die folgenden Sätze derart um, dass sie korrekte Aussagen darstellen“ (Tutorium 1, Aufgabe 14) · Multiple-Choice im Testat

**Musterbeispiel mit Lösung (Tutorium 1):**

| Falsche Aussage                                                                    | Korrigierte Aussage                                                                                                                                       |
|------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------|
| Ein Modell ist die korrekte, fehlerfreie Wiedergabe der Realität.                  | Ein Modell ist eine <b>vereinfachte Beschreibung</b> der Realität.                                                                                        |
| Deterministische Modelle sind Modelle, deren Unsicherheit man quantifizieren kann. | In deterministischen Modellen gibt es <b>keine Unsicherheit</b> .                                                                                         |
| Ein diskretes Merkmal kann nur endlich viele Werte annehmen.                       | ... endlich oder <b>abzählbar unendlich</b> viele Werte.                                                                                                  |
| Quantitative Merkmale sind stets stetig.                                           | Quantitative Merkmale können <b>diskret oder stetig</b> sein.                                                                                             |
| Ein Merkmal mit endlich vielen Ausprägungen kann stetig sein.                      | Ein Merkmal mit endlich vielen Ausprägungen ist <b>diskret</b> .                                                                                          |
| Die Stichprobe ist immer repräsentativ für die Grundgesamtheit.                    | Eine Stichprobe <b>soll</b> repräsentativ sein; sie kann aber Einheiten außerhalb der Grundgesamtheit enthalten oder Teile der Grundgesamtheit auslassen. |

#### Typ 4 Stichprobenverfahren erkennen

**So erkennst du ihn:** „Welche Methode zum Ziehen der Stichprobe sollte angewandt werden?“ (Tutorium 1, Testat 1 Aufgabe 2)

**Rezept (Schlüsselwörter):** „zufällig aus der Liste aller“ → einfache Zufallsstichprobe · „Anteil jeder Gruppe soll stimmen“, „repräsentativ für Gruppen“, „Anteile bekannt“ → geschichtet (oder Quotenverfahren) · „ganze Klassen/Straßen/Orte/Kurse“, „nur in Göttingen“ → Klumpen · „Interviewer erfüllen feste Quoten“ → Quotenverfahren.

**Musterbeispiel:** Welches Verfahren liegt vor?

1. Die Uni zieht mit einem Zufallsgenerator 500 Namen aus der Liste aller 30 000 Studierenden. → **Einfache Zufallsstichprobe**.
2. Eine Umfrage soll 60 % Frauen und 40 % Männer enthalten, wie in der Grundgesamtheit; in jeder Gruppe wird zufällig gezogen. → **Geschichtete Stichprobe**.
3. Es werden zufällig 10 Göttinger Supermärkte gewählt und dort an einem Tag alle Kunden befragt. → **Klumpenstichprobe**.
4. Interviewer in der Fußgängerzone sollen je 50 Personen unter und über 40 Jahren befragen. → **Quotenverfahren**.

#### Typ 5 Einheit, Grundgesamtheit, Stichprobe, Merkmal benennen

**So erkennst du ihn:** „Benennen Sie die statistische Einheit und die Grundgesamtheit.“ · „Erläutern Sie die Unterschiede von Stichprobe und Grundgesamtheit.“

**Rezept:** Einheit = **ein** Objekt (Singular!). Grundgesamtheit = **alle** Einheiten, für die die Frage gilt (möglichst genau: Ort, Zeit). Stichprobe = die wirklich untersuchten Einheiten.

**Musterbeispiel:** Eine Krankenkasse untersucht bei 800 zufällig gewählten Versicherten aus Niedersachsen die Anzahl der Arztbesuche im Jahr 2025.

**Lösung:** Einheit: **eine versicherte Person**. Grundgesamtheit: alle Versicherten dieser Krankenkasse in Niedersachsen (im Jahr 2025). Stichprobe: die 800 ausgewählten Versicherten. Merkmal: Anzahl der Arztbesuche (kardinal, diskret).

## Typ 6 Störvariablen und Versuchsplanung

**So erkennst du ihn:** „Nennen Sie eine mögliche Störvariable ...“, „Wie kann man ... kontrollieren?“, „Ist eine kausale Aussage zulässig?“ (Testat 1, Aufgabe 6)

**Musterbeispiel:** Ein Forschungsteam will prüfen, ob Kaffee die Konzentration verbessert. Es vergleicht Studierende, die morgens Kaffee trinken, mit Studierenden, die keinen Kaffee trinken. (a) Nennen Sie zwei Störvariablen. (b) Wie kann man sie kontrollieren?

**Lösung:** (a) z. B. **Schlafdauer**, **Alter**, Vorwissen, Tageszeit. (b) Am besten **Randomisierung**: Die Personen werden zufällig (z. B. per Los) einer Kaffee- oder einer Wasserguppe zugeteilt; dann sind die Störvariablen im Mittel in beiden Gruppen gleich. Alternativ Homogenisierung (nur Personen mit ähnlicher Schlafdauer vergleichen) oder statistische Modellierung.

### TÜRKÇE AÇIKLAMA

Störvariable = karıştırıcı değişken: sonucu etkileyen ama asıl sorumuz olmayan değişken. **Randomisierung** (rastgele atama) bu değişkenleri iki gruba eşit dağıttığı için en iyi yöntemdir. Deney yoksa sadece “ilişki” denir, “neden” denemez.

### Übe selbst · Zusatzübungen Z1 (Lösungen am Ende von Tag 1)

- Bestimme Skalenniveau und diskret/stetig: (a) Hausnummer, (b) Wohnfläche in m<sup>2</sup>, (c) Energieeffizienzklasse A+++ bis G, (d) Bundesland, (e) Anzahl Zimmer, (f) Pulsfrequenz pro Minute.
- Welches Verfahren? (a) Aus jedem der 5 Göttinger Stadtteile werden zufällig 100 Haushalte gezogen. (b) Aus dem Einwohnerregister werden zufällig 1000 Personen gezogen. (c) Es werden zufällig 3 Schulen gewählt und alle Lehrkräfte befragt.
- Richtig oder falsch? (a) „Mit Randomisierung kann man Störvariablen kontrollieren.“ (b) „Für die Energieeffizienzklasse ist der Mittelwert sinnvoll.“ (c) „Die Grundgesamtheit ist immer eine real existierende, endliche Menge.“

## Klausurtraining 1.A · Fitnessstudio

12 Punkte

Das Göttinger Fitnessstudio „FitGö“ hat 2400 Mitglieder. Die Leitung möchte das Angebot verbessern und plant eine Befragung. Für jedes befragte Mitglied sollen folgende Merkmale erhoben werden:

- Alter in ganzen Jahren
- Trainingsdauer pro Woche (in Stunden)
- Tarif (Basic, Premium, Student)
- Zufriedenheit (sehr unzufrieden, unzufrieden, neutral, zufrieden, sehr zufrieden)
- Anzahl der Besuche im letzten Monat
- Postleitzahl des Wohnorts

**(a)** Geben Sie für jedes der sechs Merkmale das Skalenniveau an und ob es diskret oder stetig ist. **(6 P)**

**(b)** Benennen Sie die statistische Einheit und die Grundgesamtheit. **(2 P)**

**(c)** Die Leitung weiß, dass 50 % der Mitglieder den Tarif Basic, 30 % Premium und 20 % Student haben. Jeder Tarif soll in der Stichprobe mit genau diesem Anteil vertreten sein. Welches Stichprobenverfahren ist

geeignet?

(1 P)

- (d)** Ein Mitarbeiter schlägt vor, zufällig 4 der 40 Kurse auszuwählen und alle Teilnehmenden dieser Kurse zu befragen. Wie heißt dieses Verfahren? Nennen Sie einen Vorteil.

(1 P)

- (e)** Richtig oder falsch? Begründen Sie jeweils kurz. (i) „Die durchschnittliche Postleitzahl ist eine sinnvolle Kennzahl.“ (ii) „Für die Zufriedenheit kann man den Median angeben.“

(2 P)

## 1.4 Häufigkeiten, Histogramm und Verteilungsfunktion

Wir haben Beobachtungen  $x_1, \dots, x_n$  ( $n$  = Stichprobenumfang). Die möglichen verschiedenen Werte heißen  $a_1 < a_2 < \dots < a_J$ .

### FORMEL: HÄUFIGKEITEN

$$h_j = \text{absolute Häufigkeit von } a_j \text{ (Anzahl)}, \quad f_j = \frac{h_j}{n} \text{ (relative Häufigkeit, Anteil)}, \quad \sum_j h_j = n, \quad \sum_j f_j = 1$$

$$H_j = h_1 + \dots + h_j \text{ (kumuliert absolut)}, \quad F_j = \frac{H_j}{n} = f_1 + \dots + f_j \text{ (kumuliert relativ)}$$

### BEISPIEL 1: MENSABESUCHE (IM STIL VON TESTAT 1)

| Besuche $a_j$ | 0     | 1      | 2      | 3    | 4      | $\Sigma$ |
|---------------|-------|--------|--------|------|--------|----------|
| $h_j$         | 3     | 5      | 8      | 6    | 2      | 24       |
| $f_j$         | 0.125 | 0.2083 | 0.3333 | 0.25 | 0.0833 | 1        |
| $H_j$         | 3     | 8      | 16     | 22   | 24     |          |

Stichprobengröße:  $n = 3 + 5 + 8 + 6 + 2 = 24$ . (Lage- und Streuungsmaße dazu in 1.5 und 1.6.)

### BEISPIEL 2 (TUTORIUM 2): SEMESTERZAHLEN VON N = 23 STUDIERENDEN

| Semester $a_j$ | 2    | 3    | 4     | 5     | 6     | 7     | $\Sigma$ |
|----------------|------|------|-------|-------|-------|-------|----------|
| $h_j$          | 1    | 7    | 5     | 5     | 1     | 4     | 23       |
| $f_j$          | 1/23 | 7/23 | 5/23  | 5/23  | 1/23  | 4/23  | 1        |
| $F_j$          | 1/23 | 8/23 | 13/23 | 18/23 | 19/23 | 23/23 |          |

(i) „mehr als 3“:  $1 - F(3) = 1 - \frac{8}{23} = \frac{15}{23}$ . (ii) „mindestens 3“:  $1 - F(2) = 1 - \frac{1}{23} = \frac{22}{23}$ . (iii) „kleiner als 4“:  $F(3) = \frac{8}{23}$ . (iv) „nicht größer als 5“:  $F(5) = \frac{18}{23}$ .

### ACHTUNG: WÖRTER GENAU ÜBERSETZEN (DISKRETE DATEN!)

| Wort                            | Zeichen  | Rechnung mit F             |
|---------------------------------|----------|----------------------------|
| höchstens 3, nicht größer als 3 | $\leq 3$ | $F(3)$                     |
| weniger als 3, kleiner als 3    | $< 3$    | $F(2)$ (bei ganzen Zahlen) |
| mindestens 3                    | $\geq 3$ | $1 - F(2)$                 |
| mehr als 3, größer als 3        | $> 3$    | $1 - F(3)$                 |



### Klassen bilden: Säulendiagramm oder Histogramm?

Stetige Daten haben (fast) alle verschiedene Werte. Deshalb bilden wir **Klassen** (Intervalle) wie  $[c_0, c_1]$ ,  $(c_1, c_2]$ ,  $\dots$ . Eine eckige Klammer  $[$  bedeutet „Grenze gehört dazu“, eine runde Klammer  $($  bedeutet „gehört nicht dazu“.

- **Säulendiagramm:** Die **Höhe** der Säule ist die Häufigkeit. Bei ungleich breiten Klassen sieht das **falsch** aus (breite Klassen wirken zu groß) – und das Bild hängt stark von der Klassenwahl ab.
- **Histogramm:** Die **Fläche** der Säule ist die relative Häufigkeit. Die Gesamtfläche ist **1**. In dieser Vorlesung der **Goldstandard** für stetige Merkmale.

### FORMEL: HÖHE IM HISTOGRAMM (DICHTE)

$$\text{Höhe}_j = \frac{f_j}{\text{Klassenbreite}_j} = \frac{h_j}{n \cdot (c_j - c_{j-1})} \Rightarrow \text{Fläche}_j = \text{Höhe}_j \cdot \text{Breite}_j = f_j$$




Gleiche Daten (Zimmergrößen, R-Skript V02), links Säulendiagramm, rechts Histogramm. Die breite Klasse (20,100] sieht links riesig aus – rechts ist sie richtig flach.

### BEISPIEL 3: EIN HISTOGRAMM SCHRITT FÜR SCHRITT BAUEN

20 Personen warten beim Arzt (Minuten, schon sortiert): 2, 3, 3, 4, 5, 5, 6, 7, 8, 9, 10, 11, 12, 14, 15, 18, 22, 25, 31, 38. Klassen: [0, 5), [5, 10), [10, 20), [20, 40).

| Klasse       | Werte darin            | $h_j$ | $f_j = h_j/20$ | Breite | Höhe = $f_j/\text{Breite}$ | Kontrolle Fläche     |
|--------------|------------------------|-------|----------------|--------|----------------------------|----------------------|
| [0, 5)       | 2, 3, 3, 4             | 4     | 0.2            | 5      | 0.04                       | $0.04 \cdot 5 = 0.2$ |
| [5, 10)      | 5, 5, 6, 7, 8, 9       | 6     | 0.3            | 5      | 0.06                       | 0.3                  |
| [10, 20)     | 10, 11, 12, 14, 15, 18 | 6     | 0.3            | 10     | 0.03                       | 0.3                  |
| [20, 40)     | 22, 25, 31, 38         | 4     | 0.2            | 20     | 0.01                       | 0.2                  |
| <b>Summe</b> |                        | 20    | 1              |        |                            | 1 ✓                  |



**Frage:** Welcher Anteil wartet zwischen 15 und 30 Minuten? Wir nehmen an, dass die Werte **innerhalb einer Klasse gleichmäßig verteilt** sind. Dann ist der Anteil = Fläche unter dem Histogramm von 15 bis 30:

$$\underbrace{(20 - 15) \cdot 0.03}_{\text{Teil von [10,20)}} + \underbrace{(30 - 20) \cdot 0.01}_{\text{Teil von [20,40)}} = 0.15 + 0.10 = 0.25$$

(In den echten Daten sind es 4 von 20 = 0.2 – das Histogramm liefert eine **Schätzung**.)

#### BEISPIEL 4 (TUTORIUM 2, AUFGABE 1): ANTEIL AUS EINER GRAFIK MIT ABSOLUTEN HÄUFIGKEITEN

20 Personen, Klassenbreite 5 cm; in (165,170] liegen 3 Personen, in (170,175] liegen 5 Personen. Gesucht: Anteil in (167, 172].

$$\underbrace{\frac{3}{5} \cdot \frac{3}{20}}_{(167,170]: 3 \text{ von } 5 \text{ cm}} + \underbrace{\frac{2}{5} \cdot \frac{5}{20}}_{(170,172]: 2 \text{ von } 5 \text{ cm}} = 0.09 + 0.10 = 0.19$$

Höhe im normierten Histogramm für (170,175]:  $\frac{5}{20 \cdot 5} = 0.05$ . Behauptet jemand „In einer Grundgesamtheit von 20 000 Personen sind genau 7 000 zwischen 175 und 180 cm“ (weil 7 von 20), ist das zu sicher: Eine Stichprobe von 20 Personen bildet die Grundgesamtheit nicht perfekt ab – das ist nur eine Schätzung.

#### MODALKLASSE – EINE FALLE AUS TESTAT 1

Die **Modalklasse** ist die Klasse mit der **größten Häufigkeit**. Ist sie „immer die Klasse mit der höchsten Säule im Histogramm“? **Nicht im Allgemeinen!** Bei ungleich breiten Klassen zeigt die Höhe die Dichte, nicht die Anzahl. Im Beispiel 3 haben [5,10) und [10,20) beide 6 Werte, aber [10,20) ist nur halb so hoch. Nur bei **gleich breiten** Klassen ist die höchste Säule die Modalklasse.

**Typen von Verteilungen** (am Histogramm erkennen): **unimodal** (ein Gipfel) oder **bimodal/multimodal** (zwei oder mehr Gipfel); **symmetrisch**, **rechtsschief** oder **linksschief** (siehe 1.5). Die Anzahl der Klassen wählt man mit Bedacht: zu wenige Klassen = zu grob, zu viele = zu zackig (Bias-Varianz-Abwägung, Tag 4).

#### Die empirische Verteilungsfunktion

##### FORMEL

$$\hat{F}(x) = \frac{\text{Anzahl der } x_i \leq x}{n} \quad (\text{Anteil der Werte, die höchstens } x \text{ sind})$$


Sie ist eine **Treppenfunktion**: Sie beginnt bei 0, springt an jedem beobachteten Wert  $a_j$  um  $f_j$  nach oben und endet bei 1. Sie ist nie fallend.

#### KLAUSURAUFGABE (PROBEKLAUSUR A, AUFGABE 2B, 6 PUNKTE!): BIERKONSUM

Daten (Liter): 8.5, 8.5, 4.0, 4.0, 12.0, 12.0, 8.5, 15.7, 4.0, 8.5. Also  $n = 10$ .

| Schritt             | 4.0 | 8.5 | 12.0 | 15.7 |
|---------------------|-----|-----|------|------|
| 1. Zählen $h_j$     | 3   | 4   | 2    | 1    |
| 2. Anteil $f_j$     | 0.3 | 0.4 | 0.2  | 0.1  |
| 3. Aufsummieren $F$ | 0.3 | 0.7 | 0.9  | 1.0  |

$$\hat{F}(x) = \begin{cases} 0 & x < 4 \\ 0.3 & 4 \leq x < 8.5 \\ 0.7 & 8.5 \leq x < 12 \\ 0.9 & 12 \leq x < 15.7 \\ 1 & x \geq 15.7 \end{cases}$$



**Ablesen:**  $\hat{F}(10) = 0.7$  heißt: 70 % der Gäste haben höchstens 10 Liter getrunken. Anteil „mehr als 10 Liter“ =  $1 - 0.7 = 0.3$ .

#### KLAUSUR-TIPP: SO BEKOMMST DU ALLE 6 PUNKTE BEIM ZEICHNEN

- Achsen beschriften (x-Achse mit Einheit, y-Achse  $\hat{F}(x)$ ) und die Sprungstellen und Höhen an die Achsen schreiben.
- Waagerechte Stufen, **keine** senkrechten Linien verbinden.
- Voller Punkt ● am linken Ende jeder Stufe (Wert gehört dazu), offener Kreis ○ am rechten Ende.
- Links bei 0 anfangen, rechts bei 1 enden, Pfeil nach rechts (geht bis unendlich weiter).
- Zusätzlich die Funktion mit Fallunterscheidung (wie oben) aufschreiben – dann ist die Antwort eindeutig.

### Aufgabentypen-Katalog 1.4 · Häufigkeiten, Histogramm, Verteilungsfunktion

#### Typ 7 Häufigkeitstabelle vervollständigen und Anteile ablesen

**So erkennst du ihn:** „Vervollständigen Sie die Tabelle, indem Sie relative Häufigkeiten, absolute und relative Summenhäufigkeiten berechnen.“ · „Bestimmen Sie die Anteile, deren Semesterzahl größer als 3 / mindestens 3 ... ist.“ (Tutorium 2) · „Bestimmen Sie n.“ (Testat 1)

**Rezept:**  $n = \sum h_j \cdot f_j = h_j / n \cdot H_j = \text{alles bis } j \text{ addieren} \cdot h_j = H_j - H_{j-1}$  (rückwärts!) ·  $F_j = H_j / n$ . Dann Wörter übersetzen: höchstens  $k \rightarrow F(k)$ ; mehr als  $k \rightarrow 1 - F(k)$ ; mindestens  $k \rightarrow 1 - F(k - 1)$ ; weniger als  $k \rightarrow F(k - 1)$ .

**Musterbeispiel:** 30 Personen wurden gefragt, wie viele Bücher (1 bis 5) sie im letzten Monat gelesen haben. Bekannt:  $h_1 = 4$ ,  $H_2 = 12$ ,  $f_3 = \frac{1}{3}$ ,  $F_4 = \frac{28}{30}$ . Vervollständigen Sie die Tabelle und bestimmen Sie die Anteile mit (i) mehr als 2, (ii) mindestens 4, (iii) höchstens 3 Büchern.

#### Lösung:

- 1  $h_2 = H_2 - h_1 = 12 - 4 = 8$ .
- 2  $h_3 = f_3 \cdot n = \frac{1}{3} \cdot 30 = 10 \Rightarrow H_3 = 12 + 10 = 22$ .
- 3  $H_4 = F_4 \cdot n = 28 \Rightarrow h_4 = 28 - 22 = 6$ .
- 4  $h_5 = 30 - 28 = 2$  (Summe muss  $n$  sein).

| Bücher $a_j$ | 1     | 2     | 3     | 4     | 5     | $\Sigma$ |
|--------------|-------|-------|-------|-------|-------|----------|
| $h_j$        | 4     | 8     | 10    | 6     | 2     | 30       |
| $f_j$        | 0.133 | 0.267 | 0.333 | 0.2   | 0.067 | 1        |
| $H_j$        | 4     | 12    | 22    | 28    | 30    |          |
| $F_j$        | 0.133 | 0.4   | 0.733 | 0.933 | 1     |          |

(i) mehr als 2:  $1 - F(2) = 1 - 0.4 = 0.6$ . (ii) mindestens 4:  $1 - F(3) = 1 - \frac{22}{30} = \frac{8}{30} = 0.267$ . (iii) höchstens 3:  $F(3) = \frac{22}{30} = 0.733$ .

Tipp: Wenn möglich, gib Anteile als gekürzte Brüche an ( $\frac{8}{30} = \frac{4}{15}$ ) – das ist in der Klausur ausdrücklich erlaubt und vermeidet Rundungsfehler.

### Typ 8 Höhen eines (normierten) Histogramms berechnen

**So erkennst du ihn:** „Welche y-Werte würden Sie den einzelnen Säulen zuweisen?“ (Tutorium 2, Aufgabe 1b) · „Berechnen Sie die y-Werte der einzelnen Klassen selbst.“ (Tutorium 3)

**Rezept:** Tabelle mit Spalten: Klasse ·  $h_j$  ·  $f_j = h_j/n$  · Breite · Höhe =  $f_j/\text{Breite}$  · Kontrolle (Summe der Flächen = 1).

**Musterbeispiel:** Monatseinkommen von 50 Personen (in €): [0, 1000): 12 · [1000, 2000): 20 · [2000, 4000): 14 · [4000, 8000]: 4.

| Klasse       | $h_j$ | $f_j$ | Breite | Höhe    |
|--------------|-------|-------|--------|---------|
| [0, 1000)    | 12    | 0.24  | 1000   | 0.00024 |
| [1000, 2000) | 20    | 0.40  | 1000   | 0.00040 |
| [2000, 4000) | 14    | 0.28  | 2000   | 0.00014 |
| [4000, 8000] | 4     | 0.08  | 4000   | 0.00002 |

Kontrolle:  $0.00024 \cdot 1000 + 0.0004 \cdot 1000 + 0.00014 \cdot 2000 + 0.00002 \cdot 4000 = 0.24 + 0.40 + 0.28 + 0.08 = 1 \checkmark$ . Die kleinen Zahlen sind normal, weil die Klassen breit sind (Einheit: „Anteil pro Euro“).

### Typ 9 Anteil (oder Anzahl) in einem beliebigen Intervall schätzen

**So erkennst du ihn:** „Schätzen Sie den Anteil von Beobachtungen in der Grundgesamtheit in den Intervallen ...“ (Tutorium 2, Aufgabe 1a) · „Benutzen Sie das Histogramm, um den Anteil ... zu schätzen.“ (Testat 1, Aufgabe 7.2)

**Rezept:** Intervall in Stücke zerlegen, die jeweils in **einer** Klasse liegen. Für jedes Stück: Länge des Stücks × Höhe der Klasse. Alles addieren. **Annahme hinschreiben:** „Die Werte sind innerhalb der Klassen gleichmäßig verteilt.“ Anzahl = Anteil × n.

**Musterbeispiel (Einkommen aus Typ 8):** Schätzen Sie den Anteil und die Anzahl der Personen mit einem Einkommen zwischen 1500 € und 3000 €, sowie den Anteil über 5000 €.

**Lösung:** 1500–2000 liegt in [1000, 2000):  $500 \cdot 0.0004 = 0.20$ . 2000–3000 liegt in [2000, 4000):  $1000 \cdot 0.00014 = 0.14$ . Zusammen **0.34**, also ca.  $0.34 \cdot 50 = 17$  Personen. Über 5000 €:  $(8000 - 5000) \cdot 0.00002 = 0.06$ .

### Typ 10 Anzahl der Beobachtungen aus einem normierten Histogramm ablesen

**So erkennst du ihn:** „Bestimmen Sie die Anzahl der Beobachtungen mit  $25 < x \leq 30$ .“ (Testat 1, Aufgabe 7.1 – gegeben ist nur das Histogramm und n)

**Rezept:** Höhe ablesen  $\rightarrow$  Fläche = Höhe  $\times$  Breite = Anteil  $\rightarrow$  Anzahl = Anteil  $\times$  n.

**Musterbeispiel:** 500 Personen, Klasse (25, 30] hat im Histogramm die Höhe 0.04. Klasse (20, 25] hat die Höhe 0.06. (a) Anzahl in (25, 30]? (b) Anteil mit  $21 < x \leq 24$ ?

**Lösung:** (a) Anteil =  $0.04 \cdot 5 = 0.2 \Rightarrow$  Anzahl =  $0.2 \cdot 500 = 100$ . (b) Das Stück (21, 24] hat Länge 3 und liegt in (20, 25]:  $3 \cdot 0.06 = 0.18$ .

#### Typ 11 Empirische Verteilungsfunktion aufstellen und zeichnen

**So erkennst du ihn:** „Zeichnen Sie die empirische Verteilungsfunktion für X!“ (Probeklausur A 2b, 6 P) · „Zeichnen Sie die Verteilungsfunktion der relativen Summenhäufigkeiten.“ (Tutorium 2)

**Rezept:** (1) Sortieren. (2) Jeden verschiedenen Wert zählen. (3)  $f_j$  und dann kumulieren. (4) Fallunterscheidung aufschreiben: 0 vor dem kleinsten Wert, dann Stufen, 1 ab dem größten Wert. (5) Zeichnen: waagerechte Stufen, • links, ○ rechts, keine senkrechten Linien, Achsen beschriften.

**Musterbeispiel:** Anzahl Kinder in 8 Familien: 0, 0, 1, 1, 1, 2, 2, 3.

**Lösung:** Häufigkeiten: 0  $\rightarrow$  2, 1  $\rightarrow$  3, 2  $\rightarrow$  2, 3  $\rightarrow$  1. Anteile: 0.25, 0.375, 0.25, 0.125. Kumuliert: 0.25, 0.625, 0.875, 1.

$$\hat{F}(x) = \begin{cases} 0 & x < 0 \\ 0.25 & 0 \leq x < 1 \\ 0.625 & 1 \leq x < 2 \\ 0.875 & 2 \leq x < 3 \\ 1 & x \geq 3 \end{cases}$$

#### Typ 12 Aus einer Verteilungsfunktion zurückrechnen

**So erkennst du ihn:** Eine (gezeichnete oder notierte) Treppenfunktion ist gegeben. Gefragt: Häufigkeiten, Mittelwert, Median, Anteile.

**Rezept:** Sprunghöhe =  $f_j$  (neuer Wert minus alter Wert).  $h_j = f_j \cdot n$ . Danach wie gewohnt rechnen. Median: Wo erreicht  $F$  zum ersten Mal 0.5? Ist  $F$  an einer Stelle **genau** 0.5, liegt der Median zwischen diesem und dem nächsten Wert.

**Musterbeispiel:**  $n = 20$ .  $\hat{F}$  springt bei 1 auf 0.2, bei 2 auf 0.5, bei 4 auf 0.9 und bei 5 auf 1. Bestimmen Sie  $h_j$ ,  $\bar{x}$ , Median und Modus.

**Lösung:** Sprünge:  $f = 0.2, 0.3, 0.4, 0.1$  für die Werte 1, 2, 4, 5  $\Rightarrow h = 4, 6, 8, 2$ .

$\bar{x} = 1 \cdot 0.2 + 2 \cdot 0.3 + 4 \cdot 0.4 + 5 \cdot 0.1 = 0.2 + 0.6 + 1.6 + 0.5 = 2.9$ .

Median:  $n = 20 \Rightarrow$  Mittel aus  $x_{(10)}$  und  $x_{(11)}$ . Wegen  $F(2) = 0.5$  ist  $x_{(10)} = 2$  (die ersten 10 Werte sind  $\leq 2$ ) und  $x_{(11)} = 4 \Rightarrow x_{med} = \frac{2+4}{2} = 3$ . Modus: 4 (Sprung 0.4 ist der größte).

#### TÜRKÇE AÇIKLAMA

Basamak fonksiyonunda her **sıçramanın yüksekliği** o değerin oranıdır (f). F tam 0.5'e eşit olduğu yerde medyan o değer ile bir sonraki değerin ortalamasıdır – bu klasik bir tuzaktır.

#### Typ 13 Modalklasse bestimmen – mit Falle

**So erkennst du ihn:** „Welche Klasse ist die Modalklasse?“ · „Ist die Behauptung ‚Die Modalklasse ist immer die Klasse mit dem höchsten Kästchen im Histogramm‘ korrekt?“ (Testat 1)

**Rezept:** Modalklasse = Klasse mit der **größten Anzahl**  $h_j$  (bzw.  $f_j$ ). Nicht die Höhe vergleichen, wenn die Klassen ungleich breit sind!

**Musterbeispiel:** 25 Werte: [0, 10): 10 Werte, [10, 40): 15 Werte. Modalklasse? Welche Säule ist höher?

**Lösung:** Modalklasse: [10, 40) (15 Werte). Höhen:  $\frac{10/25}{10} = 0.04$  und  $\frac{15/25}{30} = 0.02$ . Die höhere Säule ist [0, 10) – also ist die Behauptung **im Allgemeinen falsch**; sie stimmt nur bei gleich breiten Klassen.

#### Typ 14 Histogramm oder Säulendiagramm? (auch als R-Frage)

**So erkennst du ihn:** „Wieso handelt es sich hierbei nicht um ein (normiertes) Histogramm? Was ist der Nachteil? Wie könnte der R-Befehl geändert werden?“ (Tutorium 2, Aufgabe 3h–i) · „Mit welchem R-Befehl lässt sich ein normiertes Histogramm erstellen?“ (Testat 1)

**Musterbeispiel:** `hist(Gewicht_m, breaks = c(50, 60, 70, 80, 90, 200), prob = F)` – Warum kein normiertes Histogramm?

**Lösung:** Mit `prob = F` stehen **absolute Häufigkeiten** auf der y-Achse. Weil die letzte Klasse (90, 200] viel breiter ist, sieht sie viel zu groß aus → verzerrte Darstellung (Säulendiagramm). Richtig: `prob = TRUE` oder `freq = FALSE` → y-Achse = Dichte = relative Häufigkeit / Klassenbreite, Gesamtfläche 1.

#### Übe selbst · Zusatzübungen Z2

- Daten: 1, 1, 2, 2, 3, 5, 5. Erstelle die Häufigkeitstabelle (h, f, H, F), stelle  $\hat{F}(x)$  auf und bestimme die Anteile „mehr als 2“ und „mindestens 2“.
- 200 Werte: [0, 20): 40 · [20, 50): 90 · [50, 100]: 70. (a) Höhen im Histogramm. (b) Geschätzter Anteil zwischen 10 und 30. (c) Modalklasse.
- Ein normiertes Histogramm von 400 Beobachtungen hat über der Klasse (30, 40] die Höhe 0.025. Wie viele Beobachtungen liegen in dieser Klasse?
- $\hat{F}$  springt bei 10 auf 0.3, bei 20 auf 0.6 und bei 30 auf 1 ( $n = 10$ ). Berechne  $h_j$ ,  $\bar{x}$  und den Median.

#### Klausurtraining 1.B · Pendelzeiten

12 Punkte

Eine Umfrage unter 50 Studierenden der Universität Göttingen ergab folgende Pendelzeiten zur Uni (in Minuten):

| Klasse       | [0, 10) | [10, 20) | [20, 30) | [30, 60) | [60, 90] |
|--------------|---------|----------|----------|----------|----------|
| Anzahl $h_j$ | 8       | 15       | 12       | 10       | 5        |

- (a) Berechnen Sie für jede Klasse die relative Häufigkeit und die Höhe der Säule in einem (normierten) Histogramm. (4 P)
- (b) Schätzen Sie mit dem Histogramm den Anteil der Studierenden, die zwischen 25 und 45 Minuten pendeln. Welche Annahme treffen Sie? (3 P)
- (c) Wie viele Studierende pendeln mindestens 30 Minuten? (1 P)
- (d) Bestimmen Sie den Mittelwert für die klassierten Daten. (2 P)

- (e) Welche Klasse ist die Modalklasse? Warum sollte man hier kein Säulendiagramm mit absoluten Häufigkeiten zeichnen?

(2 P)

### Klausurtraining 1.C · Kaffee

9 Punkte

Zehn Studierende wurden gefragt, wie viele Tassen Kaffee sie gestern getrunken haben:

```
> sort(Kaffee)
[1] 0 1 1 2 2 2 3 3 4 6
```

- (a) Geben Sie Skalenniveau an und ob das Merkmal diskret oder stetig ist.

(1 P)

- (b) Stellen Sie die empirische Verteilungsfunktion  $\hat{F}(x)$  als Funktion mit Fallunterscheidung auf und skizzieren Sie sie.

(4 P)

- (c) Lesen Sie ab:  $\hat{F}(2.5)$ ; den Anteil mit mehr als 2 Tassen; den Anteil mit mindestens 1 Tasse.

(2 P)

- (d) Berechnen Sie Modus, Median und arithmetisches Mittel.

(2 P)

## 1.5 Lagemaße: Wo ist die Mitte?

### FORMEL: DIE DREI LAGEMASSE

**Arithmetisches Mittel** (Durchschnitt): alle Werte addieren und durch  $n$  teilen – oder mit Häufigkeitstabelle: jeden Wert mal seinen Anteil.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{1}{n} \sum_{j=1}^J a_j h_j = \sum_{j=1}^J a_j f_j$$

**Median:** die Mitte der **sortierten** Werte  $x_{(1)} \leq \dots \leq x_{(n)}$  (die Klammer im Index heißt „sortiert“).

$$x_{med} = \begin{cases} x_{(\frac{n+1}{2})} & n \text{ ungerade} \\ \in [x_{(n/2)}, x_{(n/2+1)}], \text{ meist } \frac{x_{(n/2)} + x_{(n/2+1)}}{2} & n \text{ gerade} \end{cases}$$

**Modus**  $x_{mod}$ : der Wert, der am häufigsten vorkommt.

### MEDIAN SCHRITT FÜR SCHRITT

**n ungerade:** 7, 2, 9, 4, 5 → sortieren: 2, 4, **5**, 7, 9.  $n = 5$ ,  $\frac{n+1}{2} = 3 \rightarrow x_{med} = x_{(3)} = 5$ .

**n gerade:** 7, 2, 9, 4, 5, 10 → sortieren: 2, 4, **5, 7**, 9, 10.  $n = 6$ ,  $\frac{n}{2} = 3 \rightarrow$  zwischen  $x_{(3)} = 5$  und  $x_{(4)} = 7 \rightarrow x_{med} = \frac{5+7}{2} = 6$ .

Achtung:  $x_{(3)}$  (sortiert) ist nicht  $x_3$  (dritter Wert in der Urliste)! Immer zuerst sortieren.

| Lagemaß    | ab welcher Skala?                  | Eigenschaft                                                          |
|------------|------------------------------------|----------------------------------------------------------------------|
| Modus      | jede Skala (auch nominal)          | bei stetigen Daten oft nicht sinnvoll (alle Werte verschieden)       |
| Median     | ab ordinal                         | <b>robust</b> gegen Ausreißer; mind. 50 % links und rechts           |
| Mittelwert | kardinal (auch 0/1-Daten → Anteil) | empfindlich gegen Ausreißer; Schwerpunkt: $\sum (x_i - \bar{x}) = 0$ |

### BEISPIEL: MENSABESUCHE (TABELLE AUS 1.4, N = 24)

**Modus:** 2 (kommt 8-mal vor, am häufigsten).

**Median:**  $n = 24$  gerade → Mittel aus  $x_{(12)}$  und  $x_{(13)}$ . Mit den kumulierten Häufigkeiten: Plätze 1–3 sind 0, Plätze 4–8 sind 1, Plätze 9–16 sind 2. Also  $x_{(12)} = x_{(13)} = 2 \rightarrow x_{med} = 2$ .

**Mittelwert:**  $\bar{x} = \frac{0 \cdot 3 + 1 \cdot 5 + 2 \cdot 8 + 3 \cdot 6 + 4 \cdot 2}{24} = \frac{47}{24} = 1.958$ .

### BEISPIEL: AUSREISSER (TUTORIUM 2)

Datensatz I: 5, 6, 7, 8, **14** →  $\bar{x} = 8$ ,  $x_{med} = 7$ . Datensatz II: 5, 6, 7, 8, 9 →  $\bar{x} = 7$ ,  $x_{med} = 7$ .

Nur ein Wert ist anders. Der Mittelwert ändert sich, der Median nicht. Der Median hängt nur von der **Reihenfolge** ab, nicht davon, **wie groß** der größte Wert ist. „**Der Median ist robuster gegenüber Extremwerten als das arithmetische Mittel.**“ (Genau dieser Satz war die Musterantwort in Probeklausur B!)

### BEISPIEL: SEMESTERZAHLEN (N = 23)

$\bar{x} = \frac{1}{23} (2 \cdot 1 + 3 \cdot 7 + 4 \cdot 5 + 5 \cdot 5 + 6 \cdot 1 + 7 \cdot 4) = \frac{102}{23} = 4.435$ .


Median:  $n = 23$  ungerade →  $x_{(12)}$ . Kumuliert: Platz 1 ist 2, Plätze 2–8 sind 3, Plätze 9–13 sind 4 →  $x_{(12)} = 4$ .

Modus: 3 (7-mal).

### BEISPIEL: 0/1-DATEN

10 Personen, 1 = „hat bestanden“: 1, 0, 1, 1, 1, 0, 1, 1, 0, 1.  $\bar{x} = \frac{7}{10} = 0.7 = \text{Bestehensquote } 70 \%$ . So kann der Mittelwert auch bei einem nominalen 0/1-Merkmal sinnvoll sein.

## Lagemaße und Form der Verteilung



### MERKE

**rechtsschief** (= linkssteil, langer Schwanz nach rechts):  $\bar{x} > x_{med} > x_{mod}$ . Typisch für Einkommen, Wartezeiten, Wohnungsgrößen.

**symmetrisch** (unimodal):  $\bar{x} \approx x_{med} \approx x_{mod}$ .

**linksschief** (= rechtssteil, langer Schwanz nach links):  $\bar{x} < x_{med} < x_{mod}$ .

Eselsbrücke: Der Mittelwert wird vom langen Schwanz „weggezogen“. Im Wartezeit-Beispiel:  $\bar{x} = 12.4 > x_{med} = 9.5 \rightarrow$  rechtsschief.

## Rechenregeln

- Lineare Transformation**  $y_i = a + b x_i$ :  $\bar{y} = a + b \bar{x}$ . Beispiel: °C in °F:  $F = 32 + 1.8 C$ . Mittel 20 °C  $\rightarrow 32 + 1.8 \cdot 20 = 68$  °F.
- Monotone Transformation**  $y_i = g(x_i)$  (z. B. log):  $y_{med} = g(x_{med})$ . Für den Mittelwert gilt das **nicht**:  $\overline{\log x} \neq \log \bar{x}$ .
- Mittelwert aus Gruppen** (Schichten):  $\bar{x} = \frac{1}{n} \sum_j n_j \bar{x}_j$  – ein gewichteter Durchschnitt. Beispiel: Kurs A hat 20 Personen mit Mittel 60 Punkte, Kurs B hat 30 Personen mit Mittel 70  $\rightarrow \bar{x} = \frac{20 \cdot 60 + 30 \cdot 70}{50} = 66$  (**nicht** 65!).

## Klassierte Daten

Wenn wir nur die Klassen kennen, nehmen wir die **Klassenmitte**  $m_j = \frac{c_{j-1} + c_j}{2}$  als Stellvertreter für alle Werte der Klasse:

### FORMEL: KLASSEMIITTE DATEN

$$\bar{x}_K = \sum_j f_j m_j \quad s_K^2 = \sum_j f_j (m_j - \bar{x}_K)^2 \quad \text{Modalklasse} = \text{Klasse mit dem größten } f_j$$

### KLAUSURAUFGABE (PROBEKLAUSUR A, 2C, 4 PUNKTE)

Bier in Klassen  $K_1 = [0, 10)$  und  $K_2 = [10, 20]$ . In  $K_1$ : 4, 4, 4, 8.5, 8.5, 8.5, 8.5  $\rightarrow n(K_1) = 7$ . In  $K_2$ : 12, 12, 15.7  $\rightarrow n(K_2) = 3$ . Mitten:  $m_1 = 5$ ,  $m_2 = 15$ .

$$\bar{x}_K = \frac{1}{10} (7 \cdot 5 + 3 \cdot 15) = \frac{80}{10} = 8$$

(Der echte Mittelwert ist 8.57 – die Klassenmitte ist nur eine Näherung.)

## Aufgabentypen-Katalog 1.5 · Lagemaße (Mittelwert, Median, Modus)

### Typ 15 Mittelwert, Median und Modus aus Rohdaten

**So erkennst du ihn:** „Berechnen Sie das arithmetische Mittel, den Median und den Modus.“ Es steht eine kurze Liste von Zahlen da (meistens unsortiert!).

**Rezept:** (1) Zahlen **sortieren** und zählen ( $n$ ). (2) Mittel = Summe /  $n$ . (3) Median:  $n$  ungerade  $\rightarrow$  mittlerer Wert  $x_{((n+1)/2)}$ ;  $n$  gerade  $\rightarrow$  Mittel aus  $x_{(n/2)}$  und  $x_{(n/2+1)}$ . (4) Modus = häufigster Wert.

**Musterbeispiel:** Wartezeiten (min) an einer Bushaltestelle: 12, 7, 3, 9, 7, 15, 7, 10.

**Lösung:**

- 1 Sortiert: 3, 7, 7, 7, 9, 10, 12, 15  $\rightarrow n = 8$ .
- 2  $\bar{x} = \frac{3+7+7+7+9+10+12+15}{8} = \frac{70}{8} = 8.75$  Minuten.
- 3  $n = 8$  gerade  $\rightarrow x_{med} = \frac{x_{(4)}+x_{(5)}}{2} = \frac{7+9}{2} = 8$  Minuten.
- 4 Modus: 7 kommt dreimal vor  $\rightarrow x_{mod} = 7$  Minuten.
- 5 Antwortsatz: „Das arithmetische Mittel beträgt 8.75 Minuten, der Median 8 Minuten und der Modus 7 Minuten.“

#### TYPISCHE FEHLER

Median aus der **unsortierten** Liste ablesen (hier käme 9 und 7  $\rightarrow$  falsch!). Bei geradem  $n$  nur einen Wert nehmen. Einheit im Antwortsatz vergessen.

### Typ 16 Lagemaße aus einer Häufigkeitstabelle

**So erkennst du ihn:** Statt einer Liste gibt es eine Tabelle mit Ausprägungen  $a_j$  und Häufigkeiten  $h_j$  (oder  $f_j$ ). „Wie viele Kinder hat ein Haushalt im Durchschnitt?“

**Rezept:**  $\bar{x} = \frac{1}{n} \sum_j a_j h_j = \sum_j a_j f_j$ . Median: Summenhäufigkeiten  $H_j$  bilden und schauen, bei welcher Ausprägung die Position  $\frac{n+1}{2}$  (bzw.  $\frac{n}{2}$  und  $\frac{n}{2} + 1$ ) liegt. Modus =  $a_j$  mit dem größten  $h_j$ .

**Musterbeispiel:** 20 Haushalte, Anzahl Kinder:

|           |   |    |    |    |    |          |
|-----------|---|----|----|----|----|----------|
| $a_j$     | 0 | 1  | 2  | 3  | 4  | $\Sigma$ |
| $h_j$     | 5 | 8  | 4  | 2  | 1  | 20       |
| $a_j h_j$ | 0 | 8  | 8  | 6  | 4  | 26       |
| $H_j$     | 5 | 13 | 17 | 19 | 20 |          |

**Lösung:**  $\bar{x} = \frac{26}{20} = 1.3$  Kinder.  $n = 20$  gerade  $\rightarrow$  Median = Mittel aus  $x_{(10)}$  und  $x_{(11)}$ . Wegen  $H_1 = 5 < 10$  und  $H_2 = 13 \geq 11$  sind beide Werte 1  $\rightarrow x_{med} = 1$ . Modus:  $h_j$  maximal bei 1  $\rightarrow x_{mod} = 1$ .

#### TÜRKÇE AÇIKLAMA

Tabloda her değer  $h_j$  kez tekrar ediyor. Yani 0'ı 5 kere, 1'i 8 kere yazmış gibi düşün. Medyan için sıralı listede 10. ve 11. elemanı arıyorsun: birikimli sıklık  $H_j$  ilk kez 10'u geçtiği yerde duruyorsun. Burada 1'in bloğu 6. elemandan 13. elemana kadar sürüyor  $\rightarrow$  medyan 1.

### Typ 17 Mittelwert und Varianz bei klassierten Daten

**So erkennst du ihn:** Nur Klassen und Häufigkeiten sind gegeben. „Berechnen Sie den Mittelwert der klassierten Daten.“ (Probeklausur A, 2c) • „Bestimmen Sie die Modalklasse.“

**Rezept:** Klassenmitte  $m_j = \frac{\text{untere} + \text{obere Grenze}}{2}$ .  $\bar{x}_K = \sum f_j m_j$ .  $s_K^2 = \sum f_j m_j^2 - \bar{x}_K^2$ . Immer als Tabelle rechnen!

**Musterbeispiel:** Monatseinkommen von 50 Personen (aus Typ 8):

| Klasse       | $h_j$ | $f_j$ | $m_j$ | $f_j m_j$ | $f_j m_j^2$ |
|--------------|-------|-------|-------|-----------|-------------|
| [0, 1000)    | 12    | 0.24  | 500   | 120       | 60 000      |
| [1000, 2000) | 20    | 0.40  | 1500  | 600       | 900 000     |
| [2000, 4000) | 14    | 0.28  | 3000  | 840       | 2 520 000   |
| [4000, 8000] | 4     | 0.08  | 6000  | 480       | 2 880 000   |
| $\Sigma$     | 50    | 1     |       | 2040      | 6 360 000   |

**Lösung:**  $\bar{x}_K = 2040 \text{ €}$ .  $s_K^2 = 6\,360\,000 - 2040^2 = 6\,360\,000 - 4\,161\,600 = 2\,198\,400 \text{ €}^2$ .  $s_K = \sqrt{2\,198\,400} = 1482.7 \text{ €}$ . Modalklasse: [1000, 2000) (größtes  $h_j = 20$ ).

Merke: Das ist nur eine **Näherung**, weil wir annehmen, dass alle Werte in der Klassenmitte liegen.

### Typ 18 Gesamtmittel aus Gruppen (gewichtetes Mittel)

**So erkennst du ihn:** „Filiale A hat ... im Durchschnitt ..., Filiale B ...; wie hoch ist der Durchschnitt aller?“ (KT 1.D e) · Schichten mit unterschiedlicher Größe.

**Rezept:**  $\bar{x} = \frac{n_1 \bar{x}_1 + n_2 \bar{x}_2 + \dots}{n_1 + n_2 + \dots}$ . Nie einfach die Mittelwerte mitteln (außer die Gruppen sind gleich groß)!

**Musterbeispiel:** In Tutorium A schreiben 12 Studierende im Schnitt die Note 2.1, in Tutorium B 18 Studierende im Schnitt 2.6. Durchschnittsnote aller?

**Lösung:**  $\bar{x} = \frac{12 \cdot 2.1 + 18 \cdot 2.6}{30} = \frac{25.2 + 46.8}{30} = \frac{72}{30} = 2.4$ . (Falsch wäre  $\frac{2.1 + 2.6}{2} = 2.35$ .)

**Variante rückwärts:** Gesamtschnitt 2.4 bei 30 Personen, Gruppe A (12 Pers.) hat 2.1. Schnitt von B?  $\bar{x}_B = \frac{30 \cdot 2.4 - 12 \cdot 2.1}{18} = \frac{72 - 25.2}{18} = 2.6$ .

### Typ 19 Fehlender, falscher oder neuer Wert

**So erkennst du ihn:** „Der Mittelwert von 5 Werten ist 6; vier Werte sind ... Wie lautet der fünfte?“ · „Ein Wert wurde falsch eingetragen ...“ · „Ein weiterer Wert kommt hinzu ...“

**Rezept:** Immer über die **Summe** gehen:  $\sum x_i = n \cdot \bar{x}$ . Dann korrigieren und neu durch  $n$  teilen. Beim Median: neu sortieren und schauen, ob sich die Mitte verschiebt.

**Musterbeispiel:** (a) 5 Werte,  $\bar{x} = 6$ ; bekannt: 4, 8, 5, 7. Fünfter Wert? (b) 10 Werte mit  $\bar{x} = 50$ ; der Wert 80 war ein Tippfehler, richtig ist 30. Neues Mittel? (c) Was passiert in (b) mit dem Median, wenn 80 der größte Wert war und 30 immer noch über dem Median liegt?

**Lösung:** (a) Summe =  $5 \cdot 6 = 30$ ; bekannt  $4 + 8 + 5 + 7 = 24 \rightarrow$  fehlender Wert =  $30 - 24 = 6$ . (b) alte Summe = 500; neue Summe =  $500 - 80 + 30 = 450 \rightarrow \bar{x}_{\text{neu}} = 45$ . (c) Der Median bleibt **gleich**, weil sich die Reihenfolge in der Mitte nicht ändert – das zeigt: der Median ist **robust**, der Mittelwert nicht.

### Typ 20 Lagemaße nach einer Transformation

**So erkennst du ihn:** „Alle Gehälter steigen um 5 %.“ · „Umrechnung in °F / in Stunden / in Euro.“ · „Jeder erhält 100 € Bonus.“

**Rezept:** Linear  $y = a + bx$ :  $\bar{y} = a + b\bar{x}$ ,  $y_{\text{med}} = a + b\bar{x}_{\text{med}}$ ,  $y_{\text{mod}} = a + b\bar{x}_{\text{mod}}$ . Monoton (z. B.  $\log$ ,  $\sqrt{\phantom{x}}$ ): **nur** Median und Modus werden mittransformiert, der Mittelwert **nicht**.

**Musterbeispiel:** Median der Gehälter 3.6 Tsd. €, Mittel 4.84 Tsd. €. (a) +5 % für alle. (b) Jeder bekommt 200 € mehr. (c) Man betrachtet  $\log(\text{Gehalt})$ .

**Lösung:** (a)  $b = 1.05$ :  $\bar{y} = 1.05 \cdot 4.84 = 5.082$ ,  $y_{med} = 1.05 \cdot 3.6 = 3.78$  Tsd. €. (b)  $a = 0.2$ :  $\bar{y} = 5.04$ ,  $y_{med} = 3.8$  Tsd. €. (c) Median von  $\log x = \log(3.6)$ ; aber das Mittel von  $\log x$  ist **nicht**  $\log(4.84)$  – man muss es neu berechnen.

#### Typ 21 Schiefe aus Lagemaßen oder Grafik bestimmen

**So erkennst du ihn:** „Ist die Verteilung rechtsschief, symmetrisch oder linksschief? Begründen Sie.“ · Histogramm oder Boxplot ist abgebildet.

**Rezept:** rechtsschief (= linkssteil):  $\bar{x} > x_{med} > x_{mod}$ , langer Schwanz nach **rechts**. linksschief:  $\bar{x} < x_{med} < x_{mod}$ . Im Boxplot: Median nah am unteren Boxrand + langer oberer Whisker → rechtsschief.

**Musterbeispiel:** Aus Typ 15:  $\bar{x} = 8.75$ ,  $x_{med} = 8$ ,  $x_{mod} = 7$ .

**Lösung:** „Da  $\bar{x} = 8.75 > x_{med} = 8 > x_{mod} = 7$ , ist die Verteilung **rechtsschief** (linkssteil). Der große Wert 15 zieht den Mittelwert nach rechts.“

#### TÜRKÇE AÇIKLAMA

„Rechtsschief“ = kuyruk **sağda** uzun (sağa çarpık). Birkaç çok büyük değer ortalamayı sağa çeker, medyan yerinde kalır. Gelir, bekleme süresi, kira gibi değişkenler genelde sağa çarpıktır. Ezber: *ortalama kuyruğa kaçır*.

#### Typ 22 Mittelwert von 0/1-Daten = Anteil

**So erkennst du ihn:** Merkmal mit nur zwei Werten (ja = 1, nein = 0). „Was bedeutet der Mittelwert hier?“ · „Ist der Mittelwert bei einem nominalen Merkmal sinnvoll?“

**Rezept:**  $\bar{x} = \frac{\text{Anzahl Einsen}}{n} = \text{Anteil der „ja“-Antworten}$ . Varianz (1/n):  $s^2 = \bar{x}(1 - \bar{x})$ .

**Musterbeispiel:** 20 Personen, 7 davon haben ein Auto (1), 13 nicht (0).

**Lösung:**  $\bar{x} = \frac{7}{20} = 0.35$ : 35 % der Befragten haben ein Auto.  $s^2 = 0.35 \cdot 0.65 = 0.2275$ . Der Mittelwert ist hier sinnvoll interpretierbar (als Anteil), obwohl das Merkmal eigentlich nominal ist – das ist die **Ausnahme** bei 0/1-Kodierung.

#### Typ 23 Aussagen über Lagemaße: richtig oder falsch?

**So erkennst du ihn:** „Welche der folgenden Aussagen sind korrekt?“ (Testat 1, Tutorium 2). Bei falschen Aussagen immer **kurz korrigieren**.

| Aussage                                                           | R/F | Begründung                                                               |
|-------------------------------------------------------------------|-----|--------------------------------------------------------------------------|
| Der Median ist robuster gegenüber Ausreißern als der Mittelwert.  | R   | Ein extremer Wert ändert nur die Summe, nicht die Mitte der Reihenfolge. |
| Der Mittelwert ist immer einer der beobachteten Werte.            | F   | Z. B. 1.3 Kinder – kein Haushalt hat 1.3 Kinder.                         |
| Der Modus ist immer eindeutig.                                    | F   | Es kann mehrere häufigste Werte geben (bimodal).                         |
| Für nominale Merkmale ist nur der Modus sinnvoll.                 | R   | Median braucht Reihenfolge, Mittel braucht Abstände.                     |
| Wenn $\bar{x} = x_{med}$ , ist die Verteilung sicher symmetrisch. | F   | Das ist nur ein Hinweis, kein Beweis.                                    |
| Verdoppelt man den größten Wert, ändert sich der Median nicht.    | R   | (bei $n \geq 3$ ) Die Mitte bleibt gleich.                               |
| Die Summe der Abweichungen vom Mittelwert ist 0.                  | R   | $\sum (x_i - \bar{x}) = n\bar{x} - n\bar{x} = 0$ .                       |

### Übe selbst · Zusatzübungen Z3

- Daten: 4, 20, 3, 6, 3, 2, 8, 3, 5. Berechne  $\bar{x}$ ,  $x_{med}$ ,  $x_{mod}$  und bestimme die Schiefe.
- Noten von 25 Studierenden: Note 1: 3x, Note 2: 7x, Note 3: 9x, Note 4: 4x, Note 5: 2x. Berechne Mittel, Median und Modus. Welches Lagemaß ist für Noten (ordinal!) eigentlich angemessen?
- Klassen [0, 20): 10 Personen, [20, 40): 25, [40, 100]: 15. Berechne  $\bar{x}_K$  und die Modalklasse.
- Der Mittelwert von 8 Zahlen ist 12. Eine neunte Zahl kommt dazu, danach ist der Mittelwert 13. Wie groß ist die neunte Zahl?
- Die Temperaturen einer Woche haben Median 15 °C und Mittel 14 °C. Berechne Median und Mittel in °F ( $F = 32 + 1.8C$ ).

### Klausurtraining 1.D · Gehälter

12 Punkte

Ein kleines Göttinger Start-up hat 9 Mitarbeitende. Ihre Monatsgehälter (in Tausend Euro) sind:

```
> sort(Gehalt)
[1] 2.8 3.1 3.1 3.4 3.6 3.9 4.2 4.5 15.0
```

Hinweis:  $\sum x_i = 43.6$ ,  $\sum x_i^2 = 329.68$ .

- Berechnen Sie arithmetisches Mittel, Median und Modus. (3 P)
- Welches Lagemaß beschreibt das „typische“ Gehalt besser? Begründen Sie in einem Satz. (1 P)
- Ist die Verteilung rechtsschief, symmetrisch oder linksschief? Begründen Sie mit den Lagemaßen. (2 P)
- Alle Gehälter steigen um 5 %. Wie lauten der neue Mittelwert und der neue Median? (Ohne alles neu zu rechnen!) (2 P)
- Eine zweite Filiale hat 6 Mitarbeitende mit einem Durchschnittsgehalt von 3.5 Tsd. €. Berechnen Sie das Durchschnittsgehalt aller 15 Mitarbeitenden. (2 P)

**(f)** Berechnen Sie die empirische Varianz und die Standardabweichung der 9 Gehälter.

**(2 P)**

## 1.6 Quantile, Streuung und Boxplot

### Quantile

Das  $\alpha$ -Quantil  $x_\alpha$  teilt die sortierten Daten: mindestens  $\alpha \cdot 100\%$  der Werte sind kleiner oder gleich  $x_\alpha$ , und mindestens  $(1 - \alpha) \cdot 100\%$  sind größer oder gleich. Wichtige Quantile: Median  $x_{0.5}$ ; **Quartile**  $x_{0.25}, x_{0.5}, x_{0.75}$ ; Dezile  $x_{0.1}, \dots, x_{0.9}$ . Voraussetzung: mindestens ordinal.

#### FORMEL: QUANTIL (DEFINITION AUS DER VORLESUNG)

$$x_\alpha = \begin{cases} x_{(\lfloor n\alpha \rfloor + 1)} & n\alpha \text{ keine ganze Zahl (aufrunden!)} \\ \in [x_{(n\alpha)}, x_{(n\alpha+1)}] & n\alpha \text{ ganze Zahl (meist Mittelwert der beiden)} \end{cases}$$

#### BEISPIEL A: N = 7 WERTE: 2, 4, 4, 5, 5, 7, 8 (SCHON SORTIERT)

$x_{0.25}$ :  $7 \cdot 0.25 = 1.75 \rightarrow$  keine ganze Zahl  $\rightarrow$  aufrunden auf 2  $\rightarrow x_{(2)} = 4$ .

$x_{0.5}$ :  $7 \cdot 0.5 = 3.5 \rightarrow$  aufrunden auf 4  $\rightarrow x_{(4)} = 5$  (passt zur Median-Formel).

$x_{0.75}$ :  $7 \cdot 0.75 = 5.25 \rightarrow$  aufrunden auf 6  $\rightarrow x_{(6)} = 7$ . IQR =  $7 - 4 = 3$ .

#### BEISPIEL B: MIETSPIEGEL (V02), N = 26 SORTIERTE MIETEN

$x_{0.25}$ :  $0.25 \cdot 26 = 6.5 \rightarrow$  keine ganze Zahl  $\rightarrow$  aufrunden auf 7  $\rightarrow x_{(7)} = 170.04$ .

$x_{0.5}$ :  $0.5 \cdot 26 = 13 \rightarrow$  ganze Zahl  $\rightarrow$  zwischen  $x_{(13)} = 243.44$  und  $x_{(14)} = 255.75 \rightarrow$  Mittelwert 249.6.

$x_{0.75}$ :  $0.75 \cdot 26 = 19.5 \rightarrow$  aufrunden auf 20  $\rightarrow x_{(20)} = 311.87$ .

#### ACHTUNG: R RECHNET QUANTILE ETWAS ANDERS

`quantile(x, 0.25)` benutzt standardmäßig eine andere Methode (Interpolation). Die Ergebnisse können leicht von der Handrechnung abweichen. In Teil A rechnest du immer mit der Vorlesungsdefinition oben. In Teil B nimmst du einfach den R-Befehl.

### Streuungsmaße

Zwei Datensätze können die gleiche Mitte haben und trotzdem ganz verschieden sein:  $\{5, 5, 5\}$  und  $\{0, 5, 10\}$  haben beide Mittelwert 5. Die **Streuung** misst, wie weit die Werte auseinander liegen.

#### FORMEL: VARIANZ UND STANDARDABWEICHUNG

$$s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \stackrel{\text{Verschiebungssatz}}{=} \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2 = \overline{x^2} - \bar{x}^2$$
$$s_*^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{n}{n-1} s^2 \quad (\text{unverzerrte / korrigierte Varianz})$$
$$s = \sqrt{s^2} \quad \text{IQR} = x_{0.75} - x_{0.25} \quad \text{Spannweite} = x_{\max} - x_{\min}$$

#### VARIANZ AUF ZWEI WEGEN: 2, 4, 4, 5, 5, 7, 8 (N = 7)

$$\bar{x} = \frac{35}{7} = 5.$$

##### Weg 1: Definition

##### Weg 2: Verschiebungssatz (schneller!)

$$\sum x_i^2 = 4 + 16 + 16 + 25 + 25 + 49 + 64 = 199$$

$$s^2 = \frac{199}{7} - 5^2 = 28.4286 - 25 = 3.429$$

$$\text{Standardabweichung: } s = \sqrt{3.4286} = 1.852.$$

$$\text{Unverzerrt: } s_*^2 = \frac{24}{6} = 4 \text{ (das gibt R mit } \text{var}() \text{).}$$

| $x_i$    | $x_i - \bar{x}$ | $(x_i - \bar{x})^2$ |
|----------|-----------------|---------------------|
| 2        | -3              | 9                   |
| 4        | -1              | 1                   |
| 4        | -1              | 1                   |
| 5        | 0               | 0                   |
| 5        | 0               | 0                   |
| 7        | 2               | 4                   |
| 8        | 3               | 9                   |
| $\Sigma$ | 0 ✓             | 24                  |

$$s^2 = \frac{24}{7} = 3.429$$

Kontrolle: Die Summe der Abweichungen  $\sum (x_i - \bar{x})$  ist immer 0.

#### ACHTUNG: 1/N ODER 1/(N-1)?

- „Empirische Varianz“ per Hand in Teil A: meistens  $s^2$  mit  $\frac{1}{n}$  (so rechnen die Musterlösungen der Tutorien und Probeklausur).
- **R** rechnet mit `var()` und `sd()` **immer** die unverzerrte Version  $s_*^2$  mit  $\frac{1}{n-1}$ !
- Umrechnen:  $s^2 = \frac{n-1}{n} s_*^2$  bzw.  $n s^2 = (n-1) s_*^2$ .
- Steht in der Aufgabe „unverzerrter Schätzer“, „Stichprobenvarianz  $s_*^2$ “ oder „korrigiert“:  $\frac{1}{n-1}$ .
- Mit Häufigkeitstabelle:  $s^2 = \sum_j a_j^2 f_j - \bar{x}^2$ .

**Vorteil der Standardabweichung:** Sie hat die **gleiche Einheit** wie das Merkmal (Euro statt Euro<sup>2</sup>). (Testat 1, Aufgabe 5.3)

#### KLAUSURAUFGABE (PROBEKLAUSUR A, 5A): SCHIESSFEHLER 3, 2, 5, 1, 3, 4

$$\bar{x} = \frac{18}{6} = 3, \quad \overline{x^2} = \frac{9+4+25+1+9+16}{6} = \frac{64}{6} = 10.6667, \quad s_x^2 = 10.6667 - 3^2 = 1.667$$

#### MIT HÄUFIGKEITSTABELLE: MENSABESUCHE (N = 24)

$$\overline{x^2} = \frac{0 \cdot 3 + 1 \cdot 5 + 4 \cdot 8 + 9 \cdot 6 + 16 \cdot 2}{24} = \frac{123}{24} = 5.125 \quad s^2 = 5.125 - 1.9583^2 = 1.290$$

**Lineare Transformation**  $y_i = a + b x_i$ :  $s_y^2 = b^2 s_x^2$ ,  $s_y = |b| s_x$ ,  $\text{IQR}_y = |b| \text{IQR}_x$ . Die Verschiebung  $a$  ändert die Streuung **nicht** (alle Werte rücken gleich weit). Tutorium 2: Datensatz III = 2 · Datensatz II → Varianz  $2^2 = 4$ -mal so groß: 8 statt 2.

### Der Boxplot

Der Boxplot ist eine **Fünf-Punkte-Zusammenfassung**: Minimum,  $x_{0.25}$ , Median,  $x_{0.75}$ , Maximum. Die **Box** geht vom unteren zum oberen Quartil – in ihr liegen die mittleren 50 % der Daten. Der Strich in der Box ist der Median.

#### FORMEL: AUSREISSERREGEL UND WHISKER

$$\text{untere Grenze} = x_{0.25} - 1.5 \cdot \text{IQR} \quad \text{obere Grenze} = x_{0.75} + 1.5 \cdot \text{IQR}$$


Werte außerhalb der Grenzen sind **Ausreißer** (einzelne Punkte). Der Whisker endet beim extremsten Wert, der **noch innerhalb** der Grenzen liegt.

### BEISPIEL (TUTORIUM 2, AUFGABE 7): 20 SEMESTERZAHLEN

1,1,1,1,2,2,3,3,3,4,4,5,6,6,6,6,7,9,13,14.  $n\alpha = 20 \cdot 0.25 = 5$  (ganz)  $\rightarrow x_{0.25} \in [x_{(5)}, x_{(6)}] = [2, 2] = 2$ ;  $20 \cdot 0.75 = 15 \rightarrow x_{0.75} \in [x_{(15)}, x_{(16)}] = [6, 6] = 6$ ; IQR = 4.

Obere Grenze:  $6 + 1.5 \cdot 4 = 12 \rightarrow$  oberer Whisker = größter Wert  $\leq 12 = 9$ ; 13 und 14 sind Ausreißer.

Untere Grenze:  $2 - 6 = -4 \rightarrow$  unterer Whisker = Minimum = 1.



### WAS MAN AUS EINEM BOXPLOT ABLESEN KANN (TESTAT 1, AUFGABE 6)

- Median, Quartile, Min/Max, Ausreißer direkt ablesen.
- **Schiefe:** Liegt der Median nah am unteren Rand der Box und ist der obere Whisker lang  $\rightarrow$  rechtsschief.
- **Vergleich von Gruppen** (mehrere Boxplots nebeneinander): Unterschiede in Lage und Streuung sehen. Aber: Ein Unterschied der Mediane beweist **keine Ursache** (keine Kausalität ohne Experiment/Kontrolle der Störvariablen).
- Sind **keine Punkte** eingezeichnet, gibt es **keine Ausreißer**. Ein langer Whisker ist kein Ausreißer!

## Aufgabentypen-Katalog 1.6 · Quantile, Streuung, Boxplot

### Typ 24 Quantile nach der Vorlesungsdefinition

**So erkennst du ihn:** „Bestimmen Sie das untere und obere Quartil (nach Definition der Vorlesung).“ · „Bestimmen Sie das 10 %- und das 90 %-Quantil.“

**Rezept:** (1) Sortieren. (2)  $n \cdot \alpha$  rechnen. (3) Keine ganze Zahl  $\rightarrow$  **aufrunden**  $\rightarrow$  dieser Platz. Ganze Zahl  $k \rightarrow$  Mittel aus Platz  $k$  und  $k + 1$ .

**Musterbeispiel:**  $n = 10$  sortierte Werte: 3, 5, 6, 8, 9, 11, 12, 14, 17, 25. Gesucht:  $x_{0.1}, x_{0.25}, x_{0.5}, x_{0.75}, x_{0.9}$ , IQR.

| $\alpha$ | $n\alpha$ | ganz? | Plätze   | $x_\alpha$             |
|----------|-----------|-------|----------|------------------------|
| 0.10     | 1         | ja    | 1 und 2  | $\frac{3+5}{2} = 4$    |
| 0.25     | 2.5       | nein  | 3        | 6                      |
| 0.50     | 5         | ja    | 5 und 6  | $\frac{9+11}{2} = 10$  |
| 0.75     | 7.5       | nein  | 8        | 14                     |
| 0.90     | 9         | ja    | 9 und 10 | $\frac{17+25}{2} = 21$ |

**Lösung:** IQR =  $14 - 6 = 8$ . Interpretation von  $x_{0.9} = 21$ : „Mindestens 90 % der Werte sind kleiner oder gleich 21.“

### VORSICHT MIT R

`quantile(x, c(.1, .25, .5, .75, .9))` liefert hier 4.8, 6.5, 10, 13.5, 17.8 – andere Methode! In Teil A zählt die Vorlesungsdefinition, in Teil B der R-Output.

### Typ 25 Varianz aus Summen (Verschiebungssatz)

**So erkennst du ihn:** Es sind  $n$ ,  $\sum x_i$  und  $\sum x_i^2$  gegeben (oft als R-Output `sum(x)`, `sum(x^2)`).

**Rezept:**  $\bar{x} = \frac{\sum x_i}{n} \rightarrow s^2 = \frac{\sum x_i^2}{n} - \bar{x}^2 \rightarrow s = \sqrt{s^2}$ . Unverzerrt:  $s_*^2 = \frac{n}{n-1} s^2$ .

**Musterbeispiel:**  $n = 8$ ,  $\sum x_i = 40$ ,  $\sum x_i^2 = 260$ .

**Lösung:**  $\bar{x} = 5$ ;  $s^2 = \frac{260}{8} - 25 = 32.5 - 25 = 7.5$ ;  $s = \sqrt{7.5} = 2.739$ ;  $s_*^2 = \frac{8}{7} \cdot 7.5 = 8.571$ ,  $s_* = 2.928$ .

**Umgekehrt (R-Output umrechnen):** R zeigt `var(x)` = 12 bei  $n = 5$ . Empirische Varianz:  $s^2 = \frac{4}{5} \cdot 12 = 9.6$ .

### Typ 26 Varianz aus einer Häufigkeitstabelle

**So erkennst du ihn:** Tabelle mit  $a_j$  und  $h_j$ ; „Berechnen Sie die empirische Varianz.“

**Rezept:** Spalte  $a_j^2 h_j$  ergänzen.  $s^2 = \frac{1}{n} \sum a_j^2 h_j - \bar{x}^2$ .

**Musterbeispiel:** Kinder-Tabelle aus Typ 16 ( $n = 20$ ,  $\bar{x} = 1.3$ ).

|             |   |   |    |    |    |          |
|-------------|---|---|----|----|----|----------|
| $a_j$       | 0 | 1 | 2  | 3  | 4  | $\Sigma$ |
| $h_j$       | 5 | 8 | 4  | 2  | 1  | 20       |
| $a_j^2 h_j$ | 0 | 8 | 16 | 18 | 16 | 58       |

**Lösung:**  $s^2 = \frac{58}{20} - 1.3^2 = 2.9 - 1.69 = 1.21$ ;  $s = 1.1$  Kinder.

### Typ 27 Boxplot erstellen mit Ausreißern und Whiskern

**So erkennst du ihn:** „Gibt es Ausreißer? Bis wohin reichen die Whisker? Zeichnen Sie den Boxplot.“ (Tutorium 2, Aufgabe 7)

**Rezept:** (1)  $x_{0.25}$ , Median,  $x_{0.75}$  nach Typ 24. (2) IQR. (3) Zäune:  $x_{0.25} - 1.5 \text{ IQR}$  und  $x_{0.75} + 1.5 \text{ IQR}$ . (4) Werte außerhalb = Ausreißer (Punkte). (5) Whisker bis zum extremsten Wert **innerhalb** der Zäune.

**Musterbeispiel:** 2, 4, 5, 5, 6, 7, 7, 8, 9, 21 ( $n = 10$ ).

1  $10 \cdot 0.25 = 2.5 \rightarrow$  Platz 3  $\rightarrow x_{0.25} = 5$ . Median: Plätze 5, 6  $\rightarrow \frac{6+7}{2} = 6.5$ .  $10 \cdot 0.75 = 7.5 \rightarrow$  Platz 8  $\rightarrow x_{0.75} = 8$ .

2  $\text{IQR} = 8 - 5 = 3$ ;  $1.5 \cdot 3 = 4.5$ .

3 Zäune: unten  $5 - 4.5 = 0.5$ , oben  $8 + 4.5 = 12.5$ .

4  $21 > 12.5 \rightarrow$  **Ausreißer**. Unten:  $2 > 0.5 \rightarrow$  kein Ausreißer.

5 Oberer Whisker: größter Wert  $\leq 12.5 = 9$  (nicht 12.5!). Unterer Whisker: 2.

Skizze: Achse von 0 bis 22, Box von 5 bis 8, Strich bei 6.5, Whisker 2 bis 9, einzelner Punkt bei 21.

### TÜRKÇE AÇIKLAMA

Whisker (bıyık) **sınıra (12.5) kadar değil**, sınırın içinde kalan **en uç gerçek veriye** (9) kadar çizilir. Sınav bunu çok sever. Sınırın dışındaki her değer ayrı bir nokta olarak çizilir.

### Typ 28 Streuung nach Transformation

**So erkennst du ihn:** „Die Lieferzeiten werden in Stunden umgerechnet.“ · „Datensatz III = 2 · Datensatz II.“ · „Zu jedem Wert werden 10 addiert.“

**Rezept:**  $y = a + bx$ :  $s_y^2 = b^2 s_x^2$ ,  $s_y = |b| s_x$ ,  $IQR_y = |b| IQR_x$ . Das  $a$  ist egal!

**Musterbeispiel:**  $\bar{x} = 5$ ,  $s_x^2 = 7.5$ ,  $IQR = 4$ . Neu:  $y = 10 + 3x$ .

**Lösung:**  $\bar{y} = 10 + 15 = 25$ ;  $s_y^2 = 9 \cdot 7.5 = 67.5$ ;  $s_y = 3 \cdot 2.739 = 8.216$ ;  $IQR_y = 12$ . Bei  $y = -2x$ :  $s_y^2 = 4 \cdot 7.5 = 30$  (Varianz wird nie negativ!).

### Typ 29 Boxplots lesen und vergleichen

**So erkennst du ihn:** Mehrere Boxplots nebeneinander (z. B. Gewicht nach Geschlecht) und Aussagen zum Ankreuzen (Testat 1, Aufgabe 6).

**Musterbeispiel:** Fünf-Punkte-Zusammenfassung der Kampfzeiten: Gruppe A: Min 2,  $x_{0.25}$  5, Median 8,  $x_{0.75}$  20, Max 40 (keine Punkte). Gruppe B: 10, 14, 16, 18, 22, dazu ein Punkt bei 35. Welche Aussagen stimmen?

| Aussage                                                    | R/F | Begründung                                                               |
|------------------------------------------------------------|-----|--------------------------------------------------------------------------|
| In A liegen 50 % der Werte zwischen 5 und 20.              | R   | Die Box enthält die mittleren 50 %.                                      |
| A streut stärker als B.                                    | R   | $IQR_A = 15$ , $IQR_B = 4$ .                                             |
| A hat einen Ausreißer bei 40.                              | F   | Kein Punkt eingezeichnet → kein Ausreißer; 40 ist das Ende des Whiskers. |
| A ist rechtsschief.                                        | R   | Median nah am unteren Boxrand, langer oberer Whisker.                    |
| Mehr als die Hälfte von B ist größer als der Median von A. | R   | Schon $\text{Min}_B = 10 > 8 \rightarrow$ alle Werte von B.              |
| Gruppe B verursacht längere Kämpfe.                        | F   | Ein Unterschied ist keine Kausalität.                                    |

### Typ 30 Ein Wert kommt hinzu – was passiert mit $\bar{x}$ und $s^2$ ?

**So erkennst du ihn:** „Ein zusätzlicher Wert ... wird aufgenommen. Wie ändern sich Mittelwert und Varianz?“

**Rezept:** Über Summen gehen:  $\sum x_i = n\bar{x}$ ,  $\sum (x_i - \bar{x})^2 = ns^2$ .

**Musterbeispiel:**  $n = 9$ ,  $\bar{x} = 10$ ,  $s^2 = 4$ . Neuer Wert  $x_{10} = 10$ .

**Lösung:** Neue Summe  $90 + 10 = 100 \rightarrow \bar{x}_{\text{neu}} = 10$  (unverändert). Quadratsumme der Abweichungen  $9 \cdot 4 = 36$ , neue Abweichung  $(10 - 10)^2 = 0 \rightarrow s_{\text{neu}}^2 = \frac{36}{10} = 3.6$ . Ein Wert genau im Mittelwert **verkleinert** die Varianz.

### Übe selbst · Zusatzübungen Z4

- Daten ( $n = 9$ ): 1, 3, 3, 4, 6, 7, 8, 10, 30. Bestimme die Quartile nach Vorlesungsdefinition, IQR, die Zäune und die Whisker. Gibt es Ausreißer?
- $n = 5$ :  $\sum x = 30$ ,  $\sum x^2 = 220$ . Berechne  $s^2$ ,  $s$ ,  $s_*^2$ .
- Für eine Stichprobe liefert R  $\text{sd}(x) = 3$  bei  $n = 10$ . Wie groß ist die empirische Varianz  $s^2$  (mit  $1/n$ )?
- Temperaturen in °C:  $s = 4$ . Wie groß ist die Standardabweichung in °F ( $F = 32 + 1.8C$ )?

Ein Online-Shop notiert für 12 Bestellungen die Lieferzeit in Tagen:

```
> sort(Lieferzeit)
[1] 2 3 3 4 4 4 5 5 6 7 9 14
```

Hinweis:  $\sum x_i = 66$ ,  $\sum x_i^2 = 482$ .

- (a)** Berechnen Sie arithmetisches Mittel und Median. (2 P)

- (b)** Bestimmen Sie das untere und das obere Quartil nach der Definition aus der Vorlesung sowie den Interquartilsabstand. (3 P)

- (c)** Berechnen Sie die empirische Varianz  $s^2$ , die unverzerzte Varianz  $s_*^2$  und die Standardabweichung  $s$ . Geben Sie Ihren Lösungsweg an. (3 P)

- (d)** Gibt es Ausreißer nach der 1.5-IQR-Regel? Bis wohin reichen die Whisker? Skizzieren Sie den Boxplot. (3 P)

- (e)** Die Lieferzeiten werden in Stunden umgerechnet (1 Tag = 24 Stunden). Wie ändern sich Mittelwert, Varianz und Standardabweichung? (2 P)

## 1.7 Zwei Merkmale: Kontingenztafel und $\chi^2$ -Koeffizient

Jetzt schauen wir zwei Merkmale  $X$  und  $Y$  **zusammen** an, gemessen an denselben Einheiten. Die **gemeinsame Verteilung** steht in einer **Kontingenztafel**. Die Summen am Rand heißen **Randverteilungen** (die Verteilung eines Merkmals allein).

### MERKE

Aus der gemeinsamen Verteilung kann man die Randverteilungen immer ausrechnen. Umgekehrt geht das **nur**, wenn die Merkmale **unabhängig** sind. Die gemeinsame Verteilung enthält also mehr Information – nämlich über den **Zusammenhang**.

### BEISPIEL (TUTORIUM 3): 1000 VERKEHRSUNFÄLLE – TABELLE AUS EINEM TEXT BAUEN

Text: „Von 1000 Unfällen waren 380 tödlich (T). Bei 160 tödlichen Unfällen war der Fahrer alkoholisiert (A). Insgesamt gab es 720 Unfälle ohne Alkohol ( $\bar{A}$ ).“

|                           | A (Alkohol) | $\bar{A}$ (kein Alkohol) | $\Sigma$ |
|---------------------------|-------------|--------------------------|----------|
| T (tödlich)               | 160         | 220                      | 380      |
| $\bar{T}$ (nicht tödlich) | 120         | 500                      | 620      |
| $\Sigma$                  | 280         | 720                      | 1000     |

Fett = aus dem Text. Rest durch Differenzen:  $380 - 160 = 220$ ;  $1000 - 380 = 620$ ;  $1000 - 720 = 280$ ;  $280 - 160 = 120$ ;  $720 - 220 = 500$ .

Anteil nicht tödlicher Unfälle:  $620/1000 = 0.62$ . Anteil „tödlich **und** ohne Alkohol“:  $220/1000 = 0.22$ .

### FORMEL: RAND UND BEDINGTE VERTEILUNG

$$h_{j\bullet} = \sum_k h_{jk} \text{ (Zeilensumme)}, \quad h_{\bullet k} = \sum_j h_{jk} \text{ (Spaltensumme)}, \quad f_{jk} = \frac{h_{jk}}{n}$$

$$\text{bedingt: } f(Y = b_k | X = a_j) = \frac{h_{jk}}{h_{j\bullet}} \text{ (Zeile durch Zeilensumme; jede Zeile summiert sich dann zu 1)}$$

Im Beispiel (Spalte durch Spaltensumme):  $f(T | A) = \frac{160}{280} = 0.571$  und  $f(T | \bar{A}) = \frac{220}{720} = 0.306$ . Mit Alkohol ist mehr als jeder zweite Unfall tödlich, ohne Alkohol knapp jeder dritte. Die bedingten Verteilungen sind **verschieden** → es gibt einen **Zusammenhang**.

### BEISPIEL AUS DER VORLESUNG (V03): AUSBILDUNG UND DAUER DER ARBEITSLOSIGKEIT (BEDINGTE VERTEILUNGEN, ZEILENWEISE)

| Ausbildung           | kurz (1–6 M.) | mittel (7–12 M.) | lang (>12 M.) | $\Sigma$ |
|----------------------|---------------|------------------|---------------|----------|
| keine Ausbildung     | 0.699         | 0.154            | 0.147         | 1        |
| Lehre                | 0.730         | 0.184            | 0.086         | 1        |
| Fachspez. Ausbildung | 0.714         | 0.197            | 0.089         | 1        |
| Hochschulabschluss   | 0.800         | 0.114            | 0.086         | 1        |
| Randverteilung       | 0.73          | 0.17             | 0.10          | 1        |

Interpretation: Mit höherer Ausbildung wird Kurzarbeitslosigkeit wahrscheinlicher und Langzeitarbeitslosigkeit unwahrscheinlicher. Wären alle Zeilen gleich (= Randverteilung), gäbe es keinen Zusammenhang.

**FORMEL:  $\chi^2$ -KOEFFIZIENT**

$$\tilde{h}_{jk} = \frac{h_{j\bullet} \cdot h_{\bullet k}}{n} \quad (\text{erwartete Anzahl bei Unabhängigkeit}) \quad \chi^2 = \sum_j \sum_k \frac{(h_{jk} - \tilde{h}_{jk})^2}{\tilde{h}_{jk}}$$

$\chi^2 \approx 0 \rightarrow$  (fast) unabhängig.  $\chi^2$  groß  $\rightarrow$  starker Zusammenhang.  $\chi^2$  ist nie negativ.

**RECHNUNG FÜR DIE UNFÄLLE – SCHRITT FÜR SCHRITT**

**Schritt 1 – erwartete Tabelle:** Zeilensumme mal Spaltensumme durch n.

| $\tilde{h}$ | A                                    | $\bar{A}$                            | $\Sigma$ |
|-------------|--------------------------------------|--------------------------------------|----------|
| T           | $\frac{380 \cdot 280}{1000} = 106.4$ | $\frac{380 \cdot 720}{1000} = 273.6$ | 380      |
| $\bar{T}$   | $\frac{620 \cdot 280}{1000} = 173.6$ | $\frac{620 \cdot 720}{1000} = 446.4$ | 620      |
| $\Sigma$    | 280                                  | 720                                  | 1000     |

**Schritt 2 – vergleichen:** beobachtet minus erwartet:  $160 - 106.4 = 53.6$ ,  $220 - 273.6 = -53.6$ ,  $120 - 173.6 = -53.6$ ,  $500 - 446.4 = 53.6$ . (Bei  $2 \times 2$ -Tafeln sind alle Differenzen gleich groß.)

**Schritt 3 – summieren:**

$$\chi^2 = \frac{53.6^2}{106.4} + \frac{53.6^2}{273.6} + \frac{53.6^2}{173.6} + \frac{53.6^2}{446.4} = 27.0015 + 10.5006 + 16.5493 + 6.4359 = 60.487$$

Ein großer Wert  $\rightarrow$  deutlicher Zusammenhang zwischen Alkohol und tödlichem Ausgang. Am Tag 4 machen wir daraus einen **Test** ( $\chi^2$ -Unabhängigkeitstest).

**Aufgabentypen-Katalog 1.7 · Kontingenztafel und  $\chi^2$** **Typ 31 Kontingenztafel aus einem Text mit Prozenten bauen**

**So erkennst du ihn:** Ein Text mit Anzahlen und Prozentangaben; „Erstellen Sie die vollständige Kontingenztafel (inkl. Randhäufigkeiten).“ (Tutorium 3, KT 1.F)

**Rezept:** (1) Leere Tafel mit  $\Sigma$ -Zeile und  $\Sigma$ -Spalte zeichnen. (2) Jede Zahl aus dem Text an den richtigen Platz. Prozente **von wem?** („30 % der Frauen“  $\rightarrow$  30 % der Zeilensumme Frauen). (3) Rest mit Differenzen füllen. (4) Kontrolle: alle Summen stimmen.

**Musterbeispiel:** 500 Personen werden befragt, 40 % davon sind Frauen. 30 % der Frauen und 50 % der Männer nutzen täglich TikTok.

- 1 Frauen:  $0.4 \cdot 500 = 200$ ; Männer:  $500 - 200 = 300$ .
- 2 Frauen mit TikTok:  $0.3 \cdot 200 = 60$ ; ohne: 140.
- 3 Männer mit TikTok:  $0.5 \cdot 300 = 150$ ; ohne: 150.
- 4 Spaltensummen: TikTok  $60 + 150 = 210$ , kein TikTok  $140 + 150 = 290$ .

|          | TikTok (T) | kein TikTok | $\Sigma$ |
|----------|------------|-------------|----------|
| Frau     | 60         | 140         | 200      |
| Mann     | 150        | 150         | 300      |
| $\Sigma$ | 210        | 290         | 500      |

### TÜRKÇE AÇIKLAMA

„30 % der Frauen“ = kadınların %30'u → kadın satır toplamı (200) ile çarpılır, 500 ile **değil**. „30 % aller Befragten sind Frauen, die TikTok nutzen“ olsaydı 500 ile çarpardın. Cümlede „der/von“ kelimesinden sonra gelen grup, çarpılacak toplamdır.

### Typ 32 Bedingte Anteile berechnen und deuten

**So erkennst du ihn:** „Berechnen Sie den Anteil ... unter den ...“ · „Deutet das auf einen Zusammenhang hin?“ · „Berechnen Sie die bedingte Verteilung von Y gegeben X.“

**Rezept:** „Anteil von A **unter** B“ =  $\frac{h(A \text{ und } B)}{h(B)}$  → Nenner ist die Gruppe nach „unter“. Zusammenhang: bedingte Anteile in den Gruppen **verschieden** → Zusammenhang; gleich → kein Zusammenhang (Unabhängigkeit).

**Musterbeispiel:** Tafel aus Typ 31. (a) Anteil TikTok-Nutzer unter Frauen und unter Männern. (b) Anteil Frauen unter den TikTok-Nutzern. (c) Zusammenhang?

**Lösung:** (a)  $f(T | \text{Frau}) = \frac{60}{200} = 0.3$ ,  $f(T | \text{Mann}) = \frac{150}{300} = 0.5$ . (b)  $f(\text{Frau} | T) = \frac{60}{210} = 0.286$  – **anderer** Nenner als in (a)! (c) Ja:  $0.3 \neq 0.5$ , Männer nutzen TikTok häufiger → Zusammenhang zwischen Geschlecht und Nutzung (aber keine Aussage über Ursachen).

**Bedingte Verteilung als Tabelle** (zeilenweise, jede Zeile summiert sich zu 1):

|      | T    | kein T | $\Sigma$ |
|------|------|--------|----------|
| Frau | 0.3  | 0.7    | 1        |
| Mann | 0.5  | 0.5    | 1        |
| Rand | 0.42 | 0.58   | 1        |

### Typ 33 $\chi^2$ -Koeffizient für eine größere Tafel (2 × 3)

**So erkennst du ihn:** „Berechnen Sie die bei Unabhängigkeit erwarteten Häufigkeiten und den  $\chi^2$ -Koeffizienten.“

**Rezept:** Für jede Zelle:  $\tilde{h} = \frac{\text{Zeilensumme} \cdot \text{Spaltensumme}}{n}$ . Dann pro Zelle  $\frac{(h - \tilde{h})^2}{\tilde{h}}$  und alles addieren. Kontrolle: Die erwarteten Häufigkeiten haben dieselben Randsummen.

**Musterbeispiel:** 200 Studierende, Studienfach und Klausurergebnis:

|          | gut | mittel | schlecht | $\Sigma$ |
|----------|-----|--------|----------|----------|
| BWL      | 30  | 50     | 20       | 100      |
| VWL      | 20  | 30     | 50       | 100      |
| $\Sigma$ | 50  | 80     | 70       | 200      |

1 Erwartet:  $\tilde{h}_{11} = \frac{100 \cdot 50}{200} = 25$ ,  $\tilde{h}_{12} = \frac{100 \cdot 80}{200} = 40$ ,  $\tilde{h}_{13} = \frac{100 \cdot 70}{200} = 35$ ; Zeile VWL genauso (25, 40, 35), weil die Zeilensummen gleich sind.

2 Differenzen  $h - \tilde{h}$ : BWL: +5, +10, -15; VWL: -5, -10, +15.

3  $\chi^2 = 2 \cdot \left( \frac{5^2}{25} + \frac{10^2}{40} + \frac{15^2}{35} \right) = 2 \cdot (1 + 2.5 + 6.429) = 19.857$ .

**Interpretation:**  $\chi^2 = 19.857 > 0$  → es gibt einen Zusammenhang zwischen Studienfach und Ergebnis (VWL-Studierende schneiden häufiger schlecht ab). Ob er „signifikant“ ist, lernst du am Tag 4.

R-Kontrolle: `chisq.test(matrix(c(30,20,50,30,20,50), 2), correct = FALSE)` → X-squared = 19.857.

### Typ 34 Tafel bei Unabhängigkeit auffüllen / fehlende Zelle finden

**So erkennst du ihn:** „Wie müsste die Tabelle aussehen, wenn X und Y unabhängig wären?“ · „Welchen Wert muss  $h_{11}$  haben, damit  $\chi^2 = 0$  ist?“

**Rezept:** Unabhängig  $\Leftrightarrow$  jede Zelle =  $\frac{\text{Zeile} \cdot \text{Spalte}}{n}$   $\Leftrightarrow$  alle Zeilen haben die gleiche bedingte Verteilung  $\Leftrightarrow \chi^2 = 0$ .

**Musterbeispiel 1:** Zeilensummen 40 und 60, Spaltensummen 30 und 70,  $n = 100$ . Tafel bei Unabhängigkeit?

**Lösung:**  $\frac{40 \cdot 30}{100} = 12$ ,  $\frac{40 \cdot 70}{100} = 28$ ,  $\frac{60 \cdot 30}{100} = 18$ ,  $\frac{60 \cdot 70}{100} = 42$ .

**Musterbeispiel 2:** Tafel mit Unbekannter  $a$ : erste Zeile  $(a, 20)$ , zweite Zeile  $(30, 60)$ . Für welches  $a$  sind die Merkmale unabhängig?

**Lösung:** Die Zeilen müssen dasselbe Verhältnis haben:  $\frac{a}{20} = \frac{30}{60} \rightarrow a = 10$ . Kontrolle: Zeilensumme 30, Spaltensumme 40,  $n = 120$ :  $\frac{30 \cdot 40}{120} = 10 \checkmark \rightarrow \chi^2 = 0$ .

### Typ 35 Eigenschaften von $\chi^2$ (richtig/falsch)

| Aussage                                                                             | R/F | Begründung                                                                                                                                                                      |
|-------------------------------------------------------------------------------------|-----|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| $\chi^2$ kann negativ sein.                                                         | F   | Summe von Quadraten geteilt durch positive Zahlen $\rightarrow \chi^2 \geq 0$ .                                                                                                 |
| $\chi^2 = 0$ genau dann, wenn beobachtete = erwartete Häufigkeiten.                 | R   | Dann sind die Merkmale (empirisch) unabhängig.                                                                                                                                  |
| Verdoppelt man alle Häufigkeiten, bleibt $\chi^2$ gleich.                           | F   | $\chi^2$ <b>verdoppelt</b> sich (Unfall-Beispiel: 60.487 $\rightarrow$ 120.97). $\chi^2$ hängt von $n$ ab und ist zwischen Studien mit verschiedenem $n$ schlecht vergleichbar. |
| $\chi^2$ sagt, welche Variable die andere beeinflusst.                              | F   | $\chi^2$ ist symmetrisch und misst nur die Stärke des Zusammenhangs, keine Richtung und keine Ursache.                                                                          |
| $\chi^2$ kann man schon für nominale Merkmale berechnen.                            | R   | Es werden nur Häufigkeiten gebraucht.                                                                                                                                           |
| Aus den Randverteilungen allein kann man die gemeinsame Verteilung immer bestimmen. | F   | Nur bei Unabhängigkeit.                                                                                                                                                         |

### Übe selbst · Zusatzübungen Z5

- Von 400 Kund\*innen zahlen 250 mit Karte. 70 % der Kartenzahlenden sind unter 40 Jahre alt, von den Barzahlenden sind es 40 %. Erstelle die Kontingenztafel.
- Berechne für die Tafel aus Aufgabe 1 den Anteil der Kartenzahlenden unter den Personen unter 40 und unter den Personen ab 40.
- Berechne die erwarteten Häufigkeiten und  $\chi^2$  für die Tafel aus Aufgabe 1.
- Die Zeilen einer Tafel lauten (12, 18) und (20, 30). Wie groß ist  $\chi^2$ ? Begründe ohne Rechnung.

### Klausurtraining 1.F · Rauchen und Sport

12 Punkte

In einer Befragung von 200 Studierenden gaben 60 Personen an, zu rauchen (R). Von den Rauchenden treiben 15 regelmäßig Sport (S). Insgesamt treiben 110 der Befragten keinen regelmäßigen Sport.

**(a)** Erstellen Sie die vollständige Kontingenztafel der absoluten Häufigkeiten (inkl. Randhäufigkeiten).

**(3 P)**

**(b)** Berechnen Sie den Anteil der Sporttreibenden unter den Rauchenden und unter den Nichtrauchernden. **(2 P)**

**(c)** Deutet Ihr Ergebnis aus (b) auf einen Zusammenhang hin? Begründen Sie. **(1 P)**

**(d)** Berechnen Sie die bei Unabhängigkeit erwarteten Häufigkeiten und den  $\chi^2$ -Koeffizienten. **(4 P)**

**(e)** Eine Zeitung schreibt: „Rauchen macht unsportlich.“ Nehmen Sie in 1–2 Sätzen Stellung. **(2 P)**

## 1.8 Kovarianz und Korrelation


Für zwei **metrische** Merkmale zeichnen wir ein **Streudiagramm** (Punktwolke): jede Einheit ist ein Punkt  $(x_i, y_i)$ . Daran sieht man: gleich gerichtet (steigend) oder gegengerichtet (fallend)? Linear oder nicht linear?

**Idee der Kovarianz:** Wir legen ein Kreuz durch den Mittelpunkt  $(\bar{x}, \bar{y})$ . Ein Punkt rechts oben oder links unten ist **konkordant**:  $(x_i - \bar{x})(y_i - \bar{y}) > 0$ . Ein Punkt links oben oder rechts unten ist **diskordant**: das Produkt ist negativ. Die Kovarianz ist der Durchschnitt dieser Produkte.

### FORMEL: KOVARIANZ UND KORRELATION (BRAVAIS-PEARSON)

$$s_{xy} = \text{Cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{n} \sum_{i=1}^n x_i y_i - \bar{x} \bar{y} = \overline{x y} - \bar{x} \bar{y}$$

$$r_{xy} = \rho_{xy} = \frac{s_{xy}}{s_x s_y} = \frac{s_{xy}}{\sqrt{s_x^2 s_y^2}} \in [-1, 1]$$



| $ r $  | 0 bis < 0.3 | 0.3 bis < 0.7 | 0.7 bis 1 |
|--------|-------------|---------------|-----------|
| Stärke | schwach     | mittel        | stark     |

### RECHENBEISPIEL MIT TABELLE (TUTORIUM 3, AUFGABE 3): GEWICHT UND GRÖSSE VON 5 MÄNNERN

| i        | Gewicht $x_i$ (kg) | Größe $y_i$ (cm) | $x_i^2$ | $y_i^2$ | $x_i y_i$ |
|----------|--------------------|------------------|---------|---------|-----------|
| 1        | 93                 | 198              | 8649    | 39204   | 18414     |
| 2        | 72                 | 160              | 5184    | 25600   | 11520     |
| 3        | 83                 | 167              | 6889    | 27889   | 13861     |
| 4        | 104                | 199              | 10816   | 39601   | 20696     |
| 5        | 76                 | 182              | 5776    | 33124   | 13832     |
| $\Sigma$ | 428                | 906              | 37314   | 165418  | 78323     |

- Mittelwerte:  $\bar{x} = \frac{428}{5} = 85.6$ ,  $\bar{y} = \frac{906}{5} = 181.2$ .
- Varianzen:  $s_x^2 = \frac{37314}{5} - 85.6^2 = 7462.8 - 7327.36 = 135.44$ ;  $s_y^2 = \frac{165418}{5} - 181.2^2 = 33083.6 - 32833.44 = 250.16$ .
- Kovarianz:  $s_{xy} = \frac{78323}{5} - 85.6 \cdot 181.2 = 15664.6 - 15510.72 = 153.88$ .
- Korrelation:  $r = \frac{153.88}{\sqrt{135.44 \cdot 250.16}} = \frac{153.88}{184.07} = 0.836$ .
- Interpretation: starker positiver linearer Zusammenhang: Schwerere Männer sind tendenziell größer.

#### MERKE – DIE WICHTIGSTEN EIGENSCHAFTEN

- Die Kovarianz hängt von den **Einheiten** ab (Größe in cm: 153.88 kg·cm; in m: 1.5388 kg·m) → ihr Wert ist schwer zu deuten. Nur das **Vorzeichen** sagt etwas.
- Die Korrelation hat **keine Einheit** und liegt immer zwischen -1 und 1.  $|r| = 1$ : alle Punkte auf einer Geraden.
- $r$  misst nur **lineare** Zusammenhänge.  $r \approx 0$  heißt **nicht** „kein Zusammenhang“: bei  $y = x^2$  (Parabel) kann  $r \approx 0$  sein.
- Unabhängig  $\Rightarrow$  unkorreliert. Aber: unkorreliert  $\nRightarrow$  unabhängig.
- $\text{Cov}(X, X) = \text{Var}(X)$ ; wenn  $X = Y$ , dann  $r = 1$ .

#### KOVARIANZ AUS EINER HÄUFIGKEITSTABELLE (TUTORIUM 3, AUFGABE 5): AUSFÄLLE ZWEIER MASCHINEN AN 100 TAGEN

| X \ Y    | 0    | 1    | 2    | $\Sigma$ |
|----------|------|------|------|----------|
| 0        | 0.30 | 0.14 | 0.02 | 0.46     |
| 1        | 0.18 | 0.10 | 0.02 | 0.30     |
| 2        | 0.12 | 0.06 | 0.06 | 0.24     |
| $\Sigma$ | 0.60 | 0.30 | 0.10 | 1        |

$$\bar{x} = 0 \cdot 0.46 + 1 \cdot 0.30 + 2 \cdot 0.24 = 0.78, \bar{y} = 0.5, s_x^2 = (1 \cdot 0.30 + 4 \cdot 0.24) - 0.78^2 = 0.652, s_y^2 = (0.30 + 0.40) - 0.25 = 0.45.$$

$$\overline{xy} = \sum a_j b_k f_{jk} = 1 \cdot 1 \cdot 0.10 + 1 \cdot 2 \cdot 0.02 + 2 \cdot 1 \cdot 0.06 + 2 \cdot 2 \cdot 0.06 = 0.50 \text{ (Felder mit einer 0 fallen weg).}$$

$$s_{xy} = 0.50 - 0.78 \cdot 0.5 = 0.11; r = \frac{0.11}{\sqrt{0.6516} \cdot \sqrt{0.45}} = 0.203 \rightarrow \text{schwacher positiver linearer Zusammenhang.}$$

#### KLAUSURAUFGABE (PROBEKLAUSUR A, 5B-D, 9 PUNKTE)

Gegeben:  $s_y^2 = 10$ ,  $s_x^2 = 1.6$ ,  $\bar{y} = 22$ ,  $\bar{x} = 3$ ,  $\sum x_\nu y_\nu = 399$ ,  $n = 6$ .

$$s_{xy} = \frac{399}{6} - 3 \cdot 22 = 66.5 - 66 = 0.5 \quad r_{xy} = \frac{0.5}{\sqrt{1.6} \cdot \sqrt{10}} = \frac{0.5}{4} = 0.125$$

**Interpretation** (2 Punkte): Der Korrelationskoeffizient ist die normierte Kovarianz und misst die Stärke des **linearen** Zusammenhangs; er liegt zwischen -1 und 1.  $r = 0.125$  ist positiv, aber klein: **schwacher positiver linearer Zusammenhang** zwischen Schießfehlern und Laufzeit. Mehr Fehler gehen tendenziell mit etwas längerer Laufzeit einher.

**5c – Kausalität?** Nein. Statistische Analysen liefern keinen Nachweis einer **Kausalität**. Der Zusammenhang kann durch dritte Variablen (z. B. Müdigkeit, Wetter) oder Zufall entstehen.

**5d:** Skizze für  $r = 0$ : Punktwolke ohne Richtung (rundliche Wolke) – Achsen beschriften (x: Schießfehler, y: Laufzeit)!

#### Rangkorrelation nach Spearman

Pearson braucht metrische Daten. Für **ordinale** Daten (oder für monotone, nicht lineare Zusammenhänge) ersetzt man die Werte durch ihre **Ränge** (kleinster Wert = Rang 1) und berechnet Pearson mit den Rängen. Bei gleichen Werten (**Bindungen**) bekommen alle den **Durchschnittsrang**.

#### SPEARMAN SCHRITT FÜR SCHRITT: LERNSTUNDEN UND PUNKTE VON 5 STUDIERENDEN

| Person   | Stunden x | Rang x | Punkte y | Rang y | rk(x)·rk(y) |
|----------|-----------|--------|----------|--------|-------------|
| 1        | 2         | 1      | 40       | 1      | 1           |
| 2        | 5         | 3      | 55       | 2.5    | 7.5         |
| 3        | 3         | 2      | 55       | 2.5    | 5           |
| 4        | 8         | 5      | 90       | 5      | 25          |
| 5        | 6         | 4      | 60       | 4      | 16          |
| <b>Σ</b> |           | 15     |          | 15     | 54.5        |

Die zwei Werte 55 teilen sich Platz 2 und 3 → beide bekommen  $\frac{2+3}{2} = 2.5$ . Mittlerer Rang =  $\frac{n+1}{2} = 3$ .  
 $\sum rk_x^2 = 1 + 4 + 9 + 16 + 25 = 55$ ;  $\sum rk_y^2 = 1 + 6.25 + 6.25 + 25 + 16 = 54.5$ ;  $n \cdot 3^2 = 45$ .

$$r_{Sp} = \frac{\sum rk_x rk_y - n \bar{rk}^2}{\sqrt{(\sum rk_x^2 - n \bar{rk}^2)(\sum rk_y^2 - n \bar{rk}^2)}} = \frac{54.5 - 45}{\sqrt{(55 - 45)(54.5 - 45)}} = \frac{9.5}{9.747} = 0.975$$

(Pearson mit den Originalwerten wäre 0.912. Spearman ist höher, weil der Zusammenhang fast perfekt **monoton**, aber nicht perfekt linear ist.) In R: `cor(x, y, method = "spearman")`.

## Korrelation ist keine Kausalität

- **Kausalität:** Eine Änderung von  $X$  **verursacht** eine Änderung von  $Y$ . Nachweis braucht: gezielte Manipulation von  $X$  (Experiment) und Kontrolle aller anderen Einflüsse (z. B. Randomisierung).
- **Scheinkorrelation:** Margarineverbrauch und Scheidungsrate in Maine haben  $r = 0.99$  – aber Margarine verursacht keine Scheidungen. Mögliche dritte Variable: die wirtschaftliche Lage; oder reiner Zufall. Ein Margarineverbot wäre sinnlos.
- **Ökologischer Fehlschluss:** Man schließt von Gruppen-Daten (Stadtbezirke) auf einzelne Personen. EHEC 2011: Bezirke mit vielen Grünen-Wählern hatten mehr Kranke – die Ursache war aber Sprossengemüse, nicht die Partei.
- **Cholera in London** (19. Jh.): Der Vergleich der Wasserversorger zeigte den Zusammenhang zwischen Wasser und Cholera-Toten – die Geburtsstunde der Epidemiologie.

### KONTROLLFRAGEN 1.7 – 1.8 (KURZ)

- 1 Richtig oder falsch (Testat 2)? (a) Wenn  $r \neq 0$ , sind  $X$  und  $Y$  abhängig. (b) Wenn  $Y = -X^2$ , kann  $r \approx 0$  sein. (c) Wenn  $X = Y$ , gilt  $r = 1$ . (d) Wenn  $r \neq 0$ , gibt es einen kausalen Zusammenhang. (e)  $\text{Cov} \geq 0.8$  bedeutet immer starken Zusammenhang.
- 2 Berechne mit dem Verschiebungssatz (Testat 2):  $n = 50$ ,  $\sum x = 2019$ ,  $\sum y = 3733$ ,  $\sum x^2 = 87611$ ,  $\sum y^2 = 301695$ ,  $\sum xy = 160064$ . Gesucht:  $s_{xy}$  und  $r$ .

## Aufgabentypen-Katalog 1.8 · Kovarianz, Korrelation, Kausalität

### Typ 36 Kovarianz und Korrelation aus Rohdaten (Arbeitstabelle)

**So erkennst du ihn:** Zwei Zeilen  $x_\nu, y_\nu$  mit wenigen Werten. „Berechnen Sie Kovarianz und Korrelationskoeffizienten nach Bravais-Pearson.“

**Rezept:** Tabelle mit Spalten  $x, y, x^2, y^2, xy \rightarrow$  fünf Summen  $\rightarrow \bar{x}, \bar{y} \rightarrow s_x^2 = \overline{x^2} - \bar{x}^2, s_y^2 = \overline{y^2} - \bar{y}^2, s_{xy} = \overline{xy} - \bar{x}\bar{y}$   
 $\rightarrow r = \frac{s_{xy}}{\sqrt{s_x^2 s_y^2}}$ .

**Musterbeispiel:** Übungsstunden  $x$  und Punkte  $y$  (in 10er-Punkten) von 5 Personen.

| v | x  | y  | x <sup>2</sup> | y <sup>2</sup> | xy |
|---|----|----|----------------|----------------|----|
| 1 | 1  | 2  | 1              | 4              | 2  |
| 2 | 2  | 4  | 4              | 16             | 8  |
| 3 | 3  | 5  | 9              | 25             | 15 |
| 4 | 4  | 4  | 16             | 16             | 16 |
| 5 | 5  | 5  | 25             | 25             | 25 |
| Σ | 15 | 20 | 55             | 86             | 66 |

- 1  $\bar{x} = 3, \bar{y} = 4.$
- 2  $s_x^2 = \frac{55}{5} - 9 = 2; s_y^2 = \frac{86}{5} - 16 = 1.2.$
- 3  $s_{xy} = \frac{66}{5} - 3 \cdot 4 = 13.2 - 12 = 1.2.$
- 4  $r = \frac{1.2}{\sqrt{2 \cdot 1.2}} = \frac{1.2}{1.549} = 0.775.$
- 5 „Es besteht ein starker positiver linearer Zusammenhang zwischen Übungsstunden und Punkten.“

### Typ 37 Kovarianz und Korrelation aus gegebenen Summen

**So erkennst du ihn:** R-Output mit `length(x)`, `sum(x)`, `sum(x^2)`, `sum(x*y)` ... (Testat 2, Aufgabe 1.2).

**Musterbeispiel:**  $n = 10, \sum x = 50, \sum y = 80, \sum x^2 = 290, \sum y^2 = 700, \sum xy = 430.$

**Lösung:**  $\bar{x} = 5, \bar{y} = 8. s_x^2 = 29 - 25 = 4, s_y^2 = 70 - 64 = 6, s_{xy} = 43 - 40 = 3. r = \frac{3}{\sqrt{4 \cdot 6}} = \frac{3}{4.899} = 0.612 \rightarrow$   
mittlerer positiver linearer Zusammenhang.

**Welche Formel ist richtig?** (Testat 2, 1.1)  $\text{Cov}(X, Y) = \frac{1}{n} \sum x_i y_i - \bar{x} \bar{y}$  – Antwort (d). Achtung:  $\frac{1}{n} \sum (x_i y_i - \bar{x} \bar{y})$  ist zwar gleich viel, aber nicht die „vereinfachte“ Form.

### Typ 38 Rückwärts: Kovarianz aus $r$ oder $r$ aus Standardabweichungen

**So erkennst du ihn:** „Gegeben:  $s_x^2 = 1.6, s_y^2 = 10 \dots$ “ (Probeklausur A, 5b) oder  $r$  ist gegeben und die Kovarianz gesucht.

**Rezept:**  $s_{xy} = r \cdot s_x \cdot s_y$ . Achtung: gegeben sind oft **Varianzen**  $\rightarrow$  erst die Wurzel ziehen!

**Musterbeispiel:**  $r = -0.6, s_x^2 = 4, s_y^2 = 25.$

**Lösung:**  $s_x = 2, s_y = 5 \rightarrow s_{xy} = -0.6 \cdot 2 \cdot 5 = -6.$

### Typ 39 Einheiten ändern: Was passiert mit Kovarianz und Korrelation?

**So erkennst du ihn:** „Der Umsatz wird in Euro statt in Tsd. € angegeben.“  $\cdot$  „Größe in m statt cm.“

**Rezept:**  $u = a + bx, v = c + dy: s_{uv} = b d s_{xy}. r_{uv} = r_{xy}$ , wenn  $b \cdot d > 0; r_{uv} = -r_{xy}$ , wenn  $b \cdot d < 0$ .  
Verschiebungen  $a, c$  sind egal.

**Musterbeispiel:**  $s_{xy} = 153.88 \text{ kg} \cdot \text{cm}, r = 0.836.$  (a) Größe in m. (b) Gewicht in Gramm und Größe in m. (c)  $u = -x$ .

**Lösung:** (a)  $d = 0.01 \rightarrow s = 1.5388 \text{ kg} \cdot \text{m}, r = 0.836.$  (b)  $b = 1000, d = 0.01 \rightarrow s = 1538.8 \text{ g} \cdot \text{m}, r = 0.836.$  (c)  $s = -153.88, r = -0.836.$

### TÜRKÇE AÇIKLAMA

Kovaryans birime bağlıdır (cm → m olunca 100'e bölünür). Korelasyon birimsizdir, **değişmez**. Tek istisna: bir değişkeni negatif bir sayıyla çarparsan korelasyonun sadece **işareti** döner.

#### Typ 40 Spearman-Rangkorrelation (ohne und mit Bindungen)

**So erkennst du ihn:** Ordinale Daten (Platzierungen, Noten, Zufriedenheit) oder „monotoner Zusammenhang“. „Bestimmen Sie den Rangkorrelationskoeffizienten nach Spearman.“

**Rezept:** (1) Ränge vergeben (kleinster = 1, Bindungen = Durchschnittsrang). (2) Pearson mit den Rängen. Ohne Bindungen geht es schneller mit  $r_{Sp} = 1 - \frac{6 \sum d_i^2}{n(n^2-1)}$ ,  $d_i = rk(x_i) - rk(y_i)$ .

**Musterbeispiel:** Zwei Jurorinnen ordnen 5 Bands: Jurorin A: Ränge 1, 2, 3, 4, 5; Jurorin B: Ränge 2, 1, 4, 3, 5.

**Lösung:**  $d = -1, 1, -1, 1, 0$ ;  $\sum d^2 = 4$ ;  $r_{Sp} = 1 - \frac{6 \cdot 4}{5 \cdot 24} = 1 - 0.2 = 0.8 \rightarrow$  starker positiver monotoner Zusammenhang, die Jurorinnen urteilen ähnlich.

**Schnelltrick (KT 1.G d):** Sind die  $x$ -Ränge und die  $y$ -Ränge **genau gleich** (größeres  $x \rightarrow$  immer größeres  $y$ ), ist  $r_{Sp} = 1$  ohne Rechnung; genau umgekehrt  $\rightarrow -1$ .

#### Typ 41 Kovarianz aus einer gemeinsamen Häufigkeitstabelle

**So erkennst du ihn:** Kontingenztafel mit Zahlenwerten als Zeilen/Spalten und relativen Häufigkeiten (Tutorium 3, Aufgabe 5).

**Rezept:** Ränder  $\rightarrow \bar{x}, \bar{y}, s_x^2, s_y^2, \overline{xy} = \sum_j \sum_k a_j b_k f_{jk}$  (Zellen mit 0 fallen weg).  $s_{xy} = \overline{xy} - \bar{x}\bar{y}$ .

**Musterbeispiel:**  $X$  = Kind im Haushalt (0/1),  $Y$  = Haustier (0/1):

| $X \setminus Y$ | 0   | 1   | $\Sigma$ |
|-----------------|-----|-----|----------|
| 0               | 0.4 | 0.1 | 0.5      |
| 1               | 0.2 | 0.3 | 0.5      |
| $\Sigma$        | 0.6 | 0.4 | 1        |

**Lösung:**  $\bar{x} = 0.5, \bar{y} = 0.4$ ;  $s_x^2 = 0.5 \cdot 0.5 = 0.25, s_y^2 = 0.4 \cdot 0.6 = 0.24$  (0/1-Trick aus Typ 22).  $\overline{xy} = 1 \cdot 1 \cdot 0.3 = 0.3$ .  $s_{xy} = 0.3 - 0.2 = 0.1$ .  $r = \frac{0.1}{\sqrt{0.25 \cdot 0.24}} = 0.408 \rightarrow$  mittlerer positiver Zusammenhang.

#### Typ 42 Streudiagramm lesen, zuordnen und skizzieren

**So erkennst du ihn:** „Welche Aussage lässt sich anhand der Punktwolke über  $\rho$  treffen?“ (Testat 2, 1.4) · „Skizzieren Sie ein Streudiagramm mit  $r = 0$ .“ (Probeklausur A, 5d) · „Ordnen Sie die Werte  $-0.9, 0, 0.5, 0.95$  den Grafiken zu.“

**Rezept:** Richtung: steigt die Wolke  $\rightarrow r > 0$ ; fällt  $\rightarrow r < 0$ ; keine Richtung  $\rightarrow r \approx 0$ . Stärke: je **schmäler** die Wolke um eine Gerade, desto näher an  $\pm 1$ . Die **Steigung** sagt nichts über die Stärke!

**Musterlösung für Zuordnung:** fast perfekte steigende Linie  $\rightarrow 0.95$ ; locker steigende Wolke  $\rightarrow 0.5$ ; rundliche Wolke oder Parabel/U-Form  $\rightarrow 0$ ; eng fallende Linie  $\rightarrow -0.9$ .

**Skizze  $r = 0$ :** Achsen beschriften (Name + Einheit), Titel, runde Punktwolke ohne Richtung – oder eine U-Form (zeigt: Zusammenhang da, aber nicht linear).

**Typ 43 Nichtlinearer Zusammenhang mit  $r = 0$** 

**So erkennst du ihn:** „Wenn  $Y = -X^2$ , kann  $\rho$  annähernd 0 sein.“ (Testat 2) · „Unkorreliert heißt unabhängig?“

**Musterbeispiel:**  $x = -2, -1, 0, 1, 2$  und  $y = x^2 = 4, 1, 0, 1, 4$ .

**Lösung:**  $\bar{x} = 0$ ;  $\sum xy = \sum x^3 = -8 - 1 + 0 + 1 + 8 = 0 \rightarrow s_{xy} = 0 - 0 \cdot \bar{y} = 0 \rightarrow r = 0$ . Trotzdem hängt  $y$  **perfekt** von  $x$  ab! Also: unkorreliert  $\neq$  unabhängig;  $r$  misst nur **lineare** Zusammenhänge. (Auch Spearman ist hier 0, weil der Zusammenhang nicht monoton ist.)

**Typ 44 Richtig/falsch zu Korrelation (Testat-2-Stil)**

| Aussage                                                                    | R/F | Begründung                                                                   |
|----------------------------------------------------------------------------|-----|------------------------------------------------------------------------------|
| Wenn $\rho \neq 0$ , sind X und Y niemals unabhängig.                      | R   | Unabhängig $\Rightarrow \rho = 0$ ; also $\rho \neq 0 \Rightarrow$ abhängig. |
| Wenn $Y = -X^2$ , kann $\rho \approx 0$ sein.                              | R   | Parabel, symmetrisch um 0 $\rightarrow$ nicht linear.                        |
| Wenn $X = Y$ , gilt immer $\rho = 1$ .                                     | R   | $\text{Cov}(X, X) = \text{Var}(X) \rightarrow r = 1$ (wenn $s_x > 0$ ).      |
| Wenn $\rho \neq 0$ , besteht ein kausaler Zusammenhang.                    | F   | Korrelation $\neq$ Kausalität (Drittvariablen, Zufall).                      |
| $\text{Cov} \geq 0.8$ bedeutet immer einen starken Zusammenhang.           | F   | Die Kovarianz hängt von den Einheiten ab; nur $r$ ist normiert.              |
| Mit mehr als 60 Stunden Lernen hat man auf jeden Fall mehr als 100 Punkte. | F   | Stochastischer, nicht deterministischer Zusammenhang: Es gibt Ausnahmen.     |
| $r = -0.9$ ist ein schwächerer Zusammenhang als $r = 0.5$ .                | F   | Die Stärke ist $ r $ : $0.9 > 0.5$ .                                         |

**Typ 45 Kausalität beurteilen und Drittvariable nennen**

**So erkennst du ihn:** „Die Geschäftsführung folgert ... Beurteilen Sie.“ · „Kann man daraus schließen, dass ...?“ · „Nennen Sie eine mögliche Drittvariable.“ (Probeklausur A, 5c)

**Mustergerüst (3 Sätze):** (1) „Nein, eine Korrelation belegt keine Kausalität.“ (2) „Der Zusammenhang könnte durch eine Drittvariable wie ... entstehen, die beide Merkmale beeinflusst (oder durch Zufall / umgekehrte Richtung).“ (3) „Für einen Kausalnachweis bräuchte man ein Experiment mit zufälliger Zuteilung (Randomisierung).“

**Musterbeispiel:** In Städten mit mehr Störchen werden mehr Kinder geboren ( $r = 0.7$ ).

**Lösung:** Nein, Störche bringen keine Kinder. Drittvariable: **ländliche Gegend / Größe der Region** – auf dem Land gibt es mehr Störche und tendenziell mehr Geburten pro Kopf. Weitere Klassiker: Eisverkauf  $\leftrightarrow$  Ertrinken (Drittvariable: Temperatur/Sommer); Feuerwehrleute  $\leftrightarrow$  Schaden (Drittvariable: Größe des Brandes); umgekehrte Richtung: Krankenhausaufenthalt  $\leftrightarrow$  Krankheit.

**TÜRKÇE AÇIKLAMA**

Bu soru tipinde puanı **gerekçe** getirir. Sadece „Nein“ yazma. Kalıp: *Hayır + üçüncü değişken örneği + randomize deney gerekir*. Üçüncü değişken (Drittvariable/Störvariable) her iki değişkeni birden etkileyen şeydir.

### Übe selbst · Zusatzübungen Z6

1.  $x$ : 2, 4, 6, 8;  $y$ : 10, 7, 5, 2. Berechne  $s_{xy}$  und  $r$ . Wie groß ist  $r_{Sp}$  (ohne Rechnung)?
2.  $n = 20$ ,  $\bar{x} = 4$ ,  $\bar{y} = 10$ ,  $\sum xy = 760$ ,  $s_x = 2$ ,  $s_y = 5$ . Berechne  $s_{xy}$  und  $r$ .
3. Temperatur in °C und Eisverkauf in Stück haben  $s_{xy} = 120$  und  $r = 0.8$ . Wie lauten beide Werte, wenn die Temperatur in °F ( $F = 32 + 1.8C$ ) angegeben wird?
4. Zwei Lehrer ordnen 4 Aufsätze: Ränge A: 1, 2, 3, 4; Ränge B: 4, 3, 1, 2. Berechne  $r_{Sp}$ .
5. „Menschen, die mehr Kaffee trinken, haben häufiger Lungenkrebs.“ Beurteile die Aussage „Kaffee verursacht Lungenkrebs“ und nenne eine Drittvariable.

### Klausurtraining 1.G · Werbung und Umsatz

14 Punkte

Eine Bäckereikette untersucht in 6 Filialen die Werbeausgaben  $X$  (in Tsd. €) und den Umsatz  $Y$  (in Tsd. €) eines Monats:

| Filiale $v$ | 1  | 2  | 3  | 4  | 5  | 6  |
|-------------|----|----|----|----|----|----|
| $x_v$       | 2  | 4  | 3  | 6  | 5  | 1  |
| $y_v$       | 30 | 45 | 38 | 60 | 48 | 25 |

Hinweis:  $\sum x = 21$ ,  $\sum y = 246$ ,  $\sum x^2 = 91$ ,  $\sum y^2 = 10898$ ,  $\sum xy = 979$ .

- (a) Zeichnen Sie ein beschriftetes Streudiagramm. (2 P)

- (b) Berechnen Sie die empirische Kovarianz. Geben Sie Ihren Lösungsweg an. (2 P)

- (c) Berechnen Sie den Korrelationskoeffizienten nach Bravais-Pearson und interpretieren Sie ihn. (4 P)

- (d) Bestimmen Sie den Rangkorrelationskoeffizienten nach Spearman, ohne lange zu rechnen. Begründen Sie. (2 P)

- (e) Der Umsatz wird nun in Euro statt in Tsd. € angegeben. Wie ändern sich Kovarianz und Korrelation? (2 P)

- (f) Die Geschäftsführung folgert: „Mehr Werbung verursacht mehr Umsatz.“ Beurteilen Sie diese Aussage und nennen Sie eine mögliche Drittvariable. (2 P)

## 1.9 R-Kurs von null an

Klausurteil B (45 Punkte, 60 Minuten) schreibst du am Computer mit **RStudio**. Hier lernst du R **Befehl für Befehl**. Bei jedem Befehl siehst du: den Code (dunkler Kasten), die echte Ausgabe von R (heller Kasten, beginnt oft mit `[1]`) und eine Erklärung. Bei schwierigen Stellen gibt es eine **türkische Erklärung**.

### SO LERNST DU R RICHTIG

Öffne RStudio und tippe **jeden** Befehl selbst ab (nicht kopieren!). Die Übungsdatei `Taverne.csv` liegt im Ordner `Lernpaket/uebungsdaten`. Lege sie in deinen Ordner *Dokumente*. R lernt man nur mit den Fingern.

### TÜRKÇE AÇIKLAMA

R'ı sadece okuyarak öğrenemezsin. Her komutu RStudio'da **kendin yaz** ve Enter'a bas. Çıkan sonucu buradaki açık renkli kutuyla karşılaştı. Hata alırsan panik yapma: hata mesajını oku, genelde bir virgöl, tırnak işareti ya da büyük/küçük harf hatasıdır. Sınav B kısmının 45 puanı tamamen buna bağlı.

### 1.9.1 RStudio kennenlernen

| Fenster                                    | Was ist das?                                                                                                             | Türkçe                               |
|--------------------------------------------|--------------------------------------------------------------------------------------------------------------------------|--------------------------------------|
| <b>Skript</b> (oben links)                 | Hier schreibst du deine Befehle. Datei → New File → R Script. Speichern mit Strg + S (Datei endet auf <code>.R</code> ). | Kodları yazdığın defter. Kaydedilir. |
| <b>Konsole</b> (unten links)               | Hier führt R die Befehle aus und zeigt das Ergebnis. Zeichen <code>&gt;</code> = R wartet.                               | Sonuçların çıktığı yer.              |
| <b>Environment</b> (oben rechts)           | Liste aller Objekte, die du gespeichert hast (z. B. <code>d</code> , <code>x</code> ).                                   | Kaydettiğin nesnelerin listesi.      |
| <b>Plots / Files / Help</b> (unten rechts) | Grafiken, Dateien im Ordner, Hilfe zu Befehlen.                                                                          | Grafikler, dosyalar, yardım.         |

**Ausführen:** Cursor in die Zeile setzen und **Strg + Enter** drücken (Mac: Cmd + Enter). Mehrere Zeilen markieren und Strg + Enter führt alle aus. **Kommentare** beginnen mit `#` – R ignoriert alles dahinter. Schreibe Kommentare, damit die Korrektoren deinen Weg verstehen.

### 1.9.2 R als Taschenrechner und Objekte

```
3 + 4 * 2      # Punkt vor Strich
(3 + 4) * 2
2^3           # Potenz: 2 hoch 3
sqrt(16)      # Wurzel
log(10); exp(1) # natürlicher Logarithmus, e hoch 1
choose(10, 2)  # Binomialkoeffizient "10 über 2"
```

```
[1] 11
[1] 14
[1] 8
[1] 4
[1] 2.302585
[1] 2.718282
[1] 45
```

Das `[1]` bedeutet nur: „Hier beginnt das erste Element der Ausgabe“. Es ist kein Teil des Ergebnisses.

```
a <- 5          # Objekt a bekommt den Wert 5
b <- a * 2
b
```

```
[1] 10
```

- `<-` ist der **Zuweisungspfeil** („bekommt“): kleiner-Zeichen und Minus. Man kann auch `=` schreiben, aber `<-` ist üblich.
- Bei einer Zuweisung zeigt R **nichts** an. Um den Inhalt zu sehen, tippt man den Namen (`b`) oder setzt Klammern um die ganze Zeile: `(b <- a * 2)`.
- Namen: Buchstaben, Zahlen, Punkt, Unterstrich; nicht mit einer Zahl beginnen. **Groß-/Kleinschreibung zählt**: `d` und `D` sind zwei verschiedene Objekte.
- Dezimalzahlen immer mit **Punkt**: `2.5`. Das Komma trennt in R die Argumente eines Befehls!

#### TÜRKÇE AÇIKLAMA

`<-` işareti “içine koy / ata” demektir: `a <- 5` → “a adlı kutuya 5’i koy”. Ondalık sayılarda **nokta** kullan (2.5); virgöl R’da komutun parçalarını (argümanları) ayırır. Büyük-küçük harf farklıdır: `Mean` çalışmaz, `mean` çalışır.

### 1.9.3 Vektoren – die wichtigste Datenstruktur

Ein **Vektor** ist eine Reihe von Werten des gleichen Typs, z. B. alle Beobachtungen eines Merkmals.

```
x <- c(3, 2, 5, 1, 3, 4)  # c() = "combine": Werte zusammenfügen
x
length(x)                # Anzahl der Werte = n
```

```
[1] 3 2 5 1 3 4
[1] 6
```

**Auf Elemente zugreifen** mit eckigen Klammern `[ ]` (Position zählt ab 1):

```
x[1]      # erstes Element
x[c(2, 4)] # zweites und viertes Element
x[-1]     # alle AUSSER dem ersten
```

```
[1] 3
[1] 2 1
[1] 2 5 1 3 4
```

**Rechnen mit Vektoren**: R rechnet automatisch mit **jedem** Element („vektorisiert“) – du brauchst keine Schleife.

```
x * 2
x + 10
sum(x)
sort(x)      # aufsteigend sortieren
```

```
[1] 6 4 10 2 6 8
[1] 13 12 15 11 13 14
[1] 18
[1] 1 2 3 3 4 5
```

**Bedingungen** (logische Vektoren): Ein Vergleich gibt für jedes Element `TRUE` (wahr) oder `FALSE` (falsch).

```
x > 2
x[x > 2]      # nur die Werte, bei denen die Bedingung TRUE ist
sum(x > 2)     # wie viele sind größer als 2? (TRUE zählt als 1)
mean(x > 2)    # welcher ANTEIL ist größer als 2?
```

```
[1] TRUE FALSE TRUE FALSE TRUE TRUE
[1] 3 5 3 4
[1] 4
[1] 0.6666667
```

Vergleichszeichen: `>`, `>=` (größer gleich), `<`, `<=`, `==` (gleich – **zwei** Gleichheitszeichen!), `!=` (ungleich). Verknüpfen: `&` (und), `|` (oder).

### TÜRKÇE AÇIKLAMA

`x > 2` her eleman için “doğru mu yanlış mı?” sorusunu sorar. R’da TRUE = 1, FALSE = 0 sayılır. Bu yüzden `sum(x > 2)` kaç tane olduğunu, `mean(x > 2)` ise **oranını** verir. “Eşittir” için **iki** eşittir işareti yazılır: `==`. Tek `=` atama yapar, karşılaştırma yapmaz!

### Folgen erzeugen:

```
1:6           # ganze Zahlen von 1 bis 6
seq(0, 20, by = 5) # von 0 bis 20 in 5er-Schritten
rep(1/6, 3)    # den Wert 1/6 dreimal wiederholen
```

```
[1] 1 2 3 4 5 6
[1]  0  5 10 15 20
[1] 0.1666667 0.1666667 0.1666667
```

### 1.9.4 Datentypen: typeof, class, factor

In beiden R-Probeklausuren gab es 2–4 Punkte für die Frage: „Welchen Objekttyp hat die Variable?“

```
typeof(x)           # x = c(3, 2, 5, 1, 3, 4)
typeof(1:6)
typeof(c("Wolf", "Troll"))
typeof(x > 2)
```

```
[1] "double"
[1] "integer"
[1] "character"
[1] "logical"
```

| Typ       | Bedeutung                                                                | Beispiel                           | Türkçe                   |
|-----------|--------------------------------------------------------------------------|------------------------------------|--------------------------|
| double    | Kommazahl (Oberbegriff: <b>numeric</b> )                                 | Lungenvolumen 2.35, Kampfzeit 12.5 | ondalıkli sayı           |
| integer   | ganze Zahl (auch <b>numeric</b> )                                        | Anzahl Münzen 18                   | tam sayı                 |
| character | Text (in Anführungszeichen)                                              | "Bergtal"                          | metin                    |
| logical   | TRUE / FALSE                                                             | <code>x &gt; 2</code>              | mantıksal (doğru/yanlış) |
| factor    | Kategorien mit festen Stufen (levels); mit <code>class()</code> erkennen | Ergebnis von <code>cut()</code>    | kategorik değişken       |

```
f <- factor(c("Wolf", "Troll", "Wolf"))
f
class(f)
levels(f)      # die möglichen Kategorien (alphabetisch sortiert)
```

```
[1] Wolf  Troll Wolf
Levels: Troll Wolf
[1] "factor"
[1] "Troll" "Wolf"
```

`typeof()` zeigt den **Speichertyp**, `class()` die **Klasse**. Bei einem Faktor sagt `typeof` „integer“ (intern Nummern), `class` aber „factor“. In der Klausur ist beides als Befehl okay (Musterlösung: „`typeof()`“, alternativ `class()`, `str(d)`“).

## 1.9.5 Einen Datensatz einlesen

Die Übungsdatei `Taverne.csv` sieht als Text so aus (erste Zeilen):

```
Taverne;Tal;Monster;Muenzen;Kampfzeit
T01;Flusstal;Ghul;18;12.5
T02;Bergtal;Troll;25;45.0
T03;Flusstal;Wolf;12;3.2
```

Man sieht: Die erste Zeile enthält die **Namen** (header), die Spalten sind mit **Semikolon** getrennt (sep), Dezimalzeichen ist der **Punkt** (dec).

```
setwd(path.expand("~/"))      # Arbeitsordner = Dokumente (genau so in der Klausur!)
getwd()                       # zeigt den aktuellen Arbeitsordner
d <- read.csv("Taverne.csv", header = TRUE, sep = ";", dec = ".")
head(d)                       # die ersten 6 Zeilen
```

|   | Taverne | Tal      | Monster | Muenzen | Kampfzeit |
|---|---------|----------|---------|---------|-----------|
| 1 | T01     | Flusstal | Ghul    | 18      | 12.5      |
| 2 | T02     | Bergtal  | Troll   | 25      | 45.0      |
| 3 | T03     | Flusstal | Wolf    | 12      | 3.2       |
| 4 | T04     | Walddal  | Greif   | 30      | 75.5      |
| 5 | T05     | Bergtal  | Ghul    | 22      | 8.0       |
| 6 | T06     | Walddal  | Wolf    | 15      | 4.5       |

| Teil                               | Bedeutung                                                                           | Türkçe                                 |
|------------------------------------|-------------------------------------------------------------------------------------|----------------------------------------|
| <code>setwd(...)</code>            | „set working directory“: In diesem Ordner sucht R Dateien und speichert PDFs.       | Çalışma klasörünü ayarla.              |
| <code>path.expand("~/")</code>     | „~“ ist der Benutzerordner; im Prüfungsraum ist das <i>Dokumente</i> .              | Kullanıcı klasörü (sınavda Dokumente). |
| <code>d &lt;- read.csv(...)</code> | Datei lesen und als <b>Data Frame</b> (Tabelle) im Objekt <code>d</code> speichern. | Dosyayı oku, tabloyu d'ye kaydet.      |
| <code>"Taverne.csv"</code>         | Dateiname in Anführungszeichen, genau so geschrieben.                               | Dosya adı, tırnak içinde.              |
| <code>header = TRUE</code>         | Die erste Zeile enthält die Spaltennamen.                                           | İlk satır sütun isimleri.              |
| <code>sep = ";"</code>             | Trennzeichen zwischen den Spalten (oft „," oder ";").                               | Sütunları ayıran işaret.               |
| <code>dec = "."</code>             | Dezimalzeichen in der Datei („." oder ",").                                         | Ondalık işareti.                       |

**Die Struktur ansehen** – der wichtigste Befehl nach dem Einlesen:

```
str(d)
```

```
'data.frame':  12 obs. of  5 variables:
 $ Taverne   : chr  "T01" "T02" "T03" "T04" ...
 $ Tal       : chr  "Flusstal" "Bergtal" "Flusstal" "Walddal" ...
 $ Monster   : chr  "Ghul" "Troll" "Wolf" "Greif" ...
 $ Muenzen   : int   18 25 12 30 22 15 27 33 20 10 ...
 $ Kampfzeit : num   12.5 45 3.2 75.5 8 4.5 50 90 15 2.5 ...
```

Lies so: 12 Beobachtungen (Zeilen), 5 Variablen (Spalten). `chr` = character, `int` = integer, `num` = numeric/double. **Prüfe hier immer, ob das Einlesen geklappt hat!** Wenn alles in einer einzigen Spalte steht, war `sep` falsch. Wenn Zahlen als `chr` erscheinen, war oft `dec` falsch.

```
names(d)      # Spaltennamen
dim(d)        # Zeilen, Spalten
d$Muenzen     # eine Spalte mit $ auswählen -> Vektor
```

```
[1] "Taverne" "Tal" "Monster" "Muenzen" "Kampfzeit"
[1] 12 5
[1] 18 25 12 30 22 15 27 33 20 10 24 29
```

**Zeilen und Spalten auswählen** mit `d[Zeile, Spalte]`. Leer lassen = „alle“:

```
d[2, ] # Zeile 2, alle Spalten
d[1:3, c("Tal", "Muenzen")] # Zeilen 1-3, zwei Spalten
```

```
  Taverne    Tal Monster Muenzen Kampfzeit
2    T02 Bergtal  Troll    25      45
  Tal Muenzen
1 Flusstal    18
2 Bergtal    25
3 Flusstal    12
```

```
typeof(d$Tal)
typeof(d$Muenzen)
typeof(d$Kampfzeit)
```

```
[1] "character"
[1] "integer"
[1] "double"
```

### TÜRKÇE AÇIKLAMA

Data frame = Excel tablosu gibi bir tablo. Her sütun bir değişken, her satır bir gözlem. `d$Muenzen` → “d tablosundaki Muenzen sütunu”. `d[2, ]` → “2. satır, bütün sütunlar” (virgülden önce satır, sonra sütun). Veriyi okuduktan hemen sonra `str(d)` yaz: veri doğru okunduysa sayılar `int / num`, metinler `chr` görünür. Her şey tek sütundaysa `sep` yanlıştır.

## 1.9.6 Kennzahlen berechnen

```
mean(d$Muenzen) # arithmetisches Mittel
median(d$Muenzen) # Median
var(d$Muenzen) # Varianz -> mit 1/(n-1) !
sd(d$Muenzen) # Standardabweichung -> mit 1/(n-1) !
```

```
[1] 22.08333
[1] 23
[1] 53.17424
[1] 7.292067
```

### ACHTUNG: VAR() UND SD() SIND DIE UNVERZERRTEN VERSIONEN

R teilt durch  $n - 1$ . Das ist genau der „unverzerrte Schätzer für die Standardabweichung  $s_*$ “ aus der Probeklausur B. Brauchst du die Varianz mit  $\frac{1}{n}$ , rechnest du um:

```
n <- length(d$Muenzen)
var(d$Muenzen) * (n - 1) / n # Varianz mit 1/n
```

```
[1] 48.74306
```

```
round(mean(d$Muenzen), 3)      # IMMER runden, wenn eine Zahl gefragt ist
round(sd(d$Muenzen), 3)
range(d$Muenzen)              # Minimum und Maximum (Wertebereich)
quantile(d$Muenzen, c(0.25, 0.5, 0.75))
IQR(d$Muenzen)
summary(d$Muenzen)
```

```
[1] 22.083
[1] 7.292
[1] 10 33
 25%   50%   75%
17.25 23.00 27.50
[1] 10.25
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 10.00  17.25   23.00   22.08  27.50   33.00
```

`round(wert, 3)` : erstes Argument = was gerundet wird, zweites = Anzahl Nachkommastellen. Man kann Befehle **verschachteln**: R rechnet von innen nach außen – erst `mean`, dann `round`. (Die Quantile von R sind interpoliert und können von der Handrechnung abweichen – in Teil B ist der R-Wert richtig.)

**Häufigkeiten** für kategoriale Variablen:

```
table(d$Monster)              # absolute Häufigkeiten
prop.table(table(d$Monster))  # relative Häufigkeiten (Anteile)
which(table(d$Monster) == max(table(d$Monster))) # Modus
```

```
Ghul Greif Troll Wolf
 3     2     4     3

      Ghul      Greif      Troll      Wolf
0.2500000 0.1666667 0.3333333 0.2500000

Troll
 3
```

Beim Modus liest du den **Namen** (Troll) – die 3 darunter ist nur die Position in der Tabelle, nicht die Anzahl!

**Nach Gruppen rechnen und filtern:**

```
tapply(d$Muenzen, d$Tal, mean)      # Mittelwert von Muenzen für jedes Tal
subset(d, Tal == "Bergtal")         # nur die Zeilen aus dem Bergtal
d[d$Muenzen > 25, ]                  # nur Zeilen mit mehr als 25 Münzen
mean(d$Muenzen > 25)                 # Anteil mit mehr als 25 Münzen
```

```
Bergtal Flusstal Walddtal
 26.00   16.75   23.50
Taverne   Tal Monster Muenzen Kampfzeit
2    T02 Bergtal  Troll     25      45
5    T05 Bergtal  Ghul     22       8
8    T08 Bergtal  Greif     33     90
11   T11 Bergtal  Troll     24     38
Taverne   Tal Monster Muenzen Kampfzeit
4    T04 Walddtal  Greif     30    75.5
7    T07 Flusstal  Troll     27    50.0
8    T08 Bergtal  Greif     33    90.0
12   T12 Walddtal  Troll     29    62.0
[1] 0.3333333
```

## TÜRKÇE AÇIKLAMA

`tapply(A, B, mean)` → "A değişkeninin ortalamasını, B'nin her grubu için ayrı ayrı hesapla". `subset(d, Tal == "Bergtal")` → "sadece Bergtal satırlarını al". `d[d$Muenzen > 25, ]` aynı mantık: köşeli parantezin içinde, virgülden önce bir koşul yazarsan sadece koşulu sağlayan satırlar gelir.

## Fehlende Werte (NA):

```
x <- c(3, 2, 5, NA, 4)
mean(x)
mean(x, na.rm = TRUE)      # na.rm = "NA remove": fehlende Werte weglassen
```


```
[1] NA
[1] 3.5
```

## 1.9.7 Grafiken zeichnen und als PDF speichern

In der Klausur musst du Grafiken als PDF-Datei speichern und hochladen (z. B. 7–8 Punkte für ein Histogramm!). Das geht in **drei Schritten**:

```
pdf("Histogramm.pdf")           # 1. PDF-Datei öffnen
hist(d$Muenzen,                 # 2. Grafik zeichnen
     breaks = c(10, 20, 30, 40), # Klassengrenzen
     right = FALSE,              # Intervalle [a, b)
     freq = FALSE,               # Dichte statt Anzahl -> normiert
     main = "Sitz 12, Matr.Nr. 12345678, Aufgabenteil d)",
     xlab = "Muenzen",
     ylab = "Dichte")
dev.off()                       # 3. PDF-Datei schließen (WICHTIG!)
```

Sitz 12, Matr.Nr. 12345678, Aufgabenteil d)



So sieht die gespeicherte Grafik aus.

| Argument                      | Bedeutung                                                                 |
|-------------------------------|---------------------------------------------------------------------------|
| <code>breaks = c(...)</code>  | Klassengrenzen                                                            |
| <code>right = TRUE</code>     | (a, b] – rechts geschlossen (Standard)                                    |
| <code>right = FALSE</code>    | [a, b) – links geschlossen                                                |
| <code>freq = FALSE</code>     | normiert: $y = \text{Dichte}$ , Fläche 1 (= $\text{prob} = \text{TRUE}$ ) |
| <code>freq = TRUE</code>      | $y = \text{absolute Anzahl}$ (Standard)                                   |
| <code>main</code>             | Titel (Aufgabenteil, Matr.-Nr., Sitz!)                                    |
| <code>xlab, ylab</code>       | Beschriftung der Achsen                                                   |
| <code>ylim = c(0, 0.1)</code> | Bereich der y-Achse                                                       |

Die Zahlen hinter dem Histogramm bekommst du mit `plot = FALSE`:

```
h <- hist(d$Muenzen, breaks = c(10, 20, 30, 40), right = FALSE, plot = FALSE)
h$counts      # Anzahl pro Klasse
h$density     # Höhe pro Klasse = Anteil / Breite
```

```
[1] 4 6 2
[1] 0.03333333 0.05000000 0.01666667
```

Kontrolle: 4 von 12 Werten in [10, 20) → Anteil 0.3333, Breite 10 → Höhe 0.0333. ✓

## TÜRKÇE AÇIKLAMA



Grafiği PDF olarak kaydetmek üç adımdır: **(1)** `pdf("isim.pdf")` ile dosyayı aç, **(2)** grafiği çiz, **(3)** `dev.off()` ile dosyayı kapat. `dev.off()` unutulursa PDF boş kalır ve puan gider! Başlıkta (`main`) sınavda mutlaka **alt görev harfi, matrikül numarası ve oturduğun yer numarası** olmalı. `freq = FALSE` histogramı "normalleştirir": y ekseninde yoğunluk olur, toplam alan 1'dir.

## Weitere Grafiken:

```
plot(d$Kampfzeit, d$Muenzen, pch = 16,                # Streudiagramm: erst x, dann y
     xlab = "Kampfzeit (min)", ylab = "Muenzen", main = "Streudiagramm")
boxplot(Muenzen ~ Tal, data = d,                       # Boxplot je Gruppe
        main = "Muenzen je Tal", xlab = "Tal", ylab = "Muenzen")
boxplot(d$Kampfzeit, plot = FALSE)$stats             # Zahlen des Boxplots
```

```
[,1]
[1,] 2.50
[2,] 6.25
[3,] 26.50
[4,] 56.00
[5,] 90.00
```

Die fünf Zahlen sind: unterer Whisker, unteres Quartil, Median, oberes Quartil, oberer Whisker. `pch = 16` macht gefüllte Punkte.



**Alternative zu `pdf()/dev.off()`:** Grafik im Plots-Fenster zeichnen und über *Export* → *Save as PDF* speichern. Mit `pdf()` ist es aber sicherer und steht im Skript.

## 1.9.8 Klassen bilden, Kontingenztafeln, Korrelation

Mit `cut()` teilt man eine metrische Variable in Klassen. Das Ergebnis ist ein **factor**.

```
d$Kampfzeit.3 <- cut(d$Kampfzeit, breaks = c(0, 5, 60, Inf), right = FALSE)
d$Kampfzeit.3
table(d$Kampfzeit.3)
```

```
[1] [5,60) [5,60) [0,5) [60,Inf) [5,60) [0,5) [5,60) [60,Inf)
[9] [5,60) [0,5) [5,60) [60,Inf)
Levels: [0,5) [5,60) [60,Inf)

[0,5) [5,60) [60,Inf)
3      6      3
```

- `d$Kampfzeit.3 <- ...` legt eine **neue Spalte** im Data Frame an.
- `Inf` = unendlich (für „60 Minuten oder mehr“).

- `right = FALSE`:  $[0,5)$  = „weniger als 5 Minuten“,  $[5,60)$  = „5 bis weniger als 60“. Für „bis zu 10“, „mehr als 10 bis 20“ brauchst du `right = TRUE`:  $(0,10]$ ,  $(10,20]$ .
- Eigene Namen für die Klassen mit `labels`:

```
d$Muenzen.3 <- cut(d$Muenzen, breaks = c(0, 15, 25, Inf),
                  labels = c("wenig", "mittel", "viel"))
table(d$Muenzen.3)
```

```
wenig mittel  viel
      3      5      4
```

**Kontingenztafel** und bedingte Anteile:

```
table(d$Tal, d$Kampfzeit.3)           # Zeilen = Tal, Spalten = Kampfzeit-Klasse
round(prop.table(table(d$Tal[d$Kampfzeit.3 == "[5,60)"])), 2)
```

|          | $[0,5)$ | $[5,60)$ | $[60,Inf)$ |
|----------|---------|----------|------------|
| Bergtal  | 0       | 3        | 1          |
| Flusstal | 2       | 2        | 0          |
| Waldtal  | 1       | 1        | 2          |

| Bergtal | Flusstal | Waldtal |
|---------|----------|---------|
| 0.50    | 0.33     | 0.17    |

Die zweite Zeile liest man von innen nach außen: nimm die Täler `d$Tal`, aber nur dort, wo die Kampfzeit in  $[5,60)$  liegt (`[...]`), zähle sie (`table`), mache Anteile daraus (`prop.table`), runde auf 2 Stellen (`round`). Das ist genau Testat 2, Aufgabe 3.7 (Randverteilung für eine Teilgruppe).

```
cor(d$Muenzen, d$Kampfzeit)           # Pearson
cor(d$Muenzen, d$Kampfzeit, method = "spearman") # Spearman
```

```
[1] 0.9275322
[1] 0.979021
```

### TÜRKÇE AÇIKLAMA

`cut()` sürekli bir değişkeni sınıflara (aralıklara) böler ve bir **factor** üretir. `breaks` sınır noktalarıdır; `Inf` sonsuz demektir. `right = FALSE` → aralıklar **[a, b)**: sol sınır dahil, sağ sınır hariç ("5 dakikadan az" gibi ifadeler için).  
`right = TRUE` → **(a, b]**: "en fazla 10" gibi ifadeler için. Soru metnindeki kelimelere çok dikkat et: "weniger als" (-den az) ve "bis zu / maximal" (en fazla) farklı sınırlar demektir.

## 1.9.9 Hilfe und typische Fehlermeldungen

```
?hist           # Hilfeseite zu hist öffnen (auch in der Klausur erlaubt!)
help(read.csv)
```

| Fehlermeldung                          | Ursache                              | Lösung                                                                              |
|----------------------------------------|--------------------------------------|-------------------------------------------------------------------------------------|
| object 'd' not found                   | Objekt existiert (noch) nicht        | Einlese-Zeile zuerst ausführen; Schreibweise prüfen                                 |
| cannot open file 'X.csv': No such file | falscher Ordner oder Dateiname       | <code>setwd(path.expand("~/"))</code> , <code>list.files()</code> zeigt die Dateien |
| could not find function "Mean"         | Tippfehler / Großschreibung          | <code>mean</code>                                                                   |
| unexpected ')' oder '+' in der Konsole | Klammer oder Anführungszeichen fehlt | Esc drücken, Klammern zählen                                                        |
| Ergebnis NA                            | fehlende Werte                       | <code>na.rm = TRUE</code>                                                           |
| PDF ist leer / beschädigt              | <code>dev.off()</code> vergessen     | <code>dev.off()</code> ausführen                                                    |

### 1.9.10 Die wichtigsten Befehle von Tag 1 auf einen Blick

| Befehl                                                                                     | Was er macht                          | Türkçe                        |
|--------------------------------------------------------------------------------------------|---------------------------------------|-------------------------------|
| <code>c(1, 2, 3)</code>                                                                    | Vektor erstellen                      | vektör oluştur                |
| <code>setwd(path.expand("~/"))</code>                                                      | Arbeitsordner Dokumente               | çalışma klasörü               |
| <code>read.csv(datei, header, sep, dec)</code>                                             | CSV einlesen                          | CSV dosyasını oku             |
| <code>head(d)</code> / <code>str(d)</code>                                                 | erste 6 Zeilen / Struktur             | ilk 6 satır / yapı            |
| <code>typeof(x)</code> / <code>class(x)</code>                                             | Objekttyp                             | nesne tipi                    |
| <code>d\$Spalte</code> , <code>d[z, s]</code>                                              | Spalte / Zeilen und Spalten auswählen | sütun / satır seç             |
| <code>mean</code> , <code>median</code>                                                    | Mittelwert, Median                    | ortalama, medyan              |
| <code>var</code> , <code>sd</code>                                                         | Varianz, Std.-abw. (mit $n-1$ !)      | varyans, std. sapma ( $n-1$ ) |
| <code>quantile(x, p)</code> , <code>IQR</code> , <code>range</code> , <code>summary</code> | Quantile, IQR, Min/Max, Übersicht     | kantiller, özet               |
| <code>table</code> , <code>prop.table</code>                                               | absolute / relative Häufigkeiten      | frekans / oran tablosu        |
| <code>tapply(x, gruppe, mean)</code>                                                       | Kennzahl je Gruppe                    | gruplara göre hesap           |
| <code>subset(d, bedingung)</code>                                                          | Zeilen filtern                        | satır filtrele                |
| <code>round(x, 3)</code>                                                                   | auf 3 Stellen runden                  | 3 basamağa yuvarla            |
| <code>hist(x, breaks, right, freq=FALSE, main, xlab, ylab)</code>                          | Histogramm                            | histogram                     |
| <code>pdf("a.pdf")</code> ... <code>dev.off()</code>                                       | Grafik als PDF speichern              | grafiği PDF kaydet            |
| <code>boxplot</code> , <code>plot(x, y)</code>                                             | Boxplot, Streudiagramm                | kutu grafiği, serpilme        |
| <code>cut(x, breaks, right, labels)</code>                                                 | in Klassen einteilen (factor)         | sınıflara böl                 |
| <code>cor(x, y, method)</code>                                                             | Korrelation (pearson/spearman)        | korelasyon                    |

### Aufgabentypen-Katalog 1.9 · R in Teil B (ILIAS)

Alle Beispiele benutzen `Taverne.csv` (12 Tavernen) aus dem R-Kurs. Alle Outputs sind **echt** – so sieht es in RStudio aus. Tippe jeden Befehl selbst ab!

**ÜBERSETZER: FRAGEWORT → R-BEFEHL**

| In der Aufgabe steht ...                                 | Du tippst ...                                                                                    |
|----------------------------------------------------------|--------------------------------------------------------------------------------------------------|
| „Setzen Sie Ihr Working Directory“                       | <code>setwd(path.expand("~/"))</code>                                                            |
| „Speichern Sie die Daten als Data-Frame-Objekt d“        | <code>d &lt;- read.csv("Datei.csv", sep = ";", dec = ".", header = TRUE)</code>                  |
| „Geben Sie die ersten 6 Zeilen wieder“                   | <code>head(d)</code>                                                                             |
| „Wie viele Beobachtungen / Variablen?“                   | <code>nrow(d) / ncol(d) / dim(d)</code>                                                          |
| „Objekttyp / Struktur ermitteln“                         | <code>str(d), class(d\$X), typeof(d\$X)</code>                                                   |
| „arithmetisches Mittel“ · „Median“                       | <code>mean(d\$X) · median(d\$X)</code>                                                           |
| „unverzerrter Schätzer der Standardabweichung / Varianz“ | <code>sd(d\$X) / var(d\$X)</code>                                                                |
| „empirische (unkorrigierte) Varianz“                     | <code>var(d\$X) * (n - 1) / n</code>                                                             |
| „Interquartilsabstand“ · „Quantil“                       | <code>IQR(d\$X) · quantile(d\$X, 0.9)</code>                                                     |
| „Runden Sie auf drei Nachkommastellen“                   | <code>round(..., 3)</code>                                                                       |
| „absolute / relative Häufigkeiten“                       | <code>table(d\$X) / prop.table(table(d\$X))</code>                                               |
| „Kontingenztafel“                                        | <code>table(d\$X, d\$Y)</code>                                                                   |
| „für jedes Tal / jede Gruppe“                            | <code>tapply(d\$Zahl, d\$Gruppe, mean)</code>                                                    |
| „nur die Beobachtungen, bei denen ...“                   | <code>subset(d, Bedingung) oder d\$X[Bedingung]</code>                                           |
| „Wie viele / welcher Anteil ... größer als 20?“          | <code>sum(d\$X &gt; 20) / mean(d\$X &gt; 20)</code>                                              |
| „neue Variable mit Klassen, als Factor“                  | <code>d\$X.3 &lt;- cut(d\$X, breaks = c(...), right = ...)</code>                                |
| „(normiertes) Histogramm“                                | <code>hist(d\$X, breaks = c(...), freq = FALSE, right = FALSE, main = , xlab = , ylab = )</code> |
| „Streudiagramm“ · „Boxplot“ · „Säulendiagramm“           | <code>plot(x, y) · boxplot(Zahl ~ Gruppe, data = d) · barplot(table(d\$X))</code>                |
| „Speichern Sie die Grafik als PDF“                       | <code>pdf("Name.pdf") ... Grafik ... dev.off()</code>                                            |
| „Pearson-Korrelation“ · „Spearman“                       | <code>cor(x, y) · cor(x, y, method = "spearman")</code>                                          |
| „Kovarianz“                                              | <code>cov(x, y) (mit n - 1!)</code>                                                              |

**Typ 46 Einlese-Befehl vervollständigen (Lückentext)**

**So erkennst du ihn:** `d ___ read.__(("WitcherData2.csv", sep = ___, ___ = ".", header = ___))` (Testat 2, 3.1)

**Rezept:** Erst die Datei anschauen (in RStudio: Files → Datei anklicken → View File). Trennzeichen zwischen den Spalten = `sep` ; Dezimalzeichen = `dec` ; erste Zeile mit Namen → `header = TRUE` .

**Lösung:**

```
setwd(path.expand("~/"))
d <- read.csv("WitcherData2.csv", sep = ";", dec = ".", header = TRUE)
head(d)
```

### TÜRKÇE AÇIKLAMA

Boşluklar: <- (atama oku), csv , ";" (tırnak içindel), dec , TRUE , sonra head . Dosyanın ilk satırı Taverne;Tal;Monster;... gibi görünüyorsa ayırıcı ";" 'dir. Eğer str(d) sadece **1 değişken** gösteriyorsa, sep yanlış seçilmiştir – hemen düzelt.

#### Typ 47 Objekttypen bestimmen

**So erkennst du ihn:** „Ermitteln Sie unter Einbezug eines passenden R-Befehls die Objekttypen der Variablen ...“  
(Ankreuzen: numeric / character / logical / factor / date)

```
str(d)
```

```
'data.frame': 12 obs. of 5 variables:
 $ Taverne : chr "T01" "T02" "T03" "T04" ...
 $ Tal : chr "Flusstal" "Bergtal" "Flusstal" "Waldtal" ...
 $ Monster : chr "Ghul" "Troll" "Wolf" "Greif" ...
 $ Muenzen : int 18 25 12 30 22 15 27 33 20 10 ...
 $ Kampfzeit: num 12.5 45 3.2 75.5 8 4.5 50 90 15 2.5 ...
```

**Lösung:** chr → **character** (Taverne, Tal, Monster); int → **numeric** (ganze Zahlen, Typ integer); num → **numeric** (double). Antwortsatz: „Die Variable Monster ist vom Typ character, die Variable Kampfzeit ist numeric.“ Nach cut() entsteht ein **factor**.

#### Typ 48 Kennzahlen berechnen und korrekt runden

**So erkennst du ihn:** „Berechnen und nennen Sie ...; runden Sie auf drei Nachkommastellen.“

```
round(mean(d$Kampfzeit), 3)
round(sd(d$Kampfzeit), 3)
median(d$Kampfzeit)
IQR(d$Kampfzeit)
round(var(d$Muenzen), 3) # unverzerrt (n-1)
round(var(d$Muenzen) * 11 / 12, 3) # empirisch (1/n), n = 12
round(quantile(d$Kampfzeit, 0.9), 3)
summary(d$Kampfzeit)
```

```
[1] 33.85
[1] 30.667
[1] 26.5
[1] 45.875
[1] 53.174
[1] 48.743
 90%
74.15
  Min. 1st Qu. Median Mean 3rd Qu. Max.
 2.500  7.125 26.500 33.850 53.000 90.000
```

**Antwortsätze:** „Das arithmetische Mittel der Kampfzeit beträgt 33.85 Minuten, der unverzerrte Schätzer der Standardabweichung 30.667 Minuten.“ · „90 % der Kämpfe dauern höchstens 74.15 Minuten.“

### STOLPERFALLEN

(1) Fehlende Werte ( NA ) → Ergebnis NA . Lösung: mean(d\$X, na.rm = TRUE) . (2) round(mean(x, 3)) ist falsch – die Klammer der 3 gehört zu round . (3) R zeigt 33.85 statt 33.850 – das ist trotzdem auf 3 Stellen gerundet (Nullen am Ende fallen weg).

#### Typ 49 Normiertes Histogramm mit festen Klassen als PDF speichern

**So erkennst du ihn:** „Erstellen Sie ein normiertes Histogramm mit den Intervallen ...; Titel ...; speichern Sie die Grafik als ... .pdf“ (8 Punkte!)

```
pdf("Histogramm.pdf")
hist(d$Kampfzeit,
     breaks = c(0, 10, 40, 100),
     freq = FALSE,
     right = FALSE,
     main = "Sitz 17, Matr.Nr. 12345678, Aufgabenteil e)",
     xlab = "Kampfzeit in Minuten",
     ylab = "Dichte")
dev.off()
```

**Checkliste für volle Punkte:** ☐ pdf() **vor** und dev.off() **nach** der Grafik · ☐ Dateiname genau wie verlangt · ☐ freq = FALSE (normiert) · ☐ breaks decken Min und Max ab · ☐ right = FALSE bei Intervallen der Form [a, b) · ☐ Titel und Achsen exakt · ☐ PDF im Ordner prüfen und in ILIAS hochladen.

#### TÜRKÇE AÇIKLAMA

right = FALSE → aralık **solda kapalı** [a, b) demektir. right = TRUE (varsayılan) → (a, b]. Soruda köşeli parantez sol tarafta ise FALSE yaz. Hata „some 'x' not counted“ çıkarsa: bir değer breaks dışında kalmıştır → sınırları genişlet.

#### Typ 50 Klassen bilden mit cut() (Lückentext Testat 2)

**So erkennst du ihn:** „Die Variable Kampfzeit.3 stellt eine vereinfachte Darstellung ... mit drei Ausprägungen dar: {Weniger als 5 Minuten, 5 Minuten bis weniger als eine Stunde, Eine Stunde oder mehr} ... als Factor-Objekt.“

**Rezept:** Grenzen in breaks (mit 0 bzw. -Inf und Inf an den Rändern). „weniger als“ / „bis weniger als“ → [a, b) → right = FALSE. „bis zu“ / „maximal“ → (a, b] → right = TRUE.

```
d$Kampfzeit.3 <- cut(d$Kampfzeit, breaks = c(0, 5, 60, Inf), right = FALSE)
d$Muenzen.4 <- cut(d$Muenzen, breaks = c(0, 10, 20, 30, Inf), right = TRUE)
table(d$Kampfzeit.3)
```

| [0,5) | [5,60) | [60,Inf) |
|-------|--------|----------|
| 3     | 6      | 3        |

„Eine Stunde“ = 60 Minuten! Die Einheit der Variable (Minuten) bestimmt die Zahlen in breaks.

#### Typ 51 Kontingenztafel, Zelle ablesen, Randverteilung einer Teilgruppe

**So erkennst du ihn:** „Wie häufig lag bei einer Kampfzeit zwischen 5 Minuten und einer Stunde die Anzahl der Münzen zwischen 10 und 20?“ · „Ermitteln Sie für diese Beobachtungen die Randverteilung ... auf zwei Dezimalstellen.“ (Testat 2, 3.6–3.7)

```
Kontingenz.Tafel <- table(d$Muenzen.4, d$Kampfzeit.3)
Kontingenz.Tafel
s <- subset(d, Kampfzeit >= 5 & Kampfzeit < 60)
round(prop.table(table(s$Muenzen.4)), 2)
```

|          | [0,5) | [5,60) | [60,Inf) |
|----------|-------|--------|----------|
| (0,10]   | 1     | 0      | 0        |
| (10,20]  | 2     | 2      | 0        |
| (20,30]  | 0     | 4      | 2        |
| (30,Inf] | 0     | 0      | 1        |

| (0,10] | (10,20] | (20,30] | (30,Inf] |
|--------|---------|---------|----------|
| 0.00   | 0.33    | 0.67    | 0.00     |

**Lösung:** Zeile (10,20], Spalte [5,60) → **2-mal**. Randverteilung in der Teilgruppe: 0.00 / 0.33 / 0.67 / 0.00.

**Bedingte Verteilung pro Zeile:** `round(prop.table(table(d$Tal, d$Monster), 1), 3)` – die 1 heißt „zeilenweise“ (jede Zeile summiert zu 1), 2 heißt „spaltenweise“.

#### TÜRKÇE AÇIKLAMA

`&` = „ve“ (iki koşul birlikte), `|` = „veya“. „Mindestens 5“ = `>= 5`, „weniger als 60“ = `< 60`. `subset` yeni, küçük bir veri seti oluşturur; sonra her şeyi `s$...` ile ondan hesaplarsın, `d$...` ile **değil**.

### Typ 52 Gruppenvergleich mit `tapply` und Zählen mit logischen Vektoren

**So erkennst du ihn:** „Berechnen Sie ... für jedes Tal/Monster.“ · „In welchem Tal ...?“ · „Wie viele Tavernen / welcher Anteil zahlte mehr als 20 Münzen?“

```
round(tapply(d$Kampfzeit, d$Monster, mean), 3)
sum(d$Muenzen > 20)
mean(d$Muenzen > 20)
mean(d$Muenzen[d$Tal == "Bergtal"])
d[d$Muenzen == max(d$Muenzen), ]
```

```
Ghul Greif Troll Wolf
11.833 82.750 48.750 3.400
[1] 7
[1] 0.5833333
[1] 26
Taverne Tal Monster Muenzen Kampfzeit
8 T08 Bergtal Greif 33 90
```

**Antwortsätze:** „Kämpfe gegen Greife dauern im Durchschnitt am längsten (82.75 Minuten).“ · „In 7 von 12 Tavernen (58.333 %) erhielt Jaskier mehr als 20 Münzen.“

Warum funktioniert `mean(d$Muenzen > 20)`? Der Vergleich macht TRUE/FALSE; R rechnet TRUE = 1 und FALSE = 0 → der Mittelwert ist der Anteil (wie Typ 22!).

### Typ 53 Streudiagramm-Code vervollständigen und Korrelation deuten

**So erkennst du ihn:** Lückentext wie `pdf("Streudiagramm.pdf") / ____ (____, ____, pch = 16, ____ = "Streudiagramm", ____ = "Kampfzeit (min.)", ylab = ____) / ____ .off() (Testat 2, 3.4)`

```
pdf("Streudiagramm.pdf")
plot(d$Kampfzeit, d$Muenzen,
     pch = 16,
     cex = 0.3,
     main = "Streudiagramm",
     xlab = "Kampfzeit (min.)",
     ylab = "Muenzen")
dev.off()
round(cor(d$Kampfzeit, d$Muenzen), 3)
round(cor(d$Kampfzeit, d$Muenzen, method = "spearman"), 3)
```

```
[1] 0.928
[1] 0.979
```

**Regeln:** Erste Variable in `plot()` = x-Achse (steht bei `xlab`), zweite = y-Achse. Bei `png()` steht zusätzlich `width`, `height`, `res`. Das Ende ist immer `dev.off()`.

**Antwortsatz:** „Der Korrelationskoeffizient nach Pearson beträgt 0.928; es besteht ein starker positiver linearer Zusammenhang zwischen Kampfzeit und Münzen.“

#### Typ 54 R-Output interpretieren (ohne selbst zu rechnen) – auch in Teil A!

**So erkennst du ihn:** Ein Output ist abgedruckt, und du sollst Werte ablesen oder weiterrechnen (Testat 2, 1.2; Probeklausur).

#### Musterbeispiel:

```
> length(x)
[1] 12
> var(x)
[1] 53.17424
> summary(x)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 10.00  17.25   23.00   22.08  27.50   33.00
```

(a) Empirische Varianz (1/n)? (b) IQR laut R? (c) Ist die Verteilung eher symmetrisch oder schief? (d) Gibt es Ausreißer nach der 1.5-IQR-Regel?

**Lösung:** (a)  $s^2 = \frac{11}{12} \cdot 53.174 = 48.743$ . (b)  $27.5 - 17.25 = 10.25$ . (c) Mittel  $22.08 \approx$  Median 23 (etwas kleiner) → annähernd symmetrisch, leicht linksschief. (d) Zäune  $17.25 - 15.375 = 1.875$  und  $27.5 + 15.375 = 42.875$ ; Min 10 und Max 33 liegen innerhalb → keine Ausreißer.

#### Übe selbst · Zusatzübungen Z7 (am Rechner mit Taverne.csv)

1. Berechne Median und Interquartilsabstand der Variable `Kampfzeit`, gerundet auf zwei Nachkommastellen.
2. Wie viele Tavernen liegen im Flusstal? Welcher Anteil der Kämpfe war gegen einen Troll?
3. Berechne für jedes Tal die mittlere Kampfzeit (3 Nachkommastellen). Wo sind die Kämpfe am kürzesten?
4. Erstelle einen Boxplot der Münzen getrennt nach Tal, speichere ihn als `Boxplot.pdf` mit Titel „Münzen nach Tal“.
5. Bilde `Muenzen.2` mit den Klassen „bis 20 Münzen“ und „mehr als 20 Münzen“ und erstelle eine Kontingenztafel mit `Tal`.

#### Klausurtraining 1.H · R (Teil B) · Tavernen-Daten

32 Punkte

Der Barde Jaskier sammelt Daten über seine Auftritte in Tavernen. Die Daten sind in der Datei `Taverne.csv` abgespeichert. Diese Datei liegt auf Ihrem lokalen Laufwerk im Ordner *Dokumente*. Der Datensatz enthält die Variablen: `Taverne` (Kennung), `Tal` (Ort der Taverne), `Monster` (besiegttes Monster), `Muenzen` (Anzahl erhaltener Münzen), `Kampfzeit` (Dauer des Kampfes in Minuten).

Beantworten Sie jede Teilaufgabe wie in ILIAS: (1) R-Code und R-Output, (2) wenn gefragt, eine inhaltliche Antwort in einem ganzen Satz. Runden Sie auf drei Nachkommastellen mit einem R-Befehl.

- (a) Setzen Sie mittels `setwd(path.expand("~/"))` Ihr Working Directory. (2 P)
- (b) Speichern Sie die Daten als Data-Frame-Objekt `d` in R ab und geben Sie die ersten 6 Zeilen wieder. (4 P)
- (c) Ermitteln Sie unter Einbezug eines passenden R-Befehls die Objekttypen der Variablen `Monster` und `Kampfzeit`. (4 P)

- (d)** Berechnen und nennen Sie das arithmetische Mittel und den unverzerrten Schätzer der Standardabweichung der Variable `Kampfzeit`. **(4 P)**
- (e)** Erstellen Sie ein normiertes Histogramm der Variable `Kampfzeit` mit den Intervallen  $[0, 10)$ ,  $[10, 40)$ ,  $[40, 100)$ . Titel: „Sitz ..., Matr.Nr. ..., Aufgabenteil e)“, x-Achse „Kampfzeit in Minuten“, y-Achse „Dichte“. Speichern Sie die Grafik als `Histogramm.pdf`. **(8 P)**
- (f)** Bestimmen Sie den Median und den Interquartilsabstand der Variable `Muenzen`. **(3 P)**
- (g)** Berechnen Sie die durchschnittliche Anzahl an Münzen für jedes Tal. In welchem Tal verdient Jaskier im Durchschnitt am meisten? **(3 P)**
- (h)** Wie stark ist der lineare Zusammenhang zwischen `Kampfzeit` und `Muenzen`? Berechnen und interpretieren Sie eine geeignete Maßzahl. **(4 P)**

## 1.10 Antworten richtig formulieren

Viele Punkte gehen verloren, weil die Antwort unklar ist. Hier sind **Mustersätze**, die du fast wörtlich benutzen kannst.

| Frage                      | Mustersatz                                                                                                                                                                             |
|----------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Skalenniveau               | „X ist ein stetiges, kardinal (metrisch) skaliertes Merkmal, weil die Abstände zwischen den Werten sinnvoll interpretierbar sind.“                                                     |
| Parameter nicht sinnvoll   | „Der Median ist für nominale Merkmale nicht sinnvoll, weil sich die Ausprägungen nicht der Größe nach ordnen lassen.“                                                                  |
| Mittelwert (Teil B)        | „Das arithmetische Mittel der Variable Muenzen beträgt 22.083.“                                                                                                                        |
| Vorteil Median             | „Der Median ist robuster gegenüber Extremwerten (Ausreißern) als das arithmetische Mittel.“                                                                                            |
| Vorteil Standardabweichung | „Die Standardabweichung hat dieselbe Maßeinheit wie das Merkmal.“                                                                                                                      |
| Korrelation deuten         | „Der Korrelationskoeffizient von 0.836 zeigt einen starken positiven linearen Zusammenhang zwischen Gewicht und Größe.“                                                                |
| Kausalität                 | „Nein. Eine Korrelation belegt keine Kausalität. Der Zusammenhang könnte durch Drittvariablen oder Zufall entstehen; für Kausalität bräuchte man z. B. ein randomisiertes Experiment.“ |
| Kovarianz                  | „Das positive Vorzeichen deutet auf einen positiven linearen Zusammenhang hin; die Höhe ist nicht interpretierbar, da sie von den Einheiten abhängt.“                                  |
| Objektyp (Teil B)          | „Die Variable Tal ist ein character-Objekt; die Variable Muenzen ist numerisch vom Typ integer (nur ganze Zahlen).“                                                                    |

### KLAUSUR-REGELN FÜR DIE FORM

- Teil A: Nur das Endergebnis ins Lösungskästchen, außer ein Lösungsweg ist verlangt. **Nie** zwei Lösungen hinschreiben – falsche Versuche durchstreichen.
- Teil B: Pro Teilaufgabe gibt es oft zwei Kästchen: (1) R-Code **und** R-Output hineinkopieren, (2) inhaltliche Antwort in einem **ganzen Satz** ohne Code, auf 3 Nachkommastellen gerundet. Fehlerhaften Code, der nicht zur Antwort gehört, löschen.
- Folgefehler werden berücksichtigt: Wenn du eine Teilaufgabe nicht kannst, rechne mit einem plausiblen Wert weiter und schreibe das dazu.
- Hältst du eine Aufgabe für unlösbar: „nicht lösbar“ ins Kästchen und Begründung in das Feld am Ende.

## Z1 Tag 1 auf einer Seite

| Thema               | Das Wichtigste                                                                                                                                                     |
|---------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Grundbegriffe       | Einheit, Grundgesamtheit, Stichprobe, Merkmal $X$ , Ausprägung $x$ ; deskriptiv (beschreiben) vs. induktiv (schließen + Unsicherheit)                              |
| Skalen              | nominal (nur Namen) · ordinal (Reihenfolge) · kardinal (Abstände); diskret (abzählbar) vs. stetig (Intervall); 1–7-Skala = ordinal; 0/1 = nominal, Mittel = Anteil |
| Stichproben         | einfach zufällig · geschichtet (aus allen Gruppen) · Klumpen (ganze Gruppen) · Quote (bewusst)                                                                     |
| Häufigkeiten        | $h_j, f_j = h_j/n$ ; Histogramm: Höhe = $f_j$ /Breite, Fläche = Anteil, Gesamtfläche 1; Anteil in Teilintervall: Breite × Höhe                                     |
| Verteilungsfunktion | $\hat{F}(x)$ = Anteil $\leq x$ ; Treppe von 0 bis 1, ● links ○ rechts                                                                                              |
| Lagemaße            | Modus (alle Skalen), Median (ab ordinal, robust), Mittel (kardinal); rechtsschief: $\bar{x} > x_{med} > x_{mod}$ ; klassiert: $\sum f_j m_j$ ; Gruppen: gewichtet  |
| Quantile            | $n\alpha$ nicht ganz → aufrunden; ganz → Mittel aus $x_{(n\alpha)}$ und $x_{(n\alpha+1)}$                                                                          |
| Streuung            | $s^2 = \overline{x^2} - \bar{x}^2$ (1/n); $s_*^2 = \frac{n}{n-1} s^2$ (R!); $s$ gleiche Einheit; $a + bx$ : Varianz $\times b^2$                                   |
| Boxplot             | Min, $x_{0.25}$ , Median, $x_{0.75}$ , Max; Ausreißer: mehr als 1.5·IQR außerhalb der Box                                                                          |
| Kontingenztafel     | Rand = Summen; bedingt = Zeile/Zeilensumme; $\tilde{h}_{jk} = h_{j\bullet} h_{\bullet k} / n$ ; $\chi^2 = \sum (h - \tilde{h})^2 / \tilde{h}$                      |
| Korrelation         | $s_{xy} = \overline{xy} - \bar{x}\bar{y}$ ; $r = s_{xy} / (s_x s_y) \in [-1, 1]$ ; nur linear; Spearman = Pearson der Ränge; Korrelation $\neq$ Kausalität         |
| R                   | setwd, read.csv, head, str, typeof, mean, sd (n–1!), quantile, table, tapply, hist(freq=FALSE), pdf()... dev.off(), cut, cor, round(..., 3)                        |

### Checkliste: Das kann ich jetzt

- ☐ Ich bestimme Skalenniveau und diskret/stetig für jedes Merkmal und begründe es.
- ☐ Ich baue aus Rohdaten eine Häufigkeitstabelle und ein Histogramm mit richtigen Höhen.
- ☐ Ich zeichne eine empirische Verteilungsfunktion korrekt (Punkte, Kreise, Achsen).
- ☐ Ich berechne Mittelwert, Median, Modus, Quantile, Varianz (1/n und 1/(n–1)) und Standardabweichung.
- ☐ Ich bestimme Whisker und Ausreißer eines Boxplots.
- ☐ Ich ergänze eine Kontingenztafel, berechne bedingte Verteilungen und den  $\chi^2$ -Koeffizienten.
- ☐ Ich berechne Kovarianz, Pearson- und Spearman-Korrelation und interpretiere sie richtig.
- ☐ Ich erkläre, warum Korrelation keine Kausalität ist.
- ☐ Ich lese in R einen Datensatz ein, bestimme Typen und Kennzahlen, filtere nach Gruppen und speichere ein Histogramm als PDF.

## K1 Gemischte Klausuraufgaben Tag 1 – Generalprobe

Das sind echte Aufgaben aus der Probeklausur und aus Tutorien. Rechne sie am Ende des Tages **auf Zeit**: zusammen 38 Punkte  $\approx$  50 Minuten.

### Aufgabe K1.1 · Wahrsagerin (Probeklausur A, Aufgabe 1)

10 Punkte

Harry möchte die Genauigkeit der Vorhersagen der Wahrsagerin Giesela Baumrasen untersuchen. Er befragt zufällig 20 Schüler\*innen, ob ihre Vorhersagen eingetroffen sind (1 = korrekt, 0 = falsch).

```
> sort(Vorhersagen)
[1] 0 0 0 0 0 0 0 0 0 0 0 0 1 1 1 1 1 1 1 1
```

- (a) Geben Sie das Skalenniveau des Merkmals „Korrektheit der Vorhersagen“ an. (2 P)
- (b) Berechnen Sie  $x_{mod}$ ,  $x_{med}$ ,  $\bar{x}$  und  $s_x^2$ . Falls ein Parameter nicht sinnvoll angegeben werden kann, begründen Sie kurz in einem Satz. (8 P)

### Aufgabe K1.2 · Bier (Probeklausur A, Aufgabe 2)

14 Punkte

Der Betreiber der Bar „BierWirdGeschafft“ erfasst die Menge des getrunkenen Bieres  $X$  (Liter) und die Herkunft der Gäste  $Y$  (BY oder NRW):

|       |     |     |     |     |      |      |     |      |     |     |
|-------|-----|-----|-----|-----|------|------|-----|------|-----|-----|
| $x_i$ | 8.5 | 8.5 | 4.0 | 4.0 | 12.0 | 12.0 | 8.5 | 15.7 | 4.0 | 8.5 |
| $y_i$ | BY  | BY  | NRW | BY  | NRW  | BY   | BY  | NRW  | NRW | BY  |

Hinweis:  $\sum x_i = 85.7$ ;  $\sum x_i^2 = 871.49$

- (a) Geben Sie für  $X$  und  $Y$  an, ob ein diskretes oder stetiges Merkmal vorliegt. Welches Skalenniveau liegt jeweils zugrunde? (4 P)
- (b) Zeichnen Sie die empirische Verteilungsfunktion für  $X$ . (6 P)
- (c) Klassieren Sie den Bierkonsum in die Klassen  $K_1 = [0, 10)$  und  $K_2 = [10, 20]$  und bestimmen Sie den Mittelwert für die klassierten Daten. (4 P)
- (d) Zusatz: Berechnen Sie  $\bar{x}$ ,  $s^2$ ,  $s$  und den Modus von  $Y$ .

### Aufgabe K1.3 · Filmbewertungen (nach Tutorium 3)

8 Punkte

Bewertungen von 5 Filmen auf zwei Portalen: Portal A: 6, 8, 7, 9, 5; Portal B: 7, 9, 6, 10, 6.

- (a) Berechnen Sie  $\bar{x}$ ,  $\bar{y}$ ,  $s_x^2$ ,  $s_y^2$ ,  $s_{xy}$  (mit  $1/n$ ) und  $r_{xy}$ . (4 P)
- (b) Interpretieren Sie  $r_{xy}$ . (1 P)
- (c) Bestimmen Sie die Ränge und den Spearman-Koeffizienten. (3 P)

### Aufgabe K1.4 · Arbeitszeit (nach Tutorium 2, Aufgabe 5)

6 Punkte

Arbeitszeit pro Woche während der Vorlesungszeit: [0,4]: 40.2 %, (4,8]: 19.6 %, (8,12]: 21.9 %, (12,16]: 18.3 %.

- (a) Welche Klasse ist die Modalklasse? (1 P)
- (b) Berechnen Sie näherungsweise Mittelwert und Varianz mit den Klassenmitten. (3 P)
- (c) Wie hoch ist die Säule der Klasse (4,8] im Histogramm? Schätzen Sie den Anteil mit mehr als 10 Stunden. (2 P)

**Aufgabe K1.5 · Mensa-Pilotstudie (im Stil von Testat 1)****8 Punkte**

Häufigkeitstabelle der Mensabesuche in der letzten Woche:  $a_j$ : 0, 1, 2, 3, 4 mit  $h_j$ : 4, 6, 7, 2, 1.

- (a)** Bestimmen Sie die Stichprobengröße  $n$  und das Skalenniveau. **(2 P)**
- (b)** Bestimmen Sie Modus, Median und Mittelwert. **(3 P)**
- (c)** Berechnen Sie  $s^2$  und  $s_*^2$ . **(2 P)**
- (d)** Wie groß ist der Anteil der Studierenden mit mindestens 2 Besuchen? **(1 P)**

**Aufgabe K1.6 · Kampfzeiten und Boxplot****6 Punkte**

Kampfzeiten in Minuten (sortiert): 1, 3, 4, 4, 6, 7, 8, 9, 10, 12, 30.

- (a)** Bestimmen Sie  $x_{0.25}$ , Median,  $x_{0.75}$  und IQR nach der Vorlesungsdefinition. **(3 P)**
- (b)** Gibt es Ausreißer? Wo enden die Whisker? **(2 P)**
- (c)** Ist die Verteilung eher rechts- oder linksschief? Begründen Sie mit Mittelwert und Median. **(1 P)**

## Lösungen Tag 1

Vergleiche nicht nur das Ergebnis, sondern auch den Weg. In der Klausur gibt es Punkte für richtige Zwischenschritte.

### Kontrollfragen 1.1 – 1.3

1. Deskriptiv: nur die vorliegenden Daten beschreiben (Tabellen, Grafiken, Kennzahlen). Induktiv: von der Stichprobe auf die Grundgesamtheit schließen und die Unsicherheit angeben.
2. Falsch. Richtig: „Ein diskretes Merkmal kann endlich **oder abzählbar unendlich** viele Werte annehmen.“
3. Randomisierung. Störvariablen (Alter, Vorerkrankungen ...) verteilen sich zufällig und im Mittel gleich auf beide Gruppen; so kann man den Effekt des Medikaments sauber messen.

### Klausurtraining 1.A · Fitnessstudio

(a)

| Merkmal                   | Skala       | diskret/stetig |
|---------------------------|-------------|----------------|
| Alter in ganzen Jahren    | kardinal    | diskret        |
| Trainingsdauer in Stunden | kardinal    | stetig         |
| Tarif                     | nominal     | diskret        |
| Zufriedenheit (5 Stufen)  | ordinal     | diskret        |
| Anzahl Besuche            | kardinal    | diskret        |
| Postleitzahl              | nominal (!) | diskret        |

(b) Einheit: ein Mitglied des Studios. Grundgesamtheit: alle 2400 Mitglieder.

(c) Geschichtete Stichprobe (Schichten = Tarife; Anteile sind bekannt) bzw. Quotenverfahren.

(d) Klumpenstichprobe (Kurse = Klumpen). Vorteil: einfacher und kostengünstiger, weil man ganze Kurse auf einmal befragt.

(e) (i) Falsch: Die Postleitzahl ist nominal; Zahlen sind hier nur Namen, ein Durchschnitt hat keine Bedeutung. (ii) Richtig: Die Zufriedenheit ist ordinal, man kann die Werte sortieren, also ist der Median sinnvoll.

### Klausurtraining 1.B · Pendelzeiten

(a)

| Klasse  | $h_j$ | $f_j = h_j/50$ | Breite | Höhe $f_j/\text{Breite}$ |
|---------|-------|----------------|--------|--------------------------|
| [0,10)  | 8     | 0.16           | 10     | 0.016                    |
| [10,20) | 15    | 0.30           | 10     | 0.030                    |
| [20,30) | 12    | 0.24           | 10     | 0.024                    |
| [30,60) | 10    | 0.20           | 30     | 0.007 (0.0067)           |
| [60,90] | 5     | 0.10           | 30     | 0.003 (0.0033)           |

(b) Annahme: Die Werte sind innerhalb jeder Klasse gleichmäßig verteilt. Anteil = Fläche:  $(30 - 25) \cdot 0.024 + (45 - 30) \cdot 0.00667 = 0.12 + 0.10 = 0.22$ .

(c)  $10 + 5 = 15$  Studierende.

(d) Mitten 5, 15, 25, 45, 75:  $\bar{x}_K = 0.16 \cdot 5 + 0.30 \cdot 15 + 0.24 \cdot 25 + 0.20 \cdot 45 + 0.10 \cdot 75 = 0.8 + 4.5 + 6 + 9 + 7.5 = 27.8$  Minuten.

(e) Modalklasse [10,20) (15 Personen, größte Häufigkeit). Die Klassen sind ungleich breit: Im Säulendiagramm würde die breite Klasse [30,60) mit 10 Personen fast so wichtig aussehen wie [10,20), obwohl die Werte über 30 Minuten verteilt sind. Nur im Histogramm (Fläche = Anteil) ist die Darstellung nicht verzerrt.

## Klausurtraining 1.C · Kaffee

(a) kardinal, diskret (Anzahl).

$$(b) \hat{F}(x) = \begin{cases} 0 & x < 0 \\ 0.1 & 0 \leq x < 1 \\ 0.3 & 1 \leq x < 2 \\ 0.6 & 2 \leq x < 3 \\ 0.8 & 3 \leq x < 4 \\ 0.9 & 4 \leq x < 6 \\ 1 & x \geq 6 \end{cases} \quad \text{Skizze: Treppe mit Sprüngen bei 0, 1, 2, 3, 4, 6; volle Punkte links, offene Kreise rechts;}$$

Achsen beschriften.

(c)  $\hat{F}(2.5) = 0.6$ . Mehr als 2:  $1 - \hat{F}(2) = 1 - 0.6 = 0.4$ . Mindestens 1:  $1 - \hat{F}(0) = 1 - 0.1 = 0.9$ .

(d) Modus 2 (3-mal). Median:  $n = 10 \rightarrow (x_{(5)} + x_{(6)})/2 = (2 + 2)/2 = 2$ . Mittelwert:  $24/10 = 2.4$ .

## Klausurtraining 1.D · Gehälter

(a)  $\bar{x} = 43.6/9 = 4.844$  Tsd. €; Median =  $x_{(5)} = 3.6$ ; Modus = 3.1.

(b) Der Median, denn er ist robust gegenüber dem Extremwert 15.0 (Gehalt der Chefin/des Chefs), der den Mittelwert nach oben zieht.

(c) Rechtsschief, da  $\bar{x} = 4.844 > x_{med} = 3.6 > x_{mod} = 3.1$ .

(d) Lineare Transformation  $y = 1.05x$ :  $\bar{y} = 1.05 \cdot 4.8444 = 5.087$ ;  $y_{med} = 1.05 \cdot 3.6 = 3.780$ .

(e)  $\bar{x}_{ges} = \frac{9 \cdot 4.8444 + 6 \cdot 3.5}{15} = \frac{43.6 + 21}{15} = \frac{64.6}{15} = 4.307$ .

(f)  $s^2 = \frac{329.68}{9} - 4.8444^2 = 36.6311 - 23.4686 = 13.1625$ ;  $s = \sqrt{13.1625} = 3.628$  Tsd. €.

## Klausurtraining 1.E · Lieferzeiten

(a)  $\bar{x} = 66/12 = 5.5$ ; Median:  $n = 12 \rightarrow (x_{(6)} + x_{(7)})/2 = (4 + 5)/2 = 4.5$ .

(b)  $12 \cdot 0.25 = 3$  (ganz)  $\rightarrow x_{0.25} = (x_{(3)} + x_{(4)})/2 = (3 + 4)/2 = 3.5$ ;  $12 \cdot 0.75 = 9 \rightarrow x_{0.75} = (x_{(9)} + x_{(10)})/2 = (6 + 7)/2 = 6.5$ ; IQR = 3.

(c)  $s^2 = \frac{482}{12} - 5.5^2 = 40.1667 - 30.25 = 9.9167$ ;  $s_*^2 = \frac{12}{11} \cdot 9.9167 = 10.818$ ;  $s = \sqrt{9.9167} = 3.149$ .

(d) Grenzen:  $3.5 - 1.5 \cdot 3 = -1$  und  $6.5 + 4.5 = 11$ . Der Wert 14 liegt darüber  $\rightarrow$  **Ausreißer**. Unterer Whisker = 2 (Minimum), oberer Whisker = 9 (größter Wert  $\leq 11$ ). Skizze: Box von 3.5 bis 6.5, Median-Strich bei 4.5, Whisker 2 und 9, Punkt bei 14.

(e)  $y = 24x$ : Mittelwert  $24 \cdot 5.5 = 132$  Stunden; Varianz  $24^2 \cdot 9.9167 = 576 \cdot 9.9167 = 5712$  Stunden<sup>2</sup>; Standardabweichung  $24 \cdot 3.149 = 75.578$  Stunden.

## Klausurtraining 1.F · Rauchen und Sport

(a)

|                            | Sport (S) | kein Sport ( $\bar{S}$ ) | $\Sigma$ |
|----------------------------|-----------|--------------------------|----------|
| Raucher (R)                | 15        | 45                       | 60       |
| Nichtraucher ( $\bar{R}$ ) | 75        | 65                       | 140      |
| $\Sigma$                   | 90        | 110                      | 200      |

Rechenweg:  $60 - 15 = 45$ ;  $200 - 60 = 140$ ;  $200 - 110 = 90$ ;  $90 - 15 = 75$ ;  $140 - 75 = 65$ .

(b)  $f(S | R) = \frac{15}{60} = 0.25$ ;  $f(S | \bar{R}) = \frac{75}{140} = 0.536$ .

(c) Ja: Die bedingten Verteilungen unterscheiden sich deutlich (25 % vs. 53.6 %). Bei Unabhängigkeit wären sie gleich (=  $90/200 = 45$  %).

(d)  $\tilde{h}_{R,S} = \frac{60 \cdot 90}{200} = 27$ ,  $\tilde{h}_{R,\bar{S}} = \frac{60 \cdot 110}{200} = 33$ ,  $\tilde{h}_{\bar{R},S} = \frac{140 \cdot 90}{200} = 63$ ,  $\tilde{h}_{\bar{R},\bar{S}} = \frac{140 \cdot 110}{200} = 77$ . Differenzen  $\pm 12$ .  $\chi^2 = \frac{144}{27} + \frac{144}{33} + \frac{144}{63} + \frac{144}{77} = 5.3333 + 4.3636 + 2.2857 + 1.8701 = 13.853$ .

(e) Die Daten zeigen nur einen statistischen Zusammenhang, keine Kausalität. Es könnte Drittvariablen geben (z. B. Gesundheitsbewusstsein, Freizeit), oder die Richtung ist umgekehrt (Sportler fangen seltener an zu rauchen). Für eine kausale Aussage bräuchte man ein Experiment bzw. Kontrolle der Störvariablen.

## Kontrollfragen 1.7 – 1.8

1. (a) richtig (unabhängig  $\Rightarrow r = 0$ ; also  $r \neq 0 \Rightarrow$  abhängig); (b) richtig; (c) richtig; (d) falsch; (e) falsch (Kovarianz hängt von den Einheiten ab).
2.  $\bar{x} = 40.38$ ,  $\bar{y} = 74.66$ .  $s_{xy} = \frac{160064}{50} - 40.38 \cdot 74.66 = 3201.28 - 3014.7708 = 186.509$ .  $s_x^2 = 1752.22 - 1630.5444 = 121.6756$ ,  $s_y^2 = 6033.9 - 5574.1156 = 459.7844$ .  $r = \frac{186.5092}{\sqrt{121.6756 \cdot 459.7844}} = 0.789 \rightarrow$  starker positiver linearer Zusammenhang.

## Klausurtraining 1.G · Werbung und Umsatz

- (a) x-Achse „Werbeausgaben (Tsd. €)“, y-Achse „Umsatz (Tsd. €)“; sechs Punkte (1|25), (2|30), (3|38), (4|45), (5|48), (6|60) – sie steigen fast auf einer Geraden.
- (b)  $\bar{x} = 21/6 = 3.5$ ,  $\bar{y} = 246/6 = 41$ .  $s_{xy} = \frac{979}{6} - 3.5 \cdot 41 = 163.1667 - 143.5 = 19.667$ .
- (c)  $s_x^2 = \frac{91}{6} - 3.5^2 = 15.1667 - 12.25 = 2.9167$ ;  $s_y^2 = \frac{10898}{6} - 41^2 = 1816.3333 - 1681 = 135.3333$ .  $r = \frac{19.6667}{\sqrt{2.9167 \cdot 135.3333}} = \frac{19.6667}{19.8676} = 0.990$ . Sehr starker positiver linearer Zusammenhang: Filialen mit höheren Werbeausgaben haben (fast linear) höhere Umsätze.
- (d) Die Rangfolge von x und y ist in jeder Filiale gleich (Filiale 6 hat bei beiden Rang 1, Filiale 1 Rang 2, ...). Also sind die Ränge identisch  $\rightarrow r_{Sp} = 1$  (perfekter monotoner Zusammenhang).
- (e) y wird mit 1000 multipliziert: Kovarianz  $\times 1000 \rightarrow 19\,666.667$ ; die Korrelation bleibt 0.990 (sie hat keine Einheit).
- (f) Eine hohe Korrelation beweist keine Kausalität. Drittvariable z. B. Größe oder Lage der Filiale: Große Filialen in guter Lage haben mehr Budget für Werbung **und** mehr Kundschaft.

## Klausurtraining 1.H · R (Musterlösung)

(a)

```
setwd(path.expand("~/"))
```

(b)

```
d <- read.csv("Taverne.csv", header = TRUE, sep = ";", dec = ".")
head(d)
```

|   | Taverne | Tal      | Monster | Muenzen | Kampfzeit |
|---|---------|----------|---------|---------|-----------|
| 1 | T01     | Flusstal | Ghul    | 18      | 12.5      |
| 2 | T02     | Bergtal  | Troll   | 25      | 45.0      |
| 3 | T03     | Flusstal | Wolf    | 12      | 3.2       |
| 4 | T04     | Walddal  | Greif   | 30      | 75.5      |
| 5 | T05     | Bergtal  | Ghul    | 22      | 8.0       |
| 6 | T06     | Walddal  | Wolf    | 15      | 4.5       |

(c)

```
typeof(d$Monster)      # alternativ class() oder str(d)
typeof(d$Kampfzeit)
```

```
[1] "character"
[1] "double"
```

Antwortsatz: Die Variable Monster ist ein character-Objekt (Text). Die Variable Kampfzeit ist ein numerisches Objekt vom Typ double (Fließkommazahl).

(d)

```
round(mean(d$Kampfzeit), 3)
round(sd(d$Kampfzeit), 3)
```

```
[1] 33.85
[1] 30.667
```

Antwortsatz: Das arithmetische Mittel der Kampfzeit beträgt 33.850 Minuten, der unverzerzte Schätzer der Standardabweichung beträgt 30.667 Minuten.

(e)

```
pdf("Histogramm.pdf")
hist(d$Kampfzeit, breaks = c(0, 10, 40, 100), right = FALSE, freq = FALSE,
     main = "Sitz 12, Matr.Nr. 12345678, Aufgabenteil e)",
     xlab = "Kampfzeit in Minuten", ylab = "Dichte")
dev.off()
```

Kontrolle der Höhen (plot = FALSE): 0.0333, 0.0083, 0.0069. Punkte gibt es für: richtige Klassen (breaks, right = FALSE), Dichte (freq = FALSE), Titel mit Sitz/Matr.-Nr./Aufgabenteil, beide Achsenbeschriftungen, PDF gespeichert und hochgeladen.

(f)

```
median(d$Muenzen)
IQR(d$Muenzen)
```

```
[1] 23
[1] 10.25
```

Antwortsatz: Der Median der Münzen beträgt 23, der Interquartilsabstand 10.250.

(g)

```
round(tapply(d$Muenzen, d$Tal, mean), 3)
```

```
Bergtal Flusstal Walddal
26.00   16.75   23.50
```

Antwortsatz: Im Durchschnitt erhält Jaskier im Bergtal mit 26.000 Münzen am meisten (Walddal 23.500, Flusstal 16.750).

(h)

```
round(cor(d$Kampfzeit, d$Muenzen), 3)
```

```
[1] 0.928
```

Antwortsatz: Der Korrelationskoeffizient nach Bravais-Pearson beträgt 0.928. Es liegt ein starker positiver linearer Zusammenhang vor: Längere Kämpfe gehen mit mehr Münzen einher.

### K1.1 · Wahrsagerin

(a) **Nominal** (binär, 0/1-kodiert: richtig/falsch haben keine echte Ordnung; diskret).

(b)  $x_{mod} = 0$  (11-mal). Median:  $n = 20$  gerade  $\rightarrow$  zwischen  $x_{(10)} = 0$  und  $x_{(11)} = 0 \rightarrow x_{med} = 0$ . *Begründung, wenn man streng ist:* Für nominale Daten ist der Median eigentlich nicht sinnvoll (keine Ordnung); bei 0/1-Kodierung kann man ihn formal berechnen (= 0).  $\bar{x} = \frac{9}{20} = 0.45$  – sinnvoll, denn bei 0/1-Daten ist das der **Anteil** richtiger Vorhersagen (45 %).  $s^2 = \overline{x^2} - \bar{x}^2 = 0.45 - 0.2025 = 0.248$  (genau  $0.2475 = \bar{x}(1 - \bar{x})$ ).

### K1.2 · Bier

(a) X: **stetig**, kardinal/metrisch (Verhältnisskala). Y: **diskret, nominal**.

(b) Siehe 1.4: Stufen 0 / 0.3 / 0.7 / 0.9 / 1 an den Stellen 4, 8.5, 12, 15.7.

(c)  $n(K_1) = 7$ ,  $n(K_2) = 3$ ,  $m_1 = 5$ ,  $m_2 = 15$ :  $\bar{x}_K = \frac{1}{10}(7 \cdot 5 + 3 \cdot 15) = 8$ .

(d)  $\bar{x} = 85.7/10 = 8.570$ ;  $s^2 = 87.149 - 8.57^2 = 13.704$ ;  $s = 3.702$ ; Modus(Y) = BY (6-mal).

### K1.3 • Filmbewertungen

(a)  $\bar{x} = 7$ ,  $\bar{y} = 7.6$ .  $\sum x^2 = 255 \Rightarrow s_x^2 = 51 - 49 = 2$ .  $\sum y^2 = 302 \Rightarrow s_y^2 = 60.4 - 57.76 = 2.64$ .  $\sum xy = 42 + 72 + 42 + 90 + 30 = 276 \Rightarrow s_{xy} = 55.2 - 53.2 = 2$ .  $r = \frac{2}{\sqrt{2 \cdot 2.64}} = \frac{2}{2.2978} = 0.870$ .

(b) Starker positiver linearer Zusammenhang: Filme mit guter Bewertung bei A haben meist auch gute Bewertungen bei B.

(c) Ränge A:  $6 \rightarrow 2$ ,  $8 \rightarrow 4$ ,  $7 \rightarrow 3$ ,  $9 \rightarrow 5$ ,  $5 \rightarrow 1$ . Ränge B:  $7 \rightarrow 3$ ,  $9 \rightarrow 4$ ,  $6 \rightarrow 1.5$ ,  $10 \rightarrow 5$ ,  $6 \rightarrow 1.5$ .  $\sum rk_x rk_y = 6 + 16 + 4.5 + 25 + 1.5 = 53$ ;  $\sum rk_x^2 = 55$ ;  $\sum rk_y^2 = 54.5$ ;  $n \cdot 3^2 = 45$ .  $r_{Sp} = \frac{53-45}{\sqrt{(55-45)(54.5-45)}} = \frac{8}{\sqrt{95}} = 0.821$ .

### K1.4 • Arbeitszeit

(a)  $[0,4]$  (40.2 %; alle Klassen gleich breit). (b) Mitten 2, 6, 10, 14:  $\bar{x} = 0.402 \cdot 2 + 0.196 \cdot 6 + 0.219 \cdot 10 + 0.183 \cdot 14 = 6.732$ .  $s^2 = 0.402(2 - 6.732)^2 + 0.196(6 - 6.732)^2 + 0.219(10 - 6.732)^2 + 0.183(14 - 6.732)^2 = 21.112$ . (c) Höhe  $0.196/4 = 0.049$ . Anteil über 10:  $\frac{2}{4} \cdot 0.219 + 0.183 = 0.293$ .

### K1.5 • Mensa-Pilotstudie

(a)  $n = 4 + 6 + 7 + 2 + 1 = 20$ ; kardinal, diskret. (b) Modus 2. Median: Plätze 10 und 11 – Plätze 1–4 sind 0, 5–10 sind 1, 11–17 sind 2  $\rightarrow \frac{1+2}{2} = 1.5$ . Mittel:  $\frac{0+6+14+6+4}{20} = 1.5$ .

(c)  $\bar{x}^2 = \frac{0+6+28+18+16}{20} = 3.4$ ;  $s^2 = 3.4 - 2.25 = 1.15$ ;  $s_*^2 = \frac{20}{19} \cdot 1.15 = 1.211$ . (d)  $\frac{7+2+1}{20} = 0.5$ .

### K1.6 • Kampfzeiten

(a)  $n = 11$ .  $11 \cdot 0.25 = 2.75 \rightarrow x_{(3)} = 4$ ; Median  $x_{(6)} = 7$ ;  $11 \cdot 0.75 = 8.25 \rightarrow x_{(9)} = 10$ ; IQR = 6.

(b) Grenzen  $4 - 9 = -5$  und  $10 + 9 = 19$ : 30 ist ein **Ausreißer**. Oberer Whisker 12, unterer Whisker 1.

(c)  $\bar{x} = \frac{94}{11} = 8.545 > 7 = x_{med} \rightarrow$  eher **rechtsschief** (langer Schwanz nach rechts durch den Wert 30).

### Zusatzübungen Z1 • Skalen und Stichproben

- (a) Hausnummer: nominal (die Zahl ist nur ein Name; Rechnen ist sinnlos), diskret. (b) Wohnfläche: kardinal (metrisch), stetig. (c) Energieeffizienzklasse: ordinal, diskret. (d) Bundesland: nominal, diskret. (e) Anzahl Zimmer: kardinal, diskret. (f) Puls pro Minute: kardinal, diskret (Zählung).
- (a) geschichtete Stichprobe (aus **jeder** Gruppe wird gezogen). (b) einfache Zufallsstichprobe. (c) Klumpenstichprobe (ganze Gruppen werden gezogen und komplett befragt).
- (a) Richtig – Randomisierung verteilt die Störvariablen gleichmäßig auf die Gruppen. (b) Falsch – ordinal: nur Median und Modus sind sinnvoll. (c) Falsch – eine Grundgesamtheit kann auch hypothetisch/unendlich sein (z. B. alle zukünftigen Produkte einer Maschine).

### Zusatzübungen Z2 • Häufigkeiten, Histogramm, ECDF

1.  $n = 8$ :  $a_j = 1, 2, 3, 5$ ;  $h_j = 2, 3, 1, 2$ ;  $f_j = 0.25, 0.375, 0.125, 0.25$ ;  $H_j = 2, 5, 6, 8$ ;  $F_j = 0.25, 0.625, 0.75, 1$ .

$\hat{F}(x) = 0$  für  $x < 1$ ; 0.25 für  $1 \leq x < 2$ ; 0.625 für  $2 \leq x < 3$ ; 0.75 für  $3 \leq x < 5$ ; 1 für  $x \geq 5$ .

Mehr als 2:  $1 - F(2) = 0.375$ . Mindestens 2:  $1 - F(1) = 0.75$ .

2. (a)  $f = 0.2, 0.45, 0.35 \rightarrow$  Höhen  $0.2/20 = 0.01$ ,  $0.45/30 = 0.015$ ,  $0.35/50 = 0.007$ . (b)  $10 \cdot 0.01 + 10 \cdot 0.015 = 0.25$  (25 %). (c) Modalklasse  $[20, 50)$  (90 Werte).

3. Fläche =  $10 \cdot 0.025 = 0.25 \rightarrow 0.25 \cdot 400 = 100$  Beobachtungen.

4. Sprunghöhen 0.3, 0.3, 0.4  $\rightarrow h_j = 3, 3, 4$ .  $\bar{x} = \frac{3 \cdot 10 + 3 \cdot 20 + 4 \cdot 30}{10} = 21$ . Median: Plätze 5 und 6 sind beide 20  $\rightarrow x_{med} = 20$ .

### Zusatzübungen Z3 • Lagemaße

1. Sortiert: 2, 3, 3, 3, 4, 5, 6, 8, 20 ( $n = 9$ ).  $\bar{x} = \frac{54}{9} = 6$ ;  $x_{med} = x_{(5)} = 4$ ;  $x_{mod} = 3$ .  $6 > 4 > 3 \rightarrow$  rechtsschief.

2.  $\bar{x} = \frac{3+14+27+16+10}{25} = \frac{70}{25} = 2.8$ ; Median  $x_{(13)}$ :  $H = 3, 10, 19 \rightarrow$  Note 3; Modus 3. Noten sind ordinal  $\rightarrow$  eigentlich sind nur **Median und Modus** sinnvoll (der Mittelwert setzt gleiche Abstände voraus).

3.  $f = 0.2, 0.5, 0.3$ ; Mitten 10, 30, 70  $\rightarrow \bar{x}_K = 2 + 15 + 21 = 38$ . Modalklasse  $[20, 40)$ .

4. Summe vorher  $8 \cdot 12 = 96$ , nachher  $9 \cdot 13 = 117 \rightarrow$  neunte Zahl = 21.

5. Median  $32 + 1.8 \cdot 15 = 59$  °F; Mittel  $32 + 1.8 \cdot 14 = 57.2$  °F.

## Zusatzübungen Z4 · Quantile, Streuung, Boxplot

- $9 \cdot 0.25 = 2.25 \rightarrow \text{Platz 3} \rightarrow x_{0.25} = 3$ ; Median  $x_{(5)} = 6$ ;  $9 \cdot 0.75 = 6.75 \rightarrow \text{Platz 7} \rightarrow x_{0.75} = 8$ . IQR = 5. Zäune:  $3 - 7.5 = -4.5$  und  $8 + 7.5 = 15.5$ . 30 ist ein Ausreißer. Whisker: unten 1, oben 10.
- $\bar{x} = 6$ ;  $s^2 = \frac{220}{5} - 36 = 8$ ;  $s = 2.828$ ;  $s_*^2 = \frac{5}{4} \cdot 8 = 10$ .
- $s_*^2 = 9 \rightarrow s^2 = \frac{9}{10} \cdot 9 = 8.1$ .
- $s_F = 1.8 \cdot 4 = 7.2^\circ\text{F}$  (die 32 spielt keine Rolle).

## Zusatzübungen Z5 · Kontingenztafel und $\chi^2$

|          | unter 40 | ab 40 | $\Sigma$ |
|----------|----------|-------|----------|
| Karte    | 175      | 75    | 250      |
| bar      | 60       | 90    | 150      |
| $\Sigma$ | 235      | 165   | 400      |

- $0.7 \cdot 250 = 175$ ,  $0.4 \cdot 150 = 60$ , Rest durch Differenzen.
- Unter 40:  $\frac{175}{235} = 0.745$ ; ab 40:  $\frac{75}{165} = 0.455 \rightarrow$  Jüngere zahlen deutlich häufiger mit Karte (Zusammenhang).
- Erwartet:  $\frac{250 \cdot 235}{400} = 146.875$ ,  $103.125$ ,  $88.125$ ,  $61.875$ . Differenzen jeweils  $\pm 28.125$ .  $\chi^2 = 28.125^2 \left( \frac{1}{146.875} + \frac{1}{103.125} + \frac{1}{88.125} + \frac{1}{61.875} \right) = 34.816$ .
- Die zweite Zeile ist genau  $\frac{5}{3}$  mal die erste (gleiche bedingte Verteilung  $0.4 / 0.6$ )  $\rightarrow$  Unabhängigkeit  $\rightarrow \chi^2 = 0$ .

## Zusatzübungen Z6 · Kovarianz und Korrelation

- $\bar{x} = 5$ ,  $\bar{y} = 6$ ;  $\sum xy = 94$ ,  $\sum x^2 = 120$ ,  $\sum y^2 = 178$ .  $s_{xy} = 23.5 - 30 = -6.5$ ;  $s_x^2 = 5$ ,  $s_y^2 = 8.5$ ;  $r = \frac{-6.5}{\sqrt{42.5}} = -0.997$ .  $y$  fällt immer, wenn  $x$  steigt  $\rightarrow r_{Sp} = -1$ .
- $s_{xy} = \frac{760}{20} - 4 \cdot 10 = -2$ ;  $r = \frac{-2}{2.5} = -0.2$  (schwacher negativer linearer Zusammenhang).
- $s_{xy} = 1.8 \cdot 120 = 216$ ;  $r = 0.8$  bleibt gleich.
- $d = -3, -1, 2, 2$ ;  $\sum d^2 = 18$ ;  $r_{Sp} = 1 - \frac{6 \cdot 18}{4 \cdot 15} = 1 - 1.8 = -0.8$ .
- Nein, Korrelation ist keine Kausalität. Drittvariable: **Rauchen** – Raucher\*innen trinken oft mehr Kaffee und haben ein höheres Lungenkrebsrisiko. Nachweis nur mit Studien, die das Rauchen kontrollieren.

## Zusatzübungen Z7 · R (Taverne.csv)

```
round(median(d$Kampfzeit), 2); round(IQR(d$Kampfzeit), 2) # 26.5 und 45.88
sum(d$Tal == "Flusstal") # 4
mean(d$Monster == "Troll") # 0.3333333
round(tapply(d$Kampfzeit, d$Tal, mean), 3) # Bergtal 45.25 Flusstal 17.05 Walddtal 39.25
pdf("Boxplot.pdf")
boxplot(Muenzen ~ Tal, data = d, main = "Münzen nach Tal")
dev.off()
d$Muenzen.2 <- cut(d$Muenzen, breaks = c(0, 20, Inf), right = TRUE)
table(d$Tal, d$Muenzen.2)
```

|          | (0, 20] | (20, Inf] |
|----------|---------|-----------|
| Bergtal  | 0       | 4         |
| Flusstal | 3       | 1         |
| Walddtal | 2       | 2         |

Die Kämpfe sind im **Flusstal** am kürzesten (17.05 Minuten im Mittel).

## Dein Formelblatt – Teil für Tag 1

### DAS SCHREIBST DU HEUTE MIT DER HAND AUF DEIN A4-BLATT

- Skalen: nominal (Modus) · ordinal (+ Median) · kardinal (+ Mittelwert); diskret = abzählbar, stetig = Intervall; 1–7-Skala = ordinal; PLZ = nominal
- $f_j = h_j/n$ ; Histogramm-Höhe =  $f_j/\text{Breite}$ ; Anteil = Breite  $\times$  Höhe;  $\hat{F}(x) = \#\{x_i \leq x\}/n$  (Treppe, • links, ○ rechts)

- $\bar{x} = \frac{1}{n} \sum x_i = \sum a_j f_j$ ; klassiert  $\bar{x}_K = \sum f_j m_j$ ; Gruppen  $\bar{x} = \frac{1}{n} \sum n_j \bar{x}_j$ ; Median:  $x_{((n+1)/2)}$  bzw. Mittel der beiden mittleren
- Quantil:  $n\alpha$  nicht ganz  $\rightarrow$  aufrunden; ganz  $\rightarrow \frac{x_{(n\alpha)} + x_{(n\alpha+1)}}{2}$
- $s^2 = \overline{x^2} - \bar{x}^2$ ;  $s_*^2 = \frac{n}{n-1} s^2$  (R: var, sd!);  $y = a + bx \Rightarrow \bar{y} = a + b\bar{x}$ ,  $s_y^2 = b^2 s_x^2$
- Boxplot: Ausreißer außerhalb  $[x_{0.25} - 1.5 \text{ IQR}; x_{0.75} + 1.5 \text{ IQR}]$
- rechtsschief:  $\bar{x} > x_{med} > x_{mod}$
- $\tilde{h}_{jk} = \frac{h_{j\cdot} h_{\cdot k}}{n}$ ,  $\chi^2 = \sum \frac{(h_{jk} - \tilde{h}_{jk})^2}{\tilde{h}_{jk}}$ ; bedingt: Zeile / Zeilensumme
- $s_{xy} = \overline{xy} - \bar{x}\bar{y}$ ;  $r = \frac{s_{xy}}{s_x s_y}$ ;  $|r|$ : <0.3 schwach, 0.3–0.7 mittel,  $\geq 0.7$  stark; Spearman: Ränge, Bindungen  $\rightarrow$  Durchschnittsrang

**Rückseite (Teil B):** Für Teil B schreibst du ein eigenes Blatt. Übertrage die Tabelle aus 1.9.10 (Befehle) und die drei Schritte pdf()  $\rightarrow$  Grafik  $\rightarrow$  dev.off() .

## Wörterliste Tag 1 (Deutsch – Türkçe)

|                                               |                                          |                                               |
|-----------------------------------------------|------------------------------------------|-----------------------------------------------|
| <b>Grundgesamtheit</b>                        | <i>ana kütle / evren</i>                 | alle Einheiten, die uns interessieren         |
| <b>Stichprobe</b>                             | <i>örneklem</i>                          | der untersuchte Teil                          |
| <b>statistische Einheit</b>                   | <i>istatistiksel birim</i>               | Objekt, an dem gemessen wird                  |
| <b>Merkmal / Ausprägung</b>                   | <i>değişken / değer</i>                  | Eigenschaft / konkreter Wert                  |
| <b>Skalenniveau</b>                           | <i>ölçek düzeyi</i>                      | nominal, ordinal, kardinal                    |
| <b>diskret / stetig</b>                       | <i>kesikli / sürekli</i>                 | abzählbar / jede Zahl möglich                 |
| <b>geschichtete Stichprobe</b>                | <i>tabakalı örnekleme</i>                | aus jeder Gruppe ziehen                       |
| <b>Klumpenstichprobe</b>                      | <i>küme örnekleme</i>                    | ganze Gruppen ziehen                          |
| <b>Häufigkeit (absolut/relativ)</b>           | <i>frekans (mutlak/görel)</i>            | Anzahl / Anteil                               |
| <b>Klasse, Klassenbreite</b>                  | <i>sınıf, sınıf genişliği</i>            | Intervall, seine Länge                        |
| <b>Verteilungsfunktion</b>                    | <i>(birikimli) dağılım fonksiyonu</i>    | Anteil der Werte $\leq x$                     |
| <b>arithmetisches Mittel</b>                  | <i>aritmetik ortalama</i>                | Durchschnitt                                  |
| <b>Median / Modus</b>                         | <i>medyan / mod</i>                      | Mitte / häufigster Wert                       |
| <b>Streuung, Varianz</b>                      | <i>yayılım, varyans</i>                  | wie weit die Werte auseinander liegen         |
| <b>Standardabweichung</b>                     | <i>standart sapma</i>                    | Wurzel aus der Varianz                        |
| <b>Quantil / Quartil</b>                      | <i>kantil / çeyreklik</i>                | Grenze, unter der $\alpha \cdot 100$ % liegen |
| <b>Interquartilsabstand</b>                   | <i>çeyrekler açıklığı</i>                | $x_{0.75} - x_{0.25}$                         |
| <b>Ausreißer</b>                              | <i>aykırı değer</i>                      | extremer Wert                                 |
| <b>Kontingenztafel</b>                        | <i>çapraz tablo / olumsuzluk tablosu</i> | Tabelle für zwei Merkmale                     |
| <b>Randverteilung</b>                         | <i>marjinal dağılım</i>                  | Zeilen-/Spaltensummen                         |
| <b>bedingte Verteilung</b>                    | <i>koşullu dağılım</i>                   | Verteilung in einer Zeile                     |
| <b>Zusammenhang</b>                           | <i>ilişki</i>                            | Merkmale hängen zusammen                      |
| <b>Kovarianz / Korrelation</b>                | <i>kovaryans / korelasyon</i>            | Maße für linearen Zusammenhang                |
| <b>Rang, Bindung</b>                          | <i>sıra, eşit değer (bağ)</i>            | Platz in der Reihenfolge                      |
| <b>Kausalität</b>                             | <i>nedensellik</i>                       | Ursache $\rightarrow$ Wirkung                 |
| <b>Scheinkorrelation</b>                      | <i>sahte korelasyon</i>                  | Korrelation ohne Ursache                      |
| <b>schief (rechts/links)</b>                  | <i>çarpık (sağa/sola)</i>                | unsymmetrische Verteilung                     |
| <b>Arbeitsverzeichnis (working directory)</b> | <i>çalışma klasörü</i>                   | Ordner, in dem R arbeitet                     |
| <b>einlesen</b>                               | <i>(veriyi) okumak / içe aktarmak</i>    | Datei in R laden                              |

