

In 5 Tagen zur 1,x in Statistik

Dein Lernbuch zum Mitlesen und Mitdenken – für Klausurteil
A (Statistik, schriftlich) und Klausurteil B (R am Computer).
In einfachem Deutsch, mit Beispielen, Fragen und Lösungen.

Tag 1

Daten
beschreiben:
deskriptive
Statistik

Tag 2

Wahrscheinlichkeit
& Zufallsvariablen

Tag 3

Verteilungen &
Maximum-
Likelihood

Tag 4

Schätzer,
Konfidenzintervalle,
Tests

Tag 5

R-Klausur (Teil
B) &
Generalprobe

Grundlage: Vorlesungen SDS1-V01 bis V13, Tutorien 1–13, Testate 0–6, Probeklausuren Teil A und Teil B, Übungen zur ML-Schätzung.

Zu jedem Tag gibt es einen **Hörtext** (Ordner *hoertexte*). Die Nummern der Abschnitte im Hörtext und in diesem Buch sind gleich.

Hallo! Schön, dass du da bist. In den nächsten fünf Tagen lernen wir zusammen alles, was du für die Statistik-Klausur brauchst. Wir fangen ganz vorne an. Du musst nichts vorher wissen. Wir gehen Schritt für Schritt.

Das Lernpaket hat **zwei Teile**, die zusammengehören:

- **Die Hörtexte** (eine Datei pro Tag): Das ist die Stimme deiner Lehrerin. Du kannst sie mit einer KI-Stimme vorlesen lassen und zuhören.
- **Dieses Lernbuch**: Hier siehst du beim Zuhören die Formeln, Tabellen, Bilder und den R-Code. Jeder Abschnitt hat eine Nummer, zum Beispiel **1.3**. Im Hörtext hörst du dieselbe Nummer: „Abschnitt eins Punkt drei“. So weißt du immer, wo wir gerade sind.

SO LERNST DU AM BESTEN

1. **Hören + Mitlesen**: Höre den Abschnitt und schau gleichzeitig ins Buch.
2. **Anhalten**: Wenn im Hörtext eine Frage kommt („Halte kurz an ...“), stoppe die Aufnahme und denke selbst nach.
3. **Kontrollfragen**: Am Ende jeder Lektion stehen Fragen (lila Kästen). Beantworte sie schriftlich. Die Lösungen stehen am Ende des Tages.
4. **Rechnen**: Rechne die Klausuraufgaben selbst mit Stift und Taschenrechner. Erst danach schaust du in die Lösung.
5. **Formelblatt**: Schreibe jeden Tag die wichtigen Formeln auf dein eigenes A4-Blatt (siehe Anhang). In der Klausur darfst du ein handgeschriebenes Blatt pro Klausurteil benutzen!

Die Kästen in diesem Buch

MERKE

Das Wichtigste in einem Satz. Unbedingt lernen.

FORMEL

Diese Formel kommt auf dein Formelblatt.

BEISPIEL

Eine Aufgabe, Schritt für Schritt gerechnet.

ACHTUNG – TYPISCHER FEHLER

Hier machen viele Studierende Fehler.

KLAUSUR-TIPP

So holst du in der Klausur die Punkte.

R-ECKE

Der passende R-Code für Klausurteil B.

KONTROLLFRAGEN

Fragen zum Selbsttest. Lösungen am Ende jedes Tages.

Die Klausur hat **zwei Teile**. Du schreibst sie am selben Tag, zuerst Teil A, dann Teil B.

	Teil A: Statistik	Teil B: R
Ort	Hörsaal, auf Papier	E-Prüfungsraum, am Computer (ILIAS + RStudio)
Zeit	100 Minuten	60 Minuten
Punkte	75 Punkte	45 Punkte
Hilfsmittel	1 handgeschriebenes A4-Blatt (beidseitig) pro Teil , nicht-programmierbarer Taschenrechner mit Sticker, Kugelschreiber (kein Bleistift, nicht grün/rot)	
Typische Aufgaben	Skalenniveau, Lage- und Streuungsmaße, Verteilungsfunktion zeichnen, Bayes/totale Wahrscheinlichkeit, Korrelation, ML-Schätzer herleiten, Erwartungstreue prüfen, Hypothesentest, R-Output deuten	Daten einlesen, Objekttypen, Mittelwert/SD, Histogramm als PDF speichern, Likelihood mit <code>dpois / prod</code> , eigene Funktion und for-Schleife, <code>nlm</code> , <code>pgamma / qgamma</code> , Antwortsätze

RUNDUNGSREGELN (SEHR WICHTIG FÜR DIE PUNKTE!)

- **Zwischenergebnisse:** mindestens **4** Nachkommastellen.
- **Endergebnisse:** **3** Nachkommastellen (kaufmännisch runden) – oder ein gekürzter Bruch.
- Ausnahmen: ganze Zahlen; „schöne“ Ausdrücke wie $\sqrt{2}$ oder $\log 4$; andere Anweisung in der Aufgabe.
- Dezimalpunkt benutzen: 0.125 (nicht 0,125).
- In Teil B immer mit R runden: `round(x, 3)`.

Wie bekommst du eine 1,x?

Eine sehr gute Note bekommst du, wenn du die **Standardaufgaben sicher und schnell** löst. Die Klausuraufgaben sind jedes Jahr sehr ähnlich. Wenn du die Probeklausuren, die Testate und die Tutorien verstehst, bist du vorbereitet. Genau darauf ist dieses Buch aufgebaut. Für Teil A hast du ungefähr **1,3 Minuten pro Punkt**. Für Teil B hast du ungefähr **1,3 Minuten pro Punkt**. Also: nicht lange an einer Aufgabe hängen bleiben!

0.3 Dein 5-Tage-Plan

Jeder Tag hat etwa **7–8 Stunden** Lernzeit mit Pausen. Mache nach 50 Minuten immer 10 Minuten Pause. Schlafe genug – im Schlaf speichert dein Gehirn das Gelernte.

Tag	Themen (Vorlesung)	So arbeitest du
Tag 1	Grundbegriffe, Skalenniveaus, Stichproben (V01) · Häufigkeiten, Histogramm, Verteilungsfunktion, Lage- und Streuungsmaße, Quantile, Boxplot (V02) · Kontingenztafel, χ^2 -Koeffizient, Kovarianz, Korrelation, Kausalität (V03) · R-Grundlagen	Vormittag: Hörtext 1.1–1.5 + Kontrollfragen. Nachmittag: Hörtext 1.6–1.9, Klausuraufgaben Tag 1 rechnen, R-Befehle am Computer ausprobieren.
Tag 2	Mengen, Laplace, Kolmogorov, Rechenregeln, bedingte Wahrscheinlichkeit, Unabhängigkeit, totale Wahrscheinlichkeit, Bayes (V04) · Zufallsvariablen, Dichte, Verteilungsfunktion, Erwartungswert, Varianz, Rechenregeln, bivariate Verteilungen (V05, V06)	Vormittag: Wahrscheinlichkeit (2.1–2.5), Baumdiagramme zeichnen. Nachmittag: Zufallsvariablen (2.6–2.9), Integrale üben, Testat 3 und 4 nachrechnen.
Tag 3	Bernoulli, Binomial, Poisson, Gleich-, Exponential-, Normalverteilung, Standardisieren, zentraler Grenzwertsatz, R-Funktionen d/p/q/r (V07) · Maximum-Likelihood (V08)	Vormittag: Verteilungen (3.1–3.5). Nachmittag: ML-Rezept (3.6–3.8) und alle ML-Übungsaufgaben selbst herleiten. ML bringt in Teil A ca. 10 Punkte!
Tag 4	Bias, Varianz, MSE, Konsistenz, Histogramm und Kerndichte (V09) · Konfidenzintervalle (V10) · Hypothesentests, p-Wert, z-/t-/ χ^2 -/Binomialtest, Vorzeichentest, χ^2 -Unabhängigkeit, Anpassungstest (V11, V12) · Regression (V13)	Vormittag: Schätzer + KI (4.1–4.4). Nachmittag: Tests (4.5–4.9). Abends: Testat 5 und 6.
Tag 5	Klausurteil B: kompletter R-Ablauf, Witcher-Klausur, Lungenvolumen-Klausur (nlm) · Generalprobe Teil A (Probeklausur 04.03.2022) · Formelblatt fertig machen	Vormittag: Tag-5-Hörtext + R-Probeklausuren am Computer (auf Zeit: 60 Min.). Nachmittag: Probeklausur A auf Zeit (100 Min.), danach Korrektur mit Lösungen. Abends: Formelblatt schreiben, früh schlafen.

EHRLICH GESAGT

Fünf Tage sind kurz. Das schaffst du nur, wenn du wirklich aktiv arbeitest: selbst rechnen, selbst R-Code tippen. Nur Zuhören reicht nicht für eine 1,x. Der Hörtext erklärt dir alles – aber die Punkte holst du mit dem Stift und an der Tastatur.

Inhalt

Tag 1 · Daten beschreiben

1.1 Grundbegriffe · 1.2 Merkmalstypen & Skalen · 1.3 Stichproben · 1.4 Häufigkeiten, Histogramm, Verteilungsfunktion · 1.5 Lagemaße · 1.6 Quantile, Streuung, Boxplot · 1.7 Zwei Merkmale: Kontingenztafel & χ^2 · 1.8 Kovarianz & Korrelation · 1.9 R-Start · Klausuraufgaben · Lösungen

Tag 2 · Wahrscheinlichkeit

2.1 Zufallsexperiment & Mengen · 2.2 Wahrscheinlichkeit & Regeln · 2.3 Bedingte W. & Unabhängigkeit · 2.4 Totale W. & Bayes · 2.5 Zufallsvariablen · 2.6 Dichte & Verteilungsfunktion · 2.7 Erwartungswert & Varianz · 2.8 Zwei Zufallsvariablen · Klausuraufgaben · Lösungen

Tag 3 · Verteilungen & ML

3.1 Bernoulli & Binomial · 3.2 Poisson · 3.3 Gleich- & Exponentialverteilung · 3.4 Normalverteilung · 3.5 Zentraler Grenzwertsatz & R · 3.6 Idee der Likelihood · 3.7 Das ML-Rezept · 3.8 ML-Training · Klausuraufgaben · Lösungen

Tag 4 · Inferenz

4.1 Gütekriterien von Schätzern · 4.2 Erwartungstreue prüfen · 4.3 Histogramm & Kerndichte · 4.4 Konfidenzintervalle · 4.5 Testprinzip · 4.6 Tests für μ · 4.7 Varianz-, Binomial-, Vorzeichentest · 4.8 χ^2 -Tests · 4.9 R-Output lesen & Regression · Klausuraufgaben · Lösungen

Tag 5 · R-Klausur & Generalprobe

5.1 So läuft Teil B ab · 5.2 Einlesen & Objekttypen · 5.3 Kennzahlen & Grafiken · 5.4 Likelihood in R · 5.5 Funktionen, Schleifen, paste · 5.6 nlm & Transformation · 5.7 Probeklausur B komplett · 5.8 Generalprobe Teil A · 5.9 Letzte Tipps

Anhang

Formelblatt-Vorlage Teil A · R-Spickzettel Teil B · Wichtige Quantile · Wörterliste Deutsch–Türkçe

Daten beschreiben: deskriptive Statistik

Heute lernst du die Sprache der Statistik. Du lernst, wie man Daten ordnet, zeichnet und mit wenigen Zahlen beschreibt – für ein Merkmal und für zwei Merkmale zusammen. Am Ende machst du die ersten Schritte in R.

Skalenniveau

Histogramm

Verteilungsfunktion

Mittelwert & Median

Varianz

Boxplot

Korrelation

R-Start

Zeit	Was du machst
09:00–10:30	Hörtext 0 + 1.1–1.3 hören und mitlesen, Kontrollfragen 1.1–1.3
10:45–12:30	Hörtext 1.4–1.6 (Häufigkeiten, Lagemaße, Streuung), alle Beispiele mitrechnen
13:30–15:00	Hörtext 1.7–1.8 (Zusammenhänge), Kontrollfragen
15:15–16:30	1.9 R-Start: RStudio öffnen, alle Befehle abtippen
16:45–18:00	Klausuraufgaben Tag 1 rechnen, mit Lösungen vergleichen, Formelblatt ergänzen

1.1 Grundbegriffe der Statistik

Hörtext 1.1

Statistik beschreibt und analysiert **Daten**. Bevor wir rechnen, brauchen wir ein paar Wörter:

Begriff	Bedeutung	Beispiel: Wahlumfrage
statistische Einheit	Das Objekt, an dem wir etwas messen	eine wahlberechtigte Person
Grundgesamtheit (Population)	Alle Einheiten, die für die Frage wichtig sind	alle Wahlberechtigten in Deutschland
Stichprobe	Der Teil der Grundgesamtheit, den wir wirklich untersuchen	die 1000 befragten Personen
Merkmal (Variable) X	Eigenschaft, die wir messen (Großbuchstabe)	Alter, Partei
Merkmalsausprägung x	Der konkrete Wert bei einer Einheit (Kleinbuchstabe)	23 Jahre, SPD

MERKE

Meistens kennen wir nur eine **Stichprobe**. Die große Aufgabe der Statistik ist: von der Stichprobe auf die **Grundgesamtheit** schließen – und dabei die **Unsicherheit** angeben. Das nennt man **induktive Statistik** (Tag 3 und 4). Heute machen wir **deskriptive Statistik**: Wir beschreiben nur die Daten, die wir haben.

Störvariablen sind Merkmale, die das Ergebnis auch beeinflussen, die uns aber gerade nicht interessieren (z. B. Vorwissen, wenn wir eine neue Lehrmethode testen). Man kontrolliert sie durch **Homogenisierung** (Gruppen bilden), **Randomisierung** (zufällig in Gruppen einteilen) oder **statistische Modellierung**.

1.2 Merkmalstypen und Skalenniveaus

Hörtext 1.2

Diskret oder stetig?

diskret: endlich viele oder **abzählbar** unendlich viele Werte (man kann sie durchzählen: 0, 1, 2, ...).

Beispiele: Anzahl Likes, Anzahl Mensabesuche, Partei, Studienfach, Alter in ganzen Jahren

stetig: überabzählbar viele Werte, jede reelle Zahl in einem Intervall ist möglich.

Beispiele: Körpergröße, Einkommen in Euro, Liter Bier, Zeit, Gewinn einer Firma

Stetige Merkmale sind immer auch **metrisch** (kardinal). Geld (Einkommen in Euro) wird in der Statistik meist als **stetig** behandelt (quasi-stetig), weil es sehr viele mögliche Werte hat.

Die drei Skalenniveaus

Skala	Was kann man machen?	Beispiele	Häufigkeiten	Reihenfolge	Abstände
nominal	nur Namen / Kategorien, keine Ordnung	Partei, Nationalität, Mensastandort, Herkunft (BY/NRW), Geschlecht	ja	nein	nein
ordinal	man kann sortieren, aber Abstände sind nicht sinnvoll	Schulnoten, Zufriedenheit 1–7, Rang im Wettkampf	ja	ja	nein
kardinal (metrisch)	Zahlen mit sinnvollen Abständen (und meist Verhältnissen)	Alter, Einkommen, Körpergröße, Punkte 0–100, Anzahl	ja	ja	ja

ACHTUNG – TYPISCHE FEHLER

- Eine Skala „von 1 bis 5“ oder „von 1 bis 7“ (Zufriedenheit) ist **ordinal**, nicht kardinal – auch wenn es Zahlen sind! Der Abstand von 1 zu 2 ist nicht unbedingt gleich wie von 6 zu 7.
- Punkte in einem Test (0–100) sind **kardinal**: 80 Punkte sind 20 Punkte mehr als 60.
- Ein 0/1-Merkmal (richtig/falsch, ja/nein) ist **nominal** (binär). Man darf trotzdem den Mittelwert ausrechnen: er ist der **Anteil** der Einsen.
- „Diskret“ heißt nicht „endlich“: auch abzählbar unendlich viele Werte (0, 1, 2, ... ohne Ende) sind diskret.

BEISPIEL AUS TESTAT 1 (MENSA-UMFRAGE)

Merkmal	Skala	diskret/stetig
Alter in ganzen Jahren	kardinal	diskret
Anzahl Mensabesuche letzte Woche	kardinal	diskret
Präferierter Mensastandort	nominal	diskret
Zufriedenheit 1 bis 7	ordinal	diskret
Monatseinkommen in Euro	kardinal	stetig

1.3 Wie zieht man eine Stichprobe?

Hörtext 1.3

Eine gute Stichprobe ist **repräsentativ**: Sie sieht im Kleinen so aus wie die Grundgesamtheit.

Verfahren	Wie?	Wann sinnvoll?
Einfache Zufallsstichprobe	Ziehen ohne Zurücklegen aus der Liste aller Einheiten; jede Einheit und jede mögliche Stichprobe hat die gleiche Chance	Standardfall; nur zufällige, keine systematischen Unterschiede
Geschichtete Stichprobe	Grundgesamtheit in Gruppen (Schichten) teilen, dann in jeder Schicht zufällig ziehen	Gruppen sollen passend vertreten sein (z. B. jeder Studiengang mit seinem Anteil). Anteile müssen bekannt sein.
Klumpenstichprobe	Zufällig ganze Klumpen ziehen (Schulklassen, Städte, Familien) und darin alle / viele befragen	billig und einfach; Klumpen sollen innen sehr verschieden, untereinander ähnlich sein
Quotenverfahren (bewusste Auswahl)	Feste Quoten müssen erfüllt sein (z. B. 50 % Frauen)	Umfragen, die „repräsentativ für Bevölkerungsgruppen“ sein sollen

BEISPIELE AUS TUTORIUM 1 UND TESTAT 1

- Leistungen aller Zehntklässler in Deutschland, getestet an Schulen in Göttingen → **Klumpenstichprobe**.
- Umfrage, die repräsentativ für Bevölkerungsgruppen sein soll → **Quotenverfahren** oder **geschichtete Stichprobe**.
- Der Anteil jedes Studiengangs in der Stichprobe soll dem Anteil an allen Studierenden entsprechen → **geschichtete Stichprobe / Quotenverfahren**.

KONTROLLFRAGEN 1.1 – 1.3

- 1 Eine Firma befragt 200 ihrer 5000 Kunden zur Zufriedenheit. Nenne Einheit, Grundgesamtheit, Stichprobe.
- 2 Bestimme Skala und diskret/stetig: (a) Wartezeit in Minuten, (b) Hotelsterne 1–5, (c) Blutgruppe, (d) Anzahl Geschwister.
- 3 Richtig oder falsch? „Ein diskretes Merkmal kann nur endlich viele Werte annehmen.“
- 4 Du willst Göttinger Haushalte befragen und wählst zufällig 20 Straßen aus. Dort befragst du alle Haushalte. Welches Verfahren ist das?

1.4 Häufigkeiten, Histogramm und Verteilungsfunktion

Hörtext 1.4

Wir haben Beobachtungen $x_1, \dots, x_n$ (n = Stichprobenumfang). Die möglichen Werte heißen $a_1 < a_2 < \dots < a_J$.

FORMEL: HÄUFIGKEITEN

$$h_j = \text{absolute Häufigkeit von } a_j, \quad f_j = \frac{h_j}{n} \text{ (relative Häufigkeit)}, \quad \sum_j f_j = 1$$

$$H_j = h_1 + \dots + h_j \text{ (kumuliert absolut)}, \quad F_j = \frac{H_j}{n} \text{ (kumuliert relativ)}$$

BEISPIEL (TUTORIUM 2): SEMESTERZAHLEN VON N = 23 STUDIERENDEN

Semester a_j	2	3	4	5	6	7	Σ
h_j	1	7	5	5	1	4	23
f_j	1/23	7/23	5/23	5/23	1/23	4/23	1
F_j	1/23	8/23	13/23	18/23	19/23	23/23	

Anteil „mehr als 3 Semester“: $1 - F(3) = 1 - \frac{8}{23} = \frac{15}{23}$. Anteil „mindestens 3“: $1 - \frac{1}{23} = \frac{22}{23}$. Anteil „kleiner als 4“ = $F(3) = \frac{8}{23}$.

ACHTUNG

Bei diskreten Daten ist „größer als 3“ (> 3) etwas anderes als „mindestens 3“ (≥ 3). Lies die Wörter genau!



Säulendiagramm oder Histogramm?

Bei stetigen Daten bilden wir **Klassen** (Intervalle), z. B. $[0, 10]$, $(10, 20]$, $(20, 100]$.

- **Säulendiagramm:** Die **Höhe** der Säule ist die Häufigkeit. Bei ungleich breiten Klassen sieht das falsch aus (breite Klassen wirken zu groß).
- **Histogramm:** Die **Fläche** der Säule ist die relative Häufigkeit. Die Gesamtfläche ist **1**. Das ist in dieser Vorlesung der „Goldstandard“.

FORMEL: HÖHE IM HISTOGRAMM (DICHTEN)

$$\text{Höhe}_j = \frac{f_j}{\text{Klassenbreite}_j} = \frac{h_j}{n \cdot (c_j - c_{j-1})} \quad \Rightarrow \quad \text{Fläche}_j = f_j$$



Gleiche Daten (Zimmergrößen, R-Skript V02), links Säulendiagramm, rechts Histogramm. Die breite Klasse (20,100] sieht links riesig aus – rechts ist sie richtig flach.

BEISPIEL: ANTEIL AUS EINEM HISTOGRAMM SCHÄTZEN (TUTORIUM 2, AUFGABE 1)

20 Personen, Klassenbreite 5 cm; in (165,170] liegen 3 Personen, in (170,175] liegen 5 Personen.
Gesucht: Anteil in (167, 172].

Annahme: Innerhalb einer Klasse sind die Werte **gleichmäßig verteilt**. Dann nimmt man vom Anteil der Klasse nur den passenden Teil:

$$\underbrace{\frac{3}{5} \cdot \frac{3}{20}}_{(167,170]} + \underbrace{\frac{2}{5} \cdot \frac{5}{20}}_{(170,172]} = 0.09 + 0.10 = 0.19$$

Die Höhe im normierten Histogramm für (170,175] wäre $\frac{5}{20 \cdot 5} = 0.05$.

Die empirische Verteilungsfunktion

FORMEL

$$\hat{F}(x) = \frac{\text{Anzahl der } x_i \leq x}{n} \quad (\text{Anteil der Werte, die höchstens } x \text{ sind})$$

Sie ist eine **Treppenfunktion**: Sie startet bei 0, springt an jedem beobachteten Wert nach oben (um f_j) und endet bei 1.


KLAUSURAUFGABE (PROBEKLAUSUR A, AUFGABE 2B, 6 PUNKTE!): BIERKONSUM

Daten (Liter): 8.5, 8.5, 4.0, 4.0, 12.0, 12.0, 8.5, 15.7, 4.0, 8.5. Also $n = 10$.

Schritt 1 – sortieren und zählen: 4.0 kommt 3-mal vor, 8.5 kommt 4-mal, 12.0 kommt 2-mal, 15.7 kommt 1-mal.

Schritt 2 – kumulieren: 0.3, $0.3 + 0.4 = 0.7$, $0.7 + 0.2 = 0.9$, $0.9 + 0.1 = 1$.

$$\hat{F}(x) = \begin{cases} 0 & x < 4 \\ 0.3 & 4 \leq x < 8.5 \\ 0.7 & 8.5 \leq x < 12 \\ 0.9 & 12 \leq x < 15.7 \\ 1 & x \geq 15.7 \end{cases}$$



KLAUSUR-TIPP: SO BEKOMMST DU ALLE 6 PUNKTE BEIM ZEICHNEN

- Achsen beschriften (x-Achse mit Einheit, y-Achse $\hat{F}(x)$) und Werte an die Achsen schreiben.
- Waagerechte Stufen, **keine** senkrechten Linien verbinden.
- Voller Punkt ● am linken Ende jeder Stufe (Wert gehört dazu), offener Kreis ○ am rechten Ende.
- Links bei 0 anfangen, rechts bei 1 enden, Pfeil nach rechts (geht bis unendlich weiter).

FORMEL: DIE DREI LAGEMASSE

Arithmetisches Mittel (Durchschnitt):

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \sum_{j=1}^J a_j f_j$$

Median (die Mitte der **sortierten** Werte $x_{(1)} \leq \dots \leq x_{(n)}$):

$$x_{med} = \begin{cases} x_{(\frac{n+1}{2})} & n \text{ ungerade} \\ \in [x_{(n/2)}, x_{(n/2+1)}], \text{ meist } \frac{x_{(n/2)} + x_{(n/2+1)}}{2} & n \text{ gerade} \end{cases}$$

Modus x_{mod} : der Wert, der am häufigsten vorkommt.

Lagemaß	ab welcher Skala?	Eigenschaft
Modus	jede Skala (auch nominal)	bei stetigen Daten oft nicht sinnvoll
Median	ab ordinal	robust gegen Ausreißer
Mittelwert	kardinal (auch für 0/1-Daten → Anteil)	empfindlich gegen Ausreißer; $\sum (x_i - \bar{x}) = 0$

BEISPIEL: AUSREISSER (TUTORIUM 2)

Datensatz I: 5, 6, 7, 8, **14** → $\bar{x} = 8$, $x_{med} = 7$. Datensatz II: 5, 6, 7, 8, 9 → $\bar{x} = 7$, $x_{med} = 7$.


Nur ein Wert ist anders. Der Mittelwert ändert sich, der Median nicht. **Der Median ist robuster gegenüber Extremwerten.** (Diesen Satz wollte die Probeklausur B als Antwort sehen!)

BEISPIEL: SEMESTERZAHLEN (N = 23)

$$\bar{x} = \frac{1}{23} (2 \cdot 1 + 3 \cdot 7 + 4 \cdot 5 + 5 \cdot 5 + 6 \cdot 1 + 7 \cdot 4) = \frac{102}{23} = 4.435.$$

Median: $n = 23$ ungerade → $x_{(12)}$. Sortiert: 2, 3,3,3,3,3,3,3, 4,4,4,4,... → $x_{med} = 4$. Modus: 3 (kommt 7-mal vor).

Lagemaße und Form der Verteilung



MERKE

rechtsschief (= linkssteil, langer Schwanz nach rechts): $\bar{x} > x_{med} > x_{mod}$. Typisch für Einkommen.

symmetrisch: $\bar{x} \approx x_{med} \approx x_{mod}$.

linksschief (= rechtssteil): $\bar{x} < x_{med} < x_{mod}$.

Eselsbrücke: Der Mittelwert wird vom langen Schwanz „weggezogen“.

Rechenregeln

- **Lineare Transformation** $y_i = a + b x_i$: $\bar{y} = a + b \bar{x}$.
- **Monotone Transformation** $y_i = g(x_i)$ (z. B. log): $y_{med} = g(x_{med})$. Für den Mittelwert gilt das **nicht**.
- **Mittelwert aus Gruppen** (Schichten): $\bar{x} = \frac{1}{n} \sum_j n_j \bar{x}_j$ (gewichteter Durchschnitt).

Klassierte Daten

Wenn wir nur Klassen kennen, nehmen wir die **Klassenmitte** m_j als Stellvertreter:

FORMEL: KLASSIERTE DATEN

$$\bar{x}_K = \sum_j f_j m_j \qquad s_K^2 = \sum_j f_j (m_j - \bar{x}_K)^2$$

KLAUSURAUFGABE (PROBEKLAUSUR A, 2C, 4 PUNKTE)

Bier in Klassen $K_1 = [0, 10)$ und $K_2 = [10, 20]$. In K_1 : 4, 4, 4, 8.5, 8.5, 8.5, 8.5 $\rightarrow$ 7 Werte. In K_2 : 12, 12, 15.7 $\rightarrow$ 3 Werte. Mitten: $m_1 = 5$, $m_2 = 15$.

$$\bar{x}_K = \frac{1}{10} (7 \cdot 5 + 3 \cdot 15) = \frac{80}{10} = 8$$

(Der echte Mittelwert ist 8.57 – die Klassenmitte ist nur eine Näherung.)

KONTROLLFRAGEN 1.4 – 1.5

- 1 Warum ist bei ungleich breiten Klassen ein Histogramm besser als ein Säulendiagramm?
- 2 Eine Klasse (20, 40] enthält 30 % der Daten. Wie hoch ist die Säule im Histogramm?
- 3 Daten: 3, 1, 7, 2, 100, 4. Berechne Mittelwert und Median. Welches Maß beschreibt die „Mitte“ besser?
- 4 Einkommen sind meist rechtsschief. Was ist größer: Mittelwert oder Median?
- 5 Welches Lagemaß kannst du für „Lieblingsmensa“ angeben? Welche für „Zufriedenheit 1–7“?

Quantile

Das α -Quantil x_α teilt die sortierten Daten: mindestens $\alpha \cdot 100\%$ der Werte sind kleiner oder gleich x_α . Der Median ist $x_{0.5}$. Die **Quantile** sind $x_{0.25}, x_{0.5}, x_{0.75}$.

FORMEL: QUANTIL (DEFINITION AUS DER VORLESUNG)

$$x_\alpha = \begin{cases} x_{(\lfloor n\alpha \rfloor + 1)} & n\alpha \text{ keine ganze Zahl (aufrunden!)} \\ \in [x_{(n\alpha)}, x_{(n\alpha+1)}] & n\alpha \text{ ganze Zahl (meist Mittelwert der beiden)} \end{cases}$$

BEISPIEL: MIETSPIEGEL (V02), N = 26 SORTIERTE MIETEN

$x_{0.25}$: $0.25 \cdot 26 = 6.5 \rightarrow$ keine ganze Zahl $\rightarrow$ aufrunden auf 7 $\rightarrow x_{(7)} = 170.04$.

$x_{0.5}$: $0.5 \cdot 26 = 13 \rightarrow$ ganze Zahl $\rightarrow$ zwischen $x_{(13)} = 243.44$ und $x_{(14)} = 255.75 \rightarrow$ Mittelwert 249.6.

$x_{0.75}$: $0.75 \cdot 26 = 19.5 \rightarrow$ aufrunden auf 20 $\rightarrow x_{(20)} = 311.87$.

Streuungsmaße

FORMEL: VARIANZ UND STANDARDABWEICHUNG

$$s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \stackrel{\text{Verschiebungssatz}}{=} \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2 = \overline{x^2} - \bar{x}^2$$

$$s_*^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{n}{n-1} s^2 \quad (\text{unverzerrte / korrigierte Varianz})$$

$$s = \sqrt{s^2} \quad \text{IQR} = x_{0.75} - x_{0.25}$$

ACHTUNG: 1/N ODER 1/(N-1)?

- „Empirische Varianz“ per Hand in Teil A: meistens s^2 mit $\frac{1}{n}$ (so rechnen die Lösungen).
- R** rechnet mit `var()` und `sd()` immer die **unverzerrte** Version s_*^2 mit $\frac{1}{n-1}$!
- Umrechnen: $s^2 = \frac{n-1}{n} s_*^2$ bzw. $n s^2 = (n-1) s_*^2$.
- Wenn in der Aufgabe „unverzerrter Schätzer“ oder „Stichprobenvarianz s_*^2 “ steht: $\frac{1}{n-1}$.

Vorteil der Standardabweichung: Sie hat die **gleiche Einheit** wie das Merkmal (Euro statt Euro²).

KLAUSURAUFGABE (PROBEKLAUSUR A, 5A): SCHIESSFEHLER 3, 2, 5, 1, 3, 4

$$\bar{x} = \frac{18}{6} = 3, \quad \overline{x^2} = \frac{9+4+25+1+9+16}{6} = \frac{64}{6} = 10.6667$$

$$s_x^2 = 10.6667 - 3^2 = 1.667$$

Lineare Transformation $y_i = a + bx_i$: $s_y^2 = b^2 s_x^2$, $s_y = |b| s_x$, $\text{IQR}_y = |b| \text{IQR}_x$. Die Verschiebung a ändert die Streuung nicht! (Tutorium 2: Datensatz III = 2 · Datensatz II $\rightarrow$ Varianz 4-mal so groß: 8 statt 2.)

Der Boxplot


Der Boxplot ist eine **Fünf-Punkte-Zusammenfassung**: Minimum, $x_{0.25}$, Median, $x_{0.75}$, Maximum. **Ausreißer** sind Werte, die mehr als $1.5 \cdot \text{IQR}$ unter $x_{0.25}$ oder über $x_{0.75}$ liegen. Der Whisker endet beim extremsten Wert, der **noch innerhalb** dieser Grenzen liegt.

BEISPIEL (TUTORIUM 2, AUFGABE 7): 20 SEMESTERZAHLEN

1,1,1,1,2,2,3,3,3,4,4,5,6,6,6,6,7,9,13,14. $n\alpha = 20 \cdot 0.25 = 5$ (ganz) $\rightarrow x_{0.25} \in [x_{(5)}, x_{(6)}] = [2, 2] = 2$;
analog $x_{0.75} = 6$. IQR = 4.

Obere Grenze: $6 + 1.5 \cdot 4 = 12 \rightarrow$ oberer Whisker = größter Wert $\leq 12 = 9$; 13 und 14 sind Ausreißer.

Untere Grenze: $2 - 6 = -4 \rightarrow$ unterer Whisker = Minimum = 1.



KONTROLLFRAGEN 1.6

- 1 Daten: 2, 4, 4, 5, 7, 8, 9, 11 ($n = 8$). Bestimme $x_{0.25}$, Median, $x_{0.75}$ nach der Vorlesungsdefinition.
- 2 Berechne für 2, 4, 6 die Varianz s^2 (mit $1/n$) und s_*^2 (mit $1/(n-1)$). Was gibt R mit `var(c(2,4,6))` aus?
- 3 Alle Preise werden in Cent statt Euro angegeben (mal 100). Was passiert mit Mittelwert, Varianz und Standardabweichung?
- 4 Was ist ein Ausreißer im Boxplot?

1.7 Zwei Merkmale: Kontingenztafel und χ^2 -Koeffizient

Hörtext 1.7

Jetzt schauen wir zwei Merkmale X und Y **zusammen** an. Die **gemeinsame Verteilung** steht in einer **Kontingenztafel**. Die Summen am Rand heißen **Randverteilungen**.

BEISPIEL (TUTORIUM 3): 1000 VERKEHRSUNFÄLLE

380 tödlich (T), davon 160 mit alkoholisiertem Fahrer (A). 720 Unfälle ohne Alkohol ($\bar{A}$).

	A (Alkohol)	$\bar{A}$ (kein Alkohol)	Σ
T (tödlich)	160	220	380
$\bar{T}$ (nicht tödlich)	120	500	620
Σ	280	720	1000

Fehlende Zahlen durch Differenzen: $380 - 160 = 220$, $1000 - 720 = 280$, $280 - 160 = 120$, ...

FORMEL: RAND UND BEDINGTE VERTEILUNG

$$h_{j\bullet} = \sum_k h_{jk} \text{ (Zeilensumme)}, \quad h_{\bullet k} = \sum_j h_{jk} \text{ (Spaltensumme)}, \quad f_{jk} = \frac{h_{jk}}{n}$$
$$\text{bedingt: } f(Y = b_k | X = a_j) = \frac{h_{jk}}{h_{j\bullet}} \text{ (Zeile durch Zeilensumme)}$$

Im Beispiel: $f(T | A) = \frac{160}{280} = 0.571$ und $f(T | \bar{A}) = \frac{220}{720} = 0.306$. Die bedingten Verteilungen sind **verschieden** → es gibt einen **Zusammenhang**. Wären alle bedingten Verteilungen gleich, wären die Merkmale **unabhängig**.

FORMEL: χ^2 -KOEFFIZIENT

$$\tilde{h}_{jk} = \frac{h_{j\bullet} \cdot h_{\bullet k}}{n} \text{ (erwartet bei Unabhängigkeit)} \quad \chi^2 = \sum_j \sum_k \frac{(h_{jk} - \tilde{h}_{jk})^2}{\tilde{h}_{jk}}$$

$\chi^2 \approx 0 \rightarrow$ (fast) unabhängig. χ^2 groß $\rightarrow$ starker Zusammenhang.

RECHNUNG FÜR DIE UNFÄLLE

$\tilde{h}_{T,A} = \frac{380 \cdot 280}{1000} = 106.4$, $\tilde{h}_{T,\bar{A}} = 273.6$, $\tilde{h}_{\bar{T},A} = 173.6$, $\tilde{h}_{\bar{T},\bar{A}} = 446.4$. Alle Differenzen sind ± 53.6 :

$$\chi^2 = 53.6^2 \left(\frac{1}{106.4} + \frac{1}{273.6} + \frac{1}{173.6} + \frac{1}{446.4} \right) = 60.487$$

Am Tag 4 machen wir daraus einen **Test** (χ^2 -Unabhängigkeitstest).

1.8 Kovarianz und Korrelation


Hörtext 1.8

Für zwei **metrische** Merkmale zeichnen wir ein **Streudiagramm** (Punktwolke). Die Kovarianz misst, ob die Punkte eher von links unten nach rechts oben liegen (positiv) oder von links oben nach rechts unten (negativ).

FORMEL: KOVARIANZ UND KORRELATION (BRAVAIS-PEARSON)

$$s_{xy} = \text{Cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{n} \sum_{i=1}^n x_i y_i - \bar{x} \bar{y} = \overline{xy} - \bar{x} \bar{y}$$

$$r_{xy} = \rho_{xy} = \frac{s_{xy}}{s_x s_y} = \frac{s_{xy}}{\sqrt{s_x^2 s_y^2}} \in [-1, 1]$$



$ r $	0 bis < 0.3	0.3 bis < 0.7	0.7 bis 1
Stärke	schwach	mittel	stark

MERKE – DIE WICHTIGSTEN EIGENSCHAFTEN

- Die Kovarianz hängt von den **Einheiten** ab (cm oder m?) → ihr Wert ist schwer zu deuten. Nur das **Vorzeichen** sagt etwas.
- Die Korrelation hat **keine Einheit** und liegt immer zwischen -1 und 1 . $|r| = 1$: alle Punkte auf einer Geraden.
- r misst nur **lineare** Zusammenhänge. $r \approx 0$ heißt **nicht** „kein Zusammenhang“: bei $y = x^2$ kann $r \approx 0$ sein.
- Unabhängig $\Rightarrow$ unkorreliert. Aber: unkorreliert $\nRightarrow$ unabhängig.
- $\text{Cov}(X, X) = \text{Var}(X)$; wenn $X = Y$, dann $r = 1$.

KLAUSURAUFGABE (PROBEKLAUSUR A, 5B, 5 PUNKTE)

Gegeben: $s_y^2 = 10$, $s_x^2 = 1.6$, $\bar{y} = 22$, $\bar{x} = 3$, $\sum x_\nu y_\nu = 399$, $n = 6$.

$$s_{xy} = \frac{399}{6} - 3 \cdot 22 = 66.5 - 66 = 0.5 \quad r_{xy} = \frac{0.5}{\sqrt{1.6 \cdot 10}} = \frac{0.5}{4} = 0.125$$

Interpretation (2 Punkte): Der Korrelationskoeffizient misst die Stärke des **linearen** Zusammenhangs und liegt zwischen -1 und 1 . $r = 0.125$ ist positiv, aber klein: Es gibt einen **schwachen positiven linearen Zusammenhang** zwischen Schießfehlern und Laufzeit. Mehr Fehler gehen tendenziell mit etwas längerer Laufzeit einher.

5c – Kausalität? Nein. Eine Korrelation beweist **keine Kausalität**. Der Zusammenhang kann durch eine dritte Variable (z. B. Müdigkeit, Wetter) oder Zufall entstehen.

5d: Skizze für $r = 0$: Punktwolke ohne Richtung (rundliche Wolke) – Achsen beschriften (x: Schießfehler, y: Laufzeit)!

Rangkorrelation nach Spearman

Für **ordinale** Daten (oder wenn der Zusammenhang monoton, aber nicht linear ist) ersetzt man die Werte durch ihre **Ränge** (kleinster Wert = Rang 1) und berechnet Pearson mit den Rängen. Bei gleichen Werten (Bindungen) nimmt man **Durchschnittsränge** (z. B. Platz 4 und 5 → beide 4.5). In R: `cor(x, y, method = "spearman")`.

Korrelation ist keine Kausalität

- **Kausalität:** Eine Änderung von X **verursacht** eine Änderung von Y . Nachweis nur mit Experiment (gezielte Manipulation von X) und Kontrolle aller anderen Einflüsse (z. B. Randomisierung).
- **Scheinkorrelation:** Margarineverbrauch und Scheidungsrate in Maine haben $r = 0.99$ – aber Margarine verursacht keine Scheidungen. Mögliche dritte Variable: wirtschaftliche Lage; oder einfach Zufall.
- **Ökologischer Fehlschluss:** Man schließt von Gruppen-Daten (Stadtbezirke) auf einzelne Personen. Beispiel EHEC: Bezirke mit vielen Grünen-Wählern hatten mehr Kranke – aber die Ursache war Sprossengemüse, nicht die Partei.

KONTROLLFRAGEN 1.7 – 1.8

- 1 Anne misst die Größe in cm und bekommt $s_{xy} = 153.88$, Bobo misst in m und bekommt 1.5388. Wer hat recht? Was ist besser zu vergleichen?
- 2 Berechne mit dem Verschiebungssatz: $n = 50$, $\sum x = 2019$, $\sum y = 3733$, $\sum x^2 = 87611$, $\sum y^2 = 301695$, $\sum xy = 160064$. Gesucht: s_{xy} und r .
- 3 Richtig oder falsch? (a) Wenn $r \neq 0$, sind X und Y abhängig. (b) Wenn $Y = -X^2$, kann $r \approx 0$ sein. (c) Wenn $r \neq 0$, gibt es einen kausalen Zusammenhang. (d) $\text{Cov} \geq 0.8$ bedeutet immer starken Zusammenhang.
- 4 Wann sind zwei Merkmale in einer Kontingenztafel unabhängig?

In Teil B arbeitest du mit **RStudio**. Oben schreibst du das **Skript**, unten in der **Konsole** siehst du das Ergebnis. Mit **Strg + Enter** führst du eine Zeile aus. Speichere dein Skript oft!

R-ECKE: OBJEKTE UND VEKTOREN

```
# Zuweisung mit <- (sprich: "bekommt")
x <- c(3, 2, 5, 1, 3, 4) # c() = combine: Vektor
y <- 1:6                # 1 2 3 4 5 6
z <- seq(2, 8, by = 2)  # 2 4 6 8
x[1]; x[length(x)]     # erstes und letztes Element
x * 1.5                 # rechnet mit jedem Element
typeof(x)               # "double" (Kommazahl)
typeof(1:6)             # "integer" (ganze Zahlen)
typeof(c("A","B"))      # "character" (Text)
typeof(x > 2)           # "logical" (TRUE/FALSE)
f <- factor(c("a","b","a")) # Faktor = Kategorien
class(f)                # "factor"
```

R-ECKE: DATENSATZ EINLESEN (KOMMT IN JEDER TEIL-B-KLAUSUR!)

```
setwd(path.expand("~/")) # Arbeitsordner = Dokumente
d <- read.csv("daten.csv", header = TRUE, sep = ",", dec = ".")
head(d)                  # erste 6 Zeilen
str(d)                   # Struktur: Variablen und Typen
d$Muenzen                # eine Spalte mit $
typeof(d$Ta1)            # z.B. "character"
class(d$Muenzen)         # z.B. "integer"
dim(d); nrow(d)          # Anzahl Zeilen/Spalten
```

Wichtig: sep = Trennzeichen zwischen Spalten („," oder „;"), dec = Dezimalzeichen („." oder „,"), header = TRUE = erste Zeile enthält die Namen. Schau die Datei vorher an! Alternative: read.table(..., header = TRUE, sep = ";").

R-ECKE: KENNZAHLEN VON TAG 1

```
mean(x); median(x)      # Mittelwert, Median
var(x); sd(x)           # ACHTUNG: mit 1/(n-1) !
var(x) * (length(x)-1)/length(x) # Varianz mit 1/n
quantile(x, 0.25)       # Quantil (R-Methode kann leicht abweichen)
IQR(x); range(x); min(x); max(x)
summary(x)              # Min, Quartile, Median, Mittel, Max
table(x)                # absolute Häufigkeiten
prop.table(table(x))    # relative Häufigkeiten
which(table(x) == max(table(x))) # Modus
round(mean(x), 3)       # auf 3 Nachkommastellen
mean(x, na.rm = TRUE)   # fehlende Werte (NA) ignorieren
```

R-ECKE: GRAFIKEN UND ZUSAMMENHÄNGE

```
hist(x, breaks = c(0, 2, 4, 6), freq = FALSE, # freq=FALSE -> Dichte (normiert)
     right = TRUE, # Intervalle (a,b] ; FALSE -> [a,b)
     main = "Titel", xlab = "x-Achse", ylab = "Dichte")
boxplot(x, main = "Boxplot", ylab = "Semester")
boxplot(x, plot = FALSE)$stats # Whisker, Quartile, Median
plot(x, y, xlab = "x", ylab = "y", main = "Streudiagramm")
cor(x, y) # Pearson
cor(x, y, method = "spearman") # Spearman
table(d$A, d$B) # Kontingenztafel
k <- cut(x, breaks = c(0, 5, 60, Inf), right = FALSE) # in Klassen einteilen -> factor
```

`freq = FALSE` und `prob = TRUE` machen beide ein normiertes Histogramm (Fläche 1). `freq = TRUE` (Standard) zeigt absolute Häufigkeiten – das ist nur bei gleich breiten Klassen okay.

KONTROLLFRAGEN 1.9

- 1 Warum gibt `var(c(2,4,6))` den Wert 4 und nicht 2.667?
- 2 Ergänze: `d <- read.____("WitcherData2.csv", sep = ____, ____ = ".", header = ____)`
- 3 Welcher Befehl erzeugt ein **normiertes** Histogramm: `hist(x, freq = TRUE)` oder `hist(x, freq = FALSE)` ?
- 4 Was ist der Unterschied zwischen `table(x)` und `prop.table(table(x))` ?

K1 Klausuraufgaben Tag 1 – rechne selbst!

Nimm Stift, Papier und Taschenrechner. Stoppe die Zeit. Die Punkte zeigen dir, wie viele Minuten du ungefähr hast (1 Punkt $\approx$ 1.3 Minuten).

AUFGABE 1.A (10 PUNKTE) – PROBEKLAUSUR A, AUFGABE 1

Harry befragt 20 Schüler*innen, ob die Vorhersagen einer Wahrsagerin richtig waren (1 = richtig, 0 = falsch). R-Output:

```
> sort(Vorhersagen)
[1] 0 0 0 0 0 0 0 0 0 0 0 1 1 1 1 1 1 1 1 1
```

(a) Welches Skalenniveau hat „Korrektheit der Vorhersage“? (b) Berechne x_{mod} , x_{med} , $\bar{x}$ und s_x^2 . Wenn ein Wert nicht sinnvoll ist, begründe kurz.

AUFGABE 1.B (14 PUNKTE) – PROBEKLAUSUR A, AUFGABE 2

Bierkonsum X (Liter) und Herkunft Y (BY/NRW) von 10 Gästen: $X = 8.5, 8.5, 4.0, 4.0, 12.0, 12.0, 8.5, 15.7, 4.0, 8.5$; $Y = BY, BY, NRW, BY, NRW, BY, BY, NRW, NRW, BY$. Hinweis: $\sum x_i = 85.7$, $\sum x_i^2 = 871.49$.

(a) Diskret oder stetig? Skalenniveau von X und Y ? (4P) (b) Zeichne die empirische Verteilungsfunktion von X . (6P) (c) Klassen $[0, 10)$, $[10, 20]$: Mittelwert der klassierten Daten. (4P) (d) Zusatz: Berechne $\bar{x}$, s^2 und den Modus von Y .

AUFGABE 1.C (8 PUNKTE) – NACH TUTORIUM 3

Filmbewertungen von 5 Filmen: Portal A: 6, 8, 7, 9, 5; Portal B: 7, 9, 6, 10, 6.

(a) Berechne $\bar{x}$, $\bar{y}$, s_x^2 , s_y^2 , s_{xy} (mit $1/n$) und r_{xy} . (b) Interpretiere r . (c) Bestimme die Ränge und den Spearman-Koeffizienten.

AUFGABE 1.D (6 PUNKTE) – NACH TUTORIUM 2, AUFGABE 5

Arbeitszeit pro Woche während der Vorlesungszeit: $[0,4]$: 40.2 %, $(4,8]$: 19.6 %, $(8,12]$: 21.9 %, $(12,16]$: 18.3 %.

(a) Welche Klasse ist die Modalklasse? (b) Berechne näherungsweise Mittelwert und Varianz mit den Klassenmitten. (c) Wie hoch ist die Säule der Klasse $(4,8]$ im Histogramm?

AUFGABE 1.E (R, 6 PUNKTE)

Der Vektor x enthält Monatseinkommen. (a) Schreibe den Befehl für die Standardabweichung (zwei Möglichkeiten). (b) Erstelle ein normiertes Histogramm mit den Klassen $[0,1000)$, $[1000,2000)$, $[2000,5000)$ mit Titel und Achsenbeschriftung und speichere es als `Einkommen.pdf`. (c) Wie berechnest du den Anteil der Werte unter 1000?

Lösungen Tag 1

Kontrollfragen 1.1 – 1.3

1. Einheit: ein Kunde. Grundgesamtheit: alle 5000 Kunden. Stichprobe: die 200 befragten Kunden.
2. (a) kardinal, stetig; (b) ordinal, diskret; (c) nominal, diskret; (d) kardinal, diskret.
3. Falsch. Diskret = endlich **oder abzählbar unendlich** viele Werte.
4. Klumpenstichprobe (die Straßen sind die Klumpen).

Kontrollfragen 1.4 – 1.5

1. Beim Säulendiagramm wirken breite Klassen zu groß. Im Histogramm ist die **Fläche** proportional zum Anteil – das Bild ist ehrlich.
2. Höhe = $0.30 / 20 = 0.015$.
3. Sortiert: 1, 2, 3, 4, 7, 100. $\bar{x} = 117/6 = 19.5$; Median = $(3 + 4)/2 = 3.5$. Der Median beschreibt die Mitte besser (Ausreißer 100).
4. Der Mittelwert ist größer als der Median.
5. Lieblingsmensa (nominal): nur Modus. Zufriedenheit (ordinal): Modus und Median (Mittelwert eigentlich nicht erlaubt).

Kontrollfragen 1.6

1. $n\alpha = 2$ (ganz) $\rightarrow x_{0.25} = (x_{(2)} + x_{(3)})/2 = (4 + 4)/2 = 4$; Median = $(5 + 7)/2 = 6$; $8 \cdot 0.75 = 6 \rightarrow x_{0.75} = (x_{(6)} + x_{(7)})/2 = (8 + 9)/2 = 8.5$.
2. $\bar{x} = 4$; $s^2 = \frac{4+0+4}{3} = 2.667$; $s_*^2 = \frac{8}{2} = 4$. R gibt 4 aus.
3. Mittelwert $\times 100$, Standardabweichung $\times 100$, Varianz $\times 10\ 000$.
4. Ein Wert, der mehr als $1.5 \cdot \text{IQR}$ unter dem unteren oder über dem oberen Quartil liegt.

Kontrollfragen 1.7 – 1.8

1. Beide rechnen richtig, nur mit anderer Einheit (Faktor 100). Die Kovarianz hängt von der Einheit ab. Besser: der Korrelationskoeffizient (ohne Einheit, hier 0.836).
2. $\bar{x} = 40.38$, $\bar{y} = 74.66$. $s_{xy} = \frac{160064}{50} - 40.38 \cdot 74.66 = 3201.28 - 3014.7708 = 186.509$. $s_x^2 = 1752.22 - 1630.5444 = 121.6756$, $s_y^2 = 6033.9 - 5574.1156 = 459.7844$. $r = \frac{186.5092}{\sqrt{121.6756 \cdot 459.7844}} = 0.789 \rightarrow$ starker positiver linearer Zusammenhang.
3. (a) richtig (unabhängig $\Rightarrow r = 0$, also ist $r \neq 0 \Rightarrow$ abhängig); (b) richtig; (c) falsch; (d) falsch (Kovarianz hängt von der Einheit ab).
4. Wenn alle bedingten Verteilungen gleich sind, also $h_{jk} = \frac{h_{j\bullet} h_{\bullet k}}{n}$ für alle Felder (dann $\chi^2 = 0$).

Kontrollfragen 1.9

1. R rechnet die unverzerzte Varianz mit $\frac{1}{n-1}$: $8/2 = 4$.
2. `d <- read.csv("WitcherData2.csv", sep = ",", dec = ".", header = TRUE)`
3. `hist(x, freq = FALSE)`
4. `table` zählt (absolute Häufigkeiten), `prop.table(table(x))` gibt Anteile (relative Häufigkeiten).

Aufgabe 1.A

(a) **Nominal** (binär, 0/1-kodiert: richtig/falsch haben keine echte Ordnung). (b) $x_{mod} = 0$ (11-mal). Median: $n = 20$ gerade $\rightarrow$ zwischen $x_{(10)} = 0$ und $x_{(11)} = 0 \rightarrow x_{med} = 0$. *Begründung, wenn man streng ist:* Für nominale Daten ist der Median eigentlich nicht definiert (keine Ordnung); bei 0/1-Kodierung kann man ihn berechnen ($= 0$). $\bar{x} = \frac{9}{20} = 0.45$ – sinnvoll, denn bei 0/1-Daten ist das der **Anteil** richtiger Vorhersagen (45 %). $s^2 = \overline{x^2} - \bar{x}^2 = 0.45 - 0.2025 = 0.248$ (genau 0.2475; das ist $\bar{x}(1 - \bar{x})$).

Aufgabe 1.B

- (a) X: **stetig**, kardinal (Verhältnisskala). Y: **diskret, nominal**.
(b) Siehe Beispiel in 1.4: Stufen 0 / 0.3 / 0.7 / 0.9 / 1 an den Stellen 4, 8.5, 12, 15.7.
(c) $\bar{x}_K = \frac{1}{10}(7 \cdot 5 + 3 \cdot 15) = 8$.
(d) $\bar{x} = 85.7/10 = 8.570$; $s^2 = 87.149 - 8.57^2 = 13.704$ ($s = 3.702$); Modus(Y) = BY (6-mal).

Aufgabe 1.C

- (a) $\bar{x} = 7$, $\bar{y} = 7.6$. $\sum x^2 = 255 \Rightarrow s_x^2 = 51 - 49 = 2$. $\sum y^2 = 302 \Rightarrow s_y^2 = 60.4 - 57.76 = 2.64$. $\sum xy = 42 + 72 + 42 + 90 + 30 = 276 \Rightarrow s_{xy} = 55.2 - 53.2 = 2$. $r = \frac{2}{\sqrt{2 \cdot 2.64}} = \frac{2}{2.2978} = 0.870$.
(b) Starker positiver linearer Zusammenhang: Filme mit guter Bewertung bei A haben meist auch gute Bewertungen bei B.
(c) Ränge A: $6 \rightarrow 2, 8 \rightarrow 4, 7 \rightarrow 3, 9 \rightarrow 5, 5 \rightarrow 1$. Ränge B: $7 \rightarrow 3, 9 \rightarrow 4, 6 \rightarrow 1.5, 10 \rightarrow 5, 6 \rightarrow 1.5$. Mittlerer Rang 3.
 $\sum rk_x rk_y = 6 + 16 + 4.5 + 25 + 1.5 = 53$; $\sum rk_x^2 = 55$; $\sum rk_y^2 = 9 + 16 + 2.25 + 25 + 2.25 = 54.5$.
 $r_{Sp} = \frac{53 - 5 \cdot 9}{\sqrt{(55 - 45)(54.5 - 45)}} = \frac{8}{\sqrt{95}} = 0.821$.

Aufgabe 1.D

- (a) $[0, 4]$ (40.2 %). (b) Mitten 2, 6, 10, 14: $\bar{x} = 0.402 \cdot 2 + 0.196 \cdot 6 + 0.219 \cdot 10 + 0.183 \cdot 14 = 6.732$. $s^2 = 0.402(2 - 6.732)^2 + 0.196(6 - 6.732)^2 + 0.219(10 - 6.732)^2 + 0.183(14 - 6.732)^2 = 21.112$. (c) $0.196/4 = 0.049$.

Aufgabe 1.E

```
sd(x)                                # oder: sqrt(var(x))
pdf("Einkommen.pdf")
hist(x, breaks = c(0, 1000, 2000, 5000), right = FALSE, freq = FALSE,
     main = "Einkommen", xlab = "Einkommen in Euro", ylab = "Dichte")
dev.off()
mean(x < 1000)                       # Anteil (TRUE zählt als 1)
```

Dein Formelblatt – Teil für Tag 1

DAS SCHREIBST DU HEUTE MIT DER HAND AUF DEIN A4-BLATT

- Skalen: nominal (Modus) · ordinal (+ Median) · kardinal (+ Mittelwert); diskret = abzählbar, stetig = Intervall
- $f_j = h_j/n$; Histogramm-Höhe = f_j/Breite ; $\hat{F}(x) = \#\{x_i \leq x\}/n$ (Treppe, ● links, ○ rechts)
- $\bar{x} = \frac{1}{n} \sum x_i = \sum a_j f_j$; klassiert $\bar{x}_K = \sum f_j m_j$; Median: $x_{((n+1)/2)}$ bzw. Mittel der beiden mittleren
- Quantil: $n\alpha$ nicht ganz $\rightarrow$ aufrunden, $x_{(\lceil n\alpha \rceil)}$; ganz $\rightarrow \frac{x_{(n\alpha)} + x_{(n\alpha+1)}}{2}$
- $s^2 = \overline{x^2} - \bar{x}^2$; $s_*^2 = \frac{n}{n-1} s^2$ (R: var, sd!); $y = a + bx \Rightarrow s_y^2 = b^2 s_x^2$
- Boxplot: Ausreißer außerhalb $[x_{0.25} - 1.5 \text{ IQR}; x_{0.75} + 1.5 \text{ IQR}]$
- rechtsschief: $\bar{x} > x_{med} > x_{mod}$
- $\tilde{h}_{jk} = \frac{h_{jk} \cdot h_{*k}}{n}$, $\chi^2 = \sum \frac{(h_{jk} - \tilde{h}_{jk})^2}{\tilde{h}_{jk}}$

- $s_{xy} = \overline{xy} - \bar{x}\bar{y}$; $r = \frac{s_{xy}}{s_x s_y}$; $|r|$: <0.3 schwach, 0.3–0.7 mittel, ≥ 0.7 stark; Korrelation $\neq$ Kausalität

Wörterliste Tag 1 (Deutsch – Türkçe)

Grundgesamtheit	<i>ana kütle / evren</i>	alle Einheiten, die uns interessieren
Stichprobe	<i>örneklem</i>	der untersuchte Teil
Merkmal / Ausprägung	<i>değişken / değer</i>	Eigenschaft / konkreter Wert
Skalenniveau	<i>ölçek düzeyi</i>	nominal, ordinal, kardinal
Häufigkeit (absolut/relativ)	<i>frekans (mutlak/görel)</i>	Anzahl / Anteil
Verteilungsfunktion	<i>(birikimli) dağılım fonksiyonu</i>	Anteil der Werte $\leq x$
arithmetisches Mittel	<i>aritmetik ortalama</i>	Durchschnitt
Median / Modus	<i>medyan / mod</i>	Mitte / häufigster Wert
Streuung, Varianz	<i>yayılım, varyans</i>	wie weit die Werte auseinander liegen
Standardabweichung	<i>standart sapma</i>	Wurzel aus der Varianz
Quantil / Quartil	<i>kantil / çeyreklik</i>	Grenze, unter der $\alpha \cdot 100$ % liegen
Ausreißer	<i>aykırı değer</i>	extremer Wert
Kontingenztafel	<i>çapraz tablo / olumsuzluk tablosu</i>	Tabelle für zwei Merkmale
Zusammenhang	<i>ilişki</i>	Merkmale hängen zusammen
Kovarianz / Korrelation	<i>kovaryans / korelasyon</i>	Maße für linearen Zusammenhang
Kausalität	<i>nedensellik</i>	Ursache $\rightarrow$ Wirkung
schief (rechts/links)	<i>çarpık (sağa/sola)</i>	unsymmetrische Verteilung