

# In 5 Tagen zur 1,x in Statistik

Dein Lernbuch zum Mitlesen und Mitdenken – für Klausurteil A (Statistik, schriftlich) und Klausurteil B (R am Computer).  
In einfachem Deutsch, mit Beispielen, Fragen und Lösungen.

## Tag 1

Daten  
beschreiben:  
deskriptive  
Statistik

## Tag 2

Wahrscheinlichkeit  
& Zufallsvariablen

## Tag 3

Verteilungen &  
Maximum-  
Likelihood

## Tag 4

Schätzer,  
Konfidenzintervalle,  
Tests

## Tag 5

R-Klausur (Teil B)  
& Generalprobe

Grundlage: Vorlesungen SDS1-V01 bis V13, Tutorien 1–13, Testate 0–6, Probeklausuren Teil A und Teil B, Übungen zur ML-Schätzung.

Zu jedem Tag gibt es einen **Hörtext** (Ordner *hoertexte*). Die Nummern der Abschnitte im Hörtext und in diesem Buch sind gleich.

Hallo! Schön, dass du da bist. In den nächsten fünf Tagen lernen wir zusammen alles, was du für die Statistik-Klausur brauchst. Wir fangen ganz vorne an. Du musst nichts vorher wissen. Wir gehen Schritt für Schritt.

Das Lernpaket hat **zwei Teile**, die zusammengehören:

- **Die Hörtexte** (pro Tag drei Teile, z. B. *Hoertext\_Tag1\_Teil1.txt*): Das ist die Stimme deiner Lehrerin. Du kannst sie mit einer KI-Stimme vorlesen lassen und zuhören.
- **Dieses Lernbuch**: Hier siehst du beim Zuhören die Formeln, Tabellen, Bilder und den R-Code. Jeder Abschnitt hat eine Nummer, zum Beispiel **1.3**. Im Hörtext hörst du dieselbe Nummer: „Abschnitt eins Punkt drei“. So weißt du immer, wo wir gerade sind.

#### SO LERNST DU AM BESTEN

1. **Hören + Mitlesen**: Höre den Abschnitt und schau gleichzeitig ins Buch.
2. **Anhalten**: Wenn im Hörtext eine Frage kommt („Halte kurz an ...“), stoppe die Aufnahme und denke selbst nach.
3. **Klausurtraining**: Nach jedem Thema kommt eine Aufgabe im Stil der echten Klausur (grüner Rahmen, Teilaufgaben (a), (b), (c) ... mit Punkten). Dazu kurze Kontrollfragen (lila). Alle Lösungen stehen am Ende des Tages.
4. **R am Computer**: Im Ordner *uebungsdaten* liegt *Taverne.csv*. Damit tippst du jeden R-Befehl selbst.
5. **Rechnen**: Rechne die Klausuraufgaben selbst mit Stift und Taschenrechner. Erst danach schaust du in die Lösung.
6. **Formelblatt**: Schreibe jeden Tag die wichtigen Formeln auf dein eigenes A4-Blatt (siehe Anhang). In der Klausur darfst du ein handgeschriebenes Blatt pro Klausurteil benutzen!

#### Die Kästen in diesem Buch

##### MERKE

Das Wichtigste in einem Satz. Unbedingt lernen.

##### FORMEL

Diese Formel kommt auf dein Formelblatt.

##### BEISPIEL

Eine Aufgabe, Schritt für Schritt gerechnet.

##### ACHTUNG – TYPISCHER FEHLER

Hier machen viele Studierende Fehler.

##### KLAUSUR-TIPP

So holst du in der Klausur die Punkte.

##### R-ECKE

Der passende R-Code für Klausurteil B.

##### KONTROLLFRAGEN

Kurze Fragen zum Selbsttest.

##### TÜRKÇE AÇIKLAMA

Zor yerlerde Türkçe açıklama.

#### Klausurtraining

#### Punkte

Aufgabe im Klausurstil: Situation + Teilaufgaben (a), (b), (c) ...

Die Klausur hat **zwei Teile**. Du schreibst sie am selben Tag, zuerst Teil A, dann Teil B.

|                   | Teil A: Statistik                                                                                                                                                                                 | Teil B: R                                                                                                                                                                                                             |
|-------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Ort               | Hörsaal, auf Papier                                                                                                                                                                               | E-Prüfungsraum, am Computer (ILIAS + RStudio)                                                                                                                                                                         |
| Zeit              | 100 Minuten                                                                                                                                                                                       | 60 Minuten                                                                                                                                                                                                            |
| Punkte            | 75 Punkte                                                                                                                                                                                         | 45 Punkte                                                                                                                                                                                                             |
| Hilfsmittel       | 1 handgeschriebenes A4-Blatt (beidseitig) <b>pro Teil</b> , nicht-programmierbarer Taschenrechner mit Sticker, Kugelschreiber (kein Bleistift, nicht grün/rot)                                    |                                                                                                                                                                                                                       |
| Typische Aufgaben | Skalenniveau, Lage- und Streuungsmaße, Verteilungsfunktion zeichnen, Bayes/totale Wahrscheinlichkeit, Korrelation, ML-Schätzer herleiten, Erwartungstreue prüfen, Hypothesentest, R-Output deuten | Daten einlesen, Objekttypen, Mittelwert/SD, Histogramm als PDF speichern, Likelihood mit <code>dpois / prod</code> , eigene Funktion und for-Schleife, <code>nlm</code> , <code>pgamma / qgamma</code> , Antwortsätze |

### RUNDUNGSREGELN (SEHR WICHTIG FÜR DIE PUNKTE!)

- **Zwischenergebnisse:** mindestens **4** Nachkommastellen.
- **Endergebnisse:** **3** Nachkommastellen (kaufmännisch runden) – oder ein gekürzter Bruch.
- Ausnahmen: ganze Zahlen; „schöne“ Ausdrücke wie  $\sqrt{2}$  oder  $\log 4$ ; andere Anweisung in der Aufgabe.
- Dezimal**punkt** benutzen: 0.125 (nicht 0,125).
- In Teil B immer mit R runden: `round(x, 3)`.

### Wie bekommst du eine 1,x?

Eine sehr gute Note bekommst du, wenn du die **Standardaufgaben sicher und schnell** löst. Die Klausuraufgaben sind jedes Jahr sehr ähnlich. Wenn du die Probeklausuren, die Testate und die Tutorien verstehst, bist du vorbereitet. Genau darauf ist dieses Buch aufgebaut. Für Teil A hast du ungefähr **1,3 Minuten pro Punkt**. Für Teil B hast du ungefähr **1,3 Minuten pro Punkt**. Also: nicht lange an einer Aufgabe hängen bleiben!

## 0.3 Dein 5-Tage-Plan

Jeder Tag hat etwa **7–8 Stunden** Lernzeit mit Pausen. Mache nach 50 Minuten immer 10 Minuten Pause. Schlafe genug – im Schlaf speichert dein Gehirn das Gelernte.

| Tag          | Themen (Vorlesung)                                                                                                                                                                                                                                         | So arbeitest du                                                                                                                                                                                           |
|--------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Tag 1</b> | Grundbegriffe, Skalenniveaus, Stichproben (V01) · Häufigkeiten, Histogramm, Verteilungsfunktion, Lage- und Streuungsmaße, Quantile, Boxplot (V02) · Kontingenztafel, $\chi^2$ -Koeffizient, Kovarianz, Korrelation, Kausalität (V03) · <b>R-Grundlagen</b> | Vormittag: Hörtext 1.1–1.5 + Kontrollfragen.<br>Nachmittag: Hörtext 1.6–1.9, Klausuraufgaben Tag 1 rechnen, R-Befehle am Computer ausprobieren.                                                           |
| <b>Tag 2</b> | Mengen, Laplace, Kolmogorov, Rechenregeln, bedingte Wahrscheinlichkeit, Unabhängigkeit, totale Wahrscheinlichkeit, Bayes (V04) · Zufallsvariablen, Dichte, Verteilungsfunktion, Erwartungswert, Varianz, Rechenregeln, bivariate Verteilungen (V05, V06)   | Vormittag: Wahrscheinlichkeit (2.1–2.5), Baumdiagramme zeichnen. Nachmittag: Zufallsvariablen (2.6–2.9), Integrale üben, Testat 3 und 4 nachrechnen.                                                      |
| <b>Tag 3</b> | Bernoulli, Binomial, Poisson, Gleich-, Exponential-, Normalverteilung, Standardisieren, zentraler Grenzwertsatz, R-Funktionen d/p/q/r (V07) · <b>Maximum-Likelihood</b> (V08)                                                                              | Vormittag: Verteilungen (3.1–3.5). Nachmittag: ML-Rezept (3.6–3.8) und <b>alle</b> ML-Übungsaufgaben selbst herleiten. ML bringt in Teil A ca. 10 Punkte!                                                 |
| <b>Tag 4</b> | Bias, Varianz, MSE, Konsistenz, Histogramm und Kerndichte (V09) · Konfidenzintervalle (V10) · Hypothesentests, p-Wert, z-/t-/ $\chi^2$ -/Binomialtest, Vorzeichentest, $\chi^2$ -Unabhängigkeit, Anpassungstest (V11, V12) · Regression (V13)              | Vormittag: Schätzer + KI (4.1–4.4). Nachmittag: Tests (4.5–4.9). Abends: Testat 5 und 6.                                                                                                                  |
| <b>Tag 5</b> | <b>Klausurteil B:</b> kompletter R-Ablauf, Witcher-Klausur, Lungenvolumen-Klausur (nlm) · <b>Generalprobe Teil A</b> (Probeklausur 04.03.2022) · Formelblatt fertig machen                                                                                 | Vormittag: Tag-5-Hörtext + R-Probeklausuren am Computer (auf Zeit: 60 Min.). Nachmittag: Probeklausur A auf Zeit (100 Min.), danach Korrektur mit Lösungen. Abends: Formelblatt schreiben, früh schlafen. |

### EHRLICH GESAGT

Fünf Tage sind kurz. Das schaffst du nur, wenn du wirklich aktiv arbeitest: selbst rechnen, selbst R-Code tippen. Nur Zuhören reicht nicht für eine 1,x. Der Hörtext erklärt dir alles – aber die Punkte holst du mit dem Stift und an der Tastatur.

## Inhalt

### Tag 1 · Daten beschreiben

1.1 Grundbegriffe · 1.2 Merkmalstypen & Skalen · 1.3 Stichproben · 1.4 Häufigkeiten, Histogramm, Verteilungsfunktion · 1.5 Lagemaße · 1.6 Quantile, Streuung, Boxplot · 1.7 Kontingenztafel &  $\chi^2$  · 1.8 Kovarianz & Korrelation · 1.9 R-Kurs von null an · 1.10 Antworten formulieren · Klausurtraining 1.A–1.H · Generalprobe K1 · Lösungen

### Tag 2 · Wahrscheinlichkeit

2.1 Zufallsexperiment & Mengen · 2.2 Wahrscheinlichkeit & Regeln · 2.3 Bedingte W. & Unabhängigkeit · 2.4 Totale W. & Bayes · 2.5 Zufallsvariablen · 2.6 Dichte & Verteilungsfunktion · 2.7 Erwartungswert & Varianz · 2.8 Zwei Zufallsvariablen · Klausuraufgaben · Lösungen

### Tag 3 · Verteilungen & ML

3.1 Bernoulli & Binomial · 3.2 Poisson · 3.3 Gleich- & Exponentialverteilung · 3.4 Normalverteilung · 3.5 Zentraler Grenzwertsatz & R · 3.6 Idee der Likelihood · 3.7 Das ML-Rezept · 3.8 ML-Training · Klausuraufgaben · Lösungen

### Tag 4 · Inferenz

4.1 Gütekriterien von Schätzern · 4.2 Erwartungstreue prüfen · 4.3 Histogramm & Kerndichte · 4.4 Konfidenzintervalle · 4.5 Testprinzip · 4.6 Tests für  $\mu$  · 4.7 Varianz-, Binomial-, Vorzeichentest · 4.8  $\chi^2$ -Tests · 4.9 R-Output lesen & Regression · Klausuraufgaben · Lösungen

## **Tag 5 · R-Klausur & Generalprobe**

5.1 So läuft Teil B ab · 5.2 Einlesen & Objekttypen · 5.3  
Kennzahlen & Grafiken · 5.4 Likelihood in R · 5.5 Funktionen,  
Schleifen, paste · 5.6 nlm & Transformation · 5.7  
Probeklausur B komplett · 5.8 Generalprobe Teil A · 5.9  
Letzte Tipps

## **Anhang**

Formelblatt-Vorlage Teil A · R-Spickzettel Teil B · Wichtige  
Quantile · Wörterliste Deutsch–Türkçe

# Daten beschreiben: deskriptive Statistik

Heute lernst du die Sprache der Statistik: wie man Daten ordnet, zeichnet und mit wenigen Zahlen beschreibt – für ein Merkmal und für zwei Merkmale zusammen. Danach lernst du R von Anfang an, Befehl für Befehl. Nach jedem Thema kommt ein **Klausurtraining** im Stil der echten Klausur.

Skalenniveau

Stichproben

Histogramm

Verteilungsfunktion

Mittelwert &amp; Median

Quantile

Varianz

Boxplot

Kontingenztafel

Korrelation

R-Kurs

| Zeit        | Was du machst                                                                                                                                                              |
|-------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 09:00–10:45 | Hörtext Teil 1 (Abschnitt 0, 1.1–1.3) · Kontrollfragen · Klausurtraining 1.A                                                                                               |
| 11:00–13:30 | Hörtext Teil 2 (1.4–1.6): Häufigkeiten, Histogramm, Lagemaße, Streuung · Klausurtraining 1.B–1.E mit Taschenrechner                                                        |
| 14:30–16:00 | Hörtext Teil 3, erste Hälfte (1.7–1.8): Zusammenhänge · Klausurtraining 1.F–1.G                                                                                            |
| 16:15–18:00 | Hörtext Teil 3, zweite Hälfte (1.9–1.10): R-Kurs. RStudio öffnen, <b>jeden</b> Befehl selbst tippen, Übungsdatei <code>Taverne.csv</code> benutzen · R-Klausurtraining 1.H |
| 18:15–19:30 | Gemischte Klausuraufgaben K1 auf Zeit, Lösungen vergleichen, Formelblatt schreiben                                                                                         |

## WIE DU MIT DEM KLAUSURTRAINING ARBEITEST

Die grünen Kästen „Klausurtraining“ sind wie echte Klausuraufgaben gebaut: Zuerst kommt eine Situation, dann Teilaufgaben (a), (b), (c) ... mit Punkten. Rechne sie **auf Papier**, mit Lösungsweg, und stoppe die Zeit (1 Punkt  $\approx$  1.3 Minuten). Alle Lösungen stehen ausführlich am Ende von Tag 1.

## 1.1 Grundbegriffe der Statistik

Hörtext Teil 1 · 1.1

Statistik beschreibt und analysiert **Daten**. Bevor wir rechnen, brauchen wir ein paar Wörter. Wir lernen sie an zwei Beispielen aus der Vorlesung.

| Begriff                             | Bedeutung                                                  | Beispiel 1: Wahlumfrage                           | Beispiel 2: Politikmaßnahme                                 |
|-------------------------------------|------------------------------------------------------------|---------------------------------------------------|-------------------------------------------------------------|
| <b>statistische Einheit</b>         | das Objekt, an dem wir etwas messen                        | eine wahlberechtigte Person                       | eine Firma                                                  |
| <b>Grundgesamtheit</b> (Population) | alle Einheiten, die für die Frage wichtig sind             | alle Wahlberechtigten der nächsten Bundestagswahl | alle Firmen, die von der Maßnahme betroffen sind            |
| <b>Stichprobe</b>                   | der Teil der Grundgesamtheit, den wir wirklich untersuchen | die befragten Personen                            | Firmen, für die wir Emissionsdaten vorher und nachher haben |
| <b>Merkmal</b> (Variable) $X$       | die Eigenschaft, die wir messen (Großbuchstabe)            | Alter, Geschlecht, Partei                         | Emissionen in Tonnen                                        |
| <b>Merkmalsausprägung</b> $x$       | der konkrete Wert bei einer Einheit (Kleinbuchstabe)       | 23 Jahre; SPD                                     | 1250 Tonnen                                                 |

Die Grundgesamtheit kann auch **hypothetisch** sein: zum Beispiel „alle Güter, die eine Firma produziert“ oder „alle Felder, auf denen ein Dünger jemals eingesetzt werden könnte“.

#### Deskriptive Statistik (heute)

Wir **beschreiben** die Daten, die wir haben: Tabellen, Grafiken, Kennzahlen. Keine Aussage über andere Einheiten.

#### Induktive Statistik (Tag 3 + 4)

Wir **schließen** von der Stichprobe auf die Grundgesamtheit und geben die **Unsicherheit** an (Schätzer, Konfidenzintervalle, Tests).

#### MERKE

Meistens kennen wir nur eine **Stichprobe**. Die zentrale Aufgabe der (induktiven) Statistik ist: von der Stichprobe auf die **Grundgesamtheit** schließen – und dabei die **Unsicherheit** berücksichtigen.

## Versuchsplanung und Störvariablen

Eine Studie plant man vorher: Ziel festlegen, statistische Methoden auswählen, Datenerhebung planen, verbindliche Regeln festlegen. **Störvariablen** sind Merkmale, die das Ergebnis auch beeinflussen, die uns aber gerade nicht interessieren.

#### BEISPIEL (V01): NEUE LEHRMETHODE

Wir wollen wissen: Lernen Studierende mit einer neuen didaktischen Maßnahme besser? Der Lernerfolg hängt aber auch von **Alter, Vorwissen, Lernverhalten** ab. Das sind Störvariablen. Drei Wege, sie zu kontrollieren:

- **Homogenisierung:** die Grundgesamtheit in Teilgruppen zerlegen, die durch die Störvariablen festgelegt sind (z. B. nur Erstsemester mit gleichem Vorwissen vergleichen).
- **Randomisierung:** Personen **zufällig** in eine Gruppe mit und eine Gruppe ohne Maßnahme einteilen. Dann sind Vorwissen usw. in beiden Gruppen im Mittel gleich.
- **Statistische Modellierung:** die Störvariablen in der Rechnung berücksichtigen (z. B. Regression).

**Kreislauf der Datenanalyse:** Planung → Datenerhebung → Aufbereitung und Prüfung der Daten → Datenanalyse → Interpretation → Publikation von Daten und Code → Wiederverwendung.

## 1.2 Merkmalstypen und Skalenniveaus

Hörtext Teil 1 · 1.2

Diese Frage kommt in fast jeder Klausur (Probeklausur A: Aufgabe 1a und 2a = 5 Punkte; Testat 1: Aufgabe 1). Es sind **leichte Punkte** – wenn man die Regeln genau kennt.

### Frage 1: Diskret oder stetig?

**diskret:** endlich viele oder **abzählbar** unendlich viele Werte. „Abzählbar“ heißt: Man kann die Werte durchnummerieren: 0, 1, 2, 3, ...

Beispiele: Anzahl Likes, Anzahl Mensabesuche, Anzahl Geschwister, Partei, Studienfach, Note, Alter in **ganzen** Jahren

**stetig: überabzählbar** viele Werte. Jede reelle Zahl in einem Intervall ist möglich; zwischen zwei Werten gibt es immer noch weitere.

Beispiele: Körpergröße, Gewicht, Zeit, Liter, Temperatur, Einkommen in Euro, Gewinn einer Firma, BIP

In der Praxis ist es nicht immer klar: Stetige Merkmale misst man mit begrenzter Genauigkeit (Körpergröße in ganzen cm), behandelt sie aber trotzdem als **stetig** („quasi-stetig“). Umgekehrt kann man stetige Merkmale in Klassen einteilen (Altersgruppen) – das nennt man **Kategorisierung**.

### Frage 2: Welches Skalenniveau?

| Skala                         | Was kann man machen?                                             | Beispiele                                                                         | Häufigkeiten | Reihenfolge | Differenzen / Quotienten |
|-------------------------------|------------------------------------------------------------------|-----------------------------------------------------------------------------------|--------------|-------------|--------------------------|
| <b>nominal</b>                | nur Namen / Kategorien, keine Ordnung                            | Partei, Nationalität, Mensastandort, Herkunft (BY/NRW), Blutgruppe, Postleitzahl  | ja           | nein        | nein                     |
| <b>ordinal</b>                | man kann sortieren, aber Abstände sind nicht sinnvoll            | Schulnoten, Zufriedenheit 1–7, Hotelsterne, Rang im Wettkampf, Kleidergröße S/M/L | ja           | ja          | nein                     |
| <b>kardinal</b><br>(metrisch) | echte Zahlen mit sinnvollen Abständen (meist auch Verhältnissen) | Alter, Einkommen, Körpergröße, Punkte 0–100, Anzahl, Liter                        | ja           | ja          | ja                       |

#### ENTSCHEIDUNGSWEG IN 3 FRAGEN

- 1 Sind die Werte nur **Namen**, die man nicht sinnvoll sortieren kann? → **nominal**. (Vorsicht: Auch Zahlen können nur Namen sein – eine Postleitzahl ist nominal! „37073 minus 37085“ hat keine Bedeutung.)
- 2 Kann man sortieren, aber ist der **Abstand** zwischen zwei Stufen nicht klar gleich groß? → **ordinal**.
- 3 Kann man sinnvoll **rechnen** („5 mehr“, „doppelt so viel“)? → **kardinal**. Dann noch: Kann man durchzählen? → diskret. Jede Zahl im Intervall möglich? → stetig.

Zusatzwissen: Kardinale Merkmale mit echtem Nullpunkt (Einkommen, Liter) heißen auch **Verhältnisskala** („doppelt so viel“ ist sinnvoll). Die Musterlösung der Probeklausur schreibt bei „Liter Bier“: „metrisch skaliert (Verhältnisskala)“.

#### ACHTUNG – DIE 4 HÄUFIGSTEN FEHLER

- Eine Skala „von 1 bis 5“ oder „von 1 bis 7“ (Zufriedenheit) ist **ordinal**, nicht kardinal – auch wenn es Zahlen sind!
- Punkte in einem Test (0–100) sind **kardinal**: 80 Punkte sind 20 Punkte mehr als 60.
- Ein 0/1-Merkmal (richtig/falsch, ja/nein) ist **nominal** (binär). Den Mittelwert darf man trotzdem berechnen: er ist der **Anteil** der Einsen.
- „Diskret“ heißt nicht „endlich“: Auch abzählbar unendlich viele Werte (0, 1, 2, ... ohne obere Grenze) sind diskret. (Tutorium 1: Autos an der Autobahn zählen – es gibt keine halben Autos.)

### ÜBUNG MIT LÖSUNG: 10 MERKMALE

| Merkmal                                 | Skala                 | diskret/stetig | Begründung                          |
|-----------------------------------------|-----------------------|----------------|-------------------------------------|
| Alter in ganzen Jahren                  | kardinal              | diskret        | Abstände sinnvoll; nur ganze Zahlen |
| Anzahl Mensabesuche letzte Woche        | kardinal              | diskret        | Zählvariable                        |
| Präferierter Mensastandort              | nominal               | diskret        | nur Namen                           |
| Zufriedenheit 1 bis 7                   | ordinal               | diskret        | Reihenfolge ja, Abstände unklar     |
| Monatseinkommen in Euro                 | kardinal              | stetig         | sehr viele Werte, quasi-stetig      |
| Liter Bier (Probeklausur)               | kardinal (Verhältnis) | stetig         | Messwert                            |
| Herkunft BY / NRW (Probeklausur)        | nominal               | diskret        | zwei Kategorien                     |
| Vorhersage korrekt (0/1) (Probeklausur) | nominal (binär)       | diskret        | nur zwei Kategorien                 |
| Schulnote 1–6                           | ordinal               | diskret        | „1 besser als 2“, Abstände unklar   |
| Laufzeit für 7.5 km in Minuten          | kardinal              | stetig         | Zeit                                |

#### WARUM IST DAS SKALENNIVEAU SO WICHTIG?

Es bestimmt, **welche Rechnungen erlaubt sind**: Bei nominalen Daten nur Häufigkeiten und Modus; bei ordinalen Daten zusätzlich Median und Quantile; bei kardinalen Daten auch Mittelwert, Varianz, Korrelation. Genau das wird in der Klausur gefragt: „Falls ein Parameter nicht sinnvoll angegeben werden kann, begründen Sie kurz.“

### 1.3 Wie zieht man eine Stichprobe?

Hörtext Teil 1 · 1.3

Eine gute Stichprobe ist **repräsentativ**: Sie hat keine systematischen Unterschiede zur Grundgesamtheit. Zwei Probleme können passieren: (1) Die Stichprobe enthält Einheiten, die **nicht** zur Grundgesamtheit gehören. (2) Nicht alle Einheiten der Grundgesamtheit haben eine Chance, in die Stichprobe zu kommen (z. B. Online-Umfrage: Menschen ohne Internet fehlen).

| Verfahren                                    | Wie?                                                                                                                    | Vorteil / Voraussetzung                                                                                                         | Bild                                   |
|----------------------------------------------|-------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------|----------------------------------------|
| <b>Einfache Zufallsstichprobe</b>            | Ziehen ohne Zurücklegen aus der Liste aller Einheiten; jede Einheit und jede mögliche Stichprobe hat die gleiche Chance | nur zufällige, keine systematischen Unterschiede; man braucht eine vollständige Liste                                           | Lostopf mit allen Namen                |
| <b>Geschichtete Stichprobe</b>               | Grundgesamtheit in Gruppen (Schichten) teilen, dann in <b>jeder</b> Schicht zufällig ziehen                             | jede Gruppe ist sicher passend vertreten (oder gezielt überrepräsentiert); Anteile und Gruppenzugehörigkeit müssen bekannt sein | ein Lostopf pro Studiengang            |
| <b>Klumpenstichprobe</b>                     | zufällig ganze Klumpen ziehen (Schulklassen, Straßen, Familien, Orte), darin alle oder viele befragen                   | billig und einfach; innerhalb der Klumpen soll das Merkmal stark variieren, die Klumpen untereinander ähnlich sein              | 3 zufällige Schulklassen komplett      |
| <b>Quotenverfahren</b><br>(bewusste Auswahl) | vorher festgelegte Quoten müssen erfüllt sein                                                                           | Umfragen „repräsentativ für Bevölkerungsgruppen“                                                                                | Interviewer sucht 50 Frauen, 50 Männer |

#### GESCHICHTET ODER KLUMPEN? DER WICHTIGE UNTERSCHIED

**Geschichtet**: Wir ziehen aus **allen** Gruppen, aber in jeder Gruppe nur einige Personen. **Klumpen**: Wir ziehen nur **einige** Gruppen, aber in diesen Gruppen (fast) alle Personen. Im Tutorium war der häufige Fehler: „geschichtet“ zu sagen, obwohl nur Göttinger Schulen (= ein Klumpen) getestet wurden.

#### BEISPIELE AUS TUTORIUM 1 UND TESTAT 1

- Leistungen aller Zehntklässler in Deutschland, getestet an Schulen in Göttingen → **Klumpenstichprobe**.
- Öffentlich-rechtliche Sender: Umfrage, die repräsentativ für die Bevölkerungsgruppen sein soll → **Quotenverfahren** oder **geschichtete Stichprobe**. (Fehler: „repräsentativ“ überlesen und „einfache Zufallsstichprobe“ sagen.)
- Der Anteil jedes Studiengangs in der Stichprobe soll dem Anteil an allen Studierenden entsprechen → **geschichtete Stichprobe / Quotenverfahren**.

#### KONTROLLFRAGEN 1.1 – 1.3 (KURZ)

- Was ist der Unterschied zwischen deskriptiver und induktiver Statistik?
- Richtig oder falsch? „Ein diskretes Merkmal kann nur endlich viele Werte annehmen.“ Korrigiere den Satz.
- Eine Studie teilt Personen per Münzwurf in eine Gruppe mit und eine ohne neues Medikament. Wie heißt diese Methode und warum ist sie gut?

#### Klausurtraining 1.A · Fitnessstudio

12 Punkte

Das Göttinger Fitnessstudio „FitGö“ hat 2400 Mitglieder. Die Leitung möchte das Angebot verbessern und plant eine Befragung. Für jedes befragte Mitglied sollen folgende Merkmale erhoben werden:

- Alter in ganzen Jahren
- Trainingsdauer pro Woche (in Stunden)

3. Tarif (Basic, Premium, Student)

4. Zufriedenheit (sehr unzufrieden, unzufrieden, neutral, zufrieden, sehr zufrieden)

5. Anzahl der Besuche im letzten Monat

6. Postleitzahl des Wohnorts

**(a)** Geben Sie für jedes der sechs Merkmale das Skalenniveau an und ob es diskret oder stetig ist. **(6 P)**

**(b)** Benennen Sie die statistische Einheit und die Grundgesamtheit. **(2 P)**

**(c)** Die Leitung weiß, dass 50 % der Mitglieder den Tarif Basic, 30 % Premium und 20 % Student haben. Jeder Tarif soll in der Stichprobe mit genau diesem Anteil vertreten sein. Welches Stichprobenverfahren ist geeignet? **(1 P)**

**(d)** Ein Mitarbeiter schlägt vor, zufällig 4 der 40 Kurse auszuwählen und alle Teilnehmenden dieser Kurse zu befragen. Wie heißt dieses Verfahren? Nennen Sie einen Vorteil. **(1 P)**

**(e)** Richtig oder falsch? Begründen Sie jeweils kurz. (i) „Die durchschnittliche Postleitzahl ist eine sinnvolle Kennzahl.“ (ii) „Für die Zufriedenheit kann man den Median angeben.“ **(2 P)**

Wir haben Beobachtungen  $x_1, \dots, x_n$  ( $n$  = Stichprobenumfang). Die möglichen verschiedenen Werte heißen  $a_1 < a_2 < \dots < a_J$ .

### FORMEL: HÄUFIGKEITEN

$$h_j = \text{absolute Häufigkeit von } a_j \text{ (Anzahl)}, \quad f_j = \frac{h_j}{n} \text{ (relative Häufigkeit, Anteil)}, \quad \sum_j h_j = n, \quad \sum_j f_j = 1$$

$$H_j = h_1 + \dots + h_j \text{ (kumuliert absolut)}, \quad F_j = \frac{H_j}{n} = f_1 + \dots + f_j \text{ (kumuliert relativ)}$$

### BEISPIEL 1: MENSABESUCHE (IM STIL VON TESTAT 1)

| Besuche $a_j$ | 0     | 1      | 2      | 3    | 4      | $\Sigma$ |
|---------------|-------|--------|--------|------|--------|----------|
| $h_j$         | 3     | 5      | 8      | 6    | 2      | 24       |
| $f_j$         | 0.125 | 0.2083 | 0.3333 | 0.25 | 0.0833 | 1        |
| $H_j$         | 3     | 8      | 16     | 22   | 24     |          |

Stichprobengröße:  $n = 3 + 5 + 8 + 6 + 2 = 24$ . (Lage- und Streuungsmaße dazu in 1.5 und 1.6.)

### BEISPIEL 2 (TUTORIUM 2): SEMESTERZAHLEN VON N = 23 STUDIERENDEN

| Semester $a_j$ | 2    | 3    | 4     | 5     | 6     | 7     | $\Sigma$ |
|----------------|------|------|-------|-------|-------|-------|----------|
| $h_j$          | 1    | 7    | 5     | 5     | 1     | 4     | 23       |
| $f_j$          | 1/23 | 7/23 | 5/23  | 5/23  | 1/23  | 4/23  | 1        |
| $F_j$          | 1/23 | 8/23 | 13/23 | 18/23 | 19/23 | 23/23 |          |

(i) „mehr als 3“:  $1 - F(3) = 1 - \frac{8}{23} = \frac{15}{23}$ . (ii) „mindestens 3“:  $1 - F(2) = 1 - \frac{1}{23} = \frac{22}{23}$ . (iii) „kleiner als 4“:  $F(3) = \frac{8}{23}$ . (iv) „nicht größer als 5“:  $F(5) = \frac{18}{23}$ .

### ACHTUNG: WÖRTER GENAU ÜBERSETZEN (DISKRETE DATEN!)

| Wort                            | Zeichen  | Rechnung mit F             |
|---------------------------------|----------|----------------------------|
| höchstens 3, nicht größer als 3 | $\leq 3$ | $F(3)$                     |
| weniger als 3, kleiner als 3    | $< 3$    | $F(2)$ (bei ganzen Zahlen) |
| mindestens 3                    | $\geq 3$ | $1 - F(2)$                 |
| mehr als 3, größer als 3        | $> 3$    | $1 - F(3)$                 |



### Klassen bilden: Säulendiagramm oder Histogramm?

Stetige Daten haben (fast) alle verschiedenen Werte. Deshalb bilden wir **Klassen** (Intervalle) wie  $[c_0, c_1]$ ,  $(c_1, c_2]$ ,  $\dots$ . Eine eckige Klammer  $[$  bedeutet „Grenze gehört dazu“, eine runde Klammer  $($  bedeutet „gehört nicht dazu“.

- **Säulendiagramm:** Die **Höhe** der Säule ist die Häufigkeit. Bei ungleich breiten Klassen sieht das **falsch** aus (breite Klassen wirken zu groß) – und das Bild hängt stark von der Klassenwahl ab.
- **Histogramm:** Die **Fläche** der Säule ist die relative Häufigkeit. Die Gesamtfläche ist **1**. In dieser Vorlesung der **Goldstandard** für stetige Merkmale.

### FORMEL: HÖHE IM HISTOGRAMM (DICHTE)

$$\text{Höhe}_j = \frac{f_j}{\text{Klassenbreite}_j} = \frac{h_j}{n \cdot (c_j - c_{j-1})} \Rightarrow \text{Fläche}_j = \text{Höhe}_j \cdot \text{Breite}_j = f_j$$




Gleiche Daten (Zimmergrößen, R-Skript V02), links Säulendiagramm, rechts Histogramm. Die breite Klasse (20,100] sieht links riesig aus – rechts ist sie richtig flach.

### BEISPIEL 3: EIN HISTOGRAMM SCHRITT FÜR SCHRITT BAUEN

20 Personen warten beim Arzt (Minuten, schon sortiert): 2, 3, 3, 4, 5, 5, 6, 7, 8, 9, 10, 11, 12, 14, 15, 18, 22, 25, 31, 38. Klassen: [0, 5), [5, 10), [10, 20), [20, 40).

| Klasse       | Werte darin            | $h_j$ | $f_j = h_j/20$ | Breite | Höhe = $f_j/\text{Breite}$ | Kontrolle Fläche     |
|--------------|------------------------|-------|----------------|--------|----------------------------|----------------------|
| [0, 5)       | 2, 3, 3, 4             | 4     | 0.2            | 5      | 0.04                       | $0.04 \cdot 5 = 0.2$ |
| [5, 10)      | 5, 5, 6, 7, 8, 9       | 6     | 0.3            | 5      | 0.06                       | 0.3                  |
| [10, 20)     | 10, 11, 12, 14, 15, 18 | 6     | 0.3            | 10     | 0.03                       | 0.3                  |
| [20, 40)     | 22, 25, 31, 38         | 4     | 0.2            | 20     | 0.01                       | 0.2                  |
| <b>Summe</b> |                        | 20    | 1              |        |                            | 1 ✓                  |



**Frage:** Welcher Anteil wartet zwischen 15 und 30 Minuten? Wir nehmen an, dass die Werte **innerhalb einer Klasse gleichmäßig verteilt** sind. Dann ist der Anteil = Fläche unter dem Histogramm von 15 bis 30:

$$\underbrace{(20 - 15) \cdot 0.03}_{\text{Teil von } [10,20)} + \underbrace{(30 - 20) \cdot 0.01}_{\text{Teil von } [20,40)} = 0.15 + 0.10 = 0.25$$

(In den echten Daten sind es 4 von 20 = 0.2 – das Histogramm liefert eine **Schätzung**.)

#### BEISPIEL 4 (TUTORIUM 2, AUFGABE 1): ANTEIL AUS EINER GRAFIK MIT ABSOLUTEN HÄUFIGKEITEN

20 Personen, Klassenbreite 5 cm; in (165,170] liegen 3 Personen, in (170,175] liegen 5 Personen. Gesucht: Anteil in (167, 172].

$$\underbrace{\frac{3}{5} \cdot \frac{3}{20}}_{(167,170]: 3 \text{ von } 5 \text{ cm}} + \underbrace{\frac{2}{5} \cdot \frac{5}{20}}_{(170,172]: 2 \text{ von } 5 \text{ cm}} = 0.09 + 0.10 = 0.19$$

Höhe im normierten Histogramm für (170,175]:  $\frac{5}{20 \cdot 5} = 0.05$ . Behauptet jemand „In einer Grundgesamtheit von 20 000 Personen sind genau 7 000 zwischen 175 und 180 cm“ (weil 7 von 20), ist das zu sicher: Eine Stichprobe von 20 Personen bildet die Grundgesamtheit nicht perfekt ab – das ist nur eine Schätzung.

#### MODALKLASSE – EINE FALLE AUS TESTAT 1

Die **Modalklasse** ist die Klasse mit der **größten Häufigkeit**. Ist sie „immer die Klasse mit der höchsten Säule im Histogramm“? **Nicht im Allgemeinen!** Bei ungleich breiten Klassen zeigt die Höhe die Dichte, nicht die Anzahl. Im Beispiel 3 haben [5,10) und [10,20) beide 6 Werte, aber [10,20) ist nur halb so hoch. Nur bei **gleich breiten** Klassen ist die höchste Säule die Modalklasse.

**Typen von Verteilungen** (am Histogramm erkennen): **unimodal** (ein Gipfel) oder **bimodal/multimodal** (zwei oder mehr Gipfel); **symmetrisch**, **rechtsschief** oder **linksschief** (siehe 1.5). Die Anzahl der Klassen wählt man mit Bedacht: zu wenige Klassen = zu grob, zu viele = zu zackig (Bias-Varianz-Abwägung, Tag 4).

#### Die empirische Verteilungsfunktion

##### FORMEL

$$\hat{F}(x) = \frac{\text{Anzahl der } x_i \leq x}{n} \quad (\text{Anteil der Werte, die höchstens } x \text{ sind})$$


Sie ist eine **Treppenfunktion**: Sie beginnt bei 0, springt an jedem beobachteten Wert  $a_j$  um  $f_j$  nach oben und endet bei 1. Sie ist nie fallend.

#### KLAUSURAUFGABE (PROBEKLAUSUR A, AUFGABE 2B, 6 PUNKTE!): BIERKONSUM

Daten (Liter): 8.5, 8.5, 4.0, 4.0, 12.0, 12.0, 8.5, 15.7, 4.0, 8.5. Also  $n = 10$ .

| Schritt             | 4.0 | 8.5 | 12.0 | 15.7 |
|---------------------|-----|-----|------|------|
| 1. Zählen $h_j$     | 3   | 4   | 2    | 1    |
| 2. Anteil $f_j$     | 0.3 | 0.4 | 0.2  | 0.1  |
| 3. Aufsummieren $F$ | 0.3 | 0.7 | 0.9  | 1.0  |

$$\hat{F}(x) = \begin{cases} 0 & x < 4 \\ 0.3 & 4 \leq x < 8.5 \\ 0.7 & 8.5 \leq x < 12 \\ 0.9 & 12 \leq x < 15.7 \\ 1 & x \geq 15.7 \end{cases}$$



**Ablesen:**  $\hat{F}(10) = 0.7$  heißt: 70 % der Gäste haben höchstens 10 Liter getrunken. Anteil „mehr als 10 Liter“ =  $1 - 0.7 = 0.3$ .

#### KLAUSUR-TIPP: SO BEKOMMST DU ALLE 6 PUNKTE BEIM ZEICHNEN

- Achsen beschriften (x-Achse mit Einheit, y-Achse  $\hat{F}(x)$ ) und die Sprungstellen und Höhen an die Achsen schreiben.
- Waagerechte Stufen, **keine** senkrechten Linien verbinden.
- Voller Punkt ● am linken Ende jeder Stufe (Wert gehört dazu), offener Kreis ○ am rechten Ende.
- Links bei 0 anfangen, rechts bei 1 enden, Pfeil nach rechts (geht bis unendlich weiter).
- Zusätzlich die Funktion mit Fallunterscheidung (wie oben) aufschreiben – dann ist die Antwort eindeutig.

#### Klausurtraining 1.B · Pendelzeiten

12 Punkte

Eine Umfrage unter 50 Studierenden der Universität Göttingen ergab folgende Pendelzeiten zur Uni (in Minuten):

| Klasse       | [0, 10) | [10, 20) | [20, 30) | [30, 60) | [60, 90] |
|--------------|---------|----------|----------|----------|----------|
| Anzahl $h_j$ | 8       | 15       | 12       | 10       | 5        |

- (a) Berechnen Sie für jede Klasse die relative Häufigkeit und die Höhe der Säule in einem (normierten) Histogramm. (4 P)
- (b) Schätzen Sie mit dem Histogramm den Anteil der Studierenden, die zwischen 25 und 45 Minuten pendeln. Welche Annahme treffen Sie? (3 P)
- (c) Wie viele Studierende pendeln mindestens 30 Minuten? (1 P)
- (d) Bestimmen Sie den Mittelwert für die klassierten Daten. (2 P)
- (e) Welche Klasse ist die Modalklasse? Warum sollte man hier kein Säulendiagramm mit absoluten Häufigkeiten zeichnen? (2 P)

Zehn Studierende wurden gefragt, wie viele Tassen Kaffee sie gestern getrunken haben:

```
> sort(Kaffee)
[1] 0 1 1 1 2 2 2 3 3 4 6
```

- (a) Geben Sie Skalenniveau an und ob das Merkmal diskret oder stetig ist. (1 P)

- (b) Stellen Sie die empirische Verteilungsfunktion  $\hat{F}(x)$  als Funktion mit Fallunterscheidung auf und skizzieren Sie sie. (4 P)

- (c) Lesen Sie ab:  $\hat{F}(2.5)$ ; den Anteil mit mehr als 2 Tassen; den Anteil mit mindestens 1 Tasse. (2 P)

- (d) Berechnen Sie Modus, Median und arithmetisches Mittel. (2 P)

**FORMEL: DIE DREI LAGEMASSE**

**Arithmetisches Mittel** (Durchschnitt): alle Werte addieren und durch  $n$  teilen – oder mit Häufigkeitstabelle: jeden Wert mal seinen Anteil.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{1}{n} \sum_{j=1}^J a_j h_j = \sum_{j=1}^J a_j f_j$$

**Median:** die Mitte der **sortierten** Werte  $x_{(1)} \leq \dots \leq x_{(n)}$  (die Klammer im Index heißt „sortiert“).

$$x_{med} = \begin{cases} x_{(\frac{n+1}{2})} & n \text{ ungerade} \\ \in [x_{(n/2)}, x_{(n/2+1)}], \text{ meist } \frac{x_{(n/2)} + x_{(n/2+1)}}{2} & n \text{ gerade} \end{cases}$$

**Modus**  $x_{mod}$ : der Wert, der am häufigsten vorkommt.

**MEDIAN SCHRITT FÜR SCHRITT**

**n ungerade:** 7, 2, 9, 4, 5 → sortieren: 2, 4, **5**, 7, 9.  $n = 5$ ,  $\frac{n+1}{2} = 3 \rightarrow x_{med} = x_{(3)} = 5$ .

**n gerade:** 7, 2, 9, 4, 5, 10 → sortieren: 2, 4, **5, 7**, 9, 10.  $n = 6$ ,  $\frac{n}{2} = 3 \rightarrow$  zwischen  $x_{(3)} = 5$  und  $x_{(4)} = 7 \rightarrow x_{med} = \frac{5+7}{2} = 6$ .

Achtung:  $x_{(3)}$  (sortiert) ist nicht  $x_3$  (dritter Wert in der Urliste)! Immer zuerst sortieren.

| Lagemaß    | ab welcher Skala?                  | Eigenschaft                                                          |
|------------|------------------------------------|----------------------------------------------------------------------|
| Modus      | jede Skala (auch nominal)          | bei stetigen Daten oft nicht sinnvoll (alle Werte verschieden)       |
| Median     | ab ordinal                         | <b>robust</b> gegen Ausreißer; mind. 50 % links und rechts           |
| Mittelwert | kardinal (auch 0/1-Daten → Anteil) | empfindlich gegen Ausreißer; Schwerpunkt: $\sum (x_i - \bar{x}) = 0$ |

**BEISPIEL: MENSABESUCHE (TABELLE AUS 1.4, N = 24)**

**Modus:** 2 (kommt 8-mal vor, am häufigsten).

**Median:**  $n = 24$  gerade → Mittel aus  $x_{(12)}$  und  $x_{(13)}$ . Mit den kumulierten Häufigkeiten: Plätze 1–3 sind 0, Plätze 4–8 sind 1, Plätze 9–16 sind 2. Also  $x_{(12)} = x_{(13)} = 2 \rightarrow x_{med} = 2$ .

**Mittelwert:**  $\bar{x} = \frac{0 \cdot 3 + 1 \cdot 5 + 2 \cdot 8 + 3 \cdot 6 + 4 \cdot 2}{24} = \frac{47}{24} = 1.958$ .

**BEISPIEL: AUSREISSER (TUTORIUM 2)**

Datensatz I: 5, 6, 7, 8, **14** →  $\bar{x} = 8$ ,  $x_{med} = 7$ . Datensatz II: 5, 6, 7, 8, 9 →  $\bar{x} = 7$ ,  $x_{med} = 7$ .

Nur ein Wert ist anders. Der Mittelwert ändert sich, der Median nicht. Der Median hängt nur von der **Reihenfolge** ab, nicht davon, **wie groß** der größte Wert ist. „**Der Median ist robuster gegenüber Extremwerten als das arithmetische Mittel.**“ (Genau dieser Satz war die Musterantwort in Probeklausur B!)

**BEISPIEL: SEMESTERZAHLEN (N = 23)**

$\bar{x} = \frac{1}{23} (2 \cdot 1 + 3 \cdot 7 + 4 \cdot 5 + 5 \cdot 5 + 6 \cdot 1 + 7 \cdot 4) = \frac{102}{23} = 4.435$ .


Median:  $n = 23$  ungerade →  $x_{(12)}$ . Kumuliert: Platz 1 ist 2, Plätze 2–8 sind 3, Plätze 9–13 sind 4 →  $x_{(12)} = 4$ .

Modus: 3 (7-mal).

**BEISPIEL: 0/1-DATEN**

10 Personen, 1 = „hat bestanden“: 1, 0, 1, 1, 1, 0, 1, 1, 0, 1.  $\bar{x} = \frac{7}{10} = 0.7 =$  **Bestehensquote 70 %**. So kann der Mittelwert auch bei einem nominalen 0/1-Merkmal sinnvoll sein.

## Lagemaße und Form der Verteilung



### MERKE

**rechtsschief** (= linkssteil, langer Schwanz nach rechts):  $\bar{x} > x_{med} > x_{mod}$ . Typisch für Einkommen, Wartezeiten, Wohnungsgrößen.

**symmetrisch** (unimodal):  $\bar{x} \approx x_{med} \approx x_{mod}$ .

**linksschief** (= rechtssteil, langer Schwanz nach links):  $\bar{x} < x_{med} < x_{mod}$ .

Eselsbrücke: Der Mittelwert wird vom langen Schwanz „weggezogen“. Im Wartezeit-Beispiel:  $\bar{x} = 12.4 > x_{med} = 9.5 \rightarrow$  rechtsschief.

## Rechenregeln

- Lineare Transformation**  $y_i = a + b x_i$ :  $\bar{y} = a + b \bar{x}$ . Beispiel: °C in °F:  $F = 32 + 1.8 C$ . Mittel 20 °C  $\rightarrow 32 + 1.8 \cdot 20 = 68$  °F.
- Monotone Transformation**  $y_i = g(x_i)$  (z. B. log):  $y_{med} = g(x_{med})$ . Für den Mittelwert gilt das **nicht**:  $\overline{\log x} \neq \log \bar{x}$ .
- Mittelwert aus Gruppen** (Schichten):  $\bar{x} = \frac{1}{n} \sum_j n_j \bar{x}_j$  – ein gewichteter Durchschnitt. Beispiel: Kurs A hat 20 Personen mit Mittel 60 Punkte, Kurs B hat 30 Personen mit Mittel 70  $\rightarrow \bar{x} = \frac{20 \cdot 60 + 30 \cdot 70}{50} = 66$  (**nicht** 65!).

## Klassierte Daten

Wenn wir nur die Klassen kennen, nehmen wir die **Klassenmitte**  $m_j = \frac{c_{j-1} + c_j}{2}$  als Stellvertreter für alle Werte der Klasse:

### FORMEL: KLASSIERTE DATEN

$$\bar{x}_K = \sum_j f_j m_j \quad s_K^2 = \sum_j f_j (m_j - \bar{x}_K)^2 \quad \text{Modalklasse} = \text{Klasse mit dem größten } f_j$$

### KLAUSURAUFGABE (PROBEKLAUSUR A, 2C, 4 PUNKTE)

Bier in Klassen  $K_1 = [0, 10)$  und  $K_2 = [10, 20]$ . In  $K_1$ : 4, 4, 4, 8.5, 8.5, 8.5, 8.5  $\rightarrow n(K_1) = 7$ . In  $K_2$ : 12, 12, 15.7  $\rightarrow n(K_2) = 3$ . Mitten:  $m_1 = 5$ ,  $m_2 = 15$ .

$$\bar{x}_K = \frac{1}{10} (7 \cdot 5 + 3 \cdot 15) = \frac{80}{10} = 8$$

(Der echte Mittelwert ist 8.57 – die Klassenmitte ist nur eine Näherung.)

## Klausurtraining 1.D · Gehälter

12 Punkte

Ein kleines Göttinger Start-up hat 9 Mitarbeitende. Ihre Monatsgehälter (in Tausend Euro) sind:

```
> sort(Gehalt)
[1] 2.8 3.1 3.1 3.4 3.6 3.9 4.2 4.5 15.0
```

Hinweis:  $\sum x_i = 43.6$ ,  $\sum x_i^2 = 329.68$ .

**(a)** Berechnen Sie arithmetisches Mittel, Median und Modus. **(3 P)**

**(b)** Welches Lagemaß beschreibt das „typische“ Gehalt besser? Begründen Sie in einem Satz. **(1 P)**

**(c)** Ist die Verteilung rechtsschief, symmetrisch oder linksschief? Begründen Sie mit den Lagemaßen. **(2 P)**

**(d)** Alle Gehälter steigen um 5 %. Wie lauten der neue Mittelwert und der neue Median? (Ohne alles neu zu rechnen!) **(2 P)**

**(e)** Eine zweite Filiale hat 6 Mitarbeitende mit einem Durchschnittsgehalt von 3.5 Tsd. €. Berechnen Sie das Durchschnittsgehalt aller 15 Mitarbeitenden. **(2 P)**

**(f)** Berechnen Sie die empirische Varianz und die Standardabweichung der 9 Gehälter. **(2 P)**

## Quantile

Das  $\alpha$ -Quantil  $x_\alpha$  teilt die sortierten Daten: mindestens  $\alpha \cdot 100\%$  der Werte sind kleiner oder gleich  $x_\alpha$ , und mindestens  $(1 - \alpha) \cdot 100\%$  sind größer oder gleich. Wichtige Quantile: Median  $x_{0.5}$ ; **Quartile**  $x_{0.25}, x_{0.5}, x_{0.75}$ ; Dezile  $x_{0.1}, \dots, x_{0.9}$ . Voraussetzung: mindestens ordinal.

### FORMEL: QUANTIL (DEFINITION AUS DER VORLESUNG)

$$x_\alpha = \begin{cases} x_{(\lfloor n\alpha \rfloor + 1)} & n\alpha \text{ keine ganze Zahl (aufrunden!)} \\ \in [x_{(n\alpha)}, x_{(n\alpha+1)}] & n\alpha \text{ ganze Zahl (meist Mittelwert der beiden)} \end{cases}$$

### BEISPIEL A: N = 7 WERTE: 2, 4, 4, 5, 5, 7, 8 (SCHON SORTIERT)

$x_{0.25}$ :  $7 \cdot 0.25 = 1.75 \rightarrow$  keine ganze Zahl  $\rightarrow$  aufrunden auf 2  $\rightarrow x_{(2)} = 4$ .

$x_{0.5}$ :  $7 \cdot 0.5 = 3.5 \rightarrow$  aufrunden auf 4  $\rightarrow x_{(4)} = 5$  (passt zur Median-Formel).

$x_{0.75}$ :  $7 \cdot 0.75 = 5.25 \rightarrow$  aufrunden auf 6  $\rightarrow x_{(6)} = 7$ . IQR =  $7 - 4 = 3$ .

### BEISPIEL B: MIETSPIEGEL (V02), N = 26 SORTIERTE MIETEN

$x_{0.25}$ :  $0.25 \cdot 26 = 6.5 \rightarrow$  keine ganze Zahl  $\rightarrow$  aufrunden auf 7  $\rightarrow x_{(7)} = 170.04$ .

$x_{0.5}$ :  $0.5 \cdot 26 = 13 \rightarrow$  ganze Zahl  $\rightarrow$  zwischen  $x_{(13)} = 243.44$  und  $x_{(14)} = 255.75 \rightarrow$  Mittelwert 249.6.

$x_{0.75}$ :  $0.75 \cdot 26 = 19.5 \rightarrow$  aufrunden auf 20  $\rightarrow x_{(20)} = 311.87$ .

### ACHTUNG: R RECHNET QUANTILE ETWAS ANDERS

`quantile(x, 0.25)` benutzt standardmäßig eine andere Methode (Interpolation). Die Ergebnisse können leicht von der Handrechnung abweichen. In Teil A rechnest du immer mit der Vorlesungsdefinition oben. In Teil B nimmst du einfach den R-Befehl.

## Streuungsmaße

Zwei Datensätze können die gleiche Mitte haben und trotzdem ganz verschieden sein:  $\{5, 5, 5\}$  und  $\{0, 5, 10\}$  haben beide Mittelwert 5. Die **Streuung** misst, wie weit die Werte auseinander liegen.

### FORMEL: VARIANZ UND STANDARDABWEICHUNG

$$s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \stackrel{\text{Verschiebungssatz}}{=} \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2 = \overline{x^2} - \bar{x}^2$$

$$s_*^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{n}{n-1} s^2 \quad (\text{unverzerrte / korrigierte Varianz})$$

$$s = \sqrt{s^2} \quad \text{IQR} = x_{0.75} - x_{0.25} \quad \text{Spannweite} = x_{\max} - x_{\min}$$

### VARIANZ AUF ZWEI WEGEN: 2, 4, 4, 5, 5, 7, 8 (N = 7)

$$\bar{x} = \frac{35}{7} = 5.$$

#### Weg 1: Definition

#### Weg 2: Verschiebungssatz (schneller!)

$$\sum x_i^2 = 4 + 16 + 16 + 25 + 25 + 49 + 64 = 199$$

$$s^2 = \frac{199}{7} - 5^2 = 28.4286 - 25 = 3.429$$

$$\text{Standardabweichung: } s = \sqrt{3.4286} = 1.852.$$

$$\text{Unverzerrt: } s_*^2 = \frac{24}{6} = 4 \text{ (das gibt R mit } \text{var}() \text{).}$$

| $x_i$    | $x_i - \bar{x}$ | $(x_i - \bar{x})^2$ |
|----------|-----------------|---------------------|
| 2        | -3              | 9                   |
| 4        | -1              | 1                   |
| 4        | -1              | 1                   |
| 5        | 0               | 0                   |
| 5        | 0               | 0                   |
| 7        | 2               | 4                   |
| 8        | 3               | 9                   |
| $\Sigma$ | 0 ✓             | 24                  |

$$s^2 = \frac{24}{7} = 3.429$$

Kontrolle: Die Summe der Abweichungen  $\sum (x_i - \bar{x})$  ist immer 0.

#### ACHTUNG: 1/N ODER 1/(N-1)?

- „Empirische Varianz“ per Hand in Teil A: meistens  $s^2$  mit  $\frac{1}{n}$  (so rechnen die Musterlösungen der Tutorien und Probeklausur).
- **R** rechnet mit `var()` und `sd()` **immer** die unverzerrte Version  $s_*^2$  mit  $\frac{1}{n-1}$ !
- Umrechnen:  $s^2 = \frac{n-1}{n} s_*^2$  bzw.  $n s^2 = (n-1) s_*^2$ .
- Steht in der Aufgabe „unverzerrter Schätzer“, „Stichprobenvarianz  $s_*^2$ “ oder „korrigiert“:  $\frac{1}{n-1}$ .
- Mit Häufigkeitstabelle:  $s^2 = \sum_j a_j^2 f_j - \bar{x}^2$ .

**Vorteil der Standardabweichung:** Sie hat die **gleiche Einheit** wie das Merkmal (Euro statt Euro<sup>2</sup>). (Testat 1, Aufgabe 5.3)

#### KLAUSURAUFGABE (PROBEKLAUSUR A, 5A): SCHIESSFEHLER 3, 2, 5, 1, 3, 4

$$\bar{x} = \frac{18}{6} = 3, \quad \overline{x^2} = \frac{9+4+25+1+9+16}{6} = \frac{64}{6} = 10.6667, \quad s_x^2 = 10.6667 - 3^2 = 1.667$$

#### MIT HÄUFIGKEITSTABELLE: MENSABESUCHE (N = 24)

$$\overline{x^2} = \frac{0 \cdot 3 + 1 \cdot 5 + 4 \cdot 8 + 9 \cdot 6 + 16 \cdot 2}{24} = \frac{123}{24} = 5.125 \quad s^2 = 5.125 - 1.9583^2 = 1.290$$

**Lineare Transformation**  $y_i = a + b x_i$ :  $s_y^2 = b^2 s_x^2$ ,  $s_y = |b| s_x$ ,  $IQR_y = |b| IQR_x$ . Die Verschiebung  $a$  ändert die Streuung **nicht** (alle Werte rücken gleich weit). Tutorium 2: Datensatz III = 2 · Datensatz II → Varianz  $2^2 = 4$ -mal so groß: 8 statt 2.

### Der Boxplot

Der Boxplot ist eine **Fünf-Punkte-Zusammenfassung**: Minimum,  $x_{0.25}$ , Median,  $x_{0.75}$ , Maximum. Die **Box** geht vom unteren zum oberen Quartil – in ihr liegen die mittleren 50 % der Daten. Der Strich in der Box ist der Median.

#### FORMEL: AUSREISSERREGEL UND WHISKER

$$\text{untere Grenze} = x_{0.25} - 1.5 \cdot IQR \quad \text{obere Grenze} = x_{0.75} + 1.5 \cdot IQR$$


Werte außerhalb der Grenzen sind **Ausreißer** (einzelne Punkte). Der Whisker endet beim extremsten Wert, der **noch innerhalb** der Grenzen liegt.

### BEISPIEL (TUTORIUM 2, AUFGABE 7): 20 SEMESTERZAHLEN

1,1,1,1,2,2,3,3,3,4,4,5,6,6,6,6,7,9,13,14.  $n\alpha = 20 \cdot 0.25 = 5$  (ganz)  $\rightarrow x_{0.25} \in [x_{(5)}, x_{(6)}] = [2, 2] = 2$ ;  $20 \cdot 0.75 = 15 \rightarrow x_{0.75} \in [x_{(15)}, x_{(16)}] = [6, 6] = 6$ ; IQR = 4.

Obere Grenze:  $6 + 1.5 \cdot 4 = 12 \rightarrow$  oberer Whisker = größter Wert  $\leq 12 = 9$ ; 13 und 14 sind Ausreißer.

Untere Grenze:  $2 - 6 = -4 \rightarrow$  unterer Whisker = Minimum = 1.



### WAS MAN AUS EINEM BOXPLOT ABLESEN KANN (TESTAT 1, AUFGABE 6)

- Median, Quartile, Min/Max, Ausreißer direkt ablesen.
- **Schiefe:** Liegt der Median nah am unteren Rand der Box und ist der obere Whisker lang  $\rightarrow$  rechtsschief.
- **Vergleich von Gruppen** (mehrere Boxplots nebeneinander): Unterschiede in Lage und Streuung sehen. Aber: Ein Unterschied der Mediane beweist **keine Ursache** (keine Kausalität ohne Experiment/Kontrolle der Störvariablen).
- Sind **keine Punkte** eingezeichnet, gibt es **keine Ausreißer**. Ein langer Whisker ist kein Ausreißer!

### Klausurtraining 1.E · Lieferzeiten

13 Punkte

Ein Online-Shop notiert für 12 Bestellungen die Lieferzeit in Tagen:

```
> sort(Lieferzeit)
[1] 2 3 3 4 4 4 5 5 6 7 9 14
```

Hinweis:  $\sum x_i = 66$ ,  $\sum x_i^2 = 482$ .

(a) Berechnen Sie arithmetisches Mittel und Median. (2 P)

(b) Bestimmen Sie das untere und das obere Quartil nach der Definition aus der Vorlesung sowie den Interquartilsabstand. (3 P)

(c) Berechnen Sie die empirische Varianz  $s^2$ , die unverzerrte Varianz  $s_*^2$  und die Standardabweichung  $s$ . Geben Sie Ihren Lösungsweg an. (3 P)

(d) Gibt es Ausreißer nach der 1.5-IQR-Regel? Bis wohin reichen die Whisker? Skizzieren Sie den Boxplot. (3 P)

- (e)** Die Lieferzeiten werden in Stunden umgerechnet (1 Tag = 24 Stunden). Wie ändern sich Mittelwert, Varianz und Standardabweichung? **(2 P)**

## 1.7 Zwei Merkmale: Kontingenztafel und $\chi^2$ -Koeffizient

Hörtext Teil 3 · 1.7

Jetzt schauen wir zwei Merkmale  $X$  und  $Y$  **zusammen** an, gemessen an denselben Einheiten. Die **gemeinsame Verteilung** steht in einer **Kontingenztafel**. Die Summen am Rand heißen **Randverteilungen** (die Verteilung eines Merkmals allein).

### MERKE

Aus der gemeinsamen Verteilung kann man die Randverteilungen immer ausrechnen. Umgekehrt geht das **nur**, wenn die Merkmale **unabhängig** sind. Die gemeinsame Verteilung enthält also mehr Information – nämlich über den **Zusammenhang**.

### BEISPIEL (TUTORIUM 3): 1000 VERKEHRSUNFÄLLE – TABELLE AUS EINEM TEXT BAUEN

Text: „Von 1000 Unfällen waren 380 tödlich (T). Bei 160 tödlichen Unfällen war der Fahrer alkoholisiert (A). Insgesamt gab es 720 Unfälle ohne Alkohol ( $\bar{A}$ ).“

|                           | A (Alkohol) | $\bar{A}$ (kein Alkohol) | $\Sigma$ |
|---------------------------|-------------|--------------------------|----------|
| T (tödlich)               | 160         | 220                      | 380      |
| $\bar{T}$ (nicht tödlich) | 120         | 500                      | 620      |
| $\Sigma$                  | 280         | 720                      | 1000     |

Fett = aus dem Text. Rest durch Differenzen:  $380 - 160 = 220$ ;  $1000 - 380 = 620$ ;  $1000 - 720 = 280$ ;  $280 - 160 = 120$ ;  $720 - 220 = 500$ .

Anteil nicht tödlicher Unfälle:  $620/1000 = 0.62$ . Anteil „tödlich **und** ohne Alkohol“:  $220/1000 = 0.22$ .

### FORMEL: RAND UND BEDINGTE VERTEILUNG

$$h_{j\bullet} = \sum_k h_{jk} \text{ (Zeilensumme)}, \quad h_{\bullet k} = \sum_j h_{jk} \text{ (Spaltensumme)}, \quad f_{jk} = \frac{h_{jk}}{n}$$

$$\text{bedingt: } f(Y = b_k | X = a_j) = \frac{h_{jk}}{h_{j\bullet}} \text{ (Zeile durch Zeilensumme; jede Zeile summiert sich dann zu 1)}$$

Im Beispiel (Spalte durch Spaltensumme):  $f(T | A) = \frac{160}{280} = 0.571$  und  $f(T | \bar{A}) = \frac{220}{720} = 0.306$ . Mit Alkohol ist mehr als jeder zweite Unfall tödlich, ohne Alkohol knapp jeder dritte. Die bedingten Verteilungen sind **verschieden** → es gibt einen **Zusammenhang**.

### BEISPIEL AUS DER VORLESUNG (V03): AUSBILDUNG UND DAUER DER ARBEITSLOSIGKEIT (BEDINGTE VERTEILUNGEN, ZEILENWEISE)

| Ausbildung           | kurz (1–6 M.) | mittel (7–12 M.) | lang (>12 M.) | $\Sigma$ |
|----------------------|---------------|------------------|---------------|----------|
| keine Ausbildung     | 0.699         | 0.154            | 0.147         | 1        |
| Lehre                | 0.730         | 0.184            | 0.086         | 1        |
| Fachspez. Ausbildung | 0.714         | 0.197            | 0.089         | 1        |
| Hochschulabschluss   | 0.800         | 0.114            | 0.086         | 1        |
| Randverteilung       | 0.73          | 0.17             | 0.10          | 1        |

Interpretation: Mit höherer Ausbildung wird Kurzarbeitslosigkeit wahrscheinlicher und Langzeitarbeitslosigkeit unwahrscheinlicher. Wären alle Zeilen gleich (= Randverteilung), gäbe es keinen Zusammenhang.

**FORMEL:  $\chi^2$ -KOEFFIZIENT**

$$\tilde{h}_{jk} = \frac{h_{j\bullet} \cdot h_{\bullet k}}{n} \quad (\text{erwartete Anzahl bei Unabhängigkeit}) \quad \chi^2 = \sum_j \sum_k \frac{(h_{jk} - \tilde{h}_{jk})^2}{\tilde{h}_{jk}}$$

$\chi^2 \approx 0 \rightarrow$  (fast) unabhängig.  $\chi^2$  groß  $\rightarrow$  starker Zusammenhang.  $\chi^2$  ist nie negativ.

**RECHNUNG FÜR DIE UNFÄLLE – SCHRITT FÜR SCHRITT**

**Schritt 1 – erwartete Tabelle:** Zeilensumme mal Spaltensumme durch n.

| $\tilde{h}$ | A                                    | $\bar{A}$                            | $\Sigma$ |
|-------------|--------------------------------------|--------------------------------------|----------|
| T           | $\frac{380 \cdot 280}{1000} = 106.4$ | $\frac{380 \cdot 720}{1000} = 273.6$ | 380      |
| $\bar{T}$   | $\frac{620 \cdot 280}{1000} = 173.6$ | $\frac{620 \cdot 720}{1000} = 446.4$ | 620      |
| $\Sigma$    | 280                                  | 720                                  | 1000     |

**Schritt 2 – vergleichen:** beobachtet minus erwartet:  $160 - 106.4 = 53.6$ ,  $220 - 273.6 = -53.6$ ,  $120 - 173.6 = -53.6$ ,  $500 - 446.4 = 53.6$ . (Bei  $2 \times 2$ -Tafeln sind alle Differenzen gleich groß.)

**Schritt 3 – summieren:**

$$\chi^2 = \frac{53.6^2}{106.4} + \frac{53.6^2}{273.6} + \frac{53.6^2}{173.6} + \frac{53.6^2}{446.4} = 27.0015 + 10.5006 + 16.5493 + 6.4359 = 60.487$$

Ein großer Wert  $\rightarrow$  deutlicher Zusammenhang zwischen Alkohol und tödlichem Ausgang. Am Tag 4 machen wir daraus einen **Test** ( $\chi^2$ -Unabhängigkeitstest).

**Klausurtraining 1.F · Rauchen und Sport****12 Punkte**

In einer Befragung von 200 Studierenden gaben 60 Personen an, zu rauchen (R). Von den Rauchenden treiben 15 regelmäßig Sport (S). Insgesamt treiben 110 der Befragten keinen regelmäßigen Sport.

**(a)** Erstellen Sie die vollständige Kontingenztafel der absoluten Häufigkeiten (inkl. Randhäufigkeiten). **(3 P)**

**(b)** Berechnen Sie den Anteil der Sporttreibenden unter den Rauchenden und unter den Nichtrauchenden. **(2 P)**

**(c)** Deutet Ihr Ergebnis aus (b) auf einen Zusammenhang hin? Begründen Sie. **(1 P)**

**(d)** Berechnen Sie die bei Unabhängigkeit erwarteten Häufigkeiten und den  $\chi^2$ -Koeffizienten. **(4 P)**

**(e)** Eine Zeitung schreibt: „Rauchen macht unsportlich.“ Nehmen Sie in 1–2 Sätzen Stellung. **(2 P)**


Für zwei **metrische** Merkmale zeichnen wir ein **Streudiagramm** (Punktwolke): jede Einheit ist ein Punkt  $(x_i, y_i)$ . Daran sieht man: gleich gerichtet (steigend) oder gegengerichtet (fallend)? Linear oder nicht linear?

**Idee der Kovarianz:** Wir legen ein Kreuz durch den Mittelpunkt  $(\bar{x}, \bar{y})$ . Ein Punkt rechts oben oder links unten ist **konkordant**:  $(x_i - \bar{x})(y_i - \bar{y}) > 0$ . Ein Punkt links oben oder rechts unten ist **diskordant**: das Produkt ist negativ. Die Kovarianz ist der Durchschnitt dieser Produkte.

### FORMEL: KOVARIANZ UND KORRELATION (BRAVAIS-PEARSON)

$$s_{xy} = \text{Cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{n} \sum_{i=1}^n x_i y_i - \bar{x} \bar{y} = \overline{xy} - \bar{x} \bar{y}$$

$$r_{xy} = \rho_{xy} = \frac{s_{xy}}{s_x s_y} = \frac{s_{xy}}{\sqrt{s_x^2 s_y^2}} \in [-1, 1]$$



| $ r $         | 0 bis < 0.3 | 0.3 bis < 0.7 | 0.7 bis 1 |
|---------------|-------------|---------------|-----------|
| <b>Stärke</b> | schwach     | mittel        | stark     |

### RECHENBEISPIEL MIT TABELLE (TUTORIUM 3, AUFGABE 3): GEWICHT UND GRÖSSE VON 5 MÄNNERN

| i        | Gewicht $x_i$ (kg) | Größe $y_i$ (cm) | $x_i^2$ | $y_i^2$ | $x_i y_i$ |
|----------|--------------------|------------------|---------|---------|-----------|
| 1        | 93                 | 198              | 8649    | 39204   | 18414     |
| 2        | 72                 | 160              | 5184    | 25600   | 11520     |
| 3        | 83                 | 167              | 6889    | 27889   | 13861     |
| 4        | 104                | 199              | 10816   | 39601   | 20696     |
| 5        | 76                 | 182              | 5776    | 33124   | 13832     |
| $\Sigma$ | 428                | 906              | 37314   | 165418  | 78323     |

- Mittelwerte:  $\bar{x} = \frac{428}{5} = 85.6$ ,  $\bar{y} = \frac{906}{5} = 181.2$ .
- Varianzen:  $s_x^2 = \frac{37314}{5} - 85.6^2 = 7462.8 - 7327.36 = 135.44$ ;  $s_y^2 = \frac{165418}{5} - 181.2^2 = 33083.6 - 32833.44 = 250.16$ .
- Kovarianz:  $s_{xy} = \frac{78323}{5} - 85.6 \cdot 181.2 = 15664.6 - 15510.72 = 153.88$ .
- Korrelation:  $r = \frac{153.88}{\sqrt{135.44 \cdot 250.16}} = \frac{153.88}{184.07} = 0.836$ .
- Interpretation: starker positiver linearer Zusammenhang: Schwerere Männer sind tendenziell größer.

#### MERKE – DIE WICHTIGSTEN EIGENSCHAFTEN

- Die Kovarianz hängt von den **Einheiten** ab (Größe in cm: 153.88 kg·cm; in m: 1.5388 kg·m) → ihr Wert ist schwer zu deuten. Nur das **Vorzeichen** sagt etwas.
- Die Korrelation hat **keine Einheit** und liegt immer zwischen -1 und 1.  $|r| = 1$ : alle Punkte auf einer Geraden.
- $r$  misst nur **lineare** Zusammenhänge.  $r \approx 0$  heißt **nicht** „kein Zusammenhang“: bei  $y = x^2$  (Parabel) kann  $r \approx 0$  sein.
- Unabhängig  $\Rightarrow$  unkorreliert. Aber: unkorreliert  $\nRightarrow$  unabhängig.
- $\text{Cov}(X, X) = \text{Var}(X)$ ; wenn  $X = Y$ , dann  $r = 1$ .

#### KOVARIANZ AUS EINER HÄUFIGKEITSTABELLE (TUTORIUM 3, AUFGABE 5): AUSFÄLLE ZWEIER MASCHINEN AN 100 TAGEN

| X \ Y    | 0    | 1    | 2    | $\Sigma$ |
|----------|------|------|------|----------|
| 0        | 0.30 | 0.14 | 0.02 | 0.46     |
| 1        | 0.18 | 0.10 | 0.02 | 0.30     |
| 2        | 0.12 | 0.06 | 0.06 | 0.24     |
| $\Sigma$ | 0.60 | 0.30 | 0.10 | 1        |

$$\bar{x} = 0 \cdot 0.46 + 1 \cdot 0.30 + 2 \cdot 0.24 = 0.78, \bar{y} = 0.5, s_x^2 = (1 \cdot 0.30 + 4 \cdot 0.24) - 0.78^2 = 0.652, s_y^2 = (0.30 + 0.40) - 0.25 = 0.45.$$

$$\overline{xy} = \sum a_j b_k f_{jk} = 1 \cdot 1 \cdot 0.10 + 1 \cdot 2 \cdot 0.02 + 2 \cdot 1 \cdot 0.06 + 2 \cdot 2 \cdot 0.06 = 0.50 \text{ (Felder mit einer 0 fallen weg).}$$

$$s_{xy} = 0.50 - 0.78 \cdot 0.5 = 0.11; r = \frac{0.11}{\sqrt{0.6516} \cdot \sqrt{0.45}} = 0.203 \rightarrow \text{schwacher positiver linearer Zusammenhang.}$$

#### KLAUSURAUFGABE (PROBEKLAUSUR A, 5B-D, 9 PUNKTE)

Gegeben:  $s_y^2 = 10$ ,  $s_x^2 = 1.6$ ,  $\bar{y} = 22$ ,  $\bar{x} = 3$ ,  $\sum x_\nu y_\nu = 399$ ,  $n = 6$ .

$$s_{xy} = \frac{399}{6} - 3 \cdot 22 = 66.5 - 66 = 0.5 \quad r_{xy} = \frac{0.5}{\sqrt{1.6} \cdot \sqrt{10}} = \frac{0.5}{4} = 0.125$$

**Interpretation** (2 Punkte): Der Korrelationskoeffizient ist die normierte Kovarianz und misst die Stärke des **linearen** Zusammenhangs; er liegt zwischen -1 und 1.  $r = 0.125$  ist positiv, aber klein: **schwacher positiver linearer Zusammenhang** zwischen Schießfehlern und Laufzeit. Mehr Fehler gehen tendenziell mit etwas längerer Laufzeit einher.

**5c – Kausalität?** Nein. Statistische Analysen liefern keinen Nachweis einer **Kausalität**. Der Zusammenhang kann durch dritte Variablen (z. B. Müdigkeit, Wetter) oder Zufall entstehen.

**5d:** Skizze für  $r = 0$ : Punktwolke ohne Richtung (rundliche Wolke) – Achsen beschriften (x: Schießfehler, y: Laufzeit)!

#### Rangkorrelation nach Spearman

Pearson braucht metrische Daten. Für **ordinale** Daten (oder für monotone, nicht lineare Zusammenhänge) ersetzt man die Werte durch ihre **Ränge** (kleinster Wert = Rang 1) und berechnet Pearson mit den Rängen. Bei gleichen Werten (**Bindungen**) bekommen alle den **Durchschnittsrang**.

#### SPEARMAN SCHRITT FÜR SCHRITT: LERNSTUNDEN UND PUNKTE VON 5 STUDIERENDEN

| Person   | Stunden x | Rang x | Punkte y | Rang y | rk(x)·rk(y) |
|----------|-----------|--------|----------|--------|-------------|
| 1        | 2         | 1      | 40       | 1      | 1           |
| 2        | 5         | 3      | 55       | 2.5    | 7.5         |
| 3        | 3         | 2      | 55       | 2.5    | 5           |
| 4        | 8         | 5      | 90       | 5      | 25          |
| 5        | 6         | 4      | 60       | 4      | 16          |
| <b>Σ</b> |           | 15     |          | 15     | 54.5        |

Die zwei Werte 55 teilen sich Platz 2 und 3 → beide bekommen  $\frac{2+3}{2} = 2.5$ . Mittlerer Rang =  $\frac{n+1}{2} = 3$ .  
 $\sum rk_x^2 = 1 + 4 + 9 + 16 + 25 = 55$ ;  $\sum rk_y^2 = 1 + 6.25 + 6.25 + 25 + 16 = 54.5$ ;  $n \cdot 3^2 = 45$ .

$$r_{Sp} = \frac{\sum rk_x rk_y - n \bar{rk}^2}{\sqrt{(\sum rk_x^2 - n \bar{rk}^2)(\sum rk_y^2 - n \bar{rk}^2)}} = \frac{54.5 - 45}{\sqrt{(55 - 45)(54.5 - 45)}} = \frac{9.5}{9.747} = 0.975$$

(Pearson mit den Originalwerten wäre 0.912. Spearman ist höher, weil der Zusammenhang fast perfekt **monoton**, aber nicht perfekt linear ist.) In R: `cor(x, y, method = "spearman")`.

### Korrelation ist keine Kausalität

- **Kausalität:** Eine Änderung von  $X$  **verursacht** eine Änderung von  $Y$ . Nachweis braucht: gezielte Manipulation von  $X$  (Experiment) und Kontrolle aller anderen Einflüsse (z. B. Randomisierung).
- **Scheinkorrelation:** Margarineverbrauch und Scheidungsrate in Maine haben  $r = 0.99$  – aber Margarine verursacht keine Scheidungen. Mögliche dritte Variable: die wirtschaftliche Lage; oder reiner Zufall. Ein Margarineverbot wäre sinnlos.
- **Ökologischer Fehlschluss:** Man schließt von Gruppen-Daten (Stadtbezirke) auf einzelne Personen. EHEC 2011: Bezirke mit vielen Grünen-Wählern hatten mehr Kranke – die Ursache war aber Sprossengemüse, nicht die Partei.
- **Cholera in London** (19. Jh.): Der Vergleich der Wasserversorger zeigte den Zusammenhang zwischen Wasser und Cholera-Toten – die Geburtsstunde der Epidemiologie.

#### KONTROLLFRAGEN 1.7 – 1.8 (KURZ)

1. Richtig oder falsch (Testat 2)? (a) Wenn  $r \neq 0$ , sind  $X$  und  $Y$  abhängig. (b) Wenn  $Y = -X^2$ , kann  $r \approx 0$  sein. (c) Wenn  $X = Y$ , gilt  $r = 1$ . (d) Wenn  $r \neq 0$ , gibt es einen kausalen Zusammenhang. (e)  $\text{Cov} \geq 0.8$  bedeutet immer starken Zusammenhang.
2. Berechne mit dem Verschiebungssatz (Testat 2):  $n = 50$ ,  $\sum x = 2019$ ,  $\sum y = 3733$ ,  $\sum x^2 = 87611$ ,  $\sum y^2 = 301695$ ,  $\sum xy = 160064$ . Gesucht:  $s_{xy}$  und  $r$ .

### Klausurtraining 1.G · Werbung und Umsatz

14 Punkte

Eine Bäckereikette untersucht in 6 Filialen die Werbeausgaben  $X$  (in Tsd. €) und den Umsatz  $Y$  (in Tsd. €) eines Monats:

| Filiale v | 1  | 2  | 3  | 4  | 5  | 6  |
|-----------|----|----|----|----|----|----|
| $x_v$     | 2  | 4  | 3  | 6  | 5  | 1  |
| $y_v$     | 30 | 45 | 38 | 60 | 48 | 25 |

Hinweis:  $\sum x = 21$ ,  $\sum y = 246$ ,  $\sum x^2 = 91$ ,  $\sum y^2 = 10898$ ,  $\sum xy = 979$ .

- (a) Zeichnen Sie ein beschriftetes Streudiagramm.

(2 P)

**(b)** Berechnen Sie die empirische Kovarianz. Geben Sie Ihren Lösungsweg an. **(2 P)**

**(c)** Berechnen Sie den Korrelationskoeffizienten nach Bravais-Pearson und interpretieren Sie ihn. **(4 P)**

**(d)** Bestimmen Sie den Rangkorrelationskoeffizienten nach Spearman, ohne lange zu rechnen. Begründen Sie. **(2 P)**

**(e)** Der Umsatz wird nun in Euro statt in Tsd. € angegeben. Wie ändern sich Kovarianz und Korrelation? **(2 P)**

**(f)** Die Geschäftsführung folgert: „Mehr Werbung verursacht mehr Umsatz.“ Beurteilen Sie diese Aussage und nennen Sie eine mögliche Drittvariable. **(2 P)**

## 1.9 R-Kurs von null an

Hörtext Teil 3 · 1.9

Klausurteil B (45 Punkte, 60 Minuten) schreibst du am Computer mit **RStudio**. Hier lernst du R **Befehl für Befehl**. Bei jedem Befehl siehst du: den Code (dunkler Kasten), die echte Ausgabe von R (heller Kasten, beginnt oft mit `[1]`) und eine Erklärung. Bei schwierigen Stellen gibt es eine **türkische Erklärung**.

### SO LERNST DU R RICHTIG

Öffne RStudio und tippe **jeden** Befehl selbst ab (nicht kopieren!). Die Übungsdatei `Taverne.csv` liegt im Ordner `Lernpaket/uebungsdaten`. Lege sie in deinen Ordner *Dokumente*. R lernt man nur mit den Fingern.

### TÜRKÇE AÇIKLAMA

R'ı sadece okuyarak öğrenemezsin. Her komutu RStudio'da **kendin yaz** ve Enter'a bas. Çıkan sonucu buradaki açık renkli kutuyla karşılaştı. Hata alırsan panik yapma: hata mesajını oku, genelde bir virgöl, tırnak işareti ya da büyük/küçük harf hatasıdır. Sınav B kısmının 45 puanı tamamen buna bağlı.

### 1.9.1 RStudio kennenlernen

| Fenster                                    | Was ist das?                                                                                                             | Türkçe                               |
|--------------------------------------------|--------------------------------------------------------------------------------------------------------------------------|--------------------------------------|
| <b>Skript</b> (oben links)                 | Hier schreibst du deine Befehle. Datei → New File → R Script. Speichern mit Strg + S (Datei endet auf <code>.R</code> ). | Kodları yazdığın defter. Kaydedilir. |
| <b>Konsole</b> (unten links)               | Hier führt R die Befehle aus und zeigt das Ergebnis. Zeichen <code>&gt;</code> = R wartet.                               | Sonuçların çıktığı yer.              |
| <b>Environment</b> (oben rechts)           | Liste aller Objekte, die du gespeichert hast (z. B. <code>d</code> , <code>x</code> ).                                   | Kaydettiğin nesnelerin listesi.      |
| <b>Plots / Files / Help</b> (unten rechts) | Grafiken, Dateien im Ordner, Hilfe zu Befehlen.                                                                          | Grafikler, dosyalar, yardım.         |

**Ausführen:** Cursor in die Zeile setzen und **Strg + Enter** drücken (Mac: Cmd + Enter). Mehrere Zeilen markieren und Strg + Enter führt alle aus. **Kommentare** beginnen mit `#` – R ignoriert alles dahinter. Schreibe Kommentare, damit die Korrektoren deinen Weg verstehen.

### 1.9.2 R als Taschenrechner und Objekte

```
3 + 4 * 2      # Punkt vor Strich
(3 + 4) * 2
2^3           # Potenz: 2 hoch 3
sqrt(16)      # Wurzel
log(10); exp(1) # natürlicher Logarithmus, e hoch 1
choose(10, 2)  # Binomialkoeffizient "10 über 2"
```

```
[1] 11
[1] 14
[1] 8
[1] 4
[1] 2.302585
[1] 2.718282
[1] 45
```

Das `[1]` bedeutet nur: „Hier beginnt das erste Element der Ausgabe“. Es ist kein Teil des Ergebnisses.

```
a <- 5          # Objekt a bekommt den Wert 5
b <- a * 2
b
```

```
[1] 10
```

- `<-` ist der **Zuweisungspfeil** („bekommt“): kleiner-Zeichen und Minus. Man kann auch `=` schreiben, aber `<-` ist üblich.
- Bei einer Zuweisung zeigt R **nichts** an. Um den Inhalt zu sehen, tippt man den Namen (`b`) oder setzt Klammern um die ganze Zeile: `(b <- a * 2)`.
- Namen: Buchstaben, Zahlen, Punkt, Unterstrich; nicht mit einer Zahl beginnen. **Groß-/Kleinschreibung zählt**: `d` und `D` sind zwei verschiedene Objekte.
- Dezimalzahlen immer mit **Punkt**: `2.5`. Das Komma trennt in R die Argumente eines Befehls!

#### TÜRKÇE AÇIKLAMA

`<-` işareti “içine koy / ata” demektir: `a <- 5` → “a adlı kutuya 5’i koy”. Ondalık sayılarda **nokta** kullan (2.5); virgöl R’da komutun parçalarını (argümanları) ayırır. Büyük-küçük harf farklıdır: `Mean` çalışmaz, `mean` çalışır.

### 1.9.3 Vektoren – die wichtigste Datenstruktur

Ein **Vektor** ist eine Reihe von Werten des gleichen Typs, z. B. alle Beobachtungen eines Merkmals.

```
x <- c(3, 2, 5, 1, 3, 4)  # c() = "combine": Werte zusammenfügen
x
length(x)                # Anzahl der Werte = n
```

```
[1] 3 2 5 1 3 4
[1] 6
```

**Auf Elemente zugreifen** mit eckigen Klammern `[ ]` (Position zählt ab 1):

```
x[1]      # erstes Element
x[c(2, 4)] # zweites und viertes Element
x[-1]     # alle AUSSER dem ersten
```

```
[1] 3
[1] 2 1
[1] 2 5 1 3 4
```

**Rechnen mit Vektoren**: R rechnet automatisch mit **jedem** Element („vektorisiert“) – du brauchst keine Schleife.

```
x * 2
x + 10
sum(x)
sort(x)      # aufsteigend sortieren
```

```
[1] 6 4 10 2 6 8
[1] 13 12 15 11 13 14
[1] 18
[1] 1 2 3 3 4 5
```

**Bedingungen** (logische Vektoren): Ein Vergleich gibt für jedes Element `TRUE` (wahr) oder `FALSE` (falsch).

```
x > 2
x[x > 2]      # nur die Werte, bei denen die Bedingung TRUE ist
sum(x > 2)     # wie viele sind größer als 2? (TRUE zählt als 1)
mean(x > 2)    # welcher ANTEIL ist größer als 2?
```

```
[1] TRUE FALSE TRUE FALSE TRUE TRUE
[1] 3 5 3 4
[1] 4
[1] 0.6666667
```

Vergleichszeichen: `>`, `>=` (größer gleich), `<`, `<=`, `==` (gleich – **zwei** Gleichheitszeichen!), `!=` (ungleich). Verknüpfen: `&` (und), `|` (oder).

### TÜRKÇE AÇIKLAMA

`x > 2` her eleman için “doğru mu yanlış mı?” sorusunu sorar. R’da TRUE = 1, FALSE = 0 sayılır. Bu yüzden `sum(x > 2)` kaç tane olduğunu, `mean(x > 2)` ise **oranını** verir. “Eşittir” için **iki** eşittir işareti yazılır: `==`. Tek `=` atama yapar, karşılaştırma yapmaz!

### Folgen erzeugen:

```
1:6           # ganze Zahlen von 1 bis 6
seq(0, 20, by = 5) # von 0 bis 20 in 5er-Schritten
rep(1/6, 3)    # den Wert 1/6 dreimal wiederholen
```

```
[1] 1 2 3 4 5 6
[1]  0  5 10 15 20
[1] 0.1666667 0.1666667 0.1666667
```

### 1.9.4 Datentypen: typeof, class, factor

In beiden R-Probeklausuren gab es 2–4 Punkte für die Frage: „Welchen Objekttyp hat die Variable?“

```
typeof(x)           # x = c(3, 2, 5, 1, 3, 4)
typeof(1:6)
typeof(c("Wolf", "Troll"))
typeof(x > 2)
```

```
[1] "double"
[1] "integer"
[1] "character"
[1] "logical"
```

| Typ       | Bedeutung                                                                | Beispiel                           | Türkçe                   |
|-----------|--------------------------------------------------------------------------|------------------------------------|--------------------------|
| double    | Kommazahl (Oberbegriff: <b>numeric</b> )                                 | Lungenvolumen 2.35, Kampfzeit 12.5 | ondalıkli sayı           |
| integer   | ganze Zahl (auch <b>numeric</b> )                                        | Anzahl Münzen 18                   | tam sayı                 |
| character | Text (in Anführungszeichen)                                              | "Bergtal"                          | metin                    |
| logical   | TRUE / FALSE                                                             | <code>x &gt; 2</code>              | mantıksal (doğru/yanlış) |
| factor    | Kategorien mit festen Stufen (levels); mit <code>class()</code> erkennen | Ergebnis von <code>cut()</code>    | kategorik değişken       |

```
f <- factor(c("Wolf", "Troll", "Wolf"))
f
class(f)
levels(f)           # die möglichen Kategorien (alphabetisch sortiert)
```

```
[1] Wolf  Troll Wolf
Levels: Troll Wolf
[1] "factor"
[1] "Troll" "Wolf"
```

`typeof()` zeigt den **Speichertyp**, `class()` die **Klasse**. Bei einem Faktor sagt `typeof` „integer“ (intern Nummern), `class` aber „factor“. In der Klausur ist beides als Befehl okay (Musterlösung: „`typeof()`“, alternativ `class()`, `str(d)`“).

## 1.9.5 Einen Datensatz einlesen

Die Übungsdatei `Taverne.csv` sieht als Text so aus (erste Zeilen):

```
Taverne;Tal;Monster;Muenzen;Kampfzeit
T01;Flusstal;Ghul;18;12.5
T02;Bergtal;Troll;25;45.0
T03;Flusstal;Wolf;12;3.2
```

Man sieht: Die erste Zeile enthält die **Namen** (header), die Spalten sind mit **Semikolon** getrennt (sep), Dezimalzeichen ist der **Punkt** (dec).

```
setwd(path.expand("~/"))      # Arbeitsordner = Dokumente (genau so in der Klausur!)
getwd()                       # zeigt den aktuellen Arbeitsordner
d <- read.csv("Taverne.csv", header = TRUE, sep = ";", dec = ".")
head(d)                       # die ersten 6 Zeilen
```

|   | Taverne | Tal      | Monster | Muenzen | Kampfzeit |
|---|---------|----------|---------|---------|-----------|
| 1 | T01     | Flusstal | Ghul    | 18      | 12.5      |
| 2 | T02     | Bergtal  | Troll   | 25      | 45.0      |
| 3 | T03     | Flusstal | Wolf    | 12      | 3.2       |
| 4 | T04     | Walddal  | Greif   | 30      | 75.5      |
| 5 | T05     | Bergtal  | Ghul    | 22      | 8.0       |
| 6 | T06     | Walddal  | Wolf    | 15      | 4.5       |

| Teil                               | Bedeutung                                                                           | Türkçe                                 |
|------------------------------------|-------------------------------------------------------------------------------------|----------------------------------------|
| <code>setwd(...)</code>            | „set working directory“: In diesem Ordner sucht R Dateien und speichert PDFs.       | Çalışma klasörünü ayarla.              |
| <code>path.expand("~/")</code>     | „~“ ist der Benutzerordner; im Prüfungsraum ist das <i>Dokumente</i> .              | Kullanıcı klasörü (sınavda Dokumente). |
| <code>d &lt;- read.csv(...)</code> | Datei lesen und als <b>Data Frame</b> (Tabelle) im Objekt <code>d</code> speichern. | Dosyayı oku, tabloyu d'ye kaydet.      |
| <code>"Taverne.csv"</code>         | Dateiname in Anführungszeichen, genau so geschrieben.                               | Dosya adı, tırnak içinde.              |
| <code>header = TRUE</code>         | Die erste Zeile enthält die Spaltennamen.                                           | İlk satır sütun isimleri.              |
| <code>sep = ";"</code>             | Trennzeichen zwischen den Spalten (oft „," oder ";“).                               | Sütunları ayıran işaret.               |
| <code>dec = "."</code>             | Dezimalzeichen in der Datei („." oder ",“).                                         | Ondalık işareti.                       |

**Die Struktur ansehen** – der wichtigste Befehl nach dem Einlesen:

```
str(d)
```

```
'data.frame':  12 obs. of  5 variables:
 $ Taverne   : chr  "T01" "T02" "T03" "T04" ...
 $ Tal       : chr  "Flusstal" "Bergtal" "Flusstal" "Walddal" ...
 $ Monster   : chr  "Ghul" "Troll" "Wolf" "Greif" ...
 $ Muenzen   : int   18 25 12 30 22 15 27 33 20 10 ...
 $ Kampfzeit : num   12.5 45 3.2 75.5 8 4.5 50 90 15 2.5 ...
```

Lies so: 12 Beobachtungen (Zeilen), 5 Variablen (Spalten). `chr` = character, `int` = integer, `num` = numeric/double. **Prüfe hier immer, ob das Einlesen geklappt hat!** Wenn alles in einer einzigen Spalte steht, war `sep` falsch. Wenn Zahlen als `chr` erscheinen, war oft `dec` falsch.

```
names(d)      # Spaltennamen
dim(d)        # Zeilen, Spalten
d$Muenzen     # eine Spalte mit $ auswählen -> Vektor
```

```
[1] "Taverne" "Tal" "Monster" "Muenzen" "Kampfzeit"
[1] 12 5
[1] 18 25 12 30 22 15 27 33 20 10 24 29
```

**Zeilen und Spalten auswählen** mit `d[Zeile, Spalte]`. Leer lassen = „alle“:

```
d[2, ] # Zeile 2, alle Spalten
d[1:3, c("Tal", "Muenzen")] # Zeilen 1-3, zwei Spalten
```

```
Taverne Tal Monster Muenzen Kampfzeit
2 T02 Bergtal Troll 25 45
Tal Muenzen
1 Flusstal 18
2 Bergtal 25
3 Flusstal 12
```

```
typeof(d$Tal)
typeof(d$Muenzen)
typeof(d$Kampfzeit)
```

```
[1] "character"
[1] "integer"
[1] "double"
```

### TÜRKÇE AÇIKLAMA

Data frame = Excel tablosu gibi bir tablo. Her sütun bir değişken, her satır bir gözlem. `d$Muenzen` → “d tablosundaki Muenzen sütunu”. `d[2, ]` → “2. satır, bütün sütunlar” (virgülden önce satır, sonra sütun). Veriyi okuduktan hemen sonra `str(d)` yaz: veri doğru okunduysa sayılar `int / num`, metinler `chr` görünür. Her şey tek sütundaysa `sep` yanlıştır.

## 1.9.6 Kennzahlen berechnen

```
mean(d$Muenzen) # arithmetisches Mittel
median(d$Muenzen) # Median
var(d$Muenzen) # Varianz -> mit 1/(n-1) !
sd(d$Muenzen) # Standardabweichung -> mit 1/(n-1) !
```

```
[1] 22.08333
[1] 23
[1] 53.17424
[1] 7.292067
```

### ACHTUNG: VAR() UND SD() SIND DIE UNVERZERRTEN VERSIONEN

R teilt durch  $n - 1$ . Das ist genau der „unverzerrte Schätzer für die Standardabweichung  $s_*$ “ aus der Probeklausur B. Brauchst du die Varianz mit  $\frac{1}{n}$ , rechnest du um:

```
n <- length(d$Muenzen)
var(d$Muenzen) * (n - 1) / n # Varianz mit 1/n
```

```
[1] 48.74306
```

```
round(mean(d$Muenzen), 3)      # IMMER runden, wenn eine Zahl gefragt ist
round(sd(d$Muenzen), 3)
range(d$Muenzen)              # Minimum und Maximum (Wertebereich)
quantile(d$Muenzen, c(0.25, 0.5, 0.75))
IQR(d$Muenzen)
summary(d$Muenzen)
```

```
[1] 22.083
[1] 7.292
[1] 10 33
 25%   50%   75%
17.25 23.00 27.50
[1] 10.25
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 10.00  17.25   23.00   22.08  27.50   33.00
```

`round(wert, 3)` : erstes Argument = was gerundet wird, zweites = Anzahl Nachkommastellen. Man kann Befehle **verschachteln**: R rechnet von innen nach außen – erst `mean`, dann `round`. (Die Quantile von R sind interpoliert und können von der Handrechnung abweichen – in Teil B ist der R-Wert richtig.)

**Häufigkeiten** für kategoriale Variablen:

```
table(d$Monster)              # absolute Häufigkeiten
prop.table(table(d$Monster))   # relative Häufigkeiten (Anteile)
which(table(d$Monster) == max(table(d$Monster))) # Modus
```

```
Ghul Greif Troll Wolf
 3     2     4     3

      Ghul      Greif      Troll      Wolf
0.2500000 0.1666667 0.3333333 0.2500000

Troll
 3
```

Beim Modus liest du den **Namen** (Troll) – die 3 darunter ist nur die Position in der Tabelle, nicht die Anzahl!

**Nach Gruppen rechnen und filtern:**

```
tapply(d$Muenzen, d$Tal, mean) # Mittelwert von Muenzen für jedes Tal
subset(d, Tal == "Bergtal")    # nur die Zeilen aus dem Bergtal
d[d$Muenzen > 25, ]            # nur Zeilen mit mehr als 25 Münzen
mean(d$Muenzen > 25)           # Anteil mit mehr als 25 Münzen
```

```
Bergtal Flusstal Walddtal
 26.00   16.75   23.50
Taverne   Tal Monster Muenzen Kampfzeit
2    T02 Bergtal  Troll    25      45
5    T05 Bergtal  Ghul    22      8
8    T08 Bergtal  Greif    33     90
11   T11 Bergtal  Troll    24     38
Taverne   Tal Monster Muenzen Kampfzeit
4    T04 Walddtal  Greif    30    75.5
7    T07 Flusstal  Troll    27    50.0
8    T08 Bergtal  Greif    33    90.0
12   T12 Walddtal  Troll    29    62.0
[1] 0.3333333
```

## TÜRKÇE AÇIKLAMA

`tapply(A, B, mean)` → "A değişkeninin ortalamasını, B'nin her grubu için ayrı ayrı hesapla". `subset(d, Tal == "Bergtal")` → "sadece Bergtal satırlarını al". `d[d$Muenzen > 25, ]` aynı mantık: köşeli parantezin içinde, virgülden önce bir koşul yazarsan sadece koşulu sağlayan satırlar gelir.

## Fehlende Werte (NA):

```
x <- c(3, 2, 5, NA, 4)
mean(x)
mean(x, na.rm = TRUE)      # na.rm = "NA remove": fehlende Werte weglassen
```


```
[1] NA
[1] 3.5
```

## 1.9.7 Grafiken zeichnen und als PDF speichern

In der Klausur musst du Grafiken als PDF-Datei speichern und hochladen (z. B. 7–8 Punkte für ein Histogramm!). Das geht in **drei Schritten**:

```
pdf("Histogramm.pdf")           # 1. PDF-Datei öffnen
hist(d$Muenzen,                 # 2. Grafik zeichnen
     breaks = c(10, 20, 30, 40), # Klassengrenzen
     right = FALSE,             # Intervalle [a, b)
     freq = FALSE,              # Dichte statt Anzahl -> normiert
     main = "Sitz 12, Matr.Nr. 12345678, Aufgabenteil d)",
     xlab = "Muenzen",
     ylab = "Dichte")
dev.off()                       # 3. PDF-Datei schließen (WICHTIG!)
```

Sitz 12, Matr.Nr. 12345678, Aufgabenteil d)



So sieht die gespeicherte Grafik aus.

| Argument                      | Bedeutung                                                                 |
|-------------------------------|---------------------------------------------------------------------------|
| <code>breaks = c(...)</code>  | Klassengrenzen                                                            |
| <code>right = TRUE</code>     | $(a, b]$ – rechts geschlossen (Standard)                                  |
| <code>right = FALSE</code>    | $[a, b)$ – links geschlossen                                              |
| <code>freq = FALSE</code>     | normiert: $y = \text{Dichte}$ , Fläche 1 (= $\text{prob} = \text{TRUE}$ ) |
| <code>freq = TRUE</code>      | $y = \text{absolute Anzahl}$ (Standard)                                   |
| <code>main</code>             | Titel (Aufgabenteil, Matr.-Nr., Sitz!)                                    |
| <code>xlab, ylab</code>       | Beschriftung der Achsen                                                   |
| <code>ylim = c(0, 0.1)</code> | Bereich der y-Achse                                                       |

Die Zahlen hinter dem Histogramm bekommst du mit `plot = FALSE`:

```
h <- hist(d$Muenzen, breaks = c(10, 20, 30, 40), right = FALSE, plot = FALSE)
h$counts      # Anzahl pro Klasse
h$density     # Höhe pro Klasse = Anteil / Breite
```

```
[1] 4 6 2
[1] 0.03333333 0.05000000 0.01666667
```

Kontrolle: 4 von 12 Werten in  $[10, 20)$  → Anteil 0.3333, Breite 10 → Höhe 0.0333. ✓

## TÜRKÇE AÇIKLAMA



Grafiği PDF olarak kaydetmek üç adımdır: **(1)** `pdf("isim.pdf")` ile dosyayı aç, **(2)** grafiği çiz, **(3)** `dev.off()` ile dosyayı kapat. `dev.off()` unutulursa PDF boş kalır ve puan gider! Başlıkta (`main`) sınavda mutlaka **alt görev harfi, matrikül numarası ve oturduğun yer numarası** olmalı. `freq = FALSE` histogramı "normalleştirir": y ekseninde yoğunluk olur, toplam alan 1'dir.

### Weitere Grafiken:

```
plot(d$Kampfzeit, d$Muenzen, pch = 16,                # Streudiagramm: erst x, dann y
     xlab = "Kampfzeit (min)", ylab = "Muenzen", main = "Streudiagramm")
boxplot(Muenzen ~ Tal, data = d,                        # Boxplot je Gruppe
        main = "Muenzen je Tal", xlab = "Tal", ylab = "Muenzen")
boxplot(d$Kampfzeit, plot = FALSE)$stats              # Zahlen des Boxplots
```

```
[,1]
[1,] 2.50
[2,] 6.25
[3,] 26.50
[4,] 56.00
[5,] 90.00
```

Die fünf Zahlen sind: unterer Whisker, unteres Quartil, Median, oberes Quartil, oberer Whisker. `pch = 16` macht gefüllte Punkte.



**Alternative zu `pdf()/dev.off()`:** Grafik im Plots-Fenster zeichnen und über *Export* → *Save as PDF* speichern. Mit `pdf()` ist es aber sicherer und steht im Skript.

## 1.9.8 Klassen bilden, Kontingenztafeln, Korrelation

Mit `cut()` teilt man eine metrische Variable in Klassen. Das Ergebnis ist ein **factor**.

```
d$Kampfzeit.3 <- cut(d$Kampfzeit, breaks = c(0, 5, 60, Inf), right = FALSE)
d$Kampfzeit.3
table(d$Kampfzeit.3)
```

```
[1] [5,60) [5,60) [0,5) [60,Inf) [5,60) [0,5) [5,60) [60,Inf)
[9] [5,60) [0,5) [5,60) [60,Inf)
Levels: [0,5) [5,60) [60,Inf)

[0,5) [5,60) [60,Inf)
3      6      3
```

- `d$Kampfzeit.3 <- ...` legt eine **neue Spalte** im Data Frame an.
- `Inf` = unendlich (für „60 Minuten oder mehr“).

- `right = FALSE`:  $[0,5)$  = „weniger als 5 Minuten“,  $[5,60)$  = „5 bis weniger als 60“. Für „bis zu 10“, „mehr als 10 bis 20“ brauchst du `right = TRUE`:  $(0,10]$ ,  $(10,20]$ .
- Eigene Namen für die Klassen mit `labels`:

```
d$Muenzen.3 <- cut(d$Muenzen, breaks = c(0, 15, 25, Inf),
                  labels = c("wenig", "mittel", "viel"))
table(d$Muenzen.3)
```

```
wenig mittel  viel
      3      5      4
```

**Kontingenztafel** und bedingte Anteile:

```
table(d$Tal, d$Kampfzeit.3)           # Zeilen = Tal, Spalten = Kampfzeit-Klasse
round(prop.table(table(d$Tal[d$Kampfzeit.3 == "[5,60)"])), 2)
```

|          | $[0,5)$ | $[5,60)$ | $[60,Inf)$ |
|----------|---------|----------|------------|
| Bergtal  | 0       | 3        | 1          |
| Flusstal | 2       | 2        | 0          |
| Waldtal  | 1       | 1        | 2          |

| Bergtal | Flusstal | Waldtal |
|---------|----------|---------|
| 0.50    | 0.33     | 0.17    |

Die zweite Zeile liest man von innen nach außen: nimm die Täler `d$Tal`, aber nur dort, wo die Kampfzeit in  $[5,60)$  liegt (`[...]`), zähle sie (`table`), mache Anteile daraus (`prop.table`), runde auf 2 Stellen (`round`). Das ist genau Testat 2, Aufgabe 3.7 (Randverteilung für eine Teilgruppe).

```
cor(d$Muenzen, d$Kampfzeit)           # Pearson
cor(d$Muenzen, d$Kampfzeit, method = "spearman") # Spearman
```

```
[1] 0.9275322
[1] 0.979021
```

### TÜRKÇE AÇIKLAMA

`cut()` sürekli bir değişkeni sınıflara (aralıklara) böler ve bir **factor** üretir. `breaks` sınır noktalarıdır; `Inf` sonsuz demektir. `right = FALSE` → aralıklar **[a, b)**: sol sınır dahil, sağ sınır hariç ("5 dakikadan az" gibi ifadeler için).  
`right = TRUE` → **(a, b]**: "en fazla 10" gibi ifadeler için. Soru metnindeki kelimelere çok dikkat et: "weniger als" (-den az) ve "bis zu / maximal" (en fazla) farklı sınırlar demektir.

## 1.9.9 Hilfe und typische Fehlermeldungen

```
?hist           # Hilfeseite zu hist öffnen (auch in der Klausur erlaubt!)
help(read.csv)
```

| Fehlermeldung                          | Ursache                              | Lösung                                                                              |
|----------------------------------------|--------------------------------------|-------------------------------------------------------------------------------------|
| object 'd' not found                   | Objekt existiert (noch) nicht        | Einlese-Zeile zuerst ausführen; Schreibweise prüfen                                 |
| cannot open file 'X.csv': No such file | falscher Ordner oder Dateiname       | <code>setwd(path.expand("~/"))</code> , <code>list.files()</code> zeigt die Dateien |
| could not find function "Mean"         | Tippfehler / Großschreibung          | <code>mean</code>                                                                   |
| unexpected ')' oder '+' in der Konsole | Klammer oder Anführungszeichen fehlt | Esc drücken, Klammern zählen                                                        |
| Ergebnis NA                            | fehlende Werte                       | <code>na.rm = TRUE</code>                                                           |
| PDF ist leer / beschädigt              | <code>dev.off()</code> vergessen     | <code>dev.off()</code> ausführen                                                    |

### 1.9.10 Die wichtigsten Befehle von Tag 1 auf einen Blick

| Befehl                                                                                     | Was er macht                          | Türkçe                        |
|--------------------------------------------------------------------------------------------|---------------------------------------|-------------------------------|
| <code>c(1, 2, 3)</code>                                                                    | Vektor erstellen                      | vektör oluştur                |
| <code>setwd(path.expand("~/"))</code>                                                      | Arbeitsordner Dokumente               | çalışma klasörü               |
| <code>read.csv(datei, header, sep, dec)</code>                                             | CSV einlesen                          | CSV dosyasını oku             |
| <code>head(d)</code> / <code>str(d)</code>                                                 | erste 6 Zeilen / Struktur             | ilk 6 satır / yapı            |
| <code>typeof(x)</code> / <code>class(x)</code>                                             | Objekttyp                             | nesne tipi                    |
| <code>d\$Spalte</code> , <code>d[z, s]</code>                                              | Spalte / Zeilen und Spalten auswählen | sütun / satır seç             |
| <code>mean</code> , <code>median</code>                                                    | Mittelwert, Median                    | ortalama, medyan              |
| <code>var</code> , <code>sd</code>                                                         | Varianz, Std.-abw. (mit $n-1$ !)      | varyans, std. sapma ( $n-1$ ) |
| <code>quantile(x, p)</code> , <code>IQR</code> , <code>range</code> , <code>summary</code> | Quantile, IQR, Min/Max, Übersicht     | kantiller, özet               |
| <code>table</code> , <code>prop.table</code>                                               | absolute / relative Häufigkeiten      | frekans / oran tablosu        |
| <code>tapply(x, gruppe, mean)</code>                                                       | Kennzahl je Gruppe                    | gruplara göre hesap           |
| <code>subset(d, bedingung)</code>                                                          | Zeilen filtern                        | satır filtrele                |
| <code>round(x, 3)</code>                                                                   | auf 3 Stellen runden                  | 3 basamağa yuvarla            |
| <code>hist(x, breaks, right, freq=FALSE, main, xlab, ylab)</code>                          | Histogramm                            | histogram                     |
| <code>pdf("a.pdf") ... dev.off()</code>                                                    | Grafik als PDF speichern              | grafiği PDF kaydet            |
| <code>boxplot</code> , <code>plot(x, y)</code>                                             | Boxplot, Streudiagramm                | kutu grafiği, serpilme        |
| <code>cut(x, breaks, right, labels)</code>                                                 | in Klassen einteilen (factor)         | sınıflara böl                 |
| <code>cor(x, y, method)</code>                                                             | Korrelation (pearson/spearman)        | korelasyon                    |

#### Klausurtraining 1.H · R (Teil B) · Tavernen-Daten

32 Punkte

Der Barde Jaskier sammelt Daten über seine Auftritte in Tavernen. Die Daten sind in der Datei `Taverne.csv` abgespeichert. Diese Datei liegt auf Ihrem lokalen Laufwerk im Ordner *Dokumente*. Der Datensatz enthält die Variablen: `Taverne` (Kennung), `TaL` (Ort der Taverne), `Monster` (besiegttes Monster), `Muenzen` (Anzahl erhaltener Münzen), `Kampfzeit` (Dauer des Kampfes in Minuten).

Beantworten Sie jede Teilaufgabe wie in ILIAS: (1) R-Code und R-Output, (2) wenn gefragt, eine inhaltliche Antwort in einem ganzen Satz. Runden Sie auf drei Nachkommastellen mit einem R-Befehl.

**(a)** Setzen Sie mittels `setwd(path.expand("~/"))` Ihr Working Directory.

(2 P)

- (b)** Speichern Sie die Daten als Data-Frame-Objekt `d` in R ab und geben Sie die ersten 6 Zeilen wieder. **(4 P)**
- (c)** Ermitteln Sie unter Einbezug eines passenden R-Befehls die Objekttypen der Variablen `Monster` und `Kampfzeit`. **(4 P)**
- (d)** Berechnen und nennen Sie das arithmetische Mittel und den unverzerrten Schätzer der Standardabweichung der Variable `Kampfzeit`. **(4 P)**
- (e)** Erstellen Sie ein normiertes Histogramm der Variable `Kampfzeit` mit den Intervallen  $[0, 10)$ ,  $[10, 40)$ ,  $[40, 100)$ . Titel: „Sitz ..., Matr.Nr. ..., Aufgabenteil e)“, x-Achse „Kampfzeit in Minuten“, y-Achse „Dichte“. Speichern Sie die Grafik als `Histogramm.pdf`. **(8 P)**
- (f)** Bestimmen Sie den Median und den Interquartilsabstand der Variable `Muenzen`. **(3 P)**
- (g)** Berechnen Sie die durchschnittliche Anzahl an Münzen für jedes Tal. In welchem Tal verdient Jaskier im Durchschnitt am meisten? **(3 P)**
- (h)** Wie stark ist der lineare Zusammenhang zwischen `Kampfzeit` und `Muenzen`? Berechnen und interpretieren Sie eine geeignete Maßzahl. **(4 P)**

Viele Punkte gehen verloren, weil die Antwort unklar ist. Hier sind **Mustersätze**, die du fast wörtlich benutzen kannst.

| Frage                      | Mustersatz                                                                                                                                                                             |
|----------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Skalenniveau               | „X ist ein stetiges, kardinal (metrisch) skaliertes Merkmal, weil die Abstände zwischen den Werten sinnvoll interpretierbar sind.“                                                     |
| Parameter nicht sinnvoll   | „Der Median ist für nominale Merkmale nicht sinnvoll, weil sich die Ausprägungen nicht der Größe nach ordnen lassen.“                                                                  |
| Mittelwert (Teil B)        | „Das arithmetische Mittel der Variable Muenzen beträgt 22.083.“                                                                                                                        |
| Vorteil Median             | „Der Median ist robuster gegenüber Extremwerten (Ausreißern) als das arithmetische Mittel.“                                                                                            |
| Vorteil Standardabweichung | „Die Standardabweichung hat dieselbe Maßeinheit wie das Merkmal.“                                                                                                                      |
| Korrelation deuten         | „Der Korrelationskoeffizient von 0.836 zeigt einen starken positiven linearen Zusammenhang zwischen Gewicht und Größe.“                                                                |
| Kausalität                 | „Nein. Eine Korrelation belegt keine Kausalität. Der Zusammenhang könnte durch Drittvariablen oder Zufall entstehen; für Kausalität bräuchte man z. B. ein randomisiertes Experiment.“ |
| Kovarianz                  | „Das positive Vorzeichen deutet auf einen positiven linearen Zusammenhang hin; die Höhe ist nicht interpretierbar, da sie von den Einheiten abhängt.“                                  |
| Objekttyp (Teil B)         | „Die Variable Tal ist ein character-Objekt; die Variable Muenzen ist numerisch vom Typ integer (nur ganze Zahlen).“                                                                    |

#### KLAUSUR-REGELN FÜR DIE FORM

- Teil A: Nur das Endergebnis ins Lösungskästchen, außer ein Lösungsweg ist verlangt. **Nie** zwei Lösungen hinschreiben – falsche Versuche durchstreichen.
- Teil B: Pro Teilaufgabe gibt es oft zwei Kästchen: (1) R-Code **und** R-Output hineinkopieren, (2) inhaltliche Antwort in einem **ganzen Satz** ohne Code, auf 3 Nachkommastellen gerundet. Fehlerhaften Code, der nicht zur Antwort gehört, löschen.
- Folgefehler werden berücksichtigt: Wenn du eine Teilaufgabe nicht kannst, rechne mit einem plausiblen Wert weiter und schreibe das dazu.
- Hältst du eine Aufgabe für unlösbar: „nicht lösbar“ ins Kästchen und Begründung in das Feld am Ende.

## Z1 Tag 1 auf einer Seite

| Thema               | Das Wichtigste                                                                                                                                                     |
|---------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Grundbegriffe       | Einheit, Grundgesamtheit, Stichprobe, Merkmal $X$ , Ausprägung $x$ ; deskriptiv (beschreiben) vs. induktiv (schließen + Unsicherheit)                              |
| Skalen              | nominal (nur Namen) · ordinal (Reihenfolge) · kardinal (Abstände); diskret (abzählbar) vs. stetig (Intervall); 1–7-Skala = ordinal; 0/1 = nominal, Mittel = Anteil |
| Stichproben         | einfach zufällig · geschichtet (aus allen Gruppen) · Klumpen (ganze Gruppen) · Quote (bewusst)                                                                     |
| Häufigkeiten        | $h_j, f_j = h_j/n$ ; Histogramm: Höhe = $f_j$ /Breite, Fläche = Anteil, Gesamtfläche 1; Anteil in Teilintervall: Breite $\times$ Höhe                              |
| Verteilungsfunktion | $\hat{F}(x)$ = Anteil $\leq x$ ; Treppe von 0 bis 1, ● links ○ rechts                                                                                              |
| Lagemaße            | Modus (alle Skalen), Median (ab ordinal, robust), Mittel (kardinal); rechtsschief: $\bar{x} > x_{med} > x_{mod}$ ; klassiert: $\sum f_j m_j$ ; Gruppen: gewichtet  |
| Quantile            | $n\alpha$ nicht ganz $\rightarrow$ aufrunden; ganz $\rightarrow$ Mittel aus $x_{(n\alpha)}$ und $x_{(n\alpha+1)}$                                                  |
| Streuung            | $s^2 = \overline{x^2} - \bar{x}^2$ (1/n); $s_*^2 = \frac{n}{n-1} s^2$ (R!); $s$ gleiche Einheit; $a + bx$ : Varianz $\times b^2$                                   |
| Boxplot             | Min, $x_{0.25}$ , Median, $x_{0.75}$ , Max; Ausreißer: mehr als 1.5·IQR außerhalb der Box                                                                          |
| Kontingenztafel     | Rand = Summen; bedingt = Zeile/Zeilensumme; $\tilde{h}_{jk} = h_{j\bullet} h_{\bullet k} / n$ ; $\chi^2 = \sum (h - \tilde{h})^2 / \tilde{h}$                      |
| Korrelation         | $s_{xy} = \overline{xy} - \bar{x}\bar{y}$ ; $r = s_{xy} / (s_x s_y) \in [-1, 1]$ ; nur linear; Spearman = Pearson der Ränge; Korrelation $\neq$ Kausalität         |
| R                   | setwd, read.csv, head, str, typeof, mean, sd (n–1!), quantile, table, tapply, hist(freq=FALSE), pdf()... dev.off(), cut, cor, round(..., 3)                        |

### Checkliste: Das kann ich jetzt

- ☐ Ich bestimme Skalenniveau und diskret/stetig für jedes Merkmal und begründe es.
- ☐ Ich baue aus Rohdaten eine Häufigkeitstabelle und ein Histogramm mit richtigen Höhen.
- ☐ Ich zeichne eine empirische Verteilungsfunktion korrekt (Punkte, Kreise, Achsen).
- ☐ Ich berechne Mittelwert, Median, Modus, Quantile, Varianz (1/n und 1/(n–1)) und Standardabweichung.
- ☐ Ich bestimme Whisker und Ausreißer eines Boxplots.
- ☐ Ich ergänze eine Kontingenztafel, berechne bedingte Verteilungen und den  $\chi^2$ -Koeffizienten.
- ☐ Ich berechne Kovarianz, Pearson- und Spearman-Korrelation und interpretiere sie richtig.
- ☐ Ich erkläre, warum Korrelation keine Kausalität ist.
- ☐ Ich lese in R einen Datensatz ein, bestimme Typen und Kennzahlen, filtere nach Gruppen und speichere ein Histogramm als PDF.

## K1 Gemischte Klausuraufgaben Tag 1 – Generalprobe

Das sind echte Aufgaben aus der Probeklausur und aus Tutorien. Rechne sie am Ende des Tages **auf Zeit**: zusammen 38 Punkte  $\approx$  50 Minuten.

### Aufgabe K1.1 · Wahrsagerin (Probeklausur A, Aufgabe 1)

10 Punkte

Harry möchte die Genauigkeit der Vorhersagen der Wahrsagerin Giesela Baumrasen untersuchen. Er befragt zufällig 20 Schüler\*innen, ob ihre Vorhersagen eingetroffen sind (1 = korrekt, 0 = falsch).

```
> sort(Vorhersagen)
[1] 0 0 0 0 0 0 0 0 0 0 0 1 1 1 1 1 1 1 1 1
```

- (a) Geben Sie das Skalenniveau des Merkmals „Korrektheit der Vorhersagen“ an. (2 P)
- (b) Berechnen Sie  $x_{mod}$ ,  $x_{med}$ ,  $\bar{x}$  und  $s_x^2$ . Falls ein Parameter nicht sinnvoll angegeben werden kann, begründen Sie kurz in einem Satz. (8 P)

### Aufgabe K1.2 · Bier (Probeklausur A, Aufgabe 2)

14 Punkte

Der Betreiber der Bar „BierWirdGeschafft“ erfasst die Menge des getrunkenen Bieres  $X$  (Liter) und die Herkunft der Gäste  $Y$  (BY oder NRW):

|       |     |     |     |     |      |      |     |      |     |     |
|-------|-----|-----|-----|-----|------|------|-----|------|-----|-----|
| $x_i$ | 8.5 | 8.5 | 4.0 | 4.0 | 12.0 | 12.0 | 8.5 | 15.7 | 4.0 | 8.5 |
| $y_i$ | BY  | BY  | NRW | BY  | NRW  | BY   | BY  | NRW  | NRW | BY  |

Hinweis:  $\sum x_i = 85.7$ ;  $\sum x_i^2 = 871.49$

- (a) Geben Sie für  $X$  und  $Y$  an, ob ein diskretes oder stetiges Merkmal vorliegt. Welches Skalenniveau liegt jeweils zugrunde? (4 P)
- (b) Zeichnen Sie die empirische Verteilungsfunktion für  $X$ . (6 P)
- (c) Klassieren Sie den Bierkonsum in die Klassen  $K_1 = [0, 10)$  und  $K_2 = [10, 20]$  und bestimmen Sie den Mittelwert für die klassierten Daten. (4 P)
- (d) Zusatz: Berechnen Sie  $\bar{x}$ ,  $s^2$ ,  $s$  und den Modus von  $Y$ .

### Aufgabe K1.3 · Filmbewertungen (nach Tutorium 3)

8 Punkte

Bewertungen von 5 Filmen auf zwei Portalen: Portal A: 6, 8, 7, 9, 5; Portal B: 7, 9, 6, 10, 6.

- (a) Berechnen Sie  $\bar{x}$ ,  $\bar{y}$ ,  $s_x^2$ ,  $s_y^2$ ,  $s_{xy}$  (mit  $1/n$ ) und  $r_{xy}$ . (4 P)
- (b) Interpretieren Sie  $r_{xy}$ . (1 P)
- (c) Bestimmen Sie die Ränge und den Spearman-Koeffizienten. (3 P)

### Aufgabe K1.4 · Arbeitszeit (nach Tutorium 2, Aufgabe 5)

6 Punkte

Arbeitszeit pro Woche während der Vorlesungszeit: [0,4]: 40.2 %, (4,8]: 19.6 %, (8,12]: 21.9 %, (12,16]: 18.3 %.

- (a) Welche Klasse ist die Modalklasse? (1 P)
- (b) Berechnen Sie näherungsweise Mittelwert und Varianz mit den Klassenmitten. (3 P)
- (c) Wie hoch ist die Säule der Klasse (4,8] im Histogramm? Schätzen Sie den Anteil mit mehr als 10 Stunden. (2 P)

**Aufgabe K1.5 · Mensa-Pilotstudie (im Stil von Testat 1)****8 Punkte**

Häufigkeitstabelle der Mensabesuche in der letzten Woche:  $a_j$ : 0, 1, 2, 3, 4 mit  $h_j$ : 4, 6, 7, 2, 1.

- (a)** Bestimmen Sie die Stichprobengröße  $n$  und das Skalenniveau. **(2 P)**
- (b)** Bestimmen Sie Modus, Median und Mittelwert. **(3 P)**
- (c)** Berechnen Sie  $s^2$  und  $s_*^2$ . **(2 P)**
- (d)** Wie groß ist der Anteil der Studierenden mit mindestens 2 Besuchen? **(1 P)**

**Aufgabe K1.6 · Kampfzeiten und Boxplot****6 Punkte**

Kampfzeiten in Minuten (sortiert): 1, 3, 4, 4, 6, 7, 8, 9, 10, 12, 30.

- (a)** Bestimmen Sie  $x_{0.25}$ , Median,  $x_{0.75}$  und IQR nach der Vorlesungsdefinition. **(3 P)**
- (b)** Gibt es Ausreißer? Wo enden die Whisker? **(2 P)**
- (c)** Ist die Verteilung eher rechts- oder linksschief? Begründen Sie mit Mittelwert und Median. **(1 P)**

# Lösungen Tag 1

Vergleiche nicht nur das Ergebnis, sondern auch den Weg. In der Klausur gibt es Punkte für richtige Zwischenschritte.

## Kontrollfragen 1.1 – 1.3

1. Deskriptiv: nur die vorliegenden Daten beschreiben (Tabellen, Grafiken, Kennzahlen). Induktiv: von der Stichprobe auf die Grundgesamtheit schließen und die Unsicherheit angeben.
2. Falsch. Richtig: „Ein diskretes Merkmal kann endlich **oder abzählbar unendlich** viele Werte annehmen.“
3. Randomisierung. Störvariablen (Alter, Vorerkrankungen ...) verteilen sich zufällig und im Mittel gleich auf beide Gruppen; so kann man den Effekt des Medikaments sauber messen.

## Klausurtraining 1.A · Fitnessstudio

(a)

| Merkmal                   | Skala       | diskret/stetig |
|---------------------------|-------------|----------------|
| Alter in ganzen Jahren    | kardinal    | diskret        |
| Trainingsdauer in Stunden | kardinal    | stetig         |
| Tarif                     | nominal     | diskret        |
| Zufriedenheit (5 Stufen)  | ordinal     | diskret        |
| Anzahl Besuche            | kardinal    | diskret        |
| Postleitzahl              | nominal (!) | diskret        |

(b) Einheit: ein Mitglied des Studios. Grundgesamtheit: alle 2400 Mitglieder.

(c) Geschichtete Stichprobe (Schichten = Tarife; Anteile sind bekannt) bzw. Quotenverfahren.

(d) Klumpenstichprobe (Kurse = Klumpen). Vorteil: einfacher und kostengünstiger, weil man ganze Kurse auf einmal befragt.

(e) (i) Falsch: Die Postleitzahl ist nominal; Zahlen sind hier nur Namen, ein Durchschnitt hat keine Bedeutung. (ii) Richtig: Die Zufriedenheit ist ordinal, man kann die Werte sortieren, also ist der Median sinnvoll.

## Klausurtraining 1.B · Pendelzeiten

(a)

| Klasse  | $h_j$ | $f_j = h_j/50$ | Breite | Höhe $f_j/\text{Breite}$ |
|---------|-------|----------------|--------|--------------------------|
| [0,10)  | 8     | 0.16           | 10     | 0.016                    |
| [10,20) | 15    | 0.30           | 10     | 0.030                    |
| [20,30) | 12    | 0.24           | 10     | 0.024                    |
| [30,60) | 10    | 0.20           | 30     | 0.007 (0.0067)           |
| [60,90] | 5     | 0.10           | 30     | 0.003 (0.0033)           |

(b) Annahme: Die Werte sind innerhalb jeder Klasse gleichmäßig verteilt. Anteil = Fläche:  $(30 - 25) \cdot 0.024 + (45 - 30) \cdot 0.00667 = 0.12 + 0.10 = 0.22$ .

(c)  $10 + 5 = 15$  Studierende.

(d) Mitten 5, 15, 25, 45, 75:  $\bar{x}_K = 0.16 \cdot 5 + 0.30 \cdot 15 + 0.24 \cdot 25 + 0.20 \cdot 45 + 0.10 \cdot 75 = 0.8 + 4.5 + 6 + 9 + 7.5 = 27.8$  Minuten.

(e) Modalklasse [10,20) (15 Personen, größte Häufigkeit). Die Klassen sind ungleich breit: Im Säulendiagramm würde die breite Klasse [30,60) mit 10 Personen fast so wichtig aussehen wie [10,20), obwohl die Werte über 30 Minuten verteilt sind. Nur im Histogramm (Fläche = Anteil) ist die Darstellung nicht verzerrt.

## Klausurtraining 1.C · Kaffee

(a) kardinal, diskret (Anzahl).

$$(b) \hat{F}(x) = \begin{cases} 0 & x < 0 \\ 0.1 & 0 \leq x < 1 \\ 0.3 & 1 \leq x < 2 \\ 0.6 & 2 \leq x < 3 \\ 0.8 & 3 \leq x < 4 \\ 0.9 & 4 \leq x < 6 \\ 1 & x \geq 6 \end{cases} \quad \text{Skizze: Treppe mit Sprüngen bei 0, 1, 2, 3, 4, 6; volle Punkte links, offene Kreise rechts;}$$

Achsen beschriften.

(c)  $\hat{F}(2.5) = 0.6$ . Mehr als 2:  $1 - \hat{F}(2) = 1 - 0.6 = 0.4$ . Mindestens 1:  $1 - \hat{F}(0) = 1 - 0.1 = 0.9$ .

(d) Modus 2 (3-mal). Median:  $n = 10 \rightarrow (x_{(5)} + x_{(6)})/2 = (2 + 2)/2 = 2$ . Mittelwert:  $24/10 = 2.4$ .

## Klausurtraining 1.D · Gehälter

(a)  $\bar{x} = 43.6/9 = 4.844$  Tsd. €; Median =  $x_{(5)} = 3.6$ ; Modus = 3.1.

(b) Der Median, denn er ist robust gegenüber dem Extremwert 15.0 (Gehalt der Chefin/des Chefs), der den Mittelwert nach oben zieht.

(c) Rechtsschief, da  $\bar{x} = 4.844 > x_{med} = 3.6 > x_{mod} = 3.1$ .

(d) Lineare Transformation  $y = 1.05x$ :  $\bar{y} = 1.05 \cdot 4.8444 = 5.087$ ;  $y_{med} = 1.05 \cdot 3.6 = 3.780$ .

(e)  $\bar{x}_{ges} = \frac{9 \cdot 4.8444 + 6 \cdot 3.5}{15} = \frac{43.6 + 21}{15} = \frac{64.6}{15} = 4.307$ .

(f)  $s^2 = \frac{329.68}{9} - 4.8444^2 = 36.6311 - 23.4686 = 13.1625$ ;  $s = \sqrt{13.1625} = 3.628$  Tsd. €.

## Klausurtraining 1.E · Lieferzeiten

(a)  $\bar{x} = 66/12 = 5.5$ ; Median:  $n = 12 \rightarrow (x_{(6)} + x_{(7)})/2 = (4 + 5)/2 = 4.5$ .

(b)  $12 \cdot 0.25 = 3$  (ganz)  $\rightarrow x_{0.25} = (x_{(3)} + x_{(4)})/2 = (3 + 4)/2 = 3.5$ ;  $12 \cdot 0.75 = 9 \rightarrow x_{0.75} = (x_{(9)} + x_{(10)})/2 = (6 + 7)/2 = 6.5$ ; IQR = 3.

(c)  $s^2 = \frac{482}{12} - 5.5^2 = 40.1667 - 30.25 = 9.9167$ ;  $s_*^2 = \frac{12}{11} \cdot 9.9167 = 10.818$ ;  $s = \sqrt{9.9167} = 3.149$ .

(d) Grenzen:  $3.5 - 1.5 \cdot 3 = -1$  und  $6.5 + 4.5 = 11$ . Der Wert 14 liegt darüber  $\rightarrow$  **Ausreißer**. Unterer Whisker = 2 (Minimum), oberer Whisker = 9 (größter Wert  $\leq 11$ ). Skizze: Box von 3.5 bis 6.5, Median-Strich bei 4.5, Whisker 2 und 9, Punkt bei 14.

(e)  $y = 24x$ : Mittelwert  $24 \cdot 5.5 = 132$  Stunden; Varianz  $24^2 \cdot 9.9167 = 576 \cdot 9.9167 = 5712$  Stunden<sup>2</sup>; Standardabweichung  $24 \cdot 3.149 = 75.578$  Stunden.

## Klausurtraining 1.F · Rauchen und Sport

(a)

|                            | Sport (S) | kein Sport ( $\bar{S}$ ) | $\Sigma$ |
|----------------------------|-----------|--------------------------|----------|
| Raucher (R)                | 15        | 45                       | 60       |
| Nichtraucher ( $\bar{R}$ ) | 75        | 65                       | 140      |
| $\Sigma$                   | 90        | 110                      | 200      |

Rechenweg:  $60 - 15 = 45$ ;  $200 - 60 = 140$ ;  $200 - 110 = 90$ ;  $90 - 15 = 75$ ;  $140 - 75 = 65$ .

(b)  $f(S | R) = \frac{15}{60} = 0.25$ ;  $f(S | \bar{R}) = \frac{75}{140} = 0.536$ .

(c) Ja: Die bedingten Verteilungen unterscheiden sich deutlich (25 % vs. 53.6 %). Bei Unabhängigkeit wären sie gleich (=  $90/200 = 45$  %).

(d)  $\tilde{h}_{R,S} = \frac{60 \cdot 90}{200} = 27$ ,  $\tilde{h}_{R,\bar{S}} = \frac{60 \cdot 110}{200} = 33$ ,  $\tilde{h}_{\bar{R},S} = \frac{140 \cdot 90}{200} = 63$ ,  $\tilde{h}_{\bar{R},\bar{S}} = \frac{140 \cdot 110}{200} = 77$ . Differenzen  $\pm 12$ .  $\chi^2 = \frac{144}{27} + \frac{144}{33} + \frac{144}{63} + \frac{144}{77} = 5.3333 + 4.3636 + 2.2857 + 1.8701 = 13.853$ .

(e) Die Daten zeigen nur einen statistischen Zusammenhang, keine Kausalität. Es könnte Drittvariablen geben (z. B. Gesundheitsbewusstsein, Freizeit), oder die Richtung ist umgekehrt (Sportler fangen seltener an zu rauchen). Für eine kausale Aussage bräuchte man ein Experiment bzw. Kontrolle der Störvariablen.

## Kontrollfragen 1.7 – 1.8

1. (a) richtig (unabhängig  $\Rightarrow r = 0$ ; also  $r \neq 0 \Rightarrow$  abhängig); (b) richtig; (c) richtig; (d) falsch; (e) falsch (Kovarianz hängt von den Einheiten ab).
2.  $\bar{x} = 40.38$ ,  $\bar{y} = 74.66$ .  $s_{xy} = \frac{160064}{50} - 40.38 \cdot 74.66 = 3201.28 - 3014.7708 = 186.509$ .  $s_x^2 = 1752.22 - 1630.5444 = 121.6756$ ,  $s_y^2 = 6033.9 - 5574.1156 = 459.7844$ .  $r = \frac{186.5092}{\sqrt{121.6756 \cdot 459.7844}} = 0.789 \rightarrow$  starker positiver linearer Zusammenhang.

## Klausurtraining 1.G · Werbung und Umsatz

- (a) x-Achse „Werbeausgaben (Tsd. €)“, y-Achse „Umsatz (Tsd. €)“; sechs Punkte (1|25), (2|30), (3|38), (4|45), (5|48), (6|60) – sie steigen fast auf einer Geraden.
- (b)  $\bar{x} = 21/6 = 3.5$ ,  $\bar{y} = 246/6 = 41$ .  $s_{xy} = \frac{979}{6} - 3.5 \cdot 41 = 163.1667 - 143.5 = 19.667$ .
- (c)  $s_x^2 = \frac{91}{6} - 3.5^2 = 15.1667 - 12.25 = 2.9167$ ;  $s_y^2 = \frac{10898}{6} - 41^2 = 1816.3333 - 1681 = 135.3333$ .  $r = \frac{19.6667}{\sqrt{2.9167 \cdot 135.3333}} = \frac{19.6667}{19.8676} = 0.990$ . Sehr starker positiver linearer Zusammenhang: Filialen mit höheren Werbeausgaben haben (fast linear) höhere Umsätze.
- (d) Die Rangfolge von x und y ist in jeder Filiale gleich (Filiale 6 hat bei beiden Rang 1, Filiale 1 Rang 2, ...). Also sind die Ränge identisch  $\rightarrow r_{sp} = 1$  (perfekter monotoner Zusammenhang).
- (e) y wird mit 1000 multipliziert: Kovarianz  $\times 1000 \rightarrow 19\,666.667$ ; die Korrelation bleibt 0.990 (sie hat keine Einheit).
- (f) Eine hohe Korrelation beweist keine Kausalität. Drittvariable z. B. Größe oder Lage der Filiale: Große Filialen in guter Lage haben mehr Budget für Werbung **und** mehr Kundschaft.

## Klausurtraining 1.H · R (Musterlösung)

(a)

```
setwd(path.expand("~/"))
```

(b)

```
d <- read.csv("Taverne.csv", header = TRUE, sep = ";", dec = ".")
head(d)
```

|   | Taverne | Tal      | Monster | Muenzen | Kampfzeit |
|---|---------|----------|---------|---------|-----------|
| 1 | T01     | Flusstal | Ghul    | 18      | 12.5      |
| 2 | T02     | Bergtal  | Troll   | 25      | 45.0      |
| 3 | T03     | Flusstal | Wolf    | 12      | 3.2       |
| 4 | T04     | Walddal  | Greif   | 30      | 75.5      |
| 5 | T05     | Bergtal  | Ghul    | 22      | 8.0       |
| 6 | T06     | Walddal  | Wolf    | 15      | 4.5       |

(c)

```
typeof(d$Monster)      # alternativ class() oder str(d)
typeof(d$Kampfzeit)
```

```
[1] "character"
[1] "double"
```

Antwortsatz: Die Variable Monster ist ein character-Objekt (Text). Die Variable Kampfzeit ist ein numerisches Objekt vom Typ double (Fließkommazahl).

(d)

```
round(mean(d$Kampfzeit), 3)
round(sd(d$Kampfzeit), 3)
```

```
[1] 33.85
[1] 30.667
```

Antwortsatz: Das arithmetische Mittel der Kampfzeit beträgt 33.850 Minuten, der unverzernte Schätzer der Standardabweichung beträgt 30.667 Minuten.

(e)

```
pdf("Histogramm.pdf")
hist(d$Kampfzeit, breaks = c(0, 10, 40, 100), right = FALSE, freq = FALSE,
     main = "Sitz 12, Matr.Nr. 12345678, Aufgabenteil e)",
     xlab = "Kampfzeit in Minuten", ylab = "Dichte")
dev.off()
```

Kontrolle der Höhen (plot = FALSE): 0.0333, 0.0083, 0.0069. Punkte gibt es für: richtige Klassen (breaks, right = FALSE), Dichte (freq = FALSE), Titel mit Sitz/Matr.-Nr./Aufgabenteil, beide Achsenbeschriftungen, PDF gespeichert und hochgeladen.

(f)

```
median(d$Muenzen)
IQR(d$Muenzen)
```

```
[1] 23
[1] 10.25
```

Antwortsatz: Der Median der Münzen beträgt 23, der Interquartilsabstand 10.250.

(g)

```
round(tapply(d$Muenzen, d$Tal, mean), 3)
```

```
Bergtal Flusstal Walddal
26.00   16.75   23.50
```

Antwortsatz: Im Durchschnitt erhält Jaskier im Bergtal mit 26.000 Münzen am meisten (Walddal 23.500, Flusstal 16.750).

(h)

```
round(cor(d$Kampfzeit, d$Muenzen), 3)
```

```
[1] 0.928
```

Antwortsatz: Der Korrelationskoeffizient nach Bravais-Pearson beträgt 0.928. Es liegt ein starker positiver linearer Zusammenhang vor: Längere Kämpfe gehen mit mehr Münzen einher.

### K1.1 · Wahrsagerin

(a) **Nominal** (binär, 0/1-kodiert: richtig/falsch haben keine echte Ordnung; diskret).

(b)  $x_{mod} = 0$  (11-mal). Median:  $n = 20$  gerade  $\rightarrow$  zwischen  $x_{(10)} = 0$  und  $x_{(11)} = 0 \rightarrow x_{med} = 0$ . Begründung, wenn man streng ist: Für nominale Daten ist der Median eigentlich nicht sinnvoll (keine Ordnung); bei 0/1-Kodierung kann man ihn formal berechnen (= 0).  $\bar{x} = \frac{9}{20} = 0.45$  – sinnvoll, denn bei 0/1-Daten ist das der **Anteil** richtiger Vorhersagen (45 %).  $s^2 = \overline{x^2} - \bar{x}^2 = 0.45 - 0.2025 = 0.248$  (genau  $0.2475 = \bar{x}(1 - \bar{x})$ ).

### K1.2 · Bier

(a) X: **stetig**, kardinal/metrisch (Verhältnisskala). Y: **diskret, nominal**.

(b) Siehe 1.4: Stufen 0 / 0.3 / 0.7 / 0.9 / 1 an den Stellen 4, 8.5, 12, 15.7.

(c)  $n(K_1) = 7$ ,  $n(K_2) = 3$ ,  $m_1 = 5$ ,  $m_2 = 15$ :  $\bar{x}_K = \frac{1}{10}(7 \cdot 5 + 3 \cdot 15) = 8$ .

(d)  $\bar{x} = 85.7/10 = 8.570$ ;  $s^2 = 87.149 - 8.57^2 = 13.704$ ;  $s = 3.702$ ; Modus(Y) = BY (6-mal).

### K1.3 • Filmbewertungen

- (a)  $\bar{x} = 7$ ,  $\bar{y} = 7.6$ .  $\sum x^2 = 255 \Rightarrow s_x^2 = 51 - 49 = 2$ .  $\sum y^2 = 302 \Rightarrow s_y^2 = 60.4 - 57.76 = 2.64$ .  $\sum xy = 42 + 72 + 42 + 90 + 30 = 276 \Rightarrow s_{xy} = 55.2 - 53.2 = 2$ .  $r = \frac{2}{\sqrt{2 \cdot 2.64}} = \frac{2}{2.2978} = 0.870$ .
- (b) Starker positiver linearer Zusammenhang: Filme mit guter Bewertung bei A haben meist auch gute Bewertungen bei B.
- (c) Ränge A:  $6 \rightarrow 2, 8 \rightarrow 4, 7 \rightarrow 3, 9 \rightarrow 5, 5 \rightarrow 1$ . Ränge B:  $7 \rightarrow 3, 9 \rightarrow 4, 6 \rightarrow 1.5, 10 \rightarrow 5, 6 \rightarrow 1.5$ .  $\sum rk_x rk_y = 6 + 16 + 4.5 + 25 + 1.5 = 53$ ;  $\sum rk_x^2 = 55$ ;  $\sum rk_y^2 = 54.5$ ;  $n \cdot 3^2 = 45$ .  $r_{sp} = \frac{53-45}{\sqrt{(55-45)(54.5-45)}} = \frac{8}{\sqrt{95}} = 0.821$ .

### K1.4 • Arbeitszeit

- (a) [0,4] (40.2 %; alle Klassen gleich breit). (b) Mitten 2, 6, 10, 14:  $\bar{x} = 0.402 \cdot 2 + 0.196 \cdot 6 + 0.219 \cdot 10 + 0.183 \cdot 14 = 6.732$ .  $s^2 = 0.402(2 - 6.732)^2 + 0.196(6 - 6.732)^2 + 0.219(10 - 6.732)^2 + 0.183(14 - 6.732)^2 = 21.112$ . (c) Höhe  $0.196/4 = 0.049$ . Anteil über 10:  $\frac{2}{4} \cdot 0.219 + 0.183 = 0.293$ .

### K1.5 • Mensa-Pilotstudie

- (a)  $n = 4 + 6 + 7 + 2 + 1 = 20$ ; kardinal, diskret. (b) Modus 2. Median: Plätze 10 und 11 – Plätze 1–4 sind 0, 5–10 sind 1, 11–17 sind 2  $\rightarrow \frac{1+2}{2} = 1.5$ . Mittel:  $\frac{0+6+14+6+4}{20} = 1.5$ .
- (c)  $\bar{x}^2 = \frac{0+6+28+18+16}{20} = 3.4$ ;  $s^2 = 3.4 - 2.25 = 1.15$ ;  $s_*^2 = \frac{20}{19} \cdot 1.15 = 1.211$ . (d)  $\frac{7+2+1}{20} = 0.5$ .

### K1.6 • Kampfzeiten

- (a)  $n = 11$ .  $11 \cdot 0.25 = 2.75 \rightarrow x_{(3)} = 4$ ; Median  $x_{(6)} = 7$ ;  $11 \cdot 0.75 = 8.25 \rightarrow x_{(9)} = 10$ ; IQR = 6.
- (b) Grenzen  $4 - 9 = -5$  und  $10 + 9 = 19$ : 30 ist ein **Ausreißer**. Oberer Whisker 12, unterer Whisker 1.
- (c)  $\bar{x} = \frac{94}{11} = 8.545 > 7 = x_{med} \rightarrow$  eher **rechtsschief** (langer Schwanz nach rechts durch den Wert 30).

## Dein Formelblatt – Teil für Tag 1

#### DAS SCHREIBST DU HEUTE MIT DER HAND AUF DEIN A4-BLATT

- Skalen: nominal (Modus) · ordinal (+ Median) · kardinal (+ Mittelwert); diskret = abzählbar, stetig = Intervall; 1–7-Skala = ordinal; PLZ = nominal
- $f_j = h_j/n$ ; Histogramm-Höhe =  $f_j/\text{Breite}$ ; Anteil = Breite  $\times$  Höhe;  $\hat{F}(x) = \#\{x_i \leq x\}/n$  (Treppe, • links, ○ rechts)
- $\bar{x} = \frac{1}{n} \sum x_i = \sum a_j f_j$ ; klassiert  $\bar{x}_K = \sum f_j m_j$ ; Gruppen  $\bar{x} = \frac{1}{n} \sum n_j \bar{x}_j$ ; Median:  $x_{((n+1)/2)}$  bzw. Mittel der beiden mittleren
- Quantil:  $n\alpha$  nicht ganz  $\rightarrow$  aufrunden; ganz  $\rightarrow \frac{x_{(n\alpha)} + x_{(n\alpha+1)}}{2}$
- $s^2 = \overline{x^2} - \bar{x}^2$ ;  $s_*^2 = \frac{n}{n-1} s^2$  (R: var, sd!);  $y = a + bx \Rightarrow \bar{y} = a + b\bar{x}$ ,  $s_y^2 = b^2 s_x^2$
- Boxplot: Ausreißer außerhalb  $[x_{0.25} - 1.5 \text{ IQR}; x_{0.75} + 1.5 \text{ IQR}]$
- rechtsschief:  $\bar{x} > x_{med} > x_{mod}$
- $\tilde{h}_{jk} = \frac{h_{j\bullet} h_{\bullet k}}{n}$ ,  $\chi^2 = \sum \frac{(h_{jk} - \tilde{h}_{jk})^2}{\tilde{h}_{jk}}$ ; bedingt: Zeile / Zeilensumme
- $s_{xy} = \overline{xy} - \bar{x}\bar{y}$ ;  $r = \frac{s_{xy}}{s_x s_y}$ ;  $|r|$ : <0.3 schwach, 0.3–0.7 mittel,  $\geq 0.7$  stark; Spearman: Ränge, Bindungen  $\rightarrow$  Durchschnittsrang

**Rückseite (Teil B):** Für Teil B schreibst du ein eigenes Blatt. Übertrage die Tabelle aus 1.9.10 (Befehle) und die drei Schritte pdf()  $\rightarrow$  Grafik  $\rightarrow$  dev.off().

## Wörterliste Tag 1 (Deutsch – Türkçe)

|                      |                     |                                       |
|----------------------|---------------------|---------------------------------------|
| Grundgesamtheit      | ana kütle / evren   | alle Einheiten, die uns interessieren |
| Stichprobe           | örneklem            | der untersuchte Teil                  |
| statistische Einheit | istatistiksel birim | Objekt, an dem gemessen wird          |
| Merkmal / Ausprägung | değişken / değer    | Eigenschaft / konkreter Wert          |
| Skalenniveau         | ölçek düzeyi        | nominal, ordinal, kardinal            |

|                                               |                                          |                                               |
|-----------------------------------------------|------------------------------------------|-----------------------------------------------|
| <b>diskret / stetig</b>                       | <i>kesikli / sürekli</i>                 | abzählbar / jede Zahl möglich                 |
| <b>geschichtete Stichprobe</b>                | <i>tabakalı örnekleme</i>                | aus jeder Gruppe ziehen                       |
| <b>Klumpenstichprobe</b>                      | <i>küme örnekleme</i>                    | ganze Gruppen ziehen                          |
| <b>Häufigkeit (absolut/relativ)</b>           | <i>frekans (mutlak/görel)</i>            | Anzahl / Anteil                               |
| <b>Klasse, Klassenbreite</b>                  | <i>sınıf, sınıf genişliği</i>            | Intervall, seine Länge                        |
| <b>Verteilungsfunktion</b>                    | <i>(birikimli) dağılım fonksiyonu</i>    | Anteil der Werte $\leq x$                     |
| <b>arithmetisches Mittel</b>                  | <i>aritmetik ortalama</i>                | Durchschnitt                                  |
| <b>Median / Modus</b>                         | <i>medyan / mod</i>                      | Mitte / häufigster Wert                       |
| <b>Streuung, Varianz</b>                      | <i>yayılım, varyans</i>                  | wie weit die Werte auseinander liegen         |
| <b>Standardabweichung</b>                     | <i>standart sapma</i>                    | Wurzel aus der Varianz                        |
| <b>Quantil / Quartil</b>                      | <i>kantil / çeyreklik</i>                | Grenze, unter der $\alpha \cdot 100$ % liegen |
| <b>Interquartilsabstand</b>                   | <i>çeyrekler açıklığı</i>                | $x_{0.75} - x_{0.25}$                         |
| <b>Ausreißer</b>                              | <i>aykırı değer</i>                      | extremer Wert                                 |
| <b>Kontingenztafel</b>                        | <i>çapraz tablo / olumsuzluk tablosu</i> | Tabelle für zwei Merkmale                     |
| <b>Randverteilung</b>                         | <i>marjinal dağılım</i>                  | Zeilen-/Spaltensummen                         |
| <b>bedingte Verteilung</b>                    | <i>koşullu dağılım</i>                   | Verteilung in einer Zeile                     |
| <b>Zusammenhang</b>                           | <i>ilişki</i>                            | Merkmale hängen zusammen                      |
| <b>Kovarianz / Korrelation</b>                | <i>kovaryans / korelasyon</i>            | Maße für linearen Zusammenhang                |
| <b>Rang, Bindung</b>                          | <i>sıra, eşit değer (bağ)</i>            | Platz in der Reihenfolge                      |
| <b>Kausalität</b>                             | <i>nedensellik</i>                       | Ursache $\rightarrow$ Wirkung                 |
| <b>Scheinkorrelation</b>                      | <i>sahte korelasyon</i>                  | Korrelation ohne Ursache                      |
| <b>schief (rechts/links)</b>                  | <i>çarpık (sağa/sola)</i>                | unsymmetrische Verteilung                     |
| <b>Arbeitsverzeichnis (working directory)</b> | <i>çalışma klasörü</i>                   | Ordner, in dem R arbeitet                     |
| <b>einlesen</b>                               | <i>(veriyi) okumak / içe aktarmak</i>    | Datei in R laden                              |
| <b>Objekttyp</b>                              | <i>nesne tipi</i>                        | double, integer, character ...                |