

Musterlösung · Probeklausur 2 (Generalprobe Zweittermin)

Punkte in eckigen Klammern = Bewertungsschlüssel. Folgefehler werden berücksichtigt. Alle Zahlen sind mit Python bzw. R nachgerechnet. Notenorientierung (nicht offiziell, linear angenommen, Bestehen ab 50 %): Gesamt 120 P → ab 60 P = 4.0 · 66 = 3.7 · 72 = 3.3 · 78 = 3.0 · 84 = 2.7 · 90 = 2.3 · 96 = 2.0 · 102 = 1.7 · 108 = 1.3 · 114 = 1.0.

Teil A

Aufgabe 1 (9 P)

(a) Anzahl Mensabesuche: kardinal (metrisch), diskret [1] · bevorzugte Mensa: nominal, diskret [1].

(b) $x_{mod} = 2$ [1] · $n = 12$ gerade → $x_{med} = \frac{x_{(6)} + x_{(7)}}{2} = \frac{2+3}{2} = 2.5$ [1] · $\bar{x} = \frac{36}{12} = 3$ [1].

(c) $s^2 = \frac{1}{n} \sum x_i^2 - \bar{x}^2 = \frac{162}{12} - 3^2 = 13.5 - 9 = 4.5$ [1] · $s_*^2 = \frac{n}{n-1} s^2 = \frac{12}{11} \cdot 4.5 = \frac{54}{11} = 4.909$ [1].

(d) Modus = Zentralmensa [1] · Median nicht sinnvoll: Das Merkmal ist nominal, die Ausprägungen haben keine natürliche Reihenfolge [1].

Aufgabe 2 (9 P)

Geordnet: 2, 2, 5, 5, 5, 5, 8, 8, 12, 15.

$$(a) \hat{F}(x) = \begin{cases} 0 & x < 2 \\ 0.2 & 2 \leq x < 5 \\ 0.6 & 5 \leq x < 8 \\ 0.8 & 8 \leq x < 12 \\ 0.9 & 12 \leq x < 15 \\ 1 & x \geq 15 \end{cases} \quad [3] \cdot \text{Skizze: Treppenfunktion, } \bullet \text{ links (Wert gehört dazu), } \circ \text{ rechts, Achsen}$$

beschriftet [1].

(b) (i) $1 - \hat{F}(5) = 1 - 0.6 = 0.4$ [1] · (ii) $\hat{F}(8) = 0.8$ [1].

(c) K_1 : 6 Werte → $f_1 = 0.6$, Höhe $\frac{0.6}{6} = 0.1$; K_2 : 4 Werte → $f_2 = 0.4$, Höhe $\frac{0.4}{10} = 0.04$ [1] · Klassenmitten 3 und 11: $\bar{x}_K = 0.6 \cdot 3 + 0.4 \cdot 11 = 1.8 + 4.4 = 6.2$ [2]. (Zum Vergleich: der exakte Mittelwert ist 6.7.)

Aufgabe 3 (10 P)

$$\bar{x} = \frac{25}{5} = 5, \bar{y} = \frac{180}{5} = 36.$$

(a) $s_{xy} = \frac{1}{n} \sum x_\nu y_\nu - \bar{x}\bar{y} = \frac{995}{5} - 5 \cdot 36 = 199 - 180 = 19$ [2].

(b) $s_x^2 = \frac{143}{5} - 25 = 3.6$, $s_y^2 = \frac{7050}{5} - 36^2 = 1410 - 1296 = 114$ [1] · $r_{xy} = \frac{19}{\sqrt{3.6 \cdot 114}} = \frac{19}{20.2583} = 0.938$ [1] · starker positiver linearer Zusammenhang: Mehr Lernzeit geht mit höherer Punktzahl einher [1]. (Bei $r = 0.5$: mittlerer positiver linearer Zusammenhang.)

(c) $b = \frac{s_{xy}}{s_x^2} = \frac{19}{3.6} = \frac{95}{18} = 5.278$ [1.5] · $a = \bar{y} - b\bar{x} = 36 - 5.2778 \cdot 5 = \frac{173}{18} = 9.611$ [1.5] → $\hat{y} = 9.611 + 5.278x$.

(d) $\hat{y}(6) = 9.611 + 5.278 \cdot 6 = \frac{743}{18} = 41.278$ Punkte [1] · Aussage falsch: Regression/Korrelation zeigt nur einen (linearen) Zusammenhang, keine Kausalität; außerdem beschreibt die Gerade nur den Durchschnitt (Streuung, nur 5 Beobachtungen) – „garantiert“ gilt nicht [1].

Aufgabe 4 (6 P)

$$\bar{B} = \{1, 4, 6, 8, 9, 10\}, \bar{A} = \{3, 4, 6, 7, 10\}.$$

(a) $A \cap \bar{B} = \{1, 8, 9\} \rightarrow |A \cap \bar{B}| = 3$ [1] · $\bar{A} \cup B = \{2, 3, 4, 5, 6, 7, 10\} \rightarrow |\bar{A} \cup B| = 7$ (Kontrolle: $\bar{A} \cup B = \overline{A \cap \bar{B}}$, also $10 - 3$) [1].

(b) $P(A | \bar{B}) = \frac{|A \cap \bar{B}|}{|\bar{B}|} = \frac{3}{6} = \frac{1}{2}$ [1 Notation, 1 Wert].

(c) $P(A) = \frac{5}{10} = 0.5$, $P(B) = \frac{4}{10} = 0.4$, $P(A \cap B) = P(\{2, 5\}) = \frac{2}{10} = 0.2$ [1] · $P(A) \cdot P(B) = 0.2 = P(A \cap B) \rightarrow$ stochastisch unabhängig [1].

Aufgabe 5 (10 P)

Gegeben ist $P(\text{Dienst} \mid \text{pünktlich})$ bzw. $P(\text{Dienst} \mid \text{verspätet})$ – also ist der Baum zuerst nach pünktlich/verspätet verzweigt.

(a) $P(V) = 1 - 0.8 = 0.2$ [1] · $P(C \mid \bar{V}) = 1 - 0.7 - 0.25 = 0.05$ [1] · $P(C \mid V) = 1 - 0.3 - 0.4 = 0.3$ [1].

(b) $P(C) = P(C \mid \bar{V})P(\bar{V}) + P(C \mid V)P(V) = 0.05 \cdot 0.8 + 0.3 \cdot 0.2 = 0.04 + 0.06 = 0.1$ [2].

(c) $P(V \mid C) = \frac{P(C \mid V)P(V)}{P(C)} = \frac{0.06}{0.1} = 0.6$ [2].

(d) $P(A) = 0.7 \cdot 0.8 + 0.3 \cdot 0.2 = 0.56 + 0.06 = 0.62$ [1] · $P(\bar{V} \mid A) = \frac{0.56}{0.62} = 0.903$ [1].

(e) Nein: $P(\bar{V} \mid A) = 0.903 \neq 0.8 = P(\bar{V}) \rightarrow$ abhängig [1].

Aufgabe 6 (8 P)

(a) $\int_0^2 c x dx = c \left[\frac{x^2}{2} \right]_0^2 = 2c \stackrel{!}{=} 1 \rightarrow c = \frac{1}{2}$ [2].

(b) $E(X) = \int_0^2 x \cdot \frac{x}{2} dx = \left[\frac{x^3}{6} \right]_0^2 = \frac{8}{6} = \frac{4}{3} = 1.333$ [2].

(c) $P(X \leq 1) = \int_0^1 \frac{x}{2} dx = \left[\frac{x^2}{4} \right]_0^1 = \frac{1}{4}$ [1].

(d) $Y \sim B(n = 5, p = \frac{1}{4})$ [1] · $P(Y \geq 4) = \binom{5}{4} \left(\frac{1}{4}\right)^4 \frac{3}{4} + \left(\frac{1}{4}\right)^5 = \frac{15}{1024} + \frac{1}{1024} = \frac{16}{1024} = \frac{1}{64} = 0.016$ [2].

Aufgabe 7 (10 P)

(a) $L(\theta) = \prod_{i=1}^n \theta x_i^{\theta-1} = \theta^n \prod_{i=1}^n x_i^{\theta-1}$ [1] · $\ell(\theta) = \log L(\theta) = n \log \theta + (\theta - 1) \sum_{i=1}^n \log x_i$ [3].

(b) $\ell'(\theta) = \frac{n}{\theta} + \sum \log x_i \stackrel{!}{=} 0$ [1.5] $\rightarrow \hat{\theta} = -\frac{n}{\sum_{i=1}^n \log x_i}$ [1.5] (positiv, da $0 < x_i < 1 \Rightarrow \log x_i < 0$).

(c) $\ell''(\theta) = -\frac{n}{\theta^2} < 0$ für alle $\theta > 0$ [1] $\rightarrow$ Maximum [1].

(d) $\sum \log x_i = -0.6931 - 0.2231 - 0.1054 - 0.5108 = -1.5325 \rightarrow \hat{\theta} = \frac{4}{1.5325} = 2.610$ [1]. *Achtung: ln benutzen, nicht log₁₀!*

Aufgabe 8 (5 P)

(a) $E(\hat{\mu}_1) = \frac{1}{4}(\mu + 2\mu + \mu) = \mu \rightarrow$ erwartungstreu [1.5] · $E(\hat{\mu}_2) = \frac{1}{2} \cdot 3\mu = \frac{3}{2}\mu \neq \mu \rightarrow$ verzerrt, $Bias = \frac{3}{2}\mu - \mu = \frac{\mu}{2}$ [1.5].

(b) Wegen Unabhängigkeit: $Var(\hat{\mu}_1) = \frac{1}{16}(\sigma^2 + 4\sigma^2 + \sigma^2) = \frac{6}{16}\sigma^2 = \frac{3}{8}\sigma^2 = 0.375\sigma^2$ [1] · $Var(\bar{X}) = \frac{\sigma^2}{3} \approx 0.333\sigma^2$ ist kleiner, beide sind erwartungstreu $\rightarrow \bar{X}$ ist vorzuziehen (effizienter, kleinerer MSE) [1].

Aufgabe 9 (8 P)

(a) Vermutung „zu wenig“ gehört in $H_1: H_0: \mu \geq 500$ gegen $H_1: \mu < 500$ [2].

(b) $Z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}} = \frac{497.5 - 500}{4/\sqrt{16}} = \frac{-2.5}{1} = -2.5$ [1] · unter H_0 (am Rand $\mu = 500$): $Z \sim N(0, 1)$ [1].

(c) Ablehnungsbereich $(-\infty; -1.645)$; $-2.5 < -1.645 \rightarrow H_0$ wird abgelehnt [1] · Zum Niveau 5 % ist statistisch abgesichert, dass im Mittel weniger als 500 g abgefüllt werden (p-Wert $\Phi(-2.5) = 0.006$) [1].

(d) $\bar{x} \pm z_{0.975} \frac{\sigma}{\sqrt{n}} = 497.5 \pm 1.96 \cdot 1 \rightarrow [495.540; 499.460]$ [2].

Teil B (R-Musterlösung)

```
## a) [2]
```

```
setwd(path.expand("~/"))
```

```
## b) [4] (sep="," und dec="." wie in der Datei; read.table mit header=TRUE geht auch)
```

```
d <- read.csv("Bibliothek.csv", sep="," , dec=".", header=TRUE)
```

```
head(d)
```

#	Besuch	Fach	Bereich	Dauer	Buecher
# 1	B01	Jura	Cafe	1.69	0
# 2	B02	Medizin	Gruppenraum	4.26	3
# 3	B03	Jura	Lesesaal	0.79	2

```

# 4    B04      Jura    Lesesaal 3.88    1
# 5    B05      Medizin Cafe    2.98    0
# 6    B06 Informatik Lesesaal 2.11    3

## c) [4]
typeof(d$Fach)      # [1] "character"
typeof(d$Buecher)   # [1] "integer"
# Antwort: Fach ist ein character-Objekt, Buecher ist numerisch vom Typ integer (ganze Zahlen).

## d) [4]
round(mean(d$Dauer), 3) # [1] 2.762
round(sd(d$Dauer), 3)   # [1] 1.437
# Antwort: Das arithmetische Mittel der Aufenthaltsdauer beträgt 2.762 Stunden,
# der unverzerrte Schätzer der Standardabweichung 1.437 Stunden.

## e) [7] freq=FALSE (Dichte), breaks, right=FALSE (Intervalle links geschlossen), main, xlab,
ylab, pdf()/dev.off()
pdf("Histogramm.pdf")
hist(d$Dauer, freq=FALSE, breaks=c(0,1,2,3,5,8), right=FALSE,
     main="Sitz 00, Matr.Nr. 12345678, Aufgabenteil e)",
     xlab="Aufenthaltsdauer in Stunden", ylab="Dichte")
dev.off()
# Kontrolle: Anzahlen 5, 13, 20, 18, 4; Dichten 0.0833, 0.2167, 0.3333, 0.1500, 0.0222

## f) [4]
round(tapply(d$Dauer, d$Fach, mean), 3)
# Informatik      Jura      Medizin      Wiwi
#      2.321      3.593      2.808      2.262
# Antwort: Jura-Studierende bleiben im Durchschnitt am längsten (3.593 Stunden).

## g) [6]
d$iL2 <- dpois(d$Buecher, lambda=2)
head(d)          # neue Spalte iL2: 0.1353353, 0.1804470, 0.2706706, ...
prod(d$iL2)      # [1] 1.28207e-46
# Antwort: Die Likelihood aller Beobachtungen unter  $\lambda = 2$  beträgt  $L(\lambda=2) = 1.282 \times 10^{(-46)}$ .

## h) [8] Funktion [3], Berechnung für alle 7 Werte [3], ML-Schätzer + Satz [2]
Likelihood.pois <- function(lambda, x){
  L <- prod(dpois(x, lambda))
  return(L)
}
for(lambda in seq(1.5, 3, by=0.25)){
  print(c(lambda, Likelihood.pois(lambda, d$Buecher)))
}
# 1.50: 7.847123e-50
# 1.75: 1.211646e-47
# 2.00: 1.282070e-46
# 2.25: 1.751146e-46 <- größter Wert
# 2.50: 4.757502e-47
# 2.75: 3.499539e-48
# 3.00: 8.751984e-50
# Antwort: Die Likelihood ist bei  $\lambda = 2.25$  maximal; der ML-Schätzer aus der gegebenen Menge ist  $\lambda^* = 2.25$ .
# (Kontrolle: der exakte ML-Schätzer wäre  $\text{mean}(d\$Buecher) = 2.167$ , und 2.25 liegt am nächsten
# im Sinne der Likelihood.)

## i) [6] Hypothesen [2], richtiger Befehl mit alternative="greater" [2], p-Wert + Entscheidung [2]
t.test(d$Dauer, mu=2.5, alternative="greater")
# t = 1.4116, df = 59, p-value = 0.08166
# alternative hypothesis: true mean is greater than 2.5
# Antwort:  $H_0: \mu \leq 2.5$  gegen  $H_1: \mu > 2.5$ . Der p-Wert beträgt 0.082 und ist größer als  $\alpha = 0.05$ ,

```

daher wird H_0 nicht abgelehnt. Die Behauptung, dass Studierende im Mittel länger als 2.5 Stunden
bleiben, kann zum Niveau 5 % statistisch nicht abgesichert werden.