

Probeklausur 3 Statistik (Teil B)

💡 **LERNHILFE** – nur in der Übung, nicht in der echten Klausur

Diese Übungsversion enthält gelbe Lernhilfe-Kästen mit den passenden R-Befehlen – ohne Ergebnisse. Erst selbst versuchen, dann nachsehen!

Statistik und Data Science I · Probeklausur 3 für den Zweittermin (09.10.2026) · R am Computer

Übungsklausur zur Vorbereitung – keine offizielle Klausur

Name, Vorname

Matrikel-Nr.

Raum

Platz-Nr.

Bearbeitungszeit: 60 Minuten · **Anzahl der Aufgaben:** 1 · **Gesamtpunktzahl:** 45

Zugelassene Hilfsmittel: zugelassener Taschenrechner · Schreibutensilien · ein (auch beidseitig) handschriftlich beschriebenes DIN-A4-Blatt, das mit Matrikelnummer, Raum und Platznummer gekennzeichnet ist.

Teilaufgabe	a	b	c	d	e	f	g	h	i	Σ
Punkte	2	4	4	4	7	4	6	8	6	45
erreicht										

Hinweise

- Bei der Bewertung werden ausschließlich die auf ILIAS eingereichten Lösungen berücksichtigt. Speichern Sie Ihre Antworten und insbesondere Ihr R-Skript regelmäßig. Arbeiten Sie ausschließlich im Ordner *Dokumente*.
- Geben Sie pro Teilaufgabe (1) den **R-Code und R-Output** und (2) – falls gefragt – eine **inhaltliche Antwort in vollen Sätzen** (ohne R-Code) an. Bei allen Antworten wird erwartet, dass Sie Ihren gesamten Lösungsweg aufzeigen.
- Numerische Ergebnisse (auch jene in Antwortsätzen) sind – sofern nicht anders angegeben – auf **drei Nachkommastellen** zu runden. Nutzen Sie zum Runden stets einen geeigneten R-Befehl. Es gilt die Dezimalpunkt-Notation.
- Grafiken: Im Titel (Option `main`) müssen der Aufgabenteil, Ihre Matrikelnummer und Ihre Sitzplatznummer stehen. Die Achsen sind der Aufgabenstellung entsprechend zu beschriften.
- Folgefehler werden berücksichtigt. Fehlende Objekte aus vorherigen Teilaufgaben sind bei Bedarf mit nachvollziehbarem R-Code anderweitig zu erstellen. Fehlerhaften R-Code, der nicht Teil der Antwort ist, löschen Sie aus der Antwort.

Zu Hause: Schreiben Sie statt in ILIAS alles in ein R-Skript `Probeklausur3_B.R`: unter jede Teilaufgabe den Code, den Output als Kommentar (`#`) und den Antwortsatz als Kommentar. Die Datei `Fitness.csv` liegt im Lernpaket im Ordner *uebungsdaten* – kopieren Sie sie in Ihren Arbeitsordner.

Aufgabe 1

(45 Punkte)

Das Hochschulsportzentrum Göttingen betreibt drei Fitnessstudios und möchte sein Angebot verbessern. Dazu wurden die Daten von 80 zufällig ausgewählten Mitgliedern erhoben. Die Daten sind in der Datei `Fitness.csv` abgespeichert. Diese Datei ist auf Ihrem lokalen Laufwerk in dem Ordner *Dokumente* hinterlegt. In diesem Ordner sollten Sie auch mit R arbeiten und jegliche Dateien (Skripte, Abbildungsdateien etc.), welche Sie abspeichern, hinterlegen.

Der Datensatz enthält folgende Variablen:

Variablenbezeichnung	Erläuterung
Mitglied	Kennung des Mitglieds
Studio	Standort des Studios (Nord, Sued, Zentrum)
Abo	Art der Mitgliedschaft (Basic, Premium)
Minuten	durchschnittliche Trainingsdauer pro Besuch in Minuten
Besuche	Anzahl der Besuche in der letzten Woche
Wartezeit	Wartezeit in Minuten, bis beim letzten Besuch das gewünschte Gerät frei war

- (a) Setzen Sie mittels `setwd(path.expand("~/"))` Ihr Working Directory, um in dem lokalen Ordner *Dokumente* zu arbeiten.

Nutzen Sie für Ihre Antwort das Kästchen zu Frage 1 in ILIAS.

(2 P)

- (b) Speichern Sie die in der Datei hinterlegten Daten als Data-Frame-Objekt `d` in R ab und geben Sie die ersten 6 Zeilen des Data-Frame-Objektes wieder.

Nutzen Sie für Ihre Antwort das Kästchen zu Frage 2 in ILIAS.

(4 P)

💡 LERNHILFE – nur in der Übung, nicht in der echten Klausur

`d <- read.csv("Fitness.csv", sep = ",", dec = ".", header = TRUE)` und `head(d)`. Vorher die CSV ansehen: Trennzeichen „“ oder „“?

- (c) Ermitteln Sie unter Einbezug eines passenden R-Befehls die Objekttypen der Variablen `Studio` und `Besuche` im Objekt `d`.

Nutzen Sie für Ihre Antwort die Kästchen zu den Fragen 3 und 4 in ILIAS.

(4 P)

💡 LERNHILFE – nur in der Übung, nicht in der echten Klausur

`class(d$Studio)`, `class(d$Besuche)` (oder `typeof()`, `str(d)`). Antwortsatz: „... ist vom Typ character / integer (ganze Zahlen).“

- (d) Berechnen und nennen Sie den Median und den Interquartilsabstand der Variable `Minuten` (mit den Standardeinstellungen von R). Runden Sie Ihr Ergebnis auf drei Nachkommastellen.

Nutzen Sie für Ihre Antwort die Kästchen zu den Fragen 5 und 6 in ILIAS.

(4 P)

💡 LERNHILFE – nur in der Übung, nicht in der echten Klausur

`round(median(d$Minuten), 3)`, `round(IQR(d$Minuten), 3)`. Antwortsatz mit beiden Zahlen.

- (e) Erstellen Sie in **einer** Grafik nebeneinander Boxplots der Variable `Minuten` für die drei Studios. Die grafische Darstellung soll den Titel `Sitz ..., Matr.Nr. ..., Aufgabenteil e)` tragen. Die x-Achse soll mit `Studio` und die y-Achse mit `Trainingsdauer in Minuten` betitelt werden. Speichern Sie Ihre Grafik anschließend als .pdf-Datei unter `Boxplot.pdf` im Working Directory ab und laden Sie diese Datei hoch. In welchem Studio ist die mittlere Trainingsdauer (Median) am höchsten?

Nutzen Sie für Ihre Antwort die Kästchen zu den Fragen 7 und 8 in ILIAS.

(7 P)

💡 LERNHILFE – nur in der Übung, nicht in der echten Klausur

```
Gerüst: pdf("Boxplot.pdf") → boxplot(Minuten ~ Studio, data = d, main = "Sitz ..., Matr.Nr. ..., Aufgabenteil e)", xlab = "Studio", ylab = "Trainingsdauer in Minuten") → dev.off()
Mediane je Studio:
tapply(d$Minuten, d$Studio, median)
dev.off() unutursan PDF boş kalır.
```

- (f) Erstellen Sie eine Kontingenztafel der absoluten Häufigkeiten von `Studio` und `Abo`. Berechnen Sie anschließend für jedes Studio den Anteil der Premium-Mitglieder (bedingte relative Häufigkeiten). In welchem Studio ist der Premium-Anteil am höchsten?

Nutzen Sie für Ihre Antwort die Kästchen zu den Fragen 9 und 10 in ILIAS.

(4 P)

💡 LERNHILFE – nur in der Übung, nicht in der echten Klausur

```
tab <- table(d$Studio, d$Abo), dann zeilenweise Anteile: round(prop.table(tab, margin = 1), 3) → Spalte „Premium“ vergleichen.
```

- (g) Gehen Sie davon aus, dass die Wartezeit, im Folgenden X , exponentialverteilt ist, d. h. $X \sim \text{Exp}(\lambda)$. Nehmen Sie vorerst an, dass $\lambda = 0.4$, und ergänzen Sie das Data-Frame-Objekt `d` um eine Spalte `iL04`, in der Sie die durch die Dichtefunktion gegebenen individuellen Likelihoods für jede einzelne Beobachtung vermerken. Berechnen Sie auf Grundlage dieser Spalte die Likelihood aller gegebenen Beobachtungen. Notieren Sie Ihre Antwort in der Form $X \times 10^Y$, wobei X eine auf drei Nachkommastellen zu rundende reelle Zahl und Y eine ganze Zahl ist.

Nutzen Sie für Ihre Antwort die Kästchen zu den Fragen 11 und 12 in ILIAS.

(6 P)

💡 LERNHILFE – nur in der Übung, nicht in der echten Klausur

```
Exponentialdichte in R: dexp(x, rate = λ). d$iL04 <- dexp(d$Wartezeit, rate = 0.4), Likelihood = Produkt: prod(d$iL04). Aus 8.3e-64 wird  $8.3 \times 10^{-64}$ .
```

- (h) Schreiben Sie eine Funktion `Likelihood.exp(lambda, x)`, welche die Likelihood für einen beliebigen Parameter λ und gegebene Beobachtungen `x` bestimmt. Berechnen Sie auf Grundlage dieser Funktion die Likelihood für alle Werte $\lambda \in \{0.30, 0.35, 0.40, 0.45, 0.50, 0.55, 0.60\}$ und bestimmen Sie aus dieser Menge den Maximum-Likelihood-Schätzer für λ . Vergleichen Sie Ihr Ergebnis mit dem analytischen ML-Schätzer $\hat{\lambda} = 1/\bar{x}$.

Nutzen Sie für Ihre Antwort die Kästchen zu den Fragen 13 und 14 in ILIAS.

(8 P)

💡 LERNHILFE – nur in der Übung, nicht in der echten Klausur

```
Likelihood.exp <- function(lambda, x) { return(prod(dexp(x, rate = lambda))) }; Gitter: lam <- seq(0.30, 0.60, by = 0.05); Ls <- sapply(lam, Likelihood.exp, x = d$Wartezeit); ML: lam[which.max(Ls)]; Vergleich: 1/mean(d$Wartezeit).
```

- (i) Die Studioleitung behauptet, dass die mittlere Trainingsdauer **weniger als 70 Minuten** beträgt. Gehen Sie davon aus, dass die Trainingsdauer normalverteilt ist mit unbekannter Varianz. Überprüfen Sie die Behauptung mit einem geeigneten Test in R zum Signifikanzniveau $\alpha = 0.05$. Nennen Sie das Hypothesenpaar, den p-Wert und Ihre Testentscheidung im Sachzusammenhang.

Nutzen Sie für Ihre Antwort die Kästchen zu den Fragen 15 und 16 in ILIAS.

(6 P)

💡 LERNHILFE – nur in der Übung, nicht in der echten Klausur

```
Behauptung „weniger als 70“ →  $H_1: \mu < 70, H_0: \mu \geq 70$ . t.test(d$Minuten, mu = 70, alternative = "less"). Entscheidung: p-Wert < 0.05 →  $H_0$  ablehnen, sonst nicht ablehnen. Satz im Sachzusammenhang!  $p < \alpha$  ise  $H_0$  reddedilir.
```