

Probeklausur Statistik (Teil A)

Statistik und Data Science I · Übungsklausur „Tag 1“: Deskriptive Statistik (V01–V03)

Name, Vorname

Matrikel-Nr.

Raum

Platz-Nr.

Bearbeitungszeit: 85 Minuten · **Anzahl der Aufgaben:** 6 · **Gesamtpunktzahl:** 65

Zugelassene Hilfsmittel: zugelassener Taschenrechner · Schreibutensilien · ein (auch beidseitig) handschriftlich beschriebenes DIN-A4-Blatt, das mit Matrikelnummer, Raum und Platznummer gekennzeichnet ist und mit der Klausur abgegeben werden muss.

Aufgabe	1	2	3	4	5	6	Σ
Punkte	8	12	11	12	10	12	65
erreicht							

Hinweise

- Es darf nur mit Kugelschreiber oder Tinte geschrieben und gezeichnet werden. Bleistift sowie Angaben in Grün oder Rot werden nicht gewertet.
- Lesen Sie genau, wonach gefragt wird und wie die Lösung anzugeben ist. Es gilt die **Dezimalpunkt-Notation**.
- Vereinfachen Sie alle Ergebnisse. Nicht ganzzahlige Ergebnisse als **vollständig gekürzte Brüche** oder auf **drei Nachkommastellen** kaufmännisch gerundet; Zwischenergebnisse auf mindestens vier Nachkommastellen.
- Tragen Sie nur Ihr Endergebnis in die Lösungskästchen ein, es sei denn, Sie werden aufgefordert, Ihren Lösungsweg anzugeben.
- Lösungskästchen dürfen nur eine eindeutige Antwort enthalten. Geben Sie niemals mehrere Lösungsalternativen an; streichen Sie falsche Angaben.
- Alles außerhalb der Lösungskästchen wird nicht gewertet, es sei denn, Sie kennzeichnen es eindeutig. Nebenrechnungen werden nicht korrigiert.
- Ist eine Aufgabe Ihrer Meinung nach nicht lösbar, schreiben Sie „nicht lösbar“ in das Kästchen und begründen Sie dies.

Zeitrichtwert: ca. 1.3 Minuten pro Punkt. Stoppuhr stellen!

Aufgabe 1

(8 Punkte)

Ein Fahrradverleih in Göttingen möchte sein Angebot verbessern und befragt Kund*innen. Erhoben werden folgende Merkmale:

(i) Leihdauer in Minuten · (ii) Anzahl der Ausleihen im letzten Monat · (iii) Stadtteil der Wohnung · (iv) Zufriedenheit auf einer Skala von 1 (sehr unzufrieden) bis 5 (sehr zufrieden)

(a) Geben Sie für jedes der vier Merkmale das Skalenniveau an und ob es diskret oder stetig ist.

(4 P)

Lösung

(b) Aus jedem der sieben Göttinger Stadtteile werden zufällig 30 Kund*innen ausgewählt, damit jeder Stadtteil in der Stichprobe vertreten ist. Wie heißt dieses Stichprobenverfahren?

(2 P)

Lösung

(c) Welche Lagemaße sind für das Merkmal Zufriedenheit sinnvoll? Begründen Sie kurz.

(2 P)

Lösung

Aufgabe 2

(12 Punkte)

25 Kund*innen wurden nach der Anzahl ihrer Ausleihen im letzten Monat gefragt:

Anzahl Ausleihen a_j	0	1	2	3	5
h_j	3	7	8	5	2
f_j					
H_j					
F_j					

(a) Vervollständigen Sie die Tabelle.

(3 P)

- (b)** Stellen Sie die empirische Verteilungsfunktion $\hat{F}(x)$ als Funktion mit Fallunterscheidung auf und skizzieren Sie sie.

(4 P)

Lösung

- (c)** Bestimmen Sie den Anteil der Kund*innen mit (i) mehr als einer Ausleihe und (ii) mindestens drei Ausleihen.

(2 P)

Lösung

- (d)** Berechnen Sie Modus, Median und arithmetisches Mittel.

(3 P)

Lösung

Aufgabe 3

(11 Punkte)

Für 80 Ausleihen wurde die Leihdauer (in Minuten) klassiert erfasst:

Klasse	[0, 15)	[15, 30)	[30, 60)	[60, 120]
Anzahl	20	28	24	8

(a) Berechnen Sie die Höhen der Säulen eines (normierten) Histogramms.

(3 P)

Lösung

(b) Schätzen Sie mithilfe des Histogramms den Anteil der Ausleihen mit einer Dauer zwischen 20 und 45 Minuten. Welche Annahme treffen Sie?

(3 P)

Lösung

(c) Bestimmen Sie das arithmetische Mittel der klassierten Daten. Geben Sie Ihren Lösungsweg an.

(3 P)

Lösung

(d) Ist die Aussage „Die Modalklasse ist immer die Klasse mit der höchsten Säule im Histogramm“ korrekt? Begründen Sie.

(2 P)

Lösung

Aufgabe 4

(12 Punkte)

An einer Ausleihstation wurden die Wartezeiten (in Minuten) von 10 Kund*innen notiert:

```
> Wartezeit  
[1]  2  5  3  8  4  3  6 25  4  5
```

Hinweis: $\sum x_i = 65$, $\sum x_i^2 = 829$.

(a) Berechnen Sie arithmetisches Mittel und Median.

(2 P)

Lösung

- (b)** Bestimmen Sie das untere und das obere Quartil nach der Definition aus der Vorlesung sowie den Interquartilsabstand.

(3 P)

Lösung

- (c)** Berechnen Sie die empirische Varianz s^2 , die unverzerrte Varianz s_*^2 und die Standardabweichung s . Geben Sie Ihren Lösungsweg an.

(3 P)

Lösung

- (d)** Gibt es Ausreißer nach der 1.5-IQR-Regel? Wo enden die Whisker des Boxplots?

(2 P)

Lösung

- (e)** Die Wartezeiten werden in Sekunden angegeben. Wie lauten der neue Mittelwert, die neue Varianz und die neue Standardabweichung?

(2 P)

Lösung

Aufgabe 5

(10 Punkte)

Von 300 befragten Kund*innen nutzen 120 ein E-Bike (E), die übrigen ein normales Fahrrad (N). 90 der E-Bike-Nutzenden sind älter als 40 Jahre (Ü40). Insgesamt sind 150 der Befragten höchstens 40 Jahre alt (U40).

- (a) Erstellen Sie die vollständige Kontingenztafel der absoluten Häufigkeiten (inkl. Randhäufigkeiten). (3 P)

Lösung

- (b) Berechnen Sie den Anteil der E-Bike-Nutzenden unter den Ü40 und unter den U40. (2 P)

Lösung

- (c) Deutet Ihr Ergebnis aus (b) auf einen Zusammenhang zwischen Alter und Fahrradtyp hin? Begründen Sie. (1 P)

Lösung

- (d) Berechnen Sie die bei Unabhängigkeit erwarteten Häufigkeiten und den χ^2 -Koeffizienten. (4 P)

Lösung

Aufgabe 6

(12 Punkte)

An sechs Tagen wurden die Tageshöchsttemperatur X (in °C) und der Eisverkauf Y (in hundert Kugeln) eines Eiscafés neben der Station erfasst:

Tag v	1	2	3	4	5	6
x_v	18	22	25	20	28	30
y_v	5	7	9	6	12	11

Hinweis: $\sum x = 143$, $\sum y = 50$, $\sum x^2 = 3517$, $\sum y^2 = 456$, $\sum xy = 1255$.

(a) Zeichnen Sie ein beschriftetes Streudiagramm.

(2 P)

Lösung

(b) Berechnen Sie die empirische Kovarianz. Geben Sie Ihren Lösungsweg an.

(2 P)

Lösung

(c) Berechnen Sie den Korrelationskoeffizienten nach Bravais-Pearson und interpretieren Sie ihn.

(3 P)

Lösung

(d) Bestimmen Sie den Rangkorrelationskoeffizienten nach Spearman.

(2 P)

Lösung

(e) Die Temperatur wird in °F angegeben ($F = 32 + 1.8 \cdot C$). Wie ändern sich Kovarianz und Korrelation?

(1 P)

Lösung

(f) Das Eiscafé folgert: „Hohe Temperaturen verursachen mehr Eisverkauf, daher sollten wir an kalten Tagen gar nicht öffnen.“ Beurteilen Sie die Schlussfolgerung aus statistischer Sicht.

(2 P)

Lösung

Probeklausur Statistik (Teil B)

R am Computer · Übungsklausur „Tag 1“ · Bearbeitungszeit 35 Minuten · 25 Punkte

- Arbeiten Sie ausschließlich im Ordner *Dokumente*. Speichern Sie Ihr R-Skript regelmäßig.
- Geben Sie pro Teilaufgabe (1) **R-Code und R-Output** und (2) – falls gefragt – eine **inhaltliche Antwort in einem ganzen Satz** an.
- Numerische Ergebnisse (auch in Antwortsätzen) auf **drei Nachkommastellen** runden; nutzen Sie dazu stets einen geeigneten R-Befehl.
- Grafiken: Im Titel (`main`) Aufgabenteil, Matrikelnummer und Sitzplatznummer angeben; Achsen wie verlangt beschriften.
- Fehlerhaften R-Code, der nicht Teil der Antwort ist, löschen. Folgefehler werden berücksichtigt.

Der Fahrradverleih speichert Daten zu 30 Ausleihen in der Datei `Fahrrad.csv`. Die Datei liegt auf Ihrem lokalen Laufwerk im Ordner *Dokumente* (im Lernpaket: Ordner *uebungsdaten*).

Variablen: `Ausleihe` (Kennung), `Station` (Ausleihstation), `Typ` (E-Bike oder Normal), `Dauer` (Leihdauer in Minuten), `Km` (gefahrte Kilometer), `Preis` (in Euro).

Hinweis: Schauen Sie sich die Datei vor dem Einlesen an – Trennzeichen und Dezimalzeichen sind nicht dieselben wie in `Taverne.csv`!

(a) Setzen Sie mittels `setwd(path.expand("~/"))` Ihr Working Directory, speichern Sie die Daten als Data-Frame-Objekt `d` und geben Sie die ersten 6 Zeilen wieder. **(3 P)**

(b) Ermitteln Sie unter Einbezug eines passenden R-Befehls die Objekttypen der Variablen `Station` und `Dauer`. **(3 P)**

(c) Berechnen und nennen Sie das arithmetische Mittel und den unverzerrten Schätzer der Standardabweichung der Variable `Dauer`. **(4 P)**

(d) Erstellen Sie ein normiertes Histogramm der Variable `Dauer` mit den Intervallen $[0, 15)$, $[15, 30)$, $[30, 60)$, $[60, 120)$. Titel: „Sitz ..., Matr.Nr. ..., Aufgabenteil d)“, x-Achse „Leihdauer in Minuten“, y-Achse „Dichte“. Speichern Sie die Grafik als `Histogramm.pdf`. **(7 P)**

(e) Bestimmen Sie den Median und den Interquartilsabstand der Variable `Km`. **(2 P)**

(f) Berechnen Sie den durchschnittlichen Preis für jeden Fahrradtyp. Welcher Typ ist im Durchschnitt teurer? **(3 P)**

(g) Wie stark ist der lineare Zusammenhang zwischen `Dauer` und `Preis`? Berechnen und interpretieren Sie eine geeignete Maßzahl. **(3 P)**