

Musterlösung · Probeklausur Tag 1

Punkteverteilung als Orientierung. Folgefehler werden berücksichtigt. Bewertungsschlüssel: 58–65 P $\approx$ 1,0–1,3 · 52–57 $\approx$ 1,7–2,0 · 45–51 $\approx$ 2,3–2,7 · 39–44 $\approx$ 3,0–3,3 · 33–38 $\approx$ 3,7–4,0 (grobe Orientierung, nicht offiziell).

Aufgabe 1 (8 P)

- (a) je 1 P: (i) Leihdauer: kardinal, stetig · (ii) Anzahl Ausleihen: kardinal, diskret · (iii) Stadtteil: nominal, diskret · (iv) Zufriedenheit 1–5: ordinal, diskret.
- (b) Geschichtete Stichprobe (aus jeder Schicht/jedem Stadtteil wird zufällig gezogen). *Nicht* Klumpen – dort würden ganze Stadtteile gezogen und alle befragt.
- (c) Modus und Median (und Quantile), da das Merkmal ordinal ist: Die Werte lassen sich ordnen, die Abstände sind aber nicht sinnvoll interpretierbar – das arithmetische Mittel ist daher nicht sinnvoll.

Aufgabe 2 (12 P)

a_j	0	1	2	3	5
f_j	0.12	0.28	0.32	0.20	0.08
H_j	3	10	18	23	25
F_j	0.12	0.40	0.72	0.92	1

- (b) $\hat{F}(x) = 0$ für $x < 0$; 0.12 für $0 \leq x < 1$; 0.40 für $1 \leq x < 2$; 0.72 für $2 \leq x < 3$; 0.92 für $3 \leq x < 5$; 1 für $x \geq 5$. Skizze: Treppe, • links, ○ rechts, keine senkrechten Linien, Achsen „Anzahl Ausleihen“ / „ $\hat{F}(x)$ “ (2 P Formel, 2 P Skizze).
- (c) (i) mehr als 1: $1 - F(1) = 1 - 0.40 = 0.6$ · (ii) mindestens 3: $1 - F(2) = 1 - 0.72 = 0.28$.
- (d) Modus = 2 · Median: $n = 25 \rightarrow x_{(13)}$; $H_2 = 10 < 13 \leq H_3 = 18 \rightarrow \text{Median} = 2 \cdot \bar{x} = \frac{0 \cdot 3 + 1 \cdot 7 + 2 \cdot 8 + 3 \cdot 5 + 5 \cdot 2}{25} = \frac{48}{25} = 1.92$.

Aufgabe 3 (11 P)

- (a) $f = 0.25, 0.35, 0.30, 0.10 \rightarrow$ Höhen: $0.25/15 = 0.017$ (1/60), $0.35/15 = 0.023$ (7/300), $0.30/30 = 0.01$, $0.10/60 = 0.002$ (1/600). Kontrolle: Σ Fläche = 1.
- (b) $[20, 30)$: $10 \cdot \frac{7}{300} = 0.2333$; $[30, 45)$: $15 \cdot 0.01 = 0.15 \rightarrow \text{Anteil} \approx \mathbf{0.383}$. Annahme: Die Werte sind innerhalb der Klassen gleichmäßig verteilt.
- (c) Mitten 7.5, 22.5, 45, 90: $\bar{x}_K = 0.25 \cdot 7.5 + 0.35 \cdot 22.5 + 0.30 \cdot 45 + 0.10 \cdot 90 = 1.875 + 7.875 + 13.5 + 9 = 32.25$ Minuten.
- (d) Nein, im Allgemeinen falsch. Die Modalklasse ist die Klasse mit der größten **Häufigkeit** (hier $[15, 30)$ mit 28). Die Säulenhöhe ist f_j/Breite ; bei ungleich breiten Klassen kann eine breite Klasse mit vielen Werten eine niedrigere Säule haben. Hier stimmen beide zufällig überein.

Aufgabe 4 (12 P)

Sortiert: 2, 3, 3, 4, 4, 5, 5, 6, 8, 25.

- (a) $\bar{x} = 65/10 = 6.5$ · Median = $(x_{(5)} + x_{(6)})/2 = (4 + 5)/2 = 4.5$.
- (b) $10 \cdot 0.25 = 2.5 \rightarrow \text{Platz 3} \rightarrow x_{0.25} = 3 \cdot 10 \cdot 0.75 = 7.5 \rightarrow \text{Platz 8} \rightarrow x_{0.75} = 6$ · IQR = 3.
- (c) $s^2 = \frac{829}{10} - 6.5^2 = 82.9 - 42.25 = 40.65$ · $s_*^2 = \frac{10}{9} \cdot 40.65 = 45.167$ · $s = \sqrt{40.65} = 6.376$.
- (d) Grenzen: $3 - 4.5 = -1.5$ und $6 + 4.5 = 10.5$. **25 ist ein Ausreißer**. Unterer Whisker bei 2, oberer Whisker bei 8.
- (e) Faktor 60: $\bar{x} = 390$ Sekunden · $s^2 = 60^2 \cdot 40.65 = 146340$ Sekunden² · $s = 60 \cdot 6.376 = 382.544$ Sekunden.

Aufgabe 5 (10 P)

	Ü40	U40	Σ
E-Bike	90	30	120
Normal	60	120	180
Σ	150	150	300

(b) Unter Ü40: $90/150 = 0.6$ · unter U40: $30/150 = 0.2$.

(c) Ja: 60 % der Über-40-Jährigen nutzen ein E-Bike, aber nur 20 % der Jüngeren. Die bedingten Anteile unterscheiden sich deutlich → Zusammenhang zwischen Alter und Fahrradtyp.

(d) Erwartet: $\frac{120 \cdot 150}{300} = 60$ (E, Ü40), 60 (E, U40), $\frac{180 \cdot 150}{300} = 90$ (N, Ü40), 90 (N, U40). Differenzen ± 30 .

$\chi^2 = \frac{30^2}{60} + \frac{30^2}{60} + \frac{30^2}{90} + \frac{30^2}{90} = 15 + 15 + 10 + 10 = 50 \rightarrow$ deutlicher Zusammenhang.

Aufgabe 6 (12 P)

(a) x-Achse „Temperatur (°C)“, y-Achse „Eisverkauf (hundert Kugeln)“, Titel, 6 Punkte: steigende Punktwolke.

(b) $\bar{x} = 143/6 = 23.833$, $\bar{y} = 50/6 = 8.333$; $s_{xy} = \frac{1255}{6} - 23.833 \cdot 8.333 = 209.167 - 198.611 = 10.556$.

(c) $s_x^2 = \frac{3517}{6} - 23.833^2 = 18.139$, $s_y^2 = \frac{456}{6} - 8.333^2 = 6.556$; $r = \frac{10.556}{\sqrt{18.139 \cdot 6.556}} = \frac{10.556}{10.905} = 0.968$.

„Sehr starker positiver linearer Zusammenhang zwischen Temperatur und Eisverkauf: An wärmeren Tagen wird tendenziell mehr Eis verkauft.“

(d) Ränge x: 1, 3, 4, 2, 5, 6 · Ränge y: 1, 3, 4, 2, 6, 5 · $d = 0, 0, 0, 0, -1, 1 \rightarrow \sum d^2 = 2 \rightarrow r_{Sp} = 1 - \frac{6 \cdot 2}{6 \cdot 35} = 1 - \frac{12}{210} = 0.943$. (Gleiches Ergebnis mit Pearson auf den Rängen.)

(e) $b = 1.8$ (die 32 spielt keine Rolle): Kovarianz $1.8 \cdot 10.556 = 19.0$; Korrelation bleibt 0.968.

(f) Die Daten zeigen nur einen statistischen Zusammenhang; ein Kausalnachweis bräuchte ein Experiment mit Kontrolle weiterer Einflüsse. Mögliche Drittvariablen: Wochenende/Ferien, Sonnenschein, Anzahl Touristen. Zudem schließen sechs Tage nicht aus, dass auch an kalten Tagen Umsatz entsteht – die Schlussfolgerung „gar nicht öffnen“ ist aus den Daten nicht ableitbar.

Teil B (25 P) – R-Code und Output

```
setwd(path.expand("~/"))
d <- read.csv("Fahrrad.csv", sep = ";", dec = ",", header = TRUE)
head(d)
```

	Ausleihe	Station	Typ	Dauer	Km	Preis
1	A01	Altstadt	Normal	12.6	2.4	2.01
2	A02	Altstadt	Normal	43.4	9.1	4.47
3	A03	Altstadt	E-Bike	33.7	11.0	6.06
4	A04	Bahnhof	E-Bike	42.3	11.3	7.34
5	A05	Altstadt	Normal	31.4	5.3	3.51
6	A06	Bahnhof	Normal	9.6	1.9	1.77

(a) Achtung: `sep = ";"` **und** `dec = ","` (deutsches CSV-Format). Mit `dec = "."` würden Dauer, Km, Preis als character eingelesen.

```
str(d)      # oder typeof(d$Station); typeof(d$Dauer)
```

```
$ Station : chr  "Altstadt" "Altstadt" "Altstadt" "Bahnhof" ...
$ Dauer   : num  12.6 43.4 33.7 42.3 31.4 9.6 55.7 69.5 41 54.4 ...
```

(b) „Die Variable Station ist ein character-Objekt, die Variable Dauer ist numerisch (double).“

```
round(mean(d$Dauer), 3)
round(sd(d$Dauer), 3)
```

```
[1] 35.86
[1] 24.259
```

(c) „Das arithmetische Mittel der Leihdauer beträgt 35.86 Minuten, der unverzerzte Schätzer der Standardabweichung 24.259 Minuten.“

```
pdf("Histogramm.pdf")
hist(d$Dauer, breaks = c(0, 15, 30, 60, 120), freq = FALSE, right = FALSE,
     main = "Sitz ..., Matr.Nr. ..., Aufgabenteil d)",
     xlab = "Leihdauer in Minuten", ylab = "Dichte")
dev.off()
```

(d) Häufigkeiten 7, 6, 14, 3 → Dichten 0.0156, 0.0133, 0.0156, 0.0017. Punkte: pdf/dev.off, breaks, freq = FALSE, right = FALSE, Titel, Achsen, Upload.

```
median(d$Km); IQR(d$Km)
```

```
[1] 7.45
[1] 8.35
```

(e) „Der Median der gefahrenen Kilometer beträgt 7.45 km, der Interquartilsabstand 8.35 km.“

```
round(tapply(d$Preis, d$Typ, mean), 3)
```

```
E-Bike Normal
8.354  3.063
```

(f) „E-Bikes sind im Durchschnitt teurer (8.354 € gegenüber 3.063 €).“

```
round(cor(d$Dauer, d$Preis), 3)
```

```
[1] 0.954
```

(g) „Der Korrelationskoeffizient nach Pearson beträgt 0.954; es besteht ein sehr starker positiver linearer Zusammenhang zwischen Leihdauer und Preis.“