

R-Komplettkurs für Teil B · im Klausurformat

Von null bis zur Klausur an einem Tag. Jede Karte: **Aufgabe** (wie in der Klausur) → **So löst du es** → **Kästchen 1: R-Code und R-Output** (echt, aus R) → **Kästchen 2: Antwortsatz**. Tippe jeden Code selbst in RStudio ab. Daten: Taverne.csv (Objekt d) und Fahrrad.csv (Objekt f) aus dem Ordner uebungsdaten – kopiere sie in deinen Ordner Dokumente.

Prozent = geschätzte Wahrscheinlichkeit, dass dieser Aufgabentyp in Teil B (oder als R-Frage in Teil A) vorkommt – nach Probeklausur B 2022, ML-Übungsklausur B, Testaten und R-Skripten der Vorlesung. **≥ 70 %** fast sicher · **30–69 %** häufig · **< 30 %** manchmal.

Tagesplan: 09–10 Abschnitt 0–2 · 10–12 Abschnitt 3–4 · 13–14 Abschnitt 5 · 14–16 Abschnitt 6–7 · 16–17 Abschnitt 8 · 17–18 Probeklausur Teil B auf Zeit.

0 · Bevor du anfängst

So ist Teil B aufgebaut: 60 Minuten, 45 Punkte, eine große Aufgabe mit Teilen (a), (b), (c) ... zu einem Datensatz. Du arbeitest in RStudio, die Antworten trägst du in ILIAS ein. Pro Teilaufgabe gibt es bis zu zwei Kästchen: **Kästchen 1** = R-Code und R-Output (kopieren und einfügen), **Kästchen 2** = Antwortsatz ohne Code, gerundet auf 3 Nachkommastellen.

RStudio bedienen

~100 %

Aufgabe. Öffnen Sie ein neues R-Skript, schreiben Sie einen Befehl hinein und führen Sie ihn aus.

(0 P – aber nötig für alles)

SO LÖST DU ES

1. File → New File → R Script (Strg + Umschalt + N). Oben links ist jetzt dein Skript.
2. Befehl ins Skript schreiben. Cursor in die Zeile setzen und **Strg + Enter** drücken → der Befehl läuft in der Console (unten links).
3. Mehrere Zeilen markieren + Strg + Enter → alle laufen nacheinander.
4. **#** = Kommentar. Alles danach wird nicht ausgeführt.
5. Skript oft speichern (Strg + S) im Ordner Dokumente.
6. Code + Output für ILIAS: in der Console markieren und kopieren.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> 3 + 4      # Kommentar: R als Taschenrechner
[1] 7
> 2^3
[1] 8
> sqrt(16)
[1] 4
```

Aufgabe. Berechnen Sie $10/3$ und geben Sie das Ergebnis auf drei Nachkommastellen gerundet an.

(1 P)

SO LÖST DU ES

1. Immer mit `round(Zahl, 3)` runden – die Klausur verlangt einen R-Befehl zum Runden.
2. Kästchen 1: Code und Output. Kästchen 2: ganzer Satz mit der gerundeten Zahl.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> round(10/3, 3)
[1] 3.333
> round(10/3, digits = 2)
[1] 3.33
```

Lösungskästchen

Kästchen 2 · Antwortsatz

Das Ergebnis beträgt 3.333.

⚠ R zeigt Nullen am Ende nicht (2.5 statt 2.500). Das ist trotzdem korrekt gerundet.

1 · Grundlagen: Objekte, Vektoren, Datentypen

Objekte speichern

~60 %

Aufgabe. Speichern Sie die Zahl 7 im Objekt a und die Zahl 3 im Objekt b. Berechnen Sie a/b und speichern Sie das Ergebnis in q.

(2 P)

SO LÖST DU ES

1. `<-` ist der Zuweisungspfeil: rechts der Wert, links der Name.
2. Den Namen allein ausführen → R zeigt den Inhalt.
3. Groß- und Kleinschreibung zählt: `A` ist nicht `a`.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> a <- 7
> b <- 3
> q <- a / b
> q
[1] 2.333333
```

Aufgabe. Erstellen Sie (i) einen Vektor x mit den Werten 4, 8, 15, 16, 23, 42, (ii) einen Vektor mit den Zahlen 1 bis 20, (iii) die Folge 2, 4, 6, 8 und (iv) einen Vektor mit fünfmal der 0. Bestimmen Sie die Länge und die Summe von x. **(4 P)**

SO LÖST DU ES

1. `c(...)` verbindet Werte zu einem Vektor.
2. `1:20` = alle ganzen Zahlen von 1 bis 20.
3. `seq(von, bis, by = Schritt)` = Folge.
4. `rep(Wert, Anzahl)` = Wiederholung.
5. `length()` = Anzahl Elemente · `sum()` = Summe.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> x <- c(4, 8, 15, 16, 23, 42)
> 1:20
[1] 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20
> seq(2, 8, by = 2)
[1] 2 4 6 8
> rep(0, 5)
[1] 0 0 0 0 0
> length(x)
[1] 6
> sum(x)
[1] 108
```

Aufgabe. Multiplizieren Sie jedes Element von x mit 1.5. Berechnen Sie die Summe der quadrierten Werte von x. **(2 P)**

SO LÖST DU ES

1. R rechnet automatisch mit **jedem** Element – keine Schleife nötig.
2. `x^2` quadriert jedes Element.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> x * 1.5
[1] 6.0 12.0 22.5 24.0 34.5 63.0
> sum(x^2)
[1] 2854
```

Aufgabe. Geben Sie das erste, das dritte und das letzte Element von x aus. Geben Sie alle Werte größer als 10 aus. An welchen Positionen stehen sie? (3 P)

SO LÖST DU ES

1. Eckige Klammern `x[ ]` wählen aus. `x[1]` = erstes Element.
2. `x[c(1, 3)]` = mehrere Positionen. `x[length(x)]` = letztes.
3. `x[x > 10]` = alle Werte, für die die Bedingung TRUE ist.
4. `which(x > 10)` = Positionen.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> x[1]
[1] 4
> x[c(1, 3)]
[1] 4 15
> x[length(x)]
[1] 42
> x > 10
[1] FALSE FALSE TRUE TRUE TRUE TRUE
> x[x > 10]
[1] 15 16 23 42
> which(x > 10)
[1] 3 4 5 6
```

Vergleiche und logische Werte

Aufgabe. Wie viele Werte von x sind größer als 10? Welcher Anteil? Ist 15 in x enthalten? (3 P)

SO LÖST DU ES

1. Vergleiche: `==` gleich, `!=` ungleich, `>`, `>=`, `<`, `<=`.
2. Verknüpfen: `&` = und, `|` = oder.
3. TRUE zählt als 1, FALSE als 0 → `sum()` = Anzahl, `mean()` = Anteil.
4. `is.element(15, x)` oder `15 %in% x`.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> sum(x > 10)
[1] 4
> mean(x > 10)
[1] 0.6666667
> is.element(15, x)
[1] TRUE
> x > 5 & x < 20
[1] FALSE TRUE TRUE TRUE FALSE FALSE
```

Lösungskästchen

Kästchen 2 · Antwortsatz

4 Werte von x (66.7 %) sind größer als 10.

Aufgabe. Bestimmen Sie den Objekttyp von x, von "Bergtal" und von TRUE.

(3 P)

SO LÖST DU ES

1. `typeof()` : double, integer, character, logical.
2. `class()` : numeric, integer, character, logical, factor, data.frame.
3. Zahlen mit Komma → double/numeric · nur ganze Zahlen aus Datei → integer · Text → character · TRUE/FALSE → logical.
4. Prüfen: `is.numeric()`, `is.character()`, `is.factor()`. Umwandeln: `as.numeric()`, `as.character()`.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> typeof(x)
[1] "double"
> class(x)
[1] "numeric"
> typeof("Bergtal")
[1] "character"
> typeof(TRUE)
[1] "logical"
> is.numeric(x)
[1] TRUE
> as.numeric("3.5")
[1] 3.5
```

Faktoren

~40 %

Aufgabe. Speichern Sie die Antworten "ja", "nein", "ja", "ja" als Factor mit den Stufen ja und nein. Geben Sie die Stufen aus.

(2 P)

SO LÖST DU ES

1. Factor = Kategorie-Variable mit festen Stufen (levels).
2. `factor(x, levels = c(...))`. `levels()` zeigt die Stufen.
3. `cut()` erzeugt automatisch einen Factor.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> f <- factor(c("ja", "nein", "ja", "ja"), levels = c("ja", "nein"))
> f
[1] ja   nein ja   ja
Levels: ja nein
> levels(f)
[1] "ja" "nein"
> table(f)
f
ja nein
3    1
```

Aufgabe. Der Vektor `y` enthält einen fehlenden Wert: 3, NA, 5, 8. Berechnen Sie den Mittelwert. (2 P)

SO LÖST DU ES

1. NA = fehlender Wert. Mit NA liefert `mean()` wieder NA.
2. Lösung: `na.rm = TRUE` oder `na.omit()`.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> y <- c(3, NA, 5, 8)
> mean(y)
[1] NA
> mean(y, na.rm = TRUE)
[1] 5.333333
> is.na(y)
[1] FALSE TRUE FALSE FALSE
> na.omit(y)
[1] 3 5 8
attr(,"na.action")
[1] 2
attr(,"class")
[1] "omit"
```

Lösungskästchen

Kästchen 2 · Antwortsatz

Der Mittelwert der vorhandenen Werte beträgt 5.333.

Aufgabe. `A <- 3:6`, `B <- 4:2`, `C <- seq(2, 8, by = 2)`. Bestimmen Sie $A \cup B$, $A \cap C$, $B \setminus C$ und ob 6 in C liegt. (4 P)

SO LÖST DU ES

1. Vereinigung `union()`, Schnitt `intersect()`, Differenz `setdiff()`, Element `is.element()`.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> A <- 3:6
> B <- 4:2
> C <- seq(2, 8, by = 2)
> union(A, B)
[1] 3 4 5 6 2
> intersect(A, C)
[1] 4 6
> setdiff(B, C)
[1] 3
> is.element(6, C)
[1] TRUE
```

Aufgabe. Fügen Sie "Lambda =" und die Zahl 20 zu einem Text zusammen und geben Sie ihn aus.

(1 P)

SO LÖST DU ES

1. `paste("a", "b")` mit Leerzeichen, `paste0()` ohne Leerzeichen.
2. `cat()` gibt Text aus, `"\n"` = neue Zeile.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> paste("Lambda =", 20)
[1] "Lambda = 20"
> paste0("0.", 1, 2, 3)
[1] "0.123"
> cat("Lambda =", 20, "\n")
Lambda = 20
```

Matrix und Data Frame von Hand

~30 %

Aufgabe. Erstellen Sie eine 2×2-Matrix mit den Werten 15, 75, 45, 65 (spaltenweise) und einen Data Frame mit den Spalten Name und Alter.

(2 P)

SO LÖST DU ES

1. `matrix(Werte, nrow = Zeilen)` füllt spaltenweise (`byrow = TRUE` → zeilenweise).
2. `data.frame(Spalte1 = ..., Spalte2 = ...)`. `dim()` = Zeilen und Spalten.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> m <- matrix(c(15, 75, 45, 65), nrow = 2)
> m
      [,1] [,2]
[1,]   15   45
[2,]   75   65
> df <- data.frame(Name = c("Ana", "Ben"), Alter = c(21, 24))
> df
  Name Alter
1  Ana    21
2  Ben    24
> dim(df)
[1] 2 2
```

2 · Datensatz einlesen und ansehen

Working Directory setzen und Daten einlesen

~100 %

Aufgabe. Die Daten sind in der Datei `Taverne.csv` im Ordner Dokumente abgespeichert. Setzen Sie mittels `setwd(path.expand("~/"))` Ihr Working Directory. Speichern Sie die Daten als Data-Frame-Objekt `d` und geben Sie die ersten 6 Zeilen wieder. (4 P)

SO LÖST DU ES

1. `setwd(path.expand("~/"))` = Ordner Dokumente als Arbeitsordner.
2. `list.files()` zeigt, welche Dateien dort liegen → Dateiname genau abschreiben.
3. Datei vorher ansehen (RStudio: Files → Datei → View File): Trennzeichen zwischen Spalten = `sep`, Dezimalzeichen = `dec`.
4. `read.csv("Datei", sep = ..., dec = ..., header = TRUE)`. `head(d)` = erste 6 Zeilen.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> setwd(path.expand("~/"))
> list.files()
[1] "Fahrrad.csv" "Taverne.csv" "kurs.R"
> d <- read.csv("Taverne.csv", sep = ";", dec = ".", header = TRUE)
> head(d)
```

	Taverne	Tal	Monster	Muenzen	Kampfzeit
1	T01	Flusstal	Ghul	18	12.5
2	T02	Bergtal	Troll	25	45.0
3	T03	Flusstal	Wolf	12	3.2
4	T04	Walddtal	Greif	30	75.5
5	T05	Bergtal	Ghul	22	8.0
6	T06	Walddtal	Wolf	15	4.5

⚠ Fehler „kann Datei nicht öffnen“ → Datei liegt nicht in Dokumente oder Name falsch geschrieben (`list.files()` prüfen).

Anderes Dateiformat (Komma als Dezimalzeichen)

~60 %

Aufgabe. Lesen Sie `Fahrrad.csv` ein (Speicherung als Objekt `f`). Prüfen Sie, ob die Zahlen richtig eingelesen wurden. (3 P)

SO LÖST DU ES

1. In der Datei steht `12,6` → deutsches Format: `sep = ";"` und `dec = ","`.
2. Mit `str()` prüfen: Zahlen müssen `num` sein. Sind sie `chr` → `dec` falsch.
3. Nur eine Spalte → `sep` falsch.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> f <- read.csv("Fahrrad.csv", sep = ";", dec = ",", header = TRUE)
> str(f)
'data.frame': 30 obs. of 6 variables:
 $ Ausleihe: chr  "A01" "A02" "A03" "A04" ...
 $ Station : chr  "Altstadt" "Altstadt" "Altstadt" "Bahnhof" ...
 $ Typ     : chr  "Normal" "Normal" "E-Bike" "E-Bike" ...
 $ Dauer   : num  12.6 43.4 33.7 42.3 31.4 9.6 55.7 69.5 41 54.4 ...
 $ Km      : num  2.4 9.1 11 11.3 5.3 1.9 14.9 21.2 8 15.9 ...
 $ Preis   : num  2.01 4.47 6.06 7.34 3.51 ...
```

Aufgabe. Der Data Frame ist eine spezielle Liste. Ermitteln Sie unter Einbezug eines passenden R-Befehls die Objekttypen der Variablen Tal und Muenzen. (4 P)

SO LÖST DU ES

1. `str(d)` zeigt alle Variablen mit Typ. Oder einzeln: `typeof(d$Tal)` , `class(d$Tal)` .
2. `d$Name` = eine Spalte des Data Frames.
3. `chr` = character · `int` = integer (numeric, ganze Zahlen) · `num` = numeric (double).

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> str(d)
'data.frame':  12 obs. of  5 variables:
 $ Taverne  : chr  "T01" "T02" "T03" "T04" ...
 $ Tal      : chr  "Flusstal" "Bergtal" "Flusstal" "Walddal" ...
 $ Monster  : chr  "Ghul" "Troll" "Wolf" "Greif" ...
 $ Muenzen  : int   18 25 12 30 22 15 27 33 20 10 ...
 $ Kampfzeit: num   12.5 45 3.2 75.5 8 4.5 50 90 15 2.5 ...
> typeof(d$Tal)
[1] "character"
> class(d$Muenzen)
[1] "integer"
```

Lösungskästchen

Kästchen 2 · Antwortsatz

Die Variable Tal ist ein character-Objekt. Die Variable Muenzen ist numerisch vom Typ integer (nur ganze Zahlen).

Aufgabe. Wie viele Beobachtungen und Variablen enthält d? Wie heißen die Variablen? (2 P)

SO LÖST DU ES

1. `nrow()` Zeilen · `ncol()` Spalten · `dim()` beides · `names()` Variablennamen · `summary(d)` Überblick.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> nrow(d)
[1] 12
> ncol(d)
[1] 5
> dim(d)
[1] 12  5
> names(d)
[1] "Taverne"  "Tal"      "Monster"  "Muenzen"  "Kampfzeit"
```

Lösungskästchen

Kästchen 2 · Antwortsatz

Der Datensatz enthält 12 Beobachtungen und 5 Variablen.

Zeilen und Spalten auswählen

~50 %

Aufgabe. Geben Sie (i) die 3. Zeile, (ii) die Spalte Muenzen, (iii) alle Tavernen im Bergtal, (iv) die Taverne mit den meisten Münzen aus. **(4 P)**

SO LÖST DU ES

1. `d[Zeile, Spalte]`. Leer = alle. `d[3, ]` = Zeile 3.
2. `d[d$Tal == "Bergtal", ]` = alle Zeilen mit Bedingung (Komma nicht vergessen!).
3. `subset(d, Bedingung)` macht dasselbe.
4. `which.max()` = Position des Maximums.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> d[3, ]
  Taverne      Tal Monster Muenzen Kampfzeit
3   T03 Flusstal   Wolf      12         3.2
> d$Muenzen
[1] 18 25 12 30 22 15 27 33 20 10 24 29
> d[d$Tal == "Bergtal", ]
  Taverne      Tal Monster Muenzen Kampfzeit
2   T02 Bergtal   Troll      25         45
5   T05 Bergtal   Ghul       22          8
8   T08 Bergtal   Greif      33         90
11  T11 Bergtal   Troll      24         38
> d[which.max(d$Muenzen), ]
  Taverne      Tal Monster Muenzen Kampfzeit
8   T08 Bergtal   Greif      33         90
```

Teildatensatz mit subset

~50 %

Aufgabe. Betrachten Sie nur die Beobachtungen, bei denen die Kampfzeit mindestens 5, aber weniger als 60 Minuten betrug. Wie viele sind es? **(2 P)**

SO LÖST DU ES

1. `subset(d, Bedingung)`. Mehrere Bedingungen mit `&` (und) oder `|` (oder).
2. Danach mit dem neuen Objekt weiterrechnen (`s$...`, nicht `d$...`).

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> s <- subset(d, Kampfzeit >= 5 & Kampfzeit < 60)
> nrow(s)
[1] 6
> s
  Taverne      Tal Monster Muenzen Kampfzeit
1   T01 Flusstal   Ghul      18        12.5
2   T02 Bergtal   Troll      25        45.0
5   T05 Bergtal   Ghul       22          8.0
7   T07 Flusstal   Troll      27        50.0
9   T09 Walddal   Ghul       20        15.0
11  T11 Bergtal   Troll      24        38.0
```

Lösungskästchen

Kästchen 2 · Antwortsatz

6 Beobachtungen haben eine Kampfzeit von mindestens 5 und unter 60 Minuten.

Aufgabe. Ergänzen Sie d um die Variable MproMin = Münzen pro Kampfminute.

(2 P)

SO LÖST DU ES

1. `d$MproMin <- Rechnung` fügt eine Spalte hinzu.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> d$MproMin <- d$Muenzen / d$Kampfzeit
> head(d)
  Taverne      Tal Monster Muenzen Kampfzeit  MproMin
1   T01 Flusstal   Ghul    18      12.5 1.4400000
2   T02 Bergtal   Troll    25      45.0 0.5555556
3   T03 Flusstal   Wolf    12       3.2 3.7500000
4   T04 Walddtal Greif    30      75.5 0.3973510
5   T05 Bergtal   Ghul    22       8.0 2.7500000
6   T06 Walddtal Wolf    15       4.5 3.3333333
```

3 · Kennzahlen (deskriptive Statistik)

Mittelwert und Standardabweichung

~90 %

Aufgabe. Berechnen und nennen Sie das arithmetische Mittel und den unverzerrten Schätzer der Standardabweichung der Variable Kampfzeit. Runden Sie auf drei Nachkommastellen.

(4 P)

SO LÖST DU ES

1. `mean()`, `sd()`. `sd` und `var` rechnen **immer** mit $n - 1$ (unverzerrt).
2. Mit `round(..., 3)` runden.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> round(mean(d$Kampfzeit), 3)
[1] 33.85
> round(sd(d$Kampfzeit), 3)
[1] 30.667
```

Lösungskästchen

Kästchen 2 · Antwortsatz

Das arithmetische Mittel der Kampfzeit beträgt 33.85 Minuten. Der unverzerrte Schätzer der Standardabweichung beträgt 30.667 Minuten.

Aufgabe. Berechnen Sie die unverzerrte und die empirische (1/n) Varianz der Variable Muenzen.

(3 P)

SO LÖST DU ES

1. `var()` = unverzerrt ($n - 1$).
2. Empirisch: `var(x) * (n - 1) / n` mit `n <- length(x)`. Oder `mean(x^2) - mean(x)^2`.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> n <- length(d$Muenzen)
> round(var(d$Muenzen), 3)
[1] 53.174
> round(var(d$Muenzen) * (n - 1) / n, 3)
[1] 48.743
> round(mean(d$Muenzen^2) - mean(d$Muenzen)^2, 3)
[1] 48.743
```

Lösungskästchen

Kästchen 2 · Antwortsatz

Die unverzerrte Varianz beträgt 53.174, die empirische Varianz 48.743.

Median, Quantile, IQR, Wertebereich

~70 %

Aufgabe. Bestimmen Sie Median, Interquartilsabstand, das 90 %-Quantil und den Wertebereich der Variable Kampfzeit.

(4 P)

SO LÖST DU ES

1. `median()`, `IQR()`, `quantile(x, 0.9)`, `range()` (Min und Max), `min()`, `max()`.
2. `summary()` gibt Min, Quartile, Median, Mittel, Max auf einmal.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> median(d$Kampfzeit)
[1] 26.5
> IQR(d$Kampfzeit)
[1] 45.875
> quantile(d$Kampfzeit, 0.9)
90%
74.15
> quantile(d$Kampfzeit, c(0.25, 0.75))
25% 75%
7.125 53.000
> range(d$Kampfzeit)
[1] 2.5 90.0
> summary(d$Kampfzeit)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 2.500   7.125  26.500  33.850  53.000  90.000
```

Lösungskästchen

Kästchen 2 · Antwortsatz

Der Median der Kampfzeit beträgt 26.5 Minuten, der Interquartilsabstand 45.875 Minuten. Der Wertebereich ist [2.5, 90].

⚠ R-Quantile weichen von der Vorlesungsdefinition (Teil A) ab – in Teil B immer den R-Befehl nehmen.

Aufgabe. Bestimmen Sie die absoluten und relativen Häufigkeiten der Variable Monster. Welches Monster kommt am häufigsten vor?

(3 P)

SO LÖST DU ES

1. `table()` = absolute Häufigkeiten. `prop.table(table())` = relative.
2. Modus: `which.max(table(x))` oder `which(table(x) == max(table(x)))`.
3. `sort()` sortiert, `unique()` = verschiedene Werte.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> table(d$Monster)

Ghul Greif Troll Wolf
  3     2     4     3
> round(prop.table(table(d$Monster)), 3)

Ghul Greif Troll Wolf
0.250 0.167 0.333 0.250
> which.max(table(d$Monster))
Troll
3
```

Lösungskästchen

Kästchen 2 · Antwortsatz

Am häufigsten kommt der Troll vor (4-mal, Anteil 0.333).

Kennzahlen pro Gruppe

Aufgabe. Berechnen Sie die durchschnittliche Anzahl an Münzen für jedes Tal. In welchem Tal verdient Jaskier im Durchschnitt am meisten?

(3 P)

SO LÖST DU ES

1. `tapply(Zahl, Gruppe, Funktion)`.
2. Alternative: `aggregate(d$Muenzen, by = list(d$Tal), mean)`.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> round(tapply(d$Muenzen, d$Tal, mean), 3)
Bergtal Flusstal Walddtal
 26.00    16.75    23.50
> aggregate(d$Muenzen, by = list(d$Tal), mean)
  Group.1      x
1 Bergtal 26.00
2 Flusstal 16.75
3 Walddtal 23.50
```

Lösungskästchen

Kästchen 2 · Antwortsatz

Im Bergtal verdient Jaskier im Durchschnitt am meisten (26 Münzen).

Aufgabe. Ergänzen Sie d um die Variable Kampfzeit.3 mit den Ausprägungen {weniger als 5 Minuten, 5 Minuten bis weniger als eine Stunde, eine Stunde oder mehr} als Factor. Ergänzen Sie außerdem Muenzen.4 mit {bis 10, mehr als 10 bis 20, mehr als 20 bis 30, mehr als 30}. **(4 P)**

SO LÖST DU ES

1. `cut(x, breaks = Grenzen, right = ...)`. Letzte Grenze `Inf`.
2. „weniger als / bis unter“ → `[a, b)` → `right = FALSE`.
3. „bis zu / höchstens / mehr als ... bis ...“ → `(a, b]` → `right = TRUE`.
4. Einheit beachten: 1 Stunde = 60 Minuten.
5. Optional: `labels = c(...)` für eigene Namen.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> d$Kampfzeit.3 <- cut(d$Kampfzeit, breaks = c(0, 5, 60, Inf), right = FALSE)
> d$Muenzen.4 <- cut(d$Muenzen, breaks = c(0, 10, 20, 30, Inf), right = TRUE)
> table(d$Kampfzeit.3)

 [0,5)  [5,60) [60,Inf)
      3      6      3
> is.factor(d$Kampfzeit.3)
[1] TRUE
```

Aufgabe. Erstellen Sie die Kontingenztafel von Muenzen.4 und Kampfzeit.3. Wie häufig lag bei 5 bis unter 60 Minuten die Anzahl der Münzen in (10, 20]? Geben Sie die zeilenweise bedingte Verteilung an. **(4 P)**

SO LÖST DU ES

1. `table(Zeilen, Spalten)` = Kontingenztafel.
2. Zelle ablesen: Zeile (10,20], Spalte [5,60).
3. `prop.table(tafel, 1)` = zeilenweise, `prop.table(tafel, 2)` = spaltenweise, ohne Zahl = gesamt.
4. `addmargins(tafel)` = mit Randsummen.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> Kontingenz.Tafel <- table(d$Muenzen.4, d$Kampfzeit.3)
> Kontingenz.Tafel
```

	[0,5)	[5,60)	[60,Inf)
(0,10]	1	0	0
(10,20]	2	2	0
(20,30]	0	4	2
(30,Inf]	0	0	1

```
> addmargins(Kontingenz.Tafel)
```

	[0,5)	[5,60)	[60,Inf)	Sum
(0,10]	1	0	0	1
(10,20]	2	2	0	4
(20,30]	0	4	2	6
(30,Inf]	0	0	1	1
Sum	3	6	3	12

```
> round(prop.table(Kontingenz.Tafel, 1), 3)
```

	[0,5)	[5,60)	[60,Inf)
(0,10]	1.000	0.000	0.000
(10,20]	0.500	0.500	0.000
(20,30]	0.000	0.667	0.333
(30,Inf]	0.000	0.000	1.000

Lösungskästchen

Kästchen 2 · Antwortsatz

Bei einer Kampfzeit von 5 bis unter 60 Minuten lag die Anzahl der Münzen 2-mal zwischen 10 und 20.

Aufgabe. Betrachten Sie nur Kampfzeiten von mindestens 5 und unter 60 Minuten. Ermitteln Sie die relative Häufigkeit jeder Ausprägung von Muenzen.4 auf zwei Dezimalstellen.

(3 P)

SO LÖST DU ES

1. Erst `subset()`, dann `prop.table(table())` auf die Teilgruppe.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> s <- subset(d, Kampfzeit >= 5 & Kampfzeit < 60)
> round(prop.table(table(s$Muenzen.4)), 2)

(0,10] (10,20] (20,30] (30,Inf]
  0.00    0.33    0.67    0.00
```

Lösungskästchen

Kästchen 2 · Antwortsatz

(0,10]: 0.00 · (10,20]: 0.33 · (20,30]: 0.67 · (30,Inf]: 0.00.

Korrelation und Kovarianz

Aufgabe. Wie stark ist der lineare Zusammenhang zwischen Kampfzeit und Muenzen? Berechnen Sie zusätzlich Spearman und die Kovarianz.

(4 P)

SO LÖST DU ES

1. `cor(x, y)` = Pearson (Standard). `cor(x, y, method = "spearman")`.
2. `cov(x, y)` rechnet mit $n - 1$.
3. Antwort: Stärke + Richtung + linear + Merkmale.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> round(cor(d$Kampfzeit, d$Muenzen), 3)
[1] 0.928
> round(cor(d$Kampfzeit, d$Muenzen, method = "spearman"), 3)
[1] 0.979
> round(cov(d$Kampfzeit, d$Muenzen), 3)
[1] 207.423
> round(cor(rank(d$Kampfzeit), rank(d$Muenzen)), 3)
[1] 0.979
```

Lösungskästchen

Kästchen 2 · Antwortsatz

Der Korrelationskoeffizient nach Pearson beträgt 0.928; es besteht ein starker positiver linearer Zusammenhang zwischen Kampfzeit und Münzen.

4 · Grafiken erstellen und als Datei speichern

Normiertes Histogramm als PDF

~85 %

Aufgabe. Erstellen Sie ein normiertes Histogramm der Variable Kampfzeit mit den Intervallen [0, 10), [10, 40), [40, 100). Titel „Sitz 17, Matr.Nr. 12345678, Aufgabenteil e)“, x-Achse „Kampfzeit in Minuten“, y-Achse „Dichte“. Speichern Sie die Grafik als Histogramm.pdf. **(8 P)**

SO LÖST DU ES


1. `pdf("Name.pdf")` öffnet die Datei – **vor** dem Plot.
2. `hist()` mit: `breaks` (Grenzen), `freq = FALSE` (normiert = Dichte), `right = FALSE` bei [a, b), `main`, `xlab`, `ylab`.
3. `dev.off()` schließt und speichert – **nach** dem Plot.
4. Datei im Ordner Dokumente prüfen und in ILIAS hochladen.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> pdf("Histogramm.pdf")
> hist(d$Kampfzeit, breaks = c(0, 10, 40, 100), freq = FALSE, right = FALSE,
+     main = "Sitz 17, Matr.Nr. 12345678, Aufgabenteil e)",
+     xlab = "Kampfzeit in Minuten", ylab = "Dichte")
> dev.off()
null device
      1
```

⚠ Ohne `freq = FALSE` zeigt R absolute Häufigkeiten (Säulendiagramm). `prob = TRUE` ist gleichwertig. Fehler „some 'x' not counted“ → `breaks` decken nicht alle Werte ab.



Inhalt der Datei Histogramm.pdf

Aufgabe. Lassen Sie sich die absoluten Häufigkeiten und Dichten der Klassen ausgeben, ohne die Grafik zu zeichnen.

(2 P)

SO LÖST DU ES

1. `hist(..., plot = FALSE)` speichert die Kennzahlen.
2. `$counts` = Anzahl pro Klasse, `$density` = Höhen, `cumsum()` = kumuliert.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> h <- hist(d$Kampfzeit, breaks = c(0, 10, 40, 100), right = FALSE, plot = FALSE)
> h$counts
[1] 4 3 5
> round(h$density, 4)
[1] 0.0333 0.0083 0.0069
> cumsum(h$counts)
[1] 4 7 12
```

Streudiagramm als PDF (auch als Lückentext)

Aufgabe. Erstellen Sie ein Streudiagramm von Kampfzeit (x-Achse) und Muenzen (y-Achse) mit dem Titel „Streudiagramm“ und speichern Sie es als Streudiagramm.pdf.

(5 P)

SO LÖST DU ES


1. `plot(x, y)`: erste Variable = x-Achse.
2. `pch = 16` gefüllte Punkte, `cex` Punktgröße, `col` Farbe, `xlim / ylim` Achsenbereich.
3. Lückentext Testat 2: `pdf · plot · d$Kampfzeit · d$Muenzen · main · xlab · "Muenzen" · dev`.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> pdf("Streudiagramm.pdf")
> plot(d$Kampfzeit, d$Muenzen, pch = 16, cex = 1,
+      main = "Streudiagramm", xlab = "Kampfzeit (min.)", ylab = "Muenzen")
> dev.off()
null device
      1
```

△ PNG statt PDF: `png("Name.png", width = 2000, height = 2000, res = 400) ... dev.off()`.



Inhalt der Datei Streudiagramm.pdf

Aufgabe. Erstellen Sie Boxplots der Münzen getrennt nach Tal und ein Säulendiagramm der Häufigkeiten der Monster. Geben Sie die Boxplot-Kennzahlen aus. **(4 P)**


SO LÖST DU ES

1. `boxplot(Zahl ~ Gruppe, data = d)` – Tilde ~ heißt „nach“.
2. `boxplot(x, plot = FALSE)$stats` = unterer Whisker, Q1, Median, Q3, oberer Whisker.
3. `barplot(table(d$Monster))` = Säulendiagramm für kategoriale Daten.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> pdf("Boxplot.pdf")
> boxplot(Muenzen ~ Tal, data = d, main = "Muenzen nach Tal", xlab = "Tal", ylab = "Muenzen")
> dev.off()
null device
      1
> boxplot(d$Kampfzeit, plot = FALSE)$stats
      [,1]
[1,]  2.50
[2,]  6.25
[3,] 26.50
[4,] 56.00
[5,] 90.00
> barplot(table(d$Monster), main = "Monster", ylab = "Anzahl")
```



Inhalt der Datei Boxplot.pdf

Aufgabe. Visualisieren Sie einen Kerndichteschätzer der Verteilung der Variable Dauer (Datensatz f). Titel mit Sitz, Matrikelnummer und Aufgabenteil, x-Achse „Dauer“, y-Achse „Dichte“. Speichern Sie die Grafik als KDE.pdf. (5 P)


SO LÖST DU ES

1. `density(x)` berechnet den KDE, `plot(density(x), ...)` zeichnet ihn.
2. Bandbreite: `bw = ...` (klein → unruhig, groß → zu glatt). Kern: `kernel = "epanechnikov"` (Standard: "gaussian").
3. Mit Histogramm kombinieren: erst `hist(..., freq = FALSE)`, dann `lines(density(x))`.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> pdf("KDE.pdf")
> plot(density(f$Dauer), main = "Sitz 17, Matr.Nr. 12345678, Aufgabenteil c)",
+      xlab = "Dauer", ylab = "Dichte")
> dev.off()
pdf
  2
> density(f$Dauer)$bw
[1] 9.142436
> plot(density(f$Dauer, bw = 5, kernel = "epanechnikov"))
```



Inhalt der Datei KDE.pdf

Aufgabe. Zeichnen Sie ein normiertes Histogramm von Dauer und ergänzen Sie die Dichte einer Exponentialverteilung mit Rate $1/35.86$ sowie eine senkrechte Linie beim Mittelwert.

(4 P)


SO LÖST DU ES

1. Erst die Grundgrafik (hist, plot), dann ergänzen: `lines(x, y)`, `points(x, y)`, `abline(v = ...)` (senkrecht), `abline(h = ...)` (waagrecht), `curve(f(x), add = TRUE)`.
2. x-Werte für eine Kurve: `seq(0, 120, by = 0.5)`.
3. `ylim = c(0, ...)`, damit die Kurve ganz sichtbar ist.
4. Mehrere Grafiken nebeneinander: `par(mfrow = c(1, 2))`.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> pdf("HistDichte.pdf")
> hist(f$Dauer, freq = FALSE, breaks = seq(0, 120, by = 15), ylim = c(0, 0.03),
+      main = "Dauer mit Exponentialdichte", xlab = "Dauer", ylab = "Dichte")
> x.seq <- seq(0, 120, by = 0.5)
> lines(x.seq, dexp(x.seq, rate = 1/35.86), col = 2)
> abline(v = mean(f$Dauer), lty = 2)
> dev.off()
pdf
2
```



Inhalt der Datei HistDichte.pdf

5 · Verteilungen in R

Für jede Verteilung gibt es vier Befehle: **d** = Wahrscheinlichkeit/Dichte $P(X = x)$ bzw. $f(x)$ · **p** = Verteilungsfunktion $P(X \leq x)$ · **q** = Quantil (umgekehrt zu p) · **r** = Zufallszahlen. Namen: binom, pois, unif, exp, norm, t, chisq, gamma.

Aufgabe. $X \sim \text{Bin}(n = 10, \pi = 0.3)$. Berechnen Sie $P(X = 2)$, $P(X \leq 2)$, $P(X > 4)$, $P(2 < X \leq 5)$ und den Median.

(5 P)

SO LÖST DU ES

1. $P(X = k) \rightarrow \text{dbinom}(k, \text{size} = n, \text{prob} = \pi)$.
2. $P(X \leq k) \rightarrow \text{pbinom}(k, n, \pi)$.
3. $P(X > k) \rightarrow 1 - \text{pbinom}(k, n, \pi)$. $P(X \geq k) \rightarrow 1 - \text{pbinom}(k - 1, n, \pi)$.
4. $P(a < X \leq b) \rightarrow \text{pbinom}(b, n, \pi) - \text{pbinom}(a, n, \pi)$.
5. Quantil $\rightarrow \text{qbinom}(0.5, n, \pi)$.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> dbinom(2, size = 10, prob = 0.3)
[1] 0.2334744
> pbinom(2, 10, 0.3)
[1] 0.3827828
> 1 - pbinom(4, 10, 0.3)
[1] 0.1502683
> pbinom(5, 10, 0.3) - pbinom(2, 10, 0.3)
[1] 0.5698682
> qbinom(0.5, 10, 0.3)
[1] 3
> dbinom(0:3, 10, 0.3)
[1] 0.02824752 0.12106082 0.23347444 0.26682793
```

Lösungskästchen

Kästchen 2 · Antwortsatz

$P(X > 4) = 0.150$.

Aufgabe. $Y \sim \text{Po}(\lambda = 2)$. Mittels welches R-Befehls lässt sich $P(Y > 2)$ berechnen? Berechnen Sie außerdem $P(Y = 0)$ und $P(Y \leq 3)$.

(3 P)

SO LÖST DU ES

1. $\text{dpois}(k, \text{lambda}) = P(Y = k)$. $\text{ppois}(k, \text{lambda}) = P(Y \leq k)$.
2. $P(Y > 2) = 1 - P(Y \leq 2) = 1 - \text{ppois}(2, 2) = 1 - \text{dpois}(0, 2) - \text{dpois}(1, 2) - \text{dpois}(2, 2)$.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> 1 - ppois(2, lambda = 2)
[1] 0.3233236
> 1 - dpois(0, 2) - dpois(1, 2) - dpois(2, 2)
[1] 0.3233236
> dpois(0, 2)
[1] 0.1353353
> ppois(3, 2)
[1] 0.8571235
```

Lösungskästchen

Kästchen 2 · Antwortsatz

$P(Y > 2)$ beträgt 0.323.

⚠ Falsch wäre $1 - \text{dpois}(2, 2)$ – das ist $P(Y \neq 2)$.

Aufgabe. $X \sim N(\mu = 500, \sigma = 5)$. Bestimmen Sie $P(X > 505)$, $P(495 \leq X \leq 505)$, das 95 %-Quantil und $P(X > 505)$ über die Standardisierung. **(4 P)**

SO LÖST DU ES

1. `pnorm(x, mean =  $\mu$ , sd =  $\sigma$ )` = $P(X \leq x)$. Achtung: **sd**, nicht Varianz!
2. $P(X > x) = 1 - \text{pnorm}(x, \mu, \sigma)$.
3. Quantil: `qnorm(p,  $\mu$ ,  $\sigma$ )`.
4. Standardisiert: `pnorm((x -  $\mu$ ) /  $\sigma$ )` (Standardnormalverteilung). Stetig: $P(X > x) = P(X \geq x)$.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> 1 - pnorm(505, mean = 500, sd = 5)
[1] 0.1586553
> pnorm(505, 500, 5) - pnorm(495, 500, 5)
[1] 0.6826895
> qnorm(0.95, 500, 5)
[1] 508.2243
> 1 - pnorm((505 - 500) / 5)
[1] 0.1586553
> qnorm(0.975)
[1] 1.959964
```

Lösungskästchen

Kästchen 2 · Antwortsatz

$P(X > 505)$ beträgt 0.159.

Gleich-, Exponential-, t-, χ^2 - und Gammaverteilung

Aufgabe. Berechnen Sie (i) $P(X \leq 1.5)$ für $X \sim U(0, 2)$, (ii) $P(X \leq 200)$ für $X \sim \text{Exp}(0.006)$, (iii) das 97.5 %-Quantil der t-Verteilung mit 9 Freiheitsgraden, (iv) das 95 %-Quantil der χ^2 -Verteilung mit 29 FG, (v) $P(X \leq 3)$ für $X \sim \text{Gamma}(2, 1)$. **(5 P)**

SO LÖST DU ES

1. `punif(x, min, max) · pexp(x, rate) · qt(p, df) · qchisq(p, df) · pgamma(x, shape, rate)`.
2. Dichten mit `d...`, Quantile mit `q...`, Zufallszahlen mit `r...`.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> punif(1.5, min = 0, max = 2)
[1] 0.75
> pexp(200, rate = 0.006)
[1] 0.6988058
> qt(0.975, df = 9)
[1] 2.262157
> qchisq(0.95, df = 29)
[1] 42.55697
> pgamma(3, shape = 2, rate = 1)
[1] 0.8008517
```

Aufgabe. Vervollständigen Sie: `set.seed(123) / x <- ___binom(10000, size = ___, prob = ___) / hist(x, prob = T, breaks = seq(-0.5, 5.5, by = 1))` für $X \sim \text{Bin}(5, 0.3)$. Vergleichen Sie die simulierten Anteile mit `dbinom`. (3 P)

SO LÖST DU ES

1. `set.seed(Zahl)` = gleiche Zufallszahlen bei jedem Lauf (reproduzierbar).
2. `r...` erzeugt Zufallszahlen: `rbinom(Anzahl, size, prob)`, `rpois`, `rnorm`, `runif`.
3. `sample(1:6, 10, replace = TRUE)` = Würfelwürfe.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> set.seed(123)
> x <- rbinom(10000, size = 5, prob = 0.3)
> round(prop.table(table(x)), 3)
x
  0    1    2    3    4    5
0.169 0.365 0.308 0.130 0.026 0.002
> round(dbinom(0:5, 5, 0.3), 3)
[1] 0.168 0.360 0.309 0.132 0.028 0.002
> sample(1:6, 10, replace = TRUE)
[1] 3 4 1 4 6 2 3 4 2 3
```

Lösungskästchen

Kästchen 2 · Antwortsatz

Lücken: `r`, `5`, `0.3`.

Wahrscheinlichkeitsfunktion / Dichte plotten

Aufgabe. Stellen Sie die Wahrscheinlichkeitsfunktion von $\text{Po}(3)$ für 0 bis 15 und die Dichte von $N(0, 1)$ dar. (3 P)

SO LÖST DU ES

1. Diskret: `plot(werte, dpois(werte, 3), pch = 16)` (Punkte).
2. Stetig: `plot(werte, dnorm(werte), type = "l")` (Linie), `werte` mit `seq()`.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> vals <- 0:15
> plot(vals, dpois(vals, 3), pch = 16, main = "Po(3)", xlab = "x", ylab = "P(X = x)")
> v <- seq(-3, 3, length.out = 200)
> plot(v, dnorm(v), type = "l", main = "N(0,1)", xlab = "x", ylab = "Dichte")
```

6 · Programmieren: Funktionen und Schleifen

Eine Funktion schreiben

~60 %

Aufgabe. Schreiben Sie eine Funktion `quadsum(x)`, welche die Summe der quadrierten Werte eines Vektors zurückgibt. Testen Sie sie mit `1:4`.

(3 P)

SO LÖST DU ES

1. Aufbau: `name <- function(argumente) { ... return(ergebnis) }`.
2. Die Funktion erst ausführen (definieren), dann aufrufen: `quadsum(1:4)`.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> quadsum <- function(x) {  
+   s <- sum(x^2)  
+   return(s)  
+ }  
> quadsum(1:4)  
[1] 30
```

for-Schleife

~50 %

Aufgabe. Berechnen Sie mit einer `for`-Schleife für $\lambda = 1, \dots, 5$ den Wert $P(X = 3)$ mit $X \sim \text{Po}(\lambda)$ und geben Sie jeweils „Lambda = ... P = ...“ aus.

(3 P)

SO LÖST DU ES

1. `for (i in 1:5) { ... }` – `i` nimmt nacheinander jeden Wert an.
2. Ergebnisse speichern: vorher leeren Vektor anlegen `erg <- numeric(5)`, in der Schleife `erg[i] <- ...`.
3. Kürzer ohne Schleife: `sapply(1:5, function(l) dpois(3, l))` oder direkt `dpois(3, 1:5)`.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> erg <- numeric(5)  
> for (lambda in 1:5) {  
+   erg[lambda] <- dpois(3, lambda)  
+   cat("Lambda =", lambda, "P =", round(erg[lambda], 3), "\n")  
+ }  
Lambda = 1 P = 0.061  
Lambda = 2 P = 0.18  
Lambda = 3 P = 0.224  
Lambda = 4 P = 0.195  
Lambda = 5 P = 0.14  
> which.max(erg)  
[1] 3
```

Aufgabe. Ersetzen Sie in x alle Werte größer als 10 durch 1 – einmal mit ifelse und einmal mit einer Funktion mit if/else. (3 P)

SO LÖST DU ES

1. `ifelse(Bedingung, wenn_ja, wenn_nein)` arbeitet mit dem ganzen Vektor.
2. `if (Bedingung) { ... } else { ... }` prüft **einen** Wert → in einer Schleife benutzen.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> x <- c(4, 8, 15, 16, 23, 42)
> ifelse(x > 10, 1, x)
[1] 4 8 1 1 1 1
> ersetze <- function(v) {
+   for (i in 1:length(v)) {
+     if (v[i] > 10) { v[i] <- 1 } else { v[i] <- v[i] }
+   }
+   return(v)
+ }
> ersetze(x)
[1] 4 8 1 1 1 1
```

Text-Funktion mit Schleife (Yennefer-Zahl, PK B h)

Aufgabe. Schreiben Sie eine Funktion `YenneferZahl.fun(n)`, welche „0.“ und alle natürlichen Zahlen von 1 bis n hintereinander schreibt. Geben Sie das Ergebnis für $n = 17$ an. (8 P)

SO LÖST DU ES

1. Start-Text `"0."`. In der Schleife mit `paste0(alt, i)` anhängen.
2. Am Ende `return()`.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> YenneferZahl.fun <- function(n) {
+   y <- "0."
+   for (i in 1:n) {
+     y <- paste0(y, i)
+   }
+   return(y)
+ }
> YenneferZahl.fun(17)
[1] "0.1234567891011121314151617"
```

Lösungskästchen

Kästchen 2 · Antwortsatz

Die Yennefer-Zahl bis $n = 17$ lautet 0.1234567891011121314151617.

7 · Maximum-Likelihood in R

Idee: Die Likelihood $L(\theta) = \text{Produkt der Einzelwahrscheinlichkeiten (diskret: d...-Funktion) bzw. Einzeldichten (stetig)}$. Der ML-Schätzer ist der Parameterwert mit der größten Likelihood.

Aufgabe. Gehen Sie davon aus, dass Muenzen Poisson-verteilt ist, mit $\lambda = 20$. Ergänzen Sie d um die Spalte iL20 mit den individuellen Likelihoods und berechnen Sie die Likelihood aller Beobachtungen in der Form $X \times 10^Y$ (X auf drei Nachkommastellen). **(6 P)**

SO LÖST DU ES

1. Individuelle Likelihood = Wahrscheinlichkeit jeder Beobachtung: `dpois(d$Muenzen, 20)`.
2. Gesamt = Produkt: `prod()`.
3. Darstellung: R zeigt z. B. `4.104144e-20` = $4.104 \times 10^{(-20)}$. Mit `signif(L, 4)` oder `format(L, digits = 4)`.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> d$iL20 <- dpois(d$Muenzen, lambda = 20)
> head(d[, c("Muenzen", "iL20")])
  Muenzen      iL20
1      18 0.084393552
2      25 0.044587649
3      12 0.017625171
4      30 0.008343536
5      22 0.076913695
6      15 0.051648854
> L20 <- prod(d$iL20)
> L20
[1] 4.104144e-20
> format(L20, digits = 4)
[1] "4.104e-20"
```

Lösungskästchen

Kästchen 2 · Antwortsatz

Die Likelihood aller Beobachtungen unter $\lambda = 20$ beträgt $L(\lambda = 20) = 4.104 \times 10^{(-20)}$.

Aufgabe. Schreiben Sie eine Funktion `Likelihood.pois(lambda, x)`, welche die Likelihood für ein beliebiges λ bestimmt. Berechnen Sie die Likelihood für alle $\lambda \in \{17, \dots, 23\}$ und bestimmen Sie daraus den ML-Schätzer.

(9 P)

SO LÖST DU ES

1. Funktion: `prod(dpois(x, lambda))`.
2. Für alle Werte: `for`-Schleife oder `sapply(17:23, ...)`.
3. Maximum: `which.max()` gibt die Position; Wert über den Vektor der λ .
4. Kontrolle: Bei Poisson ist der ML-Schätzer = Mittelwert (22.083) $\rightarrow$ 22 passt.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> Likelihood.pois <- function(lambda, x) {
+   L <- prod(dpois(x, lambda))
+   return(L)
+ }
> lambdas <- 17:23
> Ls <- sapply(lambdas, Likelihood.pois, x = d$Muenzen)
> names(Ls) <- lambdas
> Ls
      17      18      19      20      21      22
3.498157e-23 8.138703e-22 8.346643e-21 4.104144e-20 1.039568e-19 1.442835e-19
      23
1.157575e-19
> lambdas[which.max(Ls)]
[1] 22
```

Lösungskästchen

Kästchen 2 · Antwortsatz

Das Maximum der Likelihood ergibt sich bei $\lambda = 22$; der ML-Schätzer aus der gegebenen Menge ist $\hat{\lambda} = 22$.

Log-Likelihood und numerical underflow

Aufgabe. Warum ist es bei der direkten Optimierung der Likelihood in R problematisch? Wie umgeht man das Problem? Berechnen Sie die Log-Likelihood für $\lambda = 22$.

(3 P)

SO LÖST DU ES

1. Viele kleine Wahrscheinlichkeiten multipliziert $\rightarrow$ Zahl so klein, dass R sie auf 0 rundet (numerical underflow).
2. Lösung: Logarithmus $\rightarrow$ Summe statt Produkt: `sum(log(dpois(x, lambda)))` bzw. `sum(dpois(x, lambda, log = TRUE))`.
3. Das Maximum liegt an derselben Stelle (log ist monoton).

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> prod(dpois(rep(d$Muenzen, 40), 22))
[1] 0
> sum(log(dpois(d$Muenzen, 22)))
[1] -43.38251
> sum(dpois(d$Muenzen, 22, log = TRUE))
[1] -43.38251
```

Lösungskästchen

Kästchen 2 · Antwortsatz

Bei der direkten Optimierung tritt numerical underflow auf: Das Produkt sehr kleiner Werte wird zu 0 gerundet. Deshalb maximiert man die Log-Likelihood (Summe der logarithmierten Werte).

Aufgabe. Bestimmen Sie den ML-Schätzer für λ der Poissonverteilung numerisch im Intervall [10, 40].

(4 P)

SO LÖST DU ES

1. `optimise(funktion, interval = c(a, b), daten, maximum = TRUE)` sucht das Maximum für **einen** Parameter.
2. Ergebnis: `$maximum` = Schätzer, `$objective` = Funktionswert.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> logL.pois <- function(lambda, x) sum(log(dpois(x, lambda)))
> opt <- optimise(logL.pois, interval = c(10, 40), x = d$Muenzen, maximum = TRUE)
> round(opt$maximum, 3)
[1] 22.083
```

Lösungskästchen

Kästchen 2 · Antwortsatz

Der ML-Schätzer für λ beträgt 22.083 (= Mittelwert der Münzen).

ML mit nlm (zwei Parameter, Gamma-Verteilung)

Aufgabe. Die Dauer (Datensatz f) sei Gamma(α , β)-verteilt. Warum müssen die Parameter für nlm transformiert werden? Schreiben Sie die Funktion neglogL und schätzen Sie α und β mit nlm. Nutzen Sie die Startwerte $\alpha_t = 0.01$ und $\beta_t = 0.5$. Geben Sie die rücktransformierten Schätzer an. (10 P)

SO LÖST DU ES

1. `nlm()` **minimiert** → negative Log-Likelihood benutzen.
2. $\alpha, \beta > 0$, aber nlm probiert alle reellen Zahlen → Transformation: `param = exp(t_param)`. **Achtung Startwerte:** Steht in der Aufgabe α_t, β_t (transformiert, wie in der ML-Probeklausur) → direkt `c(0.01, 0.5)` übergeben. Steht dort α, β (Originalskala) → `log(c(...))` übergeben.
3. Funktion: `param <- exp(t)` · `alpha <- param[1]` · `beta <- param[2]` · `-sum(log(dgamma(x, alpha, beta)))`.
4. `model <- nlm(neglogL, c(0.01, 0.5), x)`. Schätzer: `exp(model$estimate)`. Warnungen während der Iteration sind meist harmlos.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> x <- f$Dauer
> neglogL <- function(t_param, x) {
+   param <- exp(t_param)
+   alpha <- param[1]
+   beta <- param[2]
+   return(-sum(log(dgamma(x, alpha, beta))))
+ }
> model <- nlm(neglogL, c(0.01, 0.5), x)
> round(exp(model$estimate), 3)
[1] 2.453 0.068
```

Lösungskästchen

Kästchen 2 · Antwortsatz

Die Parameter der Gammaverteilung sind positiv, nlm optimiert aber über alle reellen Zahlen; daher werden sie mit `exp()` transformiert. Die rücktransformierten Schätzer betragen $\hat{\alpha} = 2.453$ und $\hat{\beta} = 0.068$.

Aufgabe. Zeichnen Sie das normierte Histogramm von Dauer mit der geschätzten Gammadichte. Wie groß ist $P(\text{Dauer} \leq 30)$ laut Modell? Ab welcher Dauer gehört man zu den 25 % längsten Ausleihen? **(6 P)**

SO LÖST DU ES

1. Kurve: `lines(x.seq, dgamma(x.seq, alpha.hat, beta.hat))`.
2. Wahrscheinlichkeit: `pgamma()`. Grenze der obersten 25 %: `qgamma(0.75, ...)`.

Lösungskästchen


Kästchen 1 · R-Code und R-Output

```
> alpha.hat <- exp(model$estimate[1])
> beta.hat <- exp(model$estimate[2])
> pdf("Gamma.pdf")
> hist(x, freq = FALSE, breaks = seq(0, 120, by = 10), ylim = c(0, 0.025),
+      main = "Grafik Aufgabenteil k)", xlab = "Dauer", ylab = "Dichte")
> x.seq <- seq(0, 120, by = 0.5)
> lines(x.seq, dgamma(x.seq, alpha.hat, beta.hat), col = 2)
> dev.off()
pdf
  2
> round(pgamma(30, alpha.hat, beta.hat), 3)
[1] 0.478
> round(qgamma(0.75, alpha.hat, beta.hat), 3)
[1] 47.586
```

Lösungskästchen

Kästchen 2 · Antwortsatz

Laut Modell beträgt $P(\text{Dauer} \leq 30)$ 0.478. Ab 47.586 Minuten gehört eine Ausleihe zu den 25 % längsten.



Inhalt der Datei Gamma.pdf

8 · Konfidenzintervalle und Tests in R

Konfidenzintervall für μ (σ bekannt und unbekannt)

~55 %

Aufgabe. Für die Münzen ($n = 12$) berechnen Sie ein 90 %-Konfidenzintervall für μ (i) mit bekanntem $\sigma = 7$, (ii) mit unbekanntem σ .

(5 P)

SO LÖST DU ES

1. σ bekannt: $\bar{x} \pm \text{qnorm}(1 - \alpha/2) \cdot \sigma/\sqrt{n}$.
2. σ unbekannt: $\bar{x} \pm \text{qt}(1 - \alpha/2, n - 1) \cdot s/\sqrt{n}$ mit $s = \text{sd}(x)$.
3. Ergebnis immer als Intervall [unten, oben] angeben.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> x <- d$Muenzen
> n <- length(x)
> alpha <- 0.1
> round(mean(x) + c(-1, 1) * qnorm(1 - alpha/2) * 7 / sqrt(n), 3)
[1] 18.760 25.407
> round(mean(x) + c(-1, 1) * qt(1 - alpha/2, n - 1) * sd(x) / sqrt(n), 3)
[1] 18.303 25.864
```

Lösungskästchen

Kästchen 2 · Antwortsatz

Das 90 %-Konfidenzintervall für μ (σ unbekannt) lautet [18.303, 25.864].

Konfidenzintervall für Anteil und Varianz

~30 %

Aufgabe. (i) Von 100 Befragten sagen 40 „ja“. 95 %-KI für den Anteil π . (ii) 95 %-KI für die Varianz der Münzen.

(4 P)

SO LÖST DU ES

1. Anteil: $\hat{\pi} \pm \text{qnorm}(1 - \alpha/2) \cdot \sqrt{(\hat{\pi}(1 - \hat{\pi}))/n}$.
2. Varianz: $[(n-1)s^2 / \text{qchisq}(1 - \alpha/2, n-1), (n-1)s^2 / \text{qchisq}(\alpha/2, n-1)]$.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> p <- 40/100
> round(p + c(-1, 1) * qnorm(0.975) * sqrt(p * (1 - p) / 100), 3)
[1] 0.304 0.496
> s2 <- var(d$Muenzen)
> round(c((n - 1) * s2 / qchisq(0.975, n - 1), (n - 1) * s2 / qchisq(0.025, n - 1)), 3)
[1] 26.684 153.290
```

Aufgabe. Testen Sie zum Niveau $\alpha = 0.1$, ob die mittlere Anzahl Münzen größer als 20 ist. Stellen Sie die Hypothesen auf, geben Sie Prüfgröße, Ablehnungsbereich, p-Wert und Testentscheidung an.

(6 P)**SO LÖST DU ES**

1. Hypothesen: $H_0: \mu \leq 20$ gegen $H_1: \mu > 20$.
2. `t.test(x, mu = 20, alternative = "greater", conf.level = 0.9)`. Zweiseitig: "two.sided", links: "less".
3. Output: `t` = Prüfgröße, `df` = Freiheitsgrade, `p-value`.
4. Ablehnungsbereich (rechts): `(qt(1 - alpha, n - 1), Inf)`.
5. Entscheidung: $p\text{-Wert} < \alpha \rightarrow H_0$ ablehnen.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> tt <- t.test(d$Muenzen, mu = 20, alternative = "greater", conf.level = 0.9)
> tt
```

One Sample t-test

```
data: d$Muenzen
t = 0.98969, df = 11, p-value = 0.1718
alternative hypothesis: true mean is greater than 20
90 percent confidence interval:
 19.21326      Inf
sample estimates:
mean of x
 22.08333

> round(qt(0.9, df = 11), 3)
[1] 1.363
> round(tt$statistic, 3)
      t
0.99
> round(tt$p.value, 3)
[1] 0.172
```

Lösungskästchen

Kästchen 2 · Antwortsatz

$H_0: \mu \leq 20$, $H_1: \mu > 20$. Die Prüfgröße $t = 0.99$ liegt nicht im Ablehnungsbereich $(1.363, \infty)$; der p-Wert 0.172 ist größer als $\alpha = 0.1$. H_0 wird nicht abgelehnt.

Aufgabe. Daten 19.2, 17.4, 18.5, 16.5, 18.9; $H_0: \mu = 17$, $\sigma^2 = 2.25$ bekannt, $\alpha = 0.01$ (zweiseitig). Berechnen Sie z , die kritischen Werte und den p -Wert. **(4 P)**

SO LÖST DU ES

- $z = (\bar{x} - \mu_0) / (\sigma / \sqrt{n})$.
- Kritische Werte: `qnorm(alpha/2)` und `qnorm(1 - alpha/2)`.
- p -Wert zweiseitig: `2 * (1 - pnorm(abs(z)))`. σ unbekannt $\rightarrow$ `qt / pt` mit $n - 1$.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> y <- c(19.2, 17.4, 18.5, 16.5, 18.9)
> z <- (mean(y) - 17) / (sqrt(2.25) / sqrt(length(y)))
> round(z, 3)
[1] 1.64
> round(qnorm(c(0.005, 0.995)), 3)
[1] -2.576 2.576
> round(2 * (1 - pnorm(abs(z))), 3)
[1] 0.101
```

Lösungskästchen

Kästchen 2 · Antwortsatz

$z = 1.64$ liegt nicht im Ablehnungsbereich $(-\infty, -2.576) \cup (2.576, \infty)$; $p = 0.101 > 0.01 \rightarrow H_0$ wird nicht abgelehnt.

Binomialtest über pbinom

Aufgabe. Bei 20 Münzwürfen fällt 15-mal Kopf. Berechnen Sie den p -Wert für $H_0: \pi = 0.5$ gegen $H_1: \pi > 0.5$. **(2 P)**

SO LÖST DU ES

- p -Wert = $P(X \geq 15)$ unter $H_0 = 1 - \text{pbinom}(14, 20, 0.5) = \text{sum}(\text{dbinom}(15:20, 20, 0.5))$.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> 1 - pbinom(14, 20, 0.5)
[1] 0.02069473
> sum(dbinom(15:20, 20, 0.5))
[1] 0.02069473
```

Lösungskästchen

Kästchen 2 · Antwortsatz

Der p -Wert beträgt 0.021; zum Niveau 5 % wird H_0 abgelehnt.

Aufgabe. Testen Sie mit der Kontingenztafel (Rauchen $\times$ Sport: 15, 75, 45, 65), ob Rauchen und Sport unabhängig sind ($\alpha = 0.05$). Geben Sie die erwarteten Häufigkeiten, die Prüfgröße und den p-Wert an.

(5 P)**SO LÖST DU ES**

1. Tafel als Matrix: `matrix(c(...), nrow = 2)` (spaltenweise!).
2. `chisq.test(tafel, correct = FALSE)` (ohne Korrektur = wie in der Vorlesung von Hand).
3. `$expected`, `$statistic`, `$p.value`.
4. Mit Daten: `chisq.test(table(d$X, d$Y))`.

Lösungskästchen

Kästchen 1 · R-Code und R-Output

```
> tafel <- matrix(c(15, 75, 45, 65), nrow = 2)
> test <- chisq.test(tafel, correct = FALSE)
> test$expected
  [,1] [,2]
[1,]  27  33
[2,]  63  77
> round(test$statistic, 3)
X-squared
 13.853
> round(test$p.value, 4)
[1] 2e-04
```

Lösungskästchen

Kästchen 2 · Antwortsatz

Die Prüfgröße beträgt $\chi^2 = 13.853$, der p-Wert $0.0002 < 0.05$. H_0 (Unabhängigkeit) wird abgelehnt; Rauchen und Sport hängen zusammen.

⚠ Bei 2x2-Tafeln nutzt R ohne `correct = FALSE` die Yates-Korrektur – dann weicht der Wert vom Handergebnis ab.

9 · Fehler finden und Klausur-Ablauf**Typische Fehlermeldungen**

~40 %

Aufgabe. Erklären Sie die Fehler: (i) „kann Datei nicht öffnen“, (ii) „Objekt 'd' nicht gefunden“, (iii) „unerwartetes Symbol“, (iv) Mittelwert ist NA, (v) Zahlen sind chr.

(-)**SO LÖST DU ES**

1. (i) Datei nicht im Working Directory oder Name falsch → `list.files()`.
2. (ii) Objekt wurde nie erstellt (Zeile davor hatte einen Fehler) oder falsch geschrieben.
3. (iii) Komma, Klammer oder Anführungszeichen fehlt.
4. (iv) NA in den Daten → `na.rm = TRUE`.
5. (v) `dec` falsch → neu einlesen mit richtigem `dec`.
6. Gegen Fehler: Klammern zählen, Anführungszeichen paarweise, Groß-/Kleinschreibung prüfen, `?befehl` öffnet die Hilfe.

Aufgabe. So gehst du in Teil B vor.**(45 P)****SO LÖST DU ES**

1. Minute 0–3: Datei in Dokumente ansehen (sep/dec), Skript öffnen und speichern.
2. Pro Teilaufgabe: Code ins Skript, Strg + Enter, Output prüfen.
3. Kästchen 1: Code + Output aus der Console kopieren. Kästchen 2: Satz mit 3 Nachkommastellen.
4. Grafik: pdf() ... dev.off(), Titel mit Sitz, Matr.Nr., Aufgabenteil, Datei hochladen.
5. Hängst du fest: Ersatzobjekt erzeugen und weiter (Folgefehler werden gewertet). Falschen Code aus der Antwort löschen.
6. Letzte 5 Minuten: alle Kästchen gefüllt? Alle Dateien hochgeladen?