

Rezeptbuch Tag 1 · im Klausurformat

Jede Karte: **Aufgabe** (wie in der Klausur) → **So löst du es** (Schritt für Schritt) → **Lösungskästchen** (genau das schreibst du hin) → **Vorsicht**.

Prozent-Zahl = geschätzte Wahrscheinlichkeit, dass dieser Aufgabentyp in der Klausur vorkommt (nach Probeklausur 2022, Testaten 1–2, Tutorien 1–3). Nur eine Schätzung. **≥ 70 %** fast sicher · **30–69 %** häufig · **< 30 %** manchmal.

A · Grundbegriffe, Skalen, Stichproben

Skalenniveau und diskret/stetig

~90 %

Aufgabe. Eine Umfrage im Fitnessstudio erhebt: (i) Alter in Jahren, (ii) Anzahl Besuche pro Woche, (iii) Tarif (Basic, Premium, Student), (iv) Zufriedenheit von 1 bis 7. Geben Sie jeweils das Skalenniveau an und ob das Merkmal diskret oder stetig ist. **(4 P)**

SO LÖST DU ES

- Frage 1: Kann man die Werte ordnen? Nein → **nominal**.
- Frage 2: Sind die Abstände sinnvoll? Nein → **ordinal**. Ja → **kardinal**.
- Frage 3: Wird gezählt (Personen, Besuche)? → **diskret**.
Wird gemessen (Zeit, Gewicht, Geld, Größe)? → **stetig**.
- Nominale und ordinale Merkmale sind immer diskret.

Lösungskästchen

- (i) Alter: kardinal, stetig
- (ii) Anzahl Besuche: kardinal, diskret
- (iii) Tarif: nominal, diskret
- (iv) Zufriedenheit: ordinal, diskret

⚠ Skala 1–7 ist **ordinal**, nicht kardinal. Punkte 0–100 sind kardinal. 0/1-Merkmal (richtig/falsch): „ordinalskaliert/binär“.

Sinnvolle Lagemaße

~60 %

Aufgabe. Welche Lagemaße sind für das Merkmal (iii) Tarif und (iv) Zufriedenheit sinnvoll? Begründen Sie. **(2 P)**

SO LÖST DU ES

- Skala bestimmen.
- nominal → nur Modus. ordinal → Modus und Median.
kardinal → Modus, Median, Mittelwert.
- Immer einen Grund dazuschreiben.

Lösungskästchen

Tarif: nur der Modus, da das Merkmal nominal ist.
Zufriedenheit: Modus und Median, da das Merkmal ordinal ist (ordnen möglich, Abstände nicht interpretierbar).

⚠ Ausnahme: 0/1-Daten → Mittelwert = Anteil der Einsen ist sinnvoll.

Einheit, Grundgesamtheit, Stichprobe

~25 %

Aufgabe. Das Studio befragt zufällig 200 seiner 2400 Mitglieder (Jahr 2026). Nennen Sie die statistische Einheit, die Grundgesamtheit und die Stichprobe. **(3 P)**

SO LÖST DU ES

- Einheit = **ein** einzelnes Objekt (Singular).
- Grundgesamtheit = **alle** + Ort + Zeit.
- Stichprobe = die wirklich Befragten.

Lösungskästchen

Einheit: ein Mitglied des Studios.
Grundgesamtheit: alle 2400 Mitglieder des Studios im Jahr 2026.
Stichprobe: die 200 befragten Mitglieder.

⚠ Nicht „die Mitglieder“ als Einheit schreiben.

Stichprobenverfahren

~30 %

Aufgabe. (a) Aus jedem der 7 Stadtteile werden zufällig 30 Personen gezogen. (b) Es werden zufällig 3 Schulen gewählt und alle Lehrkräfte befragt. Welche Verfahren liegen vor? (2 P)

SO LÖST DU ES

1. „zufällig aus der ganzen Liste“ → einfache Zufallsstichprobe.
2. „aus **jeder** Gruppe zufällig“ / „Anteile wie in der Gesamtheit“ → geschichtete Stichprobe.
3. „zufällig **ganze** Gruppen, darin **alle**“ → Klumpenstichprobe.
4. „Quoten bewusst erfüllen, nicht zufällig“ → Quotenverfahren.

Lösungskästchen

- (a) Geschichtete Stichprobe.
(b) Klumpenstichprobe.

⚠ Nur Göttinger Schulen für ganz Deutschland → Klumpen, nicht geschichtet.

Störvariable und Kontrolle

~20 %

Aufgabe. Ein Studio testet ein neues Trainingsprogramm. Nennen Sie eine Störvariable und eine Möglichkeit, sie zu kontrollieren. (2 P)

SO LÖST DU ES

1. Störvariable: beeinflusst das Ergebnis, wird aber nicht untersucht (Alter, Vorwissen, Fitness).
2. Kontrolle: Randomisierung (zufällige Gruppen) · Homogenisierung (gleiche Gruppen bilden) · statistische Modellierung (Variable in die Analyse).

Lösungskästchen

Störvariable: das Alter der Teilnehmenden.
Kontrolle durch Randomisierung, d. h. zufällige Aufteilung auf Trainings- und Kontrollgruppe.

Repräsentativ? Schluss auf die Grundgesamtheit

~15 %

Aufgabe. Eine Online-Umfrage mit 20 Teilnehmenden ergibt 35 % Raucher. Ein Kommilitone sagt: „Also rauchen 35 % aller Deutschen.“ Nehmen Sie Stellung. (2 P)

SO LÖST DU ES

1. Fehlen Personen systematisch? (Online → ohne Internet fehlen).
2. Ist n klein? → Schätzung unsicher.

Lösungskästchen

Nein. Die Stichprobe ist nicht repräsentativ, da Personen ohne Internet keine Chance hatten, teilzunehmen. Außerdem ist $n = 20$ zu klein; der wahre Anteil kann deutlich abweichen.

Modell · deterministisch · deskriptiv/induktiv

~10 %

Aufgabe. Korrigieren Sie: „Ein Modell ist die fehlerfreie Wiedergabe der Realität.“ (1 P)

SO LÖST DU ES

1. Auswendig lernen – keine Rechnung.

Lösungskästchen

Ein Modell ist eine vereinfachte Beschreibung der Realität.

Weitere Sätze: Deterministisch: keine Unsicherheit im Modell. · Induktive Statistik schließt von der Stichprobe auf die Grundgesamtheit unter Berücksichtigung der Unsicherheit. · Ein diskretes Merkmal kann auch abzählbar unendlich viele Werte haben.

B · Häufigkeiten, Histogramm, Verteilungsfunktion

Häufigkeitstabelle vervollständigen

~35 %

Aufgabe. 30 Personen: Anzahl gelesener Bücher 1–5. Bekannt: $h_1 = 4$, $H_2 = 12$, $f_3 = 1/3$, $F_4 = 28/30$.
Vervollständigen Sie die Tabelle (h , f , H , F).

(3 P)

SO LÖST DU ES

1. n = Summe aller h (hier gegeben: 30).
2. $f = h / n$.
3. H = von links **aufaddieren**.
4. $F = H / n$. Letztes $F = 1$.
5. Rückwärts: $h = H - \text{vorheriges } H$ · $h = f \cdot n$ · $H = F \cdot n$.

⚠ Brüche sind erlaubt ($8/30 = 4/15$).

Lösungskästchen

h : 4, 8, 10, 6, 2 · f : 0.133, 0.267, 0.333, 0.2, 0.067
 H : 4, 12, 22, 28, 30 · F : 0.133, 0.4, 0.733, 0.933, 1

Anteile: höchstens / weniger als / mehr als / mindestens

~40 %

Aufgabe. Bestimmen Sie die Anteile der Studierenden mit (i) mehr als 3, (ii) mindestens 3, (iii) weniger als 4, (iv) nicht mehr als 5 Semestern. (F : $F(2)=1/23$, $F(3)=8/23$, $F(4)=13/23$, $F(5)=18/23$)

(4 P)

SO LÖST DU ES

1. höchstens k / nicht mehr als $k \rightarrow F(k)$.
2. weniger als $k \rightarrow F(k-1)$.
3. mehr als $k \rightarrow 1 - F(k)$.
4. mindestens $k \rightarrow 1 - F(k-1)$.

Lösungskästchen

(i) $1 - 8/23 = 15/23$ · (ii) $1 - 1/23 = 22/23$ · (iii) $F(3) = 8/23$ · (iv) $F(5) = 18/23$

Höhen im normierten Histogramm

~45 %

Aufgabe. 50 Studierende, Pendelzeit: $[0,10)$: 8 · $[10,20)$: 15 · $[20,30)$: 12 · $[30,60)$: 10 · $[60,90]$: 5. Berechnen Sie für jede Klasse die relative Häufigkeit und die Höhe der Säule im (normierten) Histogramm.

(4 P)

SO LÖST DU ES

1. $f = \text{Anzahl} / n$ ($8/50 = 0.16$).
2. Breite = obere – untere Grenze (10).
3. Höhe = f / Breite ($0.16/10 = 0.016$).
4. Kontrolle: Summe (Breite · Höhe) = 1.

Lösungskästchen

f : 0.16, 0.3, 0.24, 0.2, 0.1
Höhe: 0.016, 0.03, 0.024, 0.0067, 0.0033

⚠ Bei absoluten Häufigkeiten: Höhe = $h / (\text{Breite} \cdot n)$.

Aufgabe. Zeichnen Sie das normierte Histogramm der Pendelzeiten.

(3 P)


SO LÖST DU ES

1. x-Achse: Klassengrenzen eintragen (0, 10, 20, 30, 60, 90), Name + Einheit.
2. y-Achse: „Dichte“, Skala bis zur größten Höhe.
3. Pro Klasse ein Rechteck: Breite = Klasse, Höhe = berechnete Höhe.
4. Rechtecke berühren sich (keine Lücken). Titel.

Lösungskästchen

Zeichnung wie unten. Achsen: „Pendelzeit in Minuten“ / „Dichte“.

⚠ Nicht die Anzahl als Höhe nehmen – das wäre ein Säulendiagramm.



Anteil in einem Intervall aus dem Histogramm

~40 %

Aufgabe. Schätzen Sie mit dem Histogramm den Anteil der Studierenden, die zwischen 25 und 45 Minuten pendeln. Welche Annahme treffen Sie?

(3 P)

SO LÖST DU ES

1. Intervall in Stücke teilen, jedes Stück in einer Klasse: 25–30 und 30–45.
2. Pro Stück: Breite · Höhe: $5 \cdot 0.024 = 0.12$ · $15 \cdot 0.0067 = 0.1$.
3. Addieren: 0.22. Anzahl? $\times n$.

Lösungskästchen

Anteil $\approx 5 \cdot 0.024 + 15 \cdot 0.0067 = 0.22$.

Annahme: Die Werte sind innerhalb jeder Klasse gleichmäßig verteilt.

⚠ Den Annahme-Satz nie vergessen (1 Punkt).

Anzahl aus dem Histogramm

~30 %

Aufgabe. Ein normiertes Histogramm von 400 Beobachtungen hat über (30, 40] die Höhe 0.025. Wie viele Beobachtungen liegen in dieser Klasse?

(1 P)

SO LÖST DU ES

1. Höhe · Breite = Anteil: $0.025 \cdot 10 = 0.25$.
2. Anteil · n = Anzahl: $0.25 \cdot 400$.

Lösungskästchen

100 Beobachtungen.

Aufgabe. Welche Klasse ist die Modalklasse? Ist die Aussage „Die Modalklasse ist immer die Klasse mit der höchsten Säule“ korrekt? (2 P)

SO LÖST DU ES

1. Modalklasse = Klasse mit der **größten Anzahl** (nicht die höchste Säule).
2. Bei ungleichen Breiten kann eine breite Klasse viele Werte, aber eine niedrige Säule haben.

Lösungskästchen

Modalklasse: [10, 20), da dort die meisten Beobachtungen liegen (15).

Die Aussage ist im Allgemeinen falsch: Bei ungleichen Klassenbreiten ist die Höhe = f / Breite .

Säulendiagramm oder Histogramm?



Aufgabe. Wieso ist die folgende Grafik (absolute Häufigkeiten, ungleiche Klassenbreiten) kein Histogramm? Was ist der Nachteil? Wie muss der R-Befehl geändert werden? (3 P)

SO LÖST DU ES

1. Säulendiagramm: Höhe = Anzahl. Histogramm: Fläche = Anteil.
2. Nachteil: breite Klassen wirken zu groß.
3. R: `freq = FALSE` oder `prob = TRUE`.

Lösungskästchen

Es ist ein Säulendiagramm, da absolute Häufigkeiten bei unterschiedlichen Klassenbreiten dargestellt werden. Das führt zu einer verzerrten Darstellung. Richtig: `hist(x, breaks = ..., freq = FALSE)`.



Empirische Verteilungsfunktion aufstellen und skizzieren

~55 %


Aufgabe. Zehn Studierende: Tassen Kaffee gestern: 0, 1, 1, 2, 2, 2, 3, 3, 4, 6. Stellen Sie $\hat{F}(x)$ als Funktion mit Fallunterscheidung auf und skizzieren Sie sie. (4 P)

SO LÖST DU ES

1. Verschiedene Werte sortieren: 0, 1, 2, 3, 4, 6.
2. Kumulierte Anteile: 0.1, 0.3, 0.6, 0.8, 0.9, 1.
3. Fallunterscheidung: erste Zeile 0, letzte Zeile 1; links $\leq$, rechts $<$.
4. Skizze: waagerechte Stufen, $\bullet$ links (gehört dazu), $\circ$ rechts. Keine senkrechten Linien. Links bei 0 und rechts bei 1 ins Unendliche weiterzeichnen. Achsen beschriften.

Lösungskästchen

$\hat{F}(x) = 0$ für $x < 0$
0.1 für $0 \leq x < 1$
0.3 für $1 \leq x < 2$
0.6 für $2 \leq x < 3$
0.8 für $3 \leq x < 4$
0.9 für $4 \leq x < 6$
1 für $x \geq 6$
+ Skizze wie unten



Verteilungsfunktion ablesen

~35 %

Aufgabe. Lesen Sie ab: $\hat{F}(2.5)$, den Anteil mit mehr als 2 Tassen, den Anteil mit mindestens 1 Tasse und den Median. (3 P)

SO LÖST DU ES

1. $\hat{F}(2.5)$: Stufe über 2.5 $\rightarrow$ 0.6.
2. mehr als 2: $1 - F(2) = 0.4$ · mindestens 1: $1 - F(0) = 0.9$.
3. Median aus der Grafik: bei 0.5 waagerecht gehen, bis man eine Stufe trifft $\rightarrow$ x-Wert ablesen.

Lösungskästchen

$\hat{F}(2.5) = 0.6$ · Anteil > 2 : 0.4 · Anteil ≥ 1 : 0.9 · Median = 2

Aus der Verteilungsfunktion zurückrechnen

~20 %

Aufgabe. $\hat{F}$ springt bei 10 auf 0.3, bei 20 auf 0.6 und bei 30 auf 1 ($n = 10$). Bestimmen Sie die absoluten Häufigkeiten und den Mittelwert. (3 P)

SO LÖST DU ES

1. Sprunghöhe = f : 0.3, 0.3, 0.4.
2. $h = f \cdot n$: 3, 3, 4.
3. Mittelwert = $\sum \text{Wert} \cdot h / n$.

Lösungskästchen

h : 3, 3, 4 · $\bar{x} = (3 \cdot 10 + 3 \cdot 20 + 4 \cdot 30) / 10 = 21$

C · Lagemaße

Mittelwert, Median, Modus aus Rohdaten

~85 %

Aufgabe. Wartezeiten (min): 12, 7, 3, 9, 7, 15, 7, 10. Berechnen Sie arithmetisches Mittel, Median und Modus.

(3 P)

SO LÖST DU ES

1. Zuerst **sortieren**: 3, 7, 7, 7, 9, 10, 12, 15 ($n = 8$).
2. Mittelwert = Summe / $n = 70/8$.
3. Median: n ungerade $\rightarrow$ mittlerer Wert. n gerade $\rightarrow$ Mittel aus Platz $n/2$ und $n/2+1$ (Platz 4 und 5).
4. Modus = häufigster Wert.

Lösungskästchen

$$\bar{x} = 70/8 = 8.75 \cdot x_{\text{med}} = (7 + 9)/2 = 8 \cdot x_{\text{mod}} = 7$$

⚠ Median immer aus der sortierten Liste aller Werte.

Lagemaße aus einer Häufigkeitstabelle

~40 %

Aufgabe. 20 Haushalte, Kinder a : 0, 1, 2, 3, 4 mit h : 5, 8, 4, 2, 1. Bestimmen Sie Modus, Median und Mittelwert.

(3 P)

SO LÖST DU ES

1. Mittelwert: $\sum a \cdot h / n = (0 + 8 + 8 + 6 + 4)/20$.
2. Median: H bilden (5, 13, 17, ...). Platz 10 und 11 $\rightarrow$ beide bei $a = 1$.
3. Modus: a mit größtem h .

Lösungskästchen

$$\bar{x} = 26/20 = 1.3 \cdot x_{\text{med}} = 1 \cdot x_{\text{mod}} = 1$$

Klassierte Daten: Mittelwert und Varianz

~45 %

Aufgabe. Arbeitszeit: [0,4]: 40.2 %, (4,8]: 19.6 %, (8,12]: 21.9 %, (12,16]: 18.3 %. Berechnen Sie näherungsweise Mittelwert und Varianz mit den Klassenmitten.

(3 P)

SO LÖST DU ES

1. Klassenmitte $m = (\text{unten} + \text{oben})/2$: 2, 6, 10, 14.
2. Tabelle: $f \cdot m$ und $f \cdot m^2$.
3. Mittelwert = $\sum f \cdot m$.
4. Varianz = $\sum f \cdot m^2 - \text{Mittelwert}^2$.

Lösungskästchen

$$\begin{aligned}\bar{x} &= 0.402 \cdot 2 + 0.196 \cdot 6 + 0.219 \cdot 10 + 0.183 \cdot 14 = 6.732 \\ s^2 &= 66.432 - 6.732^2 = 21.112\end{aligned}$$

⚠ Prozente sind schon f – nicht durch n teilen. Mit Anzahlen: $\sum h \cdot m / n$.

Gesamtmittelwert aus zwei Gruppen

~15 %

Aufgabe. Filiale A: 9 Personen, Ø 4.844 Tsd. €. Filiale B: 6 Personen, Ø 3.5 Tsd. €. Berechnen Sie das Durchschnittsgehalt aller 15 Personen.

(2 P)

SO LÖST DU ES

1. Summe je Gruppe = $n \cdot \text{Mittel}$: 43.6 und 21.
2. Summen addieren, durch alle teilen.

Lösungskästchen

$$\bar{x} = (9 \cdot 4.844 + 6 \cdot 3.5)/15 = 64.6/15 = 4.307$$

⚠ Nicht $(4.844 + 3.5)/2$ rechnen.

Fehlender, falscher oder neuer Wert

~10 %

Aufgabe. 5 Werte haben den Mittelwert 6. Vier Werte sind 4, 8, 5, 7. Wie lautet der fünfte?

(1 P)

SO LÖST DU ES

1. Summe = $n \cdot \text{Mittelwert} = 30$.
2. Fehlender Wert = Summe – bekannte Werte.

Lösungskästchen

$$5 \cdot 6 - (4 + 8 + 5 + 7) = 6$$

Welches Lagemaß ist typischer? (Ausreißer)

~35 %

Aufgabe. Gehälter (Tsd. €): 2.8, 3.1, 3.1, 3.4, 3.6, 3.9, 4.2, 4.5, 15.0. Welches Lagemaß beschreibt das typische Gehalt besser?

(1 P)

SO LÖST DU ES

1. Gibt es einen extremen Wert? → Median.

Lösungskästchen

Der Median (3.6), da er robust gegenüber dem Ausreißer 15.0 ist; der Mittelwert (4.844) wird von ihm nach oben gezogen.

Schiefe bestimmen

~35 %

Aufgabe. Ist die Verteilung rechtsschief, symmetrisch oder linksschief? Begründen Sie mit den Lagemaßen.

(2 P)

SO LÖST DU ES

1. Mittelwert > Median > Modus → rechtsschief (linkssteil).
2. Mittelwert < Median < Modus → linksschief.
3. Alle etwa gleich → symmetrisch.
4. Zahlen in die Antwort schreiben.

Lösungskästchen

Rechtsschief, da $\bar{x} = 4.844 > x_{\text{med}} = 3.6 > x_{\text{mod}} = 3.1$.

Transformation: Lagemaße und Streuung

~20 %

Aufgabe. Lieferzeiten in Tagen: $\bar{x} = 5.5$, $s^2 = 9.917$, $s = 3.149$. Die Zeiten werden in Stunden umgerechnet. Wie ändern sich Mittelwert, Varianz und Standardabweichung?

(2 P)

SO LÖST DU ES

1. Faktor finden: Tage → Stunden: $\cdot 24$. (+5 % → $\cdot 1.05$)
2. Mittelwert, Median, s , IQR: $\cdot$ Faktor.
3. Varianz: $\cdot \text{Faktor}^2$.
4. Nur addiert (+200 €)? → Mittelwert + 200, Varianz und s bleiben gleich.

Lösungskästchen

$$\begin{aligned}\bar{x} &= 24 \cdot 5.5 = 132 \text{ Stunden} \\ s^2 &= 24^2 \cdot 9.917 = 5712 \text{ Stunden}^2 \\ s &= 24 \cdot 3.149 = 75.58 \text{ Stunden}\end{aligned}$$

⚠ Nicht neu rechnen – nur die Regel anwenden.

0/1-Daten

~25 %

Aufgabe. 20 Vorhersagen: 11-mal falsch (0), 9-mal richtig (1). Skalenniveau? Berechnen Sie Modus, Median, Mittelwert und Varianz. Falls nicht sinnvoll, begründen Sie.

(5 P)

SO LÖST DU ES

1. Skala: ordinalskaliert/binär.
2. Modus = häufigerer Wert, Median = Mitte der sortierten Liste.
3. Mittelwert = Anzahl Einsen / n = Anteil.
4. Varianz: $\bar{x}(1 - \bar{x})$ **oder** „nicht sinnvoll“ – nur eins davon schreiben.

Lösungskästchen

$$\begin{aligned}\text{ordinalskaliert/binär} \cdot x_{\text{mod}} &= 0 \cdot x_{\text{med}} = 0 \cdot \bar{x} \\ &= 9/20 = 0.45 \\ s^2 &= 0.45 \cdot 0.55 = 0.248\end{aligned}$$

D · Quantile, Streuung, Boxplot

Quartile nach der Vorlesungsdefinition

~45 %

Aufgabe. Lieferzeiten (sortiert): 2, 3, 3, 4, 4, 4, 5, 5, 6, 7, 9, 14. Bestimmen Sie das untere und das obere Quartil sowie den Interquartilsabstand. **(3 P)**

SO LÖST DU ES

1. Plätze über die Werte schreiben: 1 ... 12.
2. $n \cdot 0.25 = 3 \rightarrow$ das ist eine **Platznummer**.
3. Keine ganze Zahl $\rightarrow$ aufrunden $\rightarrow$ dieser Platz. Ganze Zahl $k \rightarrow$ Mittel aus Platz k und $k+1$.
4. Genauso mit 0.75. IQR = oben – unten.

Lösungskästchen

$$12 \cdot 0.25 = 3 \rightarrow x_{0.25} = (x_{(3)} + x_{(4)})/2 = (3 + 4)/2 = 3.5$$
$$12 \cdot 0.75 = 9 \rightarrow x_{0.75} = (6 + 7)/2 = 6.5$$
$$\text{IQR} = 3$$

⚠ „ $x_{0.75} = 9$ “ ist falsch – 9 ist der Platz, nicht der Wert.

Varianz und Standardabweichung

~85 %

Aufgabe. Hinweis: $\sum x = 66$, $\sum x^2 = 482$, $n = 12$. Berechnen Sie die empirische Varianz s^2 , die unverzerzte Varianz s^{*2} und die Standardabweichung s . Geben Sie Ihren Lösungsweg an. **(3 P)**

SO LÖST DU ES

1. Mittelwert: $66/12 = 5.5$.
2. $s^2 = \sum x^2/n - \text{Mittelwert}^2 = 40.1667 - 30.25$.
3. $s^{*2} = s^2 \cdot n/(n-1)$ – keine Wurzel!
4. $s = \sqrt{s^2}$.
5. Ohne $\sum x^2$: jeden Wert quadrieren und addieren. Tabelle: $\sum a^2 \cdot h / n - \bar{x}^2$.

Lösungskästchen

$$s^2 = 482/12 - 5.5^2 = 9.917$$
$$s^{*2} = 12/11 \cdot 9.917 = 10.818$$
$$s = \sqrt{9.917} = 3.149$$

⚠ „empirisch“ = $1/n$. „unverzerrt“ = $1/(n-1)$. R: var und sd sind unverzerrt.

Varianz aus R-Output umrechnen

~20 %

Aufgabe. R liefert $\text{var}(x) = 53.174$ bei $n = 12$. Wie groß ist die empirische Varianz? **(1 P)**

SO LÖST DU ES

1. R rechnet mit $n - 1$.
2. $s^2 = \text{var} \cdot (n - 1)/n$.

Lösungskästchen

$$s^2 = 53.174 \cdot 11/12 = 48.743$$

Aufgabe. Gibt es Ausreißer nach der 1.5-IQR-Regel? Wo enden die Whisker? Skizzieren Sie den Boxplot ($x_{0.25} = 3.5$, Median 4.5 , $x_{0.75} = 6.5$, Daten wie oben). (3 P)

SO LÖST DU ES

1. $1.5 \cdot \text{IQR} = 4.5$.
2. Grenzen: $3.5 - 4.5 = -1$ und $6.5 + 4.5 = 11$.
3. Werte außerhalb = Ausreißer (14).
4. Whisker enden beim letzten **echten Wert innerhalb** der Grenzen: unten 2, oben 9.
5. Zeichnen: Achse mit Zahlen, Box von 3.5 bis 6.5, Strich bei 4.5, Whisker, Punkt bei 14.


Lösungskästchen

Grenzen: -1 und 11 . Der Wert 14 ist ein Ausreißer. Unterer Whisker bei 2 , oberer Whisker bei 9 .

+ Skizze wie unten

⚠ Die Whisker gehen nicht bis zur Grenze (11), sondern bis 9. Beide Whisker nennen!

Boxplot der Lieferzeiten



Boxplots lesen und vergleichen

Aufgabe. Lesen Sie für Gruppe A Median, $x_{0.25}$ und Maximum ab. Welche Aussagen sind korrekt? (i) A streut stärker als B. (ii) A hat einen Ausreißer bei 40. (iii) Gruppe B verursacht längere Kämpfe. (iv) A ist rechtsschief. (4 P)

SO LÖST DU ES


1. Strich in der Box = Median. Box-Ränder = $x_{0.25}$ und $x_{0.75}$. Whisker-Ende = Min/Max (ohne Ausreißer).
2. Streuung vergleichen: Breite der Box (IQR).
3. Nur eingezeichnete Punkte sind Ausreißer.
4. Median nah am unteren Rand + langer oberer Whisker → rechtsschief.
5. Unterschiede zwischen Gruppen sind keine Kausalität.

Lösungskästchen

A: Median 8, $x_{0.25} = 5$, Maximum 40.

(i) richtig (IQR 15 gegen 4) · (ii) falsch, kein Punkt eingezeichnet · (iii) falsch, nur Zusammenhang, keine Kausalität · (iv) richtig

Kampfzeiten nach Gruppe



Vorteil von Standardabweichung und Median

~35 %

Aufgabe. Welchen Vorteil bietet die Standardabweichung gegenüber der Varianz? Nennen Sie einen Vorteil des Medians gegenüber dem Mittelwert. (2 P)

SO LÖST DU ES

1. Auswendig lernen.

Lösungskästchen

Die Standardabweichung hat die gleiche Maßeinheit wie das Merkmal.
Der Median ist robust gegenüber Ausreißern.

⚠ Nicht: „Die Standardabweichung wird durch Ausreißer nicht verzerrt“ – das ist falsch.

Spannweite und Form der Verteilung

~10 %

Aufgabe. Bestimmen Sie die Spannweite und beschreiben Sie die Form der Verteilung. (2 P)

SO LÖST DU ES

1. Spannweite = Maximum – Minimum.
2. Form: Anzahl Gipfel (unimodal/bimodal) + Schiefe.

Lösungskästchen

Spannweite = $90 - 2.5 = 87.5$. Die Verteilung ist unimodal und rechtsschief.

E · Zwei Merkmale: Kontingenztafel und χ^2

Kontingenztafel aus einem Text

~35 %

Aufgabe. Von 200 Studierenden rauchen 60 (R). Von den Rauchenden treiben 15 Sport (S). Insgesamt treiben 110 keinen Sport. Erstellen Sie die Kontingenztafel inkl. Randhäufigkeiten. (3 P)

SO LÖST DU ES

1. Leere 2x2-Tafel mit Σ -Zeile und Σ -Spalte zeichnen, $n = 200$ unten rechts.
2. Zahlen aus dem Text eintragen (60, 15, 110).
3. Rest durch Subtraktion: $60 - 15 = 45$ · $200 - 60 = 140$ · $200 - 110 = 90$ · $90 - 15 = 75$ · $140 - 75 = 65$.
4. Kontrolle: alle Summen stimmen.

Lösungskästchen

	S	kein S	Σ
R	15	45	60
kein R	75	65	140
Σ	90	110	200

⚠ „30 % der Frauen“ → $\times$ Anzahl Frauen, nicht $\times n$.

Bedingte Anteile und Zusammenhang

~35 %

Aufgabe. Berechnen Sie den Anteil der Sporttreibenden unter den Rauchenden und unter den Nichtraucher. Deutet das auf einen Zusammenhang hin? (3 P)

SO LÖST DU ES

1. „unter den Rauchenden“ → durch die Summe der Rauchenden teilen (60).
2. Genauso für die andere Gruppe (140).
3. Anteile verschieden → Zusammenhang. Gleich → kein Zusammenhang.
4. „Anteil aller ...“ oder „A und B“ → durch n teilen.

Lösungskästchen

Unter den Rauchenden: $15/60 = 0.25$ · unter den Nichtrauchenden: $75/140 = 0.536$.
Ja, die Anteile unterscheiden sich deutlich, also gibt es einen Zusammenhang zwischen Rauchen und Sport.

Bedingte Verteilung als Tabelle

~20 %

Aufgabe. Bestimmen Sie die bedingte Verteilung von „Sport“ gegeben „Rauchen“ (zeilenweise).

(2 P)

SO LÖST DU ES

1. Jede Zelle durch ihre Zeilensumme teilen.
2. Jede Zeile ergibt 1.

Lösungskästchen

R: 0.25 / 0.75 · kein R: 0.536 / 0.464

Erwartete Häufigkeiten und χ^2 -Koeffizient

~30 %

Aufgabe. Berechnen Sie die bei Unabhängigkeit erwarteten Häufigkeiten und den χ^2 -Koeffizienten.

(4 P)

SO LÖST DU ES

1. Erwartet pro Zelle: Zeilensumme · Spaltensumme / n ($60 \cdot 90/200 = 27$).
2. Pro Zelle: $(\text{beobachtet} - \text{erwartet})^2 / \text{erwartet}$.
3. Alle Zellen addieren.
4. Kontrolle: erwartete Tafel hat dieselben Randsummen.

Lösungskästchen

Erwartet: 27, 33, 63, 77

$$\chi^2 = 12^2/27 + 12^2/33 + 12^2/63 + 12^2/77 = 5.333 + 4.364 + 2.286 + 1.870 = 13.853$$

$\chi^2 > 0 \rightarrow$ Zusammenhang.

⚠ Im Nenner steht der **erwartete** Wert. χ^2 ist nie negativ.

Tafel bei Unabhängigkeit

~15 %

Aufgabe. Wie müsste die Tafel aussehen, wenn Rauchen und Sport unabhängig wären? Wie groß wäre dann χ^2 ?

(2 P)

SO LÖST DU ES

1. Genau die erwarteten Häufigkeiten eintragen.

Lösungskästchen

Rauchen: 27 | 33 · Nichtraucher: 63 | 77. Dann wäre $\chi^2 = 0$.

Streudiagramm zeichnen

~40 %

Aufgabe. Filialen: x (Werbung, Tsd. €): 2, 4, 3, 6, 5, 1 · y (Umsatz, Tsd. €): 30, 45, 38, 60, 48, 25. Zeichnen Sie ein beschriftetes Streudiagramm. (2 P)

SO LÖST DU ES


1. x-Achse: erstes Merkmal mit Name und Einheit, Skala.
2. y-Achse: zweites Merkmal mit Name und Einheit, Skala.
3. Jedes Paar (x, y) als Punkt einzeichnen.
4. Titel darüber schreiben.

Lösungskästchen

Zeichnung wie unten mit Achsen
„Werbeausgaben X (Tsd. €)“ und „Umsatz Y (Tsd. €)“.

⚠ Ohne Achsenbeschriftung gibt es höchstens die Hälfte der Punkte.

Streudiagramm: Werbung und Umsatz



Streudiagramme lesen und zuordnen · $r = 0$ skizzieren

~35 %


Aufgabe. Ordnen Sie die Korrelationskoeffizienten 0.96, -0.91, 0.58, 0.13 und -0.02 den Grafiken A-E zu. Skizzieren Sie ein Streudiagramm mit $r \approx 0$. (3 P)

SO LÖST DU ES

1. Steigt die Wolke → r positiv. Fällt sie → r negativ.
2. Je schmaler die Wolke um eine Gerade → $|r|$ näher bei 1.
3. Runde Wolke oder U-Form → $r \approx 0$.
4. r misst nur **lineare** Zusammenhänge: die Parabel (E) hat $r \approx 0$, obwohl y von x abhängt.

Lösungskästchen

A: 0.96 · B: -0.91 · C: 0.58 · D: 0.13 · E: -0.02
Skizze $r = 0$: runde Punktwolke ohne Richtung, Achsen beschriftet.



Kovarianz und Korrelation aus Summen

~85 %

Aufgabe. Hinweis: $n = 6$, $\Sigma x = 21$, $\Sigma y = 246$, $\Sigma x^2 = 91$, $\Sigma y^2 = 10898$, $\Sigma xy = 979$. Berechnen Sie die empirische Kovarianz und den Korrelationskoeffizienten nach Bravais-Pearson. (4 P)

SO LÖST DU ES

1. Mittelwerte: $\bar{x} = 21/6 = 3.5$, $\bar{y} = 246/6 = 41$.
2. $s^2_x = \Sigma x^2/n - \bar{x}^2 = 2.917$, $s^2_y = \Sigma y^2/n - \bar{y}^2 = 135.333$.
3. Kovarianz $s_{xy} = \Sigma xy/n - \bar{x} \cdot \bar{y}$.
4. $r = s_{xy} / \sqrt{(s^2_x \cdot s^2_y)}$.

Lösungskästchen

$$s_{xy} = 979/6 - 3.5 \cdot 41 = 19.667$$
$$r = 19.667 / \sqrt{(2.917 \cdot 135.333)} = 0.990$$

⚠ $r = 1$ ist fast nie richtig – dann Zähler und Nenner prüfen. Sind s (nicht s^2) gegeben: $r = s_{xy} / (s_x \cdot s_y)$.

Kovarianz und Korrelation aus Rohdaten (Arbeitstabelle)

~45 %

Aufgabe. Portal A: 6, 8, 7, 9, 5 · Portal B: 7, 9, 6, 10, 6. Berechnen Sie $\bar{x}$, $\bar{y}$, s^2_x , s^2_y , s_{xy} (mit $1/n$) und r . (4 P)

SO LÖST DU ES

1. Tabelle mit Spalten x , y , x^2 , y^2 , $x \cdot y$.
2. Jede Spalte summieren: 35, 38, 255, 302, 276.
3. Dann weiter wie oben.

Lösungskästchen

$$\bar{x} = 7 \cdot \bar{y} = 7.6 \cdot s^2_x = 2 \cdot s^2_y = 2.64$$
$$s_{xy} = 276/5 - 7 \cdot 7.6 = 2 \cdot r = 2/\sqrt{(2 \cdot 2.64)} = 0.870$$

⚠ Ohne $x \cdot y$ -Spalte keine Kovarianz.

Korrelationskoeffizient interpretieren

~85 %

Aufgabe. Interpretieren Sie $r = 0.870$. (1–2 P)

SO LÖST DU ES

1. Stärke: $|r| < 0.3$ schwach · $0.3 \text{ bis } < 0.7$ mittel · ≥ 0.7 stark.
2. Richtung: positiv oder negativ.
3. Das Wort „linear“.
4. Die beiden Merkmale nennen.

Lösungskästchen

Es gibt einen starken positiven linearen Zusammenhang zwischen den Bewertungen von Portal A und Portal B.

Kovarianz interpretieren

~30 %

Aufgabe. Was bedeutet das Vorzeichen der Kovarianz? Kann ihr Wert interpretiert werden? (2 P)

SO LÖST DU ES

1. Nur das Vorzeichen deuten.

Lösungskästchen

Das positive Vorzeichen deutet auf einen positiven linearen Zusammenhang hin. Die Höhe ist nicht interpretierbar, da sie von den Einheiten der Merkmale abhängt (z. B. kg·cm).

Einheiten ändern: Kovarianz und Korrelation

~20 %

Aufgabe. Der Umsatz wird in Euro statt in Tsd. € angegeben. Wie ändern sich Kovarianz und Korrelation? (2 P)

SO LÖST DU ES

1. Faktor finden: Tsd. € → €: $\cdot 1000$ · cm → m: $\cdot 0.01$ · °C → °F: $\cdot 1.8$ (+32 egal).
2. Kovarianz · Faktor.
3. Korrelation bleibt gleich (Faktor negativ → nur Vorzeichen wechselt).

Lösungskästchen

Die Kovarianz wird mit 1000 multipliziert (19 667). Die Korrelation bleibt unverändert (0.990), da sie maßstabsunabhängig ist.

Kovarianz aus gegebener Korrelation

~15 %

Aufgabe. Gegeben: $r = -0.6$, $s^2_x = 4$, $s^2_y = 25$. Berechnen Sie die Kovarianz.

(1 P)

SO LÖST DU ES

1. Erst Wurzeln ziehen: $s_x = 2$, $s_y = 5$.
2. $s_{xy} = r \cdot s_x \cdot s_y$.

Lösungskästchen

$$s_{xy} = -0.6 \cdot 2 \cdot 5 = -6$$

Rangkorrelation nach Spearman

~25 %

Aufgabe. Bestimmen Sie die Ränge und den Spearman-Koeffizienten (Portal A: 6, 8, 7, 9, 5 · Portal B: 7, 9, 6, 10, 6).

(3 P)

SO LÖST DU ES

1. Ränge vergeben: kleinster Wert = 1. Gleiche Werte → Durchschnitt der Plätze ($2 \times 6 \rightarrow$ beide 1.5).
2. Mit den Rängen genau wie Pearson rechnen: Mittelwert der Ränge = $(n+1)/2 = 3$.
3. Varianz der Ränge, Kovarianz der Ränge, dann r .
4. Abkürzung: Ränge von x und y identisch → $r_{Sp} = 1$; genau umgekehrt → -1 .

Lösungskästchen

$$\begin{aligned} \text{Ränge A: } 2, 4, 3, 5, 1 \cdot \text{Ränge B: } 3, 4, 1.5, 5, 1.5 \\ s^2_A = 55/5 - 9 = 2 \cdot s^2_B = 54.5/5 - 9 = 1.9 \cdot \\ \text{Kov} = 53/5 - 9 = 1.6 \\ r_{Sp} = 1.6/\sqrt{2 \cdot 1.9} = 0.821 \end{aligned}$$

⚠ Nicht nur die Ränge angeben – der Koeffizient ist auch gefragt.

Kausalität beurteilen · Drittvariable

~70 %

Aufgabe. Die Geschäftsführung folgert: „Mehr Werbung verursacht mehr Umsatz.“ Beurteilen Sie die Aussage und nennen Sie eine mögliche Drittvariable.

(2 P)

SO LÖST DU ES

1. Satz 1: Nein, nur Zusammenhang, keine Kausalität.
2. Satz 2: konkrete Drittvariable, die **beide** Merkmale beeinflusst (oder umgekehrte Richtung).
3. Satz 3: Für Kausalität braucht man ein randomisiertes Experiment.

Lösungskästchen

Nein. Die Daten zeigen nur einen statistischen Zusammenhang, keine Kausalität. Er könnte durch eine Drittvariable wie die Lage der Filiale entstehen, die sowohl das Werbebudget als auch den Umsatz beeinflusst. Für einen Kausalnachweis bräuchte man ein randomisiertes Experiment.

Scheinkorrelation und ökologischer Fehlschluss

~15 %

Aufgabe. Margarineverbrauch und Scheidungsrate korrelieren mit $r = 0.99$. Die Regierung verbietet Margarine. Beurteilen Sie. Was ist ein ökologischer Fehlschluss?

(3 P)

SO LÖST DU ES

1. Scheinkorrelation: hohe Korrelation ohne direkten Zusammenhang – Drittvariable oder Zufall.
2. Ökologischer Fehlschluss: von Gruppendaten auf Einzelpersonen schließen.

Lösungskästchen

Das Verbot ist nicht sinnvoll: Es handelt sich um eine Scheinkorrelation. Mögliche Drittvariable: die wirtschaftliche Lage; auch Zufall ist möglich. Ökologischer Fehlschluss: Aus aggregierten Gruppendaten (z. B. Stadtbezirken) wird unzulässig auf Individuen geschlossen.

Richtig oder falsch? (Klassiker)

~45 %

Aufgabe. Welche Aussagen sind korrekt? (a) Wenn $p \neq 0$, sind X und Y nie unabhängig. (b) Wenn $Y = -X^2$, kann $p \approx 0$ sein. (c) Wenn $X = Y$, gilt $p = 1$. (d) Wenn $p \neq 0$, besteht ein kausaler Zusammenhang. (e) Wenn $\text{Cov} \geq 0.8$, liegt ein starker Zusammenhang vor.

(5 P)

SO LÖST DU ES

1. Unabhängig $\Rightarrow p = 0$, aber $p = 0 \nRightarrow$ unabhängig.
2. r misst nur lineare Zusammenhänge.
3. Kovarianz hängt von den Einheiten ab.

Lösungskästchen

(a) richtig · (b) richtig · (c) richtig · (d) falsch · (e) falsch

G · Mathe-Werkzeug

Summenzeichen

~15 %

Aufgabe. Lösen Sie die Summe $\sum (x_i - \bar{x})$ so weit wie möglich auf.

(1 P)

SO LÖST DU ES

1. $\sum (x_i - \bar{x}) = \sum x_i - n \cdot \bar{x} = \sum x_i - \sum x_i$.
2. Konstante n-mal summiert: $\sum c = n \cdot c$.
3. Nur Zahlen ohne Index dürfen vor das Summenzeichen.

Lösungskästchen

$\sum (x_i - \bar{x}) = 0$

H · R (Teil B)

Daten einlesen (auch als Lückentext)

~95 %

Aufgabe. Setzen Sie mittels `setwd(path.expand("~/"))` Ihr Working Directory. Speichern Sie die Daten aus `WitcherData2.csv` als Data-Frame-Objekt `d` und geben Sie die ersten sechs Zeilen wieder.

(4 P)

SO LÖST DU ES

1. Datei zuerst ansehen: Trennzeichen zwischen den Spalten = sep; Dezimalzeichen = dec.
2. Erste Zeile mit Namen $\rightarrow$ header = TRUE.
3. Mit `str(d)` prüfen: nur 1 Variable $\rightarrow$ sep falsch.

Lösungskästchen

```
setwd(path.expand("~/"))
d <- read.csv("WitcherData2.csv", sep =
";", dec = ".", header = TRUE)
head(d)
+ R-Output einfügen
```

⚠ Deutsches CSV (12,5): `dec = ", "`.

Objekttypen bestimmen

~80 %

Aufgabe. Ermitteln Sie unter Einbezug eines passenden R-Befehls die Objekttypen der Variablen `Tal` und `Muenzen`.

(4 P)

SO LÖST DU ES

1. `str(d)` oder `typeof(d$Tal)` / `class(d$Tal)`.
2. chr = character · int = integer (numerisch, ganze Zahlen) · num = numeric · Factor = factor.

Lösungskästchen

`str(d)` + Output
Die Variable `Tal` ist ein character-Objekt, die Variable `Muenzen` ist numerisch vom Typ integer (nur ganze Zahlen).

Mittelwert und Standardabweichung

~90 %

Aufgabe. Berechnen und nennen Sie das arithmetische Mittel und den unverzerrten Schätzer der Standardabweichung der Variable Muenzen. Runden Sie auf drei Nachkommastellen.

(4 P)

SO LÖST DU ES

1. Immer mit `round(..., 3)` runden.
2. `sd` ist schon unverzerrt.

Lösungskästchen

```
round(mean(d$Muenzen), 3)
```

```
round(sd(d$Muenzen), 3) + Output
```

Das arithmetische Mittel der Variable Muenzen beträgt 22.454. Der unverzerrte Schätzer der Standardabweichung beträgt 4.610.

⚠ Fehlende Werte: `mean(d$X, na.rm = TRUE)`.

Median, IQR, Quantile, Varianz

~60 %

Aufgabe. Bestimmen Sie Median und Interquartilsabstand der Variable Kampfzeit (zwei Nachkommastellen).

(3 P)

SO LÖST DU ES

1. `median()`, `IQR()`, `quantile(x, 0.9)`, `summary()`.
2. Empirische Varianz: $\text{var}(x) \cdot (n-1)/n$.

Lösungskästchen

```
round(median(d$Kampfzeit), 2)
```

```
round(IQR(d$Kampfzeit), 2) + Output
```

Der Median der Kampfzeit beträgt 26.5 Minuten, der Interquartilsabstand 45.88 Minuten.

Normiertes Histogramm als PDF

~80 %

Aufgabe. Erstellen Sie ein normiertes Histogramm der Variable Muenzen mit den Intervallen [5, 15), [15, 20), [20, 25), [25, 35). Titel „Sitz ..., Matr.Nr. ..., Aufgabenteil e)“, x-Achse „Muenzen“, y-Achse „Dichte“. Speichern Sie die Grafik als Histogramm.pdf.

(8 P)

SO LÖST DU ES

1. `pdf("Name.pdf")` **vor** der Grafik, `dev.off()` **danach**.
2. `freq = FALSE` → normiert.
3. `[a, b)` → `right = FALSE`. `(a, b]` → `right = TRUE`.
4. breaks müssen Minimum und Maximum abdecken.
5. Datei im Ordner prüfen und hochladen.

Lösungskästchen

```
pdf("Histogramm.pdf")
```

```
hist(d$Muenzen, breaks = c(5, 15, 20, 25, 35),
```

```
freq = FALSE, right = FALSE,
```

```
main = "Sitz 12, Matr.Nr. 123,
```

```
Aufgabenteil e)",
```

```
xlab = "Muenzen", ylab = "Dichte")
```

```
dev.off()
```

⚠ Fehler „some 'x' not counted“ → breaks sind zu klein.

Streudiagramm / Boxplot / Säulendiagramm (auch Lückentext)

~35 %

Aufgabe. Vervollständigen Sie: `pdf("Streudiagramm.pdf") / ___(____, ____, pch = 16, ___ = "Streudiagramm", ___ = "Kampfzeit (min.)", ylab = ___) / ____off()`

(4 P)

SO LÖST DU ES

1. Streudiagramm: `plot(x, y)`. Erste Variable = x-Achse.
2. Boxplot: `boxplot(Zahl ~ Gruppe, data = d)`. Säulen: `barplot(table(d$X))`.
3. `main` = Titel, `xlab/ylab` = Achsen.

Lösungskästchen

```
pdf("Streudiagramm.pdf")
```

```
plot(d$Kampfzeit, d$Muenzen, pch = 16,
```

```
main = "Streudiagramm", xlab =
```

```
"Kampfzeit (min.)", ylab = "Muenzen")
```

```
dev.off()
```

Klassen bilden mit cut (Lückentext)

~35 %

Aufgabe. Die Variable Kampfzeit.3 hat drei Ausprägungen: {weniger als 5 Minuten, 5 Minuten bis weniger als eine Stunde, eine Stunde oder mehr}. Speichern Sie sie als Factor in d. **(4 P)**

SO LÖST DU ES

- breaks: Grenzen mit Inf am Ende (1 Stunde = 60 Minuten).
- „weniger als“ → right = FALSE. „bis zu / maximal“ → right = TRUE.

Lösungskästchen

```
d$Kampfzeit.3 <- cut(d$Kampfzeit, breaks
= c(0, 5, 60, Inf), right = FALSE)
d$Muenzen.4 <- cut(d$Muenzen, breaks =
c(0, 10, 20, 30, Inf), right = TRUE)
```

Kontingenztafel, Teilgruppe, relative Häufigkeiten

~40 %

Aufgabe. Erstellen Sie die Kontingenztafel von Muenzen.4 und Kampfzeit.3. Ermitteln Sie für Kampfzeiten von mindestens 5 und unter 60 Minuten die relative Häufigkeit jeder Ausprägung von Muenzen.4 (zwei Dezimalstellen). **(4 P)**

SO LÖST DU ES

- table(x, y) = Kontingenztafel.
- subset(d, Bedingung): & = und, | = oder.
- prop.table(table(...)) = relative Häufigkeiten. prop.table(..., 1) = zeilenweise.

Lösungskästchen

```
Kontingenz.Tafel <- table(d$Muenzen.4,
d$Kampfzeit.3)
s <- subset(d, Kampfzeit >= 5 & Kampfzeit
< 60)
round(prop.table(table(s$Muenzen.4)), 2) +
Output
```

Gruppen vergleichen, zählen, Anteile

~60 %

Aufgabe. Berechnen Sie die durchschnittliche Anzahl Münzen für jedes Tal. In welchem Tal verdient Jaskier am meisten? Wie viele Tavernen zahlten mehr als 20 Münzen? **(4 P)**

SO LÖST DU ES

- tapply(Zahl, Gruppe, mean).
- sum(Bedingung) = Anzahl. mean(Bedingung) = Anteil.

Lösungskästchen

```
round(tapply(d$Muenzen, d$Tal, mean), 3)
sum(d$Muenzen > 20) + Output
Im Bergtal verdient Jaskier im Durchschnitt am
meisten (26 Münzen). 7 Tavernen zahlten mehr
als 20 Münzen.
```

Korrelation in R

~60 %

Aufgabe. Wie stark ist der lineare Zusammenhang zwischen Kampfzeit und Muenzen? Berechnen und interpretieren Sie eine geeignete Maßzahl. **(4 P)**

SO LÖST DU ES

- cor(x, y) = Pearson (Standard).
- cor(x, y, method = "spearman") = Spearman.
- Interpretation wie in Teil A (Stärke + Richtung + linear + Merkmale).

Lösungskästchen

```
round(cor(d$Kampfzeit, d$Muenzen), 3) +
Output
Der Korrelationskoeffizient nach Pearson beträgt
0.928; es besteht ein starker positiver linearer
Zusammenhang zwischen Kampfzeit und
Münzen.
```

R-Output lesen (auch in Teil A)

~30 %

Aufgabe. `> length(x)` 12 · `> var(x)` 53.174 · `> summary(x)` : Min 10, 1st Qu. 17.25, Median 23, Mean 22.08, 3rd Qu. 27.5, Max 33. Bestimmen Sie die empirische Varianz, den IQR und ob es Ausreißer gibt. **(3 P)**

SO LÖST DU ES

1. var in R = unverzerrt $\rightarrow \cdot (n-1)/n$.
2. IQR = 3rd Qu. – 1st Qu.
3. Grenzen = Quartile $\mp 1.5 \cdot \text{IQR}$, mit Min und Max vergleichen.

Lösungskästchen

$$s^2 = 53.174 \cdot 11/12 = 48.743 \cdot \text{IQR} = 27.5 - 17.25 = 10.25$$

Grenzen 1.875 und 42.875 $\rightarrow$ keine Ausreißer (Min 10, Max 33).

Typische Fehler in R

~25 %

Aufgabe. Warum liefert `mean(d$Dauer)` NA bzw. einen Fehler? **(1 P)**

SO LÖST DU ES

1. NA in den Daten $\rightarrow$ `na.rm = TRUE`.
2. „object not found“ $\rightarrow$ Name falsch geschrieben oder Objekt nicht erstellt.
3. Zahlen als chr eingelesen $\rightarrow$ dec falsch gewählt.
4. Nur 1 Spalte $\rightarrow$ sep falsch.

Lösungskästchen

Die Variable enthält fehlende Werte (NA).

Lösung: `mean(d$Dauer, na.rm = TRUE)`.

Vor dem Abgeben

Checkliste für jede Aufgabe

1. Jeden Teil der Frage beantwortet? („;“ und „und“ zählen)
2. „Begründen Sie“ $\rightarrow$ mit Zahlen begründen.
3. Ergebnis auf 3 Nachkommastellen oder gekürzter Bruch.
4. Plausibel? Anteil 0–1, Varianz ≥ 0 , $|r| \leq 1$, $\chi^2 \geq 0$.
5. Nur eine Lösung im Kästchen, Falsches durchgestrichen.
6. Kein Kästchen leer lassen.