

## KOMPAKT 1

# Beschreibende Statistik für ein Merkmal

Von null bis Klausurniveau an einem Tag: Daten verstehen, Skalen bestimmen, Häufigkeiten, Verteilungsfunktion, Histogramm, Lage, Streuung, Quantile und Boxplot — und alles davon in R. Am Ende schreibst du eine **Klausur-Simulation** auf Probeklausur-Niveau.

🕒 ca. 7.5 Stunden

📄 5 Blöcke · 20 Schritte

🔗 Simulation · 46 Punkte · 60 min

▶ R für Teil B · TR erklär mal!

## Das kannst du heute Abend

- ☐ Du bestimmst für jedes Merkmal **diskret/stetig** und das **Skalenniveau** — auch bei Fallen wie 0/1-Daten.
- ☐ Du entscheidest, welche **Maßzahl erlaubt** ist, und begründest es in einem Satz.
- ☐ Du zeichnest die **empirische Verteilungsfunktion** fehlerfrei und liest daraus Anteile ab.
- ☐ Du **klassierst** Daten, zeichnest ein **Histogramm** und rechnest den Mittelwert klassierter Daten.
- ☐ Du berechnest Mittelwert, Median, Modus, **Quantile**, **Varianz** (auch mit Verschiebungssatz) und zeichnest einen **Boxplot**.
- ☐ Du löst die passenden R-Aufgaben aus Teil B: einlesen, Kennzahlen, Histogramm als PDF.

Grundlage: Vorlesungen SDS1-V01 und V02 · R-Skripte 01 und 02 · Tutorien 1–3 · Testate 1–2 · Probeklausur Teil A (Aufgaben 1–2) und Teil B (Aufgaben a–e)

# Der 5-Tage-Plan

Jeder Tag ist ein vollständiges Paket: Lernen → R → Klausur-Simulation

| Tag       | Inhalt                                                                                                                                                                        | Klausurpunkte                            |
|-----------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------|
| 1 · heute | <b>Beschreibende Statistik (ein Merkmal)</b><br>Skalen · Häufigkeiten · Verteilungsfunktion · Histogramm · Lage · Streuung · Quantile<br>· Boxplot · R-Grundlagen             | A1 + A2 = <b>24</b><br>B a–e ≈ <b>22</b> |
| 2         | <b>Zusammenhänge und Wahrscheinlichkeit</b><br>Kontingenztafel · Kovarianz · Korrelation · Kausalität · Mengen · Laplace · bedingte<br>Wahrscheinlichkeit · Bayes             | A3 + A4 + A5 = <b>28</b>                 |
| 3         | <b>Zufallsvariablen und Verteilungen</b><br>Wahrscheinlichkeits-, Dichte-, Verteilungsfunktion · E und Var · Binomial · Poisson ·<br>Exponential · Normal · ZGWS · R: d/p/q/r | Basis für A3c, A6–<br>A8<br>und B f–g    |
| 4         | <b>Schätzen</b><br>Maximum-Likelihood · Erwartungstreue · MSE · Konsistenz · Kerndichte ·<br>Konfidenzintervalle                                                              | A6 + A7 = <b>15</b><br>B f–g ≈ <b>15</b> |
| 5         | <b>Testen und Teil B komplett</b><br>Hypothesen · Fehler 1./2. Art · p-Wert · Gauß- und t-Test · <code>t.test()</code> · Funktionen,<br>Schleifen, <code>paste()</code>       | A8 = <b>8</b><br>B h ≈ <b>8</b>          |

## ◆ VORSCHLAG BIS ZUM 01.10.

Fünf Lerntage, danach drei Tage nur üben — nichts Neues mehr:

- **Tag 1–5:** ein PDF pro Tag, jeweils mit Klausur-Simulation am Abend.
- **Tag 6:** Fehlerheft durchgehen, alle Simulationen noch einmal **ohne** Lösung.
- **Tag 7:** die echte Probeklausur (Teil A 100 min, Teil B 60 min) unter Zeitdruck — erst jetzt!
- **Tag 8:** Formelblatt (ein A4-Blatt je Teil, handschriftlich) fertig schreiben. Das Formelblatt am Ende jedes PDFs ist deine Vorlage.

## Klausur-Radar · Warum heute der wichtigste Tag ist

Heute lernst du den Stoff für fast 40 % aller Klausurpunkte (Teil A und Teil B zusammen).

|                        |                                                                                                                            |             |
|------------------------|----------------------------------------------------------------------------------------------------------------------------|-------------|
| <b>Probeklausur A1</b> | Skalenniveau · Modus, Median, Mittel, Varianz aus R-Output<br>inklusive „nicht sinnvoll — begründen“ · Block A und C       | <b>10 P</b> |
| <b>Probeklausur A2</b> | diskret/stetig · Skala · Verteilungsfunktion zeichnen · klassierte Daten<br>die Zeichnung allein bringt 6 Punkte · Block B | <b>14 P</b> |
| <b>Teil B a–e</b>      | Daten einlesen · Objekttypen · Mittel und $s_*$ · Histogramm als PDF<br>Block D · 22 von 45 Punkten in Teil B              | <b>22 P</b> |

### 1 • Kern lesen

Jeder Schritt beginnt mit einem Satz „Kern“. Wenn du nur den verstehst, hast du das Wichtigste.

### 2 • Beispiel mitrechnen

Deck die Lösung ab und rechne selbst. Erst dann vergleichen.

### 3 • Klausuraufgabe lösen

Nach jedem Block kommt eine Aufgabe im Probeklausur-Stil mit Punkteschema.

### 4 • Simulation

Am Ende: 60 Minuten, Taschenrechner, kein Blick ins Skript. Dann ehrlich korrigieren.

## 1

**Die Grundbegriffe**

Wer wird untersucht, und was wird gemessen?

V01 · FOLIE 5–10

**KERN** An **statistischen Einheiten** misst man **Merkmale**. Jede Messung ist eine **Ausprägung**. Die untersuchten Einheiten sind eine **Stichprobe** aus der **Grundgesamtheit**.

| Begriff                            | Bedeutung                                           | Beispiel: Wahlumfrage       |
|------------------------------------|-----------------------------------------------------|-----------------------------|
| <b>Statistische Einheit</b>        | das Objekt, an dem gemessen wird                    | eine wahlberechtigte Person |
| <b>Grundgesamtheit</b>             | alle Einheiten, über die man etwas wissen will      | alle Wahlberechtigten       |
| <b>Stichprobe</b>                  | die Einheiten, die man wirklich untersucht          | die 1000 befragten Personen |
| <b>Merkmal <math>X</math></b>      | die Eigenschaft, die gemessen wird (Großbuchstabe)  | Parteipräferenz, Alter      |
| <b>Ausprägung <math>x_i</math></b> | der gemessene Wert bei Einheit $i$ (Kleinbuchstabe) | „SPD“, 34 Jahre             |

• **STICHPROBENVERFAHREN (V01)**

- **Einfache Zufallsstichprobe:** jedes Element hat dieselbe Chance, gezogen zu werden. Nur zufällige, keine systematischen Unterschiede zur Grundgesamtheit.
- **Geschichtete Stichprobe:** Grundgesamtheit in Gruppen (Schichten) teilen, aus **jeder** Schicht zufällig ziehen. Voraussetzung: Anteile der Schichten bekannt.
- **Klumpenstichprobe:** ganze Gruppen (Klumpen, z. B. Schulklassen) zufällig auswählen und dort alle befragen. Günstig; die Klumpen sollen untereinander ähnlich sein.
- **Quotenverfahren:** bewusste Auswahl, bis vorher festgelegte Quoten erfüllt sind — keine Zufallsauswahl.

## TR · TABAKALI MI KÜME MI? TEK FARK

geschichtet

**Her** gruptan birkaç kişi seçilir (her tabaka temsil edilir).

Klumpen

**Birkaç** grup seçilir, seçilen grubun **tamamı** sorulur.

**KERN** Kann man die möglichen Werte **abzählen**? Dann diskret. Ist **jeder** Wert in einem Intervall möglich? Dann stetig.

#### • DISKRET

endlich oder abzählbar unendlich viele Ausprägungen

- Parteipräferenz, Studienfach
- Schulnote, Zufriedenheit (1–5)
- **Anzahlen:** Kinder, Likes, Fehler, Tore

#### • STETIG

alle reellen Zahlen in einem Intervall möglich

- Körpergröße, Gewicht, Zeit, Dauer
- Menge in Litern, Temperatur
- Einkommen, Gewinn, Preis (wird als stetig behandelt)

#### ▲ ZWEI KLAUSURFALLEN

- **Gerundete Messung bleibt stetig.** Wenn Bier in 8.5 l, 12.0 l, 15.7 l notiert wird, ist die Menge trotzdem **stetig** — man misst nur ungenau. (So in der Probeklausur-Lösung: „stetig + metrisch skaliert“.)
- **Klassiert bleibt das Merkmal stetig.** Teilt man Alter in Klassen ein, ist das Merkmal *an sich* stetig; nur die **Darstellung** ist gruppiert.

**KERN** Nominal: nur Namen. Ordinal: Namen **mit Reihenfolge**. Metrisch (kardinal): echte Zahlen, **Abstände** sind sinnvoll.

| Skala                         | Was ist sinnvoll?                                        | Beispiele                                                  | Test-Frage                                                                                   |
|-------------------------------|----------------------------------------------------------|------------------------------------------------------------|----------------------------------------------------------------------------------------------|
| <b>nominal</b>                | nur „gleich / verschieden“ zählen                        | Geschlecht, Partei, Herkunft (BY/NRW), Postleitzahl, Farbe | Kann ich die Werte sinnvoll <b>sortieren</b> ? <b>Nein</b> → nominal                         |
| <b>ordinal</b>                | zusätzlich <b>ordnen</b>                                 | Schulnote, Zufriedenheit, Platzierung, Bildungsabschluss   | Ist der <b>Abstand</b> zwischen 1 und 2 derselbe wie zwischen 4 und 5? <b>Nein</b> → ordinal |
| <b>metrisch</b><br>(kardinal) | zusätzlich <b>Differenzen</b><br>(oft auch Verhältnisse) | Größe, Zeit, Einkommen, Liter, Anzahl                      | Ist „doppelt so viel“ oder „5 mehr“ sinnvoll? <b>Ja</b> → metrisch                           |

Metrisch unterteilt man manchmal noch in **Intervallskala** (nur Differenzen sinnvoll, z. B. Temperatur in °C: 20 °C ist nicht „doppelt so warm“ wie 10 °C) und **Verhältnisskala** (natürlicher Nullpunkt, auch Quotienten sinnvoll, z. B. Liter, Euro, Sekunden).

#### ◆ WAS IST BEI WELCHER SKALA ERLAUBT? — DIE WICHTIGSTE TABELLE DES TAGES

| Maßzahl                                               | nominal | ordinal | metrisch |
|-------------------------------------------------------|---------|---------|----------|
| Häufigkeiten, Modus                                   | ✓       | ✓       | ✓        |
| Median, Quantile, Verteilungsfunktion                 | ✗       | ✓       | ✓        |
| Mittelwert, Varianz, Standardabweichung, IQR, Boxplot | ✗       | ✗*      | ✓        |

\* Die Vorlesung sagt: Der Mittelwert „wird manchmal auch für ordinale Merkmale verwendet“, und er ist „auch sinnvoll für binäre, als 0/1 kodierte Merkmale“. Deshalb akzeptiert die Musterlösung bei 0/1 - Daten **beides**: den Wert **oder** „nicht sinnvoll“ mit Begründung. Entscheidend ist die **Begründung**.

#### ▲ DER SONDERFALL 0/1 (BINÄR) — GENAU SO IN PROBEKLAUSUR A1

„1 = Vorhersage richtig, 0 = falsch“. Die Musterlösung schreibt: „**Ordinalskaliert/Binär**“. Die Zahlen 0 und 1 sind nur Codes. Aber: Der Mittelwert von 0/1 - Daten ist der **Anteil der Einsen** — das ist sehr wohl sinnvoll. Für 0/1 - Daten gilt außerdem die Abkürzung

$$\bar{x} = \text{Anteil der Einsen} \quad S^2 = \bar{x} (1 - \bar{x})$$

#### 👉 SO SCHREIBST DU „NICHT SINNVOLL“ IN DER KLAUSUR

„Der Mittelwert ist nicht sinnvoll, da das Merkmal nur ordinalskaliert ist: Die Abstände zwischen den Ausprägungen sind nicht interpretierbar.“

„Der Median ist nicht sinnvoll, da das Merkmal nominalskaliert ist und sich die Ausprägungen nicht ordnen lassen.“

✗ „Nicht sinnvoll, weil man das nicht berechnen kann.“ — Kreis, keine Skala genannt.

TR · ÖLÇEK BULMA: İKİ SORU YETER

1. Sıralanabilir mi?

Hayır → **nominal** (parti, cinsiyet, posta kodu). Evet → 2. soruya geç.

2. Farklar anlamlı mı?

Hayır → **ordinal** (not, memnuniyet). Evet → **metrisch** (süre, litre, **sayı/adet**).

Tuzak

Sayı ile yazılmış olması metrik yapmaz! Posta kodu nominal, okul notu ordinal. Ama "ders sayısı" gibi **adet** metrik.

SELBSTCHECK · SCHRITT 2-3

- ☐ Anzahl der besuchten Vorlesungen (diskret, metrisch — Mittelwert erlaubt!)
- ☐ Temperatur in °C (stetig, metrisch: Intervallskala)
- ☐ Kleidergröße S/M/L/XL (diskret, ordinal)
- ☐ Wartezeit in Sekunden (stetig, metrisch: Verhältnisskala)

BLOCK B · HÄUFIGKEITEN, VERTEILUNGSFUNKTION, HISTOGRAMM · 90 MIN

4

## Absolute und relative Häufigkeiten

Zählen — der Anfang von allem

V02 · FOLIE 5-8

**KERN**  $h_j$  = wie oft kommt Ausprägung  $a_j$  vor.  $f_j = h_j/n$  = welcher Anteil. Alle  $f_j$  zusammen ergeben 1.

✓ BEISPIEL · KAFFEETASSEN PRO TAG BEI  $N = 10$  STUDIERENDEN

Urliste: 2, 0, 3, 2, 1, 2, 4, 0, 2, 3 → sortiert: 0, 0, 1, 2, 2, 2, 2, 3, 3, 4

| $a_j$    | $h_j$     | $f_j = h_j/n$ | kumuliert $F$ |
|----------|-----------|---------------|---------------|
| 0        | 2         | 0.2           | 0.2           |
| 1        | 1         | 0.1           | 0.3           |
| 2        | 4         | 0.4           | 0.7           |
| 3        | 2         | 0.2           | 0.9           |
| 4        | 1         | 0.1           | 1.0           |
| $\Sigma$ | <b>10</b> | <b>1.0</b>    |               |

Die letzte Spalte addiert von oben nach unten. Sie ist die Grundlage für Schritt 5.

**KERN**  $\hat{F}(x)$  = Anteil der Beobachtungen, die **kleiner oder gleich**  $x$  sind. Sie ist eine **Treppe**, die an jedem beobachteten Wert nach oben springt.

• DEFINITION

$$\hat{F}(x) = \frac{\text{Anzahl der } x_i \leq x}{n} \quad (\text{ab ordinaler Skala})$$

- links vom kleinsten Wert:  $\hat{F}(x) = 0$ ; ab dem größten Wert:  $\hat{F}(x) = 1$
- an jedem beobachteten Wert springt sie um dessen relative Häufigkeit  $f_j$
- dazwischen ist sie **waagerecht** (konstant)


✓ BEISPIEL · PENDELZEIT IN MINUTEN,  $N = 10$

Urliste: 12.5, 20, 12.5, 30, 20, 45, 20, 12.5, 30, 20

| Wert | $h_j$ | $f_j$ | $\hat{F}$ ab diesem Wert |
|------|-------|-------|--------------------------|
| 12.5 | 3     | 0.3   | 0.3                      |
| 20   | 4     | 0.4   | 0.7                      |
| 30   | 2     | 0.2   | 0.9                      |
| 45   | 1     | 0.1   | 1.0                      |

Die Funktion als Formel — so will es die Musterlösung:

$$\hat{F}(x) = \begin{cases} 0 & \text{für } x < 12.5 \\ 0.3 & \text{für } 12.5 \leq x < 20 \\ 0.7 & \text{für } 20 \leq x < 30 \\ 0.9 & \text{für } 30 \leq x < 45 \\ 1 & \text{für } x \geq 45 \end{cases}$$



**Treppenfunktion.** Voller Punkt = der Wert gehört dazu ( $\leq$ ). Offener Kreis = gehört nicht dazu. Die gestrichelten Senkrechten sind nur Orientierung.

#### ▲ PUNKTESCHEMA: SO VERLIERT MAN DIE 6 PUNKTE

- **Achsen nicht beschriftet** (x-Achse: Merkmal mit Einheit, y-Achse:  $\hat{F}(x)$ , Werte 0 bis 1).
- **Schräge Linien** statt waagerechter Stufen — das wäre eine andere Funktion.
- **Gleiche Werte einzeln** gezählt: 12.5 kommt dreimal vor → **eine** Stufe der Höhe 0.3, nicht drei kleine.
- **Nicht bis 0 und 1** gezeichnet: links bei 0 anfangen, rechts bei 1 weiterlaufen lassen.
- **Offen/geschlossen** vertauscht: der Sprungpunkt gehört zur **oberen** Stufe.

#### ✓ ABLESEN — DIE DREI FRAGETYPEN

| Gesucht                                         | Formel                     | Pendel-Beispiel                       |
|-------------------------------------------------|----------------------------|---------------------------------------|
| Anteil <b>höchstens</b> $x$                     | $\hat{F}(x)$               | höchstens 20 min: $\hat{F}(20) = 0.7$ |
| Anteil <b>mehr als</b> $x$                      | $1 - \hat{F}(x)$           | mehr als 20 min: $1 - 0.7 = 0.3$      |
| Anteil <b>größer</b> $a$ , <b>höchstens</b> $b$ | $\hat{F}(b) - \hat{F}(a)$  | über 12.5 bis 30: $0.9 - 0.3 = 0.6$   |
| Anteil <b>weniger als</b> $x$ (strikt)          | Stufe <b>links</b> von $x$ | weniger als 20 min: 0.3               |

#### TR · DAĞILIM FONKSİYONU ÇİZME REÇETESİ

1. adım

Veriyi sırala, **farklı** değerleri ve kaç kez geçtiklerini yaz.

2. adım

Kümülatif oranları hesapla (0.3, 0.7, 0.9, 1).

3. adım

Eksenleri çiz ve **isimlendir**. y eksenini 0'dan 1'e.

4. adım

Her değerde yukarı zıpla: **dolu nokta üstte**, boş daire altta. Aralarda **yatay** çizgi.

5. adım

Formülü de yaz (Fallunterscheidung) — puanın bir kısmı buradan gelir.

**KERN** Beim Histogramm ist die **Fläche** gleich der relativen Häufigkeit. Die Höhe ist deshalb die **Dichte** =  $f_j / \text{Klassenbreite}$ .


• HISTOGRAMM (V02, FOLIE 9–13)

$$\text{Höhe der Klasse } j = \frac{f_j}{\text{Breite}_j} = \frac{h_j/n}{c_j - c_{j-1}} \quad \text{Gesamtfläche} = 1$$

Beim **Säulendiagramm** ist die **Höhe** proportional zur Häufigkeit. Bei ungleich breiten Klassen täuscht das. Deshalb gilt in dieser Vorlesung: **Histogramm = Goldstandard** für stetige Merkmale, immer mit relativen Häufigkeiten.

✓ BEISPIEL · PENDELZEITEN IN DREI KLASSEN (UNGLEICH BREIT!)

| Klasse   | Werte darin | $h_j$ | $f_j$ | Breite | Dichte | Mitte $m_j$ |
|----------|-------------|-------|-------|--------|--------|-------------|
| [0, 15)  | 12.5 × 3    | 3     | 0.3   | 15     | 0.0200 | 7.5         |
| [15, 30) | 20 × 4      | 4     | 0.4   | 15     | 0.0267 | 22.5        |
| [30, 60] | 30 × 2, 45  | 3     | 0.3   | 30     | 0.0100 | 45          |
| $\Sigma$ |             | 10    | 1.0   |        |        |             |



Die dritte Klasse hat genauso viele Werte wie die erste, ist aber doppelt so breit — deshalb nur halb so hoch. Probe der Flächen:  $15 \cdot 0.02 + 15 \cdot 0.0267 + 30 \cdot 0.01 = 0.3 + 0.4 + 0.3 = 1$  ✓

#### ▲ KLASSENGRENZEN GENAU LESEN

$[0, 15)$  heißt: 0 gehört dazu, 15 **nicht**. Der Wert 30 liegt deshalb in  $[30, 60]$ , nicht in  $[15, 30)$ . In der Probeklausur:  $K_1 = [0, 10)$ ,  $K_2 = [10, 20]$  — der Wert 10 gehört zu  $K_2$ .

#### • MITTELWERT KLASSIERTER DATEN

Man kennt nur die Klassen, nicht die genauen Werte. Also tut man so, als lägen alle Werte einer Klasse in der **Klassenmitte**  $m_j$ :

$$\bar{x}_{klass} = \frac{1}{n} \sum_j h_j m_j = \sum_j f_j m_j \quad m_j = \frac{\text{untere} + \text{obere Grenze}}{2}$$

#### ✓ WEITER MIT DEN PENDELZEITEN

$$\bar{x}_{klass} = \frac{1}{10} (3 \cdot 7.5 + 4 \cdot 22.5 + 3 \cdot 45) = \frac{22.5 + 90 + 135}{10} = 24.75$$

Der echte Mittelwert ist  $\bar{x} = \frac{222.5}{10} = 22.25$ . Der Unterschied entsteht, weil die Werte **nicht** in der Klassenmitte liegen (z. B. 12.5 statt 7.5). Das ist normal — und eine beliebte Zusatzfrage.

#### TR · HISTOGRAM VE SINIFLANMIŞ VERİ

Yükseklik

= oran / sınıf genişliği (**Dichte**). Alan = oran.

Sınıf ortası

(alt sınır + üst sınır) / 2. Sınıftaki herkes buradaymış gibi say.

$[a, b)$

köşeli parantez = **dahil**, yuvarlak = **hariç**. Sınırdaki değeri hangi sınıfa koyduğuna dikkat!

■ KLAUSURAUFGABE ZU BLOCK A + B · 10 PUNKTE · 15 MINUTEN · IM STIL VON A2

Eine Bäckerei notiert an 10 Tagen die verkaufte Menge Sauerteigbrot  $X$  in kg und den Wochentyp  $Y$  (W = Werktag, S = Samstag).

|       |     |     |     |      |     |     |      |     |      |     |
|-------|-----|-----|-----|------|-----|-----|------|-----|------|-----|
| $x_i$ | 6.5 | 9.0 | 6.5 | 11.5 | 9.0 | 6.5 | 14.0 | 9.0 | 11.5 | 9.0 |
| $y_i$ | W   | W   | W   | S    | W   | W   | S    | W   | S    | W   |

(a) Diskret oder stetig? Welches Skalenniveau? Für  $X$  und  $Y$ . (4P) · (b) Geben Sie  $\hat{F}(x)$  als Fallunterscheidung an und bestimmen Sie den Anteil der Tage mit mehr als 9 kg. (4P) · (c) Klassieren Sie in  $K_1 = [5, 10)$  und  $K_2 = [10, 15]$  und berechnen Sie den Mittelwert der klassierten Daten. (2P)

Lösung mit Punkteschema

(a)  $X$ : **stetig, metrisch** (Verhältnisskala) — je 1P.  $Y$ : **diskret, nominal** — je 1P.

(b) Sortiert: 6.5 (3×), 9.0 (4×), 11.5 (2×), 14.0 (1×).

$$\hat{F}(x) = \begin{cases} 0 & x < 6.5 \\ 0.3 & 6.5 \leq x < 9 \\ 0.7 & 9 \leq x < 11.5 \\ 0.9 & 11.5 \leq x < 14 \\ 1 & x \geq 14 \end{cases}$$

3P für die Funktion (je Stufe mit richtiger Grenze). Mehr als 9 kg:  $1 - \hat{F}(9) = 1 - 0.7 = \mathbf{0.3}$  (1P).

(c)  $K_1$ : 7 Werte, Mitte 7.5 ·  $K_2$ : 3 Werte, Mitte 12.5  $\rightarrow \bar{x}_{klass} = \frac{1}{10}(7 \cdot 7.5 + 3 \cdot 12.5) = \frac{52.5 + 37.5}{10} = \mathbf{9}$  (2P).

## 7

**Modus, Median, Mittelwert**

Drei Antworten auf „Wo liegt die Mitte?“

A1 (B) · 4 P

**KERN** Modus = häufigster Wert. Median = mittlerer Wert der **sortierten** Liste. Mittelwert = Summe durch  $n$ .

## • DIE DREI LAGEMASSE

$$x_{mod} = \text{häufigste Ausprägung} \quad \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \sum_j a_j f_j$$

$$x_{med} = \begin{cases} x_{(\frac{n+1}{2})} & n \text{ ungerade} \\ \frac{x_{(n/2)} + x_{(n/2+1)}}{2} & n \text{ gerade} \end{cases}$$

$x_{(i)}$  ist der  $i$ -te Wert **nach dem Sortieren**. Bei geradem  $n$  ist jeder Wert zwischen den beiden mittleren ein Median; als eine Zahl nimmt man die Mitte (so rechnet auch R).

## ✓ BEISPIEL · KAFFEETASSEN (SORTIERT: 0, 0, 1, 2, 2, 2, 2, 3, 3, 4)

- Modus: 2 kommt viermal vor  $\rightarrow x_{mod} = 2$
- Median:  $n = 10$  gerade  $\rightarrow \frac{x_{(5)} + x_{(6)}}{2} = \frac{2 + 2}{2} = 2$
- Mittel:  $\bar{x} = \frac{0 \cdot 2 + 1 \cdot 1 + 2 \cdot 4 + 3 \cdot 2 + 4 \cdot 1}{10} = \frac{19}{10} = 1.9$

## ✓ BEISPIEL · 0/1-DATEN WIE IN PROBEKLAUSUR A1

20 Befragte, `sort(x)` zeigt 7 Nullen und 13 Einsen.

- Modus: **1** (13-mal)
- Median:  $n = 20 \rightarrow \frac{x_{(10)} + x_{(11)}}{2}$ . Positionen 10 und 11 sind beide Einsen (Nullen nur bis Position 7)  $\rightarrow$  **1**
- Mittel:  $\bar{x} = \frac{13}{20} = 0.65$  — 65 % Einsen

## ▲ DEIN BEKANNTER FEHLER: POSITION UM EINS VERRUTSCHT

Schreib die sortierten Werte **mit Positionsnummern** auf, bevor du den Median suchst. Bei  $n = 20$  brauchst du Platz 10 **und** 11, bei  $n = 15$  nur Platz 8.

• GESCHICHTETE DATEN (GESAMTMITTEL AUS GRUPPEN)

$$\bar{x} = \frac{1}{n} (n_1 \bar{x}_1 + n_2 \bar{x}_2 + \dots + n_r \bar{x}_r)$$

Beispiel: 40 Wohnungen mit  $\bar{x}_1 = 9.5$  €/qm und 60 mit  $\bar{x}_2 = 11.2 \rightarrow \bar{x} = \frac{380 + 672}{100} = 10.52$ . **Nicht** einfach  $\frac{9.5 + 11.2}{2}$ !

8


## Form der Verteilung und Robustheit

Was die Lage der drei Maße verrät

V02 · FOLIE 19-25

**KERN** Der Mittelwert wird von Ausreißern **gezogen**, der Median nicht. Deshalb liegt bei rechtsschiefen Daten  $\bar{x}$  rechts vom Median.

| Form                        | Reihenfolge                               | typisch                          |
|-----------------------------|-------------------------------------------|----------------------------------|
| symmetrisch                 | $\bar{x} \approx x_{med} \approx x_{mod}$ | Körpergröße                      |
| rechtsschief (= linkssteil) | $\bar{x} > x_{med} > x_{mod}$             | Einkommen, Mieten, Wartezeiten   |
| linksschief (= rechtssteil) | $\bar{x} < x_{med} < x_{mod}$             | Punkte in einer leichten Klausur |



**Rechtsschiefe Verteilung.** Der Gipfel (Modus) liegt links. Der Mittelwert wird vom langen Ausläufer nach rechts gezogen und ist deshalb am größten. Der Median liegt dazwischen.

👉 SO SCHREIBST DU ES IN DER KLAUSUR · VORTEIL DES MEDIANS (PROBEKLAUSUR-B-BEISPIEL)

„Der Median ist robuster gegenüber Extremwerten als das arithmetische Mittel.“

## • TRANSFORMATIONEN

Lineare Transformation  $y_i = a + b x_i \rightarrow \bar{y} = a + b \bar{x}$ . Für jede **monotone** Transformation  $g$  gilt  $y_{med} = g(x_{med})$ .

Beispiel: Umrechnung °C → °F mit  $y = 32 + 1.8x$ . Mittel  $20\text{ °C} \rightarrow 32 + 1.8 \cdot 20 = 68\text{ °F}$ .

9

## Varianz und Standardabweichung

Wie weit liegen die Daten vom Mittelwert weg?

A1 (B) · A5 (A) · B (D)

**KERN** Varianz = durchschnittliche **quadrierte** Abweichung vom Mittelwert. Rechne fast immer mit dem **Verschiebungssatz**.

## • FORMELN

$$S^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \underbrace{\sum_{i=1}^n x_i^2 - n \bar{x}^2}_{\text{Verschiebungssatz}} \quad S = \sqrt{S^2}$$

$$S_*^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{n}{n-1} S^2$$

$S_*^2$  heißt „unverzerrt“ oder „korrigiert“.

$S$  hat dieselbe Einheit wie die Daten,  $S^2$  die quadrierte Einheit.

## ✓ BEISPIEL · KAFFEETASSEN MIT VERSCHIEBUNGSSATZ

1  $\sum x_i^2 = 0^2 \cdot 2 + 1^2 \cdot 1 + 2^2 \cdot 4 + 3^2 \cdot 2 + 4^2 \cdot 1 = 0 + 1 + 16 + 18 + 16 = 51$

2  $\frac{1}{n} \sum x_i^2 = \frac{51}{10} = 5.1$  und  $\bar{x}^2 = 1.9^2 = 3.61$

3  $S^2 = 5.1 - 3.61 = 1.49 \cdot S = \sqrt{1.49} = 1.2207$

4  $S_*^2 = \frac{10}{9} \cdot 1.49 = 1.6556$  — **das** würde `var(x)` in R ausgeben

## ✓ BEISPIEL · 0/1-DATEN: DER SCHNELLWEG

7 Nullen, 13 Einsen:  $\bar{x} = 0.65 \rightarrow S^2 = 0.65 \cdot 0.35 = 0.2275$ . Probe mit Verschiebungssatz:  $\frac{13}{20} - 0.65^2 = 0.65 - 0.4225 = 0.2275$  ✓ (bei 0/1 ist  $x_i^2 = x_i$ ).

## • TRANSFORMATION UND VARIANZ

$y_i = a + b x_i \rightarrow S_y^2 = b^2 S_x^2$  und  $S_y = |b| S_x$ . Die Verschiebung  $a$  ändert die Streuung **nicht**.

### TR · S² MI S²\* MI? SINAV NASIL SORAR

„empirische Varianz“

$S^2$ , bölen **n**. Probeklausur A1 ve A5 bunu istiyor.

„unverzerrt“ /  $s_*$

$S_*^2$ , bölen **n-1**. B-Teil (d) "unverzerrter Schätzer für die Standardabweichung  $s_*$ " → R'da direkt `sd(x)`.

R: `var(x)`, `sd(x)`

**Her zaman n-1**.  $S^2$  lazımsa: `(n-1)/n * var(x)`.

## 10 Quantile nach der Vorlesungsregel

V02 · FOLIE 26-29

Die Regel, die R nicht standardmäßig benutzt

**KERN** Rechne  $n \cdot \alpha$ . Keine ganze Zahl → **aufunden** und diesen Platz nehmen. Ganze Zahl → **Mittel** aus diesem und dem nächsten Platz.

## • DIE REGEL

$$x_\alpha = \begin{cases} x_{([n\alpha]+1)} & n\alpha \text{ keine ganze Zahl} \\ \frac{x_{(n\alpha)} + x_{(n\alpha+1)}}{2} & n\alpha \text{ ganze Zahl} \end{cases}$$

$[n\alpha]$  = abgerundet. „Abrunden und +1“ ist dasselbe wie „aufunden“. Voraussetzung: mindestens ordinal.

### ✓ BEISPIEL · 26 NETTOMIETEN AUS DER VORLESUNG (SORTIERT)

(1) 77.31 · (2) 104.14 · (3) 116.48 · (4) 132.24 · (5) 158.91 · (6) 163.17 · (7) **170.04** · (8) 181.98 · (9) 183.09 · (10) 200.84 · (11) 210.55 · (12) 227.91 · (13) 243.44 · (14) 255.75 · (15) 261.98 · (16) 263.21 · (17) 269.84 · (18) 276.60 · (19) 281.21 · (20) **311.87** · (21) 343.30 · (22) 359.17 · (23) 361.60 · (24) 362.00 · (25) 400.05 · (26) 533.92

- $x_{0.25}$ :  $26 \cdot 0.25 = 6.5 \rightarrow$  aufunden  $\rightarrow$  Platz 7  $\rightarrow$  **170.04**
- $x_{0.5}$ :  $26 \cdot 0.5 = 13$  ganzzahlig  $\rightarrow \frac{243.44 + 255.75}{2} =$  **249.595**
- $x_{0.75}$ :  $26 \cdot 0.75 = 19.5 \rightarrow$  aufunden  $\rightarrow$  Platz 20  $\rightarrow$  **311.87**

### ▲ R RECHNET STANDARDMÄSSIG ANDERS

`quantile(x)` interpoliert (Typ 7) und liefert oft **andere** Zahlen. `quantile(x, type = 2)` liefert genau die Vorlesungsregel. In Teil A zählt die Vorlesungsregel; in Teil B schreibst du, welchen Befehl du benutzt hast.

## 11 IQR, Ausreißer und Boxplot

Fünf Zahlen, ein Bild

V02 · FOLIE 33–36

**KERN** Box von  $x_{0.25}$  bis  $x_{0.75}$ , Strich beim Median. Ausreißer liegen mehr als  $1.5 \cdot \text{IQR}$  außerhalb der Box.


### • REZEPT

- 1 Quartile bestimmen,  $\text{IQR} = x_{0.75} - x_{0.25}$
- 2 Zäune: unten  $x_{0.25} - 1.5 \text{IQR}$ , oben  $x_{0.75} + 1.5 \text{IQR}$
- 3 Werte außerhalb der Zäune = **Ausreißer**, einzeln als Punkt zeichnen
- 4 Whisker bis zum äußersten Wert **innerhalb** der Zäune — nicht bis zum Zaun selbst

### ✓ BEISPIEL · NETTOMIETEN

$\text{IQR} = 311.87 - 170.04 = 141.83$  · Zäune:  $170.04 - 212.745 = -42.705$  und  $311.87 + 212.745 = 524.615$

533.92 liegt über 524.615 → **Ausreißer**. Der obere Whisker endet beim größten Nicht-Ausreißer 400.05.



### TR · BOXPLOT'TA EN SIK HATA

Whisker (bıyık) **çite kadar değil**, çitin içinde kalan **en uç gerçek veriye** kadar çizilir. Çit sadece hesap için var, çizilmez.

■ KLAUSURAUFGABE ZU BLOCK C · 10 PUNKTE · 12 MINUTEN · IM STIL VON A1

Eine Umfrage erfasst bei 16 Studierenden die Anzahl der Geschwister. R liefert:

```
> sort(Geschwister)
[1] 0 0 0 1 1 1 1 1 1 2 2 2 3 3 4 6
> sum(Geschwister^2)
[1] 88
```

(a) Skalenniveau? (1P) · (b)  $x_{mod}$ ,  $x_{med}$ ,  $\bar{x}$ ,  $s^2$  — falls nicht sinnvoll, begründen. (5P) · (c)  $x_{0.25}$ ,  $x_{0.75}$  und alle Ausreißer nach der 1.5-IQR-Regel. (3P) · (d) Rechts- oder linksschief? Begründen Sie mit zwei Lagemaßen. (1P)

Lösung mit Punkteschema

(a) Anzahl → **metrisch** (diskret) (1P). Deshalb sind hier **alle** Maße sinnvoll.

(b)  $x_{mod} = 1$  (1P) ·  $x_{med} = \frac{x_{(8)} + x_{(9)}}{2} = \frac{1 + 1}{2} = 1$  (1P) ·  $\bar{x} = \frac{0 \cdot 3 + 1 \cdot 6 + 2 \cdot 3 + 3 \cdot 2 + 4 + 6}{16} = \frac{28}{16} = 1.75$  (1P)

$s^2 = \frac{88}{16} - 1.75^2 = 5.5 - 3.0625 = 2.4375 \rightarrow 2.438$  (2P: Formel 1P, Ergebnis 1P)

(c)  $16 \cdot 0.25 = 4$  ganzzahlig  $\rightarrow x_{0.25} = \frac{x_{(4)} + x_{(5)}}{2} = \frac{1 + 1}{2} = 1$ ;  $16 \cdot 0.75 = 12$  ganzzahlig  $\rightarrow x_{0.75} = \frac{x_{(12)} + x_{(13)}}{2} = \frac{2 + 3}{2} = 2.5$  (2P). IQR = 1.5, oberer Zaun  $2.5 + 2.25 = 4.75 \rightarrow$  Ausreißer: **6** (1P). Der Wert 4 ist **kein** Ausreißer.

(d)  $\bar{x} = 1.75 > x_{med} = 1 \rightarrow$  **rechtsschief** (1P).

BLOCK D · R FÜR TEIL B · 60 MIN

12

## Daten einlesen und anschauen

Probeklausur B (a)–(c) · 10 Punkte

BA-C · 10 P

► R · DIE ERSTEN DREI AUFGABEN JEDER B-KLAUSUR

```
setwd(path.expand("~/")) # (a) Arbeitsordner = Dokumente

d <- read.csv("WitcherData1.csv", # (b) Datei einlesen – so in der Musterlösung
  sep = ",", dec = ".", header = TRUE)
head(d) # erste 6 Zeilen zeigen

typeof(d$Ta1) # (c) "character" (Musterlösung)
typeof(d$Muenzen) # "integer" – nur ganze Zahlen
str(d) # Alternative: alle Spalten auf einmal
```

```
setwd(path.expand("~/"))
```

Çalışma klasörünü "Dokumente" yapar. Sınavda bu komut **verilir**, aynen yaz.

```
read.csv(..., sep = ",")
```

CSV dosyasını okur. `sep` = sütun ayırıcı. Resmi çözümde WitcherData1 için `" ; "`. Sınavda görevde ne yazıyorsa onu kullan; yazmıyorsa dosyayı aç ve bak (`; mi , mi?`). `dec` = ondalık işareti.

```
header = TRUE
```

İlk satır sütun **isimleri**dir.

```
d <- ...
```

Sonucu `d` adıyla **kaydeder**. Görev "Objekt d" diyorsa isim tam `d` olmalı.

```
head(d)
```

İlk 6 satır. "ersten 6 Zeilen wiedergeben" → bu.

```
typeof(d$Tal)
```

Tek sütunun tipi: "character", "integer", "double" (= numeric), "logical". Resmi çözüm bunu kullanıyor.

```
str(d)
```

Tüm sütunların tipi birden: `chr` = character, `num` = numeric, `int` = integer, `Factor`, `logi`.

```
d$Tal
```

Data frame'in "Tal" sütunu. `$` = "içindeki".

Cevap kutusuna **kodu ve R çıktısını** birlikte kopyala; ayrı kutuya tam cümleyle cevap yaz: „Bei der Variable Tal handelt es sich um ein character-Objekt, bei der Variable Muenzen um ein numerisches Objekt des Typs integer.“ (Wortlaut der Musterlösung)

## ► R · LAGE UND STREUUNG

```

x <- d$Muenzen

round(mean(x), 3)           # arithmetisches Mittel
round(sd(x), 3)             #  $s_*$  (unverzerrt,  $n-1$ ) ← so gefragt in B (d)
median(x)
var(x)                      #  $S^2_*$  ( $n-1$ )
n <- length(x)
(n - 1) / n * var(x)        #  $S^2$  der Vorlesung ( $n$ )

quantile(x, c(0.25, 0.75), type = 2) # Vorlesungsregel
summary(x)                  # min, Quartile (Typ 7), Median, Mittel, max

table(d$Ta1)                # absolute Häufigkeiten
prop.table(table(d$Ta1))    # relative Häufigkeiten
names(which.max(table(d$Ta1))) # Modus (es gibt kein mode(!))

mean(x, na.rm = TRUE)      # falls fehlende Werte (NA) vorkommen

```

## TR · KRITIK NOKTALAR

round(..., 3)

Sınav kuralı: sonuçlar **3 ondalık**, yuvarlamayı **R komutuyla** yap.

sd(x)

 $s_*$  =  $n-1$ 'li standart sapma. B-Teil tam bunu soruyor.

mode(x)

**TUZAK:** Modus değil, nesne tipini verir ("numeric"). Modus için

table + which.max .

type = 2

Ders kuralıyla kuantil. Yazmazsan R başka yöntem kullanır.

na.rm = TRUE

Eksik değer (NA) varsa onları atla. Yoksa sonuç NA çıkar.

## ► R · KLASSEN [5, 15), [15, 20), [20, 25), [25, 35) ALS PDF

```
pdf("Histogramm.pdf")                # 1. Datei öffnen
hist(d$Muenzen,
     breaks = c(5, 15, 20, 25, 35),  # Klassengrenzen
     right = FALSE,                  # [a, b): links geschlossen
     freq = FALSE,                   # y-Achse = Dichte
     main = "Sitz 00, Matr.Nr. 12345678, Aufgabenteil e)",
     xlab = "Muenzen",
     ylab = "Dichte")
dev.off()                            # 2. Datei schließen
```

## TR · 8 PUANIN PARÇALARI

breaks = c(...)

Sınıf **sınırları** — 4 sınıf için 5 sayı. Görevdeki aralıkları aynen yaz.

right = FALSE

Aralıklar **[a, b)** ise şart. R'in varsayılanı (a, b]!

freq = FALSE

y eksenini **yoğunluk (Dichte)** olur. Görev "Dichte" diyorsa şart.

main / xlab / ylab

Başlıkta Sitz + Matr.Nr. + Aufgabenteil, eksen adları görevdeki gibi.

pdf() ... dev.off()

Aç → çiz → kapat. `dev.off()` unutulursa dosya boş kalır.

**Dikkat:** Son sınıf [25, 35) ama 35 değeri varsa R hata verir ("some x not counted"). O zaman `include.lowest = TRUE` ekle — `right = FALSE` ile birlikte bu, **son** aralığı sağdan kapatır.

## ► R · VERTEILUNGSFUNKTION UND BOXPLOT

```
plot(ecdf(x), main = "Empirische Verteilungsfunktion",
     xlab = "Muenzen", ylab = "F(x)")
boxplot(x, range = 1.5, main = "Boxplot", ylab = "Muenzen")
b <- boxplot(x, plot = FALSE)
b$stats      # Whisker unten, Box unten, Median, Box oben, Whisker oben
b$out        # Ausreißer
```

## ♦ WARUM DIESER BLOCK?

Die Klausur prüft laut Abschlusssitzung den Stoff aus **Vorlesungen, Tutorien und Übungen** — nicht nur das, was in der Probeklausur vorkam. Dieser Block sammelt alles aus V01–V02, R-Skript 01–02, Tutorium 1–2, Testat 0–1, was in Block A–D noch fehlt.

## 15 Anteile aus einem Histogramm schätzen

Tutorium 2 · A1 und Testat 1 · A7

TESTAT 1

**KERN** Liegt ein Intervall nur **teilweise** in einer Klasse, nimmt man an, dass die Werte in der Klasse **gleichmäßig** verteilt sind: Anteil = Fläche des Histogramms über dem Intervall.

## • DIE ZWEI UMRECHNUNGEN

- **Anzahl in einer Klasse** = Dichte · Klassenbreite ·  $n$  (Rückweg vom normierten Histogramm)
- **Anteil in einem Teil einer Klasse** =  $\frac{\text{Länge des Teils}}{\text{Klassenbreite}} \cdot f_j$  (= Dichte · Länge des Teils)

## ✓ BEISPIEL · 50 KÖRPERGRÖSSEN IN VIER KLASSEN

| Klasse     | $h_j$ | $f_j$ | Breite | Dichte |
|------------|-------|-------|--------|--------|
| [150, 160) | 5     | 0.10  | 10     | 0.010  |
| [160, 170) | 12    | 0.24  | 10     | 0.024  |
| [170, 180) | 15    | 0.30  | 10     | 0.030  |
| [180, 200] | 18    | 0.36  | 20     | 0.018  |

**Anteil im Intervall (165, 185]:**

$$\underbrace{\frac{5}{10} \cdot 0.24}_{165 \text{ bis } 170} + \underbrace{0.30}_{\text{ganz}} + \underbrace{\frac{5}{20} \cdot 0.36}_{180 \text{ bis } 185} = 0.12 + 0.30 + 0.09 = 0.51$$

Also etwa 51 % — bei  $n = 50$  rund 25.5 Personen. Das ist eine **Schätzung** unter der Gleichverteilungsannahme.

### ▲ TESTAT-FALLE: MODALKLASSE ≠ HÖCHSTER BALKEN

Die **Modalklasse** ist die Klasse mit der größten **Häufigkeit** (Tutorium 2, A5). Oben ist das [180, 200] mit 18 Werten. Der **höchste Balken** ist aber [170, 180], weil die letzte Klasse doppelt so breit ist. Die Aussage „Die Modalklasse ist immer die Klasse mit dem höchsten Kästchen“ ist deshalb **im Allgemeinen falsch** — sie stimmt nur bei gleich breiten Klassen.

### TR · KISMI ARALIK HESABI

Aralık bir sınıfın **bir kısmını** kapsıyorsa: o sınıfın oranını, kapsanan **uzunluk / sınıf genişliği** ile çarp. Tam kapsanan sınıfları olduğu gibi ekle. Varsayım: sınıf içinde değerler eşit dağılmış (Gleichverteilung) — bunu cevaba yaz.

## 16 Summenhäufigkeiten und die Sprache der Anteile

Tutorium 2 · A2

TUTORIUM 2

**KERN**  $H_j = h_1 + \dots + h_j$  (absolut kumuliert),  $F_j = H_j/n$  (relativ kumuliert). Jede Formulierung erst in „≤“ übersetzen.

### ✓ BEISPIEL · SEMESTERZAHLEN VON 23 KLAUSURTEILNEHMERN

| Semester | 2    | 3    | 4     | 5     | 6     | 7  |
|----------|------|------|-------|-------|-------|----|
| $h_j$    | 1    | 7    | 5     | 5     | 1     | 4  |
| $H_j$    | 1    | 8    | 13    | 18    | 19    | 23 |
| $F_j$    | 1/23 | 8/23 | 13/23 | 18/23 | 19/23 | 1  |

$$\text{„größer als 3“} = 1 - F(3) = 1 - \frac{8}{23} = \frac{15}{23}$$

$$\text{„mindestens 3“} = 1 - F(2) = 1 - \frac{1}{23} = \frac{22}{23}$$

$$\text{„kleiner als 4“} = F(3) = \frac{8}{23}$$

$$\text{„nicht größer als 5“} = F(5) = \frac{18}{23}$$

Lagemaße zur selben Tabelle (Kontrollergebnis Tutorium 2, A4):  $\bar{x} = 4.435$ ,  $x_{med} = x_{(12)} = 4$ ,  $x_{mod} = 3$ ,  $s^2 = 2.246$ ,  $s = 1.498$ .

**KERN** Wie der klassierte Mittelwert: jeder Wert sitzt in der Klassenmitte.  $s_K^2 = \sum_j f_j (m_j - \bar{x}_K)^2$ .

✓ BEISPIEL · ARBEITSSTUNDEN PRO WOCHE IN DER VORLESUNGSZEIT

| Klasse   | $f_j$ | $m_j$ | $f_j m_j$ | $f_j (m_j - \bar{x}_K)^2$ |
|----------|-------|-------|-----------|---------------------------|
| [0, 4]   | 0.402 | 2     | 0.804     | 9.0015                    |
| (4, 8]   | 0.196 | 6     | 1.176     | 0.1050                    |
| (8, 12]  | 0.219 | 10    | 2.190     | 2.3389                    |
| (12, 16] | 0.183 | 14    | 2.562     | 9.6668                    |
| $\Sigma$ | 1     |       | 6.732     | 21.1122                   |

$\bar{x}_K = 6.732 \cdot s_K^2 = 21.112 \cdot \text{Modalklasse} = [0, 4]$  (größter Anteil, 40.2 %).

**KERN** Theoriefragen kommen als Multiple Choice oder „Formulieren Sie richtig“. Die Musterantworten sind kurz — man muss sie nur **kennen**.

| Situation                                                                           | Verfahren                                                  |
|-------------------------------------------------------------------------------------|------------------------------------------------------------|
| Man wählt zufällig ganze Schulklassen aus und befragt dort alle                     | <b>Klumpenstichprobe</b>                                   |
| Anteil jedes Studiengangs soll dem Anteil in der Studierendenschaft entsprechen     | <b>geschichtete Stichprobe / Quotenverfahren</b>           |
| Umfrage soll „repräsentativ für ganz Deutschland“ sein (Merkmale wie Alter, Region) | <b>Quotenverfahren</b> oder geschichtete Zufallsstichprobe |
| Jede Person hat dieselbe Chance, ohne Gruppen                                       | <b>einfache Zufallsstichprobe</b>                          |

◆ RICHTIG FORMULIERT (TUTORIUM 1, A14)

- Ein **Modell** ist eine **vereinfachte** Beschreibung der Realität (nicht fehlerfrei).
- **Deterministisch** heißt: Im Modell liegt **keine** Unsicherheit vor.
- Ein diskretes Merkmal kann auch **abzählbar unendlich** viele Werte haben (Autos zählen an der Autobahn).
- Quantitative Merkmale können **diskret oder stetig** sein.
- Ein Merkmal mit **endlich** vielen Ausprägungen ist **diskret**.
- Punkte von 0–100 sind **kardinal**; eine Skala 1–5 („wie oft ...“) ist **ordinal**, obwohl Zahlen dastehen.

• STÖRVARIABLEN KONTROLLIEREN (V01)

**Störvariablen** beeinflussen das Ergebnis, sind aber nicht Ziel der Untersuchung (z. B. Vorwissen bei einer Lehrmethode). Kontrolle durch: **Homogenisierung** (in Teilgruppen untersuchen), **Randomisierung** (zufällige Zuteilung zu Gruppen), **statistische Modellierung**.

## 19 Summen- und Produktzeichen

Tutorium 1 · A3–A6 · Testat 0 · A4–A5 — Werkzeug für Tag 4

TESTAT 0

**KERN** Konstanten darf man vor das Summenzeichen ziehen, Werte mit Index  $i$  **nicht**.  $\sum (x_i - \bar{x}) = 0$  immer.

| Regel                                          | Beispiel                                                                                                  |
|------------------------------------------------|-----------------------------------------------------------------------------------------------------------|
| $\sum_{i=1}^n c = n \cdot c$                   | $\sum_{i=1}^n \bar{x} = n\bar{x} = \sum x_i$                                                              |
| $\sum c x_i = c \sum x_i$                      | $\sum \frac{x_i}{n} = \frac{1}{n} \sum x_i$                                                               |
| $\sum (x_i + y_i) = \sum x_i + \sum y_i$       | $\sum (x_i - \bar{x}) = \sum x_i - n\bar{x} = 0$                                                          |
| $\sum \frac{x}{i^2} \neq \frac{1}{i^2} \sum x$ | $i$ hängt am Index — darf nicht heraus                                                                    |
| $\prod_{i=1}^n c a_i = c^n \prod a_i$          | $\prod_{i=1}^3 \theta^{x_i} e^{-\theta} = \theta^{1+2+3} e^{-3\theta} = \theta^6 e^{-3\theta}$ (Testat 0) |
| $\prod a^{x_i} = a^{\sum x_i}$                 | Produkt von Potenzen → Summe im Exponenten                                                                |

## ► R · DATENOBJEKTE UND TYPEN (R-SKRIPT 01)

```
x <- c(1, 2, 3); y <- c(1, 5, 9)
l <- x >= y                                # TRUE FALSE FALSE (logical)
f <- factor(c("a", "b", "a"), levels = c("a", "b"))
as.numeric(f)                             # 1 2 1 – die internen Codes!
M <- matrix(1:6, nrow = 2)                 # spaltenweise gefüllt
M2 <- matrix(1:6, nrow = 2, byrow = TRUE) # zeilenweise gefüllt
L <- list(); L$x <- x; L$M <- M             # Liste: verschiedene Objekte
d <- data.frame(x = x, z = c("A", "B", "C")) # Data Frame = Liste gleich langer Spalten
typeof(x); typeof(l); is.numeric(x); length(x); dim(M); nrow(d); names(d)
```

## TR · NESNE TIPLERİ

c(...)

vektör — hepsi **aynı tip**. Sayı ile metin karışırsa hepsi metin olur  
( `cbind(x, z)` de öyle).

factor(..., levels)

kategorik değişken. `as.numeric(f)` etiketleri değil **sıra kodlarını** (1, 2, ...) verir.

matrix(1:6, nrow = 2)

2 satırlı matris, **sütun sütun** doldurulur. `byrow = TRUE` → satır satır.

list / data.frame

liste farklı tipte nesneleri tutar; data frame = eşit uzunlukta  
sütunlardan oluşan özel liste.

typeof / is... / dim

tipi sorar; `dim` sadece matris ve data frame'de çalışır.

## ► R · FILTERN, GRUPPENMITTEL, MENGEN

```
v <- 1:20
v[c(1, 10, length(v))]                # 1., 10. und letztes Element
t <- read.csv("titanic.csv")
mean(t$fare, na.rm = TRUE)             # Durchschnittspreis
surv <- t[t$survived == 1, ]           # nur Überlebende (Zeilen filtern)
surv_f <- subset(surv, sex == "female") # gleiches mit subset()
table(t$sex, t$survived)               # Kontingenztafel
aggregate(t$fare, by = list(t$sex), mean) # Mittel je Gruppe (R-Skript 01)

A <- 3:6; B <- 4:2; C <- seq(2, 8, by = 2) # Testat 0, A2
union(A, B)                            # 3 4 5 6 2
intersect(A, C)                         # 4 6
setdiff(B, C)                           # 3
is.element(6, C)                        # TRUE
```

► R · SCHLEIFE, BEDINGUNG, FUNKTION (TUTORIUM 1, A16)

```
w <- rep(NA, length(v))           # leeren Vektor passender Länge anlegen
for (i in 1:length(v)) {
  w[i] <- v[i] * 1.5
}
w2 <- v * 1.5                     # dasselbe ohne Schleife
w3 <- ifelse(w > 10, 1, w)        # alles über 10 wird 1

ersetze <- function(vec) {
  for (i in 1:length(vec)) {
    if (vec[i] > 10) { vec[i] <- 1 } else { vec[i] <- vec[i] }
  }
  return(vec)
}
ersetze(v)

h <- hist(v, breaks = c(0, 5, 10, 20), plot = FALSE) # Kennzahlen ohne Grafik
h$counts; h$density; cumsum(h$counts)                # h_j, Dichte, H_j
```

TR · SATIR SATIR

`d[koşul, ]` Koşulu sağlayan satırlar. `==` karşılaştırma, `=` atama değildir!

`subset(d, koşul)` Aynı filtre, daha okunaklı.

`aggregate(x, by = list(g), mean)` Gruba göre ortalama.

`union / intersect / setdiff` birleşim  $\cup$  / kesişim  $\cap$  / fark  $\setminus$  — sıra: ilk kümede olup ikincide olmayan.

`for (i in 1:n) { }`  $i = 1, 2, \dots, n$  için gövdeyi tekrarlar. B-Teil (g) ve (h) tam bunu istiyor.

`if (...) { } else { }` tek değer için koşul; vektör için `ifelse(koşul, evet, hayır)`.

`hist(..., plot = FALSE)` Grafik çizmeden sayıları verir: `$counts` =  $h_j$ , `$density` = yoğunluk.

■ ZUSATZTRAINING BLOCK E · 12 PUNKTE · 15 MINUTEN

**(Z1)** Ein normiertes Histogramm für  $n = 200$  Alterswerte hat über  $(20, 25]$  die Höhe 0.06 und über  $(25, 35]$  die Höhe 0.04. (a) Wie viele Personen sind zwischen 25 und 35? (b) Schätzen Sie den Anteil mit  $23 < x \leq 30$ . (3P)

**(Z2)** Welche Aussage ist richtig? (1)  $\sum_{i=1}^n (x_i - \bar{x}) = \bar{x} \cdot$  (2)  $\sum_{i=1}^n (x_i - \bar{x}) = 0 \cdot$  (3)  $\sum_{i=1}^n (x_i - \bar{x}) = 1$  (1P)

**(Z3)** Ergänzen Sie die R-Ausgaben: `A <- 2:5; B <- c(5, 7); union(A, B); intersect(A, B); setdiff(A, B)` (3P)

**(Z4)** Was liefert `as.numeric(factor(c("mittel", "hoch", "mittel"), levels = c("niedrig", "mittel", "hoch")))` ? (1P)

**(Z5)** Schreiben Sie eine Funktion `anteil_ueber(x, k)`, die den Anteil der Werte in `x` größer als `k` zurückgibt. (2P)

**(Z6)** Richtig oder falsch: „Eine Befragung auf einer Skala von 1 bis 5 ist kardinalskaliert, weil Zahlen verwendet werden.“ Begründen Sie. (2P)

Lösungen Zusatztraining

**(Z1)** (a)  $0.04 \cdot 10 \cdot 200 = 80$  Personen. (b)  $(23, 25]: 0.06 \cdot 2 = 0.12$ ;  $(25, 30]: 0.04 \cdot 5 = 0.20 \rightarrow 0.32$   
(Gleichverteilung in den Klassen angenommen).

**(Z2)** (2)

**(Z3)** `2 3 4 5 7` · `5` · `2 3 4`

**(Z4)** `2 3 2` — die Codes der Levels, nicht die Reihenfolge des Auftretens.

**(Z5)** `anteil_ueber <- function(x, k) { return(mean(x > k)) }` — `mean` eines logischen Vektors ist der Anteil der TRUE.

**(Z6)** **Falsch.** Die Zahlen sind nur Codes für geordnete Kategorien; die Abstände sind nicht interpretierbar → ordinalskaliert.

## Formelblatt Tag 1 · Vorlage für dein A4-Blatt

### Skalen

nominal (nur zählen) → ordinal (+ ordnen) → metrisch (+ Abstände). Modus: alle · Median/Quantile/ $\hat{F}$ : ab ordinal · Mittel/Varianz/IQR: metrisch (0/1: Mittel = Anteil)

### Verteilungsfunktion

$\hat{F}(x)$  = Anteil  $\leq x$  · Treppe · Sprung =  $f_j$  · Punkt oben voll

### Ablesen

$> x$ :  $1 - \hat{F}(x)$  ·  $(a, b]$ :  $\hat{F}(b) - \hat{F}(a)$

### Histogramm

Höhe =  $f_j$  / Breite · Fläche =  $f_j$  · Summe = 1

### Klassiert

$\bar{x} = \frac{1}{n} \sum h_j m_j \cdot m_j$  = Klassenmitte

### Median

$n$  ungerade:  $x_{((n+1)/2)}$  · gerade: Mittel aus

$x_{(n/2)}, x_{(n/2+1)}$

### Schichten

$\bar{x} = \frac{1}{n} \sum n_j \bar{x}_j$

### Varianz

$$S^2 = \frac{1}{n} \sum x_i^2 - \bar{x}^2 \cdot S_*^2 = \frac{n}{n-1} S^2 \cdot 0/1: S^2 = \bar{x}(1 - \bar{x}) \cdot y = a + bx: \bar{y} = a + b\bar{x}, S_y^2 = b^2 S_x^2$$

### Quantil

$n\alpha$  keine ganze Zahl → aufrunden,  $x_{(\lceil n\alpha \rceil)}$  · ganzzahlig →  $\frac{x_{(n\alpha)} + x_{(n\alpha+1)}}{2}$  · IQR =  $x_{0.75} - x_{0.25}$  · Zäune  $x_{0.25} - 1.5 \text{ IQR}$ ,  $x_{0.75} + 1.5 \text{ IQR}$

### Form

rechtsschief:  $\bar{x} > x_{med} > x_{mod}$  · linksschief: umgekehrt · Median robust

### R

```
read.csv(sep=";") · head · str · mean · sd =  $s_*$  · var =  $S_*^2$  · quantile(type=2) · table ·  
hist(breaks=, right=FALSE, freq=FALSE) · pdf() ... dev.off() · round(, 3)
```

# Klausur-Simulation Tag 1

5 Aufgaben · 46 Punkte · 60 Minuten · Taschenrechner · kein Skript. Niveau: Probeklausur und etwas darüber.

**Klausurregeln:** Dezimalpunkt · Zwischenergebnisse auf **vier**, Endergebnisse auf **drei** Nachkommastellen · Lösungsweg angeben · nicht-numerische Antworten in ganzen Sätzen.

**Stell dir einen Wecker. Jedes Feld bekommt eine Antwort — auch „nicht sinnvoll, weil ...“ ist eine Antwort.**

## Aufgabe 1 Mensa-Umfrage (10 Punkte)

Das Studierendenwerk fragt 15 zufällig ausgewählte Studierende: „Wie zufrieden sind Sie mit dem Essen?“ (1 = sehr unzufrieden, 2 = unzufrieden, 3 = neutral, 4 = zufrieden, 5 = sehr zufrieden).

```
> sort(Zufriedenheit)
[1] 1 1 2 2 2 3 3 3 3 4 4 4 5 5
```

- (a) Geben Sie das Skalenniveau an. (1P)
- (b) Berechnen Sie die folgenden Lage- und Streuungsparameter. Falls Sie der Meinung sind, dass ein Parameter nicht sinnvoll angegeben werden kann, begründen Sie kurz in einem Satz. (6P)
- (c) Bestimmen Sie  $x_{0,25}$  und  $x_{0,75}$  nach der Vorlesungsregel. (2P)
- (d) Die Umfrage wird umkodiert: 1 = sehr zufrieden, ..., 5 = sehr unzufrieden, also  $y = 6 - x$ . Geben Sie  $y_{mod}$  und  $y_{med}$  an. (1P)

a

$x_{mod}$

$x_{med}$

$x^-$

$s^2$

c

d

**Aufgabe 2** Duschen im Wohnheim (14 Punkte)

Die Hausverwaltung misst bei 12 Duschvorgängen den Wasserverbrauch  $X$  in Litern und notiert den Duschkopf-Typ  $Y$  (S = Sparduschkopf, N = normal).

|       |    |    |    |    |    |    |     |    |    |    |    |    |
|-------|----|----|----|----|----|----|-----|----|----|----|----|----|
| $x_i$ | 35 | 60 | 35 | 80 | 60 | 35 | 120 | 60 | 80 | 60 | 35 | 60 |
| $y_i$ | S  | N  | S  | N  | S  | S  | N   | N  | N  | S  | S  | N  |

Hinweis:  $\sum x_i = 720$ ,  $\sum x_i^2 = 50100$ .

- (a) Geben Sie für  $X$  und  $Y$  an, ob ein diskretes oder stetiges Merkmal vorliegt und welches Skalenniveau. (4P)
- (b) Zeichnen Sie die empirische Verteilungsfunktion für  $X$ . (5P)
- (c) Welcher Anteil der Duschvorgänge verbraucht mehr als 60 Liter? (1P)
- (d) Klassieren Sie  $X$  in  $K_1 = [0, 50)$ ,  $K_2 = [50, 100)$ ,  $K_3 = [100, 150]$ . Berechnen Sie den Mittelwert der klassierten Daten und vergleichen Sie ihn mit dem Mittelwert der Originaldaten (ein Satz). (3P)
- (e) Welche Höhe hat im Histogramm der Balken über  $K_2$ ? (1P)

**a****c****d****e**

### Aufgabe 3 Lieferzeiten (8 Punkte)

Ein Online-Shop notiert die Lieferzeit (in Tagen) von 12 Bestellungen, bereits sortiert:

2 · 3 · 3 · 4 · 5 · 5 · 6 · 7 · 8 · 9 · 10 · 24

- (a) Bestimmen Sie alle drei Quartile nach der Vorlesungsregel und den IQR. (3P)
- (b) Bestimmen Sie die Ausreißer und zeichnen Sie den Boxplot. (3P)
- (c) Ein Kommilitone erhält mit `quantile(x, 0.25)` den Wert 3.75. Erklären Sie den Unterschied und geben Sie einen R-Befehl an, der Ihr Ergebnis aus (a) liefert. (2P)

a

c

### Aufgabe 4 Mieten in zwei Stadtteilen (8 Punkte)

Für die Nettomiete pro qm (in €) in zwei Göttinger Stadtteilen liefert R:

|                                            |                                            |
|--------------------------------------------|--------------------------------------------|
| <pre>&gt; length(A); mean(A); var(A)</pre> | <pre>&gt; length(B); mean(B); var(B)</pre> |
| <pre>[1] 40</pre>                          | <pre>[1] 60</pre>                          |
| <pre>[1] 9.5</pre>                         | <pre>[1] 11.2</pre>                        |
| <pre>[1] 4.1</pre>                         | <pre>[1] 6.4</pre>                         |

- (a) Berechnen Sie die empirische Varianz  $S^2$  (Nenner  $n$ ) für Stadtteil A. (2P)
- (b) Berechnen Sie die durchschnittliche Miete aller 100 Wohnungen. (2P)
- (c) Ein Vermieter in Stadtteil A erhöht alle Mieten um 8 % und schlägt zusätzlich 1.50 € pauschal auf. Berechnen Sie den neuen Mittelwert und die neue Standardabweichung  $s_*$  in Stadtteil A. (3P)
- (d) Warum ändert der Pauschalaufschlag die Streuung nicht? (ein Satz) (1P)

a

b

c

d

**Aufgabe 5** R wie in Teil B (6 Punkte)

Die Datei `Dusche.csv` (Trennzeichen Semikolon, Dezimalpunkt, mit Kopfzeile) enthält die Spalte `Liter`. Ergänzen Sie die Lücken.

```
d <- _____( "Dusche.csv", sep = _____, header = _____ )           # (1P)
round( _____( d$Liter ), 3 )                                           # s_* (1P)
_____ ( "Histogramm.pdf" )
hist( d$Liter, breaks = _____, right = _____,                    # K1-K3 wie in A2
      (2P)
      freq = _____, main = "Sitz 00, Matr.Nr. 1, Aufgabenteil e)",      # (1P)
      xlab = "Liter", ylab = "Dichte" )
_____                                                                    # (1P)
```

—

## Lösungen mit Punkteschema

Korrigiere wie ein Tutor: Punkte nur für das, was wirklich dasteht. Schreib jeden Fehler ins Fehlerheft — mit dem Satz „Nächstes Mal achte ich auf ...“.

### Aufgabe 1 · 10 Punkte

**(a) ordinalskaliert** — die Stufen lassen sich ordnen, die Abstände sind nicht interpretierbar. (1P)

**(b)** Häufigkeiten: 1 (2×), 2 (3×), 3 (5×), 4 (3×), 5 (2×),  $n = 15$ .

- $x_{mod} = 3$  (1P)
- $x_{med} = x_{(8)} = 3$  ( $n$  ungerade, Platz  $\frac{15+1}{2} = 8$ ) (1P)
- $\bar{x}$ : **nicht sinnvoll**, da das Merkmal ordinalskaliert ist und die Abstände zwischen den Stufen nicht interpretierbar sind. (2P: Aussage 1P, Begründung 1P)
- $s^2$ : **nicht sinnvoll**, aus demselben Grund — die Varianz braucht Abstände zum Mittelwert. (2P)

Wer  $\bar{x} = 3$  und  $s^2 = 1.467$  ausrechnet und dazu schreibt, dass die Interpretation bei ordinalen Daten problematisch ist, bekommt nach dem Muster der Probeklausur-Lösung in der Regel auch Punkte. Ohne jede Begründung: höchstens die Hälfte.

**(c)**  $15 \cdot 0.25 = 3.75 \rightarrow$  aufrunden  $\rightarrow x_{(4)} = 2 \cdot 15 \cdot 0.75 = 11.25 \rightarrow$  aufrunden  $\rightarrow x_{(12)} = 4$  (je 1P)


**(d)**  $y = 6 - x$  ist monoton (fallend)  $\rightarrow$  Modus und Median werden mittransformiert:  $y_{mod} = 6 - 3 = 3$ ,  $y_{med} = 3$  (1P)

Aufgabe 2 · 14 Punkte

(a) X: **stetig** (1P), **metrisch/verhältnisskaliert** (1P) · Y: **diskret** (1P), **nominal** (1P)

(b) Sortiert: 35 (4×), 60 (5×), 80 (2×), 120 (1×),  $n = 12$ .

$$\hat{F}(x) = \begin{cases} 0 & x < 35 \\ 4/12 = 0.3333 & 35 \leq x < 60 \\ 9/12 = 0.75 & 60 \leq x < 80 \\ 11/12 = 0.9167 & 80 \leq x < 120 \\ 1 & x \geq 120 \end{cases}$$



Punkte: Achsen beschriftet (1P), vier Stufen an den richtigen Stellen (2P), richtige Höhen (1P), Anfang bei 0 und Ende bei 1 mit vollen/offenen Punkten (1P).

(c)  $1 - \hat{F}(60) = 1 - 0.75 = 0.25$  (1P). Achtung: 60 selbst zählt **nicht** zu „mehr als 60“.

(d)  $K_1$ : 4 Werte,  $m_1 = 25$  ·  $K_2$ : 7 Werte,  $m_2 = 75$  ·  $K_3$ : 1 Wert,  $m_3 = 125$

$$\bar{x}_{klass} = \frac{1}{12}(4 \cdot 25 + 7 \cdot 75 + 1 \cdot 125) = \frac{100 + 525 + 125}{12} = \frac{750}{12} = 62.5$$

Mittelwert der Originaldaten:  $\bar{x} = \frac{720}{12} = 60$ . Der klassierte Mittelwert ist **größer**, weil die Werte der Klassen nicht in den Klassenmitten liegen (z. B. 35 statt 25 in  $K_1$ ). (3P)


(e)  $\frac{f_2}{\text{Breite}} = \frac{7/12}{50} = \frac{0.5833}{50} = 0.0117$  (1P)

### Aufgabe 3 · 8 Punkte

(a)  $n = 12$ :  $12 \cdot 0.25 = 3$ ,  $12 \cdot 0.5 = 6$ ,  $12 \cdot 0.75 = 9$  — alle ganzzahlig!

$$x_{0.25} = \frac{x_{(3)} + x_{(4)}}{2} = \frac{3 + 4}{2} = 3.5 \cdot x_{0.5} = \frac{5 + 6}{2} = 5.5 \cdot x_{0.75} = \frac{8 + 9}{2} = 8.5 \cdot \text{IQR} = 5 \quad (3\text{P})$$

(b) Zäune:  $3.5 - 7.5 = -4$  und  $8.5 + 7.5 = 16 \rightarrow$  Ausreißer: **24**. Whisker oben bis 10, unten bis 2. (3P: Zäune 1P, Ausreißer 1P, Zeichnung 1P)



(c) `quantile()` benutzt standardmäßig eine Interpolation (Typ 7), nicht die Vorlesungsregel. (1P)

`quantile(x, 0.25, type = 2)` liefert 3.5. (1P)

### Aufgabe 4 · 8 Punkte

(a) `var()` liefert  $S_*^2$ :  $S^2 = \frac{n-1}{n} S_*^2 = \frac{39}{40} \cdot 4.1 = 3.998$  (3.9975) (2P)

(b)  $\bar{x} = \frac{40 \cdot 9.5 + 60 \cdot 11.2}{100} = \frac{380 + 672}{100} = 10.520$  (2P) — nicht  $\frac{9.5 + 11.2}{2} = 10.35$ !

(c)  $y = 1.5 + 1.08x$ :  $\bar{y} = 1.5 + 1.08 \cdot 9.5 = 11.760$  (1P) ·  $s_{*,y} = 1.08 \cdot \sqrt{4.1} = 1.08 \cdot 2.0248 = 2.187$  (2P)

(d) Eine Verschiebung um eine Konstante verschiebt alle Werte und den Mittelwert gleich stark; die Abstände zum Mittelwert bleiben unverändert. (1P)

### Aufgabe 5 · 6 Punkte

`read.csv`, `";"`, `TRUE` (1P) · `sd` (1P) · `pdf` · `c(0, 50, 100, 150)` und `FALSE` (2P) · `FALSE` bei `freq` (1P) · `dev.off()` (1P)

Weil  $K_3 = [100, 150]$  rechts geschlossen ist, wäre zusätzlich `include.lowest = TRUE` ganz korrekt (nur relevant, falls ein Wert genau 150 ist).

## Deine Auswertung

| Punkte  | Was das bedeutet                                                                                        |
|---------|---------------------------------------------------------------------------------------------------------|
| 39 – 46 | Klausurreif. Weiter mit Tag 2.                                                                          |
| 30 – 38 | Gut. Die verlorenen Punkte in der Tabelle unten zuordnen und nur diese Schritte wiederholen.            |
| 20 – 29 | Wiederhole Schritt 3, 5 und 10, dann Aufgabe 1–3 noch einmal ohne Lösung.                               |
| 0 – 19  | Block B und C morgen früh noch einmal (60 min), danach Simulation wiederholen, bevor du Tag 2 beginnst. |

| Themenblock                              | Aufgaben   | zurück zu        |
|------------------------------------------|------------|------------------|
| Skalen und „sinnvoll?“                   | 1a, 1b, 2a | Schritt 2–3      |
| Verteilungsfunktion, Klassen, Histogramm | 2b–e       | Schritt 5–6      |
| Lage, Quantile, Boxplot                  | 1c–d, 3    | Schritt 7, 10–11 |
| Varianz, Transformation, Schichten       | 4          | Schritt 7–9      |
| R                                        | 3c, 5      | Schritt 12–14    |

# Stoffabdeckung Tag 1

Jede Quelle → wo sie in diesem PDF steht

| Quelle                              | Inhalt                                                                                                                                                                   | hier                     |
|-------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------|
| <b>V01</b> Daten- und Merkmalstypen | Grundbegriffe · diskret/stetig · Skalen ·<br>Versuchsplanung · Störvariablen ·<br>Stichprobenverfahren                                                                   | 1–3, 18                  |
| <b>V02</b> Deskriptive Statistik    | Häufigkeiten · Säulendiagramm vs. Histogramm ·<br>Modalität und Schiefe · Lagemaße · Schichten ·<br>Transformationen · Quantile · Varianz · IQR · Boxplot                | 4–11                     |
| <b>R-Skript 01</b>                  | Vektoren · factor · matrix · list · data.frame · typeof/is.*<br>· subset · aggregate · sample                                                                            | 20                       |
| <b>R-Skript 02</b>                  | unique/sort · cut (labels, right, include.lowest) · table ·<br>hist + pdf · which(table==max) · quantile · var/sd ·<br>boxplot                                           | 12–14, 20                |
| <b>Tutorium 1</b>                   | Mengen · Summen/Produkte · Stichprobenverfahren ·<br>Modelle · R-Grundlagen (Schleife, if-else, Funktion,<br>Titanic)                                                    | 1–3, 18–20               |
| <b>Tutorium 2</b>                   | Anteile aus Histogramm · Summenhäufigkeiten ·<br>Verteilungsfunktion zeichnen · hist-Optionen ·<br>Lage/Streuung · klassierte Varianz · Transformation ·<br>Boxplot in R | 5–6, 9–11, 14–17         |
| <b>Tutorium 3 A1</b>                | Median als Intervall · $\text{var}() = S_*^2$ · hist(prob = T)                                                                                                           | 7, 9, 13–14              |
| <b>Testat 0</b>                     | Einlesen · Mengen in R · Summen · Produkte (Log,<br>Ableitung, Integral → Tag 3/4)                                                                                       | 12, 19–20                |
| <b>Testat 1</b>                     | Skalen · Stichprobenverfahren · Lagemaße · sd() ·<br>Boxplot ablesen · Kausalität · Histogramm/Modalklasse                                                               | 2–3, 7–11, 15, 18        |
| <b>Probeklausur A1, A2, B a–e</b>   | vollständig                                                                                                                                                              | alle Blöcke + Simulation |