

KOMPAKT 1

Beschreibende Statistik für ein Merkmal

Von null bis Klausurniveau an einem Tag: Daten verstehen, Skalen bestimmen, Häufigkeiten, Verteilungsfunktion, Histogramm, Lage, Streuung, Quantile und Boxplot — und alles davon in R. Am Ende schreibst du eine **Klausur-Simulation** auf Probeklausur-Niveau.

🕒 ca. 6.5 Stunden

📄 4 Blöcke · 14 Schritte

🔗 Simulation · 46 Punkte · 60 min

▶ R für Teil B · TR erklär mal!

Das kannst du heute Abend

- ☐ Du bestimmst für jedes Merkmal **diskret/stetig** und das **Skalenniveau** — auch bei Fallen wie 0/1-Daten.
- ☐ Du entscheidest, welche **Maßzahl erlaubt** ist, und begründest es in einem Satz.
- ☐ Du zeichnest die **empirische Verteilungsfunktion** fehlerfrei und liest daraus Anteile ab.
- ☐ Du **klassierst** Daten, zeichnest ein **Histogramm** und rechnest den Mittelwert klassierter Daten.
- ☐ Du berechnest Mittelwert, Median, Modus, **Quantile**, **Varianz** (auch mit Verschiebungssatz) und zeichnest einen **Boxplot**.
- ☐ Du löst die passenden R-Aufgaben aus Teil B: einlesen, Kennzahlen, Histogramm als PDF.

Grundlage: Vorlesungen SDS1-V01 und V02 · R-Skripte 01 und 02 · Tutorien 1–3 · Testate 1–2 · Probeklausur Teil A (Aufgaben 1–2) und Teil B (Aufgaben a–e)

Der 5-Tage-Plan

Jeder Tag ist ein vollständiges Paket: Lernen → R → Klausur-Simulation

Tag	Inhalt	Klausurpunkte
1 · heute	Beschreibende Statistik (ein Merkmal) Skalen · Häufigkeiten · Verteilungsfunktion · Histogramm · Lage · Streuung · Quantile · Boxplot · R-Grundlagen	A1 + A2 = 24 B a–e ≈ 22
2	Zusammenhänge und Wahrscheinlichkeit Kontingenztafel · Kovarianz · Korrelation · Kausalität · Mengen · Laplace · bedingte Wahrscheinlichkeit · Bayes	A3 + A4 + A5 = 28
3	Zufallsvariablen und Verteilungen Wahrscheinlichkeits-, Dichte-, Verteilungsfunktion · E und Var · Binomial · Poisson · Exponential · Normal · ZGWS · R: d/p/q/r	Basis für A3c, A6– A8 und B f–g
4	Schätzen Maximum-Likelihood · Erwartungstreue · MSE · Konsistenz · Kerndichte · Konfidenzintervalle	A6 + A7 = 15 B f–g ≈ 15
5	Testen und Teil B komplett Hypothesen · Fehler 1./2. Art · p-Wert · Gauß- und t-Test · <code>t.test()</code> · Funktionen, Schleifen, <code>paste()</code>	A8 = 8 B h ≈ 8

◆ VORSCHLAG BIS ZUM 01.10.

Fünf Lerntage, danach drei Tage nur üben — nichts Neues mehr:

- **Tag 1–5:** ein PDF pro Tag, jeweils mit Klausur-Simulation am Abend.
- **Tag 6:** Fehlerheft durchgehen, alle Simulationen noch einmal **ohne** Lösung.
- **Tag 7:** die echte Probeklausur (Teil A 100 min, Teil B 60 min) unter Zeitdruck — erst jetzt!
- **Tag 8:** Formelblatt (ein A4-Blatt je Teil, handschriftlich) fertig schreiben. Das Formelblatt am Ende jedes PDFs ist deine Vorlage.

Klausur-Radar · Warum heute der wichtigste Tag ist

Heute lernst du den Stoff für fast 40 % aller Klausurpunkte (Teil A und Teil B zusammen).

Probeklausur A1	Skalenniveau · Modus, Median, Mittel, Varianz aus R-Output inklusive „nicht sinnvoll — begründen“ · Block A und C	10 P
Probeklausur A2	diskret/stetig · Skala · Verteilungsfunktion zeichnen · klassierte Daten die Zeichnung allein bringt 6 Punkte · Block B	14 P
Teil B a–e	Daten einlesen · Objekttypen · Mittel und s_* · Histogramm als PDF Block D · 22 von 45 Punkten in Teil B	22 P

1 • Kern lesen

Jeder Schritt beginnt mit einem Satz „Kern“. Wenn du nur den verstehst, hast du das Wichtigste.

2 • Beispiel mitrechnen

Deck die Lösung ab und rechne selbst. Erst dann vergleichen.

3 • Klausuraufgabe lösen

Nach jedem Block kommt eine Aufgabe im Probeklausur-Stil mit Punkteschema.

4 • Simulation

Am Ende: 60 Minuten, Taschenrechner, kein Blick ins Skript. Dann ehrlich korrigieren.

1

Die Grundbegriffe

V01 · FOLIE 5–10

Wer wird untersucht, und was wird gemessen?

KERN An **statistischen Einheiten** misst man **Merkmale**. Jede Messung ist eine **Ausprägung**. Die untersuchten Einheiten sind eine **Stichprobe** aus der **Grundgesamtheit**.

Begriff	Bedeutung	Beispiel: Wahlumfrage
Statistische Einheit	das Objekt, an dem gemessen wird	eine wahlberechtigte Person
Grundgesamtheit	alle Einheiten, über die man etwas wissen will	alle Wahlberechtigten
Stichprobe	die Einheiten, die man wirklich untersucht	die 1000 befragten Personen
Merkmal X	die Eigenschaft, die gemessen wird (Großbuchstabe)	Parteipräferenz, Alter
Ausprägung x_i	der gemessene Wert bei Einheit i (Kleinbuchstabe)	„SPD“, 34 Jahre

• STICHPROBENVERFAHREN (V01)

- **Einfache Zufallsstichprobe:** jedes Element hat dieselbe Chance, gezogen zu werden. Nur zufällige, keine systematischen Unterschiede zur Grundgesamtheit.
- **Geschichtete Stichprobe:** Grundgesamtheit in Gruppen (Schichten) teilen, aus **jeder** Schicht zufällig ziehen. Voraussetzung: Anteile der Schichten bekannt.
- **Klumpenstichprobe:** ganze Gruppen (Klumpen, z. B. Schulklassen) zufällig auswählen und dort alle befragen. Günstig; die Klumpen sollen untereinander ähnlich sein.
- **Quotenverfahren:** bewusste Auswahl, bis vorher festgelegte Quoten erfüllt sind — keine Zufallsauswahl.

TR · TABAKALI MI KÜME MI? TEK FARK

geschichtet

Her gruptan birkaç kişi seçilir (her tabaka temsil edilir).

Klumpen

Birkaç grup seçilir, seçilen grubun **tamamı** sorulur.

KERN Kann man die möglichen Werte **abzählen**? Dann diskret. Ist **jeder** Wert in einem Intervall möglich? Dann stetig.

• DISKRET

endlich oder abzählbar unendlich viele Ausprägungen

- Parteipräferenz, Studienfach
- Schulnote, Zufriedenheit (1–5)
- **Anzahlen:** Kinder, Likes, Fehler, Tore

• STETIG

alle reellen Zahlen in einem Intervall möglich

- Körpergröße, Gewicht, Zeit, Dauer
- Menge in Litern, Temperatur
- Einkommen, Gewinn, Preis (wird als stetig behandelt)

▲ ZWEI KLAUSURFALLEN

- **Gerundete Messung bleibt stetig.** Wenn Bier in 8.5 l, 12.0 l, 15.7 l notiert wird, ist die Menge trotzdem **stetig** — man misst nur ungenau. (So in der Probeklausur-Lösung: „stetig + metrisch skaliert“.)
- **Klassiert bleibt das Merkmal stetig.** Teilt man Alter in Klassen ein, ist das Merkmal *an sich* stetig; nur die **Darstellung** ist gruppiert.

KERN Nominal: nur Namen. Ordinal: Namen **mit Reihenfolge**. Metrisch (kardinal): echte Zahlen, **Abstände** sind sinnvoll.

Skala	Was ist sinnvoll?	Beispiele	Test-Frage
nominal	nur „gleich / verschieden“ zählen	Geschlecht, Partei, Herkunft (BY/NRW), Postleitzahl, Farbe	Kann ich die Werte sinnvoll sortieren ? Nein → nominal
ordinal	zusätzlich ordnen	Schulnote, Zufriedenheit, Platzierung, Bildungsabschluss	Ist der Abstand zwischen 1 und 2 derselbe wie zwischen 4 und 5? Nein → ordinal
metrisch (kardinal)	zusätzlich Differenzen (oft auch Verhältnisse)	Größe, Zeit, Einkommen, Liter, Anzahl	Ist „doppelt so viel“ oder „5 mehr“ sinnvoll? Ja → metrisch

Metrisch unterteilt man manchmal noch in **Intervallskala** (nur Differenzen sinnvoll, z. B. Temperatur in °C: 20 °C ist nicht „doppelt so warm“ wie 10 °C) und **Verhältnisskala** (natürlicher Nullpunkt, auch Quotienten sinnvoll, z. B. Liter, Euro, Sekunden).

◆ WAS IST BEI WELCHER SKALA ERLAUBT? — DIE WICHTIGSTE TABELLE DES TAGES

Maßzahl	nominal	ordinal	metrisch
Häufigkeiten, Modus	✓	✓	✓
Median, Quantile, Verteilungsfunktion	✗	✓	✓
Mittelwert, Varianz, Standardabweichung, IQR, Boxplot	✗	✗*	✓

* Die Vorlesung sagt: Der Mittelwert „wird manchmal auch für ordinale Merkmale verwendet“, und er ist „auch sinnvoll für binäre, als 0/1 kodierte Merkmale“. Deshalb akzeptiert die Musterlösung bei 0/1 - Daten **beides**: den Wert **oder** „nicht sinnvoll“ mit Begründung. Entscheidend ist die **Begründung**.

▲ DER SONDERFALL 0/1 (BINÄR) — GENAU SO IN PROBEKLAUSUR A1

„1 = Vorhersage richtig, 0 = falsch“. Die Musterlösung schreibt: „**Ordinalskaliert/Binär**“. Die Zahlen 0 und 1 sind nur Codes. Aber: Der Mittelwert von 0/1 - Daten ist der **Anteil der Einsen** — das ist sehr wohl sinnvoll. Für 0/1 - Daten gilt außerdem die Abkürzung

$$\bar{x} = \text{Anteil der Einsen} \quad S^2 = \bar{x} (1 - \bar{x})$$

👉 SO SCHREIBST DU „NICHT SINNVOLL“ IN DER KLAUSUR

„Der Mittelwert ist nicht sinnvoll, da das Merkmal nur ordinalskaliert ist: Die Abstände zwischen den Ausprägungen sind nicht interpretierbar.“

„Der Median ist nicht sinnvoll, da das Merkmal nominalskaliert ist und sich die Ausprägungen nicht ordnen lassen.“

✗ „Nicht sinnvoll, weil man das nicht berechnen kann.“ — Kreis, keine Skala genannt.

TR · ÖLÇEK BULMA: İKİ SORU YETER

1. Sıralanabilir mi?

Hayır → **nominal** (parti, cinsiyet, posta kodu). Evet → 2. soruya geç.

2. Farklar anlamlı mı?

Hayır → **ordinal** (not, memnuniyet). Evet → **metrisch** (süre, litre, **sayı/adet**).

Tuzak

Sayı ile yazılmış olması metrik yapmaz! Posta kodu nominal, okul notu ordinal. Ama "ders sayısı" gibi **adet** metrik.

SELBSTCHECK · SCHRITT 2-3

- ☐ Anzahl der besuchten Vorlesungen (diskret, metrisch — Mittelwert erlaubt!)
- ☐ Temperatur in °C (stetig, metrisch: Intervallskala)
- ☐ Kleidergröße S/M/L/XL (diskret, ordinal)
- ☐ Wartezeit in Sekunden (stetig, metrisch: Verhältnisskala)

BLOCK B · HÄUFIGKEITEN, VERTEILUNGSFUNKTION, HISTOGRAMM · 90 MIN

4

Absolute und relative Häufigkeiten

Zählen — der Anfang von allem

V02 · FOLIE 5-8

KERN h_j = wie oft kommt Ausprägung a_j vor. $f_j = h_j/n$ = welcher Anteil. Alle f_j zusammen ergeben 1.

✓ BEISPIEL · KAFFEETASSEN PRO TAG BEI $N = 10$ STUDIERENDEN

Urliste: 2, 0, 3, 2, 1, 2, 4, 0, 2, 3 → sortiert: 0, 0, 1, 2, 2, 2, 2, 3, 3, 4

a_j	h_j	$f_j = h_j/n$	kumuliert F
0	2	0.2	0.2
1	1	0.1	0.3
2	4	0.4	0.7
3	2	0.2	0.9
4	1	0.1	1.0
Σ	10	1.0	

Die letzte Spalte addiert von oben nach unten. Sie ist die Grundlage für Schritt 5.

KERN $\hat{F}(x)$ = Anteil der Beobachtungen, die **kleiner oder gleich** x sind. Sie ist eine **Treppe**, die an jedem beobachteten Wert nach oben springt.

• DEFINITION

$$\hat{F}(x) = \frac{\text{Anzahl der } x_i \leq x}{n} \quad (\text{ab ordinaler Skala})$$

- links vom kleinsten Wert: $\hat{F}(x) = 0$; ab dem größten Wert: $\hat{F}(x) = 1$
- an jedem beobachteten Wert springt sie um dessen relative Häufigkeit f_j
- dazwischen ist sie **waagerecht** (konstant)


✓ BEISPIEL · PENDELZEIT IN MINUTEN, $N = 10$

Urliste: 12.5, 20, 12.5, 30, 20, 45, 20, 12.5, 30, 20

Wert	h_j	f_j	$\hat{F}$ ab diesem Wert
12.5	3	0.3	0.3
20	4	0.4	0.7
30	2	0.2	0.9
45	1	0.1	1.0

Die Funktion als Formel — so will es die Musterlösung:

$$\hat{F}(x) = \begin{cases} 0 & \text{für } x < 12.5 \\ 0.3 & \text{für } 12.5 \leq x < 20 \\ 0.7 & \text{für } 20 \leq x < 30 \\ 0.9 & \text{für } 30 \leq x < 45 \\ 1 & \text{für } x \geq 45 \end{cases}$$



Treppenfunktion. Voller Punkt = der Wert gehört dazu ($\leq$). Offener Kreis = gehört nicht dazu. Die gestrichelten Senkrechten sind nur Orientierung.

▲ PUNKTESCHEMA: SO VERLIERT MAN DIE 6 PUNKTE

- **Achsen nicht beschriftet** (x-Achse: Merkmal mit Einheit, y-Achse: $\hat{F}(x)$, Werte 0 bis 1).
- **Schräge Linien** statt waagerechter Stufen — das wäre eine andere Funktion.
- **Gleiche Werte einzeln** gezählt: 12.5 kommt dreimal vor → **eine** Stufe der Höhe 0.3, nicht drei kleine.
- **Nicht bis 0 und 1** gezeichnet: links bei 0 anfangen, rechts bei 1 weiterlaufen lassen.
- **Offen/geschlossen** vertauscht: der Sprungpunkt gehört zur **oberen** Stufe.

✓ ABLESEN — DIE DREI FRAGETYPEN

Gesucht	Formel	Pendel-Beispiel
Anteil höchstens x	$\hat{F}(x)$	höchstens 20 min: $\hat{F}(20) = 0.7$
Anteil mehr als x	$1 - \hat{F}(x)$	mehr als 20 min: $1 - 0.7 = 0.3$
Anteil größer a , höchstens b	$\hat{F}(b) - \hat{F}(a)$	über 12.5 bis 30: $0.9 - 0.3 = 0.6$
Anteil weniger als x (strikt)	Stufe links von x	weniger als 20 min: 0.3

TR · DAĞILIM FONKSİYONU ÇİZME REÇETESİ

1. adım

Veriyi sırala, **farklı** değerleri ve kaç kez geçtiklerini yaz.

2. adım

Kümülatif oranları hesapla (0.3, 0.7, 0.9, 1).

3. adım

Eksenleri çiz ve **isimlendir**. y eksenini 0'dan 1'e.

4. adım

Her değerde yukarı zıpla: **dolu nokta üstte**, boş daire altta. Aralarda **yatay** çizgi.

5. adım

Formülü de yaz (Fallunterscheidung) — puanın bir kısmı buradan gelir.

KERN Beim Histogramm ist die **Fläche** gleich der relativen Häufigkeit. Die Höhe ist deshalb die **Dichte** = $f_j / \text{Klassenbreite}$.


• HISTOGRAMM (V02, FOLIE 9–13)

$$\text{Höhe der Klasse } j = \frac{f_j}{\text{Breite}_j} = \frac{h_j/n}{c_j - c_{j-1}} \quad \text{Gesamtfläche} = 1$$

Beim **Säulendiagramm** ist die **Höhe** proportional zur Häufigkeit. Bei ungleich breiten Klassen täuscht das. Deshalb gilt in dieser Vorlesung: **Histogramm = Goldstandard** für stetige Merkmale, immer mit relativen Häufigkeiten.

✓ BEISPIEL · PENDELZEITEN IN DREI KLASSEN (UNGLEICH BREIT!)

Klasse	Werte darin	h_j	f_j	Breite	Dichte	Mitte m_j
[0, 15)	12.5 × 3	3	0.3	15	0.0200	7.5
[15, 30)	20 × 4	4	0.4	15	0.0267	22.5
[30, 60]	30 × 2, 45	3	0.3	30	0.0100	45
Σ		10	1.0			



Die dritte Klasse hat genauso viele Werte wie die erste, ist aber doppelt so breit — deshalb nur halb so hoch. Probe der Flächen: $15 \cdot 0.02 + 15 \cdot 0.0267 + 30 \cdot 0.01 = 0.3 + 0.4 + 0.3 = 1$ ✓

▲ KLASSENGRENZEN GENAU LESEN

$[0, 15)$ heißt: 0 gehört dazu, 15 **nicht**. Der Wert 30 liegt deshalb in $[30, 60]$, nicht in $[15, 30)$. In der Probeklausur: $K_1 = [0, 10)$, $K_2 = [10, 20]$ — der Wert 10 gehört zu K_2 .

• MITTELWERT KLASSIERTER DATEN

Man kennt nur die Klassen, nicht die genauen Werte. Also tut man so, als lägen alle Werte einer Klasse in der **Klassenmitte** m_j :

$$\bar{x}_{klass} = \frac{1}{n} \sum_j h_j m_j = \sum_j f_j m_j \quad m_j = \frac{\text{untere} + \text{obere Grenze}}{2}$$

✓ WEITER MIT DEN PENDELZEITEN

$$\bar{x}_{klass} = \frac{1}{10} (3 \cdot 7.5 + 4 \cdot 22.5 + 3 \cdot 45) = \frac{22.5 + 90 + 135}{10} = 24.75$$

Der echte Mittelwert ist $\bar{x} = \frac{222.5}{10} = 22.25$. Der Unterschied entsteht, weil die Werte **nicht** in der Klassenmitte liegen (z. B. 12.5 statt 7.5). Das ist normal — und eine beliebte Zusatzfrage.

TR · HISTOGRAM VE SINIFLANMIŞ VERİ

Yükseklik

= oran / sınıf genişliği (**Dichte**). Alan = oran.

Sınıf ortası

(alt sınır + üst sınır) / 2. Sınıftaki herkes buradaymış gibi say.

$[a, b)$

köşeli parantez = **dahil**, yuvarlak = **hariç**. Sınırdaki değeri hangi sınıfa koyduğuna dikkat!

■ KLAUSURAUFGABE ZU BLOCK A + B · 10 PUNKTE · 15 MINUTEN · IM STIL VON A2

Eine Bäckerei notiert an 10 Tagen die verkaufte Menge Sauerteigbrot X in kg und den Wochentyp Y (W = Werktag, S = Samstag).

x_i	6.5	9.0	6.5	11.5	9.0	6.5	14.0	9.0	11.5	9.0
y_i	W	W	W	S	W	W	S	W	S	W

(a) Diskret oder stetig? Welches Skalenniveau? Für X und Y . (4P) · (b) Geben Sie $\hat{F}(x)$ als Fallunterscheidung an und bestimmen Sie den Anteil der Tage mit mehr als 9 kg. (4P) · (c) Klassieren Sie in $K_1 = [5, 10)$ und $K_2 = [10, 15]$ und berechnen Sie den Mittelwert der klassierten Daten. (2P)

Lösung mit Punkteschema

(a) X : **stetig, metrisch** (Verhältnisskala) — je 1P. Y : **diskret, nominal** — je 1P.

(b) Sortiert: 6.5 (3×), 9.0 (4×), 11.5 (2×), 14.0 (1×).

$$\hat{F}(x) = \begin{cases} 0 & x < 6.5 \\ 0.3 & 6.5 \leq x < 9 \\ 0.7 & 9 \leq x < 11.5 \\ 0.9 & 11.5 \leq x < 14 \\ 1 & x \geq 14 \end{cases}$$

3P für die Funktion (je Stufe mit richtiger Grenze). Mehr als 9 kg: $1 - \hat{F}(9) = 1 - 0.7 = \mathbf{0.3}$ (1P).

(c) K_1 : 7 Werte, Mitte 7.5 · K_2 : 3 Werte, Mitte 12.5 $\rightarrow \bar{x}_{klass} = \frac{1}{10}(7 \cdot 7.5 + 3 \cdot 12.5) = \frac{52.5 + 37.5}{10} = \mathbf{9}$ (2P).

7

Modus, Median, Mittelwert

Drei Antworten auf „Wo liegt die Mitte?“

A1 (B) · 4 P

KERN Modus = häufigster Wert. Median = mittlerer Wert der **sortierten** Liste. Mittelwert = Summe durch n .

• DIE DREI LAGEMASSE

$$x_{mod} = \text{häufigste Ausprägung} \quad \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \sum_j a_j f_j$$

$$x_{med} = \begin{cases} x_{(\frac{n+1}{2})} & n \text{ ungerade} \\ \frac{x_{(n/2)} + x_{(n/2+1)}}{2} & n \text{ gerade} \end{cases}$$

$x_{(i)}$ ist der i -te Wert **nach dem Sortieren**. Bei geradem n ist jeder Wert zwischen den beiden mittleren ein Median; als eine Zahl nimmt man die Mitte (so rechnet auch R).

✓ BEISPIEL · KAFFEETASSEN (SORTIERT: 0, 0, 1, 2, 2, 2, 2, 3, 3, 4)

- Modus: 2 kommt viermal vor $\rightarrow x_{mod} = 2$
- Median: $n = 10$ gerade $\rightarrow \frac{x_{(5)} + x_{(6)}}{2} = \frac{2 + 2}{2} = 2$
- Mittel: $\bar{x} = \frac{0 \cdot 2 + 1 \cdot 1 + 2 \cdot 4 + 3 \cdot 2 + 4 \cdot 1}{10} = \frac{19}{10} = 1.9$

✓ BEISPIEL · 0/1-DATEN WIE IN PROBEKLAUSUR A1

20 Befragte, `sort(x)` zeigt 7 Nullen und 13 Einsen.

- Modus: **1** (13-mal)
- Median: $n = 20 \rightarrow \frac{x_{(10)} + x_{(11)}}{2}$. Positionen 10 und 11 sind beide Einsen (Nullen nur bis Position 7) $\rightarrow$ **1**
- Mittel: $\bar{x} = \frac{13}{20} = 0.65$ — 65 % Einsen

▲ DEIN BEKANNTER FEHLER: POSITION UM EINS VERRUTSCHT

Schreib die sortierten Werte **mit Positionsnummern** auf, bevor du den Median suchst. Bei $n = 20$ brauchst du Platz 10 **und** 11, bei $n = 15$ nur Platz 8.

• GESCHICHTETE DATEN (GESAMTMITTEL AUS GRUPPEN)

$$\bar{x} = \frac{1}{n} (n_1 \bar{x}_1 + n_2 \bar{x}_2 + \dots + n_r \bar{x}_r)$$

Beispiel: 40 Wohnungen mit $\bar{x}_1 = 9.5$ €/qm und 60 mit $\bar{x}_2 = 11.2 \rightarrow \bar{x} = \frac{380 + 672}{100} = 10.52$. **Nicht** einfach $\frac{9.5 + 11.2}{2}$!


8 Form der Verteilung und Robustheit

Was die Lage der drei Maße verrät

V02 · FOLIE 19-25

KERN Der Mittelwert wird von Ausreißern **gezogen**, der Median nicht. Deshalb liegt bei rechtsschiefen Daten $\bar{x}$ rechts vom Median.

Form	Reihenfolge	typisch
symmetrisch	$\bar{x} \approx x_{med} \approx x_{mod}$	Körpergröße
rechtsschief (= linkssteil)	$\bar{x} > x_{med} > x_{mod}$	Einkommen, Mieten, Wartezeiten
linksschief (= rechtssteil)	$\bar{x} < x_{med} < x_{mod}$	Punkte in einer leichten Klausur



Rechtsschiefe Verteilung. Der Gipfel (Modus) liegt links. Der Mittelwert wird vom langen Ausläufer nach rechts gezogen und ist deshalb am größten. Der Median liegt dazwischen.

👉 SO SCHREIBST DU ES IN DER KLAUSUR · VORTEIL DES MEDIANS (PROBEKLAUSUR-B-BEISPIEL)

„Der Median ist robuster gegenüber Extremwerten als das arithmetische Mittel.“

• TRANSFORMATIONEN

Lineare Transformation $y_i = a + b x_i \rightarrow \bar{y} = a + b \bar{x}$. Für jede **monotone** Transformation g gilt $y_{med} = g(x_{med})$.

Beispiel: Umrechnung °C → °F mit $y = 32 + 1.8x$. Mittel $20\text{ °C} \rightarrow 32 + 1.8 \cdot 20 = 68\text{ °F}$.

9

Varianz und Standardabweichung

Wie weit liegen die Daten vom Mittelwert weg?

A1 (B) · A5 (A) · B (D)

KERN Varianz = durchschnittliche **quadrierte** Abweichung vom Mittelwert. Rechne fast immer mit dem **Verschiebungssatz**.

• FORMELN

$$S^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \underbrace{\sum_{i=1}^n x_i^2 - n \bar{x}^2}_{\text{Verschiebungssatz}} \quad S = \sqrt{S^2}$$

$$S_*^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{n}{n-1} S^2$$

S_*^2 heißt „unverzerrt“ oder „korrigiert“.

S hat dieselbe Einheit wie die Daten, S^2 die quadrierte Einheit.

✓ BEISPIEL · KAFFEETASSEN MIT VERSCHIEBUNGSSATZ

1 $\sum x_i^2 = 0^2 \cdot 2 + 1^2 \cdot 1 + 2^2 \cdot 4 + 3^2 \cdot 2 + 4^2 \cdot 1 = 0 + 1 + 16 + 18 + 16 = 51$

2 $\frac{1}{n} \sum x_i^2 = \frac{51}{10} = 5.1$ und $\bar{x}^2 = 1.9^2 = 3.61$

3 $S^2 = 5.1 - 3.61 = 1.49 \cdot S = \sqrt{1.49} = 1.2207$

4 $S_*^2 = \frac{10}{9} \cdot 1.49 = 1.6556$ — **das** würde `var(x)` in R ausgeben

✓ BEISPIEL · 0/1-DATEN: DER SCHNELLWEG

7 Nullen, 13 Einsen: $\bar{x} = 0.65 \rightarrow S^2 = 0.65 \cdot 0.35 = 0.2275$. Probe mit Verschiebungssatz: $\frac{13}{20} - 0.65^2 = 0.65 - 0.4225 = 0.2275$ ✓ (bei 0/1 ist $x_i^2 = x_i$).

• TRANSFORMATION UND VARIANZ

$y_i = a + b x_i \rightarrow S_y^2 = b^2 S_x^2$ und $S_y = |b| S_x$. Die Verschiebung a ändert die Streuung **nicht**.

TR · S² MI S²* MI? SINAV NASIL SORAR

„empirische Varianz“

S^2 , bölen **n**. Probeklausur A1 ve A5 bunu istiyor.

„unverzerrt“ / s_*

S_*^2 , bölen **n-1**. B-Teil (d) "unverzerrter Schätzer für die Standardabweichung s_* " → R'da direkt `sd(x)`.

R: `var(x)`, `sd(x)`

Her zaman n-1. S^2 lazımsa: `(n-1)/n * var(x)`.

10 Quantile nach der Vorlesungsregel

V02 · FOLIE 26-29

Die Regel, die R nicht standardmäßig benutzt

KERN Rechne $n \cdot \alpha$. Keine ganze Zahl → **aufunden** und diesen Platz nehmen. Ganze Zahl → **Mittel** aus diesem und dem nächsten Platz.

• DIE REGEL

$$x_\alpha = \begin{cases} x_{([n\alpha]+1)} & n\alpha \text{ keine ganze Zahl} \\ \frac{x_{(n\alpha)} + x_{(n\alpha+1)}}{2} & n\alpha \text{ ganze Zahl} \end{cases}$$

$[n\alpha]$ = abgerundet. „Abrunden und +1“ ist dasselbe wie „aufunden“. Voraussetzung: mindestens ordinal.

✓ BEISPIEL · 26 NETTOMIETEN AUS DER VORLESUNG (SORTIERT)

(1) 77.31 · (2) 104.14 · (3) 116.48 · (4) 132.24 · (5) 158.91 · (6) 163.17 · (7) **170.04** · (8) 181.98 · (9) 183.09 · (10) 200.84 · (11) 210.55 · (12) 227.91 · (13) 243.44 · (14) 255.75 · (15) 261.98 · (16) 263.21 · (17) 269.84 · (18) 276.60 · (19) 281.21 · (20) **311.87** · (21) 343.30 · (22) 359.17 · (23) 361.60 · (24) 362.00 · (25) 400.05 · (26) 533.92

- $x_{0.25}$: $26 \cdot 0.25 = 6.5 \rightarrow$ aufrunden $\rightarrow$ Platz 7 $\rightarrow$ **170.04**
- $x_{0.5}$: $26 \cdot 0.5 = 13$ ganzzahlig $\rightarrow \frac{243.44 + 255.75}{2} =$ **249.595**
- $x_{0.75}$: $26 \cdot 0.75 = 19.5 \rightarrow$ aufrunden $\rightarrow$ Platz 20 $\rightarrow$ **311.87**

▲ R RECHNET STANDARDMÄSSIG ANDERS

`quantile(x)` interpoliert (Typ 7) und liefert oft **andere** Zahlen. `quantile(x, type = 2)` liefert genau die Vorlesungsregel. In Teil A zählt die Vorlesungsregel; in Teil B schreibst du, welchen Befehl du benutzt hast.

11 IQR, Ausreißer und Boxplot

Fünf Zahlen, ein Bild

V02 · FOLIE 33–36

KERN Box von $x_{0.25}$ bis $x_{0.75}$, Strich beim Median. Ausreißer liegen mehr als $1.5 \cdot \text{IQR}$ außerhalb der Box.


• REZEPT

- 1 Quartile bestimmen, $\text{IQR} = x_{0.75} - x_{0.25}$
- 2 Zäune: unten $x_{0.25} - 1.5 \text{IQR}$, oben $x_{0.75} + 1.5 \text{IQR}$
- 3 Werte außerhalb der Zäune = **Ausreißer**, einzeln als Punkt zeichnen
- 4 Whisker bis zum äußersten Wert **innerhalb** der Zäune — nicht bis zum Zaun selbst

✓ BEISPIEL · NETTOMIETEN

$\text{IQR} = 311.87 - 170.04 = 141.83$ · Zäune: $170.04 - 212.745 = -42.705$ und $311.87 + 212.745 = 524.615$

533.92 liegt über 524.615 → **Ausreißer**. Der obere Whisker endet beim größten Nicht-Ausreißer 400.05.



TR · BOXPLOT'TA EN SIK HATA

Whisker (bıyık) **çite kadar değil**, çitin içinde kalan **en uç gerçek veriye** kadar çizilir. Çit sadece hesap için var, çizilmez.

■ KLAUSURAUFGABE ZU BLOCK C · 10 PUNKTE · 12 MINUTEN · IM STIL VON A1

Eine Umfrage erfasst bei 16 Studierenden die Anzahl der Geschwister. R liefert:

```
> sort(Geschwister)
[1] 0 0 0 1 1 1 1 1 1 2 2 2 3 3 4 6
> sum(Geschwister^2)
[1] 88
```

(a) Skalenniveau? (1P) · (b) x_{mod} , x_{med} , $\bar{x}$, s^2 — falls nicht sinnvoll, begründen. (5P) · (c) $x_{0.25}$, $x_{0.75}$ und alle Ausreißer nach der 1.5-IQR-Regel. (3P) · (d) Rechts- oder linksschief? Begründen Sie mit zwei Lagemaßen. (1P)

Lösung mit Punkteschema

(a) Anzahl → **metrisch** (diskret) (1P). Deshalb sind hier **alle** Maße sinnvoll.

(b) $x_{mod} = 1$ (1P) · $x_{med} = \frac{x_{(8)} + x_{(9)}}{2} = \frac{1 + 1}{2} = 1$ (1P) · $\bar{x} = \frac{0 \cdot 3 + 1 \cdot 6 + 2 \cdot 3 + 3 \cdot 2 + 4 + 6}{16} = \frac{28}{16} = 1.75$ (1P)

$s^2 = \frac{88}{16} - 1.75^2 = 5.5 - 3.0625 = 2.4375 \rightarrow 2.438$ (2P: Formel 1P, Ergebnis 1P)

(c) $16 \cdot 0.25 = 4$ ganzzahlig $\rightarrow x_{0.25} = \frac{x_{(4)} + x_{(5)}}{2} = \frac{1 + 1}{2} = 1$; $16 \cdot 0.75 = 12$ ganzzahlig $\rightarrow x_{0.75} = \frac{x_{(12)} + x_{(13)}}{2} = \frac{2 + 3}{2} = 2.5$ (2P). IQR = 1.5, oberer Zaun $2.5 + 2.25 = 4.75 \rightarrow$ Ausreißer: **6** (1P). Der Wert 4 ist **kein** Ausreißer.

(d) $\bar{x} = 1.75 > x_{med} = 1 \rightarrow$ **rechtsschief** (1P).

BLOCK D · R FÜR TEIL B · 60 MIN

12

Daten einlesen und anschauen

Probeklausur B (a)–(c) · 10 Punkte

BA-C · 10 P

► R · DIE ERSTEN DREI AUFGABEN JEDER B-KLAUSUR

```
setwd(path.expand("~/")) # (a) Arbeitsordner = Dokumente

d <- read.csv("WitcherData1.csv", # (b) Datei einlesen
  sep = ";", dec = ".", header = TRUE)

head(d) # erste 6 Zeilen zeigen

str(d) # (c) Objekttypen aller Spalten
class(d$Ta1) # z. B. "character"
class(d$Muenzen) # z. B. "integer" / "numeric"
```

`setwd(path.expand("~/"))`

Çalışma klasörünü "Dokumente" yapar. Sınavda bu komut **verilir**, aynen yaz.

`read.csv(..., sep = ";")`

CSV dosyasını okur. `sep` = sütun ayırıcı (dosyaya bak: ; mi , mi?).
`dec` = ondalık işareti.

`header = TRUE`

İlk satır sütun **isimleri**dir.

`d <- ...`

Sonucu `d` adıyla **kaydeder**. Görev "Objekt d" diyorsa isim tam `d` olmalı.

`head(d)`

İlk 6 satır. "ersten 6 Zeilen wiedergeben" → bu.

`str(d)`

Her sütunun tipini gösterir: `chr` = character, `num` = numeric, `int` = integer, `Factor`, `logi`.

`d$Tal`

Data frame'in "Tal" sütunu. `$` = "içindeki".

Cevap kutusuna **kodu ve R çıktısını** birlikte kopyala; ayrı kutuya tam cümleyle cevap yaz: „Die Variable Tal ist vom Typ character, die Variable Muenzen vom Typ integer.“

13

Kennzahlen in R

Probeklausur B (d) · 4 Punkte

B D · 4 P

► R · LAGE UND STREUUNG

```
x <- d$Muenzen

round(mean(x), 3)           # arithmetisches Mittel
round(sd(x), 3)             # s_* (unverzerrt, n-1) ← so gefragt in B (d)
median(x)
var(x)                      # S^2_* (n-1)
n <- length(x)
(n - 1) / n * var(x)        # S^2 der Vorlesung (n)

quantile(x, c(0.25, 0.75), type = 2) # Vorlesungsregel
summary(x)                  # min, Quartile (Typ 7), Median, Mittel, max

table(d$Tal)                # absolute Häufigkeiten
prop.table(table(d$Tal))    # relative Häufigkeiten
names(which.max(table(d$Tal))) # Modus (es gibt kein mode(!))

mean(x, na.rm = TRUE)      # falls fehlende Werte (NA) vorkommen
```

TR · KRITİK NOKTALAR

`round(..., 3)`

Sınav kuralı: sonuçlar **3 ondalık**, yuvarlamayı **R komutuyla** yap.

`sd(x)`

s_* = n-1'li standart sapma. B-Teil tam bunu soruyor.

`mode(x)`

TUZAK: Modus değil, nesne tipini verir ("numeric"). Modus için `table` + `which.max`.

`type = 2`

Ders kuralıyla kuantil. Yazmazsan R başka yöntem kullanır.

`na.rm = TRUE`

Eksik değer (NA) varsa onları atla. Yoksa sonuç NA çıkar.

14

Histogramm mit Klassen als PDF

Probeklausur B (e) · 8 Punkte — die teuerste R-Aufgabe

BE · 8 P

► R · KLASSEN [5, 15), [15, 20), [20, 25), [25, 35) ALS PDF

```
pdf("Histogramm.pdf")                # 1. Datei öffnen
hist(d$Muenzen,
     breaks = c(5, 15, 20, 25, 35),    # Klassengrenzen
     right = FALSE,                    # [a, b): links geschlossen
     freq = FALSE,                     # y-Achse = Dichte
     main = "Sitz 00, Matr.Nr. 12345678, Aufgabenteil e)",
     xlab = "Muenzen",
     ylab = "Dichte")
dev.off()                             # 2. Datei schließen
```

TR · 8 PUANIN PARÇALARI

`breaks = c(...)`

Sınıf **sınırları** — 4 sınıf için 5 sayı. Görevdeki aralıkları aynen yaz.

`right = FALSE`

Aralıklar **[a, b)** ise şart. R'ın varsayılması (a, b]!

`freq = FALSE`

y eksenini **yoğunluk (Dichte)** olur. Görev "Dichte" diyorsa şart.

`main / xlab / ylab`

Başlıkta Sitz + Matr.Nr. + Aufgabenteil, eksen adları görevdeki gibi.

`pdf()` ... `dev.off()`

Aç → çiz → kapat. `dev.off()` unutulursa dosya boş kalır.

Dikkat: Son sınıf [25, 35) ama 35 değeri varsa R hata verir ("some x not counted"). O zaman `include.lowest = TRUE` ekle — `right = FALSE` ile birlikte bu, **son** aralığı sağdan kapatır.

► R · VERTEILUNGSFUNKTION UND BOXPLOT

```
plot(ecdf(x), main = "Empirische Verteilungsfunktion",
     xlab = "Muenzen", ylab = "F(x)")
boxplot(x, range = 1.5, main = "Boxplot", ylab = "Muenzen")
b <- boxplot(x, plot = FALSE)
b$stats      # Whisker unten, Box unten, Median, Box oben, Whisker oben
b$out        # Ausreißer
```

Formelblatt Tag 1 · Vorlage für dein A4-Blatt

Skalen

nominal (nur zählen) → ordinal (+ ordnen) → metrisch (+ Abstände). Modus: alle · Median/Quantile/ $\hat{F}$: ab ordinal · Mittel/Varianz/IQR: metrisch (0/1: Mittel = Anteil)

Verteilungsfunktion

$\hat{F}(x)$ = Anteil $\leq x$ · Treppe · Sprung = f_j · Punkt oben voll

Ablesen

$> x$: $1 - \hat{F}(x)$ · $(a, b]$: $\hat{F}(b) - \hat{F}(a)$

Histogramm

Höhe = f_j / Breite · Fläche = f_j · Summe = 1

Klassiert

$\bar{x} = \frac{1}{n} \sum h_j m_j$ · m_j = Klassenmitte

Median

n ungerade: $x_{((n+1)/2)}$ · gerade: Mittel aus $x_{(n/2)}, x_{(n/2+1)}$

Schichten

$\bar{x} = \frac{1}{n} \sum n_j \bar{x}_j$

Varianz

$S^2 = \frac{1}{n} \sum x_i^2 - \bar{x}^2$ · $S_*^2 = \frac{n}{n-1} S^2$ · 0/1: $S^2 = \bar{x}(1 - \bar{x})$ · $y = a + bx$: $\bar{y} = a + b\bar{x}$, $S_y^2 = b^2 S_x^2$

Quantil

$n\alpha$ keine ganze Zahl → aufrunden, $x_{(\lceil n\alpha \rceil)}$ · ganzzahlig → $\frac{x_{(n\alpha)} + x_{(n\alpha+1)}}{2}$ · IQR = $x_{0.75} - x_{0.25}$ · Zäune $x_{0.25} - 1.5 \text{ IQR}$, $x_{0.75} + 1.5 \text{ IQR}$

Form

rechtsschief: $\bar{x} > x_{med} > x_{mod}$ · linksschief: umgekehrt · Median robust

R

`read.csv(sep=";")` · `head` · `str` · `mean` · `sd` = s_* · `var` = S_*^2 · `quantile(type=2)` · `table` · `hist(breaks=, right=FALSE, freq=FALSE)` · `pdf()` ... `dev.off()` · `round(, 3)`

Klausur-Simulation Tag 1

5 Aufgaben · 46 Punkte · 60 Minuten · Taschenrechner · kein Skript. Niveau: Probeklausur und etwas darüber.

Klausurregeln: Dezimalpunkt · Zwischenergebnisse auf **vier**, Endergebnisse auf **drei** Nachkommastellen · Lösungsweg angeben · nicht-numerische Antworten in ganzen Sätzen.

Stell dir einen Wecker. Jedes Feld bekommt eine Antwort — auch „nicht sinnvoll, weil ...“ ist eine Antwort.

Aufgabe 1 Mensa-Umfrage (10 Punkte)

Das Studierendenwerk fragt 15 zufällig ausgewählte Studierende: „Wie zufrieden sind Sie mit dem Essen?“ (1 = sehr unzufrieden, 2 = unzufrieden, 3 = neutral, 4 = zufrieden, 5 = sehr zufrieden).

```
> sort(Zufriedenheit)
[1] 1 1 2 2 2 3 3 3 3 3 4 4 4 5 5
```

- (a) Geben Sie das Skalenniveau an. (1P)
- (b) Berechnen Sie die folgenden Lage- und Streuungsparameter. Falls Sie der Meinung sind, dass ein Parameter nicht sinnvoll angegeben werden kann, begründen Sie kurz in einem Satz. (6P)
- (c) Bestimmen Sie $x_{0,25}$ und $x_{0,75}$ nach der Vorlesungsregel. (2P)
- (d) Die Umfrage wird umkodiert: 1 = sehr zufrieden, ..., 5 = sehr unzufrieden, also $y = 6 - x$. Geben Sie y_{mod} und y_{med} an. (1P)

a

x_{mod}

x_{med}

x^-

s^2

c

d

Aufgabe 2 Duschen im Wohnheim (14 Punkte)

Die Hausverwaltung misst bei 12 Duschvorgängen den Wasserverbrauch X in Litern und notiert den Duschkopf-Typ Y (S = Sparduschkopf, N = normal).

x_i	35	60	35	80	60	35	120	60	80	60	35	60
y_i	S	N	S	N	S	S	N	N	N	S	S	N

Hinweis: $\sum x_i = 720$, $\sum x_i^2 = 50100$.

- (a) Geben Sie für X und Y an, ob ein diskretes oder stetiges Merkmal vorliegt und welches Skalenniveau. (4P)
- (b) Zeichnen Sie die empirische Verteilungsfunktion für X . (5P)
- (c) Welcher Anteil der Duschvorgänge verbraucht mehr als 60 Liter? (1P)
- (d) Klassieren Sie X in $K_1 = [0, 50)$, $K_2 = [50, 100)$, $K_3 = [100, 150]$. Berechnen Sie den Mittelwert der klassierten Daten und vergleichen Sie ihn mit dem Mittelwert der Originaldaten (ein Satz). (3P)
- (e) Welche Höhe hat im Histogramm der Balken über K_2 ? (1P)

a**c****d****e**


Aufgabe 3 Lieferzeiten (8 Punkte)

Ein Online-Shop notiert die Lieferzeit (in Tagen) von 12 Bestellungen, bereits sortiert:

2 · 3 · 3 · 4 · 5 · 5 · 6 · 7 · 8 · 9 · 10 · 24

- (a) Bestimmen Sie alle drei Quartile nach der Vorlesungsregel und den IQR. (3P)
- (b) Bestimmen Sie die Ausreißer und zeichnen Sie den Boxplot. (3P)
- (c) Ein Kommilitone erhält mit `quantile(x, 0.25)` den Wert 3.75. Erklären Sie den Unterschied und geben Sie einen R-Befehl an, der Ihr Ergebnis aus (a) liefert. (2P)

a



c

Aufgabe 4 Mieten in zwei Stadtteilen (8 Punkte)

Für die Nettomiete pro qm (in €) in zwei Göttinger Stadtteilen liefert R:

```
> length(A); mean(A); var(A)
[1] 40
[1] 9.5
[1] 4.1
```

```
> length(B); mean(B); var(B)
[1] 60
[1] 11.2
[1] 6.4
```

- (a) Berechnen Sie die empirische Varianz S^2 (Nenner n) für Stadtteil A. (2P)
- (b) Berechnen Sie die durchschnittliche Miete aller 100 Wohnungen. (2P)
- (c) Ein Vermieter in Stadtteil A erhöht alle Mieten um 8 % und schlägt zusätzlich 1.50 € pauschal auf. Berechnen Sie den neuen Mittelwert und die neue Standardabweichung s_* in Stadtteil A. (3P)
- (d) Warum ändert der Pauschalaufschlag die Streuung nicht? (ein Satz) (1P)

a

b

c

d

Aufgabe 5 R wie in Teil B (6 Punkte)

Die Datei `Dusche.csv` (Trennzeichen Semikolon, Dezimalpunkt, mit Kopfzeile) enthält die Spalte `Liter`. Ergänzen Sie die Lücken.

```
d <- _____( "Dusche.csv", sep = _____, header = _____ )           # (1P)
round( _____( d$Liter ), 3 )                                           # s_* (1P)
_____ ( "Histogramm.pdf" )
hist( d$Liter, breaks = _____, right = _____,                      # K1-K3 wie in A2
      (2P)
      freq = _____, main = "Sitz 00, Matr.Nr. 1, Aufgabenteil e)",      # (1P)
      xlab = "Liter", ylab = "Dichte" )
_____                                                                    # (1P)
```

—

Lösungen mit Punkteschema

Korrigiere wie ein Tutor: Punkte nur für das, was wirklich dasteht. Schreib jeden Fehler ins Fehlerheft — mit dem Satz „Nächstes Mal achte ich auf ...“.

Aufgabe 1 · 10 Punkte

(a) ordinalskaliert — die Stufen lassen sich ordnen, die Abstände sind nicht interpretierbar. (1P)

(b) Häufigkeiten: 1 (2×), 2 (3×), 3 (5×), 4 (3×), 5 (2×), $n = 15$.

- $x_{mod} = 3$ (1P)
- $x_{med} = x_{(8)} = 3$ (n ungerade, Platz $\frac{15+1}{2} = 8$) (1P)
- $\bar{x}$: **nicht sinnvoll**, da das Merkmal ordinalskaliert ist und die Abstände zwischen den Stufen nicht interpretierbar sind. (2P: Aussage 1P, Begründung 1P)
- s^2 : **nicht sinnvoll**, aus demselben Grund — die Varianz braucht Abstände zum Mittelwert. (2P)

Wer $\bar{x} = 3$ und $s^2 = 1.467$ ausrechnet und dazu schreibt, dass die Interpretation bei ordinalen Daten problematisch ist, bekommt nach dem Muster der Probeklausur-Lösung in der Regel auch Punkte. Ohne jede Begründung: höchstens die Hälfte.

(c) $15 \cdot 0.25 = 3.75 \rightarrow$ aufrunden $\rightarrow x_{(4)} = 2 \cdot 15 \cdot 0.75 = 11.25 \rightarrow$ aufrunden $\rightarrow x_{(12)} = 4$ (je 1P)


(d) $y = 6 - x$ ist monoton (fallend) $\rightarrow$ Modus und Median werden mittransformiert: $y_{mod} = 6 - 3 = 3$, $y_{med} = 3$ (1P)

Aufgabe 2 · 14 Punkte

(a) X : **stetig** (1P), **metrisch/verhältnisskaliert** (1P) · Y : **diskret** (1P), **nominal** (1P)

(b) Sortiert: 35 (4×), 60 (5×), 80 (2×), 120 (1×), $n = 12$.

$$\hat{F}(x) = \begin{cases} 0 & x < 35 \\ 4/12 = 0.3333 & 35 \leq x < 60 \\ 9/12 = 0.75 & 60 \leq x < 80 \\ 11/12 = 0.9167 & 80 \leq x < 120 \\ 1 & x \geq 120 \end{cases}$$



Punkte: Achsen beschriftet (1P), vier Stufen an den richtigen Stellen (2P), richtige Höhen (1P), Anfang bei 0 und Ende bei 1 mit vollen/offenen Punkten (1P).

(c) $1 - \hat{F}(60) = 1 - 0.75 = \mathbf{0.25}$ (1P). Achtung: 60 selbst zählt **nicht** zu „mehr als 60“.

(d) K_1 : 4 Werte, $m_1 = 25$ · K_2 : 7 Werte, $m_2 = 75$ · K_3 : 1 Wert, $m_3 = 125$

$$\bar{x}_{klass} = \frac{1}{12}(4 \cdot 25 + 7 \cdot 75 + 1 \cdot 125) = \frac{100 + 525 + 125}{12} = \frac{750}{12} = 62.5$$

Mittelwert der Originaldaten: $\bar{x} = \frac{720}{12} = 60$. Der klassierte Mittelwert ist **größer**, weil die Werte der Klassen nicht in den Klassenmitten liegen (z. B. 35 statt 25 in K_1). (3P)


(e) $\frac{f_2}{\text{Breite}} = \frac{7/12}{50} = \frac{0.5833}{50} = \mathbf{0.0117}$ (1P)

Aufgabe 3 · 8 Punkte

(a) $n = 12$: $12 \cdot 0.25 = 3$, $12 \cdot 0.5 = 6$, $12 \cdot 0.75 = 9$ — alle ganzzahlig!

$$x_{0.25} = \frac{x_{(3)} + x_{(4)}}{2} = \frac{3 + 4}{2} = 3.5 \cdot x_{0.5} = \frac{5 + 6}{2} = 5.5 \cdot x_{0.75} = \frac{8 + 9}{2} = 8.5 \cdot \text{IQR} = 5 \quad (3\text{P})$$

(b) Zäune: $3.5 - 7.5 = -4$ und $8.5 + 7.5 = 16 \rightarrow$ Ausreißer: **24**. Whisker oben bis 10, unten bis 2. (3P: Zäune 1P, Ausreißer 1P, Zeichnung 1P)



(c) `quantile()` benutzt standardmäßig eine Interpolation (Typ 7), nicht die Vorlesungsregel. (1P)

`quantile(x, 0.25, type = 2)` liefert 3.5. (1P)

Aufgabe 4 · 8 Punkte

(a) `var()` liefert S_*^2 : $S^2 = \frac{n-1}{n} S_*^2 = \frac{39}{40} \cdot 4.1 = 3.998$ (3.9975) (2P)

(b) $\bar{x} = \frac{40 \cdot 9.5 + 60 \cdot 11.2}{100} = \frac{380 + 672}{100} = 10.520$ (2P) — nicht $\frac{9.5 + 11.2}{2} = 10.35$!

(c) $y = 1.5 + 1.08x$: $\bar{y} = 1.5 + 1.08 \cdot 9.5 = 11.760$ (1P) · $s_{*,y} = 1.08 \cdot \sqrt{4.1} = 1.08 \cdot 2.0248 = 2.187$ (2P)

(d) Eine Verschiebung um eine Konstante verschiebt alle Werte und den Mittelwert gleich stark; die Abstände zum Mittelwert bleiben unverändert. (1P)

Aufgabe 5 · 6 Punkte

`read.csv`, `";"`, `TRUE` (1P) · `sd` (1P) · `pdf` · `c(0, 50, 100, 150)` und `FALSE` (2P) · `FALSE` bei `freq` (1P) · `dev.off()` (1P)

Weil $K_3 = [100, 150]$ rechts geschlossen ist, wäre zusätzlich `include.lowest = TRUE` ganz korrekt (nur relevant, falls ein Wert genau 150 ist).

Deine Auswertung

Punkte	Was das bedeutet
39 – 46	Klausurreif. Weiter mit Tag 2.
30 – 38	Gut. Die verlorenen Punkte in der Tabelle unten zuordnen und nur diese Schritte wiederholen.
20 – 29	Wiederhole Schritt 3, 5 und 10, dann Aufgabe 1–3 noch einmal ohne Lösung.
0 – 19	Block B und C morgen früh noch einmal (60 min), danach Simulation wiederholen, bevor du Tag 2 beginnst.

Themenblock	Aufgaben	zurück zu
Skalen und „sinnvoll?“	1a, 1b, 2a	Schritt 2–3
Verteilungsfunktion, Klassen, Histogramm	2b–e	Schritt 5–6
Lage, Quantile, Boxplot	1c–d, 3	Schritt 7, 10–11
Varianz, Transformation, Schichten	4	Schritt 7–9
R	3c, 5	Schritt 12–14