

TAG 01

Daten- und Merkmalstypen

Heute lernst du die Sprache der Statistik. Du lernst, wie man Daten benennt und wie man sie sortiert. Das klingt einfach — aber alles, was in den nächsten Wochen kommt, baut genau darauf auf.

ca. 2,5 Stunden

7 Schritte

11 Aufgaben · 20 Punkte

▶ R-Ecke

Das kannst du heute Abend

- ☐ Du kannst **Grundgesamtheit** und **Stichprobe** unterscheiden.
- ☐ Du weißt, was ein **Merkmal** und was eine **Merkmalsausprägung** ist.
- ☐ Du erkennst, ob ein Merkmal **diskret** oder **stetig** ist.
- ☐ Du bestimmst das **Skalenniveau**: nominal, ordinal oder kardinal.
- ☐ Du weißt, welche Rechnung bei welchem Skalenniveau erlaubt ist.
- ☐ Du kennst die wichtigsten **Stichprobenverfahren**.
- ☐ Du kannst in **R** Vektoren, Faktoren und Datensätze anlegen.

Grundlage: Vorlesung SDS1-V01 „Daten- und Merkmalstypen“ · R-Skript 01StatDS-Datenobjekte.R

■ BEVOR DU ANFÄNGST

Lies jeden Schritt **einmal ganz**. Lies ihn dann **ein zweites Mal** und schreibe dabei die fett gedruckten Wörter mit ihrer Bedeutung auf ein Blatt. Dieses Blatt ist am Ende des Tages deine eigene Zusammenfassung.

1

Die drei Grundbegriffe

Einheit · Grundgesamtheit · Stichprobe

Statistik beginnt immer mit einer **Frage**. Zum Beispiel: „Wie viel Miete zahlen Studierende in Göttingen?“ Um diese Frage zu beantworten, brauchst du Daten. Und für Daten brauchst du drei Begriffe.

• DEFINITION

Statistische Einheit: das einzelne Objekt, an dem du misst. Das kann eine Person sein, eine Firma, eine Wohnung oder eine Pflanze.

Grundgesamtheit (auch: Population): *alle* Einheiten, die für deine Frage wichtig sind.

Stichprobe: der *Teil* der Grundgesamtheit, den du wirklich untersuchst.

Der Grund für die Stichprobe ist einfach: Die Grundgesamtheit ist fast immer zu groß. Du kannst nicht alle 60 Millionen Wahlberechtigten in Deutschland fragen. Also fragst du 1 000 Personen — und schließt von diesen 1 000 auf alle.

✓ BEISPIEL 1 · WAHLUMFRAGE

Frage	Welche Partei wird gewählt?
Statistische Einheit	eine wahlberechtigte Person
Grundgesamtheit	alle Personen, die bei der nächsten Bundestagswahl wählen dürfen
Stichprobe	die 1 000 Personen, die tatsächlich befragt wurden

✓ BEISPIEL 2 · POLITIK UND UMWELT

Frage	Senkt ein neues Gesetz die Emissionen von Firmen?
Statistische Einheit	eine Firma
Grundgesamtheit	alle Firmen, für die das Gesetz gilt
Stichprobe	die Firmen, für die wir Zahlen vor <i>und</i> nach dem Gesetz haben

◆ MERKE DIR DAS

Die Grundgesamtheit muss nicht real existieren. Sie darf auch **gedacht** sein. Beispiel: „Alle Weizenfelder, auf denen man diesen Dünger je einsetzen könnte.“ Diese Menge gibt es nicht als Liste — trotzdem ist sie die Grundgesamtheit.

2

Merkmal und Merkmalsausprägung

Was du misst — und was dabei herauskommt

An jeder Einheit misst du eine oder mehrere **Eigenschaften**. Eine solche Eigenschaft heißt in der Statistik **Merkmal**.

• DEFINITION

Merkmal: die Eigenschaft, die du untersuchen willst. Zum Beispiel: Alter, Geschlecht, Parteipräferenz.

Merkmalsausprägung: der konkrete Wert bei *einer* Einheit. Zum Beispiel: 23 Jahre, weiblich, SPD.

Für die Schreibweise gibt es eine feste Regel, die du dir jetzt merken solltest, weil sie in *allen* späteren Vorlesungen so benutzt wird:

- **Großbuchstaben** X, Y, Z stehen für das **Merkmal**.
- **Kleinbuchstaben** x, y, z stehen für die **Ausprägung**.
- $x_1, x_2, \dots, x_n$ sind die Werte der einzelnen Einheiten.
- n ist der **Stichprobenumfang**, also die Anzahl der Einheiten.

✓ BEISPIEL · FÜNF STUDIERENDE

Merkmal X = Alter in Jahren. Wir befragen $n = 5$ Personen:

Einheit	1	2	3	4	5
Wert	$x_1 = 21$	$x_2 = 24$	$x_3 = 19$	$x_4 = 27$	$x_5 = 22$

Hier ist X das Merkmal „Alter“, und $x_3 = 19$ ist die Ausprägung bei der dritten Person. Der Stichprobenumfang ist $n = 5$.

3 Diskret oder stetig?

Die erste Sortierung: Wie viele Werte sind möglich?

Jetzt sortieren wir Merkmale zum ersten Mal. Die Frage lautet: **Wie viele verschiedene Werte kann das Merkmal annehmen?**

• DEFINITION

Diskret: Das Merkmal hat **abzählbar** viele Werte. Du kannst die Werte aufzählen: 1, 2, 3, ... Zwischen zwei Werten liegt nichts.

Stetig: Das Merkmal hat **überabzählbar** viele Werte. Zwischen zwei Werten liegt immer noch ein weiterer Wert. Alle reellen Zahlen in einem Bereich sind möglich.

Typ	Beispiele	Warum?
diskret	Parteipräferenz (CDU, SPD, Grüne, ...)	Es gibt eine feste, endliche Liste.
diskret	Studienfach	Endlich viele Studiengänge.
diskret	Anzahl der Likes eines Beitrags	0, 1, 2, 3, ... — unendlich, aber <i>abzählbar</i> .
stetig	Körpergröße	1,80 m · 1,801 m · 1,8014 m — beliebig fein.
stetig	Jahresgewinn einer Firma	Jeder Betrag dazwischen ist denkbar.
stetig	Bruttoinlandsprodukt	Beliebig fein messbar.

▲ VORSICHT — HIER MACHEN VIELE EINEN FEHLER

In der Praxis ist die Grenze **nicht scharf**. Zwei Punkte musst du kennen:

1. Stetige Merkmale werden immer **ungenau gemessen**. Dein Alter steht im Ausweis in ganzen Jahren. Trotzdem behandeln wir Alter als stetig.
2. Stetige Merkmale kann man **in Gruppen einteilen**, zum Beispiel Altersklassen 0–18, 19–30, 31–50. Das heißt **Kategorisierung**. Danach verhält sich das Merkmal wie ein diskretes.

◆ SCHNELLTEST

Frage dich: „Kann ich zwischen zwei Werten noch einen dritten Wert finden?“

Ja → stetig. · Nein → diskret.

Zwischen 3 Likes und 4 Likes gibt es nichts → diskret. Zwischen 1,80 m und 1,81 m gibt es 1,805 m → stetig.

4

Die Skalenniveaus

Die wichtigste Einteilung des ganzen Tages

Jetzt kommt der Teil, den du wirklich sitzen haben musst. Merkmale unterscheiden sich nicht nur in der *Anzahl* der Werte, sondern auch in der **Qualität** der Werte. Diese Qualität heißt **Skalenniveau**.

Es gibt drei Stufen. Sie bauen aufeinander auf: Jede Stufe kann alles, was die Stufe darunter kann — und noch etwas mehr.

• STUFE 1 · NOMINALSKALA

Die Werte sind nur **Namen**. Sie haben **keine Reihenfolge**. Du kannst sie nicht sinnvoll als Zahlen lesen.

Erlaubt: zählen, wie oft jeder Wert vorkommt. Mehr nicht.

Beispiele: Parteipräferenz · Nationalität · Verwendungszweck eines Kredits · Geschlecht · Augenfarbe

Bei „Nationalität“ kannst du nicht sagen, dass Deutschland *größer* ist als Italien. Es sind einfach zwei verschiedene Namen. Auch wenn du sie im Computer als 1 und 2 speicherst — rechnen darfst du damit nicht.

• STUFE 2 · ORDINALSKALA

Die Werte haben eine **Reihenfolge**. Du kannst sie sortieren. **Aber:** Die Abstände zwischen den Werten bedeuten nichts.

Erlaubt: zählen *und* sortieren. Aber nicht subtrahieren.

Beispiele: Schulnoten · Kundenzufriedenheit (sehr gut / gut / schlecht) · Platz im Wettkampf

Denk an Schulnoten. Note 1 ist besser als Note 2 — die Reihenfolge stimmt. Aber ist der Unterschied zwischen 1 und 2 *genauso groß* wie zwischen 3 und 4? Das weiß niemand. Deshalb darfst du Noten nicht voneinander abziehen.

Noch klarer beim Wettkampf: Der Erste und der Zweite können 0,01 Sekunden trennen, der Zweite und der Dritte 5 Minuten. Der Abstand „1 Platz“ bedeutet jedes Mal etwas anderes.

• STUFE 3 · KARDINALSKALA

Die Werte sind **echte Zahlen**. Reihenfolge *und* Abstände sind sinnvoll. Meistens sind auch Verhältnisse sinnvoll.

Erlaubt: zählen, sortieren, subtrahieren, dividieren — alles.

Beispiele: Alter beim Studienabschluss · Körpergröße · Jahreseinkommen · Temperatur · Miete in Euro

Hier gilt: Der Unterschied zwischen 20 und 25 Jahren ist genau so groß wie zwischen 40 und 45 Jahren — nämlich 5 Jahre. Deshalb darfst du rechnen. Kardinalskalierte Merkmale nennt man auch **metrisch**.

Was darf ich bei welcher Skala?

Skala	Häufigkeiten zählen	Rangordnung sortieren	Differenzen / Quotienten rechnen
nominal	ja	nein	nein
ordinal	ja	ja	nein
kardinal	ja	ja	ja

◆ WARUM IST DAS SO WICHTIG?

Das Skalenniveau **entscheidet, welche Methode du benutzen darfst**. Ein Beispiel, das dir an Tag 3 wieder begegnet: Den **Mittelwert** darfst du nur bei kardinalen Merkmalen berechnen. Den **Median** schon ab ordinal. Wer den Mittelwert von Nationalitäten ausrechnet, hat nicht falsch gerechnet — er hat *sinnlos* gerechnet.

✓ ÜBUNG ZUM MITDENKEN

Bestimme das Skalenniveau. Decke die rechte Spalte zuerst ab.

Merkmal	Skala
Postleitzahl	nominal — sieht aus wie eine Zahl, ist aber ein Name
Schulnote	ordinal
Nettomiete in Euro	kardinal
Zufriedenheit (1 – 5 Sterne)	ordinal
Anzahl Kinder	kardinal (und diskret)
Trikotnummer	nominal

▲ DIE KLASSISCHE FALLE

Eine Zahl ist noch kein kardinales Merkmal. Postleitzahl 37073 und Trikotnummer 10 sind Zahlen — aber nur als Namen. 37073 ist nicht „mehr“ als 10000. Frage dich immer: *Ergibt die Differenz einen Sinn?*

5

Bevor die Daten da sind: die Versuchsplanung

Und das Problem der Störvariablen

Gute Daten entstehen nicht zufällig. Vor der Erhebung überlegt man vier Dinge:

1. Was ist das **Ziel** der Untersuchung?
2. Welche **statistischen Methoden** will ich später benutzen?
3. Wie werden die Daten **erhoben**?
4. Welche **Regeln** lege ich vorher verbindlich fest?

Punkt 4 ist wichtiger, als er aussieht. Wer erst die Daten anschaut und *dann* entscheidet, was er sucht, findet fast immer irgendetwas.

• DEFINITION

Störvariable: ein Merkmal, das die Ergebnisse beeinflusst, das dich aber eigentlich gar nicht interessiert.

✓ BEISPIEL · NEUE LEHRMETHODE

Du willst wissen: Verbessert eine neue Lehrmethode den Lernerfolg?

- **Interessiert dich:** die Lehrmethode und der Lernerfolg.
- **Stört dich:** Alter, Vorwissen, Lernverhalten, Motivation, Schlaf ...

Wenn in der Gruppe mit neuer Methode zufällig alle Studierenden mit viel Vorwissen sitzen, dann sieht die Methode gut aus — obwohl sie vielleicht nichts bringt. Genau das musst du verhindern.

Drei Wege, Störvariablen zu kontrollieren

Methode	Was man tut
Homogenisierung	Die Grundgesamtheit wird in Teilgruppen zerlegt, die bei der Störvariablen gleich sind. Zum Beispiel: nur Erstsemester untersuchen.
Randomisierung	Die Einheiten werden zufällig auf die Gruppen verteilt. Dann sind Vorwissen, Alter usw. in beiden Gruppen im Schnitt gleich verteilt.
Statistische Modellierung	Die Störvariable wird miterhoben und später im Modell ausdrücklich berücksichtigt (dazu mehr in späteren Vorlesungen).

◆ MERKE DIR DAS

Randomisierung ist der stärkste Weg. Sie schützt auch gegen Störvariablen, an die du gar nicht gedacht hast. Das ist der Grund, warum Medikamente in randomisierten Studien getestet werden.

6

Wie zieht man eine gute Stichprobe?

Vier Verfahren

Eine Stichprobe soll **repräsentativ** sein. Das heißt: Sie soll sich von der Grundgesamtheit **nicht systematisch unterscheiden**. Zufällige Unterschiede sind in Ordnung — systematische nicht.

▲ ZWEI TYPISCHE PROBLEME

1. In der Stichprobe sind Einheiten, die gar nicht zur Grundgesamtheit gehören (z. B. Nicht-Wahlberechtigte in einer Wahlumfrage).
2. Ein Teil der Grundgesamtheit hat **keine Chance**, in die Stichprobe zu kommen (z. B. Menschen ohne Telefon bei einer Telefonumfrage).

Verfahren 1 • Einfache Zufallsstichprobe

Du ziehst aus der Liste der Grundgesamtheit zufällig, **ohne Zurücklegen**. Dabei gilt:

- Jedes Element hat die **gleiche Chance**, gezogen zu werden.
- Jede mögliche Stichprobe hat die **gleiche Wahrscheinlichkeit**.
- Es gibt **keine systematischen** Unterschiede zur Grundgesamtheit — nur zufällige.

Das ist der Standard. Alle anderen Verfahren sind Varianten davon.

Verfahren 2 • Geschichtete Stichprobe

Du teilst die Grundgesamtheit vorher in **Schichten** ein und ziehst *in jeder Schicht* eine einfache Zufallsstichprobe.

- **Schichten sind zum Beispiel:** Geschlecht, Nationalität, Einkommensgruppen.
- **Vorteil:** Jede Gruppe ist sicher vertreten. Du kannst kleine Gruppen sogar absichtlich stärker einbeziehen.
- **Bedingung:** Du musst die Anteile der Gruppen vorher kennen.

Verfahren 3 • Klumpenstichprobe

Du bildest **Klumpen** (englisch: cluster) und ziehst zufällig ganze Klumpen. In den gezogenen Klumpen befragst du dann alle oder wieder eine Zufallsstichprobe.

- **Klumpen sind zum Beispiel:** Stadtteile, Schulklassen, Familien.
- **Vorteil:** viel einfacher und billiger. Du musst nicht durch das ganze Land fahren, sondern nur in fünf Schulen.
- **Bedingung:** *Innerhalb* eines Klumpens soll das Merkmal stark streuen, die Klumpen *untereinander* sollen sich ähneln.

▲ SCHICHTEN UND KLUMPEN NICHT VERWECHSELN

Das ist genau **umgekehrt** gedacht:

- **Schicht:** innen ähnlich, außen verschieden. Du ziehst aus *jeder* Schicht.
- **Klumpen:** innen verschieden, außen ähnlich. Du ziehst *einige* Klumpen komplett.

Verfahren 4 • Bewusste Auswahl (Quotenverfahren)

Hier wird **nicht** zufällig gezogen. Stattdessen gibt es feste Quoten, die erfüllt werden müssen — zum Beispiel „50 % Frauen, 30 % über 60 Jahre“. Der Interviewer sucht sich die Personen selbst.

◆ DER KREISLAUF DER DATENANALYSE

Die Vorlesung zeigt Statistik als Kreis, nicht als gerade Linie:

Planung → Datenerhebung → Aufbereitung und Prüfung → Datenanalyse → Interpretation →
Publikation von Daten und Code → Wiederverwendung → *wieder Planung*

Wichtig sind die letzten beiden Schritte: Daten **und** Code werden veröffentlicht, damit andere die Ergebnisse nachprüfen können.

7

Die R-Ecke

Deine ersten Datenobjekte

R ist ein Taschenrechner für Statistik. Heute lernst du nur, wie man Daten **hineinschreibt**. Rechnen kommt ab morgen.

Ein wichtiges Zeichen zuerst: `<-` heißt „speichere rechts in links“. Man spricht es „bekommt“.

► R · VEKTOREN

```
# Ein Vektor ist eine Reihe von Werten des gleichen Typs.  
# c() steht für "combine" = zusammenfügen.  
x <- c(1, 2, 3)  
print(x)  
#> [1] 1 2 3  
  
y <- c(1, 5, 9)  
  
# Text kommt in Anführungszeichen.  
z <- c("A", "B", "C")  
  
# Ein Vergleich liefert TRUE / FALSE.  
l <- x >= y  
l  
#> [1] TRUE FALSE FALSE
```

Jetzt kommt das Objekt, das direkt mit dem heutigen Thema zu tun hat: der **Faktor**.

► R · FAKTOR = NOMINALES ODER ORDINALES MERKMAL

```
# Ein Faktor speichert Kategorien, nicht Zahlen.  
# levels legt fest, welche Ausprägungen es überhaupt gibt.  
f <- factor(c("a", "b", "a", "a"), levels = c("a", "b"))  
f  
#> [1] a b a a  
#> Levels: a b
```

◆ DIE BRÜCKE ZWISCHEN THEORIE UND R

Statistik	R-Objekt
nominales Merkmal	<code>factor(...)</code>
ordinales Merkmal	<code>factor(..., ordered = TRUE)</code>
kardinales Merkmal	<code>numeric</code> (normale Zahlen)

► R · MATRIX, LISTE UND DATA FRAME

```
# Matrix: eine Tabelle aus lauter Zahlen.  
M1 <- matrix(1:6, nrow = 2) # füllt spaltenweise  
M2 <- matrix(1:6, nrow = 2, byrow = TRUE) # füllt zeilenweise  
  
# cbind() klebt Vektoren als Spalten zusammen.  
M3 <- cbind(x, y)  
  
# Liste: darf alles Mögliche gemischt enthalten.  
L <- list()  
L$x <- x  
L$M <- M1  
  
# Data Frame: DAS Objekt für echte Datensätze.  
# Jede Spalte = ein Merkmal, jede Zeile = eine statistische Einheit.  
d <- data.frame(x = x, z = z)  
d  
#>   x z  
#> 1 1 A  
#> 2 2 B  
#> 3 3 C
```

✓ DAS MUSST DU DIR MERKEN

Der **Data Frame** ist genau die Tabelle aus Schritt 1 und 2: **Zeile = statistische Einheit, Spalte = Merkmal, Zelle = Merkmalsausprägung.**

► R · TYP PRÜFEN UND GRÖSSE BESTIMMEN

```
typeof(x)      #> "double"      (Zahl)
typeof(z)      #> "character"  (Text)
typeof(l)      #> "logical"    (TRUE/FALSE)

is.numeric(x)  #> TRUE
is.factor(f)   #> TRUE
is.matrix(M1)  #> TRUE

length(x)      # Anzahl Werte in einem Vektor
#> [1] 3

dim(M1)        # Zeilen und Spalten (nur Matrix / Data Frame)
#> [1] 2 3
dim(x)         # bei einem Vektor gibt es keine Dimension
#> NULL
```

▲ EINE STOLPERFALLE MIT FAKTOREN

```
as.numeric(f)      #> [1] 1 2 1 1
as.numeric(f) - 1  #> [1] 0 1 0 0
```

R gibt dir hier die **Nummer des Levels**, nicht den Inhalt. Bei einem nominalen Merkmal sind diese Zahlen **bedeutungslos** — genau wie in Schritt 4 erklärt. Rechne nie damit weiter.

► R · EIN ECHTER DATENSATZ ZUM AUSPROBIEREN

```
library("datasets")
data(iris)

names(iris)      # Welche Merkmale gibt es?
#> "Sepal.Length" "Sepal.Width" "Petal.Length" "Petal.Width" "Species"

dim(iris)        # 150 Einheiten, 5 Merkmale
#> [1] 150 5

head(iris)       # die ersten sechs Zeilen anschauen
is.factor(iris$Species) #> TRUE -> nominales Merkmal
is.numeric(iris$Sepal.Length) #> TRUE -> kardinales Merkmal
```

✓ MACH DAS JETZT SELBST

Öffne R oder RStudio und tippe den Code oben ab — **nicht kopieren**, tippen. Verändere dann Zahlen und schau, was passiert. Fehlermeldungen sind normal und kein Problem.

■ WORTSCHATZ · LEICHT ERKLÄRT

Grundgesamtheit — alle, die dich interessieren

Stichprobe — die, die du wirklich gefragt hast

Merkmal — die Eigenschaft, die du misst

Merkmalsausprägung — der Wert bei einer Person oder Sache

Stichprobenumfang n — wie viele Einheiten du hast

diskret — man kann die Werte aufzählen

stetig — zwischen zwei Werten liegt immer noch ein Wert

Skalenniveau — wie „stark“ ein Merkmal ist: nominal, ordinal oder kardinal

nominal — nur Namen, keine Reihenfolge

ordinal — Reihenfolge ja, Abstände nein

kardinal / metrisch — echte Zahlen, alles erlaubt

Störvariable — stört das Ergebnis, interessiert dich aber nicht

repräsentativ — die Stichprobe passt zur Grundgesamtheit

Spickzettel Tag 1

Die drei Begriffe

Einheit = das Einzelne · Grundgesamtheit = alle · Stichprobe = der untersuchte Teil

Schreibweise

X = Merkmal, x_i = Wert der i -ten Einheit, n = Stichprobenumfang

Diskret

Abzählbar viele Werte. Zwischen zwei Werten liegt nichts.

Stetig

Überabzählbar viele Werte. Dazwischen liegt immer noch einer.

nominal

Nur Namen. Zählen erlaubt. Sortieren und Rechnen verboten.

ordinal

Reihenfolge ja. Abstände bedeuten nichts. Rechnen verboten.

kardinal (metrisch)

Echte Zahlen. Zählen, sortieren, subtrahieren, dividieren — alles erlaubt.

Skalen-Tabelle

nominal: zählen ✓ · sortieren ✗ · rechnen ✗ | ordinal: zählen ✓ · sortieren ✓ · rechnen ✗ | kardinal: zählen ✓ · sortieren ✓ · rechnen ✓

Störvariable kontrollieren

Homogenisierung · Randomisierung · statistische Modellierung

Stichprobenverfahren

einfache Zufallsstichprobe · geschichtet · Klumpen · Quoten

Schicht gegen Klumpen

Schicht: innen ähnlich, außen verschieden → aus *jeder* Schicht ziehen. Klumpen: innen verschieden, außen ähnlich → *einige* Klumpen ganz nehmen.

R

`c()` Vektor · `factor()` Kategorien · `data.frame()` Datensatz · `typeof()` Typ · `dim()` Größe · `length()` Anzahl

Teste dich selbst

11 Aufgaben · 20 Punkte · ohne Hilfsmittel · ca. 40 Minuten. Schreibe deine Antworten auf ein Blatt. Schau **nicht** nach vorne und **nicht** in die Lösungen.

A 1 Eine Universität will wissen, wie zufrieden ihre Studierenden mit der Mensa sind. Sie befragt dazu 200 zufällig ausgewählte Studierende. (2 Punkte)

Benenne: (a) die statistische Einheit, (b) die Grundgesamtheit, (c) die Stichprobe, (d) ein mögliches Merkmal.

A 2 Welche Aussage über die Grundgesamtheit ist richtig? (1 Punkt)

- ☐ A Die Grundgesamtheit muss immer als vollständige Liste vorliegen.
- ☐ B Die Grundgesamtheit darf auch nur gedacht (hypothetisch) sein.
- ☐ C Die Grundgesamtheit ist immer kleiner als die Stichprobe.
- ☐ D Grundgesamtheit und Stichprobe sind dasselbe.

A 3 Diskret oder stetig? Entscheide für jedes Merkmal. (2 Punkte)

a) Anzahl der Geschwister

b) Wartezeit an der Kasse in Minuten

c) Lieblingsfarbe

d) Gewicht eines Pakets in kg

e) Anzahl der Tore in einem Spiel

f) Temperatur in Grad Celsius

A 4 Bestimme das Skalenniveau: nominal, ordinal oder kardinal. (3 Punkte)

a) Blutgruppe (A, B, AB, 0)

b) Schulabschluss (Hauptschule, Realschule, Abitur)

c) Monatsmiete in Euro

d) Hausnummer

e) Platzierung beim Marathon

f) Anzahl der Vorlesungen pro Woche

A 5 Ein Merkmal ist ordinalskaliert. Was ist nicht erlaubt? (1 Punkt)

- ☐ A Zählen, wie oft jede Ausprägung vorkommt.
- ☐ B Die Ausprägungen der Größe nach sortieren.
- ☐ C Die Differenz zwischen zwei Ausprägungen berechnen.
- ☐ D Die häufigste Ausprägung bestimmen.

A 6 Richtig oder falsch? Begründe jeweils in einem Satz. (2 Punkte)

- ☐ a Jedes Merkmal, dessen Werte Zahlen sind, ist kardinalskaliert.
- ☐ b Ein kardinales Merkmal ist immer stetig.
- ☐ c Bei nominalen Merkmalen darf man Häufigkeiten zählen.
- ☐ d Ein stetiges Merkmal kann man in Klassen einteilen.

A 7 Erkläre in zwei bis drei Sätzen, warum das Skalenniveau in der Statistik so wichtig ist. Nenne dabei ein konkretes Beispiel. (2 Punkte)

A 8 Ein Sportverein testet ein neues Trainingsprogramm und misst danach die Laufzeit über 5 km. (2 Punkte)

(a) Nenne zwei mögliche Störvariablen. (b) Nenne ein Verfahren, mit dem man sie kontrollieren kann, und erkläre es in einem Satz.

A 9 Welches Stichprobenverfahren wird hier beschrieben? (2 Punkte)

- ☐ a Aus einer Liste aller 40 000 Studierenden werden per Zufallszahl 500 gezogen.
- ☐ b Es werden getrennt 250 Frauen und 250 Männer zufällig gezogen, weil man beide Gruppen sicher abbilden will.
- ☐ c Es werden 10 von 200 Schulklassen zufällig ausgewählt; in diesen 10 Klassen werden alle Schüler befragt.
- ☐ d Der Interviewer sucht sich Passanten so aus, dass am Ende 30 % über 60 Jahre alt sind.

A 10 Bei einer Klumpenstichprobe sollen die Klumpen ... (1 Punkt)

- A** ... innen möglichst ähnlich und untereinander möglichst verschieden sein.
- B** ... innen möglichst verschieden und untereinander möglichst ähnlich sein.
- C** ... alle gleich groß sein.
- D** ... vorher nach dem Zielmerkmal sortiert werden.

A 11 R-Aufgabe. (2 Punkte)

```
note <- factor(c("gut", "schlecht", "gut", "mittel"),
               levels = c("schlecht", "mittel", "gut"))

length(note)
as.numeric(note)
```

(a) Was geben die beiden letzten Zeilen aus? (b) Welches Skalenniveau hat das Merkmal „Note“ — und darf man mit dem Ergebnis von `as.numeric()` den Mittelwert bilden?

Lösungen

Vergleiche ehrlich. Schreibe jeden Fehler in dein Fehlerheft: *Was war die Frage? Warum war ich falsch?*

A 1 · 2 Punkte

- (a) **Statistische Einheit:** eine Studentin / ein Student der Universität.
- (b) **Grundgesamtheit:** alle Studierenden dieser Universität.
- (c) **Stichprobe:** die 200 befragten Studierenden.
- (d) **Merkmal:** z. B. „Zufriedenheit mit der Mensa“ (ordinal), „Anzahl der Mensabesuche pro Woche“ (kardinal), „Studienfach“ (nominal).

A 2 · 1 Punkt

Richtig ist **B**.

Die Grundgesamtheit darf hypothetisch sein — zum Beispiel „alle Felder, auf denen dieser Dünger je eingesetzt werden könnte“. A ist falsch, weil eine Liste oft gar nicht existiert. C und D widersprechen der Definition: Die Stichprobe ist ein *Teil* der Grundgesamtheit.

A 3 · 2 Punkte

a) **diskret** — 0, 1, 2, ... · b) **stetig** · c) **diskret** — endlich viele Farbnamen · d) **stetig** · e) **diskret** · f) **stetig**

Bei b), d) und f) gilt der Schnelltest: Zwischen 3 und 4 Minuten liegt 3,5 Minuten. Dass die Kasse nur ganze Minuten anzeigt, ändert daran nichts — das ist nur die Messgenauigkeit.

A 4 · 3 Punkte

- a) **nominal** — Blutgruppen haben keine Reihenfolge.
- b) **ordinal** — es gibt eine Reihenfolge, aber kein sinnvoller Abstand.
- c) **kardinal** — 600 € minus 500 € = 100 €, das ergibt Sinn.
- d) **nominal** — eine Zahl, aber nur als Name. Haus 12 ist nicht „doppelt“ Haus 6.
- e) **ordinal** — Platz 1 ist besser als Platz 2, aber die Abstände sind unterschiedlich groß.
- f) **kardinal** — und zusätzlich diskret.

A 5 · 1 Punkt

Nicht erlaubt ist **C**.

Bei ordinalen Merkmalen darfst du zählen (A, D) und sortieren (B). Differenzen sind verboten, weil die Abstände zwischen den Ausprägungen keine feste Bedeutung haben.

A 6 · 2 Punkte

- a) **falsch.** Postleitzahl und Hausnummer sind Zahlen, aber nominal. Entscheidend ist, ob die Differenz einen Sinn ergibt.
- b) **falsch.** „Anzahl der Kinder“ ist kardinal *und* diskret. Skalenniveau und diskret/stetig sind zwei **unabhängige** Einteilungen.
- c) **richtig.** Häufigkeiten zählen ist auf jedem Skalenniveau erlaubt — auch auf dem niedrigsten.
- d) **richtig.** Das ist die Kategorisierung, zum Beispiel Altersklassen. Danach verhält sich das Merkmal wie ein diskretes.

A 7 · 2 Punkte

Das Skalenniveau legt fest, **welche Rechnungen und welche statistischen Methoden überhaupt sinnvoll sind**. Wählt man eine Methode, die ein höheres Skalenniveau voraussetzt, bekommt man zwar ein Ergebnis — aber ein sinnloses.

Beispiel: Der Mittelwert braucht mindestens Kardinalskala. Bei den nominalen Ausprägungen „CDU = 1, SPD = 2, Grüne = 3“ kann man zwar 2,0 ausrechnen, aber „die durchschnittliche Partei ist SPD“ bedeutet nichts. Der Median dagegen ist schon ab ordinal erlaubt.

A 8 · 2 Punkte

- (a) **Störvariablen:** z. B. **Alter, Trainingszustand vor dem Programm**, Gewicht, Ernährung, Schlaf, Motivation, Wetter am Testtag.
- (b) **Ein Verfahren** — eines von drei genügt:
- **Randomisierung:** Die Sportler werden *zufällig* auf „neues Programm“ und „altes Programm“ verteilt. Dann sind Alter und Trainingszustand in beiden Gruppen im Schnitt gleich.
 - **Homogenisierung:** Man testet nur Sportler mit ähnlichem Alter und ähnlichem Trainingszustand.
 - **Statistische Modellierung:** Alter und Trainingszustand werden miterhoben und später im Modell berücksichtigt.

A 9 · 2 Punkte

- a) **einfache Zufallsstichprobe** — aus der vollständigen Liste wird rein zufällig gezogen.
- b) **geschichtete Stichprobe** — vorher werden Schichten (Geschlecht) gebildet, dann wird in jeder Schicht zufällig gezogen.
- c) **Klumpenstichprobe** — es werden ganze Klumpen (Klassen) gezogen und darin vollständig erhoben.
- d) **bewusste Auswahl / Quotenverfahren** — es wird nicht zufällig gezogen, sondern eine Quote erfüllt.

A 10 · 1 Punkt

Richtig ist **B**.

Ein Klumpen soll ein kleines Abbild der Grundgesamtheit sein: **innen verschieden** (das Merkmal streut stark) und **untereinander ähnlich** (egal, welchen Klumpen du erwischst). Antwort A beschreibt die *Schichtung* — dort ist es genau umgekehrt.

A 11 · 2 Punkte

(a) Ausgabe:

```
length(note)      #> [1] 4
as.numeric(note)  #> [1] 3 1 3 2
```

`length()` zählt die Werte: vier Beobachtungen. `as.numeric()` gibt die **Nummer des Levels** zurück. Die Levels stehen in der Reihenfolge `schlecht (1), mittel (2), gut (3)`, also wird „gut“ zu 3, „schlecht“ zu 1, „gut“ zu 3 und „mittel“ zu 2.

(b) Das Merkmal ist **ordinal**: schlecht < mittel < gut hat eine Reihenfolge, aber die Abstände bedeuten nichts. Deshalb darf man mit den Zahlen 1, 2, 3 **keinen Mittelwert bilden**. Erlaubt wären Häufigkeiten, der Modus und der Median.

Deine Auswertung

Punkte	Was das bedeutet
17 – 20	Sehr gut. Du kannst direkt mit Tag 2 weitermachen.
12 – 16	Gut. Lies die Schritte zu deinen Fehlern noch einmal (10 Minuten), dann weiter zu Tag 2.
8 – 11	Wiederhole heute Abend Schritt 4 (Skalenniveaus) und den Spickzettel. Mache Tag 2 trotzdem morgen.
0 – 7	Arbeite Schritt 1 bis 4 morgen früh noch einmal durch (45 Minuten) und mache den Test erneut. Dann Tag 2.

◆ MORGEN · TAG 2

Du hast heute gelernt, wie man Daten **benennt** und **sortiert**. Morgen lernst du, wie man sie **zählt** und **zeichnet**: absolute und relative Häufigkeiten, Klassen bilden und der Unterschied zwischen Säulendiagramm und Histogramm.