

TAG 02

Häufigkeiten und Histogramm

Gestern hast du gelernt, wie man Daten *benennt*. Heute lernst du, wie man sie *zählt* und *zeichnet*. Am Ende des Tages verstehst du den wichtigsten Unterschied der ganzen Vorlesung: Säulendiagramm gegen Histogramm.

ca. 3 Stunden

9 Schritte

11 Aufgaben · 24 Punkte

▶ R-Ecke

Das kannst du heute Abend

- ☐ Du berechnest **absolute** und **relative Häufigkeiten**.
- ☐ Du fasst stetige Daten in **Klassen** zusammen.
- ☐ Du kennst den Unterschied zwischen **Säulendiagramm** und **Histogramm**.
- ☐ Du berechnest die **Dichte** eines Histogramm-Rechtecks.
- ☐ Du liest aus einer **Fläche** im Histogramm einen **Anteil** ab.
- ☐ Du benennst die **Form** einer Verteilung: unimodal, bimodal, schief.
- ☐ Du zeichnest die **empirische Verteilungsfunktion** als Treppenfunktion.
- ☐ Du erzeugst in **R** Häufigkeitstabellen und Histogramme.

Grundlage: Vorlesung SDS1-V02 „Deskriptive Statistik zur Beschreibung von Merkmalen“ · R-Skript [02StatDS-HistogrammeMittelwertUndCo.R](#)

■ WAS DU VON GESTERN BRAUCHST

- X ist das **Merkmal**, $x_1, \dots, x_n$ sind die **Werte**, n ist der **Stichprobenumfang**.
- **Diskret** = abzählbar viele Werte. **Stetig** = dazwischen liegt immer noch ein Wert.
- Skalenniveaus: **nominal** (nur Namen) → **ordinal** (Reihenfolge) → **kardinal** (echte Zahlen).

Heute brauchst du besonders das Wort **Ausprägung**: Das ist ein möglicher Wert, den das Merkmal annehmen kann.

TEIL 1 · LERNEN

1 Häufigkeiten zählen

Absolut und relativ

Stell dir vor, du hast 20 Zahlen auf einem Blatt. So viele Zahlen kann kein Mensch überblicken. Also machst du das Einfachste, was es gibt: **Du zählst, wie oft jeder Wert vorkommt**. Das Ergebnis heißt **Häufigkeitsverteilung**.

• DIE SCHREIBWEISE

Gegeben sind die Beobachtungen $x_1, \dots, x_n$ zum Merkmal X . Die möglichen Ausprägungen nennen wir

$$a_1, a_2, \dots, a_J \quad \text{mit } J \leq n.$$

Bei mindestens ordinalen Merkmalen ordnen wir sie der Größe nach: $a_1 < a_2 < \dots < a_J$.

Achte auf den Unterschied: n ist die Anzahl der **Beobachtungen** (wie viele Personen du gefragt hast). J ist die Anzahl der **verschiedenen Werte**, die überhaupt vorkommen können.

• DEFINITION

Absolute Häufigkeit — wie oft kommt die Ausprägung a_j vor?

$$h(a_j) = h_j = \text{Anzahl der } x_i \text{ mit } x_i = a_j$$

Relative Häufigkeit — welcher *Anteil* ist das?

$$f(a_j) = f_j = \frac{h_j}{n}$$

Daraus ergeben sich zwei Verteilungen:

- Die Verteilung der absoluten Häufigkeiten: $h_1, \dots, h_J$
- Die Verteilung der relativen Häufigkeiten: $f_1, \dots, f_J$

◆ ZWEI KONTROLLEN, DIE IMMER GELTEN

$$\sum_{j=1}^J h_j = n \qquad \sum_{j=1}^J f_j = 1$$

Die absoluten Häufigkeiten ergeben zusammen den Stichprobenumfang. Die relativen Häufigkeiten ergeben zusammen immer **1** (also 100 %). Rechne das in jeder Aufgabe nach — so findest du Rechenfehler sofort.

✓ BEISPIEL 1 · ANZAHL DER GESCHWISTER

Du fragst $n = 20$ Studierende, wie viele Geschwister sie haben. Die Antworten sind:

1 · 0 · 2 · 1 · 1 · 3 · 0 · 1 · 2 · 0 · 4 · 1 · 1 · 2 · 0 · 3 · 1 · 2 · 0 · 1

Die möglichen Ausprägungen sind $a_1 = 0$, $a_2 = 1$, $a_3 = 2$, $a_4 = 3$, $a_5 = 4$. Also ist $J = 5$. Jetzt zählen wir:

a_j · Geschwister	h_j · absolut	Rechnung	f_j · relativ
0	5	5 / 20	0.25
1	8	8 / 20	0.40
2	4	4 / 20	0.20
3	2	2 / 20	0.10
4	1	1 / 20	0.05
Summe	20 = n	—	1.00

Beide Kontrollen stimmen: $\sum h_j = 20 = n$ und $\sum f_j = 1$. ✓

Lesen kannst du die Tabelle so: 40 % der Befragten haben genau ein Geschwisterkind. 25 % haben gar keines.

▲ WANN ABSOLUT, WANN RELATIV?

Mit **absoluten** Häufigkeiten siehst du, wie viele Fälle es wirklich sind. Mit **relativen** Häufigkeiten kannst du **Gruppen unterschiedlicher Größe vergleichen**. „In Kurs A haben 30 Personen bestanden, in Kurs B 60“ sagt nichts, solange du nicht weißt, wie groß die Kurse sind. „In A haben 60 % bestanden, in B 40 %“ sagt alles.

2 Klassen bilden

Was tun, wenn jeder Wert nur einmal vorkommt?

Bei **stetigen** Merkmalen funktioniert das Zählen aus Schritt 1 nicht mehr. Wenn du das Gewicht von 1 000 Personen misst, kommt fast jeder Wert genau **einmal** vor. Eine Tabelle mit 1 000 Zeilen, in denen überall „1“ steht, hilft niemandem.

Die Lösung: Du teilst den Zahlenbereich in **Klassen** (auch: Intervalle) ein und zählst, wie viele Werte in jede Klasse fallen.

• DEFINITION

Der Datenbereich wird in J Klassen zerlegt:

$$[c_0, c_1], (c_1, c_2], \dots, (c_{J-1}, c_J]$$

Die Zahlen $c_0, c_1, \dots, c_J$ heißen **Klassengrenzen**. Die **Klassenbreite** der j -ten Klasse ist $b_j = c_j - c_{j-1}$.

▲ DIE ECKIGE UND DIE RUNDE KLAMMER

Das ist keine Schönschrift, das ist wichtig:

- $(c_{j-1}, c_j]$ — links **offen**, rechts **geschlossen**. Die linke Grenze gehört *nicht* dazu, die rechte *schon*.
- Beispiel: Bei $(10, 20]$ gehört der Wert 20 in diese Klasse, der Wert 10 **nicht** — der gehört in die Klasse davor.
- Die **allererste** Klasse $[c_0, c_1]$ ist auf beiden Seiten geschlossen, damit der kleinste Wert nicht verloren geht.

So ist sichergestellt: **Jeder Wert gehört zu genau einer Klasse**. Kein Wert wird doppelt gezählt und keiner fällt heraus.

✓ BEISPIEL 2 · LERNZEIT PRO WOCHE

Du fragst $n = 20$ Studierende, wie viele Stunden sie pro Woche lernen. Du bildest vier Klassen. Sie sind **absichtlich unterschiedlich breit** — genau das brauchen wir gleich in Schritt 4.

Klasse (Stunden)	Breite b_j	h_j	f_j
[0, 5]	5	4	0.20
(5, 10]	5	8	0.40
(10, 20]	10	6	0.30
(20, 40]	20	2	0.10
Summe	—	20	1.00

Merke dir diese Tabelle. Wir benutzen sie in den nächsten drei Schritten immer wieder.

3

Das Säulendiagramm

Die Höhe zeigt die Häufigkeit

• DEFINITION

Beim **Säulendiagramm** wird über jeder Ausprägung ein Rechteck gezeichnet. Die **Höhe** H_j des Rechtecks ist proportional zur Häufigkeit:

$$H_1 \propto h_1, \dots, H_J \propto h_J \quad \text{oder} \quad H_1 \propto f_1, \dots, H_J \propto f_J$$

Das Zeichen $\propto$ heißt „proportional zu“. Es bedeutet einfach: Doppelte Häufigkeit → doppelt so hohes Rechteck.

◆ WOFÜR IST ES GUT?

Für **diskrete** Merkmale ist das Säulendiagramm perfekt. Bei „Anzahl Geschwister“ oder „Parteipräferenz“ hat jede Säule dieselbe Bedeutung, und die Höhe sagt direkt: so oft kommt das vor.

▲ DAS PROBLEM BEI STETIGEN DATEN

Bei stetigen Daten **hängt das Bild davon ab, wie breit du die Klassen wählst**. Nimmst du breitere Klassen, werden die Säulen automatisch höher — obwohl sich an den Daten nichts geändert hat. Das Säulendiagramm kann dich also **täuschen**. Genau deshalb gibt es das Histogramm.

4

Das Histogramm

Der wichtigste Schritt des Tages

Beim Histogramm ändern wir **eine einzige Sache** — aber die verändert alles:

• DEFINITION

Beim **Histogramm** ist nicht die Höhe, sondern die **Fläche** F_j des Rechtecks proportional zur relativen Häufigkeit:

$$F_1 \propto f_1, \dots, F_J \propto f_J$$

Das Histogramm ist also eine **flächenproportionale** Darstellung der Häufigkeitsverteilung.

Daraus folgt sofort die Formel für die Höhe. Denn für ein Rechteck gilt ja: Fläche = Breite · Höhe. Wenn die Fläche f_j sein soll, muss gelten:

◆ DIE FORMEL, DIE DU AUSWENDIG KÖNNEN MUSST

$$\text{Höhe} = \text{Dichte} = \frac{\text{relative Häufigkeit}}{\text{Breite der Klasse}} = \frac{f_j}{b_j}$$

Diese Höhe heißt **Dichte**. Das Wort kommt an Tag 10 noch einmal — dort wird es mathematisch sauber definiert. Für heute reicht dir ein Satz: **Flächen unter der Dichte sind relative Häufigkeiten**.


✓ BEISPIEL 2 · WEITERGERECHNET

Wir nehmen die Lernzeit- Tabelle aus Schritt 2 und rechnen die Dichte aus:

Klasse	b_j	f_j	Rechnung f_j/b_j	Dichte
[0, 5]	5	0.20	$0.20 / 5$	0.040
(5, 10]	5	0.40	$0.40 / 5$	0.080
(10, 20]	10	0.30	$0.30 / 10$	0.030
(20, 40]	20	0.10	$0.10 / 20$	0.005


Jetzt schau dir an, was passiert. Links siehst du das Säulendiagramm (Höhe = Häufigkeit), rechts das Histogramm (Fläche = Häufigkeit). Es sind **dieselben Daten**:

✗ Säulendiagramm · Höhe = h_j



Alle Säulen sind **gleich breit** — obwohl die Klassen 5, 5, 10 und 20 Stunden umfassen. Die dritte Säule wirkt größer als die erste.

✓ Histogramm · Fläche = f_j



Die x-Achse ist **maßstabsgetreu**. Breite Klassen sind breit und dafür flach. Jetzt stimmt das Bild: die Klasse 5–10 ist am dichtesten besetzt.

◆ DER KERNSATZ DES TAGES

Beim **Säulendiagramm** schaust du auf die **Höhe**.

Beim **Histogramm** schaust du auf die **Fläche**.

Deshalb ist das Histogramm bei stetigen Merkmalen der **Goldstandard**: Es zeigt die Verteilung richtig, egal wie du die Klassen wählst. Beim Säulendiagramm ändert sich das Bild mit jeder neuen Klasseneinteilung.

▲ KLEINE WARNUNG FÜR DIE KLAUSUR

In manchen Büchern findest du Histogramme, die auf *absoluten* Häufigkeiten beruhen. **In dieser Veranstaltung nicht.** Hier gilt immer: Histogramm = relative Häufigkeiten, Höhe = f_j/b_j .

5

Fläche = Anteil

Warum das Histogramm so mächtig ist

Aus der Definition „Fläche = relative Häufigkeit“ folgt etwas sehr Nützliches. Die relativen Häufigkeiten ergeben zusammen 1. Also gilt:

◆ GESAMTFLÄCHE

Die **gesamte Fläche** eines Histogramms ist immer **genau 1**.

Und wenn die ganze Fläche 1 ist, dann ist **jedes Stück der Fläche ein Anteil**. Du kannst aus dem Bild also direkt ablesen, wie viel Prozent der Daten in einem Bereich liegen.

✓ BEISPIEL · ANTEIL AUSRECHNEN

Wie viel Prozent der Studierenden lernen **höchstens 10 Stunden** pro Woche? Wir addieren die beiden ersten Flächen:

1 Klasse $[0, 5]$: Fläche = Breite · Höhe = $5 \cdot 0.040 = 0.20$

2 Klasse $(5, 10]$: Fläche = $5 \cdot 0.080 = 0.40$

3 Zusammen: $0.20 + 0.40 = 0.60$

Antwort: 60 % der Studierenden lernen höchstens 10 Stunden pro Woche. Das ist genau $f_1 + f_2$ — die Rechnung geht auf.

• DIE ALLGEMEINE SCHREIBWEISE

In der Vorlesung steht das Ganze mit einem Integral. Sei H_x die Höhe des Histogramms an der Stelle x . Dann ist der geschätzte Anteil der Beobachtungen zwischen a und b :

$$\text{Anteil}(a \leq X \leq b) = \int_a^b H_x dx$$

Lass dich vom Integralzeichen nicht erschrecken. Es bedeutet hier nichts anderes als: „**Miss die Fläche unter dem Histogramm zwischen a und b .**“ Solange die Rechtecke gerade sind, ist das einfaches Rechteck-Rechnen.

◆ WARUM DU DIR DAS JETZT SCHON MERKEN SOLLST

An **Tag 10** lernst du stetige Zufallsvariablen. Dort gilt exakt dasselbe: Fläche unter der Dichte = Wahrscheinlichkeit. Wenn du den Gedanken heute verstehst, ist Tag 10 halb geschafft.

6 Wie viele Klassen soll ich nehmen?

Der Bias - Variance - Trade - Off

Meistens nimmt man **gleich breite** (äquidistante) Klassen. Aber wie viele? Diese Entscheidung musst du bewusst treffen, denn beide Extreme sind schlecht.

Klassenzahl J	Was passiert	Problem
zu klein wenige, breite Klassen	Das Bild wird sehr glatt. Details verschwinden — zum Beispiel ein zweiter Gipfel, den es wirklich gibt.	zu viel Bias (Verzerrung)
zu groß viele, schmale Klassen	Das Bild wird sehr zackig. In jeder Klasse liegen nur noch ein bis zwei Werte, also schlägt jeder Zufall voll durch.	zu viel Varianz (Unruhe)

◆ BIAS-VARIANCE-TRADE-OFF



Du musst also einen **Mittelweg** finden: fein genug, um die echte Form zu sehen — grob genug, um den Zufall zu glätten. Dieses Grundproblem trifft dich in der Statistik immer wieder, zum Beispiel an **Tag 16** bei der Kerndichteschätzung.

7 Die Form der Verteilung benennen

Modalität und Schiefe


Wenn du ein Histogramm vor dir hast, sollst du in einem Satz sagen können, wie es aussieht. Dafür gibt es zwei Fragen.

Frage 1 · Wie viele Gipfel? (Modalität)




Achtung
Zwei Gipfel bedeuten meistens:
Hier sind
zwei Gruppen
vermischt.


Frage 2 · Hängt ein Ende länger? (Schiefe)



linksschief
= rechtssteil
langer Ausläufer
links



symmetrisch
beide Seiten gleich



rechtsschief
= linkssteil
langer Ausläufer
rechts

▲ DIE NAMEN SIND VERWIRREND — HIER IST DER TRICK

Die Schiefe ist nach dem **langen Ausläufer** benannt, nicht nach dem Gipfel.

- **Rechtsschief** = der lange Schwanz zeigt nach **rechts**. Der Gipfel sitzt links. Deshalb heißt es auch **linkssteil** (links geht es steil hoch).
- **Linksschief** = der lange Schwanz zeigt nach **links**. Der Gipfel sitzt rechts. Deshalb auch **rechtssteil**.

Eselsbrücke: „schief nach ...“ = wohin der *Schwanz* zeigt. „steil nach ...“ = wo die *Wand* ist.

✓ BEISPIEL AUS DEM ECHTEN LEBEN

Einkommen ist fast immer **rechtsschief**: Die meisten Menschen verdienen wenig bis mittel (Gipfel links), aber einige wenige verdienen sehr viel (langer Schwanz nach rechts).

Unser Lernzeit-Histogramm aus Schritt 4 ist ebenfalls **rechtsschief**: Gipfel bei 5–10 Stunden, danach ein langer, flacher Ausläufer bis 40 Stunden.

◆ WARUM DU DAS BRAUCHST

An **Tag 3** lernst du Mittelwert, Median und Modus. Bei schiefen Verteilungen liegen diese drei Werte **nicht** an derselben Stelle — und die Schiefe sagt dir, in welcher Reihenfolge sie stehen.

8

Die empirische Verteilungsfunktion

Dieselben Häufigkeiten — von unten aufaddiert

▲ KLAUSUR-HINWEIS

Diesen Schritt musst du besonders ernst nehmen. In der Probeklausur gab es **6 Punkte** allein dafür, diese Funktion von Hand zu **zeichnen**. Lesen reicht hier nicht — nimm Papier und zeichne mit.

Bis jetzt hast du gefragt: „Wie viele liegen *bei* diesem Wert?“ Jetzt fragst du: „Wie viele liegen **bei oder unter** diesem Wert?“ Du addierst die relativen Häufigkeiten also von links nach rechts auf.

• DEFINITION

Die **empirische Verteilungsfunktion** $F(x)$ gibt den Anteil der Beobachtungen an, die kleiner oder gleich x sind:

$$F(x) = \frac{\text{Anzahl der } x_i \leq x}{n} = \sum_{j: a_j \leq x} f_j$$

Man nennt sie auch **kumulierte relative Häufigkeit**. „Kumuliert“ heißt einfach „aufsummiert“.

◆ VIER EIGENSCHAFTEN, DIE IMMER GELTEN

1. F ist eine **Treppenfunktion** — sie steigt nicht schräg, sondern springt.
2. Sie springt genau bei jeder Ausprägung a_j , und zwar um f_j nach oben.
3. Sie startet links bei **0** und endet rechts bei **1**. Sie fällt nie.
4. An der Sprungstelle gilt der **obere** Wert (der Punkt a_j gehört dazu).

✓ BEISPIEL · ECHTE KLAUSURAUFGABE

Getrunkene Biermenge X in Litern bei $n = 10$ Gästen:

8.5 · 8.5 · 4.0 · 4.0 · 12.0 · 12.0 · 8.5 · 15.7 · 4.0 · 8.5

Schritt 1 — sortieren und zählen:


a_j	h_j	f_j	$F(a_j)$ · aufaddiert
4.0	3	0.3	0.3
8.5	4	0.4	0.3 + 0.4 = 0.7
12.0	2	0.2	0.7 + 0.2 = 0.9
15.7	1	0.1	0.9 + 0.1 = 1.0

Kontrolle: Die letzte Zahl muss **1** sein. Wenn nicht, hast du dich verzählt.

Schritt 2 — als Formel aufschreiben. So wird es in der Klausur erwartet:

$$F(x) = \begin{cases} 0 & x < 4 \\ 0.3 & 4 \leq x < 8.5 \\ 0.7 & 8.5 \leq x < 12 \\ 0.9 & 12 \leq x < 15.7 \\ 1 & x \geq 15.7 \end{cases}$$

Schritt 3 — zeichnen. So sieht die Treppe aus:



Voller Punkt = dieser Wert gehört zur Stufe. **Offener Kreis** = er gehört nicht mehr dazu. Genau diese zwei Symbole bringen in der Klausur die Punkte — wer sie weglässt, verliert sie.

◆ REZEPT FÜR DIE KLAUSUR · VIER HANDGRIFFE

- 1 Werte **sortieren** und h_j zählen.
- 2 $f_j = h_j/n$ ausrechnen und von oben nach unten **aufaddieren**.
- 3 Achsen zeichnen: y geht immer von **0 bis 1**, x deckt alle Werte ab.
- 4 Stufen waagerecht ziehen, an jeder Ausprägung springen — **voller Punkt oben, offener Kreis unten**.

✓ WIE MAN $F(x)$ ABLEIST

Frage: Welcher Anteil der Gäste trank höchstens 10 Liter?

Antwort: $F(10) = 0.7$, also 70 %. Man geht bei 10 nach oben und liest die Stufe ab, auf der man landet.

Frage: Welcher Anteil trank *mehr* als 12 Liter?

Antwort: $1 - F(12) = 1 - 0.9 = 0.1$, also 10 %.

▲ DIE ZWEI HÄUFIGSTEN FEHLER

- **Punkte verbinden statt Stufen zeichnen.** F ist eine Treppe, keine schräge Linie. Zwischen zwei Ausprägungen passiert nichts.
- **Bei der Sprungstelle die falsche Stufe nehmen.** $F(8.5) = 0.7$, nicht 0.3 — der Wert 8.5 zählt mit, weil „ $\leq$ “ gilt.

9

Die R-Ecke

Zählen und zeichnen lassen

Wir benutzen einen kleinen Datensatz: Zimmergrößen in Quadratmetern.

► R · DATEN ANLEGEN

```
x <- c(22, 12, 8, 20, 35, 20, 18, 60, 15, 20, 18, 13,  
      20, 74, 15, 24, 18, 18, 16, 22, 13, 19, 80, 27)
```

```
length(x)           # Stichprobenumfang n  
#> [1] 24
```

Klassen bilden mit `cut()`

► R · CUT()

```
# breaks = die Klassengrenzen c_0, c_1, ..., c_J  
# Standard: rechts geschlossen (c_{j-1}, c_j]  
k1 <- cut(x, breaks = c(0, 10, 20, 100), include.lowest = TRUE)  
  
# right = FALSE dreht es um: [c_{j-1}, c_j)  
k2 <- cut(x, breaks = c(0, 10, 20, 100), right = FALSE)  
  
# Eigene Namen für die Klassen  
k3 <- cut(x, breaks = c(0, 10, 20, 100), include.lowest = TRUE,  
          labels = c("klein", "mittel", "groß"))  
k3  
#> [1] groß mittel klein mittel groß ...  
#> Levels: klein mittel groß
```

✓ ACHTE DARAUF

`cut()` macht aus Zahlen einen **Faktor** — genau das Objekt von gestern. Du hast also gerade ein stetiges Merkmal **kategorisiert**. Das ist die Klassenbildung aus Schritt 2, nur in R.

Häufigkeiten zählen mit `table()`

► R · ABSOLUTE UND RELATIVE HÄUFIGKEITEN

```
# absolute Häufigkeiten h_j
table(k3)
#> klein mittel groß
#>      1      15      8

# relative Häufigkeiten f_j = h_j / n
table(k3) / sum(table(k3))
#>      klein      mittel      groß
#> 0.04166667 0.62500000 0.33333333

# Kontrolle: ergibt die Summe wirklich 1?
sum(table(k3) / sum(table(k3)))
#> [1] 1
```

Das Histogramm zeichnen

► R · HIST()

```
h <- hist(x,
  breaks = c(0, 10, 20, 100),
  right = FALSE,
  main = "Ein Histogramm von Wohnraum",
  xlab = "Wohnraum in qm",
  ylab = "Dichte")

# hist() gibt die Rechenergebnisse zurück:
h$counts      # die absoluten Häufigkeiten h_j
h$density      # die DICHTEN, also f_j / b_j
h$breaks      # die Klassengrenzen
```

◆ DER WICHTIGSTE R-BEFEHL VON HEUTE

`h$density` ist genau die Größe aus Schritt 4: **relative Häufigkeit geteilt durch Klassenbreite**. Rechne einmal von Hand nach, dass R dasselbe herausbekommt wie du. Dann hast du es verstanden.

Wichtig: Wenn du `breaks` mit **ungleichen** Klassen angibst, zeichnet R automatisch die Dichte. Gibst du gleich breite Klassen an, zeichnet R standardmäßig die absoluten Häufigkeiten — mit `freq = FALSE` erzwingst du die Dichte.

► R · SÄULENDIAGRAMM FÜR DISKRETE MERKMALE

```
# Für diskrete Merkmale nimmt man barplot(), nicht hist().
geschwister <- c(1,0,2,1,1,3,0,1,2,0,4,1,1,2,0,3,1,2,0,1)

table(geschwister)
#> geschwister
#> 0 1 2 3 4
#> 5 8 4 2 1

barplot(table(geschwister),
        main = "Anzahl Geschwister",
        xlab = "Geschwister",
        ylab = "absolute Häufigkeit")
```

Die empirische Verteilungsfunktion in R

► R · ECDF()

```
bier <- c(8.5, 8.5, 4.0, 4.0, 12.0, 12.0, 8.5, 15.7, 4.0, 8.5)

F <- ecdf(bier)      # erzeugt die Funktion F(x)

F(10)                # Anteil der Werte kleiner/gleich 10
#> [1] 0.7

plot(F,
     main = "Empirische Verteilungsfunktion",
     xlab = "Biermenge in Litern",
     ylab = "F(x)")
```

✓ MACH DAS JETZT SELBST

1. Tippe den Code ab und lasse ihn laufen.
2. Vergleiche den Plot von `ecdf()` mit deiner eigenen Zeichnung aus Schritt 8. Stimmen die Stufenhöhen?
3. Vergleiche `h$density` mit deiner eigenen Rechnung.
4. Ändere `breaks` auf `c(0, 20, 40, 100)` und schau, wie sich das Bild verändert — und wie es *nicht* kippt, weil die Fläche stimmt.

■ WORTSCHATZ · LEICHT ERKLÄRT

Häufigkeitsverteilung — die Übersicht, wie oft jeder Wert vorkommt

absolute Häufigkeit h_j — die Anzahl

relative Häufigkeit f_j — der Anteil, also Anzahl geteilt durch n

Ausprägung a_j — ein möglicher Wert des Merkmals

Klasse / Intervall — eine Gruppe von Werten, z. B. 10 bis 20

Klassengrenze c_j — wo eine Klasse anfängt oder aufhört

Klassenbreite b_j — obere Grenze minus untere Grenze

äquidistant — alle Klassen sind gleich breit

Säulendiagramm — Höhe zeigt die Häufigkeit

Histogramm — Fläche zeigt die Häufigkeit

Dichte — die Höhe im Histogramm: f_j/b_j

unimodal — ein Gipfel · **bimodal** — zwei Gipfel

rechtsschief (linkssteil) — langer Ausläufer nach rechts

kumuliert — aufsummiert, von links nach rechts addiert

empirische Verteilungsfunktion $F(x)$ — Anteil der Werte, die $\leq x$ sind

Treppenfunktion — eine Funktion, die springt statt schräg zu steigen

linksschief (rechtssteil) — langer Ausläufer nach links

Spickzettel Tag 2

Absolute Häufigkeit

h_j = wie oft a_j vorkommt

Relative Häufigkeit

$$f_j = \frac{h_j}{n}$$

Kontrollen

$\sum_j h_j = n$ und $\sum_j f_j = 1$ — immer nachrechnen!

Klassenbreite

$$b_j = c_j - c_{j-1}$$

Klammern

$(c_{j-1}, c_j]$: links offen, rechts zu. Nur die erste Klasse ist links zu.

Säulendiagramm

Höhe $\propto$ Häufigkeit. Gut für

diskrete

Merkmale.

Histogramm

Fläche $\propto$ relative Häufigkeit. Gut für

stetige

Merkmale.

Die Formel des Tages

Dichte = Höhe = $\frac{f_j}{b_j}$ · Umgekehrt: Fläche = $b_j \cdot$ Höhe = f_j

Gesamtfläche

Die Fläche des ganzen Histogramms ist immer

1

. Jede Teilfläche ist ein Anteil.

Klassenzahl

Zu wenige $\rightarrow$ zu glatt (Bias). Zu viele $\rightarrow$ zu zackig (Varianz).

Form

unimodal / bimodal · rechtsschief = Schwanz rechts · linksschief = Schwanz links

Empirische Verteilungsfunktion

$F(x) = \frac{\text{Anzahl der } x_i \leq x}{n}$ — Treppe von 0 bis 1, Sprunghöhe = f_j , voller Punkt oben, offener Kreis unten. Mehr als x : $1 - F(x)$.

R

`cut()` Klassen · `table()` zählen · `table()/sum(table())` relativ · `hist()` Histogramm · `h$density` Dichten · `barplot()` Säulen · `ecdf()` Verteilungsfunktion

Teste dich selbst

11 Aufgaben · 24 Punkte · Taschenrechner erlaubt · ca. 50 Minuten. Schreibe alles auf ein Blatt und schau **nicht** in die Lösungen, bevor du fertig bist.

Übe ab heute die Klausurregeln mit: Dezimal**punkt** statt Komma (also 0.075, nicht 0,075) · Zwischenergebnisse auf **vier** Nachkommastellen · Endergebnisse auf **drei** · kein Bleistift.

A 1 In einem Kurs mit $n = 25$ Studierenden wurden die Noten erfasst: (3 Punkte)

2 · 3 · 1 · 2 · 4 · 2 · 3 · 3 · 1 · 2 · 5 · 3 · 2 · 2 · 4 · 3 · 1 · 2 · 3 · 3 · 4 · 2 · 1
· 3 · 2

Erstelle die Häufigkeitstabelle mit a_j , h_j und f_j . Prüfe beide Kontrollsummen.

A 2 Was gilt für die relativen Häufigkeiten? (1 Punkt)

- ☐ A Sie ergeben zusammen n .
- ☐ B Sie ergeben zusammen 1.
- ☐ C Sie sind immer größer als die absoluten Häufigkeiten.
- ☐ D Sie ergeben zusammen J .

A 3 Ein Datensatz mit $n = 200$ Wohnungen wurde in Klassen eingeteilt. Berechne die fehlenden Werte. (3 Punkte)

Klasse (qm)	b_j	h_j	f_j	Dichte
[0, 40]	?	60	?	?
(40, 60]	?	80	?	?
(60, 120]	?	60	?	?

A 4 Erkläre in eigenen Worten den Unterschied zwischen Säulendiagramm und Histogramm. Nenne für jedes einen passenden Einsatzfall. (2 Punkte)


A 5 Benutze deine Tabelle aus A 3. (2 Punkte)

- (a) Welcher Anteil der Wohnungen ist höchstens 60 qm groß?
- (b) Welche der drei Klassen ist am *dichtesten* besetzt? Begründe kurz, warum das nicht die Klasse mit der größten Breite ist.


A 6 Richtig oder falsch? (2 Punkte)

- ☐ a Die Gesamtfläche eines Histogramms ist immer 1.
- ☐ b Beim Histogramm ist die Höhe eines Rechtecks gleich der relativen Häufigkeit.
- ☐ c Wenn alle Klassen gleich breit sind, sehen Säulendiagramm und Histogramm gleich aus (bis auf die Beschriftung der y-Achse).
- ☐ d Je mehr Klassen man wählt, desto besser ist das Histogramm.


A 7 Benenne die Form jeder Verteilung (Modalität *und* Schiefe). (2 Punkte)



a)



b)



c)

A 8 Eine Zeitung zeigt ein Diagramm mit den Klassen „0–20 Jahre“, „21–40 Jahre“ und „41–100 Jahre“. Alle drei Balken sind gleich breit gezeichnet, die Höhe ist die absolute Häufigkeit. (2 Punkte)

Warum ist diese Darstellung irreführend? Wie müsste man es richtig machen?

A 9 Ein Histogramm hat eine Klasse der Breite 4 mit der Dichte 0.05. Welchen Anteil der Daten enthält diese Klasse? (1 Punkt)

- A** 0.05 (5 %)
- B** 0.20 (20 %)
- C** 4.00
- D** 0.0125 (1.25 %)

A 10 R-Aufgabe. (2 Punkte)

```
x <- c(5, 12, 18, 25, 33, 47, 8, 14, 22, 60)

k <- cut(x, breaks = c(0, 10, 20, 60), include.lowest = TRUE)
table(k)
```

- (a) Welche Ausgabe erzeugt `table(k)` ?
- (b) Der Datensatz enthält den Wert 22. Angenommen, er wäre stattdessen genau **20** — in welche Klasse fiel er dann, und warum?

A 11 In einem Café wurde bei $n = 8$ Gästen die Anzahl bestellter Tassen Kaffee erfasst. (4 Punkte)

2 · 1 · 3 · 2 · 1 · 2 · 4 · 1

- (a) Stellen Sie die empirische Verteilungsfunktion $F(x)$ abschnittsweise auf. (2P)
- (b) Zeichnen Sie $F(x)$. Achten Sie auf die korrekte Kennzeichnung der Sprungstellen. (1P)
- (c) Bestimmen Sie den Anteil der Gäste, die *mehr* als 2 Tassen bestellt haben. (1P)

Lösungen

Vergleiche ehrlich. Jeden Fehler ins Fehlerheft: *Was war die Frage? Warum war ich falsch?*

A 1 • 3 Punkte

Wir zählen: Note 1 kommt 4-mal vor, Note 2 kommt 9-mal vor, usw.

a_j	h_j	$f_j = h_j/25$
1	4	0.16
2	9	0.36
3	8	0.32
4	3	0.12
5	1	0.04
Summe	25	1.00

Kontrollen: $\sum h_j = 4 + 9 + 8 + 3 + 1 = 25 = n$ ✓ und $\sum f_j = 1.00$ ✓

Hinweis: Hier ist $J = 5$ (fünf verschiedene Noten) und $n = 25$ (25 Studierende). Verwechsle die beiden nicht.

A 2 • 1 Punkt

Richtig ist **B**.

Denn $\sum_j f_j = \sum_j \frac{h_j}{n} = \frac{1}{n} \sum_j h_j = \frac{n}{n} = 1$. Antwort A beschreibt die *absoluten* Häufigkeiten. C ist falsch: relative Häufigkeiten liegen immer zwischen 0 und 1.

A 3 • 3 Punkte

Zuerst $n = 60 + 80 + 60 = 200$. Dann b_j , dann $f_j = h_j/200$, dann Dichte = f_j/b_j :

Klasse	b_j	h_j	f_j	Dichte
[0, 40]	40	60	0.30	0.0075
(40, 60]	20	80	0.40	0.0200
(60, 120]	60	60	0.30	0.0050

Rechenweg der letzten Spalte: $0.30/40 = 0.0075$ · $0.40/20 = 0.0200$ · $0.30/60 = 0.0050$.

Probe: Fläche = $40 \cdot 0.0075 + 20 \cdot 0.02 + 60 \cdot 0.005 = 0.30 + 0.40 + 0.30 = 1$ ✓

A 4 · 2 Punkte

Säulendiagramm: die **Höhe** der Rechtecke ist proportional zur Häufigkeit. Gut für **diskrete** Merkmale, zum Beispiel Parteipräferenz oder Anzahl der Geschwister.

Histogramm: die **Fläche** der Rechtecke ist proportional zur relativen Häufigkeit; die Höhe ist die Dichte f_j/b_j . Gut für **stetige** Merkmale, zum Beispiel Miete, Körpergröße, Wohnfläche.

Der entscheidende Vorteil: Beim Histogramm hängt das Bild **kaum** von der gewählten Klassenbreite ab, beim Säulendiagramm sehr stark.

A 5 · 2 Punkte

(a) Höchstens 60 qm heißt: Klasse 1 plus Klasse 2, also $0.30 + 0.40 = 0.70$, also **70 %**.

(b) Am dichtesten ist die Klasse **(40, 60]** mit der Dichte 0.0200. Sie ist mit 20 qm die *schmalste* Klasse, enthält aber die *meisten* Wohnungen (80). Die Klasse (60, 120] ist zwar dreimal so breit, verteilt ihre 60 Wohnungen aber über einen viel größeren Bereich — deshalb ist sie flach. **Breite Klassen sind im Histogramm nicht „groß“, sondern flach.**

A 6 · 2 Punkte

a) **richtig.** Die Flächen sind die relativen Häufigkeiten, und die ergeben zusammen 1.

b) **falsch.** Die **Fläche** ist die relative Häufigkeit. Die Höhe ist die **Dichte** f_j/b_j . Nur wenn eine Klasse zufällig die Breite 1 hat, sind Höhe und relative Häufigkeit gleich.

c) **richtig.** Bei gleichen Breiten wird jede Höhe durch dieselbe Zahl geteilt. Die Form bleibt identisch, nur die Zahlen an der y-Achse ändern sich.

d) **falsch.** Das ist der **Bias - Variance - Trade - Off**: Zu viele Klassen machen das Histogramm zackig und zufällig, weil in jeder Klasse nur noch sehr wenige Beobachtungen liegen.

A 7 · 2 Punkte

a) **unimodal und rechtsschief** (= linkssteil). Der Gipfel liegt links, der lange Ausläufer zeigt nach rechts.

b) **bimodal** — zwei Gipfel, ungefähr symmetrisch. Das deutet meist auf zwei vermischte Gruppen hin.

c) **unimodal und linksschief** (= rechtssteil). Der Gipfel liegt rechts, der lange Ausläufer zeigt nach links.

A 8 · 2 Punkte

Warum irreführend: Die Klassen sind **unterschiedlich breit** (20, 20 und 60 Jahre), werden aber gleich breit gezeichnet. Die dritte Klasse deckt einen dreimal so großen Bereich ab. Ihre Häufigkeit wirkt dadurch viel zu groß — der Balken suggeriert eine Konzentration, die es gar nicht gibt.

Richtig wäre: ein **Histogramm**. Die x-Achse wird maßstabsgetreu gezeichnet (die dritte Klasse ist dreimal so breit), und als Höhe nimmt man die Dichte f_j/b_j . Dann entspricht die Fläche dem Anteil, und der breite Balken wird entsprechend flach.

A 9 · 1 Punkt

Richtig ist **B**.

Fläche = Breite · Höhe = $4 \cdot 0.05 = 0.20$. Die Klasse enthält also 20 % der Daten. Antwort A verwechselt Dichte mit Anteil — das ist der häufigste Fehler bei dieser Aufgabenart.

A 10 · 2 Punkte

(a) Ausgabe:

```
k
[0,10] [10,20] [20,60]
      2      3      5
```

Die Werte sind: 5 und 8 → erste Klasse (2 Werte). 12, 14 und 18 → zweite Klasse (3 Werte). 22, 25, 33, 47 und 60 → dritte Klasse (5 Werte). Zusammen $10 = n$. ✓

(b) Ein Wert von genau 20 fiel in die Klasse **(10, 20]**. R schneidet standardmäßig **rechts geschlossen** (`right = TRUE`): Die obere Grenze gehört zur Klasse, die untere nicht. Mit `right = FALSE` wäre 20 dagegen in der Klasse `[20, 60)` gelandet.

`include.lowest = TRUE` sorgt dafür, dass die unterste Grenze 0 mitgenommen wird — sonst würde ein Wert von genau 0 als `NA` herausfallen.

A 11 · 4 Punkte

(a) Sortieren und aufaddieren, $n = 8$:

a_j	h_j	f_j	$F(a_j)$
1	3	0.375	0.375
2	3	0.375	0.750
3	1	0.125	0.875
4	1	0.125	1.000

$$F(x) = \begin{cases} 0 & x < 1 \\ 0.375 & 1 \leq x < 2 \\ 0.750 & 2 \leq x < 3 \\ 0.875 & 3 \leq x < 4 \\ 1 & x \geq 4 \end{cases}$$

(b) Treppenfunktion mit Sprüngen bei 1, 2, 3 und 4. Sprunghöhen der Reihe nach 0.375, 0.375, 0.125, 0.125. An jeder Sprungstelle **voller Punkt oben, offener Kreis unten**. Die y-Achse läuft von 0 bis 1.

(c) Mehr als 2 Tassen heißt $1 - F(2)$: $1 - 0.750 = 0.250$, also 25 %.

Häufiger Fehler: $1 - F(3)$ rechnen. Gefragt ist „mehr als 2“, also alles *oberhalb* der Stufe bei 2 — und die Stufe bei 2 schließt die Zwei mit ein.

Deine Auswertung

Punkte	Was das bedeutet
20 – 24	Sehr gut. Du hast Histogramm und Verteilungsfunktion sitzen — der schwerste Teil von V02 ist geschafft.
15 – 19	Gut. Rechne A 3, A 5 und A 11 noch einmal komplett durch, dann weiter zu Tag 3.
10 – 14	Wiederhole heute Abend Schritt 4, 5 und 8 (Dichte, Fläche, Treppenfunktion). Das ist die Grundlage für Tag 10.
0 – 9	Arbeite Schritt 1 bis 5 und Schritt 8 morgen früh noch einmal durch (45 Minuten) und mache den Test erneut. Dann Tag 3.

◆ MORGEN · TAG 3

Heute hast du die **ganze** Verteilung angeschaut. Morgen drücken wir sie auf **eine einzige Zahl** zusammen: das arithmetische Mittel, den Median und den Modus. Du lernst auch, warum bei schiefen Verteilungen — wie der von heute — Mittelwert und Median **auseinanderfallen**.