

TAG 03

Lagemaße

Gestern hast du die *ganze* Verteilung beschrieben — mit Tabelle, Histogramm und Treppenfunktion. Heute drückst du sie auf **eine einzige Zahl** zusammen. Das klingt nach weniger Arbeit, ist aber gefährlicher: Es gibt drei solche Zahlen, und wer die falsche wählt, rechnet Unsinn.

ca. 3 Stunden

10 Schritte

10 Aufgaben · 24 Punkte

► R-Ecke · TR erklär mal!

Das kannst du heute Abend

- ☐ Du berechnest **arithmetisches Mittel, Median** und **Modus**.
- ☐ Du weißt, welches Lagemaß bei welchem **Skalenniveau** erlaubt ist.
- ☐ Du erkennst, wann ein **Ausreißer** den Mittelwert unbrauchbar macht.
- ☐ Du berechnest den Mittelwert für **klassierte Daten**.
- ☐ Du berechnest den Mittelwert aus **Schichten**.
- ☐ Du liest die **Schiefte** aus der Reihenfolge der drei Lagemaße ab.
- ☐ Du weißt, was bei einer **Transformation** $y = a + bx$ passiert.

Grundlage: Vorlesung SDS1-V02 · R-Skript [02StatDS-HistogrammeMittelwertUndCo.R](#) · Testat 1, Aufgaben 3 – 5 · Probeklausur Teil A, Aufgaben 1 und 2

■ WAS DU VON GESTERN BRAUCHST

- a_j sind die **Ausprägungen**, h_j die **absoluten**, $f_j = h_j/n$ die **relativen Häufigkeiten**.
- Kontrollen: $\sum_j h_j = n$ und $\sum_j f_j = 1$.
- Bei stetigen Daten bildest du **Klassen** mit Grenzen c_j und Breiten b_j .
- **Rechtsschief** = langer Ausläufer nach rechts. **Linksschief** = nach links.

Von Tag 1 brauchst du die **Skalenniveaus**: nominal → ordinal → kardinal. Heute entscheidet genau das, welches Lagemaß du benutzen darfst.

TEIL 1 · LERNEN

1

Was ist ein Lagemaß?

Eine Zahl für die ganze Verteilung

Ein **Lagemaß** beschreibt das **Zentrum** der Daten — die Stelle, um die herum sich die Beobachtungen sammeln. Auf Deutsch sagt man auch *zentrale Tendenz*.

• DIE DREI LAGEMASSE

Name	Zeichen	Was es sagt
Arithmetisches Mittel	$\bar{x}$	der Durchschnitt — alle Werte zusammen, geteilt durch n
Median	x_{med}	der Wert in der <i>Mitte</i> , wenn man sortiert
Modus	x_{mod}	der Wert, der am <i>häufigsten</i> vorkommt

◆ WARUM DREI?

Weil sie unterschiedlich **reagieren**. Bei symmetrischen Daten sind sie fast gleich. Bei schiefen Daten oder bei einem einzigen extremen Wert laufen sie weit auseinander — und dann musst du wissen, welche Zahl du berichtest. Genau das lernst du in Schritt 5.

• DEFINITION

Aus den Rohdaten:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Aus einer Häufigkeitstabelle:

$$\bar{x} = \sum_{j=1}^J a_j f_j$$

▲ DIE ZWEITE FORMEL WIRD OFT ÜBERSEHEN

Wenn dir eine **Häufigkeitstabelle** gegeben ist (nicht die Rohdaten), wäre es Zeitverschwendung, alle Werte einzeln aufzuschreiben. Multipliziere jede Ausprägung mit ihrer relativen Häufigkeit und addiere. Gleichwertig und oft bequemer:

$$\bar{x} = \frac{1}{n} \sum_{j=1}^J a_j h_j$$

In der Klausur kommt genau diese Situation vor: Du bekommst eine Tabelle mit a_j und h_j und sollst $\bar{x}$ bestimmen.

✓ BEISPIEL · AUS TESTAT 1

Merkmal X = Anzahl der Mensabesuche in der vergangenen Woche:

a_j	1	3	4	5	10	Summe
h_j	1	2	5	3	1	12

1 **Stichprobenumfang:** $n = \sum h_j = 1 + 2 + 5 + 3 + 1 = 12$

2 **Zähler:** $\sum a_j h_j = 1 \cdot 1 + 3 \cdot 2 + 4 \cdot 5 + 5 \cdot 3 + 10 \cdot 1 = 1 + 6 + 20 + 15 + 10 = 52$

3 **Mittel:** $\bar{x} = \frac{52}{12} = 4.3333$

Auf drei Nachkommastellen gerundet: $\bar{x} = 4.333$ Mensabesuche.

◆ DIE EIGENSCHAFT, DIE DU SCHON KENNST

$$\sum_{i=1}^n (x_i - \bar{x}) = 0$$

Die Abweichungen nach links und nach rechts heben sich **exakt** auf. Das ist die Rechnung aus Tag 0, Schritt 2 — und es ist der Grund, warum man beim Streuungsmaß morgen **quadrieren** muss: Ohne Quadrat käme immer null heraus.

3

Der Median

Der Wert in der Mitte

Der Median teilt die sortierten Beobachtungen in zwei gleich große Hälften: **mindestens 50 %** liegen links davon, **mindestens 50 %** rechts.

• DEFINITION

Mit den **geordneten** Beobachtungen $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$:

$$x_{med} = \begin{cases} x_{(\frac{n+1}{2})} & n \text{ ungerade} \\ \in [x_{(\frac{n}{2})}, x_{(\frac{n}{2}+1)}] & n \text{ gerade} \end{cases}$$

Die Klammern $x_{(i)}$ bedeuten: **der i -te Wert nach dem Sortieren** — nicht die i -te Person!

▲ BEI GERADEM N IST DER MEDIAN NICHT EINDEUTIG

Die Definition sagt „irgendein Wert in diesem Intervall“. Um eine **eindeutige** Zahl zu bekommen, nimmt man üblicherweise den **Mittelwert der beiden**:

$$x_{med} = \frac{x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}}{2}$$

Wichtig: Das ist nur bei **kardinalen** Merkmalen erlaubt — bei ordinalen darfst du nicht mitteln. Dort gibst du das Intervall an oder nennst eine der beiden Ausprägungen.

✓ BEISPIEL · DIESELBEN MENSADATEN

Sortiert ($n = 12$, also **gerade**):

1 · 3 · 3 · 4 · 4 · 4 · 4 · 4 · 5 · 5 · 5 · 10

1 $n/2 = 6$ und $n/2 + 1 = 7$ — wir brauchen den 6. und den 7. Wert.

2 $x_{(6)} = 4$ und $x_{(7)} = 4$

3 $x_{med} = \frac{4 + 4}{2} = 4$

TR · MEDIAN BULMA REÇETESİ

1. adım

Sırala. Bu adımı atlarsan her şey yanlış olur. Sınavda verilen liste genelde sıralı değildir.

2. adım

n tek mi çift mi? Tek ise tam ortadaki değer: $(n + 1)/2$ 'inci.

3. adım

n çift ise ortadaki **iki** değeri al: $n/2$ ve $n/2 + 1$. Kardinal veride ortalamalarını al.

Sık yapılan hata: $n/2$ sonucunu "medyan" sanmak. $n/2$ bir **sıra numarası**, medyanın kendisi değil. $n = 12$ için 6 bir konumdur, değer $x_{(6)} = 4$ 'tür.

4

Der Modus

Der häufigste Wert

• DEFINITION

x_{mod} = die am häufigsten beobachtete Ausprägung

Du liest ihn direkt aus der Häufigkeitstabelle ab: die Ausprägung mit dem **größten** h_j .

✓ BEISPIEL · DIESELBEN MENSADATEN

Das größte h_j ist 5, und es gehört zur Ausprägung 4. Also $x_{mod} = 4$.

▲ ZWEI BESONDERHEITEN

- Der Modus ist **nicht immer eindeutig**. Wenn zwei Ausprägungen gleich häufig sind, gibt es zwei Modi — die Verteilung ist dann **bimodal** (siehe Tag 2, Schritt 7).
- Bei **stetigen** Merkmalen ist der Modus meist sinnlos, weil fast jeder Wert nur einmal vorkommt. Dort benutzt man ihn höchstens für *klassierte* Daten: die Klasse mit der größten Dichte.

5

Welches Lagemaß darf ich benutzen?

Der wichtigste Schritt des Tages

Hier treffen Tag 1 und Tag 3 aufeinander. Das **Skalenniveau** entscheidet, welches Lagemaß überhaupt sinnvoll ist.

Lagemaß	nominal	ordinal	kardinal	Anmerkung
Modus	ja	ja	ja	auf <i>jedem</i> Niveau erlaubt
Median	nein	ja	ja	braucht eine Reihenfolge
Arithm. Mittel	nein	nein	ja	braucht sinnvolle Abstände

◆ EINE WICHTIGE AUSNAHME

Bei **binären**, als **0/1 kodierten** Merkmalen ist das arithmetische Mittel sinnvoll — obwohl das Merkmal nur zwei Kategorien hat. Denn dann gilt:

$$\bar{x} = \text{Anteil der Einsen}$$

Beispiel aus der Probeklausur: 20 Vorhersagen, davon 9 richtig (= 1) und 11 falsch (= 0). Dann ist $\bar{x} = \frac{9}{20} = 0.45$, also **45 % richtige Vorhersagen**. Das ist eine sinnvolle Aussage.

Die zweite Frage: Ausreißer

Selbst wenn das Skalenniveau alle drei erlaubt, ist der Mittelwert nicht automatisch die beste Wahl. Er ist **nicht robust**: Ein einziger extremer Wert zieht ihn weg.

✓ BEISPIEL · AUS TESTAT 1

Monatseinkommen von $n = 12$ Studierenden in Euro, sortiert:

550 · 600 · 750 · 800 · 900 · 900 · 900 · 1000 · 1100 · 1400 · 1600 · 7500

- 1 **Mittel:** Summe = 18 000, also $\bar{x} = \frac{18\,000}{12} = 1500$
- 2 **Median:** n gerade, $x_{(6)} = 900$ und $x_{(7)} = 900$, also $x_{med} = 900$
- 3 **Modus:** 900 kommt dreimal vor, also $x_{mod} = 900$

Der Mittelwert ist 1500 €, der Median 900 €. Kein einziger der zwölf Studierenden verdient 1500 €. Die Zahl entsteht allein durch den einen Wert 7500 — vermutlich jemand mit Nebenjob oder ein Tippfehler.

Hier ist der **Median** die ehrlichere Zahl. Deshalb berichten Statistikämter beim Einkommen fast immer den Median.

TR · KARAR KURALI · HANGI LAGEMASS

Sınavda "hangi Lagemaß kullanılabılır?" sorusu gelirse iki soru sor:

1. Skala?

nominal → sadece **Modus**
ordinal → **Modus + Median**
kardinal → **üçü de**

2. Ausreißer?

Aşırı uç bir değer var mı? Varsa **Median** daha dürüst. Mittelwert uç değerlerin peşinden sürüklenir.

İki kelimeyi karıştırma: **Modus** = en sık geçen değer · **Median** = ortadaki değer. Türkçede ikisi de "orta" gibi duruyor ama tamamen farklı şeyler.

▲ WAS IN DER KLAUSUR VERLANGT WIRD

In der Probeklausur (Aufgabe 1) steht wörtlich: „Falls Sie der Meinung sind, dass ein Parameter nicht sinnvoll angegeben werden kann, begründen Sie kurz in einem Satz.“

Das heißt: Du darfst „nicht sinnvoll“ schreiben — aber **nur mit Begründung**. Ein leeres Kästchen gibt null Punkte, „nicht sinnvoll, weil das Merkmal nur ordinalskaliert ist“ gibt die vollen Punkte.

▲ KLAUSUR-HINWEIS

In der Probeklausur, Aufgabe 2(c), steht genau diese Aufgabe — **4 Punkte**. Sie ist leicht, wenn du das Rezept kennst, und unmöglich, wenn nicht.

Die Situation: Du hast **keine** Rohdaten mehr, sondern nur noch eine Tabelle mit Klassen und Häufigkeiten. Die einzelnen Werte sind verloren. Was tust du?

• DIE IDEE UND DIE FORMEL

Du tust so, als läge jeder Wert einer Klasse genau in der **Klassenmitte**. Die Klassenmitte m_j ist:

$$m_j = \frac{c_{j-1} + c_j}{2} \quad (\text{untere Grenze} + \text{obere Grenze, geteilt durch } 2)$$

Dann rechnest du wie bei einer Häufigkeitstabelle, nur mit m_j statt a_j :

$$\bar{x}_K = \frac{1}{n} \sum_{j=1}^J n(K_j) \cdot m_j = \sum_{j=1}^J m_j f_j$$

Dabei ist $n(K_j)$ die Anzahl der Beobachtungen in Klasse K_j .

✓ BEISPIEL · DIE ECHTE KLAUSURAUFGABE

Getrunkene Biermenge in Litern bei $n = 10$ Gästen:

$$8.5 \cdot 8.5 \cdot 4.0 \cdot 4.0 \cdot 12.0 \cdot 12.0 \cdot 8.5 \cdot 15.7 \cdot 4.0 \cdot 8.5$$

Klassiert in $K_1 = [0, 10)$ und $K_2 = [10, 20]$.

1 Zählen: In K_1 liegen 8.5, 8.5, 4.0, 4.0, 8.5, 4.0, 8.5 $\rightarrow n(K_1) = 7$.

In K_2 liegen 12.0, 12.0, 15.7 $\rightarrow n(K_2) = 3$. Kontrolle: $7 + 3 = 10$ ✓

2 Klassenmitten: $m_1 = \frac{0 + 10}{2} = 5$ und $m_2 = \frac{10 + 20}{2} = 15$

3 Einsetzen: $\bar{x}_K = \frac{1}{10} (7 \cdot 5 + 3 \cdot 15) = \frac{35 + 45}{10} = \frac{80}{10} = 8$

Der echte Mittelwert aus den Rohdaten wäre $\frac{85.7}{10} = 8.57$. Die Klassierung kostet also Genauigkeit — das ist der Preis dafür, dass man die Einzelwerte weggeworfen hat.

1. adım

Her sınıfta **kaç gözlem** var, say $\rightarrow n(K_j)$

2. adım

Her sınıfın **orta noktasını** bul $\rightarrow m_j = \frac{\text{alt} + \text{üst}}{2}$

3. adım

Çarp ve topla: $\sum n(K_j) \cdot m_j$, sonra n 'e böl

Neden orta nokta? Sınıftaki değerlerin nerede olduğunu artık bilmiyorsun. En adil tahmin, hepsinin ortada olduğunu varsaymaktır. Bu yüzden sonuç gerçek ortalamadan biraz sapar — bu **hata değil**, yöntemin doğası.

7

Mittelwert bei Schichten

Wenn die Daten schon in Gruppen vorliegen

Manchmal bekommst du nicht die Rohdaten, sondern die **Mittelwerte einzelner Gruppen** (Schichten) und deren Größen. Auch daraus lässt sich das Gesamtmittel berechnen.

• FORMEL

$$\bar{x} = \frac{1}{n} (n_1 \bar{x}_1 + n_2 \bar{x}_2 + \dots + n_r \bar{x}_r) = \frac{1}{n} \sum_{j=1}^r n_j \bar{x}_j$$

Das Gesamtmittel ist der **gewichtete Durchschnitt** der Gruppenmittel. Gewichtet wird mit den **Gruppengrößen** n_j .

▲ DER HÄUFIGSTE FEHLER ÜBERHAUPT

Man darf die Gruppenmittel **nicht einfach mitteln**, wenn die Gruppen unterschiedlich groß sind.

Beispiel: Gruppe A hat 90 Personen mit $\bar{x}_A = 10$, Gruppe B hat 10 Personen mit $\bar{x}_B = 20$.


- **Falsch:** $\frac{10 + 20}{2} = 15$
- **Richtig:** $\frac{90 \cdot 10 + 10 \cdot 20}{100} = \frac{900 + 200}{100} = 11$

Die große Gruppe zieht das Ergebnis zu sich. 15 wäre nur richtig, wenn beide Gruppen gleich groß wären.

Gestern hast du die Schiefe aus dem **Bild** abgelesen. Heute liest du sie aus **drei Zahlen** ab — ohne Bild.

◆ DIE DREI FÄLLE

Form	Reihenfolge
symmetrisch, unimodal	$\bar{x} \approx x_{med} \approx x_{mod}$
rechtsschief (linkssteil)	$\bar{x} > x_{med} > x_{mod}$
linksschief (rechtssteil)	$\bar{x} < x_{med} < x_{mod}$



Rechtsschiefe Verteilung. Der Gipfel (Modus) liegt links. Der Mittelwert wird vom langen Ausläufer nach rechts gezogen und ist deshalb am größten. Der Median liegt dazwischen.

TR · SIRALAMAYI EZBERLEMEDEN HATIRLAMA

Ezberleme — **mantiğini kur**. Mittelwert uç değerlerden etkilenir, Modus hiç etkilenmez. Uzun kuyruk hangi taraftaysa, Mittelwert o tarafa doğru kayar.

kuyruk sağda

rechtsschief → Mittelwert sağa kaçır → $\bar{x}$ en büyük

$$\bar{x} > x_{med} > x_{mod}$$

kuyruk solda

linksschief → Mittelwert sola kaçır → $\bar{x}$ en küçük

$$\bar{x} < x_{med} < x_{mod}$$

Kontrol örneği: Testat 1'deki gelir verisinde $\bar{x} = 1500$, $x_{med} = 900$, $x_{mod} = 900$. Yani $\bar{x} > x_{med} \geq x_{mod} \rightarrow$ **rechtsschief**. 7500'lük uç değer sağda, tam da beklediğimiz gibi.

Verhalten bei Transformation

Was passiert, wenn man alle Werte umrechnet?

Manchmal rechnet man Daten um: Euro in Tausend Euro, Celsius in Fahrenheit, oder man zieht von allen Werten dasselbe ab. Was wird dann aus dem Lagemaß?

• LINEARE TRANSFORMATION

Wenn $y_i = a + b x_i$ für alle i , dann gilt:

$$\bar{y} = a + b \bar{x}$$

Das arithmetische Mittel wird also **genauso mittransformiert** wie die einzelnen Werte. Du musst nicht neu rechnen.

• MONOTONE TRANSFORMATION

Wenn $y_i = g(x_i)$ mit einer **monotonen** Funktion g , dann gilt:

$$y_{med} = g(x_{med})$$

„Monoton“ heißt: g dreht die Reihenfolge nicht um (zum Beispiel $\log$, $\sqrt{\cdot}$, oder $a + bx$ mit $b > 0$). Weil der Median nur von der **Reihenfolge** abhängt, bleibt er an derselben Stelle.

✓ BEISPIEL · AUS DER VORLESUNG

Original: $\bar{x} = 0.096$, $x_{med} = 0.042$. Transformation $y = 5 + 2x$:

1 $\bar{y} = 5 + 2 \cdot 0.096 = 5 + 0.192 = \mathbf{5.192}$

2 $y_{med} = 5 + 2 \cdot 0.042 = 5 + 0.084 = \mathbf{5.084}$

▲ DER UNTERSCHIED, DER PUNKTE BRINGT

Beim **Mittelwert** funktioniert die einfache Regel nur bei **linearen** Transformationen. Bei $y = \log(x)$ ist $\bar{y} \neq \log(\bar{x})$!

Beim **Median** funktioniert es bei *jeder* monotonen Transformation — also auch beim Logarithmus. Der Median ist in dieser Hinsicht der robustere der beiden.

► R · MITTELWERT UND FEHLENDE WERTE

```
x <- c(1400, 750, 900, 1100, 900, 550,  
      800, 1600, 900, 7500, 1000, 600)
```

```
mean(x)  
#> [1] 1500
```

```
# Was passiert bei einem fehlenden Wert?  
x2 <- c(x, NA)      # NA = "not available"  
mean(x2)  
#> [1] NA
```

```
mean(x2, na.rm = TRUE) # na.rm = "NA remove"  
#> [1] 1500
```

TR · NA VE NA.RM

NA

Eksik değer. "Bu hücrede veri yok" demek. Anket yapılmamış, ölçüm başarısız olmuş vs.

mean(x2)

NA döner. R bilerek böyle yapar: "İçinde bilinmeyen bir sayı var, ortalamayı sana söyleyemem."

na.rm = TRUE

"NA'ları **çıklar**, kalanla hesapla." Bu argüman `mean`, `var`, `sd`, `median` — hepsinde var.

B-Teil için: Bir hesap beklenmedik şekilde NA döndürüyorsa, ilk kontrol edeceğin şey veride NA olup olmadığıdır. `sum(is.na(x))` kaç tane eksik değer olduğunu söyler.

► R · MEDIAN UND MODUS

```
median(x)
#> [1] 900

# gleichwertig über die Quantilfunktion:
quantile(x, 0.5)
#> 50%
#> 900

# Für den Modus gibt es in R keine fertige Funktion.
# Man sucht den Eintrag mit der größten Häufigkeit:
table(x)
#> x
#> 550 600 750 800 900 1000 1100 1400 1600 7500
#>    1    1    1    1    3    1    1    1    1    1

which(table(x) == max(table(x)))
#> 900
#> 5
```

TR · MODUS KOMUTU NEDEN BÖYLE

R'da hazır bir `mode()` fonksiyonu **yoktur** (`mode()` diye bir komut var ama o veri tipini söyler, Modus'u değil — klasik bir tuzak). O yüzden elle kuruyoruz:

`table(x)`

Her değerin kaç kez geçtiğini sayar (Tag 2'den tanıdık).

`max(table(x))`

Bu sayıların **en büyüğü** → burada 3.

`table(x) == max(...)`

Her sayı için "en büyüğe eşit mi?" → TRUE/FALSE dizisi.

`which(...)`

TRUE olanların **yerini** verir. Üstteki `900` aradığın Modus, alttaki `5` ise onun tablodaki kaçınıcı sırada olduğu.

Çıktıyı okurken: Üst satır **isim** (yani değerin kendisi = 900), alt satır **konum** (5). Sınavda cevap **900**'dür, 5 değil.

► R · MITTELWERT PRO GRUPPE

```
# Beispiel: Mittelwert je Gruppe berechnen
gruppe <- factor(c("A", "A", "B", "B", "B", "A"))
wert <- c(10, 12, 20, 22, 24, 14)

aggregate(wert, by = list(gruppe), mean)
#>   Group.1  x
#> 1      A 12
#> 2      B 22

# Rundung – in der Klausur auf drei Nachkommastellen
round(mean(x), 3)
#> [1] 1500
```

TR · AGGREGATE VE ROUND

```
aggregate(wert, by =
list(gruppe), mean)
```

"**wert**"'i, **gruppe**'ye göre ayır, her gruba **mean** uygula." Schritt 7'deki Schichten hesabının R hali.

```
by = list(...)
```

Gruplama değişkeni **liste** içinde verilir — R'in tuhaf ama zorunlu bir kuralı.

```
round(x, 3)
```

3 ondalığa yuvarla. **Sınav kuralı bu** — son sonuçlar 3 basamak.

B-Teil'de: "Nutzen Sie zum Runden stets einen geeigneten R-Befehl" diye yazıyor. Yani elle yuvarlamak değil, `round()` kullanmak isteniyor.

✓ MACH DAS JETZT SELBST

1. Tippe den Einkommens-Vektor ab und lasse `mean()` und `median()` laufen. Siehst du den Unterschied 1500 gegen 900?
2. Ersetze die 7500 durch 1200 und rechne erneut. Wie stark ändert sich der **Mittelwert**, wie stark der **Median**?
3. Genau dieser Vergleich ist die Antwort auf jede Klausurfrage nach „Welches Lagemaß ist robuster?“

■ WORTSCHATZ · LEICHT ERKLÄRT

Lagemaß — eine Zahl für das Zentrum der Daten

zentrale Tendenz — dasselbe, nur feiner gesagt

arithmetisches Mittel $\bar{x}$ — der Durchschnitt

Median x_{med} — der mittlere Wert nach dem Sortieren

Modus x_{mod} — der häufigste Wert

geordnete Beobachtung $x_{(i)}$ — der i -te Wert *nach* dem Sortieren

robust — reagiert wenig auf Ausreißer (der Median ist robust)

Ausreißer — ein ungewöhnlich großer oder kleiner Wert

klassierte Daten — Daten, von denen nur noch Klassen bekannt sind

Klassenmitte m_j — die Mitte einer Klasse

Schicht — eine vorher gebildete Teilgruppe

gewichteter Durchschnitt — Mittelwert, bei dem größere Gruppen mehr zählen

lineare Transformation — Umrechnung der Form $y = a + bx$

monoton — die Funktion dreht die Reihenfolge nicht um

Spickzettel Tag 3

Arithmetisches Mittel

$$\bar{x} = \frac{1}{n} \sum_i x_i = \sum_j a_j f_j = \frac{1}{n} \sum_j a_j h_j$$

Median · n ungerade

$$x_{med} = x_{\left(\frac{n+1}{2}\right)}$$

Median · n gerade

$$x_{med} = \frac{x_{(n/2)} + x_{(n/2+1)}}{2}$$

Modus

die Ausprägung mit dem größten h_j

Wer darf was?

nominal → nur Modus | ordinal → Modus, Median | kardinal → alle drei. Ausnahme: 0/1-kodiert → $\bar{x}$ = Anteil der Einsen.

Klassierte Daten

$$m_j = \frac{c_{j-1} + c_j}{2} \cdot \bar{x}_K = \frac{1}{n} \sum_j n(K_j) m_j$$

Schichten

$$\bar{x} = \frac{1}{n} \sum_j n_j \bar{x}_j \text{ — nie einfach die Gruppenmittel mitteln!}$$

Rechtsschief

$$\bar{x} > x_{med} > x_{mod}$$

Linksschief

$$\bar{x} < x_{med} < x_{mod}$$

Transformation · Mittel

$$y = a + bx \Rightarrow \bar{y} = a + b\bar{x} \text{ (nur linear!)}$$

Transformation · Median

$$y = g(x) \text{ monoton} \Rightarrow y_{med} = g(x_{med})$$

Nützlich

$$\sum_i (x_i - \bar{x}) = 0 \text{ — deshalb wird morgen quadriert.}$$

R

`mean()` · `median()` · `quantile(x, 0.5)` · `table()` + `which(... == max(...))` für den Modus ·
`na.rm = TRUE` · `aggregate()` · `round(x, 3)`

Teste dich selbst

10 Aufgaben · 24 Punkte · Taschenrechner erlaubt · ca. 50 Minuten.

Klausurregeln: Dezimalpunkt · Zwischenergebnisse auf **vier**, Endergebnisse auf **drei** Nachkommastellen · Lösungsweg angeben, wo verlangt.

Beantworte jede Teilaufgabe (a), (b), (c) — auch wenn du unsicher bist. Ein leeres Kästchen gibt sicher null Punkte.

A 1 Gegeben ist die Häufigkeitstabelle für das Merkmal X = Anzahl der Vorlesungen pro Woche. (3 Punkte)

a_j	2	4	6	8	12
h_j	2	6	7	4	1

Bestimmen Sie (a) n , (b) x_{mod} , (c) x_{med} , (d) $\bar{x}$.

A 2 Sieben Wohnungen kosten (in Euro Nettomiete): (3 Punkte)

480 · 520 · 610 · 550 · 490 · 2400 · 530

- (a) Berechnen Sie $\bar{x}$ und x_{med} .
(b) Welches der beiden Maße beschreibt die typische Miete besser? Begründen Sie in einem Satz.
(c) Welche Schiefe hat die Verteilung?

A 3 Ein Merkmal ist ordinalskaliert. Welche Lagemaße dürfen Sie berechnen? (2 Punkte)

- ☐ A nur den Modus
☐ B Modus und Median
☐ C Median und arithmetisches Mittel
☐ D alle drei

Begründen Sie Ihre Wahl in einem Satz.

A 4 Die Lernzeit von $n = 40$ Studierenden wurde klassiert erfasst. (4 Punkte)

Klasse (Stunden)	$[0, 4)$	$[4, 10)$	$[10, 20]$
$n(K_j)$	12	20	8

- (a) Bestimmen Sie die Klassenmitten m_j .
(b) Berechnen Sie den Mittelwert der klassierten Daten. Geben Sie den Lösungsweg an.
(c) Warum weicht dieser Wert im Allgemeinen vom echten Mittelwert ab?

A 5 Für einen Datensatz gilt $\bar{x} = 32$, $x_{med} = 40$, $x_{mod} = 45$. (2 Punkte)

- (a) Welche Schiefe liegt vor? Nennen Sie beide gebräuchlichen Namen.
(b) Auf welcher Seite liegt der lange Ausläufer?

A 6 Ein Datensatz hat $\bar{x} = 18$ und $x_{med} = 15$. Alle Werte werden mit $y_i = 3 + 2x_i$ transformiert. (2 Punkte)

- (a) Berechnen Sie $\bar{y}$ und y_{med} .
(b) Gilt $\bar{y} = a + b\bar{x}$ auch für $y_i = \log(x_i)$? Begründen Sie kurz.

A 7 Richtig oder falsch? (2 Punkte)

- ☐ a Der Median ist robuster gegenüber Ausreißern als das arithmetische Mittel.
☐ b Der Modus ist immer eindeutig bestimmt.
☐ c Bei einem 0/1-kodierten Merkmal ist das arithmetische Mittel der Anteil der Einsen.
☐ d Es gilt immer $\sum_{i=1}^n (x_i - \bar{x}) = 0$.

A 8 Eine Universität hat zwei Fakultäten. In Fakultät A studieren 800 Personen mit einem Durchschnittsalter von 23 Jahren, in Fakultät B studieren 200 Personen mit einem Durchschnittsalter von 28 Jahren. (2 Punkte)

- (a) Berechnen Sie das Durchschnittsalter aller Studierenden.
(b) Warum ist $(23 + 28)/2 = 25.5$ falsch?

A 9 Lesen Sie den R-Output. (2 Punkte)

```
> mean(alter)
[1] NA

> mean(alter, na.rm = TRUE)
[1] 24.6

> sum(is.na(alter))
[1] 3
```

- (a) Warum gibt der erste Befehl `NA` zurück?
(b) Wie viele Beobachtungen fehlen, und was bewirkt `na.rm = TRUE` ?

A 10 R-Aufgabe. (2 Punkte)

```
x <- c(3, 7, 3, 5, 3, 9, 7)

table(x)
which(table(x) == max(table(x)))
```

- (a) Welche Ausgabe erzeugt `table(x)` ?
(b) Welchen Wert liefert die letzte Zeile als Modus — und was bedeutet die zweite Zahl in der Ausgabe?

Lösungen

Vergleiche ehrlich. Jeden Fehler ins Fehlerheft: *Was war die Frage? Warum war ich falsch?*

A 1 · 3 Punkte

(a) $n = 2 + 6 + 7 + 4 + 1 = 20$

(b) Größtes h_j ist 7 bei der Ausprägung 6, also $x_{mod} = 6$

(c) $n = 20$ ist gerade, gesucht sind $x_{(10)}$ und $x_{(11)}$. Kumuliert: bis Ausprägung 2 sind es 2 Werte, bis 4 sind es 8, bis 6 sind es 15. Also liegen sowohl der 10. als auch der 11. Wert bei der Ausprägung 6:

$$x_{med} = \frac{6 + 6}{2} = 6$$

(d) $\sum a_j h_j = 2 \cdot 2 + 4 \cdot 6 + 6 \cdot 7 + 8 \cdot 4 + 12 \cdot 1 = 4 + 24 + 42 + 32 + 12 = 114$

$$\bar{x} = \frac{114}{20} = 5.700$$

Kontrolle: $\bar{x} < x_{med}$ deutet auf eine leicht **linksschiefe** Verteilung hin — passt, denn die kleinen Ausprägungen ziehen etwas nach unten.

A 2 · 3 Punkte

(a) Sortiert: 480, 490, 520, **530**, 550, 610, 2400

Summe = $480 + 520 + 610 + 550 + 490 + 2400 + 530 = 5580$, also $\bar{x} = \frac{5580}{7} = 797.142857 \approx 797.143$

$n = 7$ ist ungerade, $\frac{n+1}{2} = 4$, also $x_{med} = x_{(4)} = 530$

(b) Der **Median** beschreibt die typische Miete besser. Sechs der sieben Wohnungen liegen zwischen 480 und 610 € — der Mittelwert von 797 € entsteht allein durch den Ausreißer 2400 € und wird von keiner einzigen Wohnung auch nur annähernd erreicht.

(c) Wegen $\bar{x} > x_{med}$ ist die Verteilung **rechtsschief** (= linkssteil). Der lange Ausläufer zeigt nach rechts, dorthin, wo die 2400 liegt.

A 3 · 2 Punkte

Richtig ist **B** — Modus und Median.

Begründung: Ordinalskalierte Merkmale haben eine **Reihenfolge**, also kann man sortieren und den mittleren Wert bestimmen — der Median ist erlaubt. Häufigkeiten darf man auf jedem Niveau zählen, also auch den Modus. Das arithmetische Mittel braucht dagegen **sinnvolle Abstände**, und die gibt es bei ordinalen Daten nicht.

A 4 · 4 Punkte

(a) Klassenmitten:

$$m_1 = \frac{0+4}{2} = 2 \cdot m_2 = \frac{4+10}{2} = 7 \cdot m_3 = \frac{10+20}{2} = 15$$

(b) Kontrolle zuerst: $12 + 20 + 8 = 40 = n$ ✓

$$\bar{x}_K = \frac{1}{40} (12 \cdot 2 + 20 \cdot 7 + 8 \cdot 15) = \frac{24 + 140 + 120}{40} = \frac{284}{40} = 7.1$$

Also $\bar{x}_K = 7.100$ Stunden.

(c) Weil die Einzelwerte nicht mehr bekannt sind. Man **unterstellt**, dass alle Beobachtungen einer Klasse genau in der Klassenmitte liegen. Tatsächlich sind sie aber innerhalb der Klasse verteilt — liegen sie überwiegend am unteren Rand, überschätzt $\bar{x}_K$ den echten Mittelwert, und umgekehrt.

A 5 · 2 Punkte

(a) Es gilt $\bar{x} < x_{med} < x_{mod}$ ($32 < 40 < 45$). Das ist der Fall **linksschief**, auch **rechtssteil** genannt.

(b) Der lange Ausläufer liegt **links**. Der Gipfel (Modus) sitzt rechts bei 45, und die kleinen Werte im linken Ausläufer ziehen den Mittelwert nach unten auf 32.

A 6 · 2 Punkte

(a) Die Transformation ist linear mit $a = 3$ und $b = 2$:

$$\bar{y} = 3 + 2 \cdot 18 = 39 \cdot y_{med} = 3 + 2 \cdot 15 = 33$$

(b) **Nein**. Die Regel $\bar{y} = a + b\bar{x}$ gilt nur für **lineare** Transformationen. Der Logarithmus ist nicht linear, deshalb ist im Allgemeinen $\overline{\log(x)} \neq \log(\bar{x})$.

Für den **Median** wäre es dagegen richtig: $\log$ ist monoton, also gilt $y_{med} = \log(x_{med})$.

A 7 · 2 Punkte

a) **richtig**. Der Median hängt nur von der Position in der sortierten Reihe ab, nicht vom Betrag der Extremwerte.

b) **falsch**. Sind zwei Ausprägungen gleich häufig, gibt es **zwei Modi** — die Verteilung ist bimodal.

c) **richtig**. Bei 0/1-Kodierung ist $\sum x_i$ genau die Anzahl der Einsen, geteilt durch n ergibt das den Anteil.

d) **richtig**. Das ist die Rechnung aus Tag 0: $\sum x_i - n\bar{x} = n\bar{x} - n\bar{x} = 0$.

A 8 · 2 Punkte

(a) Gewichteter Durchschnitt mit $n = 800 + 200 = 1000$:

$$\bar{x} = \frac{800 \cdot 23 + 200 \cdot 28}{1000} = \frac{18\,400 + 5\,600}{1000} = \frac{24\,000}{1000} = 24$$

Das Durchschnittsalter beträgt **24.000** Jahre.

(b) Weil die Fakultäten **unterschiedlich groß** sind. Der einfache Durchschnitt 25.5 würde beide Gruppen gleich stark gewichten, obwohl Fakultät A viermal so viele Studierende hat. Die große Gruppe muss entsprechend stärker zählen — deshalb liegt das richtige Ergebnis (24) viel näher an 23 als an 28.

A 9 · 2 Punkte

(a) Weil der Vektor `alter` mindestens einen **fehlenden Wert (NA)** enthält. R rechnet dann bewusst nicht weiter: Wenn ein Summand unbekannt ist, ist auch die Summe unbekannt — und damit der Mittelwert.

(b) `sum(is.na(alter))` zeigt **3 fehlende Werte**. `na.rm = TRUE` entfernt diese vor der Rechnung („NA remove“), sodass der Mittelwert aus den übrigen Beobachtungen gebildet wird: 24.6.

A 10 · 2 Punkte

(a)

```
x
3 5 7 9
3 1 2 1
```

Die 3 kommt dreimal vor, die 5 einmal, die 7 zweimal, die 9 einmal. Kontrolle: $3 + 1 + 2 + 1 = 7 = n$ ✓

(b) Das größte h_j ist 3, es gehört zur Ausprägung 3. Also $x_{mod} = \mathbf{3}$.

Die Ausgabe sieht so aus:

```
3
1
```

Die obere Zahl (**3**) ist der **Name**, also die gesuchte Merkmalsausprägung. Die untere Zahl (**1**) ist die **Position in der Tabelle** — die 3 steht an erster Stelle. Gefragt war der Modus, also lautet die Antwort **3**, nicht 1.

Deine Auswertung

Punkte	Was das bedeutet
20 – 24	Sehr gut. Besonders A4 (klassierte Daten) ist bare Klausurpunkte — die sitzen.
15 – 19	Gut. Rechne A1 und A4 noch einmal komplett durch, dann weiter zu Tag 4.
10 – 14	Wiederhole heute Abend Schritt 5 (welches Maß wann) und Schritt 6 (klassierte Daten).
0 – 9	Arbeite Schritt 2 bis 6 morgen früh noch einmal durch (45 Minuten) und mache den Test erneut.

◆ MORGEN · TAG 4

Heute hast du das **Zentrum** der Daten bestimmt. Morgen bestimmst du, wie weit die Daten davon **wegstreuen**: Quantile, Varianz, Standardabweichung, Interquartilsabstand und der Boxplot.

Zur Vorbereitung ein Satz von heute: $\sum_i (x_i - \bar{x}) = 0$. Weil diese Summe immer null ist, kann man sie nicht als Streuungsmaß benutzen — morgen siehst du, wie man das Problem mit einem Quadrat löst.