

TAG 03

Lagemaße

Gestern hast du die *ganze* Verteilung beschrieben — mit Tabelle, Histogramm und Treppenfunktion. Heute drückst du sie auf **eine einzige Zahl** zusammen. Das klingt nach weniger Arbeit, ist aber gefährlicher: Es gibt drei solche Zahlen, und wer die falsche wählt, rechnet Unsinn.

ca. 3 Stunden

10 Schritte

14 Aufgaben · 34 Punkte

► R-Ecke · TR erklär mal!

Das kannst du heute Abend

- ☐ Du berechnest **arithmetisches Mittel**, **Median** und **Modus**.
- ☐ Du weißt, welches Lagemaß bei welchem **Skalenniveau** erlaubt ist.
- ☐ Du erkennst, wann ein **Ausreißer** den Mittelwert unbrauchbar macht.
- ☐ Du berechnest den Mittelwert für **klassierte Daten**.
- ☐ Du berechnest den Mittelwert aus **Schichten**.
- ☐ Du liest die **Schiefte** aus der Reihenfolge der drei Lagemaße ab.
- ☐ Du weißt, was bei einer **Transformation** $y = a + bx$ passiert.

Grundlage: Vorlesung SDS1-V02 · R-Skript [02StatDS-HistogrammeMittelwertUndCo.R](#) · Testat 1, Aufgaben 3 – 5 · Probeklausur Teil A, Aufgaben 1 und 2

■ WAS DU VON GESTERN BRAUCHST

- a_j sind die **Ausprägungen**, h_j die **absoluten**, $f_j = h_j/n$ die **relativen Häufigkeiten**.
- Kontrollen: $\sum_j h_j = n$ und $\sum_j f_j = 1$.
- Bei stetigen Daten bildest du **Klassen** mit Grenzen c_j und Breiten b_j .
- **Rechtsschief** = langer Ausläufer nach rechts. **Linksschief** = nach links.

Von Tag 1 brauchst du die **Skalenniveaus**: nominal → ordinal → kardinal. Heute entscheidet genau das, welches Lagemaß du benutzen darfst.

TEIL 1 · LERNEN

1

Was ist ein Lagemaß?

Eine Zahl für die ganze Verteilung

Ein **Lagemaß** beschreibt das **Zentrum** der Daten — die Stelle, um die herum sich die Beobachtungen sammeln. Auf Deutsch sagt man auch *zentrale Tendenz*.

• DIE DREI LAGEMASSE

Name	Zeichen	Was es sagt
Arithmetisches Mittel	$\bar{x}$	der Durchschnitt — alle Werte zusammen, geteilt durch n
Median	x_{med}	der Wert in der <i>Mitte</i> , wenn man sortiert
Modus	x_{mod}	der Wert, der am <i>häufigsten</i> vorkommt

◆ WARUM DREI?

Weil sie unterschiedlich **reagieren**. Bei symmetrischen Daten sind sie fast gleich. Bei schiefen Daten oder bei einem einzigen extremen Wert laufen sie weit auseinander — und dann musst du wissen, welche Zahl du berichtest. Genau das lernst du in Schritt 5.

• DEFINITION

Aus den Rohdaten:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Aus einer Häufigkeitstabelle:

$$\bar{x} = \sum_{j=1}^J a_j f_j$$

▲ DIE ZWEITE FORMEL WIRD OFT ÜBERSEHEN

Wenn dir eine **Häufigkeitstabelle** gegeben ist (nicht die Rohdaten), wäre es Zeitverschwendung, alle Werte einzeln aufzuschreiben. Multipliziere jede Ausprägung mit ihrer relativen Häufigkeit und addiere. Gleichwertig und oft bequemer:

$$\bar{x} = \frac{1}{n} \sum_{j=1}^J a_j h_j$$

In der Klausur kommt genau diese Situation vor: Du bekommst eine Tabelle mit a_j und h_j und sollst $\bar{x}$ bestimmen.

✓ BEISPIEL · AUS TESTAT 1

Merkmal X = Anzahl der Mensabesuche in der vergangenen Woche:

a_j	1	3	4	5	10	Summe
h_j	1	2	5	3	1	12

1 **Stichprobenumfang:** $n = \sum h_j = 1 + 2 + 5 + 3 + 1 = 12$

2 **Zähler:** $\sum a_j h_j = 1 \cdot 1 + 3 \cdot 2 + 4 \cdot 5 + 5 \cdot 3 + 10 \cdot 1 = 1 + 6 + 20 + 15 + 10 = 52$

3 **Mittel:** $\bar{x} = \frac{52}{12} = 4.3333$

Auf drei Nachkommastellen gerundet: $\bar{x} = 4.333$ Mensabesuche.

✓ BEISPIEL 2 · AUS ROHDATEN

Wartezeiten in Minuten bei $n = 7$ Kundinnen und Kunden:

12 · 15 · 11 · 18 · 14 · 13 · 17

1 **Summe:** $12 + 15 + 11 + 18 + 14 + 13 + 17 = 100$

2 **Mittel:** $\bar{x} = \frac{100}{7} = 14.2857$

3 **Runden:** auf drei Nachkommastellen $\bar{x} = 14.286$ Minuten

Bei Rohdaten musst du **nicht** sortieren — für den Mittelwert ist die Reihenfolge egal. Für den Median gleich schon.

◆ DIE EIGENSCHAFT, DIE DU SCHON KENNST

$$\sum_{i=1}^n (x_i - \bar{x}) = 0$$

Die Abweichungen nach links und nach rechts heben sich **exakt** auf. Das ist die Rechnung aus Tag 0, Schritt 2 — und es ist der Grund, warum man beim Streuungsmaß morgen **quadrieren** muss: Ohne Quadrat käme immer null heraus.

3 Der Median

Der Wert in der Mitte

Der Median teilt die sortierten Beobachtungen in zwei gleich große Hälften: **mindestens 50 %** liegen links davon, **mindestens 50 %** rechts.

• DEFINITION

Mit den **geordneten** Beobachtungen $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$:

$$x_{med} = \begin{cases} x_{(\frac{n+1}{2})} & n \text{ ungerade} \\ \in [x_{(\frac{n}{2})}, x_{(\frac{n}{2}+1)}] & n \text{ gerade} \end{cases}$$

Die Klammern $x_{(i)}$ bedeuten: **der i -te Wert nach dem Sortieren** — nicht die i -te Person!

▲ BEI GERADEM N IST DER MEDIAN NICHT EINDEUTIG

Die Definition sagt „irgendein Wert in diesem Intervall“. Um eine **eindeutige** Zahl zu bekommen, nimmt man üblicherweise den **Mittelwert der beiden**:

$$x_{med} = \frac{x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}}{2}$$

Wichtig: Das ist nur bei **kardinalen** Merkmalen erlaubt — bei ordinalen darfst du nicht mitteln. Dort gibst du das Intervall an oder nennst eine der beiden Ausprägungen.

✓ BEISPIEL · DIESELBEN MENSADATEN

Sortiert ($n = 12$, also **gerade**):

1 · 3 · 3 · 4 · 4 · 4 · 4 · 4 · 5 · 5 · 5 · 10

1 $n/2 = 6$ und $n/2 + 1 = 7$ — wir brauchen den 6. und den 7. Wert.

2 $x_{(6)} = 4$ und $x_{(7)} = 4$

3 $x_{med} = \frac{4 + 4}{2} = 4$

✓ BEISPIEL 2 · UNGERADES N

Dieselben Wartezeiten wie in Schritt 2 — jetzt **sortiert** ($n = 7$, also ungerade):

11 · 12 · 13 · 14 · 15 · 17 · 18

1 $\frac{n+1}{2} = \frac{7+1}{2} = 4$ — wir brauchen den **4. Wert**.

2 $x_{med} = x_{(4)} = 14$ Minuten

Bei ungeradem n gibt es **keine** Mittelung: Der Median ist ein tatsächlich beobachteter Wert. Vergleiche: $\bar{x} = 14.286$, aber $x_{med} = 14$ — hier liegen beide nah beieinander, die Verteilung ist also ziemlich symmetrisch.

TR · MEDIAN BULMA REÇETESİ

1. adım

Sırala. Bu adımı atlarsan her şey yanlış olur. Sınavda verilen liste genelde sıralı değildir.

2. adım

n tek mi çift mi? Tek ise tam ortadaki değer: $(n + 1)/2$ 'inci.

3. adım

n çift ise ortadaki **iki** değeri al: $n/2$ ve $n/2 + 1$. Kardinal veride ortalamalarını al.

Sık yapılan hata: $n/2$ sonucunu "medyan" sanmak. $n/2$ bir **sıra numarası**, medyanın kendisi değil. $n = 12$ için 6 bir konumdur, değer $x_{(6)} = 4$ 'tür.

4

Der Modus

Der häufigste Wert

• DEFINITION

x_{mod} = die am häufigsten beobachtete Ausprägung

Du liest ihn direkt aus der Häufigkeitstabelle ab: die Ausprägung mit dem **größten** h_j .

✓ BEISPIEL · DIESELBEN MENSADATEN

Das größte h_j ist 5, und es gehört zur Ausprägung 4. Also $x_{mod} = 4$.

▲ ZWEI BESONDERHEITEN

- Der Modus ist **nicht immer eindeutig**. Wenn zwei Ausprägungen gleich häufig sind, gibt es zwei Modi — die Verteilung ist dann **bimodal** (siehe Tag 2, Schritt 7).
- Bei **stetigen** Merkmalen ist der Modus meist sinnlos, weil fast jeder Wert nur einmal vorkommt. Dort benutzt man ihn höchstens für *klassierte* Daten: die Klasse mit der größten Dichte.

✓ BEISPIEL 2 · WENN ES ZWEI MODI GIBT

Bewertung eines Films auf einer Skala von 1 bis 4, $n = 20$:

a_j	1	2	3	4
h_j	3	7	7	3

Das größte h_j ist 7 — und es kommt **zweimal** vor, bei den Ausprägungen 2 und 3. Also gibt es **zwei Modi**: $x_{mod} \in \{2, 3\}$.

Die Verteilung ist damit **bimodal** (Tag 2, Schritt 7). Solche Daten entstehen oft, wenn zwei verschiedene Gruppen vermischt sind — hier vielleicht Fans und Kritiker des Films.

5 Welches Lagemaß darf ich benutzen?

Der wichtigste Schritt des Tages

Hier treffen Tag 1 und Tag 3 aufeinander. Das **Skalenniveau** entscheidet, welches Lagemaß überhaupt sinnvoll ist.

Lagemaß	nominal	ordinal	kardinal	Anmerkung
Modus	ja	ja	ja	auf <i>jedem</i> Niveau erlaubt
Median	nein	ja	ja	braucht eine Reihenfolge
Arithm. Mittel	nein	nein	ja	braucht sinnvolle Abstände

◆ EINE WICHTIGE AUSNAHME

Bei **binären**, als **0/1 kodierten** Merkmalen ist das arithmetische Mittel sinnvoll — obwohl das Merkmal nur zwei Kategorien hat. Denn dann gilt:

$$\bar{x} = \text{Anteil der Einsen}$$

Beispiel aus der Probeklausur: 20 Vorhersagen, davon 9 richtig (= 1) und 11 falsch (= 0). Dann ist $\bar{x} = \frac{9}{20} = 0.45$, also **45 % richtige Vorhersagen**. Das ist eine sinnvolle Aussage.

Die zweite Frage: Ausreißer

Selbst wenn das Skalenniveau alle drei erlaubt, ist der Mittelwert nicht automatisch die beste Wahl. Er ist **nicht robust**: Ein einziger extremer Wert zieht ihn weg.

✓ BEISPIEL · AUS TESTAT 1

Monatseinkommen von $n = 12$ Studierenden in Euro, sortiert:

550 · 600 · 750 · 800 · 900 · 900 · 900 · 1000 · 1100 · 1400 · 1600 · 7500

- 1 **Mittel:** Summe = 18 000, also $\bar{x} = \frac{18\,000}{12} = 1500$
- 2 **Median:** n gerade, $x_{(6)} = 900$ und $x_{(7)} = 900$, also $x_{med} = 900$
- 3 **Modus:** 900 kommt dreimal vor, also $x_{mod} = 900$

Der Mittelwert ist 1500 €, der Median 900 €. Kein einziger der zwölf Studierenden verdient 1500 €. Die Zahl entsteht allein durch den einen Wert 7500 — vermutlich jemand mit Nebenjob oder ein Tippfehler.

Hier ist der **Median** die ehrlichere Zahl. Deshalb berichten Statistikämter beim Einkommen fast immer den Median.

TR · KARAR KURALI · HANGI LAGEMAŞ

Sınavda "hangi Lagemaş kullanılabilir?" sorusu gelirse iki soru sor:

1. Skala?

nominal → sadece **Modus**
ordinal → **Modus + Median**
kardinal → **üçü de**

2. Ausreißer?

Aşırı uç bir değer var mı? Varsa **Median** daha dürüst. Mittelwert uç değerlerin peşinden sürüklenir.

İki kelimeyi karıştırma: **Modus** = en sık geçen değer · **Median** = ortadaki değer. Türkçede ikisi de "orta" gibi duruyor ama tamamen farklı şeyler.

▲ WAS IN DER KLAUSUR VERLANGT WIRD

In der Probeklausur (Aufgabe 1) steht wörtlich: „*Falls Sie der Meinung sind, dass ein Parameter nicht sinnvoll angegeben werden kann, begründen Sie kurz in einem Satz.*“

Das heißt: Du darfst „nicht sinnvoll“ schreiben — aber **nur mit Begründung**. Ein leeres Kästchen gibt null Punkte, „nicht sinnvoll, weil das Merkmal nur ordinalskaliert ist“ gibt die vollen Punkte.

✓ BEISPIEL 2 · EIN ORDINALES MERKMAL

Kundenzufriedenheit bei $n = 50$ Befragten, fünf geordnete Kategorien:

Kategorie	sehr unzufrieden	unzufrieden	neutral	zufrieden	sehr zufrieden
h_j	2	5	8	20	15
kumuliert	2	7	15	35	50

- 1 Modus:** größtes h_j ist 20 $\rightarrow x_{mod} = \text{„zufrieden“}$
- 2 Median:** $n = 50$ gerade, gesucht sind $x_{(25)}$ und $x_{(26)}$. Laut kumulierter Zeile belegen die Positionen 16 bis 35 die Kategorie „zufrieden“ — beide gesuchten Positionen liegen also dort. $x_{med} = \text{„zufrieden“}$
- 3 Arithmetisches Mittel: nicht erlaubt.** Die Kategorien haben eine Reihenfolge, aber keine messbaren Abstände.

So schreibt man es in der Klausur: „Das arithmetische Mittel kann nicht sinnvoll angegeben werden, da das Merkmal nur ordinalskaliert ist.“ Ein Satz — volle Punkte.

6 Mittelwert für klassierte Daten

Direkt aus der Klausur: 4 Punkte

▲ KLAUSUR-HINWEIS

In der Probeklausur, Aufgabe 2(c), steht genau diese Aufgabe — **4 Punkte**. Sie ist leicht, wenn du das Rezept kennst, und unmöglich, wenn nicht.

Die Situation: Du hast **keine** Rohdaten mehr, sondern nur noch eine Tabelle mit Klassen und Häufigkeiten. Die einzelnen Werte sind verloren. Was tust du?

• DIE IDEE UND DIE FORMEL

Du tust so, als läge jeder Wert einer Klasse genau in der **Klassenmitte**. Die Klassenmitte m_j ist:

$$m_j = \frac{c_{j-1} + c_j}{2} \quad (\text{untere Grenze} + \text{obere Grenze, geteilt durch } 2)$$

Dann rechnest du wie bei einer Häufigkeitstabelle, nur mit m_j statt a_j :

$$\bar{x}_K = \frac{1}{n} \sum_{j=1}^J n(K_j) \cdot m_j = \sum_{j=1}^J m_j f_j$$

Dabei ist $n(K_j)$ die Anzahl der Beobachtungen in Klasse K_j .

✓ BEISPIEL · DIE ECHTE KLAUSURAUFGABE

Getrunkene Biermenge in Litern bei $n = 10$ Gästen:

$$8.5 \cdot 8.5 \cdot 4.0 \cdot 4.0 \cdot 12.0 \cdot 12.0 \cdot 8.5 \cdot 15.7 \cdot 4.0 \cdot 8.5$$

Klassiert in $K_1 = [0, 10)$ und $K_2 = [10, 20]$.

1 Zählen: In K_1 liegen 8.5, 8.5, 4.0, 4.0, 8.5, 4.0, 8.5 $\rightarrow n(K_1) = 7$.

In K_2 liegen 12.0, 12.0, 15.7 $\rightarrow n(K_2) = 3$. Kontrolle: $7 + 3 = 10$ ✓

2 Klassenmitten: $m_1 = \frac{0 + 10}{2} = 5$ und $m_2 = \frac{10 + 20}{2} = 15$

3 Einsetzen: $\bar{x}_K = \frac{1}{10} (7 \cdot 5 + 3 \cdot 15) = \frac{35 + 45}{10} = \frac{80}{10} = 8$

Der echte Mittelwert aus den Rohdaten wäre $\frac{85.7}{10} = 8.57$. Die Klassierung kostet also Genauigkeit — das ist der Preis dafür, dass man die Einzelwerte weggeworfen hat.

TR · KLASSEIERTE DATEN REÇETESİ

1. adım

Her sınıfta **kaç gözlem** var, say $\rightarrow n(K_j)$

2. adım

Her sınıfın **orta noktasını** bul $\rightarrow m_j = \frac{\text{alt} + \text{üst}}{2}$

3. adım

Çarp ve topla: $\sum n(K_j) \cdot m_j$, sonra n 'e böl

Neden orta nokta? Sınıftaki değerlerin nerede olduğunu artık bilmiyorsun. En adil tahmin, hepsinin ortada olduğunu varsaymaktır. Bu yüzden sonuç gerçek ortalamadan biraz sapar — bu **hata değil**, yöntemin doğası.

✓ BEISPIEL 2 · UNGLEICH BREITE KLASSEN

Monatliche Ausgaben für Bücher (in Euro) bei $n = 50$ Studierenden:

Klasse	$[0, 20)$	$[20, 50)$	$[50, 100]$
$n(K_j)$	15	25	10
m_j	10	35	75

1 **Kontrolle:** $15 + 25 + 10 = 50 = n$ ✓

2 **Klassenmitten:** $\frac{0+20}{2} = 10$, $\frac{20+50}{2} = 35$, $\frac{50+100}{2} = 75$

3 **Einsetzen:** $\bar{x}_K = \frac{15 \cdot 10 + 25 \cdot 35 + 10 \cdot 75}{50} = \frac{150 + 875 + 750}{50} = \frac{1775}{50} = 35.5$ Euro

Beachte: Dass die Klassen **unterschiedlich breit** sind, ändert an der Rechnung **nichts**. Anders als beim Histogramm (Tag 2) wird hier nicht durch die Breite geteilt — die Breite geht nur über die Klassenmitte ein.

7

Mittelwert bei Schichten

Wenn die Daten schon in Gruppen vorliegen

Manchmal bekommst du nicht die Rohdaten, sondern die **Mittelwerte einzelner Gruppen** (Schichten) und deren Größen. Auch daraus lässt sich das Gesamtmittel berechnen.

• FORMEL

$$\bar{x} = \frac{1}{n} (n_1 \bar{x}_1 + n_2 \bar{x}_2 + \dots + n_r \bar{x}_r) = \frac{1}{n} \sum_{j=1}^r n_j \bar{x}_j$$

Das Gesamtmittel ist der **gewichtete Durchschnitt** der Gruppenmittel. Gewichtet wird mit den **Gruppengrößen** n_j .

▲ DER HÄUFIGSTE FEHLER ÜBERHAUPT

Man darf die Gruppenmittel **nicht einfach mitteln**, wenn die Gruppen unterschiedlich groß sind.

Beispiel: Gruppe A hat 90 Personen mit $\bar{x}_A = 10$, Gruppe B hat 10 Personen mit $\bar{x}_B = 20$.

- **Falsch:** $\frac{10 + 20}{2} = 15$
- **Richtig:** $\frac{90 \cdot 10 + 10 \cdot 20}{100} = \frac{900 + 200}{100} = 11$

Die große Gruppe zieht das Ergebnis zu sich. 15 wäre nur richtig, wenn beide Gruppen gleich groß wären.

✓ BEISPIEL · DREI SCHICHTEN

Durchschnittliche Anzahl gelesener Bücher pro Monat, getrennt nach Fachbereich:

Schicht	n_j	$\bar{x}_j$	$n_j \bar{x}_j$
Wirtschaft	120	2.4	288
Jura	80	3.1	248
Informatik	50	1.8	90
Summe	250	—	626

$$\bar{x} = \frac{626}{250} = 2.504 \text{ Bücher pro Monat.}$$

Vergleich: Der ungewichtete Durchschnitt wäre $\frac{2.4+3.1+1.8}{3} = 2.433$ — also falsch. Die große Wirtschaftsgruppe zieht das richtige Ergebnis zu ihrem Wert 2.4 hin.

Tipp für die Klausur: Lege dir immer eine **vierte Spalte** $n_j \bar{x}_j$ an. Dann musst du am Ende nur noch die Spaltensumme durch n teilen — und der Lösungsweg ist automatisch nachvollziehbar.

8


Lagemaße und die Form der Verteilung

Die Reihenfolge verrät die Schiefe

Gestern hast du die Schiefe aus dem **Bild** abgelesen. Heute liest du sie aus **drei Zahlen** ab — ohne Bild.

◆ DIE DREI FÄLLE

Form	Reihenfolge
symmetrisch, unimodal	$\bar{x} \approx x_{med} \approx x_{mod}$
rechtsschief (linkssteil)	$\bar{x} > x_{med} > x_{mod}$
linksschief (rechtssteil)	$\bar{x} < x_{med} < x_{mod}$



Rechtsschiefe Verteilung. Der Gipfel (Modus) liegt links. Der Mittelwert wird vom langen Ausläufer nach rechts gezogen und ist deshalb am größten. Der Median liegt dazwischen.

TR · SIRALAMAYI EZBERLEMEDEN HATIRLAMA

Ezberleme — **mantığını kur.** Mittelwert uç değerlerden etkilenir, Modus hiç etkilenmez. Uzun kuyruk hangi taraftaysa, Mittelwert o tarafa doğru kayar.

kuyruk sağda

rechtsschief → Mittelwert sağa kaçır → $\bar{x}$ en büyük

$$\bar{x} > x_{med} > x_{mod}$$

kuyruk solda

linksschief → Mittelwert sola kaçır → $\bar{x}$ en küçük

$$\bar{x} < x_{med} < x_{mod}$$

Kontrol örneği: Testat 1'deki gelir verisinde $\bar{x} = 1500$, $x_{med} = 900$, $x_{mod} = 900$. Yani $\bar{x} > x_{med} \geq x_{mod} \rightarrow$ **rechtsschief**. 7500'lük uç değer sağda, tam da beklediğimiz gibi.

✓ ÜBUNG ZUM MITDENKEN

Bestimme die Form. Decke die rechte Spalte zuerst ab.

Gegeben	Form
$\bar{x} = 52, x_{med} = 50, x_{mod} = 47$	rechtsschief — $\bar{x}$ ist am größten
$\bar{x} = 8.1, x_{med} = 8.0, x_{mod} = 8.0$	annähernd symmetrisch — alle drei fast gleich
$\bar{x} = 3.2, x_{med} = 4.0, x_{mod} = 4.5$	linksschief — $\bar{x}$ ist am kleinsten
Einkommen aus Testat 1: 1500, 900, 900	rechtsschief — der Ausreißer 7500 liegt rechts

Immer zuerst: Wo steht $\bar{x}$ im Vergleich zu den anderen beiden? Ganz oben → rechtsschief. Ganz unten → linksschief. Mittendrin und nah dran → symmetrisch.

9 Verhalten bei Transformation

Was passiert, wenn man alle Werte umrechnet?

Manchmal rechnet man Daten um: Euro in Tausend Euro, Celsius in Fahrenheit, oder man zieht von allen Werten dasselbe ab. Was wird dann aus dem Lagemaß?

• LINEARE TRANSFORMATION

Wenn $y_i = a + b x_i$ für alle i , dann gilt:

$$\bar{y} = a + b \bar{x}$$

Das arithmetische Mittel wird also **genauso mittransformiert** wie die einzelnen Werte. Du musst nicht neu rechnen.

• MONOTONE TRANSFORMATION

Wenn $y_i = g(x_i)$ mit einer **monotonen** Funktion g , dann gilt:

$$y_{med} = g(x_{med})$$

„Monoton“ heißt: g dreht die Reihenfolge nicht um (zum Beispiel $\log$, $\sqrt{}$, oder $a + bx$ mit $b > 0$). Weil der Median nur von der **Reihenfolge** abhängt, bleibt er an derselben Stelle.

✓ BEISPIEL · AUS DER VORLESUNG

Original: $\bar{x} = 0.096$, $x_{med} = 0.042$. Transformation $y = 5 + 2x$:

1 $\bar{y} = 5 + 2 \cdot 0.096 = 5 + 0.192 = \mathbf{5.192}$

2 $y_{med} = 5 + 2 \cdot 0.042 = 5 + 0.084 = \mathbf{5.084}$

▲ DER UNTERSCHIED, DER PUNKTE BRINGT

Beim **Mittelwert** funktioniert die einfache Regel nur bei **linearen** Transformationen. Bei $y = \log(x)$ ist $\bar{y} \neq \log(\bar{x})$!

Beim **Median** funktioniert es bei *jeder* monotonen Transformation — also auch beim Logarithmus. Der Median ist in dieser Hinsicht der robustere der beiden.

✓ BEISPIEL 2 · WÄHRUNGSUMRECHNUNG

Preise in Euro: $\bar{x} = 45$ und $x_{med} = 40$. Umrechnung in Dollar zum Kurs 1.08, also $y = 1.08x$ (hier ist $a = 0$ und $b = 1.08$).

1 $\bar{y} = 1.08 \cdot 45 = \mathbf{48.6}$ Dollar

2 $y_{med} = 1.08 \cdot 40 = \mathbf{43.2}$ Dollar

Weil $b = 1.08 > 0$ ist, bleibt die Reihenfolge erhalten — die Transformation ist monoton, und der Median darf einfach mittransformiert werden.

TR · TRANSFORMASYON KARAR KURALI

$$y = a + bx$$

Doğrusal. Hem $\bar{x}$ hem x_{med} doğrudan dönüştürülür: $a + b \cdot$ (eski değer).

$$y = \log x, \sqrt{x}$$

Doğrusal değil ama monoton. Sadece **Median** dönüştürülebilir. Mittelwert için veriyi baştan hesaplaman gerekir.

Neden Median her zaman çalışıyor? Çünkü Median sadece **sıraya** bakar. Monoton fonksiyon sırayı bozmaz, yani ortadaki değer dönüşümden sonra da ortadaki değer olarak kalır. Mittelwert ise tüm değerlerin **büyükliğini** kullanır, o yüzden sadece doğrusal dönüşümde tahmin edilebilir.

► R · MITTELWERT UND FEHLENDE WERTE

```
x <- c(1400, 750, 900, 1100, 900, 550,  
      800, 1600, 900, 7500, 1000, 600)
```

```
mean(x)  
#> [1] 1500
```

```
# Was passiert bei einem fehlenden Wert?  
x2 <- c(x, NA)      # NA = "not available"  
mean(x2)  
#> [1] NA
```

```
mean(x2, na.rm = TRUE) # na.rm = "NA remove"  
#> [1] 1500
```

TR · NA VE NA.RM

NA

Eksik değer. "Bu hücrede veri yok" demek. Anket yapılmamış, ölçüm başarısız olmuş vs.

mean(x2)

NA döner. R bilerek böyle yapar: "İçinde bilinmeyen bir sayı var, ortalamayı sana söyleyemem."

na.rm = TRUE

"NA'ları **çıklar**, kalanla hesapla." Bu argüman `mean`, `var`, `sd`, `median` — hepsinde var.

B-Teil için: Bir hesap beklenmedik şekilde NA döndürüyorsa, ilk kontrol edeceğin şey veride NA olup olmadığıdır. `sum(is.na(x))` kaç tane eksik değer olduğunu söyler.

► R · MEDIAN UND MODUS

```
median(x)
#> [1] 900

# gleichwertig über die Quantilfunktion:
quantile(x, 0.5)
#> 50%
#> 900

# Für den Modus gibt es in R keine fertige Funktion.
# Man sucht den Eintrag mit der größten Häufigkeit:
table(x)
#> x
#> 550 600 750 800 900 1000 1100 1400 1600 7500
#>    1    1    1    1    3    1    1    1    1    1

which(table(x) == max(table(x)))
#> 900
#> 5
```

TR · MODUS KOMUTU NEDEN BÖYLE

R'da hazır bir mode () fonksiyonu **yoktur** (mode () diye bir komut var ama o veri tipini söyler, Modus'u değil — klasik bir tuzak). O yüzden elle kuruyoruz:

`table(x)`

Her değerin kaç kez geçtiğini sayar (Tag 2'den tanıdık).

`max(table(x))`

Bu sayıların **en büyüğü** → burada 3.

`table(x) == max(...)`

Her sayı için "en büyüğe eşit mi?" → TRUE/FALSE dizisi.

`which(...)`

TRUE olanların **yerini** verir. Üstteki `900` aradığın Modus, alttaki `5` ise onun tablodaki kaçınıcı sırada olduğu.

Çıktıyı okurken: Üst satır **isim** (yani değerin kendisi = 900), alt satır **konum** (5). Sınavda cevap **900**'dür, 5 değil.

► R · MITTELWERT PRO GRUPPE

```
# Beispiel: Mittelwert je Gruppe berechnen
gruppe <- factor(c("A", "A", "B", "B", "B", "A"))
wert <- c(10, 12, 20, 22, 24, 14)

aggregate(wert, by = list(gruppe), mean)
#>   Group.1  x
#> 1      A 12
#> 2      B 22

# Rundung – in der Klausur auf drei Nachkommastellen
round(mean(x), 3)
#> [1] 1500
```

TR · AGGREGATE VE ROUND

```
aggregate(wert, by =
list(gruppe), mean)
```

"**wert**"'i, **gruppe**'ye göre ayır, her gruba **mean** uygula." Schritt 7'deki Schichten hesabının R hali.

```
by = list(...)
```

Gruplama değişkeni **liste** içinde verilir — R'in tuhaf ama zorunlu bir kuralı.

```
round(x, 3)
```

3 ondalığa yuvarla. **Sınav kuralı bu** — son sonuçlar 3 basamak.

B-Teil'de: "Nutzen Sie zum Runden stets einen geeigneten R-Befehl" diye yazıyor. Yani elle yuvarlamak değil, `round()` kullanmak isteniyor.

✓ MACH DAS JETZT SELBST

1. Tippe den Einkommens-Vektor ab und lasse `mean()` und `median()` laufen. Siehst du den Unterschied 1500 gegen 900?
2. Ersetze die 7500 durch 1200 und rechne erneut. Wie stark ändert sich der **Mittelwert**, wie stark der **Median**?
3. Genau dieser Vergleich ist die Antwort auf jede Klausurfrage nach „Welches Lagemaß ist robuster?“

■ WORTSCHATZ · LEICHT ERKLÄRT

Lagemaß — eine Zahl für das Zentrum der Daten

zentrale Tendenz — dasselbe, nur feiner gesagt

arithmetisches Mittel $\bar{x}$ — der Durchschnitt

Median x_{med} — der mittlere Wert nach dem Sortieren

Modus x_{mod} — der häufigste Wert

geordnete Beobachtung $x_{(i)}$ — der i -te Wert *nach* dem Sortieren

robust — reagiert wenig auf Ausreißer (der Median ist robust)

Ausreißer — ein ungewöhnlich großer oder kleiner Wert

klassierte Daten — Daten, von denen nur noch Klassen bekannt sind

Klassenmitte m_j — die Mitte einer Klasse

Schicht — eine vorher gebildete Teilgruppe

gewichteter Durchschnitt — Mittelwert, bei dem größere Gruppen mehr zählen

lineare Transformation — Umrechnung der Form $y = a + bx$

monoton — die Funktion dreht die Reihenfolge nicht um

Spickzettel Tag 3

Arithmetisches Mittel

$$\bar{x} = \frac{1}{n} \sum_i x_i = \sum_j a_j f_j = \frac{1}{n} \sum_j a_j h_j$$

Median · n ungerade

$$x_{med} = x_{\left(\frac{n+1}{2}\right)}$$

Median · n gerade

$$x_{med} = \frac{x_{(n/2)} + x_{(n/2+1)}}{2}$$

Modus

die Ausprägung mit dem größten h_j

Wer darf was?

nominal → nur Modus | ordinal → Modus, Median | kardinal → alle drei. Ausnahme: 0/1-kodiert → $\bar{x}$ = Anteil der Einsen.

Klassierte Daten

$$m_j = \frac{c_{j-1} + c_j}{2} \cdot \bar{x}_K = \frac{1}{n} \sum_j n(K_j) m_j$$

Schichten

$$\bar{x} = \frac{1}{n} \sum_j n_j \bar{x}_j \text{ — nie einfach die Gruppenmittel mitteln!}$$

Rechtsschief

$$\bar{x} > x_{med} > x_{mod}$$

Linksschief

$$\bar{x} < x_{med} < x_{mod}$$

Transformation · Mittel

$$y = a + bx \Rightarrow \bar{y} = a + b\bar{x} \text{ (nur linear!)}$$

Transformation · Median

$$y = g(x) \text{ monoton} \Rightarrow y_{med} = g(x_{med})$$

Nützlich

$$\sum_i (x_i - \bar{x}) = 0 \text{ — deshalb wird morgen quadriert.}$$

R

`mean()` · `median()` · `quantile(x, 0.5)` · `table()` + `which(... == max(...))` für den Modus ·
`na.rm = TRUE` · `aggregate()` · `round(x, 3)`

Teste dich selbst

14 Aufgaben · 34 Punkte · Taschenrechner erlaubt · ca. 70 Minuten.

Klausurregeln: Dezimalpunkt · Zwischenergebnisse auf **vier**, Endergebnisse auf **drei** Nachkommastellen · Lösungsweg angeben, wo verlangt.

Beantworte jede Teilaufgabe (a), (b), (c) — auch wenn du unsicher bist. Ein leeres Kästchen gibt sicher null Punkte.

A 1 Gegeben ist die Häufigkeitstabelle für das Merkmal X = Anzahl der Vorlesungen pro Woche. (3 Punkte)

a_j	2	4	6	8	12
h_j	2	6	7	4	1

Bestimmen Sie (a) n , (b) x_{mod} , (c) x_{med} , (d) $\bar{x}$.

A 2 Sieben Wohnungen kosten (in Euro Nettomiete): (3 Punkte)

480 · 520 · 610 · 550 · 490 · 2400 · 530

- (a) Berechnen Sie $\bar{x}$ und x_{med} .
(b) Welches der beiden Maße beschreibt die typische Miete besser? Begründen Sie in einem Satz.
(c) Welche Schiefe hat die Verteilung?

A 3 Ein Merkmal ist ordinalskaliert. Welche Lagemaße dürfen Sie berechnen? (2 Punkte)

- ☐ A nur den Modus
☐ B Modus und Median
☐ C Median und arithmetisches Mittel
☐ D alle drei

Begründen Sie Ihre Wahl in einem Satz.

A 4 Die Lernzeit von $n = 40$ Studierenden wurde klassiert erfasst. (4 Punkte)

Klasse (Stunden)	$[0, 4)$	$[4, 10)$	$[10, 20]$
$n(K_j)$	12	20	8

- (a) Bestimmen Sie die Klassenmitten m_j .
(b) Berechnen Sie den Mittelwert der klassierten Daten. Geben Sie den Lösungsweg an.
(c) Warum weicht dieser Wert im Allgemeinen vom echten Mittelwert ab?

A 5 Für einen Datensatz gilt $\bar{x} = 32$, $x_{med} = 40$, $x_{mod} = 45$. (2 Punkte)

- (a) Welche Schiefe liegt vor? Nennen Sie beide gebräuchlichen Namen.
(b) Auf welcher Seite liegt der lange Ausläufer?

A 6 Ein Datensatz hat $\bar{x} = 18$ und $x_{med} = 15$. Alle Werte werden mit $y_i = 3 + 2x_i$ transformiert. (2 Punkte)

- (a) Berechnen Sie $\bar{y}$ und y_{med} .
(b) Gilt $\bar{y} = a + b\bar{x}$ auch für $y_i = \log(x_i)$? Begründen Sie kurz.

A 7 Richtig oder falsch? (2 Punkte)

- ☐ a Der Median ist robuster gegenüber Ausreißern als das arithmetische Mittel.
☐ b Der Modus ist immer eindeutig bestimmt.
☐ c Bei einem 0/1-kodierten Merkmal ist das arithmetische Mittel der Anteil der Einsen.
☐ d Es gilt immer $\sum_{i=1}^n (x_i - \bar{x}) = 0$.

A 8 Eine Universität hat zwei Fakultäten. In Fakultät A studieren 800 Personen mit einem Durchschnittsalter von 23 Jahren, in Fakultät B studieren 200 Personen mit einem Durchschnittsalter von 28 Jahren. (2 Punkte)

- (a) Berechnen Sie das Durchschnittsalter aller Studierenden.
(b) Warum ist $(23 + 28)/2 = 25.5$ falsch?

A 9 Lesen Sie den R-Output. (2 Punkte)

```
> mean(alter)
[1] NA

> mean(alter, na.rm = TRUE)
[1] 24.6

> sum(is.na(alter))
[1] 3
```

- (a) Warum gibt der erste Befehl `NA` zurück?
(b) Wie viele Beobachtungen fehlen, und was bewirkt `na.rm = TRUE` ?

A 10 R-Aufgabe. (2 Punkte)

```
x <- c(3, 7, 3, 5, 3, 9, 7)

table(x)
which(table(x) == max(table(x)))
```

- (a) Welche Ausgabe erzeugt `table(x)` ?
(b) Welchen Wert liefert die letzte Zeile als Modus — und was bedeutet die zweite Zahl in der Ausgabe?

A 11 Sieben Pakete wiegen (in kg): (3 Punkte)

23 · 19 · 31 · 25 · 19 · 28 · 22

(a) Bestimmen Sie $\bar{x}$, x_{med} und x_{mod} .

(b) Welche Schiefe liegt vor? Begründen Sie mit der Reihenfolge der drei Maße.

A 12 In einer Umfrage wurde der höchste Schulabschluss erfasst: Hauptschule (8), Realschule (14), Abitur (28). (2 Punkte)

(a) Welches Skalenniveau liegt vor?

(b) Welche Lagemaße dürfen Sie berechnen? Bestimmen Sie alle erlaubten. Für die nicht erlaubten geben Sie eine kurze Begründung an.

A 13 Eine Klausur wurde in drei Hörsälen geschrieben. (3 Punkte)

Hörsaal	A	B	C
Anzahl n_j	45	30	25
Durchschnittspunkte $\bar{x}_j$	68	74	80

(a) Berechnen Sie die Durchschnittspunktzahl aller Teilnehmenden. Lösungsweg angeben.

(b) Ein Kommilitone rechnet $(68 + 74 + 80)/3 = 74$. Warum ist das falsch?

(c) Liegt Ihr Ergebnis näher an 68 oder an 80? Erklären Sie, warum das so sein muss.

A 14 Die Fahrzeit zur Uni wurde bei $n = 25$ Studierenden klassiert erfasst. (2 Punkte)

Klasse (Minuten)	[0, 10)	[10, 30)	[30, 60]
$n(K_j)$	8	14	3

Berechnen Sie den Mittelwert der klassierten Daten. Geben Sie die Klassenmitten und den vollständigen Lösungsweg an.

Lösungen

Vergleiche ehrlich. Jeden Fehler ins Fehlerheft: *Was war die Frage? Warum war ich falsch?*

A 1 · 3 Punkte

(a) $n = 2 + 6 + 7 + 4 + 1 = 20$

(b) Größtes h_j ist 7 bei der Ausprägung 6, also $x_{\text{mod}} = 6$

(c) $n = 20$ ist gerade, gesucht sind $x_{(10)}$ und $x_{(11)}$. Kumuliert: bis Ausprägung 2 sind es 2 Werte, bis 4 sind es 8, bis 6 sind es 15. Also liegen sowohl der 10. als auch der 11. Wert bei der Ausprägung 6:

$$x_{\text{med}} = \frac{6 + 6}{2} = 6$$

(d) $\sum a_j h_j = 2 \cdot 2 + 4 \cdot 6 + 6 \cdot 7 + 8 \cdot 4 + 12 \cdot 1 = 4 + 24 + 42 + 32 + 12 = 114$

$$\bar{x} = \frac{114}{20} = 5.700$$

Kontrolle: $\bar{x} < x_{\text{med}}$ deutet auf eine leicht **linksschiefe** Verteilung hin — passt, denn die kleinen Ausprägungen ziehen etwas nach unten.

A 2 · 3 Punkte

(a) Sortiert: 480, 490, 520, **530**, 550, 610, 2400

Summe = $480 + 520 + 610 + 550 + 490 + 2400 + 530 = 5580$, also $\bar{x} = \frac{5580}{7} = 797.142857 \approx 797.143$

$n = 7$ ist ungerade, $\frac{n+1}{2} = 4$, also $x_{\text{med}} = x_{(4)} = 530$

(b) Der **Median** beschreibt die typische Miete besser. Sechs der sieben Wohnungen liegen zwischen 480 und 610 € — der Mittelwert von 797 € entsteht allein durch den Ausreißer 2400 € und wird von keiner einzigen Wohnung auch nur annähernd erreicht.

(c) Wegen $\bar{x} > x_{\text{med}}$ ist die Verteilung **rechtsschief** (= linkssteil). Der lange Ausläufer zeigt nach rechts, dorthin, wo die 2400 liegt.

A 3 · 2 Punkte

Richtig ist **B** — Modus und Median.

Begründung: Ordinalskalierte Merkmale haben eine **Reihenfolge**, also kann man sortieren und den mittleren Wert bestimmen — der Median ist erlaubt. Häufigkeiten darf man auf jedem Niveau zählen, also auch den Modus. Das arithmetische Mittel braucht dagegen **sinnvolle Abstände**, und die gibt es bei ordinalen Daten nicht.

A 4 · 4 Punkte

(a) Klassenmitten:

$$m_1 = \frac{0+4}{2} = 2 \cdot m_2 = \frac{4+10}{2} = 7 \cdot m_3 = \frac{10+20}{2} = 15$$

(b) Kontrolle zuerst: $12 + 20 + 8 = 40 = n$ ✓

$$\bar{x}_K = \frac{1}{40} (12 \cdot 2 + 20 \cdot 7 + 8 \cdot 15) = \frac{24 + 140 + 120}{40} = \frac{284}{40} = 7.1$$

Also $\bar{x}_K = 7.100$ Stunden.

(c) Weil die Einzelwerte nicht mehr bekannt sind. Man **unterstellt**, dass alle Beobachtungen einer Klasse genau in der Klassenmitte liegen. Tatsächlich sind sie aber innerhalb der Klasse verteilt — liegen sie überwiegend am unteren Rand, überschätzt $\bar{x}_K$ den echten Mittelwert, und umgekehrt.

A 5 · 2 Punkte

(a) Es gilt $\bar{x} < x_{med} < x_{mod}$ ($32 < 40 < 45$). Das ist der Fall **linksschief**, auch **rechtssteil** genannt.

(b) Der lange Ausläufer liegt **links**. Der Gipfel (Modus) sitzt rechts bei 45, und die kleinen Werte im linken Ausläufer ziehen den Mittelwert nach unten auf 32.

A 6 · 2 Punkte

(a) Die Transformation ist linear mit $a = 3$ und $b = 2$:

$$\bar{y} = 3 + 2 \cdot 18 = 39 \cdot y_{med} = 3 + 2 \cdot 15 = 33$$

(b) **Nein**. Die Regel $\bar{y} = a + b\bar{x}$ gilt nur für **lineare** Transformationen. Der Logarithmus ist nicht linear, deshalb ist im Allgemeinen $\overline{\log(x)} \neq \log(\bar{x})$.

Für den **Median** wäre es dagegen richtig: $\log$ ist monoton, also gilt $y_{med} = \log(x_{med})$.

A 7 · 2 Punkte

a) **richtig**. Der Median hängt nur von der Position in der sortierten Reihe ab, nicht vom Betrag der Extremwerte.

b) **falsch**. Sind zwei Ausprägungen gleich häufig, gibt es **zwei Modi** — die Verteilung ist bimodal.

c) **richtig**. Bei 0/1-Kodierung ist $\sum x_i$ genau die Anzahl der Einsen, geteilt durch n ergibt das den Anteil.

d) **richtig**. Das ist die Rechnung aus Tag 0: $\sum x_i - n\bar{x} = n\bar{x} - n\bar{x} = 0$.

A 8 · 2 Punkte

(a) Gewichteter Durchschnitt mit $n = 800 + 200 = 1000$:

$$\bar{x} = \frac{800 \cdot 23 + 200 \cdot 28}{1000} = \frac{18\,400 + 5\,600}{1000} = \frac{24\,000}{1000} = 24$$

Das Durchschnittsalter beträgt **24.000** Jahre.

(b) Weil die Fakultäten **unterschiedlich groß** sind. Der einfache Durchschnitt 25.5 würde beide Gruppen gleich stark gewichten, obwohl Fakultät A viermal so viele Studierende hat. Die große Gruppe muss entsprechend stärker zählen — deshalb liegt das richtige Ergebnis (24) viel näher an 23 als an 28.

A 9 · 2 Punkte

(a) Weil der Vektor `alter` mindestens einen **fehlenden Wert (NA)** enthält. R rechnet dann bewusst nicht weiter: Wenn ein Summand unbekannt ist, ist auch die Summe unbekannt — und damit der Mittelwert.

(b) `sum(is.na(alter))` zeigt **3 fehlende Werte**. `na.rm = TRUE` entfernt diese vor der Rechnung („NA remove“), sodass der Mittelwert aus den übrigen Beobachtungen gebildet wird: 24.6.

A 10 · 2 Punkte

(a)

```
x
3 5 7 9
3 1 2 1
```

Die 3 kommt dreimal vor, die 5 einmal, die 7 zweimal, die 9 einmal. Kontrolle: $3 + 1 + 2 + 1 = 7 = n$ ✓

(b) Das größte h_j ist 3, es gehört zur Ausprägung 3. Also $x_{mod} = 3$.

Die Ausgabe sieht so aus:

```
3
1
```

Die obere Zahl (**3**) ist der **Name**, also die gesuchte Merkmalsausprägung. Die untere Zahl (**1**) ist die **Position in der Tabelle** — die 3 steht an erster Stelle. Gefragt war der Modus, also lautet die Antwort **3**, nicht 1.

A 11 · 3 Punkte

(a) Sortiert: 19, 19, 22, **23**, 25, 28, 31

Mittel: Summe = $23 + 19 + 31 + 25 + 19 + 28 + 22 = 167$, also $\bar{x} = \frac{167}{7} = 23.8571 \approx \mathbf{23.857}$ kg

Median: $n = 7$ ist ungerade, $\frac{n+1}{2} = 4$, also $x_{med} = x_{(4)} = \mathbf{23}$ kg

Modus: Nur die 19 kommt zweimal vor, alle anderen einmal, also $x_{mod} = \mathbf{19}$ kg

(b) Es gilt $23.857 > 23 > 19$, also $\bar{x} > x_{med} > x_{mod} \rightarrow$ die Verteilung ist **rechtsschief** (= linkssteil). Der lange Ausläufer zeigt nach rechts, hin zum schwersten Paket mit 31 kg.

A 12 · 2 Punkte

(a) **Ordinalskaliert.** Die Kategorien haben eine klare Reihenfolge (Hauptschule < Realschule < Abitur), aber die Abstände zwischen ihnen sind nicht messbar.

(b) Erlaubt sind **Modus und Median.**

Modus: größtes h_j ist 28 $\rightarrow x_{mod} = \text{„Abitur“}$

Median: $n = 8 + 14 + 28 = 50$, gerade, gesucht sind $x_{(25)}$ und $x_{(26)}$. Kumuliert: $8 \cdot 22 \cdot 50$. Die Positionen 23 bis 50 gehören zu „Abitur“, also $x_{med} = \text{„Abitur“}$.

Arithmetisches Mittel: nicht erlaubt — das Merkmal ist nur ordinalskaliert, es gibt keine sinnvollen Abstände zwischen den Abschlüssen.

A 13 · 3 Punkte

(a) Gewichteter Durchschnitt, $n = 45 + 30 + 25 = 100$:

Hörsaal	n_j	$\bar{x}_j$	$n_j \bar{x}_j$
A	45	68	3060
B	30	74	2220
C	25	80	2000
Summe	100	—	7280

$$\bar{x} = \frac{7280}{100} = \mathbf{72.800} \text{ Punkte}$$

(b) Weil die Hörsäle **unterschiedlich groß** sind. Der ungewichtete Durchschnitt würde jeden Hörsaal gleich stark zählen, obwohl in A fast doppelt so viele Personen sitzen wie in C.

(c) Näher an **68**. Hörsaal A stellt mit 45 von 100 Personen die größte Gruppe und zieht das Gesamtmittel zu seinem Wert hin. Deshalb liegt 72.8 unterhalb des ungewichteten Werts 74.

A 14 · 2 Punkte

Klassenmitten:

$$m_1 = \frac{0 + 10}{2} = 5 \cdot m_2 = \frac{10 + 30}{2} = 20 \cdot m_3 = \frac{30 + 60}{2} = 45$$

Kontrolle: $8 + 14 + 3 = 25 = n$ ✓

$$\bar{x}_K = \frac{1}{25} (8 \cdot 5 + 14 \cdot 20 + 3 \cdot 45) = \frac{40 + 280 + 135}{25} = \frac{455}{25} = 18.2$$

Also $\bar{x}_K = 18.200$ Minuten.

Beachte: Die Klassen sind unterschiedlich breit (10, 20 und 30 Minuten) — das ändert an der Rechnung nichts. Anders als beim Histogramm wird hier **nicht** durch die Breite geteilt.

Deine Auswertung

Punkte	Was das bedeutet
28 – 34	Sehr gut. Besonders A4 und A14 (klassierte Daten) sind bare Klausurpunkte — die sitzen.
21 – 27	Gut. Rechne A1, A4 und A13 noch einmal komplett durch, dann weiter zu Tag 4.
14 – 20	Wiederhole heute Abend Schritt 5 (welches Maß wann) und Schritt 6 (klassierte Daten).
0 – 13	Arbeite Schritt 2 bis 6 morgen früh noch einmal durch (45 Minuten) und mache den Test erneut.

◆ MORGEN · TAG 4

Heute hast du das **Zentrum** der Daten bestimmt. Morgen bestimmst du, wie weit die Daten davon **wegstreuen**: Quantile, Varianz, Standardabweichung, Interquartilsabstand und der Boxplot.

Zur Vorbereitung ein Satz von heute: $\sum_i (x_i - \bar{x}) = 0$. Weil diese Summe immer null ist, kann man sie nicht als Streuungsmaß benutzen — morgen siehst du, wie man das Problem mit einem Quadrat löst.