

TAG 04

Quantile, Streuung und Boxplot

Gestern hast du das **Zentrum** gefunden. Aber zwei Datensätze können denselben Mittelwert haben und trotzdem völlig verschieden aussehen. Heute lernst du, das zu messen — und du lernst die eine R-Falle, die in dieser Vorlesung am häufigsten Punkte kostet.

ca. 3 Stunden

10 Schritte

10 Aufgaben · 24 Punkte

► R-Ecke · TR erklären

Das kannst du heute Abend

- ☐ Du bestimmst **Quantile** und **Quartile** nach der Vorlesungsregel.
- ☐ Du berechnest **Varianz** und **Standardabweichung**.
- ☐ Du benutzt den **Verschiebungssatz** als Rechenabkürzung.
- ☐ Du unterscheidest S^2 und S_*^2 — und weißt, welche R berechnet.
- ☐ Du berechnest den **Interquartilsabstand**.
- ☐ Du zeichnest einen **Boxplot** und findest **Ausreißer**.
- ☐ Du weißt, was bei $y = a + bx$ mit der Streuung passiert.

Grundlage: Vorlesung SDS1-V02 · R-Skript [02StatDS-HistogrammeMittelwertUndCo.R](#) · Probeklausur Teil A, Aufgaben 1 und 5 · Testat 1, Aufgabe 5

■ WAS DU VON GESTERN BRAUCHST

- $\bar{x} = \frac{1}{n} \sum_i x_i$ — das arithmetische Mittel.
- $x_{(i)}$ ist der i -te Wert **nach dem Sortieren**.
- Der **Median** ist der mittlere Wert; bei geradem n mittelt man die beiden inneren.
- $\sum_i (x_i - \bar{x}) = 0$ — merke dir diesen Satz, er ist heute der Ausgangspunkt.

TEIL 1 · LERNEN

1

Warum reicht das Zentrum nicht?

Zwei Datensätze, ein Mittelwert

✓ BEISPIEL · ZWEI KURSE, DIESELBE DURCHSCHNITTSNOTE

Kurs	Punkte der fünf Studierenden	$\bar{x}$
A	48 · 49 · 50 · 51 · 52	50
B	10 · 30 · 50 · 70 · 90	50

Beide Kurse haben denselben Mittelwert. Aber in Kurs A sind alle fast gleich gut, in Kurs B liegen Welten zwischen der besten und der schlechtesten Leistung. **Der Mittelwert allein verschweigt das.**

Deshalb braucht jede Beschreibung einer Verteilung **zwei** Zahlen: ein **Lagemaß** (wo liegt das Zentrum?) und ein **Streuungsmaß** (wie weit liegen die Daten davon weg?).

◆ DIE IDEE HINTER JEDEM STREUUNGSMASS

Man misst, wie weit jeder Wert vom Zentrum entfernt ist: $x_i - \bar{x}$. Dann fasst man diese Abstände zu einer Zahl zusammen.

Aber: Von gestern weißt du, dass $\sum_i (x_i - \bar{x}) = 0$ — immer. Die negativen und positiven Abweichungen heben sich auf. Man muss die Vorzeichen also loswerden. Die Statistik tut das mit dem **Quadrat**.

Der Median teilt die Daten bei 50 %. Ein **Quantil** tut dasselbe an beliebiger Stelle: Das 25 %-Quantil trennt das untere Viertel ab, das 90 %-Quantil die unteren 90 %.

• DEFINITION

Das α -Quantil x_α (mit $0 \leq \alpha \leq 1$) ist die Zahl, für die mindestens $\alpha \cdot 100\%$ der Daten kleiner oder gleich und mindestens $(1 - \alpha) \cdot 100\%$ größer oder gleich sind:

$$x_\alpha = \begin{cases} x_{([n\alpha]+1)} & n\alpha \notin \mathbb{N} \\ \in [x_{(n\alpha)}, x_{(n\alpha+1)}] & n\alpha \in \mathbb{N} \end{cases}$$

Dabei ist $[n\alpha]$ die **nächstkleinere ganze Zahl** zu $n\alpha$.

Voraussetzung: mindestens Ordinalskala.

TR · QUANTIL HESAPLAMA REÇETESİ

Formül korkutucu görünüyor ama üç adımdan ibaret. Anahtar soru: $n \cdot \alpha$ **tam sayı mı, değil mi?**

1. adım

Verileri **sırala**.

2. adım

$n \cdot \alpha$ hesapla.

tam sayı DEĞİLSE

Yukarı yuvarla, o sıradaki değeri al.

Örnek: $n\alpha = 6.5 \rightarrow 7 \rightarrow x_{(7)}$

tam sayı İSE

O sıradaki **ve bir sonraki** değer arasında herhangi bir sayı. Tek cevap için **ikisinin ortalamasını** al.

Örnek: $n\alpha = 13 \rightarrow \frac{x_{(13)} + x_{(14)}}{2}$

Neden iki farklı kural? $n\alpha$ tam sayı çıkarsa, veriyi tam o noktadan ikiye bölen **bir aralık** oluşur — tek bir değer değil. Tam sayı değilse bölme noktası iki gözlemin arasına düşer ve üstteki gözlem tek adaydır.

• DIE GEBRÄUCHLICHEN QUANTILE

Name	Quantile
Median	$x_{med} = x_{0.5}$
Quartile	$x_{0.25}, x_{0.5}, x_{0.75}$ — teilen in vier Viertel
Dezile	$x_{0.1}, x_{0.2}, \dots, x_{0.9}$ — teilen in zehn Teile
Vingtile	$x_{0.05}$ und $x_{0.95}$

$x_{0.25}$ heißt **unteres Quartil**, $x_{0.75}$ **oberes Quartil**.

3 Quartile ausrechnen

Das Beispiel aus der Vorlesung, Schritt für Schritt

✓ BEISPIEL • 26 NETTOMIETEN IN EURO

Die Werte sind bereits sortiert ($n = 26$):

77.31 104.14 116.48 132.24 158.91 163.17 **170.04** 181.98
 183.09 200.84 210.55 227.91 **243.44** **255.75** 261.98 263.21
 269.84 276.60 281.21 **311.87** 343.30 359.17 361.60 362.00
 400.05 533.92

Unteres Quartil $x_{0.25}$:

1 $n\alpha = 26 \cdot 0.25 = 6.5$ — **keine** ganze Zahl

2 Also aufrunden: $6.5 \rightarrow 7$

3 $x_{0.25} = x_{(7)} = \mathbf{170.04}$

Median $x_{0.5}$:

1 $n\alpha = 26 \cdot 0.5 = 13$ — das **ist** eine ganze Zahl

2 Also liegt der Median zwischen $x_{(13)} = 243.44$ und $x_{(14)} = 255.75$

3 Für einen eindeutigen Wert mitteln wir: $x_{0.5} = \frac{243.44 + 255.75}{2} = \mathbf{249.595 \approx 249.6}$

Oberes Quartil $x_{0.75}$:

1 $n\alpha = 26 \cdot 0.75 = 19.5$ — keine ganze Zahl

2 Aufrunden: $19.5 \rightarrow 20$

3 $x_{0.75} = x_{(20)} = \mathbf{311.87}$

▲ DER FEHLER, DER HIER PASSIERT

Viele runden 6.5 auf 6 ab („kaufmännisch runden“). **Falsch.** Bei Quantilen wird immer **aufgerundet** — die Definition sagt $[n\alpha] + 1$, also „nächstkleinere ganze Zahl *plus eins*“.

Bei 6.5 ist $[6.5] = 6$, also $6 + 1 = 7$. Bei 19.5 ist $[19.5] = 19$, also $19 + 1 = 20$.

4

Varianz und Standardabweichung

Die mittlere quadratische Abweichung

• DEFINITION

Varianz — der Durchschnitt der quadrierten Abweichungen:

$$S^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Standardabweichung — die Wurzel daraus:

$$S = \sqrt{S^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

◆ WARUM ZWEI MASSE FÜR DASSELBE?

Durch das Quadrieren wird auch die **Einheit** quadriert. Bei Mieten in Euro hat S^2 die Einheit „Euro zum Quadrat“ — das kann niemand deuten.

Die Wurzel macht das rückgängig: S **hat dieselbe Einheit wie die Daten**. Deshalb berichtet man in der Praxis fast immer S , rechnet aber mit S^2 .

✓ BEISPIEL · DIREKT NACH DEFINITION

Gegeben $x = 2, 4, 4, 6, 9$ mit $n = 5$.

1 **Mittelwert:** $\bar{x} = \frac{2 + 4 + 4 + 6 + 9}{5} = \frac{25}{5} = 5$

2 **Abweichungen:** $-3, -1, -1, 1, 4$ (Kontrolle: Summe = 0 ✓)

3 **Quadrate:** $9, 1, 1, 1, 16$ — Summe = 28

4 **Varianz:** $S^2 = \frac{28}{5} = 5.6$

5 **Standardabweichung:** $S = \sqrt{5.6} = 2.366$

Der Verschiebungssatz

Dieselbe Zahl, halb so viel Rechnen

Die Definition verlangt, dass du erst $\bar{x}$ bestimmst, dann jede einzelne Abweichung bildest und quadrierst. Bei 26 Werten ist das mühsam. Es geht kürzer.

• VERSCHIEBUNGSSATZ

$$S^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2$$

In Worten: **Mittelwert der Quadrate minus Quadrat des Mittelwerts.**

TR · VERSCHIEBUNGSSATZ NASIL KULLANILIR

Sınavda genelde sana **iki toplam** hazır verilir: $\sum x_i$ ve $\sum x_i^2$. Tam da bu formül için.

1. adım

$$\bar{x} = \frac{\sum x_i}{n} \text{ hesapla}$$

2. adım

$$\frac{\sum x_i^2}{n} \text{ hesapla}$$

3. adım

$$\text{Çıkar: } S^2 = \frac{\sum x_i^2}{n} - \bar{x}^2$$

İki sık hata: (1) $\bar{x}^2$ yerine $\bar{x}$ çıkarmak — **kareyi unutma**. (2) $(\sum x_i)^2$ ile $\sum x_i^2$ 'yi karıştırmak — bunlar **tamamen farklı** sayılardır. Önce kareler alınır, sonra toplanır.

✓ BEISPIEL 1 · PROBE MIT DEN BEKANNTEN ZAHLEN

Wieder $x = 2, 4, 4, 6, 9$, also $\bar{x} = 5$.

$$1 \quad \sum x_i^2 = 4 + 16 + 16 + 36 + 81 = 153$$

$$2 \quad \frac{1}{n} \sum x_i^2 = \frac{153}{5} = 30.6$$

$$3 \quad S^2 = 30.6 - 5^2 = 30.6 - 25 = \mathbf{5.6} \quad \checkmark$$

Dasselbe Ergebnis wie in Schritt 4 — nur ohne einzelne Abweichungen.

✓ **BEISPIEL 2 · AUS DER VORLESUNG (MIETSPIEGEL)**

Gegeben sind $\frac{1}{n} \sum x_i^2 = 72\,616.82$ und $\bar{x} = 250.02$.

1 $S^2 = 72\,616.82 - (250.02)^2 = 72\,616.82 - 62\,510.00 = \mathbf{10\,106.82}$

2 $S = \sqrt{10\,106.82} = \mathbf{100.53}$ Euro

✓ **BEISPIEL 3 · ECHTE KLAUSURAUFGABE MIT 0/1-DATEN**

Aus der Probeklausur, Aufgabe 1: 20 Vorhersagen, davon 11-mal die 0 und 9-mal die 1.

1 $\bar{x} = \frac{9}{20} = 0.45$

2 Weil $0^2 = 0$ und $1^2 = 1$, gilt $\sum x_i^2 = 9$, also $\frac{1}{n} \sum x_i^2 = \frac{9}{20} = 0.45$

3 $S^2 = 0.45 - 0.45^2 = 0.45 - 0.2025 = 0.2475 \approx \mathbf{0.248}$

Kleiner Trick für 0/1-Daten: Dort gilt immer $S^2 = \bar{x}(1 - \bar{x})$. Probe: $0.45 \cdot 0.55 = 0.2475$ ✓

6 S^2 oder S_*^2 ?

Die Falle, die in dieser Vorlesung am meisten Punkte kostet

Es gibt **zwei** Varianzformeln. Sie unterscheiden sich nur im Nenner — aber die Ergebnisse sind verschieden, und R benutzt nicht die, die du erwartest.

• **DIE BEIDEN VARIANTEN**

Verzerrt (Nenner n) — die Definition aus Schritt 4:

$$S^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Unverzerrt (Nenner $n - 1$):

$$S_*^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

S_*^2 hat bessere theoretische Eigenschaften — warum genau, lernst du an **Tag 14** (Erwartungstreue). Für heute reicht: Es gibt beide, und du musst wissen, welche gemeint ist.

◆ DIE UMRECHNUNG

$$n \cdot S^2 = (n - 1) \cdot S_*^2 \quad \Longleftrightarrow \quad S_*^2 = \frac{n}{n - 1} S^2$$

Beide enthalten dieselbe Summe $\sum (x_i - \bar{x})^2$ — nur anders geteilt. Mit dieser Zeile kannst du jederzeit zwischen den beiden wechseln. Sie taucht bei den **Konfidenzintervallen** an Tag 15 wieder auf.

✓ BEISPIEL · WIEDER $x = 2, 4, 4, 6, 9$

Die Summe der quadrierten Abweichungen war 28, und $n = 5$.

Variante	Rechnung	Ergebnis
S^2 (verzerrt)	$28/5$	5.600
S_*^2 (unverzerrt)	$28/4$	7.000

Probe der Umrechnung: $\frac{5}{4} \cdot 5.6 = 7 \checkmark \quad \cdot \quad 5 \cdot 5.6 = 28 = 4 \cdot 7 \checkmark$

▲ WAS R TUT — HIER MUSST DU AUFPASSEN

Der R-Befehl `var()` berechnet S_*^2 , also die Variante mit $n - 1$. Ebenso `sd()`, das $\sqrt{S_*^2}$ liefert.

Wenn eine Aufgabe nach der **empirischen Varianz** S^2 fragt und dir einen R-Output mit `var(x)` vorlegt, musst du **umrechnen**:

$$S^2 = \frac{n - 1}{n} \cdot \text{var}(x)$$

Die Tutorienlösungen führen genau das als **häufige Fehlerquelle** auf. Schreibe dir diese Zeile auf dein Formelblatt.

S^2

Bölen **n**. Derste "empirische Varianz" dendiğinde bu kastedilir.
Probeklausur A1'in cevabı da buydu (0.248).

 S_*^2

Bölen **n-1**. "unverzerrt" / "erwartungstreu" kelimesi geçiyorsa bu.
Konfidenzintervall'lerde hep bu kullanılır.

R: var(x)

Her zaman S_*^2 verir — yani n-1'li olan. R'da n'li versiyonu veren hazır komut **yoktur**.

Kural: Soruda "unverzerrt", "erwartungstreu" veya bir Konfidenzintervall geçiyorsa → S_*^2 . Sadece "Varianz" veya "empirische Varianz" diyorsa → S^2 . Emin değilsen **hangisini kullandığını yaz** — gerekçeli cevap kısmi puan alır.

7

Der Interquartilsabstand

Ein robustes Streuungsmaß

• DEFINITION

$$d_Q = \text{IQR} = x_{0.75} - x_{0.25}$$

Der **Interquartilsabstand** ist die Breite des Bereichs, in dem die **mittleren 50 %** der Daten liegen.

◆ WARUM MAN IHN BRAUCHT

Die Varianz quadriert die Abweichungen — ein einziger Ausreißer wird dadurch **enorm** gewichtet. Der IQR schaut gar nicht auf die Ränder, sondern nur auf die Mitte. Er ist damit **robust**, genau wie der Median.

Faustregel: Berichstest du den **Median**, passt der **IQR** dazu. Berichstest du den **Mittelwert**, passt die **Standardabweichung** dazu.

✓ BEISPIEL · DIE 26 MIETEN

Aus Schritt 3: $x_{0.25} = 170.04$ und $x_{0.75} = 311.87$.

$$\text{IQR} = 311.87 - 170.04 = \mathbf{141.83 \text{ Euro}}$$

Aussage: Die mittlere Hälfte der Wohnungen liegt in einem Preisband von rund 142 Euro Breite.

• DIE REGELN FÜR $Y_I = A + B X_I$

Maß	wird zu
Varianz	$s^2 \mapsto b^2 s^2$
Standardabweichung	$s \mapsto b s$
Interquartilsabstand	$\text{IQR} \mapsto b \text{IQR}$

Für $b > 0$ — der übliche Fall — kannst du die Betragsstriche weglassen. Sie sind nur nötig, falls b negativ ist, denn eine Streuung ist nie negativ.

◆ DAS ENTSCHEIDENDE: A FÄLLT WEG

Beim **Lagemaß** wirken beide: $\bar{y} = a + b\bar{x}$. Beim **Streuungsmaß** wirkt nur b . Der Summand a taucht nirgends auf.

Warum? Wenn du zu allen Werten dieselbe Zahl addierst, verschiebst du die ganze Verteilung — die Abstände zwischen den Punkten bleiben unverändert. Streuung misst genau diese Abstände.

✓ BEISPIEL

Ein Datensatz hat $s^2 = 16$, also $s = 4$. Transformation $y = 100 + 3x$:

- 1 $s_y^2 = 3^2 \cdot 16 = 9 \cdot 16 = 144$
- 2 $s_y = |3| \cdot 4 = 12$ (Probe: $\sqrt{144} = 12$ ✓)
- 3 Die 100 spielt **keine Rolle**.

▲ DAS QUADRAT NICHT VERGESSEN

Bei der Varianz wird b **quadriert**, bei der Standardabweichung nicht. Wer $s^2 \mapsto b s^2$ schreibt, verliert den Punkt. Merke: Die Varianz lebt in quadrierten Einheiten, also muss auch der Faktor quadriert werden.

• DIE FÜNF-PUNKTE-ZUSAMMENFASSUNG

Ein Boxplot zeigt fünf Werte auf einen Blick:

1. das Minimum x_{min}
2. das untere Quartil $x_{0.25}$
3. den Median x_{med}
4. das obere Quartil $x_{0.75}$
5. das Maximum x_{max}

Die **Box** geht von $x_{0.25}$ bis $x_{0.75}$ — in ihr liegt also die mittlere Hälfte der Daten, und ihre Breite ist genau der **IQR**.

• DIE AUSREISSERREGEL


Ein Wert gilt als **Ausreißer**, wenn er mehr als $1.5 \cdot \text{IQR}$ von der Box entfernt liegt. Die beiden Grenzen („Zäune“) sind:

$$x_{0.25} - 1.5 \cdot \text{IQR} \quad \text{und} \quad x_{0.75} + 1.5 \cdot \text{IQR}$$

Ausreißer werden als **einzelne Punkte** gezeichnet. Die **Whisker** (die Striche links und rechts) reichen dann nur bis zum äußersten Wert, der *kein* Ausreißer ist.

✓ BEISPIEL • DIE 26 MIETEN KOMPLETT DURCHGERECHNET

- 1 **Fünf Punkte:** $x_{min} = 77.31$, $x_{0.25} = 170.04$, $x_{med} = 249.60$, $x_{0.75} = 311.87$, $x_{max} = 533.92$
- 2 **IQR:** $311.87 - 170.04 = 141.83$
- 3 $1.5 \cdot \text{IQR}$: $1.5 \cdot 141.83 = 212.745$
- 4 **Zaun unten:** $170.04 - 212.745 = -42.705 \rightarrow$ kein Wert liegt darunter (Minimum ist 77.31), also **keine** Ausreißer unten
- 5 **Zaun oben:** $311.87 + 212.745 = 524.615 \rightarrow$ der Wert $533.92 > 524.615$ ist ein **Ausreißer**
- 6 **Whisker oben:** reicht bis zum größten Nicht-Ausreißer, also bis **400.05**



Der Whisker rechts endet bei **400.05**, nicht beim Maximum — denn 533.92 wurde als Ausreißer aussortiert und separat als Kreis gezeichnet.

TR · BOXPLOT ÇİZME REÇETESİ

1. adım Beş sayıyı bul: min, $x_{0.25}$, medyan, $x_{0.75}$, max
2. adım IQR = $x_{0.75} - x_{0.25}$ hesapla
3. adım Çitleri hesapla: $x_{0.25} - 1.5 \text{ IQR}$ ve $x_{0.75} + 1.5 \text{ IQR}$
4. adım Çitlerin **dışındaki** değerleri ayrı nokta olarak çiz → Ausreißer
5. adım Whisker'ları çitlere değil, **çit içindeki en uç gerçek değere** kadar uzat

En sık hata: Whisker'ı çite kadar çizmek. Çit sadece bir **hesap sınırı**; çizgi her zaman **gerçek bir veri noktasında** biter. Örnekte çit 524.615 ama whisker 400.05'te duruyor.

◆ WAS MAN AUS EINEM BOXPLOT ABLEIST

- **Zentrum:** wo die Medianlinie liegt
- **Streuung:** wie breit die Box ist (= IQR)
- **Schiefe:** Liegt der Median *nicht* in der Mitte der Box, ist die Verteilung schief. Sitzt er links und ist der rechte Whisker länger → **rechtsschief**.
- **Extremwerte:** die einzeln gezeichneten Punkte

Im Beispiel: Median 249.60 liegt fast mittig in der Box, aber rechts gibt es einen langen Whisker und einen Ausreißer → leicht **rechtsschief**.

► R · QUANTILE

```
x <- c(22, 12, 8, 20, 35, 20, 18, 60, 15, 20)

quantile(x, 0.5)           # Median
quantile(x, 0.25)          # unteres Quartil
quantile(x, 0.75)          # oberes Quartil

# mehrere auf einmal
quantile(x, c(0.25, 0.5, 0.75))

# alle fünf Punkte des Boxplots
summary(x)
```

TR · QUANTILE() VE BİR UYARI

```
quantile(x, 0.25)
```

%25 kuantili. İkinci argüman α değeridir, 0 ile 1 arası.

```
quantile(x, c(...))
```

Birden fazla α verip hepsini birden alabilirsin.

```
summary(x)
```

Min, 1. Quartil, Median, Mittelwert, 3. Quartil, Max — hepsi tek satırda.

Dikkat: R'in `quantile()` fonksiyonu varsayılan olarak **interpolasyon** yapar (type 7) ve derste öğrendiğin kuraldan **farklı** sonuç verebilir. Elle hesapta **her zaman ders kuralını** kullan (Schritt 2). R'in sayısı birebir tutmazsa panik yapma — sınavda istenen ders kuralıdır.

► R · VARIANZ UND STANDARDABWEICHUNG

```
var(x)                # ACHTUNG: das ist  $S^2_{*}$  (Nenner  $n-1$ )
sd(x)                 # Wurzel daraus

# Die empirische Varianz  $S^2$  (Nenner  $n$ ) selbst bauen:
n <- length(x)
S2 <- (n - 1) / n * var(x)
S2

# Probe über die Definition:
mean((x - mean(x))^2)  # liefert dasselbe  $S^2$ 

# Interquartilsabstand
quantile(x, 0.75) - quantile(x, 0.25)
IQR(x)                 # kürzer, dasselbe Ergebnis
```

TR · BUGÜNÜN EN ÖNEMLİ R SATIRI

`var(x)` sana S_*^2 verir, yani **n-1**'li olanı. Derste "empirische Varianz" S^2 ise **n**'lidir. Bu ikisi farklıdır.

`var(x)`

S_*^2 — unverzerrt, bölen n-1

`(n-1)/n * var(x)`

S^2 — empirische Varianz, bölen n

`mean((x - mean(x))^2)`

Aynı S^2 'yi tanımdan doğrudan kurar. Kontrol için ideal.

`sd(x)`

$\sqrt{S_*^2}$ — yani o da n-1'li

Bu satırı Formelsammlung'a yaz: $S^2 = \frac{n-1}{n} \cdot \text{var}(x)$. Tutorium çözümleri bunu "häufige Fehlerquelle" olarak işaretlemiş — yani bilerek tuzak kuruyor.

► R · BOXPLOT

```
boxplot(x,
  range      = 1.5,           # Faktor der Ausreißerregel
  main       = "Boxplot",
  ylab       = "Zimmergröße in qm",
  horizontal = FALSE)        # TRUE = liegend
```

Die Zahlen hinter der Grafik abrufen:

```
b <- boxplot(x, plot = FALSE)
b$stats      # die fünf Punkte
b$out        # die Ausreißer
```

TR · BOXPLOT() ARGÜMANLARI

`range = 1.5`

Ausreißer kuralındaki **1.5** çarpanı. Varsayılan zaten 1.5; `range = 0` yazarsan whisker'lar min ve max'a kadar uzar ve hiç Ausreißer gösterilmez.

`horizontal = TRUE`

Kutuyu **yatay** çizer. Varsayılan dikey (FALSE).

`plot = FALSE`

Çizme, sadece **hesapla**. Sayıları okumak istediğinde kullanılır.

`b$stats`

Beş nokta: alt whisker, $x_{0.25}$, medyan, $x_{0.75}$, üst whisker.

`b$out`

Ausreißer listesi. Boşsa hiç Ausreißer yok demektir.

Not: `b$stats`'taki ilk ve son değer **min/max değil**, whisker uçlarıdır — yani Ausreißer olmayan en uç değerler. Schritt 9'daki örnekte bu 400.05 olurdu, 533.92 değil.

✓ MACH DAS JETZT SELBST

1. Tippe den Vektor `x` ab und vergleiche `var(x)` mit `mean((x - mean(x))^2)`. Die Zahlen sind **verschieden** — genau darum geht es in Schritt 6.
2. Rechne `(n-1)/n * var(x)` und prüfe, dass jetzt beide übereinstimmen.
3. Zeichne den Boxplot. Der Wert 60 sollte als Ausreißer erscheinen — rechne die Zäune von Hand nach und prüfe, ob R dasselbe entscheidet.

■ WORTSCHATZ · LEICHT ERKLÄRT

Streuungsmaß — wie weit die Daten vom Zentrum wegliegen

Variabilität — dasselbe, anderes Wort

Quantil x_α — der Wert, unter dem $\alpha \cdot 100\%$ der Daten liegen

Quartil — Viertel-Quantil: $x_{0.25}$, $x_{0.5}$, $x_{0.75}$

unteres / oberes Quartil — $x_{0.25}$ bzw. $x_{0.75}$

Varianz S^2 — mittlere quadratische Abweichung

Standardabweichung S — Wurzel der Varianz, gleiche Einheit wie die Daten

Verschiebungssatz — die Abkürzung $\frac{1}{n} \sum x_i^2 - \bar{x}^2$

verzerrt — die Variante mit Nenner n

unverzerrt / erwartungstreu — die Variante mit Nenner $n - 1$

Interquartilsabstand (IQR) — $x_{0.75} - x_{0.25}$

robust — reagiert wenig auf Ausreißer

Boxplot — Fünf-Punkte-Bild einer Verteilung

Whisker — die Striche links und rechts der Box

Ausreißer — Wert außerhalb von $1.5 \cdot \text{IQR}$ um die Box

Spannweite — $x_{\max} - x_{\min}$ (das einfachste, aber unrobusteste Maß)

Spickzettel Tag 4

Quantil-Regel

$n\alpha$ keine ganze Zahl $\rightarrow$ aufrunden, $x_\alpha = x_{([n\alpha]+1)}$ | $n\alpha$ ganze Zahl $\rightarrow \frac{x_{(n\alpha)} + x_{(n\alpha+1)}}{2}$

Varianz

$$S^2 = \frac{1}{n} \sum_i (x_i - \bar{x})^2$$

Verschiebungssatz

$$S^2 = \frac{1}{n} \sum_i x_i^2 - \bar{x}^2$$

Standardabweichung

$S = \sqrt{S^2}$ — gleiche Einheit wie die Daten

Unverzerrt

$$S_*^2 = \frac{1}{n-1} \sum_i (x_i - \bar{x})^2$$

Umrechnung · aufs Formelblatt!

$$nS^2 = (n-1)S_*^2 \cdot S_*^2 = \frac{n}{n-1}S^2 \cdot$$

R:

`var(x)` ist S_*^2 , also $S^2 = \frac{n-1}{n} \cdot \text{var}(x)$

IQR

$$\text{IQR} = x_{0.75} - x_{0.25}$$

0/1-Daten

$$S^2 = \bar{x}(1 - \bar{x})$$

Transformation $y = a + bx$

$$s^2 \mapsto b^2 s^2 \cdot s \mapsto |b|s \cdot \text{IQR} \mapsto |b| \text{IQR} \cdot a \text{ hat}$$

keinen

Einfluss

Boxplot

Fünf Punkte: $\min \cdot x_{0.25} \cdot x_{\text{med}} \cdot x_{0.75} \cdot \max$ · Zäune: $x_{0.25} - 1.5 \text{IQR}$ und $x_{0.75} + 1.5 \text{IQR}$ · Whisker enden am äußersten

Nicht-Ausreißer

Welches Paar berichten?

Mittelwert + Standardabweichung | Median + IQR

R

`quantile()` · `summary()` · `var()` = S_*^2 · `sd()` · `IQR()` · `boxplot(x, range=1.5)` · `b$stats` · `b$out`

Teste dich selbst

10 Aufgaben · 24 Punkte · Taschenrechner erlaubt · ca. 50 Minuten.

Klausurregeln: Dezimal**punkt** · Zwischenergebnisse auf **vier**, Endergebnisse auf **drei** Nachkommastellen · Lösungsweg angeben, wo verlangt.

Beantworte jede Teilaufgabe. Letztes Mal hast du 6 von 8 verlorenen Punkten allein dadurch verloren, dass Teilaufgaben leer blieben.

A 1 Gegeben sind $n = 8$ Werte (bereits sortiert): (3 Punkte)

4 · 7 · 9 · 12 · 15 · 18 · 22 · 31

Bestimmen Sie (a) $x_{0.25}$, (b) $x_{0.5}$, (c) $x_{0.75}$. Geben Sie bei jedem Quantil an, ob $n\alpha$ ganzzahlig war.

A 2 Für einen Datensatz mit $n = 10$ ist gegeben: $\sum_{i=1}^{10} x_i = 60$ und $\sum_{i=1}^{10} x_i^2 = 430$. (3 Punkte)

- (a) Berechnen Sie $\bar{x}$.
- (b) Berechnen Sie S^2 mit dem Verschiebungssatz. Lösungsweg angeben.
- (c) Berechnen Sie S .

A 3 Ein R-Output liefert für $n = 25$ Beobachtungen `var(x)` = 48. (3 Punkte)

- (a) Welche der beiden Varianzformeln hat R berechnet?
- (b) Bestimmen Sie daraus die empirische Varianz S^2 (Nenner n).
- (c) Bestimmen Sie $\sum_{i=1}^n (x_i - \bar{x})^2$.

A 4 Ein Datensatz hat $x_{0.25} = 20$ und $x_{0.75} = 32$. (3 Punkte)

- (a) Berechnen Sie den Interquartilsabstand.
- (b) Berechnen Sie beide Zäune der Ausreißerregel.
- (c) Sind die Werte 2 und 50 Ausreißer? Begründen Sie jeweils.

A 5 Ein Merkmal hat $s^2 = 25$ und $\text{IQR} = 8$. Alle Werte werden mit $y_i = 50 + 4x_i$ transformiert. (2 Punkte)

- (a) Bestimmen Sie s_y^2 , s_y und IQR_y .
- (b) Warum spielt die 50 keine Rolle?

A 6 Richtig oder falsch? (2 Punkte)

- ☐ a Die Standardabweichung hat dieselbe Einheit wie die Daten.
- ☐ b Der IQR ist robuster gegenüber Ausreißern als die Standardabweichung.
- ☐ c Es gilt immer $S^2 > S_*^2$.
- ☐ d In einem Boxplot enden die Whisker immer genau bei Minimum und Maximum.

A 7 Bei einer Umfrage wurde erfasst, ob eine Person Rad fährt (1 = ja, 0 = nein). Von $n = 50$ Personen antworteten 30 mit „ja“. (2 Punkte)

- (a) Berechnen Sie $\bar{x}$ und interpretieren Sie den Wert in einem Satz.
- (b) Berechnen Sie S^2 .

A 8 Zwei Boxplots derselben Größe werden verglichen. Bei Verteilung A liegt der Median genau in der Mitte der Box und beide Whisker sind gleich lang. Bei Verteilung B sitzt der Median nahe am unteren Rand der Box und der obere Whisker ist deutlich länger. (2 Punkte)

Welche Form hat jede der beiden Verteilungen? Begründen Sie kurz.

A 9 Lesen Sie den R-Output. (2 Punkte)

```
> b <- boxplot(miete, plot = FALSE)
> b$stats
      [,1]
[1,]  77.31
[2,] 170.04
[3,] 249.60
[4,] 311.87
[5,] 400.05

> b$out
[1] 533.92
```

- (a) Wofür stehen die fünf Werte in `b$stats` ?
(b) Warum steht in Zeile [5,] der Wert 400.05 und nicht 533.92?

A 10 R-Aufgabe. (2 Punkte)

```
x <- c(2, 4, 4, 6, 9)

var(x)
mean((x - mean(x))^2)
```

- (a) Welche Zahl gibt jede der beiden Zeilen aus?
(b) Warum sind die Ergebnisse verschieden? Mit welchem Faktor rechnet man um?

Lösungen

Vergleiche ehrlich. Jeden Fehler ins Fehlerheft: *Was war die Frage? Warum war ich falsch?*

A 1 · 3 Punkte

Die Werte mit Positionen: $x_{(1)} = 4$, $x_{(2)} = 7$, $x_{(3)} = 9$, $x_{(4)} = 12$, $x_{(5)} = 15$, $x_{(6)} = 18$, $x_{(7)} = 22$, $x_{(8)} = 31$. $n = 8$.

(a) $n\alpha = 8 \cdot 0.25 = 2$ — **ganzzahlig**.

$$\text{Also } x_{0.25} = \frac{x_{(2)} + x_{(3)}}{2} = \frac{7 + 9}{2} = 8$$

(b) $n\alpha = 8 \cdot 0.5 = 4$ — **ganzzahlig**.

$$\text{Also } x_{0.5} = \frac{x_{(4)} + x_{(5)}}{2} = \frac{12 + 15}{2} = 13.5$$

(c) $n\alpha = 8 \cdot 0.75 = 6$ — **ganzzahlig**.

$$\text{Also } x_{0.75} = \frac{x_{(6)} + x_{(7)}}{2} = \frac{18 + 22}{2} = 20$$

Hier waren **alle drei** $n\alpha$ ganzzahlig — das passiert bei $n = 8$ und diesen α -Werten immer. Wer hier stur aufrundet, bekommt drei falsche Zahlen.

A 2 · 3 Punkte

(a) $\bar{x} = \frac{60}{10} = 6$

(b) Verschiebungssatz:

$$S^2 = \frac{1}{n} \sum x_i^2 - \bar{x}^2 = \frac{430}{10} - 6^2 = 43 - 36 = 7$$

Also $S^2 = 7.000$

(c) $S = \sqrt{7} = 2.6458 \approx 2.646$

Häufiger Fehler bei (b): $43 - 6 = 37$ rechnen, also das **Quadrat** des Mittelwerts vergessen.

A 3 · 3 Punkte

(a) R berechnet mit `var()` immer die **unverzerrte Variante** S_*^2 mit Nenner $n - 1$. Also $S_*^2 = 48$.

(b) Umrechnung mit $n = 25$:

$$S^2 = \frac{n-1}{n} S_*^2 = \frac{24}{25} \cdot 48 = 0.96 \cdot 48 = 46.08$$

Also $S^2 = \mathbf{46.080}$

(c) Die Summe der quadrierten Abweichungen bekommst du aus jeder der beiden:

$$\sum_i (x_i - \bar{x})^2 = (n-1) S_*^2 = 24 \cdot 48 = 1152$$

Probe über die andere Formel: $n \cdot S^2 = 25 \cdot 46.08 = 1152 \checkmark$ — also **1152**.

A 4 · 3 Punkte

(a) $\text{IQR} = 32 - 20 = \mathbf{12}$

(b) $1.5 \cdot \text{IQR} = 1.5 \cdot 12 = 18$

Zaun unten: $20 - 18 = \mathbf{2}$ · Zaun oben: $32 + 18 = \mathbf{50}$

(c) Die Regel lautet „**mehr als** 1.5 IQR Abstand“. Beide Werte liegen **genau auf** dem Zaun, nicht darüber hinaus:

- Der Wert 2 liegt genau auf dem unteren Zaun → **kein Ausreißer**
- Der Wert 50 liegt genau auf dem oberen Zaun → **kein Ausreißer**

Ein Wert von 1 oder von 51 wäre dagegen ein Ausreißer. Wer hier „beide sind Ausreißer“ schreibt, hat die Grenze richtig, aber die Ungleichung falsch gelesen.

A 5 · 2 Punkte

(a) Mit $a = 50$ und $b = 4$:

$$s_y^2 = b^2 s^2 = 16 \cdot 25 = \mathbf{400} \quad s_y = |b| s = 4 \cdot 5 = \mathbf{20} \quad \text{IQR}_y = |b| \text{IQR} = 4 \cdot 8 = \mathbf{32}$$

Probe: $\sqrt{400} = 20 \checkmark$

(b) Weil das Addieren einer Konstanten alle Werte um denselben Betrag **verschiebt**. Die **Abstände zwischen den Werten** bleiben dabei unverändert — und genau diese Abstände misst ein Streuungsmaß. Nur der Faktor b staucht oder streckt die Daten.

A 6 · 2 Punkte

- a) **richtig**. Die Wurzel macht das Quadrieren der Einheit rückgängig. Genau deshalb berichtet man S statt S^2 .
- b) **richtig**. Der IQR benutzt nur die beiden Quartile und ignoriert die Ränder völlig.
- c) **falsch**. Es gilt immer $S^2 < S_*^2$, denn beide haben denselben Zähler, aber S^2 teilt durch das **größere** n . Beispiel aus Schritt 6: $5.6 < 7$.
- d) **falsch**. Gibt es Ausreißer, enden die Whisker beim äußersten **Nicht-Ausreißer**. Nur wenn kein Ausreißer existiert, fallen Whiskerende und Minimum bzw. Maximum zusammen.

A 7 · 2 Punkte

(a) $\bar{x} = \frac{30}{50} = \mathbf{0.600}$

Interpretation: 60 % der befragten Personen fahren Rad. Bei einem 0/1-kodierten Merkmal ist das arithmetische Mittel genau der **Anteil der Einsen**.

(b) Mit der Kurzformel für 0/1-Daten:

$$S^2 = \bar{x}(1 - \bar{x}) = 0.6 \cdot 0.4 = 0.24$$

Also $S^2 = \mathbf{0.240}$. Probe über den Verschiebungssatz: $\frac{1}{n} \sum x_i^2 = \frac{30}{50} = 0.6$, also $S^2 = 0.6 - 0.36 = 0.24$ ✓

A 8 · 2 Punkte

Verteilung A: symmetrisch. Der Median teilt die Box in zwei gleiche Hälften und beide Whisker sind gleich lang — die Daten liegen links und rechts des Zentrums gleich verteilt.

Verteilung B: rechtsschief (= linkssteil). Der Median nahe am *unteren* Rand bedeutet, dass sich die untere Hälfte der Daten auf einem engen Bereich drängt, während die obere Hälfte weit gestreut ist. Der lange obere Whisker zeigt den Ausläufer nach rechts.

A 9 · 2 Punkte

(a) Von oben nach unten:

Zeile	Wert	Bedeutung
[1,]	77.31	unteres Whiskerende
[2,]	170.04	unteres Quartil $x_{0.25}$
[3,]	249.60	Median $x_{0.5}$
[4,]	311.87	oberes Quartil $x_{0.75}$
[5,]	400.05	oberes Whiskerende

(b) Weil 533.92 ein **Ausreißer** ist — deshalb steht er separat in `b$out`. Der Whisker endet immer beim äußersten Wert **innerhalb** des Zauns.

Nachrechnen: $IQR = 311.87 - 170.04 = 141.83$, Zaun oben = $311.87 + 1.5 \cdot 141.83 = 524.615$. Da $533.92 > 524.615$, ist der Wert ein Ausreißer; der größte Wert darunter ist 400.05.

A 10 · 2 Punkte

(a)

```
var(x)           #> [1] 7
mean((x - mean(x))^2) #> [1] 5.6
```

(b) Weil beide **verschiedene Formeln** benutzen. Mit $\bar{x} = 5$ und $\sum (x_i - \bar{x})^2 = 28$:

- `var(x)` teilt durch $n - 1 = 4 \rightarrow S_*^2 = 28/4 = 7$
- `mean((x - mean(x))^2)` teilt durch $n = 5 \rightarrow S^2 = 28/5 = 5.6$

Umrechnungsfaktor: $S^2 = \frac{n-1}{n} S_*^2 = \frac{4}{5} \cdot 7 = 5.6 \checkmark$ und umgekehrt $S_*^2 = \frac{n}{n-1} S^2 = \frac{5}{4} \cdot 5.6 = 7 \checkmark$

Deine Auswertung

Punkte	Was das bedeutet
20 – 24	Sehr gut. Damit ist die gesamte beschreibende Statistik für ein Merkmal abgedeckt — 35 % des A-Teils.
15 – 19	Gut. Rechne A1 und A3 noch einmal durch — Quantilregel und S^2/S_*^2 sind die beiden Klausurfallen.
10 – 14	Wiederhole heute Abend Schritt 2 (Quantilregel) und Schritt 6 (S^2 gegen S_*^2).
0 – 9	Arbeite Schritt 2 bis 7 morgen früh noch einmal durch (45 Minuten) und mache den Test erneut.

◆ WAS DU JETZT KANNST

Mit Tag 2, 3 und 4 zusammen beherrschst du die **beschreibende Statistik für ein einzelnes Merkmal** vollständig: Häufigkeiten, Histogramm, Verteilungsfunktion, Lage und Streuung. In der Probeklausur sind das die Aufgaben 1 und 2 — **24 von 75 Punkten**.

Als Nächstes kommt der Schritt zu **zwei** Merkmalen gleichzeitig: Kontingenztafel und Chi-Quadrat, danach Korrelation und Regression. Dort warten weitere 11 Punkte.