

TAG 05

Kontingenztafel und Chi-Quadrat

Bis gestern hast du immer **ein** Merkmal allein betrachtet. Ab heute stellst du die spannendere Frage: **Hängen zwei Merkmale zusammen?** Du baust Tabellen, liest Anteile richtig herum ab und misst den Zusammenhang mit einer einzigen Zahl.

ca. 3 Stunden

10 Schritte

14 Aufgaben · 36 Punkte

▶ R-Ecke · TR açıklamalı

Das kannst du heute Abend

- ☐ Du baust aus Rohdaten oder aus einem **Text** eine **Kontingenztafel**.
- ☐ Du bestimmst **Randverteilungen** und **relative Häufigkeiten**.
- ☐ Du berechnest **bedingte Verteilungen** — und teilst immer durch die richtige Zahl.
- ☐ Du erkennst an Zahlen, ob zwei Merkmale **unabhängig** sind.
- ☐ Du berechnest **erwartete Häufigkeiten** und den χ^2 -**Koeffizienten**.
- ☐ Du erzeugst all das in R mit `table()`, `prop.table()` und `cut()`.

Grundlage: Vorlesung SDS1-V03 (Folien 1–23) · R-Skript `03StatDS-Zusammenhänge.R` · Tutorium 3, Aufgabe 2 · Testat 2, Aufgabe 3 · Ausblick: V06 (bedingte Verteilung), V12 (χ^2 -Test)

Dein Tag auf einen Blick

Erst lesen, dann loslegen · 3 Minuten

1

Tafel bauen

Schritt 1–2 · 25 min

2

Ränder & Anteile

Schritt 3–4 · 20 min

3

Bedingte Verteilung

Schritt 5 · 30 min

4

Unabhängigkeit

Schritt 6–7 · 30 min

5

χ^2 -Koeffizient

Schritt 8–9 · 30 min

R

R-Ecke

Schritt 10 · 25 min

7

Spickzettel

abschreiben · 5 min

📝

Test

14 Aufgaben · 70 min

Klausur-Radar · Wo kommt das dran?

Ehrlich gesagt: In der Probeklausur gibt es **keine** eigene Kontingenztafel-Aufgabe. Trotzdem ist dieser Tag Pflicht — denn drei Klausurthemen bauen direkt darauf auf.

Probeklausur A3

Bayes · Vierfeldertafel und bedingte Anteile

„Anteil unter den ...“ — genau Schritt 5 · kommt an Tag 8

11 P

Teil B (R)

`cut()` + `table()` + Randverteilung

so im Testat 2 geprüft · Schritt 10

≈ 6 P

V12 · Tag 17

χ^2 -Unabhängigkeitstest

benutzt exakt $\tilde{h}_{jk}$ und χ^2 von heute

Test

Dein persönlicher Fokus · aus deinem Tag-3-Test

Teilaufgaben leer gelassen

Bei A4 und A14 fehlten ganze Teile.

→ Heute hat jede Teilaufgabe ein eigenes Feld (a), (b), (c). Keins bleibt leer.

„Begründen“ im Kreis

„Weil es so ist“ bringt 0 Punkte.

→ Die grünen Kästen „So schreibst du es“ geben dir fertige Sätze mit Zahlen.

Position um eins verrutscht

Median 550 statt 530.

→ Heute: immer prüfen, ob die Randsummen wirklich n ergeben.

Runden

797.142 statt 797.143.

→ Zwischenwerte 4 Stellen, Ende 3 Stellen. Jede Lösung zeigt beides.

■ DIE NEUEN SYMBOLE VON HEUTE

h_{jk} — wie oft die Kombination „Zeile j , Spalte k “ vorkommt

$h_{j\bullet}$ — Summe der Zeile j (der Punkt heißt: „über alle Spalten summiert“)

$h_{\bullet k}$ — Summe der Spalte k (der Punkt steht vorne: „über alle Zeilen summiert“)

$\tilde{h}_{jk}$ — die Häufigkeit, die man bei Unabhängigkeit **erwarten** würde (lies: „h-Schlange“)

χ^2 — „Chi-Quadrat“, eine Zahl für die Stärke des Zusammenhangs

1

Warum zwei Merkmale gemeinsam?

Die Geburtsstunde der Epidemiologie

V03 · FOLIE 4–7

KERN Einen Zusammenhang sieht man nur, wenn man beide Merkmale **für dieselben Einheiten** gleichzeitig betrachtet.

✓ BEISPIEL · CHOLERA IN LONDON, 1854

Damals glaubte man, Cholera komme aus „üblem Dunst“. Der Arzt John Snow notierte für jedes Haus **zwei** Merkmale: den Wasserversorger und ob es Cholera-Tote gab.

Wasserversorger	Häuser	Cholera-Tote	Tote je 1000 Häuser
Southwark & Vauxhall	40 046	1 263	31.54
Lambeth	26 107	98	3.75

Rechnung: $\frac{1263}{40046} \cdot 1000 = 31.54$ und $\frac{98}{26107} \cdot 1000 = 3.75$. Bei Southwark & Vauxhall starben **achtmal so viele** Menschen je Haus. Das Wasser war verschmutzt.

Hätte man nur „Wasserversorger“ oder nur „Cholera ja/nein“ angeschaut, hätte man nichts gesehen. Erst die **gemeinsame Verteilung** zeigt den Zusammenhang.

• ZWEI BEGRIFFE

Gemeinsame Verteilung: wie sich zwei Merkmale X und Y **zusammen** verhalten. Grundlage sind Paare (x_i, y_i) für dieselben Einheiten $i = 1, \dots, n$.

Randverteilung: die Verteilung von nur **einem** der beiden Merkmale — so, als gäbe es das andere nicht.

◆ DER WICHTIGSTE SATZ AUS FOLIE 8–9

Aus der gemeinsamen Verteilung kann man die Randverteilungen **immer** ausrechnen. Umgekehrt geht das **nur**, wenn X und Y **unabhängig** sind. Die gemeinsame Verteilung enthält also **mehr Information**.

KERN Eine Kontingenztafel zählt, wie oft **jede Kombination** von zwei Merkmalen vorkommt.

✓ **BEISPIEL · 12 STUDIERENDE, ZWEI FRAGEN**

X = Wohnform (WG, Eltern, allein) · Y = isst regelmäßig in der Mensa (ja, nein)

Person	1	2	3	4	5	6	7	8	9	10	11	12
x_i	WG	Eltern	WG	allein	WG	Eltern	allein	WG	Eltern	allein	WG	Eltern
y_i	ja	nein	ja	nein	nein	nein	ja	ja	ja	nein	ja	nein

So zählst du: Geh die Personen der Reihe nach durch und mach für jedes Paar einen Strich in die passende Zelle.

- WG und ja: Person 1, 3, 8, 11 → **4** · WG und nein: Person 5 → **1**
- Eltern und ja: Person 9 → **1** · Eltern und nein: Person 2, 6, 12 → **3**
- allein und ja: Person 7 → **1** · allein und nein: Person 4, 10 → **2**

Wohnform \ Mensa	ja	nein	Summe
WG	4	1	5
Eltern	1	3	4
allein	1	2	3
Summe	6	6	12

Probe: $4 + 1 + 1 + 3 + 1 + 2 = 12 = n$ ✓ — jede Person steht in genau einer Zelle.

• DIE ALLGEMEINE FORM

X hat die Ausprägungen $a_1, \dots, a_J$ (die **Zeilen**), Y hat $b_1, \dots, b_K$ (die **Spalten**). Dann ist

$$h_{jk} = h(a_j, b_k) = \text{Anzahl der Beobachtungen mit } x_i = a_j \text{ und } y_i = b_k.$$

	b_1	$\dots$	b_K	Summe
a_1	h_{11}	$\dots$	h_{1K}	$h_{1\bullet}$
$\vdots$	$\vdots$		$\vdots$	$\vdots$
a_J	h_{J1}	$\dots$	h_{JK}	$h_{J\bullet}$
Summe	$h_{\bullet 1}$	$\dots$	$h_{\bullet K}$	n

Die **Merkmale müssen diskret** sein (wenige Ausprägungen) — oder vorher **in Klassen eingeteilt** werden. Genau dafür benutzt man in R `cut()` (Schritt 10).

TR · KONTINGENZTAFEL NE DEMEK?

Kontingenztafel = çapraz tablo. Satırlarda bir değişkenin, sütunlarda diğer değişkenin kategorileri durur. Her hücre: "bu iki özelliği **birlikte** taşıyan kaç kişi var?"

`hjk`

j. satır ve k. sütundaki hücre — ikisi birden

`hj•` (nokta sağda)

j. **satırın toplamı** — sütunlar üzerinden toplandı

`h•k` (nokta solda)

k. **sütunun toplamı** — satırlar üzerinden toplandı

Hafıza hilesi: Nokta, **üzerinden toplanan** indeksin yerine geçer. $h_{j\bullet}$: ikinci indeks (sütun) gitti → satır toplamı.

KERN Die Zeilensummen sind die Verteilung von X , die Spaltensummen die von Y . Beide ergeben zusammen n .

• RANDVERTEILUNGEN

$$h_{j\bullet} = h_{j1} + h_{j2} + \dots + h_{jK} \quad (\text{für } X) \quad h_{\bullet k} = h_{1k} + h_{2k} + \dots + h_{Jk} \quad (\text{für } Y)$$

Probe: $\sum_j h_{j\bullet} = \sum_k h_{\bullet k} = n$.

✓ BEISPIEL AUS DER VORLESUNG · AUSBILDUNG UND DAUER DER ARBEITSLOSIGKEIT (SOEP, $N = 447$)

Ausbildung \ Dauer	1–6 Monate	7–12 Monate	über 12 Monate	$h_{j\bullet}$
keine Ausbildung	86	19	18	123
Lehre	170	43	20	233
Fachspez. Ausbildung	40	11	5	56
Hochschulabschluss	28	4	3	35
$h_{\bullet k}$	324	77	46	447

Zum Beispiel $h_{1\bullet} = 86 + 19 + 18 = 123$ und $h_{\bullet 3} = 18 + 20 + 5 + 3 = 46$. Probe: $123 + 233 + 56 + 35 = 447$ und $324 + 77 + 46 = 447$ ✓

Die Tafel aus einem Text rekonstruieren

Dieser Aufgabentyp kommt in Tutorium 3 und später bei Bayes (Tag 8) immer wieder. Im Text stehen nur **einige** Zahlen. Den Rest findest du, weil jede Zeile und jede Spalte **aufgehen** muss.

✓ BEISPIEL · WOHNEN UND KOCHEN

„Von 500 Studierenden wohnen 200 in einer WG, die übrigen allein. 120 der WG-Bewohner kochen selbst. Insgesamt kochen 260 Studierende nicht selbst.“

- 1 Leere 2×2 -Tafel mit Rändern zeichnen. Eintragen, was direkt dasteht: $n = 500$, $h_{WG\bullet} = 200$, $h_{WG,selbst} = 120$, $h_{\bullet nicht} = 260$.
- 2 Was sofort folgt: allein = $500 - 200 = 300$ und kocht selbst = $500 - 260 = 240$.
- 3 Zeile WG aufgehen lassen: WG und nicht selbst = $200 - 120 = 80$.
- 4 Spalte „selbst“ aufgehen lassen: allein und selbst = $240 - 120 = 120$.
- 5 Letzte Zelle: allein und nicht selbst = $300 - 120 = 180$. Probe über die Spalte: $80 + 180 = 260$ ✓

	kocht selbst	kocht nicht selbst	Summe
WG	120	80	200
allein	120	180	300
Summe	240	260	500

Grün = Zahlen aus dem Text. Alles andere ist ausgerechnet.

TR · METINDEN TABLO KURMA REÇETESİ

1. adım

Boş tabloyu **toplam satırı ve sütunuyla** birlikte çiz.

2. adım

Metindeki her sayıyı doğru hücreye yaz. "Insgesamt" → kenar toplamı.
"...!den ... tanesi" → iç hücre.

3. adım

Tek bilinmeyen olan satır veya sütunu bul, çıkarma ile doldur.
Tekrarla.

4. adım

Son hücreyi **iki yoldan** kontrol et (satırdan ve sütundan). Aynı çıkmalı.

KERN $f_{jk} = h_{jk}/n$ ist der Anteil **an allen** Beobachtungen. Die ganze Tafel summiert sich zu 1.

• DEFINITION

$$f_{jk} = \frac{h_{jk}}{n}, \quad f_{j\bullet} = \frac{h_{j\bullet}}{n}, \quad f_{\bullet k} = \frac{h_{\bullet k}}{n}$$

✓ BEISPIEL · WOHNEN UND KOCHEN, JEDE ZAHL DURCH 500

	kocht selbst	kocht nicht selbst	$f_{j\bullet}$
WG	0.24	0.16	0.40
allein	0.24	0.36	0.60
$f_{\bullet k}$	0.48	0.52	1

Lies zum Beispiel $f_{11} = 0.24$ so: **24 % aller Studierenden** wohnen in einer WG **und** kochen selbst. Nicht: „24 % der WG-Bewohner“ — das wäre eine **bedingte** Häufigkeit (Schritt 5).

KERN Bedingt heißt: Man schaut nur auf **eine Gruppe** und teilt durch **deren** Größe — nicht durch n .

• DEFINITION

Verteilung von Y gegeben $X = a_j$ — zeilenweise normieren (durch die Zeilensumme teilen):

$$f_Y(b_k | a_j) = \frac{h_{jk}}{h_{j\bullet}}$$

Verteilung von X gegeben $Y = b_k$ — spaltenweise normieren (durch die Spaltensumme teilen):

$$f_X(a_j | b_k) = \frac{h_{jk}}{h_{\bullet k}}$$

Jede bedingte Verteilung summiert sich **in ihrer Zeile** (bzw. Spalte) zu 1.

✓ ZEILENWEISE · MENSA GEGEBEN WOHNFORM

	ja	nein	Σ
WG	4/5 = 0.8	1/5 = 0.2	1
Eltern	1/4 = 0.25	3/4 = 0.75	1
allein	1/3 = 0.333	2/3 = 0.667	1

„80 % der WG-Bewohner essen in der Mensa.“

✓ SPALTENWEISE · WOHNFORM GEGEBEN MENSA

	ja	nein
WG	4/6 = 0.667	1/6 = 0.167
Eltern	1/6 = 0.167	3/6 = 0.5
allein	1/6 = 0.167	2/6 = 0.333
Σ	1	1

„66.7 % der Mensa-Esser wohnen in einer WG.“

Dieselbe Zelle (WG, ja) = 4 liefert **drei verschiedene** Anteile — je nachdem, wodurch man teilt:

Teilen durch ...	Ergebnis	Wie man es sagt
$n = 12$	0.333	Anteil aller Studierenden, die in einer WG wohnen und in die Mensa gehen
Zeilensumme WG = 5	0.800	Anteil der Mensa-Esser unter den WG-Bewohnern
Spaltensumme ja = 6	0.667	Anteil der WG-Bewohner unter den Mensa-Essern

TR · HANGI SAYIYA BÖLÜYORUM? TEK KURAL

Soruda **hangi grup içinde** bakıldığını bul. O grubun toplamı paydaya gider.

„unter den ...“

"... arasında" → **o grubun toplamına** böl

„von den ... waren“

"... 'den kaç' → yine **o grubun toplamı**

„gegeben“, „wenn“, „|“

Koşul → çizginin **sağındaki** grup paydadır: $f(Y | X)$ ise X'in toplamı


„aller“, „insgesamt“

Koşul yok → **n'**ye böl

Kontrol: Bulduğun oranları aynı grup içinde topla. Toplam 1 değilse yanlış sayıya bölmüşsün.

✓ VORLESUNGSBEISPIEL · DAUER DER ARBEITSLOSIGKEIT GEGEBEN AUSBILDUNG (ZEILENWEISE)

Ausbildung	1–6 Monate	7–12 Monate	über 12 Monate	Σ
keine Ausbildung	$86/123 = 0.699$	0.154	0.146	1
Lehre	$170/233 = 0.730$	0.185	0.086	1
Fachspez. Ausbildung	$40/56 = 0.714$	0.196	0.089	1
Hochschulabschluss	$28/35 = 0.800$	0.114	0.086	1
Randverteilung	$324/447 = 0.725$	0.172	0.103	1



Jede Zeile ein Balken. Wären die Merkmale unabhängig, wären alle Balken gleich eingeteilt — wie der Randverteilungs-Balken unten.

Auf den Folien steht für „keine Ausbildung / über 12 Monate“ der Wert 0.147; genau gerechnet ist $18/123 = 0.1463 \approx 0.146$. Die Folie hat vermutlich so gerundet, dass die Zeile 1 ergibt.

📝 SO SCHREIBST DU ES IN DER KLAUSUR · INTERPRETATION BEDINGTER VERTEILUNGEN

„Unter den Hochschulabsolventen sind 80.0 % kurzzeitarbeitslos, unter den Personen ohne Ausbildung nur 69.9 %. Der Anteil der Kurzzeitarbeitslosen nimmt mit höherem Ausbildungsniveau zu, der Anteil der Langzeitarbeitslosen nimmt ab (14.6 % gegenüber 8.6 %). Da sich die bedingten Verteilungen unterscheiden, besteht ein Zusammenhang zwischen Ausbildung und Dauer der Arbeitslosigkeit.“

✗ „Es gibt einen Zusammenhang, weil die Merkmale abhängig sind.“ — Das ist ein Kreis. Ohne Zahlen keine Punkte.

- **Gruppe** nennen („unter den ...“)
- **Zahlen** nennen und **vergleichen**
- **Schluss** ziehen: gleich → kein Zusammenhang, verschieden → Zusammenhang

SELBSTCHECK · SCHRITT 5

- ☐ In der Kochen-Tafel: Wie groß ist der Anteil der Selbstkocher unter den Alleinwohnenden? ($120/300 = 0.4$)
- ☐ Und der Anteil der Alleinwohnenden unter den Selbstkochern? ($120/240 = 0.5$)

6

Unabhängigkeit

Wann besteht kein Zusammenhang?

V03 · FOLIE 20

KERN Unabhängig heißt: Alle bedingten Verteilungen sind **gleich** — und damit gleich der Randverteilung.


• REGEL AUS DER VORLESUNG

Sind alle bedingten Verteilungen von Y gegeben $X = a_j$ **gleich**, egal welches a_j , dann besteht **kein Zusammenhang** zwischen X und Y . Unterscheiden sie sich, dann **besteht ein Zusammenhang**.


✓ BEISPIEL · EIN UNABHÄNGIGES PAAR

	Kaffee: ja	Kaffee: nein	Summe
Frühaufsteher	12	18	30
Langschläfer	28	42	70
Summe	40	60	100

Frühaufsteher: $12/30 = 0.4$ trinken Kaffee. Langschläfer: $28/70 = 0.4$ trinken Kaffee. Insgesamt: $40/100 = 0.4$. **Überall 40 %** — das Aufstehen sagt nichts über den Kaffee aus.



✓ GEGENBEISPIEL · WOHNEN UND KOCHEN



WG: $120/200 = 0.6$ kochen selbst. Allein: $120/300 = 0.4$. Die Balken sind **verschieden** eingeteilt → es besteht ein Zusammenhang.

▲ WARUM MAN DIE TAFEL NICHT AUS DEN RÄNDERN BAUEN KANN

Beide Tafeln haben **dieselben Ränder** (Zeilen 30/70, Spalten 40/60):

A	ja	nein	Σ
früh	12	18	30
spät	28	42	70
Σ	40	60	100

B	ja	nein	Σ
früh	30	0	30
spät	10	60	70
Σ	40	60	100

A ist unabhängig, B hat einen extremen Zusammenhang (alle Frühaufsteher trinken Kaffee). Die Ränder allein verraten den Unterschied **nicht**. Nur wenn man Unabhängigkeit **annimmt**, sind die Zellen festgelegt — das ist die Idee von Schritt 7.

7 Erwartete Häufigkeiten

V03 · FOLIE 21 · V12

Wie sähe die Tafel aus, wenn es keinen Zusammenhang gäbe?

KERN $\tilde{h}_{jk} = \frac{\text{Zeilensumme} \cdot \text{Spaltensumme}}{n}$ — die Zahl, die bei Unabhängigkeit in der Zelle stehen müsste.

• FORMEL UND HERLEITUNG

Bei Unabhängigkeit ist der Anteil von b_k in **jeder** Zeile gleich dem Gesamtanteil $h_{\bullet k}/n$. Also muss in Zeile j (mit $h_{j\bullet}$ Personen) gelten:

$$\frac{\tilde{h}_{jk}}{h_{j\bullet}} = \frac{h_{\bullet k}}{n} \implies \tilde{h}_{jk} = \frac{h_{j\bullet} \cdot h_{\bullet k}}{n}$$

✓ BEISPIEL · WOHNEN UND KOCHEN ($N = 500$)

$\tilde{h}_{jk}$	kocht selbst (240)	kocht nicht selbst (260)	Summe
WG (200)	$\frac{200 \cdot 240}{500} = 96$	$\frac{200 \cdot 260}{500} = 104$	200
allein (300)	$\frac{300 \cdot 240}{500} = 144$	$\frac{300 \cdot 260}{500} = 156$	300
Summe	240	260	500

Beobachtet waren 120 / 80 / 120 / 180. Bei Unabhängigkeit wären es 96 / 104 / 144 / 156.

Probe: Die erwartete Tafel hat **genau dieselben Ränder** wie die beobachtete.

✓ VORLESUNGSBEISPIEL · ARBEITSLOSIGKEIT, ERSTE ZELLE

$$\tilde{h}_{11} = \frac{h_{1\bullet} \cdot h_{\bullet 1}}{n} = \frac{123 \cdot 324}{447} = \frac{39852}{447} = 89.1544$$

Beobachtet sind 86 — etwas weniger, als bei Unabhängigkeit zu erwarten wäre.

TR · BEKLENNEN FREKANS REÇETESİ

1. adım

Hücrenin **satır toplamını** bul

2. adım

Hücrenin **sütun toplamını** bul

3. adım

Çarp, **n**'ye böl

$\tilde{h}$ tam sayı **olmak zorunda değil** (89.1544 gibi). Yuvarlama! Ara sonuç olarak 4 basamak tut. Kontrol: $\tilde{h}$ tablosunun satır ve sütun toplamaları gözlenen tabloyla aynı olmalı.

KERN χ^2 misst, wie weit die beobachtete Tafel von der „unabhängigen“ Tafel entfernt ist. 0 = unabhängig.

• DEFINITION

$$\chi^2 = \sum_{j=1}^J \sum_{k=1}^K \frac{(h_{jk} - \tilde{h}_{jk})^2}{\tilde{h}_{jk}}$$

- $\chi^2 \approx 0 \rightarrow$ die Merkmale sind (näherungsweise) **unabhängig**
- χ^2 groß $\rightarrow$ **starker Zusammenhang**
- $\chi^2 \geq 0$ immer, weil nur Quadrate durch positive Zahlen geteilt werden

✓ RECHENSHEMA · WOHNEN UND KOCHEN

Zelle	h_{jk}	$\tilde{h}_{jk}$	$h - \tilde{h}$	$(h - \tilde{h})^2$	$\frac{(h - \tilde{h})^2}{\tilde{h}}$
WG · selbst	120	96	24	576	6.0000
WG · nicht	80	104	-24	576	5.5385
allein · selbst	120	144	-24	576	4.0000
allein · nicht	180	156	24	576	3.6923
Summe	500	500	0		19.2308

$\chi^2 = 19.2308 \approx \mathbf{19.231}$. Die Merkmale sind nicht unabhängig.

Zwei eingebaute Proben: Die Spalte $h - \tilde{h}$ summiert sich zu 0. Und bei einer 2×2-Tafel ist $|h - \tilde{h}|$ in allen vier Zellen gleich groß (hier 24).

✓ VORLESUNGSBEISPIEL · ARBEITSLOSIGKEIT, ALLE 12 ZELLEN

$\frac{(h - \tilde{h})^2}{\tilde{h}}$	1–6 M.	7–12 M.	über 12 M.
keine ($\tilde{h}$: 89.15 · 21.19 · 12.66)	0.1116	0.2259	2.2547
Lehre (168.89 · 40.14 · 23.98)	0.0073	0.2043	0.6598
Fachspez. (40.59 · 9.65 · 5.76)	0.0086	0.1899	0.1010
Hochschule (25.37 · 6.03 · 3.60)	0.2728	0.6829	0.1005

Summe aller zwölf Beiträge: $\chi^2 = 4.8195 \approx \mathbf{4.820}$. Den größten Beitrag liefert „keine Ausbildung, über 12 Monate“: 18 beobachtet statt 12.66 erwartet.

Hinweis: Auf Folie 23 steht $\chi^2 \approx 4.51$. Mit den Zahlen der Folie ergibt sich Zelle für Zelle aber 4.82 (in R: `chisq.test(z)$statistic` liefert ebenfalls 4.8195). Rechne in der Klausur einfach sauber mit der Formel — der Rechenweg zählt.

▲ DREI FALLEN BEIM INTERPRETIEREN

- **Keine feste Obergrenze.** Anders als eine Korrelation liegt χ^2 nicht zwischen –1 und 1. „4.82 ist klein“ kann man ohne Vergleich nicht sagen.
- **Hängt von n ab.** Verdoppelt man alle Häufigkeiten, verdoppelt sich χ^2 (probiere es: 240/160/240/360 ergibt 38.462) — obwohl die Anteile gleich bleiben.
- **Keine Richtung.** χ^2 sagt nur „Zusammenhang ja/wie stark“, nicht „mehr von A, mehr von B“. Die Richtung liest man an den bedingten Verteilungen ab.

Ob 4.82 „groß genug“ ist, entscheidet man mit dem χ^2 -**Unabhängigkeitstest** (V12, Tag 17). Dort wird genau diese Zahl mit einem Tabellenwert verglichen.

👉 SO SCHREIBST DU ES IN DER KLAUSUR · χ^2 INTERPRETIEREN

„Der χ^2 -Koeffizient beträgt 19.231. Er vergleicht die beobachteten Häufigkeiten mit den bei Unabhängigkeit erwarteten Häufigkeiten. Da er deutlich größer als 0 ist, weichen die beobachteten Häufigkeiten von den erwarteten ab; es besteht ein Zusammenhang zwischen Wohnform und Kochverhalten. WG-Bewohner kochen häufiger selbst (60 %) als Alleinwohnende (40 %).“

TR · χ^2 HESAPLAMA REÇETESİ

1. adım

Kenar toplamlarını hesapla (satırlar, sütunlar, n)

2. adım

Her hücre için $\tilde{h} = \text{satır} \cdot \text{sütun} / n$

3. adım

Her hücre için $(\text{gözlenen} - \text{beklenen})^2 / \text{beklenen}$

4. adım

Hepsini topla $\rightarrow \chi^2$

En sık hata: Paydaya gözlenen değeri (h) yazmak. Payda **her zaman beklenen $\tilde{h}$** . Bir hücreyi atlamamak için Rechenschema tablosunu kullan: J·K satır olmalı (burada 4, Arbeitslosigkeit'ta 12).

9

Welche Methode passt zu welchen Merkmalen?

Die Landkarte für heute und morgen

V03 · TAKE HOME

KERN Das Skalenniveau entscheidet, welches Zusammenhangsmaß erlaubt ist.

Nominal (oder wenige Kategorien)

z. B. Wohnform × Mensa,
Geschlecht × Partei

→ **Kontingenztafel, bedingte Verteilungen, χ^2 · heute**

Ordinal

z. B. Schulnote × Zufriedenheit
(sehr gut ... schlecht)

→ **Spearman-Rangkorrelation · morgen**

Metrisch

z. B. Lernstunden × Punkte,
Wohnfläche × Miete

→ **Streudiagramm, Kovarianz, Pearson-Korrelation · morgen**

Metrische Merkmale kann man auch in Klassen einteilen (mit `cut()`) und dann in eine Kontingenztafel stecken — genau das verlangt Testat 2. Umgekehrt geht es **nicht**: Für nominale Merkmale gibt es keine Korrelation.

► R · KONTINGENZTAFEL AUS ZWEI VEKTOREN

```

wohnen <- c("WG", "Eltern", "WG", "allein", "WG", "Eltern",
            "allein", "WG", "Eltern", "allein", "WG", "Eltern")
mensa   <- c("ja", "nein", "ja", "nein", "nein", "nein",
            "ja", "ja", "ja", "nein", "ja", "nein")

# Reihenfolge der Zeilen selbst festlegen (sonst sortiert R selbst)
wohnen <- factor(wohnen, levels = c("WG", "Eltern", "allein"))

tab <- table(wohnen, mensa)      # erst Zeilen-, dann Spaltenmerkmal
tab

      mensa
wohnen  ja  nein
WG       4    1
Eltern   1    3
allein   1    2

addmargins(tab)                # mit Randsummen

      mensa
wohnen  ja  nein Sum
WG       4    1  5
Eltern   1    3  4
allein   1    2  3
Sum       6    6 12

```

TR · SATIR SATIR

`c(...)`

Her kişinin cevabını sırayla bir vektöre koyar. İki vektörde **aynı sıra = aynı kişi**.

`factor(x, levels = ...)`

Kategorilerin **sırasını** sen belirlersin. Yazmazsan R kendi sıralar (çoğu zaman büyük harfler önce: Eltern, WG, allein).

`table(x, y)`

Çapraz tabloyu (Kontingenztafel) sayar. **İlk argüman satırlar**, ikincisi sütunlar.

`addmargins(tab)`

Kenar toplamalarını ekler. `Sum` satırı = $h_{\bullet k}$, `Sum` sütunu = $h_{j \bullet}$.

► R · RELATIVE UND BEDINGTE HÄUFIGKEITEN

```
prop.table(tab)                # f_jk: alles durch n
round(prop.table(tab, 1), 3)    # zeilenweise: Y gegeben X

mensa
wohnen    ja  nein
WG        0.800 0.200
Eltern    0.250 0.750
allein    0.333 0.667
round(prop.table(tab, 2), 3)    # spaltenweise: X gegeben Y

# Randverteilungen
rowSums(tab)                   # h_j. (gleich: apply(tab, 1, sum))
colSums(tab)                   # h_.k (gleich: apply(tab, 2, sum))
prop.table(table(mensa))       # relative Randverteilung von Y
```

TR · 1 MI 2 MI? EN ÖNEMLİ AYRIM

`prop.table(tab)`

Her hücre / **n**. Tüm tablo toplamı 1.

`prop.table(tab, 1)`

1 = satır. Her hücre / kendi **satır** toplamı. Her satır toplamı 1. → $f(Y | X)$

`prop.table(tab, 2)`

2 = sütun. Her hücre / kendi **sütun** toplamı. Her sütun toplamı 1. → $f(X | Y)$

`apply(tab, 1, sum)`

Ders script'indeki yazım: 1 = satırlar üzerinde topla. `rowSums` ile aynı sonuç.

Hafıza: R'da **1 hep satır, 2 hep sütun** demektir — `prop.table`, `apply`, hepsinde. Soruda "unter den WG-Bewohnern" → WG bir **satır** → `prop.table(tab, 1)`.

► R · ERWARTETE HÄUFIGKEITEN UND χ^2

```
z <- tab
z.tilde <- outer(rowSums(z), colSums(z)) / sum(z)
z.tilde
      ja nein
WG    2.5  2.5
Eltern 2.0  2.0
allein 1.5  1.5

# so steht es im R-Skript der Vorlesung (gleiches Ergebnis):
z.tilde <- apply(z, 1, sum) %*% t(apply(z, 2, sum)) / sum(z)

chisq.koef <- sum((z - z.tilde)^2 / z.tilde)
round(chisq.koef, 3)
[1] 3.133

# Kontrolle mit der eingebauten Funktion (correct = FALSE bei 2x2 wichtig!)
chisq.test(z, correct = FALSE)$statistic
```

TR · BEKLENNEN TABLO VE χ^2

`outer(a, b)`

a'nın her elemanını b'nin her elemanı ile çarpıp → satır toplamı × sütun toplamı tablosu

`/ sum(z)`

n'ye böler → $\tilde{h}_{jk}$

`(z - z.tilde)^2 / z.tilde`

Her hücre için formülün içi — R bunu **tüm hücrelere aynı anda** uygular

`sum(...)`

Hücreleri toplar → χ^2

`chisq.test(...)$statistic`

Hazır fonksiyon. 2×2 tabloda `correct = FALSE` yazmazsan R bir düzeltme (Yates) yapar ve sayı **farklı** çıkar.

Bu küçük örnekte beklenen değerler çok küçük (1.5 – 2.5). Burada sadece **hesaplamayı** gösteriyoruz; test için (Tag 17) bu kadar küçük hücreler sorun olur.

```
# Kampfzeit: "weniger als 5" / "5 bis unter 60" / "60 oder mehr" (Minuten)
d$Kampfzeit.3 <- cut(d$Kampfzeit, breaks = c(0, 5, 60, Inf), right = FALSE)

# Muenzen: "bis zu 10" / "mehr als 10 bis 20" / "mehr als 20 bis 30" / "mehr als 30"
d$Muenzen.4 <- cut(d$Muenzen, breaks = c(0, 10, 20, 30, Inf), right = TRUE)

Kontingenz.Tafel <- table(d$Muenzen.4, d$Kampfzeit.3)

# Randverteilung von Muenzen.4 NUR für Kampfzeit in [5, 60)
teil <- d[d$Kampfzeit >= 5 & d$Kampfzeit < 60, ]
round(prop.table(table(teil$Muenzen.4)), 2)
```

TR · CUT() ILE SINIFLARA AYIRMA

breaks = c(0, 5, 60, Inf)

Sınıf **sınırları**. 3 sınıf için 4 sınır gerekir. **Inf** = sonsuz, "ve üstü".

right = FALSE

Aralık **solda kapalı**: [5, 60). Metinde "**weniger als**" / "bis unter" varsa bunu seç.

right = TRUE

Aralık **sağda kapalı**: (10, 20]. Metinde "**bis zu**", "maximal", "höchstens" varsa bunu seç. (Varsayılan budur.)

d[koşul,]

Sadece koşulu sağlayan **satırları** alır. Virgülden sonrası boş = tüm sütunlar.

&

"ve" — iki koşul birden doğru olmalı

Karar sorusu: Sınır değeri (örneğin tam 60) hangi sınıfa girmeli? "60 oder mehr" → 60 üst sınıfta → sol taraf kapalı → right = FALSE. "bis zu 10" → 10 alt sınıfta → sağ taraf kapalı → right = TRUE.

Spickzettel Tag 5 · aufs Formelblatt

Ränder

$$h_{j\bullet} = \sum_k h_{jk} \text{ (Zeile)} \cdot h_{\bullet k} = \sum_j h_{jk} \text{ (Spalte)}$$

Relativ

$$f_{jk} = h_{jk}/n \cdot \text{ganze Tafel summiert zu 1}$$

Bedingt — durch die Größe der Gruppe teilen

Y gegeben $X = a_j: \frac{h_{jk}}{h_{j\bullet}}$ (zeilenweise) · X gegeben $Y = b_k: \frac{h_{jk}}{h_{\bullet k}}$ (spaltenweise) · „unter den ...“ = Bedingung

Unabhängig

alle bedingten Verteilungen gleich (= Randverteilung)

Erwartet

$$\tilde{h}_{jk} = \frac{h_{j\bullet} \cdot h_{\bullet k}}{n}$$

χ^2 -Koeffizient

$$\chi^2 = \sum_j \sum_k \frac{(h_{jk} - \tilde{h}_{jk})^2}{\tilde{h}_{jk}} \cdot \geq 0 \cdot 0 = \text{unabhängig} \cdot \text{groß} = \text{starker Zusammenhang} \cdot \text{keine Obergrenze} \cdot \text{wächst mit } n$$

R

```
table(x, y) · addmargins() · prop.table(tab, 1) Zeile · prop.table(tab, 2) Spalte · cut(x, breaks=, right=) · chisq.test(z, correct=FALSE)
```

Teste dich selbst

14 Aufgaben · 36 Punkte · Taschenrechner erlaubt · ca. 70 Minuten.

Klausurregeln: Dezimalpunkt · Zwischenergebnisse auf **vier**, Endergebnisse auf **drei** Nachkommastellen · Lösungsweg angeben.

Jede Teilaufgabe hat ihr eigenes Feld. Bevor du umblätterst: Ist jedes Feld (a), (b), (c) gefüllt? Ein Versuch mit Rechenweg bringt fast immer Teilpunkte — ein leeres Feld nie.

Für A1 bis A5 gilt diese Tafel: 200 Studierende wurden nach Studienfach und Lernort gefragt.

Fach \ Lernort	Bibliothek	Zuhause
BWL	30	50
VWL	24	16
Informatik	16	64

A 1 Randverteilungen (3 Punkte)

(a) Bestimmen Sie die Randverteilung des Fachs $h_{j\bullet}$. (b) Bestimmen Sie die Randverteilung des Lernorts $h_{\bullet k}$. (c) Zeigen Sie mit einer Probe, dass beide zu n summieren.

a

b

c

A 2 Relative Häufigkeiten (3 Punkte)

Berechnen Sie (a) f_{21} , (b) $f_{\bullet 2}$, (c) $f_{3\bullet}$ und formulieren Sie zu (a) einen Satz, was die Zahl bedeutet.

a

b

c

A 3 Bedingte Häufigkeiten (3 Punkte)

(a) Wie groß ist der Anteil der Bibliotheksnutzer **unter den VWL-Studierenden**? (b) Wie groß ist der Anteil der VWL-Studierenden **unter den Bibliotheksnutzern**? (c) Welche der beiden Zahlen gehört zur bedingten Verteilung „Lernort gegeben Fach“?

a

b

c

A 4 Zusammenhang begründen (2 Punkte)

Besteht ein Zusammenhang zwischen Fach und Lernort? Begründen Sie mit den bedingten Verteilungen **aller drei Fächer** (Zahlen nennen!).

–

A 5 Erwartete Häufigkeiten (3 Punkte)

Berechnen Sie die bei Unabhängigkeit erwarteten Häufigkeiten (a) $\tilde{h}_{11}$ (BWL, Bibliothek), (b) $\tilde{h}_{21}$ (VWL, Bibliothek), (c) $\tilde{h}_{32}$ (Informatik, Zuhause).

a

b

c

A 6 χ^2 **komplett** (4 Punkte)

100 Personen: Haben Sie ein Haustier? Wohnen Sie auf dem Land oder in der Stadt?

	Haustier ja	Haustier nein
Land	45	15
Stadt	15	25

(a) Berechnen Sie alle vier erwarteten Häufigkeiten. (b) Berechnen Sie den χ^2 -Koeffizienten mit Rechenschema. (c) Interpretieren Sie das Ergebnis in einem Satz.

a

b

c

A 7 **Tafel aus einem Text** (3 Punkte)

„Von 400 Pendlern fahren 150 mit dem Rad, die übrigen mit dem Bus. 90 der Radfahrer kommen pünktlich. Insgesamt kommen 100 Pendler zu spät.“

(a) Stellen Sie die vollständige Kontingenztafel mit Rändern auf. (b) Vergleichen Sie den Anteil der Verspäteten unter den Radfahrern und unter den Busfahrern.

a

b

A 8 Richtig oder falsch? (2 Punkte · je 0.5)

- ☐ a $\chi^2 = 0$ genau dann, wenn in jeder Zelle $h_{jk} = \tilde{h}_{jk}$ gilt.
- ☐ b Der χ^2 -Koeffizient liegt immer zwischen 0 und 1.
- ☐ c Aus den beiden Randverteilungen lässt sich die gemeinsame Verteilung immer eindeutig bestimmen.
- ☐ d Verdoppelt man alle Häufigkeiten einer Tafel, verdoppelt sich auch χ^2 .

a

b

c

d

A 9 Tafel bei Unabhängigkeit (2 Punkte)

Bekannt sind nur die Ränder: Zeilen $h_{1\bullet} = 60$, $h_{2\bullet} = 40$; Spalten $h_{\bullet 1} = 30$, $h_{\bullet 2} = 70$. (a) Füllen Sie die Tafel so aus, dass die Merkmale **unabhängig** sind. (b) Wie groß ist χ^2 für Ihre Tafel?

a

b

A 10 R-Output lesen (2 Punkte)

```
      konzentration
fruehstueck gut  schlecht
ja      0.8      0.2
nein    0.4      0.6
```

- (a) Welcher Befehl hat diesen Output erzeugt: `prop.table(tab)`, `prop.table(tab, 1)` oder `prop.table(tab, 2)`? Begründen Sie kurz. (b) Formulieren Sie die Zahl 0.8 als deutschen Satz.

a

b

A 11 R-Code ergänzen (2 Punkte)

Im Data Frame `d` gibt es die Variablen `Geschlecht` und `Partei`. Ergänzen Sie die Lücken.

```
tab <- _____( d$Geschlecht, d$Partei )           # (a) Kontingenztafel  
round( _____( tab, ___ ), 3 )                 # (b) Partei gegeben Geschlecht
```

a

b

A 12 Klassen mit `cut()` (2 Punkte)

Die Variable `d$Alter` soll in drei Klassen eingeteilt werden: „unter 18“, „18 bis unter 30“, „30 und älter“. Schreiben Sie den vollständigen `cut()`-Befehl und begründen Sie Ihre Wahl bei `right`.

—

A 13 Multiple Choice (2 Punkte · je 1)

(a) Die unter Unabhängigkeit erwartete Häufigkeit ist ...

- 1 $\tilde{h}_{jk} = h_{j\bullet} + h_{\bullet k} - n$
- 2 $\tilde{h}_{jk} = \frac{h_{j\bullet} \cdot h_{\bullet k}}{n}$
- 3 $\tilde{h}_{jk} = \frac{h_{jk}}{h_{j\bullet}}$
- 4 $\tilde{h}_{jk} = \frac{h_{j\bullet} \cdot h_{\bullet k}}{n^2}$

(b) Gesucht: „Anteil der Langzeitarbeitslosen unter den Hochschulabsolventen“ (Zeilen = Ausbildung, Spalten = Dauer). Man teilt h_{43} durch ...

- 1 n
- 2 $h_{\bullet 3}$, die Summe der Spalte „über 12 Monate“
- 3 $h_{4\bullet}$, die Summe der Zeile „Hochschulabschluss“
- 4 $\tilde{h}_{43}$

a

b

A 14 Vorlesungsbeispiel nachrechnen (3 Punkte)

Nutzen Sie die Arbeitslosigkeits-Tafel aus Schritt 3 (nur die Zeile **Hochschulabschluss**: $28 \cdot 4 \cdot 3$). (a) Berechnen Sie $\tilde{h}_{41}$, $\tilde{h}_{42}$, $\tilde{h}_{43}$. (b) Berechnen Sie den Beitrag dieser Zeile zu χ^2 , also die Summe der drei Summanden.

a

b

Lösungen

Vergleiche ehrlich — Teilaufgabe für Teilaufgabe. Jeden Fehler ins Fehlerheft: *Was war gefragt?*
Durch welche Zahl hätte ich teilen müssen?

A 1 · 3 Punkte

(a) BWL $30 + 50 = 80$, VWL $24 + 16 = 40$, Informatik $16 + 64 = 80$

(b) Bibliothek $30 + 24 + 16 = 70$, Zuhause $50 + 16 + 64 = 130$

(c) $80 + 40 + 80 = 200$ und $70 + 130 = 200 = n$ ✓

A 2 · 3 Punkte

(a) $f_{21} = \frac{24}{200} = 0.120$ — 12 % **aller** Befragten studieren VWL **und** lernen in der Bibliothek.

(b) $f_{\bullet 2} = \frac{130}{200} = 0.650$

(c) $f_{3\bullet} = \frac{80}{200} = 0.400$

A 3 · 3 Punkte

(a) Gruppe = VWL (Zeile, 40 Personen): $\frac{24}{40} = 0.600$

(b) Gruppe = Bibliotheksnutzer (Spalte, 70 Personen): $\frac{24}{70} = 0.3429 \approx 0.343$

(c) „Lernort gegeben Fach“ = innerhalb eines Fachs schauen = zeilenweise → (a).

Dieselbe Zelle 24, zwei verschiedene Nenner. Genau dieser Unterschied ist bei Bayes (Tag 8) der Kern.

A 4 · 2 Punkte

Bedingte Verteilung des Lernorts gegeben Fach (Anteil Bibliothek):

BWL $30/80 = 0.375$ · VWL $24/40 = 0.600$ · Informatik $16/80 = 0.200$

Ja, es besteht ein Zusammenhang. Die bedingten Verteilungen unterscheiden sich deutlich: Unter den VWL-Studierenden lernen 60 % in der Bibliothek, unter den Informatik-Studierenden nur 20 %. Bei Unabhängigkeit müssten alle drei Anteile gleich der Randverteilung $70/200 = 0.35$ sein.

Volle Punktzahl nur mit Zahlen **und** Vergleich. Zur Kontrolle: $\chi^2 = 19.121$.

A 5 · 3 Punkte

(a) $\tilde{h}_{11} = \frac{80 \cdot 70}{200} = 28$ (beobachtet 30)

(b) $\tilde{h}_{21} = \frac{40 \cdot 70}{200} = 14$ (beobachtet 24)

(c) $\tilde{h}_{32} = \frac{80 \cdot 130}{200} = 52$ (beobachtet 64)

A 6 · 4 Punkte

Ränder: Land 60, Stadt 40; Haustier ja 60, nein 40; $n = 100$.

(a) $\tilde{h}_{11} = \frac{60 \cdot 60}{100} = 36$, $\tilde{h}_{12} = \frac{60 \cdot 40}{100} = 24$, $\tilde{h}_{21} = \frac{40 \cdot 60}{100} = 24$, $\tilde{h}_{22} = \frac{40 \cdot 40}{100} = 16$

Zelle	h	$\tilde{h}$	$h - \tilde{h}$	$\frac{(h - \tilde{h})^2}{\tilde{h}}$
Land · ja	45	36	9	$81/36 = 2.2500$
Land · nein	15	24	-9	$81/24 = 3.3750$
Stadt · ja	15	24	-9	$81/24 = 3.3750$
Stadt · nein	25	16	9	$81/16 = 5.0625$
Summe	100	100	0	14.0625

(b) $\chi^2 = 14.0625 \approx \mathbf{14.063}$

(c) Da χ^2 deutlich größer als 0 ist, besteht ein Zusammenhang zwischen Wohnort und Haustierbesitz: Auf dem Land haben 75 % (45/60) ein Haustier, in der Stadt 37.5 % (15/40).

A 7 · 3 Punkte

(a) Aus dem Text: $n = 400$, Rad 150, Rad & pünktlich 90, zu spät insgesamt 100. Daraus: Bus = 250, pünktlich = 300, Rad & spät = $150 - 90 = 60$, Bus & pünktlich = $300 - 90 = 210$, Bus & spät = $250 - 210 = 40$. Probe: $60 + 40 = 100$ ✓

	pünktlich	zu spät	Σ
Rad	90	60	150
Bus	210	40	250
Σ	300	100	400

(b) Unter den Radfahrern: $60/150 = \mathbf{0.400}$; unter den Busfahrern: $40/250 = \mathbf{0.160}$. Radfahrer kommen in diesen Daten deutlich häufiger zu spät.

A 8 · 2 Punkte

(a) **richtig** — jeder Summand ist ≥ 0 ; die Summe ist nur 0, wenn jeder Summand 0 ist.

(b) **falsch** — χ^2 hat keine Obergrenze (Beispiel: 19.231).

(c) **falsch** — nur bei Unabhängigkeit (siehe Tafeln A und B in Schritt 6).

(d) **richtig** — h und $\tilde{h}$ verdoppeln sich; Zähler $\times 4$, Nenner $\times 2$, also Summand $\times 2$.

A 9 · 2 Punkte

(a) Bei Unabhängigkeit ist jede Zelle $\tilde{h}_{jk}$:

$$\frac{60 \cdot 30}{100} = 18, \frac{60 \cdot 70}{100} = 42, \frac{40 \cdot 30}{100} = 12, \frac{40 \cdot 70}{100} = 28$$

(b) Beobachtet = erwartet in jeder Zelle, also $\chi^2 = 0$.

A 10 · 2 Punkte

(a) `prop.table(tab, 1)` — jede **Zeile** summiert sich zu 1 ($0.8 + 0.2 = 1$, $0.4 + 0.6 = 1$), also wurde zeilenweise normiert.

(b) „80 % der Personen, die frühstücken, haben eine gute Konzentration.“ (Nicht: „80 % der Personen mit guter Konzentration frühstücken.“)

A 11 · 2 Punkte

(a) `table`

(b) `prop.table` und `1` — „Partei gegeben Geschlecht“ heißt: innerhalb jedes Geschlechts, und Geschlecht steht in den Zeilen (erstes Argument von `table`).

A 12 · 2 Punkte

```
d$Alter.3 <- cut(d$Alter, breaks = c(0, 18, 30, Inf), right = FALSE)
```

„unter 18“ und „18 bis **unter** 30“: Die Grenze 18 gehört zur **oberen** Klasse, 30 ebenso. Die Intervalle sind also links geschlossen, rechts offen: $[0, 18)$, $[18, 30)$, $[30, \infty)$ → `right = FALSE`.

A 13 · 2 Punkte

(a) **2** — Zeilensumme mal Spaltensumme durch n .

(b) **3** — „unter den Hochschulabsolventen“ → die Gruppe ist die Zeile 4 → $28 + 4 + 3 = 35$. Ergebnis $3/35 = 0.086$.

A 14 · 3 Punkte

(a) Zeilensumme $h_{4\bullet} = 35$, Spaltensummen 324, 77, 46, $n = 447$:

$$\tilde{h}_{41} = \frac{35 \cdot 324}{447} = 25.3691, \quad \tilde{h}_{42} = \frac{35 \cdot 77}{447} = 6.0291, \quad \tilde{h}_{43} = \frac{35 \cdot 46}{447} = 3.6018$$

(b)

$$\frac{(28 - 25.3691)^2}{25.3691} + \frac{(4 - 6.0291)^2}{6.0291} + \frac{(3 - 3.6018)^2}{3.6018} = 0.2728 + 0.6829 + 0.1005 = 1.0562$$

Beitrag der Zeile: **1.056** (von insgesamt 4.820).

Deine Auswertung

Punkte	Was das bedeutet
30 – 36	Sehr gut. Kontingenztafeln sitzen — damit ist auch Bayes (Tag 8) halb gelernt.
23 – 29	Gut. Schau in der Tabelle unten nach, welcher Themenblock die Punkte gekostet hat.
15 – 22	Wiederhole Schritt 5 (bedingte Verteilungen) und Schritt 8 (Rechenschema), dann A3, A6 und A7 noch einmal.
0 – 14	Arbeite Schritt 3 bis 8 morgen früh noch einmal durch (40 Minuten) und mache den Test erneut.

Themenblock	Aufgaben	zurück zu
Tafel, Ränder, relative Häufigkeiten	A1, A2, A7a	Schritt 2–4
Bedingte Verteilungen	A3, A4, A7b, A13b	Schritt 5
Unabhängigkeit, $\tilde{h}$, χ^2	A5, A6, A8, A9, A13a, A14	Schritt 6–8
R	A10, A11, A12	Schritt 10

◆ WIE ES MORGEN WEITERGEHT

Heute ging es um Merkmale mit **wenigen Kategorien**. Morgen kommen **metrische** Merkmale: Streudiagramm, Kovarianz, Korrelation nach Bravais-Pearson und nach Spearman — und die Frage, warum Korrelation keine Kausalität ist. Das ist Probeklausur - Aufgabe 5: **11 Punkte**.