

TAG 06

Kovarianz, Korrelation und Kausalität

Heute geht es um zwei **metrische** Merkmale: Lernstunden und Punkte, Größe und Gewicht. Du lernst, einen Zusammenhang zu zeichnen, zu messen und — das bringt die meisten Punkte — ihn in der Klausur **richtig zu formulieren**.

ca. 3.5 Stunden

12 Schritte

14 Aufgaben · 34 Punkte

▶ R-Ecke · TR erklär mal

Das kannst du heute Abend

- ☐ Du liest aus einem **Streudiagramm** Richtung, Form und Stärke ab.
- ☐ Du berechnest die **Kovarianz** mit Arbeitstabelle und mit dem **Verschiebungssatz**.
- ☐ Du berechnest den **Korrelationskoeffizienten nach Bravais-Pearson**.
- ☐ Du **interpretierst** ihn mit den Sätzen aus der offiziellen Musterlösung.
- ☐ Du berechnest die **Rangkorrelation nach Spearman** — auch mit Bindungen.
- ☐ Du erklärst, warum **Korrelation keine Kausalität** beweist.
- ☐ Du erstellst in R ein beschriftetes Streudiagramm und speicherst es als PDF.

Grundlage: Vorlesung SDS1-V03 (Folien 24–46) · R-Skript [03StatDS-Zusammenhänge.R](#) · Tutorium 3, Aufgaben 3–4 · Testat 2, Aufgaben 1–2 · **Probeklausur Teil A, Aufgabe 5 (11 Punkte)**

Dein Tag auf einen Blick

Erst lesen, dann loslegen · 3 Minuten

1

Streudiagramm
Schritt 1–2 · 20 min

2

Kovarianz
Schritt 3–5 · 40 min

3

Pearson & Deuten
Schritt 6–7 · 35 min

4

Spearman
Schritt 8–9 · 30 min

5

Kausalität
Schritt 10 · 15 min

6

Klausur-Zwilling
Schritt 11 · 25 min

R

R-Ecke
Schritt 12 · 25 min

🔍

Test
14 Aufgaben · 70 min

Klausur-Radar · Wo kommt das dran?

Dieser Tag ist einer der wertvollsten im ganzen Plan. Die Probeklausur hat eine komplette Aufgabe dazu.

Probeklausur A5

Varianz · Kovarianz · Korrelation · Interpretation · Kausalität · Skizze
fünf Teilaufgaben, alle heute geübt · Schritt 3–11

11 P

Teil B (R)

`plot()` mit Beschriftung, als PDF speichern, `cor()`
so im Testat 2 und in der B-Klausur verlangt · Schritt 12

≈ 6 P

Testat 2

Verschiebungssatz (MC) · Richtig/Falsch zu ρ
typische Kurzfragen im A-Teil · Schritt 4, 9, 10

≈ 4 P

Dein persönlicher Fokus · aus deinen bisherigen Tests

„Begründen“ im Kreis

Heute kostet das am meisten: Interpretation und Kausalität sind 4 von 11 Punkten.

→ Schritt 7 und 10 geben dir die Sätze der offiziellen Musterlösung.

Teilaufgaben ausgelassen

A5 hat (a) bis (d) — eine Skizze ist schnell vergessen.

→ Der Klausur-Zwilling in Schritt 11 ist genauso aufgebaut.

Regel zu weit angewendet

Du hast bei „Anzahl Vorlesungen“ den Mittelwert verboten.

→ Schritt 9: welche Maßzahl bei welchem Skalenniveau — mit klarer Tabelle.

Rechnen ist deine Stärke

Deine Rechenaufgaben waren fast immer richtig.

→ Die Arbeitstabelle macht auch die Kovarianz zur reinen Rechenroutine.

■ WAS DU VON GESTERN UND VORGESTERN BRAUCHST

$\bar{x} = \frac{1}{n} \sum x_i$ — das arithmetische Mittel

$S^2 = \frac{1}{n} \sum (x_i - \bar{x})^2 = \frac{1}{n} \sum x_i^2 - \bar{x}^2$ — die empirische Varianz (Verschiebungssatz, Tag 4)

R: `var(x)` rechnet mit $n - 1$ — das gilt heute genauso für `cov(x, y)`

Rang — der Platz eines Werts nach dem Sortieren (kleinster Wert = Rang 1)

1






Das Streudiagramm lesen

Jeder Punkt ist eine Person

V03 · FOLIE 24–26

KERN Im Streudiagramm liest du drei Dinge ab: die **Richtung**, die **Form** und die **Stärke** des Zusammenhangs.

Für zwei metrische Merkmale zeichnet man jedes Paar (x_i, y_i) als Punkt in ein Koordinatensystem: x nach rechts, y nach oben. Das ist das **Streudiagramm** (auch: Punktwolke).

**gleichgerichtet, linear, eng**Je größer x , desto größer y . $\rho = 0.964$ **gegengerichtet, linear, eng**Je größer x , desto kleiner y . $\rho = -0.937$ **gleichgerichtet, schwach**Tendenz nach oben, aber breite Wolke.
 $\rho = 0.375$ **kein Zusammenhang**Formlose Wolke. $\rho = 0.001$ **nichtlinear, nicht monoton**Klarer U-Zusammenhang — trotzdem
 $\rho \approx 0!$ **nichtlinear, aber monoton**Pearson $\rho = 0.811$, Spearman = 0.997

Frage	Begriffe aus der Vorlesung
Richtung	gleichgerichtet (positiv: steigt mit) oder gegengerichtet (negativ: fällt)
Form	linear (Punkte um eine Gerade) oder nichtlinear (Kurve)
Stärke	Wie eng liegen die Punkte an dieser Linie oder Kurve?

▲ MERKE DIR DAS FÜNFTE BILD

Die U-Form ist ein **perfekter** Zusammenhang — kennt man x , kennt man y fast genau. Trotzdem ist der Korrelationskoeffizient ungefähr 0. Warum, verstehst du in Schritt 9. Diese Idee wird im Testat und in Richtig/Falsch-Fragen gerne abgefragt.

2 Konkordant und diskordant

Die Idee hinter der Kovarianz


V03 · FOLIE 27–30

KERN Zieh durch den Schwerpunkt $(\bar{x}, \bar{y})$ ein Kreuz. Punkte oben rechts und unten links sprechen für einen positiven Zusammenhang.

✓ BEISPIEL · 5 STUDIERENDE: LERNSTUNDEN PRO WOCHE UND KLAUSURPUNKTE

Person i	1	2	3	4	5
x_i Stunden	2	4	6	8	10
y_i Punkte	55	70	60	65	100

Mittelwerte: $\bar{x} = \frac{30}{5} = 6$ und $\bar{y} = \frac{350}{5} = 70$.



Grün: konkordant, das Produkt $(x_i - \bar{x})(y_i - \bar{y})$ ist positiv. **Rot:** diskordant, das Produkt ist negativ. **Grau:** liegt auf einer Mittellinie, Produkt 0.

• DEFINITION

Eine Beobachtung (x_i, y_i) heißt

- **konkordant**, wenn $x_i > \bar{x}$ und $y_i > \bar{y}$ **oder** $x_i < \bar{x}$ und $y_i < \bar{y}$. Dann ist $(x_i - \bar{x})(y_i - \bar{y}) > 0$.
- **diskordant**, wenn $x_i < \bar{x}$ und $y_i > \bar{y}$ **oder** $x_i > \bar{x}$ und $y_i < \bar{y}$. Dann ist $(x_i - \bar{x})(y_i - \bar{y}) < 0$.

Viele konkordante Punkte → gleichgerichteter Zusammenhang. Viele diskordante → gegengerichtet.

3

Die Kovarianz

Mit der Arbeitstabelle — Schritt für Schritt

A5 • TEIL VON (B)

KERN Die Kovarianz ist der **Durchschnitt** aller Produkte $(x_i - \bar{x})(y_i - \bar{y})$.

• DEFINITION

$$\text{Cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

- $\text{Cov} > 0$ → positiver linearer Zusammenhang
- $\text{Cov} < 0$ → negativer linearer Zusammenhang
- $\text{Cov} = 0$ → kein **linearer** Zusammenhang (X und Y sind **unkorreliert**)

✓ ARBEITSTABELLE · LERNSTUNDEN UND PUNKTE

i	x_i	y_i	$x_i - \bar{x}$	$y_i - \bar{y}$	Produkt	$(x_i - \bar{x})^2$	$(y_i - \bar{y})^2$
1	2	55	-4	-15	60	16	225
2	4	70	-2	0	0	4	0
3	6	60	0	-10	0	0	100
4	8	65	2	-5	-10	4	25
5	10	100	4	30	120	16	900
Σ	30	350	0	0	170	40	1250

$$\text{Cov}(X, Y) = \frac{170}{5} = 34$$

Die beiden letzten Spalten brauchst du gleich für die Korrelation — in der Klausur rechnest du sie **in derselben Tabelle** gleich mit. Probe: Die Spalten $x_i - \bar{x}$ und $y_i - \bar{y}$ summieren sich zu 0.

TR · KOVARYANS TABLOSU REÇETESİ

1. adım

$\bar{x}$ ve $\bar{y}$ 'yi hesapla

2. adım

Her satırda sapmaları yaz: $x_i - \bar{x}$ ve $y_i - \bar{y}$ (**işaretleriyle!**)

3. adım

İki sapmayı **çarp** → "Produkt" sütunu

4. adım

Produkt sütununu topla, **n**'ye böl → Cov

İşaret kontrolü: Sapma sütunlarının toplamı **her zaman 0**. 0 çıkmıyorsa ortalamayı yanlış hesaplamışsın. Negatif × negatif = **pozitif** (1. satır: $-4 \cdot -15 = +60$).

KERN $\text{Cov}(X, Y) = \frac{1}{n} \sum x_i y_i - \bar{x} \bar{y}$ — genau wie bei der Varianz, nur mit $x_i y_i$ statt x_i^2 .

• VERSCHIEBUNGSSATZ

$$\text{Cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n x_i y_i - \bar{x} \cdot \bar{y}$$

Vergleiche mit Tag 4: $S^2 = \frac{1}{n} \sum x_i^2 - \bar{x}^2$. Setzt man $Y = X$, kommt genau das heraus.

✓ PROBE AM BEISPIEL

$$\sum x_i y_i = 2 \cdot 55 + 4 \cdot 70 + 6 \cdot 60 + 8 \cdot 65 + 10 \cdot 100 = 110 + 280 + 360 + 520 + 1000 = 2270$$

$$\text{Cov}(X, Y) = \frac{2270}{5} - 6 \cdot 70 = 454 - 420 = 34 \quad \checkmark$$

✓ TESTAT 2 · NUR R-SUMMEN GEGEBEN

```
> length(x)      [1] 50      > sum(x^2)      [1] 87611
> sum(x)         [1] 2019    > sum(y^2)      [1] 301695
> sum(y)         [1] 3733    > sum(x*y)      [1] 160064
```

1 $\bar{x} = \frac{2019}{50} = 40.38$ und $\bar{y} = \frac{3733}{50} = 74.66$

2 $\text{Cov} = \frac{160064}{50} - 40.38 \cdot 74.66 = 3201.28 - 3014.7708 = 186.5092$

Kovarianz ≈ 186.509 . Die Korrelation dazu rechnen wir in Schritt 6 weiter.

▲ DIE MULTIPLE-CHOICE-FALLE AUS TESTAT 2

Nur **eine** Darstellung ist richtig:

$$\frac{1}{n} \sum (x_i y_i - \bar{x} \bar{y})$$

richtig, aber nicht vereinfacht

$$\frac{1}{n^2} \sum x_i y_i - \bar{x} \bar{y}$$

falsch: n^2

$$\frac{1}{n} \sum x_i y_i - \bar{x} - \bar{y}$$

falsch: minus statt mal

$$\frac{1}{n} \sum x_i y_i - \bar{x} \bar{y}$$

die gesuchte vereinfachte Form

Die erste Zeile ist mathematisch gleichwertig, aber nicht „so weit wie möglich vereinfacht“ — danach war gefragt.

5

Eigenschaften der Kovarianz

Und warum sie allein nicht reicht

V03 · FOLIE 31–34

KERN Das **Vorzeichen** der Kovarianz ist aussagekräftig, ihre **Größe** nicht — sie hängt von den Einheiten ab.

• DREI EIGENSCHAFTEN

1. $\text{Cov}(X, X) = \text{Var}(X)$ — die Kovarianz ist eine Verallgemeinerung der Varianz.
2. Sie ist **maßabhängig**: Ändert man die Einheit, ändert sich der Wert. Allgemein: $\text{Cov}(a + bX, c + dY) = b \cdot d \cdot \text{Cov}(X, Y)$.
3. Sie erkennt nur **lineare** Zusammenhänge. Nichtlineare werden nicht unbedingt erkannt.

✓ TUTORIUM 3 · ANNE UND BOBO

Fünf Männer, Gewicht in kg und Größe. Anne rechnet mit der Größe in **cm** und erhält $\text{Cov} = 153.88 \text{ kg} \cdot \text{cm}$. Bobo rechnet mit der Größe in **m** und erhält $1.5388 \text{ kg} \cdot \text{m}$.

Beide haben richtig gerechnet. Von cm zu m wird jede Größe mit $d = 0.01$ multipliziert, also auch die Kovarianz: $153.88 \cdot 0.01 = 1.5388$.

Folge: „Die Kovarianz ist 153.88, also ist der Zusammenhang stark“ ist **sinnlos** — in Metern wäre es dieselbe Stärke mit 1.54. Man braucht eine Zahl **ohne Einheit**. Das ist die Korrelation.

KERN $\rho = \frac{\text{Cov}(X, Y)}{S_X \cdot S_Y}$ — liegt immer zwischen -1 und 1 und hat keine Einheit.

• DEFINITION

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \cdot \text{Var}(Y)}} = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2 \cdot \sum_i (y_i - \bar{y})^2}}$$

- $-1 \leq \rho \leq 1$
- $\rho = 0 \Leftrightarrow$ kein **linearer** Zusammenhang
- $|\rho| = 1 \Leftrightarrow$ **perfekter** linearer Zusammenhang (alle Punkte auf einer Geraden)
- Voraussetzung: beide Merkmale **metrisch** (es werden Abstände zum Mittelwert berechnet)

✓ BEISPIEL · LERNSTUNDEN UND PUNKTE · ZWEI WEGE, EIN ERGEBNIS

Weg 1 — mit den Varianzen: $\text{Var}(X) = \frac{40}{5} = 8$, $\text{Var}(Y) = \frac{1250}{5} = 250$

$$\rho = \frac{34}{\sqrt{8 \cdot 250}} = \frac{34}{\sqrt{2000}} = \frac{34}{44.7214} = 0.7603$$

Weg 2 — direkt mit den Summen der Arbeitstabelle (das $\frac{1}{n}$ kürzt sich weg):

$$\rho = \frac{170}{\sqrt{40 \cdot 1250}} = \frac{170}{\sqrt{50000}} = \frac{170}{223.6068} = 0.7603$$

Ergebnis: $\rho \approx \mathbf{0.760}$

✓ TESTAT 2 · WEITER MIT DEN R-SUMMEN AUS SCHRITT 4

$$\mathbf{1} \quad \text{Var}(X) = \frac{87611}{50} - 40.38^2 = 1752.22 - 1630.5444 = 121.6756$$

$$\mathbf{2} \quad \text{Var}(Y) = \frac{301695}{50} - 74.66^2 = 6033.9 - 5574.1156 = 459.7844$$

$$\mathbf{3} \quad \rho = \frac{186.5092}{\sqrt{121.6756 \cdot 459.7844}} = \frac{186.5092}{236.5260} = 0.7885$$

Ergebnis: $\rho \approx \mathbf{0.789}$ — ein starker positiver linearer Zusammenhang.

◆ GUT ZU WISSEN: N ODER $N - 1$ IST HIER EGAL

Ob man Kovarianz und Varianzen mit $\frac{1}{n}$ oder mit $\frac{1}{n-1}$ rechnet: Der Faktor steht oben und unten und **kürzt sich weg**. Deshalb liefert `cor()` in R genau den Wert der Vorlesung — anders als `var()` und `cov()`. Wichtig ist nur, **nicht zu mischen**.

TR · KORELASYON HESAPLAMA YOLU

Ham veri verildiyse

Arbeitstabelle kur → üç toplam: Produkt, $(x - \bar{x})^2$, $(y - \bar{y})^2$ → Weg 2 ile tek satırda ρ

Sadece toplamlar verildiyse

Verschiebungssatz: önce Cov, sonra iki varyans, sonra ρ (Testat 2 yolu)

Varyanslar hazır verildiyse

Direkt $\rho = \text{Cov} / \sqrt{\text{Var}X \cdot \text{Var}Y}$ (Probeklausur A5 yolu)

Kontrol: Sonuç -1 ile 1 arasında olmak **zorunda**. 1.3 çıktıysa kök almayı ya da bir varyansı unuttun. Kovaryansın işareti ile ρ 'nun işareti **hep aynıdır**.

7 Den Koeffizienten interpretieren

Die zwei Punkte, die viele verschenken

A5 (B) · 2 P

KERN Eine Interpretation nennt: was ρ misst, den Wertebereich, die **Richtung**, die **Stärke** — und das Wort **linear**.

• STÄRKE · DIE GRENZEN AUS TUTORIUM 3

Betrag $ \rho $	Stärke des linearen Zusammenhangs
$0 < \rho < 0.3$	schwach (in der Musterlösung auch: „niedrig“)
$0.3 \leq \rho < 0.7$	mittel
$0.7 \leq \rho \leq 1$	stark

Das **Vorzeichen** gibt die Richtung: + gleichgerichtet, – gegengerichtet.

„Es handelt sich um die normierte Kovarianz. Der Koeffizient gibt den Grad des linearen Zusammenhangs von X und Y an. Der Korrelationskoeffizient kann Werte zwischen -1 und $+1$ annehmen. Ein positiver Korrelationskoeffizient bedeutet eine positive Korrelation. Bei einer positiven Korrelation steigt eine Variable, wenn die andere auch steigt. Hier kann man von einer niedrigen positiven Korrelation ausgehen.“

Dein Baukasten — die fett gedruckten Teile passt du an:

1. **Was:** „Der Korrelationskoeffizient ist die normierte Kovarianz und misst den Grad des **linearen** Zusammenhangs.“
2. **Bereich:** „Er kann Werte zwischen -1 und $+1$ annehmen.“
3. **Richtung:** „Da ρ **positiv/negativ** ist, steigt Y tendenziell, wenn X **steigt/fällt**.“
4. **Stärke:** „Mit $\rho = \mathbf{0.760}$ liegt ein **starker** positiver linearer Zusammenhang vor.“

✗ „Der Zusammenhang ist stark, weil die Korrelation stark ist.“ — Kreis, keine Zahl, kein „linear“.

✗ „Mehr Lernen verursacht mehr Punkte.“ — Das ist Kausalität (Schritt 10). Nicht in eine Interpretation schreiben.

TR · YORUM = 4 PARÇA

Ne ölçer?

"normierte Kovarianz", "**linearen** Zusammenhang" kelimeleri mutlaka geçsin

Aralık

"zwischen -1 und $+1$ "

Yön

İşaret: $+$ ise ikisi birlikte artar, $-$ ise biri artarken diğeri azalır

Güç

$|\rho| < 0.3$ schwach · $0.3-0.7$ mittel · ≥ 0.7 stark — **sayıyı cümlede yaz**

Probeklausur'da bu kısım **2 puan**. Cümleler ezberlenebilir; her seferinde sadece sayı, yön ve güç kelimesi değişir.

KERN Spearman = Pearson, angewendet auf die **Ränge** statt auf die Werte.

• IDEE UND FORMELN

Pearson braucht Abstände zum Mittelwert — das geht nur bei metrischen Daten. Ersetzt man jeden Wert durch seinen **Rang** (kleinster Wert = 1, nächster = 2, ...), kann man auch ordinale Merkmale korrelieren.

$$r_S = \rho(\text{rg}(X), \text{rg}(Y))$$

Nur wenn es keine gleichen Werte gibt (keine Bindungen), gilt die Abkürzung mit $d_i = \text{rg}(x_i) - \text{rg}(y_i)$:

$$r_S = 1 - \frac{6 \sum_i d_i^2}{n(n^2 - 1)}$$

✓ BEISPIEL OHNE BINDUNGEN · LERNSTUNDEN UND PUNKTE

i	x_i	$\text{rg}(x_i)$	y_i	$\text{rg}(y_i)$	d_i	d_i^2
1	2	1	55	1	0	0
2	4	2	70	4	-2	4
3	6	3	60	2	1	1
4	8	4	65	3	1	1
5	10	5	100	5	0	0
Σ		15		15	0	6

So findest du $\text{rg}(y)$: sortiert ist $55 < 60 < 65 < 70 < 100$, also hat 55 Rang 1, 60 Rang 2, 65 Rang 3, 70 Rang 4, 100 Rang 5.

$$r_S = 1 - \frac{6 \cdot 6}{5(25 - 1)} = 1 - \frac{36}{120} = 0.7$$

Spearman = 0.700, Pearson war 0.760. Beide zeigen einen starken positiven Zusammenhang.

✓ BEISPIEL MIT BINDUNGEN · DURCHSCHNITTSRÄNGE

$x = (3, 5, 5, 8, 9)$ und $y = (2, 4, 3, 6, 7)$. Der Wert 5 kommt in x zweimal vor.

- 1 **Ränge für x :** Die beiden Fünfen belegen die Plätze 2 und 3. Jede bekommt den Durchschnitt $\frac{2+3}{2} = 2.5$. Also $\text{rg}(x) = (1, 2.5, 2.5, 4, 5)$.
- 2 **Ränge für y :** keine Bindung, $\text{rg}(y) = (1, 3, 2, 4, 5)$.
- 3 **Pearson auf die Ränge:** Mittelwert beider Rangreihen = 3. Abweichungen $(-2, -0.5, -0.5, 1, 2)$ und $(-2, 0, -1, 1, 2)$. Produkte $4 + 0 + 0.5 + 1 + 4 = 9.5$. Quadratsummen 9.5 und 10.

$$r_s = \frac{9.5}{\sqrt{9.5 \cdot 10}} = \frac{9.5}{9.7468} = 0.9747$$

Die Abkürzung mit d_i gäbe hier 0.975 — zufällig fast gleich. Beim offiziellen Filme-Beispiel aus Tutorium 3 (viele Bindungen) ist der Unterschied sichtbar: richtig 0.551, Abkürzung 0.558.

TR · SIRA (RANG) VERME REÇETESİ

1. adım

Her değişkeni **ayrı ayrı** küçükten büyüğe sırala

2. adım

En küçük = 1, sonraki = 2, ...

Eşitlik (Bindung)

Aynı değerler hangi sıraları kaplıyorsa onların **ortalamasını** alır. 2. ve 3. sıra → ikisi de 2.5

3. adım

Eşitlik **yoksa**: d_i formülü. Eşitlik **varsa**: sıralar üzerinde Pearson hesapla.

Kontrol: Sıraların toplamı her zaman $\frac{n(n+1)}{2}$ olmalı. $n = 5$ için 15. Eşitlikte de bu tutar ($1 + 2.5 + 2.5 + 4 + 5 = 15$).

KERN Pearson misst **lineare**, Spearman **monotone** Zusammenhänge. Keiner von beiden erkennt eine U-Form.

Zusammenhang (V03, Folie 40)	Pearson	Spearman	Warum
linear	0.98	0.97	Beide erkennen ihn.
monoton, nichtlinear (z. B. exponentiell)	0.48	1	Die Ränge steigen perfekt mit, die Werte nicht linear.
nicht monoton (Welle, U-Form)	-0.36	-0.35	Beide versagen.

✓ **BEISPIEL** · $Y = X^2$ **HAT KORRELATION 0**

$x = (-2, -1, 0, 1, 2)$ und $y = x^2 = (4, 1, 0, 1, 4)$. Dann $\bar{x} = 0$, $\bar{y} = 2$ und

$$\text{Cov} = \frac{1}{5} \sum x_i y_i - \bar{x} \bar{y} = \frac{1}{5} (-8 - 1 + 0 + 1 + 8) - 0 \cdot 2 = 0$$

Also $\rho = 0$. Trotzdem hängt Y **vollständig** von X ab. Die linke Hälfte fällt, die rechte steigt — die konkordanten und diskordanten Beiträge heben sich genau auf.

◆ **DIE LOGISCHE RICHTUNG — RICHTIG/FALSCH-KLASSIKER**

unabhängig $\Rightarrow \rho = 0$

richtig

$\rho \neq 0 \Rightarrow$ nicht unabhängig

richtig (dieselbe Aussage umgedreht)

$\rho = 0 \Rightarrow$ unabhängig

falsch — siehe $Y = X^2$

$Y = -X^2 \Rightarrow \rho$ kann ≈ 0 sein

richtig (Testat 2)

$X = Y \Rightarrow \rho = 1$

richtig (perfekt linear mit Steigung 1)

$\text{Cov} \geq 0.8 \Rightarrow$ starker Zusammenhang

falsch — Kovarianz ist maßabhängig

Welches Maß ist erlaubt?

Skalenniveau beider Merkmale	erlaubt	Beispiel
nominal	Kontingenztafel, χ^2 (Tag 5)	Geschlecht × Studienfach
ordinal	Spearman (und Tag-5-Methoden)	Schulnote × Zufriedenheit
metrisch	Pearson , Spearman, Kovarianz	Lernstunden × Punkte

Die Regel geht nur **nach unten**: Was für ordinale Daten erlaubt ist, darf man auch bei metrischen benutzen, nicht umgekehrt. Eine Anzahl (z. B. „Anzahl der Vorlesungen“) ist metrisch — Pearson ist erlaubt.

10

Korrelation ist keine Kausalität

Und der ökologische Fehlschluss

A5 (C) · 2 P

KERN Eine Korrelation zeigt einen **statistischen** Zusammenhang. Ob X die **Ursache** von Y ist, zeigt sie nicht.

• KAUSALITÄT (V03, FOLIE 41–42)

Kausalität: Aus einer Veränderung von X ergibt sich **ursächlich** eine Veränderung von Y .

Zum Nachweis braucht man:

- eine **gezielte Manipulation** der Ursache X in der Untersuchung (Experiment)
- die **Kontrolle** aller weiteren Einflussgrößen, zum Beispiel durch **Randomisierung**

Die meisten Datenanalysen tun beides nicht. Sie liefern deshalb nur einen statistischen Zusammenhang.

✓ DRITTVARIABLEN · „SCHEINKORRELATIONEN“

Beobachtet	Falscher Schluss	Wirklicher Grund
Eisverkauf und Sonnenbrände korrelieren positiv	Eis verursacht Sonnenbrand	Drittvariable Sonnenwetter
Mehr Feuerwehrleute im Einsatz, höherer Schaden	Feuerwehr verursacht Schaden	Drittvariable Größe des Brandes
Margarinekonsum und Scheidungsrate (Tutorium 3)	Margarine zerstört Ehen	Zufall / gemeinsamer Zeittrend

▲ ÖKOLOGISCHER FEHLSCHLUSS (V03, FOLIE 43–45)

Man schließt von **Gruppendaten** (Stadtbezirke, Länder) unzulässig auf **einzelne Personen**.

EHEC, Hamburg 2011: In Bezirken mit vielen Grünen-Wählern gab es mehr Erkrankungen. Falscher Schluss: Grün wählen erhöht das Risiko. Tatsächlich kamen die Erreger aus Sprossen aus ökologischem Anbau. Zwei Probleme: (1) Aus Bezirksdaten weiß man nicht, ob die Erkrankten selbst Grünen-Wähler waren. (2) Die Drittvariable Ernährung wurde nicht beachtet.

👉 SO SCHREIBST DU ES IN DER KLAUSUR · WORTLAUT DER OFFIZIELLEN MUSTERLÖSUNG

„Nein, statistische Analysen liefern keinen Nachweis einer Kausalität, der Zusammenhang könnte auch durch dritte Variablen entstehen.“

Noch sicherer mit einem Beispiel für die Drittvariable, z. B.: „... etwa durch die allgemeine Tagesform, die sowohl das Schießen als auch das Laufen beeinflusst.“ **Immer mit „Nein“ oder „Ja“ beginnen** — die Frage war „Stimmen Sie zu?“.

TR · NEDENSELLİK SORUSU

Soru "X, Y'ye **neden oluyor mu?**" / "führt zu ...?" / "verursacht ...?" ise cevap bu derste **hemen hemen her zaman "Nein"**. Sebep: korelasyon sadece **istatistiksel ilişki** gösterir; nedensellik için **deney** (X'i bilerek değiştirmek) ve **diğer etkenleri kontrol** (randomizasyon) gerekir.

Tam puan cümlesi: "Nein" + "keine Kausalität" + "Drittvariable" + mümkünse **bir örnek** drittvariable.

KERN Die Probeklausur selbst sparst du dir für die Generalprobe auf. Hier übst du ihren exakten Aufbau.

■ AUFGABE

Eine Studentin vermutet einen Zusammenhang zwischen ihrem Kaffeekonsum am Nachmittag (X , Tassen) und ihrer Schlafdauer in der folgenden Nacht (Y , Stunden). Grundlage sind 6 Tage:

Tag ν	1	2	3	4	5	6
Tassen x_ν	2	5	1	4	3	3
Schlaf y_ν	7	5	8	6	8	5

(a) Berechnen Sie die empirische Varianz von X . (2P) · (b) Berechnen Sie ρ_{xy} mit $s_y^2 = 1.5833$, $\bar{y} = 6.5$, $\sum x_\nu y_\nu = 110$ und interpretieren Sie. (3P + 2P) · (c) „Der Kaffee führt zum schlechten Schlaf.“ Stimmen Sie zu? (2P) · (d) Skizzieren Sie ein Streudiagramm für $\rho_{xy} = 0$. (2P)

(a) · 2 Punkte

$$\bar{x} = \frac{2 + 5 + 1 + 4 + 3 + 3}{6} = \frac{18}{6} = 3 \text{ und } \frac{1}{n} \sum x_\nu^2 = \frac{4 + 25 + 1 + 16 + 9 + 9}{6} = \frac{64}{6} = 10.6667$$

$$s_x^2 = \frac{1}{n} \sum x_\nu^2 - \bar{x}^2 = 10.6667 - 9 = 1.6667$$

Also $s_x^2 \approx \mathbf{1.667}$

(b) Rechnung · 3 Punkte

Kovarianz mit dem Verschiebungssatz:

$$s_{xy} = \frac{1}{6} \sum x_\nu y_\nu - \bar{x} \bar{y} = \frac{110}{6} - 3 \cdot 6.5 = 18.3333 - 19.5 = -1.1667$$

$$\rho_{xy} = \frac{s_{xy}}{\sqrt{s_x^2 \cdot s_y^2}} = \frac{-1.1667}{\sqrt{1.6667 \cdot 1.5833}} = \frac{-1.1667}{1.6245} = -0.7182$$

Also $\rho_{xy} \approx \mathbf{-0.718}$


(b) Interpretation · 2 Punkte

Es handelt sich um die normierte Kovarianz. Der Koeffizient gibt den Grad des linearen Zusammenhangs von X und Y an und kann Werte zwischen -1 und $+1$ annehmen. Ein negativer Korrelationskoeffizient bedeutet eine negative Korrelation: Wenn die eine Variable steigt, sinkt die andere tendenziell. Hier liegt mit $\rho_{xy} = -0.718$ eine **starke negative** Korrelation vor.

(c) · 2 Punkte

Nein. Statistische Analysen liefern keinen Nachweis einer Kausalität; der Zusammenhang könnte auch durch dritte Variablen entstehen — zum Beispiel durch Stress in Prüfungsphasen, der sowohl zu mehr Kaffee als auch zu schlechterem Schlaf führt.

(d) · 2 Punkte



Eine **formlose Wolke** ohne Richtung und ohne erkennbare Gerade.

Punkte gibt es für: beschriftete Achsen (X: Kaffeetassen, Y: Schlafdauer) und eine Wolke ohne steigenden oder fallenden Trend.

Auch richtig: eine U-Form — sie hat ebenfalls $\rho = 0$.

12 Die R-Ecke

Streudiagramm, Kovarianz, Korrelation

TEIL B

► R · STREUDIAGRAMM ALS PDF SPEICHERN · SO WIE IN DER B-KLAUSUR

```
x <- c(2, 4, 6, 8, 10)      # Lernstunden
y <- c(55, 70, 60, 65, 100) # Punkte

pdf("Streudiagramm.pdf")    # 1. Datei öffnen
plot(x, y,                  # 2. zeichnen: erst x, dann y
     pch = 16,              #   ausgefüllte Punkte
     cex = 0.8,             #   Punktgröße
     main = "Sitz 00, Matr.Nr. 12345678, Aufgabenteil c)",
     xlab = "Lernstunden pro Woche",
     ylab = "Punkte")
dev.off()                   # 3. Datei schließen – sonst ist das PDF leer!
```

`pdf("Dosya.pdf")`

Çizimi ekrana değil, bu **dosyaya** yazmaya başla. PNG için `png("dosya.png")`.

`plot(x, y, ...)`

Serpme diyagramı. **İlk** vektör yatay eksen, **ikinci** dikey eksen.

`pch = 16`

Nokta şekli (16 = dolu yuvarlak). `cex` = nokta boyutu.

`main / xlab / ylab`

Başlık / x eksen adı / y eksen adı. B-sınavında başlıkta **Sitz, Matr.Nr., Aufgabenteil** olmak zorunda.

`dev.off()`

Dosyayı **kapat ve kaydet**. Unutursan PDF boş/bozuk olur — Tutorium'da "häufige Fehlerquelle".

Sıra ezberle: aç (pdf) → çiz (plot) → kapat (dev.off). Testat 2'de boşluk doldurma olarak soruldu: plot, main, xlab, ylab, dev.

► R · KOVARIANZ UND KORRELATION

```

cov(x, y)                                # ACHTUNG: Nenner n-1, wie var()
[1] 42.5
n <- length(x)
(n - 1) / n * cov(x, y)                  # empirische Kovarianz der Vorlesung
[1] 34

cor(x, y)                                # Pearson (Standard) – kein Umrechnen nötig
[1] 0.7602631
round(cor(x, y), 3)                      # R lässt die Null weg – du schreibst 0.760
[1] 0.76

cor(x, y, method = "spearman")
[1] 0.7
rank(y)                                  # Ränge; bei Bindungen automatisch Durchschnittsränge
[1] 1 4 2 3 5

```

TR · HANGI FONKSİYON NEYİ VERİR

`cov(x, y)`

Kovaryans ama **n-1** ile (tıpkı `var` gibi). Dersteki değer için $\frac{n-1}{n}$ ile çarp.

`cor(x, y)`

Pearson. **Düzeltmeye gerek yok** — n-1 pay ve paydada birbirini götürür.

`method = "spearman"`

Spearman sıra korelasyonu. Eşitliklerde ortalama sırayı kendisi kullanır.

`rank(y)`

Her değerın sırası. Kontrol için kullanışlı.

Kural: var ve cov → dikkat, n-1. cor → güvenli, aynen yaz.

► R · KORRELATIONSMATRIX FÜR EINEN GANZEN DATA FRAME

```
d <- data.frame(Stunden = x, Punkte = y, Fehltag = c(9, 6, 7, 4, 1))
round(cor(d), 3)
```

	Stunden	Punkte	Fehltag
Stunden	1.000	0.760	-0.933
Punkte	0.760	1.000	-0.904
Fehltag	-0.933	-0.904	1.000

TR · KORELASYON MATRİSİ NASIL OKUNUR

Köşegen (1.000)

Her değişkenin kendisiyle korelasyonu — **her zaman 1**, bilgi taşımaz

Köşegen dışı

Aradığın sayılar burada. Satır "Punkte", sütun "Fehltag" → -0.904

Simetri

Üst üçgen = alt üçgen. Her çifti bir kez oku.

Tutorium hatası: köşegendeki 1'i "mükemmel korelasyon bulundu" diye yorumlamak. **Nebendiagonale** (köşegen dışı) önemli olan.

■ AUSBLICK · REGRESSION (V13)

In der letzten Vorlesung kommt die **Regressionsgerade**: die Gerade, die am besten durch die Punktwolke passt. In R: `lm(y ~ x)` und `abline(lm(y ~ x))`. Für heute reicht: Korrelation misst, **wie gut** die Punkte auf einer Geraden liegen — die Regression sagt, **welche** Gerade es ist.

Spickzettel Tag 6 · aufs Formelblatt

Kovarianz

$$\text{Cov} = \frac{1}{n} \sum (x_i - \bar{x})(y_i - \bar{y})$$

Verschiebungssatz

$$\text{Cov} = \frac{1}{n} \sum x_i y_i - \bar{x} \bar{y}$$

Pearson

$$\rho = \frac{\text{Cov}}{\sqrt{\text{Var}X \cdot \text{Var}Y}} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}} \cdot -1 \leq \rho \leq 1 \cdot \text{nur}$$

linear

· metrisch

Stärke

$|\rho| < 0.3$ schwach · $0.3-0.7$ mittel · ≥ 0.7 stark

Maßabhängig

$\text{Cov}(a+bX, c+dY) = bd \text{Cov}$ · ρ bleibt (bis aufs Vorzeichen)

Spearman

Pearson auf die Ränge · Bindungen → Durchschnittsrank · ohne Bindungen: $r_s = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$ · misst

monotone

Zusammenhänge · ab ordinal

Logik

unabhängig $\Rightarrow \rho = 0$ · aber $\rho = 0 \nRightarrow$ unabhängig ($Y = X^2$) · Korrelation $\nRightarrow$ Kausalität (Nachweis: Manipulation + Randomisierung) · ökologischer Fehlschluss: Gruppe $\nRightarrow$ Individuum

R

`pdf("...")` → `plot(x, y, main=, xlab=, ylab=)` → `dev.off()` · `cov()` = `n-1!` · `cor(x, y)` · `cor(x, y, method="spearman")` · `rank()`

Teste dich selbst

14 Aufgaben · 34 Punkte · Taschenrechner erlaubt · ca. 70 Minuten.

Klausurregeln: Dezimalpunkt · Zwischenergebnisse auf **vier**, Endergebnisse auf **drei** Nachkommastellen · Lösungsweg angeben · Antwortsätze in ganzen Sätzen.

Bei jeder Interpretation: Zahl nennen, Richtung, Stärke, das Wort „linear“. Bei jeder Kausalitätsfrage: erst „Ja“ oder „Nein“, dann die Begründung.

A 1 Arbeitstabelle (4 Punkte)

Fünf Studierende: bearbeitete Übungsblätter x und Testatpunkte y .

x_i	1	2	3	4	5
y_i	3	5	4	8	10

(a) $\bar{x}$ und $\bar{y}$ · (b) Kovarianz mit Arbeitstabelle · (c) ρ · (d) Interpretation in einem Satz

a

b

c

d

A 2 Nur Summen gegeben (3 Punkte)

$n = 8$, $\sum x_i = 40$, $\sum y_i = 64$, $\sum x_i^2 = 240$, $\sum y_i^2 = 560$, $\sum x_i y_i = 344$. Berechnen Sie (a) die Kovarianz, (b) beide Varianzen, (c) ρ .

a**b****c****A 3 Verschiebungssatz · Multiple Choice (1 Punkt)**

Welche Darstellung ist die vollständig vereinfachte Form von $\frac{1}{n} \sum (x_i - \bar{x})(y_i - \bar{y})$?

a $\frac{1}{n} \sum x_i y_i - \bar{x} - \bar{y}$

b $\frac{1}{n} \sum x_i y_i - \bar{x} \bar{y}$

c $\frac{1}{n^2} \sum x_i y_i - \bar{x} \bar{y}$

d $\frac{1}{n} \sum (x_i y_i - \bar{x} \bar{y})$

—**A 4 Interpretieren (2 Punkte)**

Für X = tägliche Bildschirmzeit (h) und Y = Schlafdauer (h) ergibt sich $\rho = -0.42$. Interpretieren Sie den Wert vollständig.

—

A 5 Kausalität (2 Punkte)

Bei Bränden korrelieren die Anzahl der eingesetzten Feuerwehrleute und die Schadenshöhe mit $\rho = 0.81$. Ein Politiker folgert: „Weniger Feuerwehrleute würden den Schaden senken.“ Stimmen Sie zu? Begründen Sie in 1–2 Sätzen.

–

A 6 Skizze (2 Punkte)

Skizzieren Sie ein mögliches Streudiagramm für X = Fehlstunden und Y = Klausurpunkte mit $\rho \approx -0.9$.



A 7 Spearman ohne Bindungen (3 Punkte)

Mathe x_i	12	15	9	20	18	11
Statistik y_i	30	28	25	40	41	27

(a) Bestimmen Sie die Ränge beider Merkmale. (b) Berechnen Sie r_S .

a

b

A 8 Spearman mit Bindungen (3 Punkte)

$x = (2, 4, 4, 6, 7)$ und $y = (10, 14, 12, 12, 20)$. (a) Bestimmen Sie die Ränge (mit Durchschnittsrängen). (b) Berechnen Sie r_S als Pearson-Korrelation der Ränge. (c) Warum darf man hier die Formel mit d_i^2 nicht benutzen?

a

b

c

A 9 Richtig oder falsch? (3 Punkte · je 0.5)

- a Wenn $\rho_{XY} \neq 0$, sind X und Y niemals unabhängig.
- b Wenn $Y = -X^2$, kann ρ_{XY} annähernd 0 sein.
- c Wenn $X = Y$ (und X nicht konstant), gilt $\rho_{XY} = 1$.
- d Wenn $\rho_{XY} \neq 0$, besteht stets ein kausaler Zusammenhang.
- e Wenn $\text{Cov}(X, Y) \geq 0.8$, spricht man immer von einem starken Zusammenhang.
- f Wenn $\rho_{XY} = 0$, sind X und Y unabhängig.

a

b

c

d

e

f

A 10 Einheiten wechseln (2 Punkte)

Für Gewicht (kg) und Größe (cm) gilt $\text{Cov} = 153.88$ und $\rho = 0.836$. Die Größe wird nun in Metern angegeben. (a) Wie groß ist die neue Kovarianz? (b) Wie groß ist das neue ρ ? Begründen Sie.

a

b

A 11 Quadratischer Zusammenhang (2 Punkte)

$x = (-3, -1, 0, 1, 3)$ und $y_i = x_i^2$. (a) Berechnen Sie ρ . (b) Folgt daraus, dass kein Zusammenhang besteht?

a

b

A 12 Welches Maß? (2 Punkte · je 0.5)

Nennen Sie jeweils ein geeignetes Zusammenhangsmaß: (a) Schulnote (1–6) und Zufriedenheit (sehr / eher / kaum / nicht) · (b) Wohnfläche (qm) und Nettomiete (€) · (c) Geschlecht und Studienfach · (d) Platzierung im Rennen und Platzierung im Vorjahr

a

b

c

d

A 13 R-Code ergänzen (2 Punkte)

Das Streudiagramm von `d$Kampfzeit` (x-Achse) und `d$Muenzen` (y-Achse) soll als PDF gespeichert werden.

```
pdf("Streudiagramm.pdf")
_____( _____ , _____ ,
      pch = 16,
      _____ = "Streudiagramm",
      xlab = "Kampfzeit (min.)",
      ylab = _____ )
_____.off()
```

—

A 14 R-Output auswerten (3 Punkte)

```
> length(x)
[1] 5
> cov(x, y)
[1] 12.5
> var(x); var(y)
[1] 2.5
[1] 100
```

(a) Wie groß ist die empirische Kovarianz im Sinne der Vorlesung (Nenner n)? (b) Berechnen Sie ρ aus dem Output. Muss man vorher umrechnen? (c) Mit welchem Befehl erhält man Spearmans r_s ?

a

b

c

Lösungen

Vergleiche ehrlich — Teilaufgabe für Teilaufgabe. Bei Interpretationen: Hast du Zahl, Richtung, Stärke und „linear“ genannt? Jedes fehlende Element kostet in der Klausur Punkte.

A 1 • 4 Punkte

(a) $\bar{x} = \frac{15}{5} = 3, \bar{y} = \frac{30}{5} = 6$

i	$x_i - \bar{x}$	$y_i - \bar{y}$	Produkt	$(x_i - \bar{x})^2$	$(y_i - \bar{y})^2$
1	-2	-3	6	4	9
2	-1	-1	1	1	1
3	0	-2	0	0	4
4	1	2	2	1	4
5	2	4	8	4	16
Σ	0	0	17	10	34

(b) $\text{Cov} = \frac{17}{5} = 3.400$

(c) $\rho = \frac{17}{\sqrt{10 \cdot 34}} = \frac{17}{18.4391} = 0.9220 \approx 0.922$

(d) Es liegt ein **starker positiver linearer** Zusammenhang vor: Wer mehr Übungsblätter bearbeitet, hat tendenziell mehr Testpunkte ($\rho = 0.922 \geq 0.7$).

A 2 • 3 Punkte

$\bar{x} = \frac{40}{8} = 5, \bar{y} = \frac{64}{8} = 8$

(a) $\text{Cov} = \frac{344}{8} - 5 \cdot 8 = 43 - 40 = 3.000$

(b) $\text{Var}(X) = \frac{240}{8} - 5^2 = 30 - 25 = 5, \text{Var}(Y) = \frac{560}{8} - 8^2 = 70 - 64 = 6$

(c) $\rho = \frac{3}{\sqrt{5 \cdot 6}} = \frac{3}{5.4772} = 0.5477 \approx 0.548$ (mittlerer positiver linearer Zusammenhang)

A 3 • 1 Punkt

(b). (d) ist zwar gleichwertig, aber nicht vereinfacht; (a) und (c) sind falsch.


A 4 · 2 Punkte

Der Korrelationskoeffizient ist die normierte Kovarianz und misst den Grad des **linearen** Zusammenhangs; er liegt zwischen -1 und $+1$. Da $\rho = -0.42$ negativ ist, liegt eine **negative** Korrelation vor: Mit steigender Bildschirmzeit sinkt die Schlafdauer tendenziell. Wegen $0.3 \leq 0.42 < 0.7$ ist der lineare Zusammenhang **mittelstark**.

A 5 · 2 Punkte

Nein. Statistische Analysen liefern keinen Nachweis einer Kausalität; der Zusammenhang entsteht durch eine dritte Variable: die **Größe des Brandes**. Große Brände verursachen großen Schaden **und** erfordern viele Feuerwehrleute.

A 6 · 2 Punkte



Punkte eng um eine **fallende** Gerade, von links oben nach rechts unten.

1 Punkt für die Achsenbeschriftung (Fehlstunden, Klausurpunkte), **1 Punkt** für eine enge, fallende Wolke.

A 7 · 3 Punkte

(a) Sortiert: x : 9, 11, 12, 15, 18, 20 · y : 25, 27, 28, 30, 40, 41

i	x_i	$rg(x_i)$	y_i	$rg(y_i)$	d_i	d_i^2
1	12	3	30	4	-1	1
2	15	4	28	3	1	1
3	9	1	25	1	0	0
4	20	6	40	5	1	1
5	18	5	41	6	-1	1
6	11	2	27	2	0	0
Σ		21		21	0	4

(b) $r_s = 1 - \frac{6 \cdot 4}{6(36 - 1)} = 1 - \frac{24}{210} = 0.8857 \approx \mathbf{0.886}$

A 8 · 3 Punkte

(a) x : die beiden Vieren belegen Platz 2 und 3 $\rightarrow$ je 2.5. $\text{rg}(x) = (1, 2.5, 2.5, 4, 5)$.

y : sortiert 10, 12, 12, 14, 20; die beiden Zwölfen belegen Platz 2 und 3 $\rightarrow$ je 2.5. $\text{rg}(y) = (1, 4, 2.5, 2.5, 5)$

.

(b) Beide Rang-Mittelwerte sind 3. Abweichungen: $(-2, -0.5, -0.5, 1, 2)$ und $(-2, 1, -0.5, -0.5, 2)$.

Produkte: $4 - 0.5 + 0.25 - 0.5 + 4 = 7.25$ · Quadratsummen: 9.5 und 9.5

$$r_S = \frac{7.25}{\sqrt{9.5 \cdot 9.5}} = \frac{7.25}{9.5} = 0.7632$$

Also $r_S \approx 0.763$

(c) Es gibt **Bindungen**. Die d_i -Formel gilt nur ohne Bindungen; hier würde sie 0.775 liefern — falsch.

A 9 · 3 Punkte

(a) **richtig** — Unabhängigkeit hätte $\rho = 0$ zur Folge. (b) **richtig** — symmetrische Parabel, wie $Y = X^2$. (c) **richtig** — alle Punkte liegen auf der Geraden mit Steigung 1.

(d) **falsch** — Korrelation ist keine Kausalität. (e) **falsch** — die Kovarianz ist maßabhängig; über Stärke sagt nur ρ etwas. (f) **falsch** — $\rho = 0$ heißt nur: kein **linearer** Zusammenhang.

A 10 · 2 Punkte

(a) Jede Größe wird mit 0.01 multipliziert, also auch die Kovarianz: $153.88 \cdot 0.01 = 1.539$

(b) $\rho = 0.836$ bleibt gleich. Der Faktor 0.01 steht auch in S_Y im Nenner und kürzt sich; der Korrelationskoeffizient ist dimensionslos.

A 11 · 2 Punkte

(a) $y = (9, 1, 0, 1, 9)$, $\bar{x} = 0$, $\bar{y} = 4$, $\sum x_i y_i = -27 - 1 + 0 + 1 + 27 = 0$. $\text{Cov} = \frac{0}{5} - 0 \cdot 4 = 0$, also $\rho = 0$.

(b) **Nein**. Es besteht ein perfekter, aber **nichtlinearer** (quadratischer) Zusammenhang. $\rho = 0$ heißt nur, dass kein **linearer** Zusammenhang besteht.

A 12 · 2 Punkte

(a) beide ordinal $\rightarrow$ **Spearman** · (b) beide metrisch $\rightarrow$ **Pearson** (Spearman auch möglich) · (c) nominal $\rightarrow$ **Kontingenztafel / χ^2** · (d) Platzierungen sind Ränge, also ordinal $\rightarrow$ **Spearman**

A 13 · 2 Punkte

```
plot ( d$Kampfzeit , d$Muenzen , ... main = "Streudiagramm", ... ylab = "Muenzen" ) und  
dev .off()
```

Achtung: zuerst die x-Variable, dann die y-Variable. Die Achsenbeschriftung braucht Anführungszeichen.

A 14 · 3 Punkte

(a) `cov()` teilt durch $n - 1$: $\frac{n-1}{n} \cdot 12.5 = \frac{4}{5} \cdot 12.5 = \mathbf{10.000}$

(b) **Keine** Umrechnung nötig, weil alle drei Werte denselben Nenner $n - 1$ haben:

$$\rho = \frac{12.5}{\sqrt{2.5 \cdot 100}} = \frac{12.5}{15.8114} = 0.7906$$

Also $\rho \approx \mathbf{0.791}$. Probe mit Nenner n : $\frac{10}{\sqrt{2 \cdot 80}} = \frac{10}{12.6491} = 0.7906 \checkmark$

(c) `cor(x, y, method = "spearman")`

Deine Auswertung

Punkte	Was das bedeutet
28 – 34	Sehr gut. Probeklausur - Aufgabe 5 kannst du jetzt voll lösen — 11 von 75 Punkten.
21 – 27	Gut. Schau in die Themen - Tabelle unten und wiederhole genau den einen Block.
14 – 20	Rechne den Klausur - Zwillings (Schritt 11) morgen noch einmal ohne Lösung, dann A1, A4, A5 erneut.
0 – 13	Arbeite Schritt 3, 6, 7 und 10 morgen früh noch einmal durch (45 Minuten) und mache den Test erneut.

Themenblock	Aufgaben	zurück zu
Rechnen: Kovarianz, Pearson	A1a–c, A2, A3, A10, A14	Schritt 3–6
Formulieren: Interpretation, Kausalität	A1d, A4, A5	Schritt 7, 10
Spearman und Grenzen der Korrelation	A7, A8, A9, A11, A12	Schritt 8, 9
Zeichnen und R	A6, A13	Schritt 1, 11, 12

◆ WAS DU JETZT KANNST

Damit ist die **gesamte beschreibende Statistik** abgeschlossen: ein Merkmal (Tag 2–4) und zwei Merkmale (Tag 5–6). In der Probeklausur sind das die Aufgaben 1, 2 und 5 — **35 von 75 Punkten**.

Ab morgen beginnt der zweite große Block: **Wahrscheinlichkeitsrechnung**. Die bedingten Anteile von gestern heißen dort bedingte Wahrscheinlichkeiten — und führen direkt zu Bayes (Probeklausur A3, 11 Punkte).