



Probeklausur zur Maximum-Likelihood-Schätzung

Datum:	Sommersemester 2026								
Prüfungsfach:	STATISTIK (TEIL B) (SoSe 2026)								
Themensteller*innen:	T. Kneib, A. Silbersdorff, S. Kuhls								
Kandidat*in									
Matrikel-Nr.:	<table border="1"><tr><td></td><td></td><td></td><td></td><td></td><td></td><td></td><td></td></tr></table>								
Fachrichtung:									
Raum:									
Platz:									
Bitte beachten Sie:	▪ Versehen Sie alle Seiten mit Ihrer Matrikelnummer. ▪ Schreiben Sie leserlich. ▪ Lösen Sie nicht die Heftung der Klausur. ▪ Beachten Sie auch die Hinweise auf der nächsten Seite!								
Zugelassene Hilfsmittel:	▪ Zugelassener Taschenrechner ▪ Schreibutensilien ▪ Ein (auch beidseitig) handschriftlich beschriebenes DIN A4-Blatt, das mit Ihrer Matrikelnummer, Raum und Platznummer gekennzeichnet ist und mit der Klausur abgegeben werden muss.								
Seitenumfang:	5 + Deckblatt + Hinweise + Beispielaufgabe								
Anzahl der Aufgaben:	1								
Gesamtpunktzahl:	45								

Auszufüllen nur durch eine Aufsichtsperson

Identitätskontrolle:

Formelblatt: ☐ handschriftlich ☐ Kopie ☐ nicht vorhanden

Klausurergebnis

Punktzahl (1. Durchlauf)	Änderungen	Punktzahl (Endergebnis)	Note

Hinweise

Allgemeines:

- Bei der Bewertung werden ausschließlich die auf ILIAS eingereichten Lösungen berücksichtigt. Verfassen Sie daher Ihre Antworten ausschließlich in ILIAS.
- Speichern Sie Ihre digital verfassten Antworten und Rechnungen regelmäßig ab, insbesondere das R-Skript.
- Arbeiten Sie ausschließlich in dem Ordner Dokumente.
- Lesen Sie genau, wonach gefragt wird und wie die Lösung anzugeben ist.
- Folgefehler aus vorherigen Teilaufgaben werden berücksichtigt. Fehlende Objekte aus vorherigen, nicht komplettierten Aufgaben sind entsprechend bei Bedarf mit nachvollziehbarem R-Skript anderweitig zu erstellen. Sollten Sie Probleme beim korrekten Einlesen des Datensatzes haben, geben Sie die R-Befehle ohne den Datensatz in ILIAS an.
- Im Rahmen dieser Klausur wird die Dezimalpunkt-Notation – d. h. ein Dezimalpunkt als Dezimaltrennzeichen – verwendet. Wir empfehlen, diese Notation auch für Ihre Antworten zu verwenden; andernfalls ist explizit anzugeben, dass Sie eine anderweitige Dezimalnotation verwenden.
- Für jede Aufgabe ist die maximal erreichbare Punktzahl angegeben.
- Die Bearbeitungszeit beträgt 60 Minuten.

Form der Einträge in ILIAS:

- Die Struktur Ihrer Antworten in ILIAS gliedert sich pro Teilaufgabe in bis zu zwei Blöcke: Je nach Aufgabenstellung werden Sie aufgefordert, inhaltliche Antworten und/oder R-Code und R-Output in die dafür vorgesehenen Antwortboxen einzutragen. Orientieren Sie sich hinsichtlich der Struktur Ihrer Antworten an der unten aufgeführten Beispielaufgabe. Bei allen Antworten wird erwartet, dass Sie Ihren gesamten Lösungsweg aufzeigen und auf eine nachvollziehbare Struktur achten.
- Ggf. werden Sie aufgefordert, eine über R erstellte graphische Darstellung in ein vorgegebenes Dateiformat abzuspeichern und die Datei auf ILIAS hochzuladen. Im Titel der Grafik müssen über die Option `main` der Aufgabenteil, Ihre Matrikelnummer und Ihre Sitzplatznummer angegeben werden. Des Weiteren sind die Achsen der Aufgabenstellung entsprechend zu beschriften.
- Nicht-numerische Antworten sollen in vollen Sätzen verfasst werden.
- Numerische Ergebnisse (auch jene in Antwortsätzen) sollen – sofern nicht anderweitig spezifiziert – **auf drei Nachkommastellen gerundet** werden. Nutzen Sie zum Runden stets einen geeigneten R-Befehl.
- Ihre Antwortsätze in ILIAS inklusive des angehängten R-Outputs sollten **eindeutig** und von widersprüchlichen Mehrfachlösungen frei sein. Fehlerhafter R-Code, welcher nicht Teil der Antwort ist, ist aus der Antwort in ILIAS entsprechend zu streichen und sollte nicht mit eingereicht werden.

Beispielaufgabe:

Nutzen Sie den Datensatz `data.csv` mit 100 Beobachtungen der Zufallsvariablen X und Y , um die folgenden Aufgaben zu bearbeiten:

- (a) Speichern Sie den Datensatz in R als Dataframe unter dem Objektnamen `d` ab.
Nutzen Sie hierfür die Antwortbox der Aufgabe 1 in ILIAS. (2 Punkte)
- (b) Berechnen Sie das arithmetische Mittel der Beobachtungen von X .
Nutzen Sie hierfür die Antwortboxen der Aufgaben 2 und 3 in ILIAS. (3 Punkte)
- (c) Visualisieren Sie einen Kerndichteschätzer der Verteilung der Variable Y .
Nutzen Sie hierfür die Antwortboxen der Aufgaben 4 und 5 in ILIAS. (5 Punkte)
- (d) Nennen Sie einen Vorteil des Medians als Lagemaß gegenüber dem arithmetischen Mittel.
Nutzen Sie hierfür die Antwortbox der Aufgabe 6 in ILIAS. (2 Punkte)

Beispielantwort:

Frage und Antwortbox 1 (in ILIAS):

Geben Sie im folgenden Kästchen Ihre Antwort für den Aufgabenteil a) in Form von R-Code und R-Output an. Beachten Sie hinsichtlich der Struktur Ihrer Antwort die Hinweise auf dem Aufgabenzettel.

```
1 > setwd(path.expand("~/"))
2 > d <- read.table("data.csv", sep=";")
```

Frage und Antwortbox 2 (in ILIAS):

Geben Sie im folgenden Kästchen den für Ihre Antwort erforderlichen R-Code und R-Output zum Aufgabenteil b) an. [...]

```
1 > mean(d$X)
2 [1] 1.17
```

Frage und Antwortbox 3 (in ILIAS):

Geben Sie im folgenden Kästchen Ihre inhaltliche Antwort (ohne R-Code und R-Output) für den Aufgabenteil b) an. [...]

Das arithmetische Mittel der Variable X ist 1.170.

Frage und Antwortbox 4 (in ILIAS):

Geben Sie im folgenden Kästchen den für Ihre Antwort erforderlichen R-Code und R-Output zum Aufgabenteil c) an. [...]

```
1 plot(density(d$Y),
2      main="Sitz 00, Matr.Nr. 31415926,
3      Beispielaufgabe (c)",
      xlab="Y", ylab="Dichte")
```

Frage und Antwortbox 5 (in ILIAS):


Laden Sie die PDF-Datei mit der zu erstellenden Grafik für Aufgabenteil c) hoch.

Frage und Antwortbox 6 (in ILIAS):

Im folgenden Kästchen geben Sie bitte Ihre inhaltliche Antwort zu Aufgabenteil d) an.
[...]

Der Median ist robuster gegenüber Extremwerten als das arithmetische Mittel.

Die hochgeladene PDF-Datei für Aufgabenteil c) sollte folgende Grafik enthalten:



Aufgabe 3 (45 Punkte)

Im Nachgang der Corona-Pandemie beschäftigten sich die medizinische Forschung und Statistik zunehmend mit der Messung des menschlichen Lungenvolumens. Im Schnitt hat eine gesunde erwachsene Person ein Lungenvolumen von zwei bis drei Litern. Die individuellen Werte einer Person geben dabei Aufschluss über ihre Lungenfunktion. Leistungssportler*innen können ein Volumen von bis zu acht Litern erreichen.

Im Datensatz `Lungenvolumen.csv` liegen Ihnen Daten über das Lungenvolumen von 400 Personen aus dem Jahr 2022 vor. Laden Sie den Datensatz aus dem Ordner **Großübung (Testate)** in Stud.IP herunter und legen Sie ihn im Ordner **Dokumente** auf Ihrem PC ab. Definieren Sie anschließend Ihren Dokumente-Ordner als Working Directory in R. Lesen Sie den Datensatz in R ein und speichern Sie ihn als Data Frame unter dem Objektnamen `df` ab.

Hinweis: In der Klausur lautet die entsprechende Anweisung „Die Daten sind in der Datei `Lungenvolumen.csv` abgespeichert. Diese Datei ist auf Ihrem lokalen Laufwerk in dem Ordner **Dokumente** hinterlegt. In diesem Ordner sollten Sie auch mit R arbeiten und jegliche Dateien (Skripte, Abbildungsdateien, etc.), welche Sie abspeichern, hinterlegen.“

- (a) Setzen Sie mittels eines geeigneten Befehls Ihr Working Directory, um in dem lokalen Ordner **Dokumente** zu arbeiten.

Hinweis: In der Klausur lautet die entsprechende Anweisung „Setzen Sie mittels `setwd(path.expand("~/"))` Ihr Working Directory, um in dem lokalen Ordner **Dokumente** zu arbeiten.“

Nutzen Sie für Ihre Antwort das Kästchen zu Frage 1 in Ilias.

(2 Punkte)

- (b) Speichern Sie die in der Datei hinterlegten Daten als Data-Frame-Objekt `df` in R ab und geben Sie die ersten 6 Zeilen des Data-Frame-Objektes wieder.

Nutzen Sie für Ihre Antwort das Kästchen zu Frage 2 in Ilias.

(2 Punkte)

- (c) Der erstellte Data Frame ist eine spezielle Form der Liste, welche wiederum eine

Sammlung potentiell verschiedener Objekttypen darstellt. Ermitteln Sie unter Einbezug eines passenden R-Befehls den Objekttypen der im gespeicherten Objekt `df` enthaltenen Variable `Lungenvolumen`.

Nutzen Sie für Ihre Antwort die Kästchen zu den Fragen 3 und 4 in Ilias.

(2 Punkte)

- (d) Bestimmen und nennen Sie den Wertebereich sowie die unverzerzte Varianz der Variable `Lungenvolumen`. Runden Sie Ihr Ergebnis auf 2 Nachkommastellen.

Nutzen Sie für Ihre Antwort die Kästchen zu den Fragen 5 und 6 in Ilias.

(4 Punkte)

- (e) Erstellen Sie auf Grundlage der gegebenen Daten ein normiertes Histogramm für die Variable `Lungenvolumen`.

- Beschriften Sie die x-Achse mit `Lungenvolumen`,
- die y-Achse mit `Wahrscheinlichkeitsdichte`,
- und geben Sie dem Diagramm den Titel `Grafik Aufgabenteil e)` und fügen Sie außerdem Ihre Sitzplatz- und Matrikelnummer hinzu.

Speichern Sie die Grafik als .pdf-Datei unter dem Namen **Histogramm.pdf** in Ihrem Working Directory ab und laden Sie diese Datei anschließend hoch.

Nutzen Sie für Ihre Antwort die Kästchen zu den Fragen 7 und 8 in Ilias.

(7 Punkte)

- (f) Im Folgenden soll nun mit Hilfe der Maximum-Likelihood-Methode eine parametrische Verteilung der `Lungenvolumen`-Werte geschätzt werden. Dabei wird bei der Parameterschätzung üblicherweise nicht direkt die Likelihood maximiert.

- Welches Problem tritt bei der direkten Optimierung der Likelihood in R auf?
- Nennen Sie eine Transformation der Likelihood, die üblicherweise verwendet wird, um das obengenannte Problem zu umgehen.

Nutzen Sie für Ihre Antwort das Kästchen zu Frage 9 in Ilias.

(2 Punkte)

- (g) Nehmen Sie an, dass die Daten einer Gamma-Verteilung folgen. Die Gamma-

Verteilung besitzt den Formparameter α , den Skalenparameter β und die Dichte

$$f(x) = \frac{1}{\beta^\alpha \Gamma(\alpha)} x^{\alpha-1} e^{-x/\beta}, \quad x \geq 0, \alpha > 0, \beta > 0,$$

die in R über den Befehl `dgamma()` implementiert ist. In den folgenden Teilaufgaben sollen Sie die Maximum-Likelihood-Methode zur Schätzung der Parameter α und β anwenden.

Auf welchen Zahlenraum sind die Parameter α und β restringiert? Welches Problem ergibt sich, wenn die Optimierungsfunktion `nlm()` über ganz $\mathbb{R}$, also im gesamten Raum der reellen Zahlen, nach Optima sucht?

Nutzen Sie für Ihre Antwort das Kästchen zu Frage 10 in Ilias.

(2 Punkte)

- (h) Schreiben Sie eine Funktion `neglogL(transformed_param, x)`, welche für einen beliebigen transformierten Parametervektor $\begin{pmatrix} \alpha^t \\ \beta^t \end{pmatrix}$ und den gegebenen Beobachtungsvektor x die negative Log-Likelihood berechnet.

Wählen Sie für die restringierten Parameter α und β eine geeignete Transformationen $\alpha^t = g(\alpha)$ und $\beta^t = h(\beta)$, sodass α^t und β^t Werte aus dem gesamten reellen Zahlenraum annehmen können. Nutzen Sie sodann die transformierten Parameter α^t und β^t innerhalb Ihrer Funktion zur Berechnung der negativen Log-Likelihood.

Nutzen Sie für Ihre Antwort das Kästchen zu Frage 11 in Ilias.

(8 Punkte)

- (i) Bestimmen Sie auf Grundlage dieser Funktion den Maximum-Likelihood-Schätzer mittels der Optimierungsroutine `nlm` und speichern Sie diesen in dem Objekt `model` ab. Nutzen Sie für die Optimierung die Startwerte $\alpha^t = 0.01$ und $\beta^t = 0.5$.

Nutzen Sie für Ihre Antwort das Kästchen zu Frage 12 in Ilias.

(4 Punkte)

- (j) Speichern Sie anschließend die erhaltenen Parameterschätzer für α und β in der Rücktransformation unter den Objekten `alpha.hat` und `beta.hat` ab und lassen

Sie sich die Werte in R ausgeben.

Nutzen Sie für Ihre Antwort die Kästchen zu den Fragen 13 und 14 in Ilias.

(4 Punkte)

- (k) Zeichnen Sie die parametrische Dichteverteilung in das bestehende Histogramm aus Aufgabe (a) ein.

Nutzen Sie für Ihre Antwort das Kästchen zu Frage 15 in Ilias.

(4 Punkte)

- (l) Wie hoch ist die Wahrscheinlichkeit, dass Sie bei Ihrer parametrischen Schätzung einen Wert von maximal 3 Liter Lungenvolumen erhalten?

Nutzen Sie für Ihre Antwort die Kästchen zu den Fragen 16 und 17 in Ilias.

(2 Punkte)

- (m) Ab welchem Wert gehört ein Mensch auf Basis des geschätzten Modells zu den 25% mit dem größten Lungenvolumen?

Nutzen Sie für Ihre Antwort die Kästchen zu den Fragen 18 und 19 in Ilias.

(2 Punkte)

erreichte Punkte
