

Aufgabe 1 (10 Punkte)

Harry möchte gerne für seine ZAGs (Zauberergrade) die Entwicklung der Genauigkeit von Vorhersagen der einschlägigen Wahrsagerin Giesela Baumrasen untersuchen. Er vermutet, dass die meisten Vorhersagen falsch sind und befragt zufällig 20 Schüler*innen, ob ihre Vorhersagen eingetroffen sind. Dabei steht eine **1** für eine korrekte Vorhersage und **0** für eine falsche Vorhersage.

```
1 > sort(Vorhersagen)
2 [1] 0 0 0 0 0 0 0 0 0 0 0 0 1 1 1 1 1 1 1 1
```

- (a) Geben Sie das Skalenniveau des Merkmals 'Korrektheit der Vorhersagen' an.

- (b) Berechnen Sie die folgenden Lage- und Streuungsparameter der Variable Vorhersagen.

Falls Sie der Meinung sind, dass ein Parameter nicht sinnvoll angegeben werden kann, **begründen Sie kurz in einem Satz**. Sie können den obigen R-Output benutzen.

 $x_{mod} =$ _____ $x_{med} =$ _____ $\bar{x} =$ _____

$$s_x^2 =$$

Lösung:

(a) Ordinalskaliert/Binär

(b) $x_{mod} = 0$, $x_{med} = 0$, $\bar{x} = 0.45$, $s_x^2 = 0.248$ ODER $s_x^2 = NA$: Weil Daten ordinalskaliert sind, ist die Varianz nicht sinnvoll zu interpretieren.

Aufgabe 2 (14 Punkte)

Der Betreiber der Bar „BierWirdGeschafft“ möchte sich für den gigantischen Ansturm an Tourist*innen im Sommer rüsten. Daher plant der Betreiber Klaus Stani den Einkauf alkoholischer Getränke für die Sommerferien. Der Betreiber steht vor der Entscheidung, eine bayrische oder westfälische Biersorte zu bestellen. Hierzu erfasste er die Menge des getrunkenen Bieres X in Litern (l) im letzten Jahr vor der Pandemie sowie die Herkunft der Gäste Y (Bayern (BY) oder Nordrhein-Westfalen (NRW)).


Menge in l	x_i	8.5	8.5	4.0	4.0	12.0	12.0	8.5	15.7	4.0	8.5
Herkunft	y_i	BY	BY	NRW	BY	NRW	BY	BY	NRW	NRW	BY

Hinweis: $\sum_{i=1}^{10} x_i = 85.7$; $\sum_{i=1}^{10} x_i^2 = 871.49$

- (a) Geben Sie für X und Y an, ob ein diskretes oder stetiges Merkmal vorliegt! Welches Skalenniveau liegt jeweils zugrunde? (4P)

X :


Y :



(b) Zeichnen Sie die empirische Verteilungsfunktion für X ! (6P)



(c) Klassieren Sie den Bierkonsum in die Klassen $K_1 = [0, 10)$ und $K_2 = [10, 20]$ und bestimmen Sie den Mittelwert für die klassierten Daten! (4P)



Lösung:

(a)

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{1}{10} \cdot 85.7 = 8.570$$

$$\tilde{s}_x^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2 = \frac{1}{10} \cdot 871.49 - 8.57^2 = 13.704$$

$$\tilde{s}_x = 3.702$$

(b)

Y - nominal skaliert $\Rightarrow$ Modus

$$\text{Mode}(Y) = BY$$


(c)

X - stetig + metrisch skaliert (Verhältnisskala)

Y - diskret + nominal skaliert

(d)

$$\hat{F}(x) = \begin{cases} 0 & \text{für } x < 4 \\ 0.3 & \text{für } 4 \leq x < 8.5 \\ 0.7 & \text{für } 8.5 \leq x < 12 \\ 0.9 & \text{für } 12 \leq x < 15.7 \\ 1 & \text{für } x \geq 15.7 \end{cases}$$



(e)

$$n(K_1) = 7$$

$$n(K_2) = 3$$

$$m_1 = 5$$

$$m_2 = 15$$

$$\bar{x}_K = \frac{1}{10} (7 \cdot 5 + 3 \cdot 15) = 8$$

Aufgabe 3 (11 Punkte)

Franziska hat das Corona-Semester genutzt und sämtliche Flixnet Serien durchgeschaut. Nun hat sie mit ihren Mitstudierenden festgestellt, dass ihnen nur noch zwei Tage bis zur nächsten Klausur verbleiben. Sie möchte nun dennoch all ihre Energie bündeln und sich auf diese vorbereiten. Um in der wenigen Zeit so effektiv wie möglich zu lernen, möchte sie die beste Strategie zum Bestehen finden. Dazu befragt sie Studierende, die bereits im letzten Jahr geschrieben haben. Franziska weiß, dass die Wahrscheinlichkeit, jene Klausur zu bestehen, 70% betrug.

Unter den Studierenden konnte sie drei (sich gegenseitig ausschließende) Lernstrategien feststellen:

1. Regelmäßiges Lernen mit selbstständigem Rechnen der Aufgaben
2. Ansehen der Lernvideos ohne aktive Mitarbeit
3. Gänzlich ohne Lernen

Zunächst betrachtet sie die Studierenden, die bestanden haben: Mit einer Wahrscheinlichkeit von 80% gehört ein Studierender, der bestanden hat, der ersten Kategorie an. Mit einer Wahrscheinlichkeit von 15% gehört ein Besteher der zweiten Kategorie an.

Franziska hat in einer Flixnet-Pause aus schlechtem Gewissen ein Video einer Vorlesung gesehen und weiß, dass man auch die Studierenden, die nicht bestanden haben, betrachten sollte. Mit einer Wahrscheinlichkeit von 10% gehört ein Nicht-Besteher zur ersten Kategorie und mit einer Wahrscheinlichkeit von 20% gehört ein Nicht-Besteher zur zweiten Kategorie.

(a) Berechnen Sie die folgenden Wahrscheinlichkeiten. (7P)

$$P(\text{"Nicht-Bestehen"}) =$$

--

$$P(\text{"Strategie 3"}|\text{"Bestehen"}) =$$

--

$$P(\text{"Strategie 3"}|\text{"Nicht Bestehen"}) =$$

--

Berechnen Sie nun die Wahrscheinlichkeit, dass eine Person in der Klausur sitzt und nicht gelernt hat (Strategie 3)!

--

- (b) Franziska entscheidet sich für die zweite Lernstrategie. Wie groß ist die Wahrscheinlichkeit, dass sie besteht? Geben Sie Ihren Lösungsweg an. (2P)

- (c) Wie groß ist die Wahrscheinlichkeit, dass sich unter den ersten zehn befragten Studierenden mindestens eine Person befindet, die nicht bestanden hat? (Gehen Sie davon aus, dass die Auswahl unabhängig und zufällig erfolgte und für alle Studierenden die obige Bestehenswahrscheinlichkeit gilt.) **Vereinfachen Sie hierbei so weit wie möglich!** (2P)

Lösung:

B – "Bestehen" $P(B) = 0.7$

$$A_1 - \text{"Strategie 1"} \quad P(A_1|B) = 0.8 \quad P(A_1|\bar{B}) = 0.1$$

$$A_2 - \text{"Strategie 2"} \quad P(A_2|B) = 0.15 \quad P(A_2|\bar{B}) = 0.2$$

$$A_3 - \text{"Strategie 3"}$$

1.

$$P(\bar{B}) = 0.3$$

$$P(A_3|B) = 1 - P(A_1|B) - P(A_2|B) = 0.05$$

$$P(A_3|\bar{B}) = 1 - P(A_1|\bar{B}) - P(A_2|\bar{B}) = 0.7$$

$$P(A_3) = P(A_3|B) \cdot P(B) + P(A_3|\bar{B}) \cdot P(\bar{B}) = 0.245$$

2. gesucht:

$$P(B|A_2)$$

$$P(A_2) = P(A_2|B) \cdot P(B) + P(A_2|\bar{B}) \cdot P(\bar{B}) = 0.165$$

$$P(B|A_2) = \frac{P(A_2|B) \cdot P(B)}{P(A_2)} = 0.6364$$

3. X – "Anzahl der Nicht-Besteher unter 10 befragten Personen"

$$X \sim B(10, 0.3)$$

$$P(X \geq 1) = 1 - P(X = 0) = 1 - \binom{10}{0} 0.3^0 0.7^{10} = 0.9718$$

Aufgabe 4 (6 Punkte)

Ihnen sei folgender Ergebnisraum $\Omega = \{1, 2, 3, 4, 5, 6, 7, 8, 9\}$ eines Laplace-Experiments gegeben. Außerdem seien die Mengen $A = \{1, 3, 6, 7\}$, $B = \{1, 3, 6, 9\}$ bekannt.

- (a) Berechnen Sie die folgenden Mächtigkeiten (Anzahl an Elementen in einer Menge).

$$|A \cap \bar{B}| =$$

$$|\bar{A} \cup B| =$$

- (b) Berechnen Sie die Wahrscheinlichkeit, dass A eintritt, wenn Sie wissen, dass B **nicht** eingetreten ist **und** tragen Sie links die korrekte Notation für die gesuchte Wahrscheinlichkeit in die beiden Lücken ein.

$$P(\quad | \quad) =$$

Lösung:

(a) $|A \cap \bar{B}| = 1, \quad |\bar{A} \cup B| = 8$

(b) $P(A|\bar{B}) = \frac{1}{5}$

Aufgabe 5 (11 Punkte)

Der Nationaltrainer des deutschen Biathlon-Frauennationalteams ist unzufrieden mit den letzten Ergebnissen seiner Favoritin Franziska Herrfrau. Er vermutet einen Zusammenhang zwischen der Fehlerquote im Schießen (X) und der Laufzeit (gemessen in Minuten) für 7,5 km (Y). Die Grundlage seiner Beobachtungen bilden 6 Trainingseinheiten aus der Saison 2021/22:

Trainingseinheit	ν	1	2	3	4	5	6
Schießfehler (gesamt)	x_ν	3	2	5	1	3	4
Laufzeit für 7,5 km (in min)	y_ν	18	20	26	24	25	19

- (a) Berechnen Sie die empirische Varianz für Franziskas Schießfehler. Geben Sie Ihren Lösungsweg an: (2 P)

$s_x^2 =$

- (b) Ermitteln Sie den Korrelationskoeffizienten ρ_{xy} aus den Werten der obigen Tabelle. Verwenden Sie im Folgenden für die Berechnung die hier angegebenen, stark gerundeten Werte:


$$s_y^2 = 10, \quad s_x^2 = 1.6, \quad \bar{y} = 22 \quad \text{und} \quad \sum_{\nu=1}^6 (x_{\nu} \cdot y_{\nu}) = 399$$

Geben Sie Ihren Lösungsweg an: (3 P)

Interpretieren Sie den berechneten Wert. Wenn Sie den Wert nicht berechnen konnten, interpretieren Sie $\rho_{xy} = 0.2$. (2 P)

- (c) Der Trainer behauptet, dass ein hoher Korrelationskoeffizient bedeutet, dass die vielen Schießfehler zur schwachen Laufleistung führen. Stimmen Sie dieser Aussage zu? Begründen Sie in 1–2 Sätzen. (2 P)

- (d) Skizzieren Sie ein mögliches Streudiagramm, wenn der Wert des Korrelationskoeffizienten zwischen der Laufzeit und den Schießfehlern $\rho_{xy} = 0$ beträgt. (2 P)



Lösung:

- (a) Varianz:

$$\bar{x} = \frac{1}{n} \sum x_{\nu} = 3$$

$$\bar{x}^2 = \frac{1}{n} \sum x_{\nu}^2 = 9$$

$$S_x^2 = 1.667$$

- (b) Gesamtmittelwert: $\bar{xy} = \frac{399}{6} = 66.5$

$$\text{Berechnung Kovarianz: } s_{xy} = \bar{xy} - \bar{x} \cdot \bar{y} = \frac{399}{6} - 3 \cdot 22 = 0.5$$

$$\text{Berechnung Korrelationskoeffizient: } r_{xy} = \frac{0.5}{\sqrt{1.6 \cdot 10}} = 0.5 / \sqrt{16} = 0.125$$


Interpretation: Es handelt sich um die normierte Kovarianz. Der Koeffizient gibt den **Grad des linearen Zusammenhangs von X und Y** an. Der Korrelationskoeffizient kann Werte zwischen -1 und +1 annehmen. Ein **positiver Kor-**

relationskoeffizient bedeutet eine positive Korrelation. Bei einer positiven Korrelation **steigt eine Variable, wenn die andere auch steigt**. Hier kann man von einer **niedrigen positiven Korrelation** ausgehen.

(c) Nein, statistische Analysen liefern keinen Nachweis einer Kausalität, der Zusammenhang könnte auch durch dritten Variablen entstehen.

(d) Eine mögliche Skizze eines Streudiagramms inklusive Beschriftung (fehlt hier)

z.Bsp:



Aufgabe 6 (10 Punkte)

Sie denken darüber nach, sich ein gebrauchtes Elektroauto zu kaufen. Um abzuschätzen, ob sich der Kauf lohnt, betrachten Sie die Zufallsvariable X , wobei

X : Monate bis zum Defekt des Motors.

Gehen Sie davon aus, dass X Weibull-verteilt ist mit zunächst unbekannten Parametern λ und r . Für $x \geq 0$ ist die Dichte somit gegeben durch

$$f(x; \lambda, r) = r\lambda(\lambda x)^{r-1} \exp(-(\lambda x)^r)$$

und die Verteilungsfunktion durch


$$F(x; \lambda, r) = 1 - \exp(-(\lambda x)^r)$$

Nehmen Sie im Folgenden an, dass $r = 1$. Stellen Sie die den Maximum-Likelihood-Schätzer für λ basierend auf einer Stichprobe von n Beobachtungen $X_1, \dots, X_n$, wobei die X_i identisch und unabhängig verteilt sind.


- (a) Stellen Sie hierfür zunächst die Log-Likelihood auf. Geben Sie Ihren vollständigen Lösungsweg an (vereinfachen Sie ihr Endresultat so weit wie möglich!):

A large, empty rectangular box with a thin black border, occupying the central portion of the page. It is intended for the student to write their answers to the exam questions.

- (b) Bestimmen Sie auf Grundlage ihres Ergebnisses aus (a) den Maximum-Likelihood-Schätzer. Geben Sie Ihren vollständigen Lösungsweg an.



- (c) Prüfen Sie auch die hinreichende Bedingung, bzw. die Bedingung zweiter Ordnung!



Lösung:

(a) Die log-Likelihood Funktion ist gegeben durch:

$$LL(x_1, \dots, x_n; \lambda) = n \log(\lambda) - \lambda \sum_{i=1}^n x_i$$

(b) ML-Schätzer:

$$\hat{\lambda}_{ML} = \frac{n}{\sum_{i=1}^n x_i}$$

Aufgabe 7 (5 Punkte)

Sei X eine Zufallsvariable mit $E(X) = \frac{\alpha}{4}$ mit $\alpha \in \mathbb{R}$. Nun ziehen Sie eine n -fache, unabhängige Zufallsstichprobe $\{X_1, \dots, X_n\}$ dieser Zufallsvariablen.

Testen Sie, ob der Schätzer

$$\hat{\alpha} = \frac{\prod_{i=2}^{n-1} X_i}{\prod_{i=1}^{n-1} X_i} + \frac{X_n}{\alpha} - \frac{1}{4}$$

ein unverzerrter Schätzer für α ist.

Lösung:

Unverzerrt, wenn $E(\hat{\alpha}) \stackrel{!}{=} \alpha$

$$\begin{aligned} E(\hat{\alpha}) &= E\left(\frac{\prod_{i=2}^{n-1} X_i}{\prod_{i=1}^{n-1} X_i} + \frac{X_n}{\alpha} - \frac{1}{4}\right) \\ &= E\left(\frac{\prod_{i=2}^{n-1} X_i}{\prod_{i=1}^{n-1} X_i}\right) + E\left(\frac{X_n}{\alpha}\right) - E\left(\frac{1}{4}\right) \\ &= E\left(\frac{1}{X_1}\right) + \frac{E(X_n)}{\alpha} - E\left(\frac{1}{4}\right) \\ &= \frac{1}{\frac{\alpha}{4}} + \frac{\frac{\alpha}{4}}{\alpha} - \frac{1}{4} \\ &= \frac{4}{\alpha} + \frac{1}{4} - \frac{1}{4} = \frac{4}{\alpha} \neq \alpha \rightarrow \text{Verzerrter Schätzer} \end{aligned}$$

Aufgabe 8 (8 Punkte)

Bei der 4-Schanzentournee treten die Skispringer M. Stahlbichler und K. Fiedler gegeneinander an. Sie wollen herausfinden, welcher der beiden Sportler weiter springt. Sie beobachten dafür beim ersten Springen in Oberstdorf sowohl die Weiten im Probesprung, der Qualifikationsrunde sowie in den zwei Hauptrunden. Die 4 Beobachtungen sind in der folgenden Tabelle aufgeführt

Sprung	1	2	3	4	$\bar{x}$
Stahlbichler	130	134	129.5	132.5	131.5
Fiedler	131	135.5	131.5	136	133.5

Näherungsweise nehmen Sie an, dass die Varianz der Sprungweite bekannt sei und $\sigma^2 = 16$ beträgt. Gehen Sie davon aus, dass die Beobachtungen jeweils einer Normalverteilung folgen ($N(\mu_1, \sigma^2)$ für Stahlbichler und $N(\mu_2, \sigma^2)$ für Fiedler).

Nun wollen Sie statistisch absichern, dass ihr Favorit Fiedler tatsächlich weiter springt als sein Konkurrent Stahlbichler. Überprüfen Sie hierzu zunächst mithilfe eines statistischen Tests, dass Stahlbichler nicht weiter als 133.5 m springt.

- (a) Stellen Sie das passende Hypothesenpaar auf. (2 P)

- (b) Berechnen Sie die Prüfgröße und geben Sie ihre Verteilung an. (3 P)

- (c) Ein Kommilitone will R benutzen, um zu einem Signifikanzniveau von 10% statistisch abzusichern, dass Stahlbichler nicht weiter als 133.5 m fliegt. Leider ist er sich nicht sicher und probiert mehrere Möglichkeiten:

(1)

```
1 x <- c(131, 135.5, 131.5, 136)
2 t.test(x,mu=133.5,alternative="l",conf.level
   =0.9)
3   One Sample t-test
4 t = ?, df = 3, p-value = 0.5
```

(2)

```
1 x <- c(130, 134, 129.5, 132.5)
2 t.test(x,mu=133.5,alternative="l",conf.level
   =0.9)
3   One Sample t-test
4 t = ?, df = 3, p-value = 0.07791
```

(3)

```
1 x <- c(130, 134, 129.5, 132.5)
2 t.test(x,mu=133.5,alternative="g",conf.level
   =0.9)
3   One Sample t-test
4 t = ?, df = 3, p-value = 0.9221
```

Geben Sie die Nummer des R-Codes an, den Sie wählen würden, um den Test durchzuführen. (1 P)

Treffen Sie anhand des R-Codes eine Testentscheidung und begründen Sie diese.
(2 P)

Lösung:

- (a) Wir wollen beweisen, dass der Durchschnitt von SBs Sprüngen signifikant kleiner ist, als 133.5. Dies ist also unsere Alternativhypothese.

$$H_0 : \mu \geq 133.5 \text{ und } H_1 : \mu < 133.5$$

- (b) Prüfgröße: $Z = \frac{\bar{X} - \mu_0}{\sigma} \cdot \sqrt{n} \sim N(0, 1)$, wobei:

- $\bar{X}$: Mittelwert der Beobachtungen (hier Mittelwert der Sprünge von SB)
- μ_0 : Wert von μ aus der Nullhypothese
- σ : (bekannte) Standardabweichung
- n : Stichprobengröße

$$\text{Durch Einsetzen ergibt sich: } Z = \frac{\bar{X} - \mu_0}{\sigma} \cdot \sqrt{n} = \frac{131.5 - 133.5}{\sqrt{16}} \cdot \sqrt{4} = -1$$

- (c) Da wir absichern wollen, dass der zu erwartende Wert *kleiner* ist als ein bestimmter Wert, handelt es sich hier um einen linksseitigen Test. Somit ist R Code (2) der richtige.

- Begründung über p-Wert, H_0 kann abgelehnt werden
 - damit springt SB nicht weiter als F zu einem Signifikanzniveau von 0.1
-

Begründung nicht lösbare Aufgabe(n)

Nutzen Sie die folgende Box für jegliche Erläuterungen, wenn Aufgabenstellungen Ihrer Meinung nach nicht lösbar, widersprüchlich oder unzureichend definiert sind. Notieren Sie hierfür eindeutig, auf welche Aufgabe Sie sich beziehen.