

Daten- und Merkmalstypen

Dr. Alexander Silbersdorff

Leiter der Arbeitsgruppe Learning Analytics und Data Literacy

Sommersemester 2026



Voraussetzungen

- Zahlenmengen ($\Rightarrow$ M-V01)

Lernziele

- Welche Grundbegriffe sind zur Beschreibung statistischer Fragestellungen notwendig?
- Wie unterscheiden sich verschiedene Arten statistischer Daten voneinander?
- Welche Rolle spielen Stichproben und ihre Erhebung in der statistischen Analyse von Daten?

Grundbegriffe

- **Statistische Einheiten:** Die im Rahmen der statistischen Untersuchung interessierenden Objekte, an denen die Daten erhoben werden
- **Grundgesamtheit/Population:** Menge aller für die Fragestellung relevanten statistischen Einheiten
- **Stichprobe:** Teilmenge der Grundgesamtheit, die der Untersuchung zugrunde liegt

Beispiel: Wahlumfrage

- Umfrage zu Wahlentscheidungen
 - Statistische Einheiten: Wahlberechtigte Personen
 - Grundgesamtheit: Alle im Rahmen der nächsten Bundestagswahl wahlberechtigten Personen
 - Stichprobe: Die im Rahmen der Wahlumfrage zu ihrer Parteipräferenz befragten Personen

Beispiel: Politikmaßnahme

- Einfluss einer Politikmaßnahme auf die Emissionen von Firmen
 - Statistische Einheiten: Firmen
 - Grundgesamtheit: Alle von der Politikmaßnahme betroffenen Firmen
 - Stichprobe: Firmen, für die tatsächlich Informationen zu den Emissionen vor und nach Einführung der Politikmaßnahme vorliegen

Anmerkungen zu den Grundbegriffen

- Statistische Einheiten können auch abstrakte Größen sein.
- Die Grundgesamtheit kann ebenfalls nur hypothetischen Charakter besitzen.
- Beispiele:
 - Grundgesamtheit = Menge aller in einer Firma produzierten Güter
 - Untersuchung zu einer allgemeinen Gesetzmäßigkeit (Einsatz eines Düngemittels erhöht den Ertrag)

Merkmale und Merkmalsausprägungen

- **Merkmale:** Eigenschaften der statistischen Einheiten, die im Rahmen der statistischen Analyse untersucht werden sollen
- **Merkmalsausprägung:** Ausprägung eines Merkmals für eine konkrete Einheit
- Merkmale werden in der Regel mit Großbuchstaben (z.B. X , Y , Z) bezeichnet, Ausprägungen mit den zugehörigen Kleinbuchstaben (z.B. x , y , z)

Beispiel: Wahlumfrage

- Umfrage zu Wahlentscheidungen
 - Merkmale: Alter, Geschlecht, Parteipräferenz, ...
 - Merkmalsausprägungen:
 - Alter: 18, 19, ...
 - Geschlecht: männlich/weiblich/divers
 - Parteipräferenz: CDU/CSU, AfD, SPD, Grüne, Linke, FDP, ...

Datentypen

- Für statistische Analysen muss zwischen verschiedenen Datentypen der Merkmale unterschieden werden.
- Wesentliches Unterscheidungsmerkmal ist die Anzahl möglicher Ausprägungen des Merkmals, aber auch die Skala des Merkmals.
- Je nach Datentyp kommen verschiedene statistische Methoden zum Einsatz.

Diskrete Merkmale

- Diskrete Merkmale besitzen endlich oder höchstens abzählbar unendlich viele verschiedene Ausprägungen (vgl. die natürlichen oder die rationalen Zahlen).
- Beispiele:
 - Parteipräferenz mit einer endlichen Anzahl zur Wahl stehender Parteien
 - Studienfach mit einer endlichen Anzahl möglicher Studiengänge
 - Anzahl Likes für einen Social-Media-Beitrag mit einer prinzipiell unbegrenzten, aber abzählbaren möglichen Zahl an Likes

Stetige Merkmale

- Stetige Merkmale besitzen überabzählbar unendlich viele Ausprägungen (vgl. die reellen Zahlen).
- Alle reellen Zahlen in einem Intervall sind theoretisch als Ausprägungen möglich.
- Stetige Merkmale werden auch als metrisch bezeichnet.
- Beispiele:
 - Körpergröße
 - Gewinn einer Firma in einem Jahr
 - Bruttosozialprodukt in einem gegebenen Jahr

Diskrete vs. Stetige Merkmale

- Oft ist die Unterscheidung diskreter und stetiger Merkmale in der Praxis nicht eindeutig möglich.
- So werden stetige Merkmale immer nur mit endlicher Messgenauigkeit erhoben, aber in der statistischen Analyse dennoch als stetig behandelt.
- Stetige Merkmale können nachträglich in Gruppen eingeteilt werden, beispielsweise in verschiedene Altersklassen ($\Rightarrow$ Kategorisierung stetiger Merkmale).

Skalenniveaus

- Merkmale unterscheiden sich auch anhand ihres Skalenniveaus, also der Qualität ihrer Merkmalsausprägungen.
- **Nominalskala:** Die möglichen Ausprägungen sind lediglich verschiedene Bezeichnungen, besitzen aber keine Ordnung und können auch nicht sinnvoll als Zahlen interpretiert werden.
- **Ordinalskala:** Die möglichen Ausprägungen lassen sich sinnvoll der Größe nach anordnen, aber die Abstände zwischen den Werten sind nicht sinnvoll interpretierbar.
- **Kardinalskala:** Die möglichen Ausprägungen lassen sich sinnvoll als Zahlen interpretieren, d.h. insbesondere sind die Abstände (und in der Regel auch die Verhältnisse) der Ausprägungen interpretierbar.

Beispiele

- Nominalskala:
 - Parteipräferenz
 - Nationalität
 - Verwendungszweck eines Kredits
- Ordinalskala:
 - Schulnoten
 - Einschätzung zur Kundenzufriedenheit
 - Rangordnung in Wettkämpfen
- Kardinalskala:
 - Alter bei Studienabschluss
 - Körpergröße
 - Jahreseinkommen

Skalenniveaus und Berechnungen

- Je nach Skalenniveau sind verschiedene Berechnungen sinnvoll für ein Merkmal durchführbar:

Skala	Häufigkeiten	Rangordnung	Differenzen/ Quotienten
nominal	ja	nein	nein
ordinal	ja	ja	nein
kardinal	ja	ja	ja

- Das Skalenniveau bestimmt also, welche Art von statistischem Ansatz für gegebene Merkmale anwendbar ist!

Elemente der Versuchsplanung

- Die Versuchsplanung umfasst im Allgemeinen
 - die Festlegung des Ziels der Untersuchung,
 - die Auswahl der zur Analyse geplanten statistischen Methoden,
 - die Planung der Datenerhebung und
 - verbindliche Festlegungen zu allgemeinen Aspekten der Untersuchung.

Kontrolle von Störvariablen

- Als Störvariablen bezeichnet man Merkmale, die für die untersuchten Größen grundsätzlich eine Rolle spielen, die aber für die konkrete Untersuchung nicht relevant sind.
- Beispiel: Untersuchung einer didaktischen Maßnahme zur Erhöhung des Lernerfolgs in einer Vorlesung.
 - Interessierende Größen sind hier das Vorliegen der didaktischen Maßnahme und der Lernerfolg der Studierenden.
 - Für den Lernerfolg spielen aber auch eine Vielzahl weiterer Variablen eine Rolle, z.B. Alter, Vorwissen, Lernverhalten, etc.
- Um den tatsächlichen Effekt der Maßnahme herausfinden zu können, muss für das Vorliegen solcher Störvariablen kontrolliert werden.

- Mögliche Ansätze zur Kontrolle von Störvariablen:
 - Homogenisierung: Zerlegung der Grundgesamtheit in Teilgruppen, die durch die Störvariablen festgelegt werden
 - Randomisierung: zufällige Aufteilung der Grundgesamtheit in eine Gruppe mit und eine Gruppe ohne Anwendung der didaktischen Maßnahme
 - Statistische Modellierung: explizite Berücksichtigung der Störvariablen in der statistischen Analyse
- Es existieren eine Vielzahl weiterer Möglichkeiten.

Stichproben

- Stichproben sollen möglichst **repräsentativ** für die Grundgesamtheit sein, also möglichst keine systematischen Unterschiede zur Grundgesamtheit aufweisen.
- In der Praxis kann es jedoch passieren, dass
 - eine Stichprobe Einheiten enthält, die nicht zur Grundgesamtheit gehören oder
 - nicht alle Elemente der Grundgesamtheit tatsächlich die Möglichkeit haben, in die Stichprobe zu gelangen.

Einfache Zufallsstichprobe

- Ziehen ohne Zurücklegen aus der Liste der Grundgesamtheit
- Gleiche Chance für jedes Element in die Stichprobe zu gelangen
- Gleiche Wahrscheinlichkeit für jede mögliche Stichprobe
- Keine systematischen, sondern nur zufällige Unterschiede zwischen Grundgesamtheit und Stichprobe

Weitere Techniken

- **Geschichtete Stichprobe:** Einfache Zufallsstichproben aus vorab gebildeten Teilgruppen
 - Beispiele: Geschlecht, Nationalität, Einkommensschichten
 - Vorteil: Die verwendeten Teilgruppen sind repräsentativ in der Stichprobe enthalten oder können gezielt überrepräsentiert werden.
 - Voraussetzung: Die Anteile der Gruppen (und die Gruppenzugehörigkeit) müssen bekannt sein.

- **Klumpenstichprobe:** Einfache Zufallsstichprobe von vorab gebildeten Klumpen mit einfachen Zufallsstichproben oder Vollerhebungen in den Klumpen
 - Beispiele: Geografische Einheiten, Schulklassen, Familien
 - Vorteil: Einfachere und kostengünstigere Durchführung der Datenerhebung
 - Voraussetzung: Innerhalb der Klumpen soll das interessierende Merkmal möglichst stark variieren, während die Klumpen untereinander möglichst homogen sein sollen.
- **Bewusste Auswahl (Quotenverfahren):** Vorab festgelegte Quoten müssen erfüllt sein.

Kreislauf der Datenanalyse



Take Home Messages

- Statistik beschäftigt sich mit der Beschreibung und Analyse von Daten.
- Es gibt verschiedene Arten von Merkmalen, deren Unterschiede bei der Auswahl geeigneter statistischer Methoden berücksichtigt werden müssen.
- In der Regel kann für interessierende Merkmale nicht die gesamte Grundgesamtheit betrachtet werden, sondern es steht nur eine Stichprobe zur Verfügung.
- Zentrale Aufgabe der (induktiven) Statistik ist dann das Schließen von der Stichprobe auf die Grundgesamtheit bei Berücksichtigung der entsprechenden Unsicherheit.