

Deskriptive Statistik zur Beschreibung von Merkmalen

Dr. Alexander Silbersdorff

Leiter der Arbeitsgruppe Learning Analytics und Data Literacy

Sommersemester 2026



Voraussetzungen

- Summenzeichen und mathematische Notation ($\Rightarrow$ M-V03, Vorkurs B1)
- Skalenniveaus ($\Rightarrow$ SDS1-V01)

Lernziele

- Wie lässt sich die Verteilung eines Merkmals in einem gegebenen Datensatz beschreiben?
- Welche Maßzahlen beschreiben verschiedene Aspekte dieser Verteilung?
- Wie können Verteilungen grafisch dargestellt und typisiert werden?

Häufigkeiten und Häufigkeitsverteilungen

- Gegeben seien Beobachtungen $x_1, \dots, x_n$ zu einem Merkmal X , wobei n den Stichprobenumfang bezeichne.
- Seien $a_1, \dots, a_J$, $J \leq n$ die möglichen Ausprägungen des Merkmals X .
- Für mindestens ordinale Merkmale seien diese Werte darüberhinaus geordnet, also $a_1 < \dots < a_J$.

- Absolute und relative Häufigkeiten der Merkmalsausprägungen:

$h(a_j) = h_j$ absolute Häufigkeit der Ausprägung a_j ,

d.h. Anzahl der x_i aus $x_1, \dots, x_n$ mit $x_i = a_j$

$f(a_j) = f_j = h_j/n$ relative Häufigkeit von a_j

- Verteilung der absoluten Häufigkeiten:

$$h_1, \dots, h_J$$

- Verteilung der relativen Häufigkeiten:

$$f_1, \dots, f_J$$

- Bei stetigen Daten mit vielen möglichen Ausprägungen werden die Häufigkeiten in der Regel basierend auf einer Zerlegung des Datenbereichs in J Intervalle/Klassen

$$[c_0, c_1], \dots, (c_{j-1}, c_j], \dots, (c_{J-1}, c_J]$$

bestimmt.

Beispiel: Landwirtschaftliche Flächen

- Daten zur landwirtschaftlich genutzten Fläche von $n = 1.565$ Landwirten in der Wesermarsch
- Eine auf neun Klassen reduzierte Häufigkeitsverteilung aller Beobachtungen ergibt folgende absoluten Häufigkeiten:

Anbaufläche in ha	Absolute Häufigkeit
$0 < x \leq 10$	421
$10 < x \leq 20$	127
$20 < x \leq 30$	134
$30 < x \leq 50$	302
$50 < x \leq 75$	365
$75 < x \leq 100$	159
$100 < x \leq 125$	38
$125 < x \leq 150$	14
$150 < x \leq 200$	5
Summe	1565

- Für die relativen Häufigkeiten ergibt sich folgende Verteilung für den Datensatz:

Anbaufläche in ha	Relative Häufigkeit
$0 < x \leq 10$	0.2690
$10 < x \leq 20$	0.0812
$20 < x \leq 30$	0.0856
$30 < x \leq 50$	0.1930
$50 < x \leq 75$	0.2332
$75 < x \leq 100$	0.1016
$100 < x \leq 125$	0.0243
$125 < x \leq 150$	0.0089
$150 < x \leq 200$	0.0032
Summe	1.0000

Säulendiagramm

- Die Häufigkeiten werden jeweils über ein zur x -Achse senkrechtes Rechteck dargestellt, wobei die **Höhen** $\mathcal{H}_j$ der Rechtecke proportional sind zu den absoluten bzw. relativen Häufigkeiten, d.h.

$$\mathcal{H}_1 \propto h_1, \dots, \mathcal{H}_J \propto h_J$$

bzw.

$$\mathcal{H}_1 \propto f_1, \dots, \mathcal{H}_J \propto f_J.$$

Histogramm

- Die Häufigkeiten werden jeweils über ein zur x -Achse senkrechtes Rechteck dargestellt, wobei die **Flächen** $\mathcal{F}_j$ der Rechtecke proportional sind zu den relativen Häufigkeiten, d.h.

$$\mathcal{F}_1 \propto f_1, \dots, \mathcal{F}_J \propto f_J.$$


- Das Histogramm ist eine flächenproportionale Darstellung der Häufigkeitsverteilung.
- Die Höhen der Rechtecke sind entsprechend proportional zur

$$\text{Dichte: } \frac{\text{relative Häufigkeit}}{\text{Breite des Rechtecks}}.$$



- Der Begriff **Dichte** wird in SDS1-V05 formal eingeführt. Hier reicht das Verständnis, dass Flächen unter der Dichte relativen Häufigkeiten entsprechen.
- In der Literatur werden auch Histogramme basierend auf absoluten Häufigkeiten verwendet. In dieser Veranstaltung betrachten wir nur Histogramme basierend auf relativen Häufigkeiten.

Säulendiagramme und Histogramme


- Darstellung der Größe der landwirtschaftlicher Anbauflächen als Säulendiagramm:





- Beim Säulendiagramm ist die visuelle Darstellung abhängig von der gewählten Breite der Klassen:



- Darstellung der Größe landwirtschaftlicher Anbauflächen als Histogramm:




- Beim Histogramm ist die visuelle Darstellung weitaus weniger abhängig von der gewählten Breite der Klassen:





Histogramme

- Histogramme werden in dieser Veranstaltung als Goldstandard für die Visualisierung von Häufigkeiten stetiger Merkmale betrachtet.
- Die Gesamtfläche des Histogramms ist Eins, da die Flächen den Anteilen entsprechen, und alle Anteile zusammen eins ergeben.
- Entsprechend können Teile der Fläche zur Schätzung von Häufigkeiten beliebiger Klassen benutzt werden.
- Der geschätzte Anteil der landwirtschaftlichen Anbauflächen zwischen a und b ergibt sich aus $\int_a^b \mathcal{H}_x dx$, wobei $\mathcal{H}_x$ die Höhe des Histogramms an der Stelle x ist.
- Diese Erkenntnis ist im Speziellen relevant für die Behandlung stetiger Verteilungen in der Veranstaltung SDS1-V05.

- Beispiel: Anteil der Landwirte mit landwirtschaftlich genutzter Fläche zwischen 40 und 70 ha:




- Üblicherweise werden für Histogramme J äquidistante Klassen verwendet.
- Bei der Wahl der Anzahl J sollte grundsätzlich mit Bedacht vorgegangen werden $\Rightarrow$ **Bias-Variance-Trade Off**.




Typisierung von Häufigkeitsverteilungen

- Anhand ihrer Histogramme können Häufigkeitsverteilungen in verschiedene Typen eingeteilt werden.
- Modalität der Verteilung:

Unimodal




Bimodal/Multimodal




- Symmetrie bzw. Schiefe der Verteilung:


linksschief/rechtssteil



symmetrisch



rechtsschief/linkssteil



Lagemaße

- Lagemaße beschreiben das Zentrum/die zentrale Tendenz der Daten.
- Das arithmetische Mittel ist die durchschnittliche Ausprägung eines Merkmals:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \sum_{j=1}^J a_j f_j$$

- Der Median teilt die Beobachtungen eines Merkmals in 50% große und 50% kleine Beobachtungen ein:

$$x_{med} = \begin{cases} x_{(\frac{n+1}{2})} & n \text{ ungerade} \\ \in [x_{(\frac{n}{2})}, x_{(\frac{n}{2}+1)}] & n \text{ gerade} \end{cases}$$

mit den geordneten Beobachtungen $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$.

- Der Modus ist die am häufigsten beobachtete Ausprägung eines Merkmals: x_{mod} = häufigste Merkmalsausprägung
- Die Lagemaße beschreiben die zentrale Tendenz der Daten:
 - Für das arithmetische Mittel gilt: $\sum_{i=1}^n (x_i - \bar{x}) = 0$,
d.h. die Differenzen nach links und rechts heben sich gegenseitig auf.
 - Für den Median liegen mindestens 50 % der Beobachtungen links und mindestens 50 % der Beobachtungen rechts des Medians.

Beispiel: Mietspiegel

- Beobachtungen zur Nettomiete pro Quadratmeter zu $n = 2051$ Wohnungen in München
- Gegliedert nach Baualter und Wohnflächenkategorien (klein, mittel, groß)

Nettomiete/qm				
	Wohnfläche			
Baualter	bis 38 qm	39 bis 80 qm	81 qm und mehr	
bis 1918	10.96 (20)	7.86 (189)	7.46 (190)	7.82 (399)
1919 bis 48	8.00 (5)	7.07 (128)	6.71 (53)	7.00 (186)
1949 bis 65	10.32 (64)	8.10 (321)	7.68 (68)	8.35 (453)
1966 bis 77	10.43 (112)	8.10 (364)	7.67 (151)	8.42 (627)
1987 bis 89	11.00 (10)	9.41 (115)	8.95 (42)	9.39 (167)
ab 1990	11.40 (6)	10.19 (154)	9.80 (59)	10.12 (219)
	10.44 (217)	8.33 (1271)	7.83 (563)	8.42 (2051)

- In Klammern ist jeweils die Anzahl der einbezogenen Wohnungen angegeben.

- Arithmetisches Mittel bei Schichtenbildung:

$$\bar{x} = \frac{1}{n}(n_1\bar{x}_1 + \cdots + n_r\bar{x}_r) = \frac{1}{n} \sum_{j=1}^r n_j\bar{x}_j$$

- Das Gesamtmittel entspricht dem gewichteten Durchschnitt der arithmetischen Mittel in den Schichten.

Voraussetzung für die Lagemaße

- Arithmetisches Mittel:
 - Anwendbar für kardinale Merkmale
 - Auch sinnvoll für binäre, als 0/1 kodierte Merkmale
 - Wird manchmal auch für ordinale Merkmale verwendet.
- Median:
 - Anwendbar ab Ordinalskala
- Modus:
 - Anwendbar für beliebiges Skalenniveau
 - Bei metrischen Merkmalen (mit vielen verschiedenen Ausprägungen) häufig nicht sinnvoll interpretierbar
 - Im Folgenden weniger relevant

Lagemaße und Form der Verteilung

- Symmetrische, unimodale Verteilung:

$$\bar{x} \approx x_{med} \approx x_{mod}$$


- rechtsschiefe/linkssteile Verteilung:

$$\bar{x} > x_{med} > x_{mod}$$

- linksschiefe/rechtssteile Verteilung:

$$\bar{x} < x_{med} < x_{mod}$$

Beispiel: Schiefe Verteilungen



Verhalten bei Transformation


- Bei linearer Transformation der Daten wird das arithmetische Mittel entsprechend mittransformiert:

$$y_i = a + bx_i \implies \bar{y} = a + b\bar{x}.$$


- Für monotone Transformationen g wird der Median mittransformiert:

$$y_i = g(x_i) \implies y_{med} = g(x_{med}).$$

Beispiel: Lineare Transformation



Beispiel: Monotone Transformation



Quantile

- Verallgemeinerung des Median: Das α -Quantil ist jene Zahl bzw. sind jene Zahlen für welche mindestens $\alpha \cdot 100$ % der Daten kleiner oder gleich sind und für $(1 - \alpha) \cdot 100$ % größer oder gleich sind, wobei $0 \leq \alpha \leq 1$ gilt, d.h.

$$x_{\alpha} \begin{cases} = x_{([n\alpha]+1)} & n\alpha \notin \mathbb{N}, \\ \in [x_{(n\alpha)}, x_{(n\alpha+1)}] & n\alpha \in \mathbb{N}. \end{cases}$$

- Dabei ist $[n\alpha]$ die zu $n\alpha$ nächstkleinere ganze Zahl.
- Voraussetzung: Mindestens ordinalskaliertes Merkmal

Häufig verwendete Quantile


- Median: $x_{med} = x_{0.5}$
- Quartile: $x_{0.25}, x_{0.5}, x_{0.75}$
- Dezile: $x_{0.1}, x_{0.2}, \dots, x_{0.8}, x_{0.9}$
- Vingtile: $x_{0.05}$ und $x_{0.95}$

Beispiel: Mietspiegel

- Stichprobe von 26 Wohnungen, Nettomieten nach Größe geordnet:

77.31	104.14	116.48	132.24	158.91	163.17	170.04	181.98
183.09	200.84	210.55	227.91	243.44	255.75	261.98	263.21
269.84	276.60	281.21	311.87	343.30	359.17	361.60	362.00
400.05	533.92						

- Ziel: Bestimmung des 25%-, 50%- und des 75%-Quantils.



- Für die Quartile ergibt sich:
 - $x_{0.25}$: $0.25 \cdot 26 = 6.5 \rightarrow$ aufrunden auf 7
 $x_{0.25} = x_{(7)} = 170.04$
 - $x_{0.50}$: Jeder Wert auf der Treppenstufe zwischen 243.44 und 255.57 teilt die Stichprobe in zwei gleichgroße Hälften.
 - Um einen eindeutigen Wert zu erhalten, bilden wir hier den Mittelwert der beiden Beobachtungen:
 $x_{0.50} = \frac{243.44 + 255.75}{2} = 249.6$
 - $x_{0.75}$: $0.75 \cdot 26 = 19.5 \rightarrow$ aufrunden auf 20
 $x_{0.75} = x_{(20)} = 311.87$

Streuungsmaße

- Ziel: Beschreibe nicht nur die zentrale Tendenz, sondern auch die Streuung oder Variabilität eines Merkmals.
- Varianz:
 - Definition: $S^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$ (mittlere quadratische Abweichung vom Mittelwert)
 - Verschiebungssatz zur einfacheren Berechnung: $S^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2$
- Standardabweichung:

$$S = \sqrt{S^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

- Vorteil: S hat die gleiche Einheit wie das betrachtete Merkmal.

- Variante:

$$S_*^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

- Vorteil: S_*^2 hat bessere theoretische Eigenschaften (mehr dazu in SDS1-V09).

Beispiel: Mietspiegel

- Für die Stichprobe aus 26 Wohnungen erhält man

$$\frac{1}{n} \sum_{i=1}^n x_i^2 = 72616.82$$

und

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = 250.02$$

- Nach dem Verschiebungssatz für die Varianz ergibt sich also

$$S^2 = 72616.82 - (250.02)^2 = 10106.82$$

und

$$S = \sqrt{\tilde{S}^2} = \sqrt{10106.82} = 100.53.$$

- Für die Nettomieten pro Quadratmeter der gesamten Stichprobe ist die Standardabweichung gegeben durch

$$S_{\text{ges}} = 2.45$$

und für die Schichten der kleinen, mittleren und großen Wohnungen erhält man

$$S_{\text{kl}} = 2.31, \quad S_{\text{mi}} = 2.36, \quad S_{\text{gr}} = 2.28.$$

- In Bezug auf die Streuung der Nettomiete pro Quadratmeter sind sich kleine, mittlere und große Wohnungen also relativ ähnlich.

- Für die absoluten Nettomieten der gesamten Stichprobe ist die Standardabweichung gegeben durch

$$S_{\text{ges}} = 241.92$$

und für die Schichten der kleinen, mittleren und großen Wohnungen erhält man

$$S_{\text{kl}} = 67.53, \quad S_{\text{mi}} = 166.20, \quad S_{\text{gr}} = 262.76.$$

- Die kleinen Wohnungen sind also in Bezug auf die absolute Nettomiete homogener (weisen eine kleinere Varianz / Standardabweichung auf) als große Wohnungen.

Interquartilsabstand

- Anstelle der Varianz und der Standardabweichung wird auch ein auf Quartilen beruhendes Streuungsmaß verwendet.
- Die Distanz

$$d_{Qn} = x_{0.75} - x_{0.25}$$

heißt Interquartilsabstand (IQR).

Eigenschaften der Streuungsmaße bei linearer Transformation:

- Für lineare Transformation der Varianz gilt

$$x_i \mapsto a + bx_i \implies s^2 \mapsto b^2 s^2 \text{ bzw. } s_*^2 \mapsto b^2 s_*^2.$$

- Für lineare Transformation der Standardabweichung gilt

$$x_i \mapsto a + bx_i \implies s \mapsto bs \text{ bzw. } s_* \mapsto bs_*.$$

- Für lineare Transformationen des Interquartilsabstands gilt

$$x_i \mapsto a + bx_i \implies IQR \mapsto b IQR.$$


Boxplots

- Boxplots sind eine grafische Fünf-Punkte-Zusammenfassung einer Verteilung bestehend aus:
 - dem minimalen Wert x_{min} ,
 - dem unteren Quartil $x_{0.25}$,
 - dem Median x_{med} ,
 - dem oberen Quartil $x_{0.75}$ und
 - dem maximalen Wert x_{max} .

- Häufig werden zusätzlich Ausreißer (also außergewöhnlich kleine oder große Beobachtungen) separat eingezeichnet.
- Übliche Ausreißerregel: mehr als 1.5 *IQR* Abstand zu $x_{0.25}$ bzw. $x_{0.75}$
- Der Boxplot gibt einen schnellen Überblick über die Form der Verteilung (Zentrale Tendenz, Variabilität, Schiefe, Extreme Werte).

Beispiel: Mietspiegel

- Box-Plots für die Nettomieten geschichtet nach Wohnungsgröße



- Der Median wird mit wachsender Wohnungsgröße erwartungsgemäß größer.
- Ausreißer – gekennzeichnet durch runde Kreise – gibt es in allen drei Kategorien, aber die Spannweite der Daten wächst zusammen mit der Wohnungsgröße.
- Bei den großen Wohnungen ist zu erkennen, dass die Verteilung linkssteil (rechtsschief) ist.

Take Home Messages

- Für diskrete Merkmale kann die Verteilung durch die Häufigkeitsverteilung, für stetige Merkmale durch Histogramme dargestellt werden.
- Neben der grafischen Darstellung bieten Maßzahlen für Lokation, Streuung, etc. eine Möglichkeit, die Verteilung zu beschreiben.
- Die Maßzahlen besitzen verschiedene Voraussetzungen an das Skalenniveau und haben verschiedene Güteeigenschaften.
- Mit Quantilen kann ein Überblick über einen gesamten Datensatz gegeben werden. Dieser Überblick kann z.B. mit Boxplots visualisiert werden.