

Deskriptive Statistik zur Beschreibung von Zusammenhängen

Dr. Alexander Silbersdorff

Leiter der Arbeitsgruppe Learning Analytics und Data Literacy

Sommersemester 2026



Voraussetzungen

- Mathematische Notation und Summenzeichen ($\Rightarrow$ M-V03, Vorkurs B1)
- Deskriptive Statistik für einzelne Merkmale ($\Rightarrow$ SDS1-V02)
- Skalenniveaus ($\Rightarrow$ SDS1-V01)
- Datensatz Mietspiegel ($\Rightarrow$ SDS1-V02)


Lernziele


- Wie lassen sich Zusammenhänge zwischen Merkmalen untersuchen und statistisch darstellen?
- Wie lassen sich Zusammenhänge quantitativ in geeigneten Maßzahlen ausdrücken?
- Wie unterscheiden sich Ansätze je nach Skalenniveau der Merkmale?
- Was unterscheidet statistische Zusammenhänge und kausale Zusammenhänge?

Motivation: Ausbreitung von Cholera

- Mitte des 19. Jahrhunderts: Choleraepidemie in London
- Führende Theorie zu damaliger Zeit: Verbreitung durch Miasma, also durch krankheitsverursachenden „üblen Dunst“.
- Tatsächlich fand die Verbreitung über bakteriell belastetes Wasser aus der lokalen Wasserversorgung statt.
- Die Untersuchungen der Epidemie und deren Zusammenhang mit der lokalen Wasserversorgung werden als Geburtsstunde der Epidemiologie betrachtet ¹.

¹Quelle: Rothman, Kenneth J., Krista F. Huybrechts, and Eleanor J. Murray, 'Pioneers in Epidemiology and Public Health', Epidemiology: An Introduction, 3rd edn.





- Evidenz für die Wasserversorgungs-Theorie

Wasserversorger	Anzahl Häuser	Cholera-Tote	$\frac{\text{Cholera-Tote}}{1.000 \text{ Häuser}}$
Southwark/Vauxhall	40.046	1.263	32
Lambeth	26.107	98	4

- Die gemeinsame Verteilung von Wasserversorger und Cholera-Toten erlaubt es, einen statistischen Zusammenhang herzustellen!

Gemeinsame Verteilung vs. Randverteilung

- Die gemeinsame Verteilung zweier Merkmale X und Y beschreibt, wie sich die beiden Merkmale gemeinsam verhalten.
⇒ Grundlage sind Beobachtungen (x_i, y_i) für die gleichen statistischen Einheiten $i = 1, \dots, n$
- Betrachtet man die Verteilung nur eines der beiden Merkmale, so ergeben sich die Randverteilungen von X beziehungsweise Y .
- Intuitiv: Die gemeinsame Verteilung bestimmt die Randverteilungen eindeutig, aber im Allgemeinen nicht umgekehrt.

- Genauer: Die gemeinsame Verteilung lässt sich nur dann aus den Randverteilungen bestimmen, wenn die Merkmale X und Y keinen Zusammenhang aufweisen, also unabhängig voneinander sind.
⇒ Wie kann der Zusammenhang zwischen X und Y aus Daten ermittelt werden?
- Die Vorgehensweise hängt u.A. vom Skalenniveau der Merkmale X und Y ab.

Gemeinsame Verteilung

- Seien im Folgenden die beiden Merkmale X und Y diskret oder geeignet gruppiert mit den Ausprägungen

$$a_1, \dots, a_J \quad \text{für } X,$$

$$b_1, \dots, b_K \quad \text{für } Y.$$

- Gegeben seien Beobachtungspaare $(x_1, y_1), \dots, (x_n, y_n)$.

- Gemeinsame absolute Häufigkeitsverteilung:

$$h_{jk} = h(a_j, b_k), \quad j = 1, \dots, J, \quad k = 1, \dots, K,$$

= Anzahl der Beobachtungen mit $x_i = a_j$ und $y_i = b_k$.

- Gemeinsame relative Häufigkeitsverteilung:

$$f_{jk} = \frac{h_{jk}}{n} = f(a_j, b_k), \quad j = 1, \dots, J, \quad k = 1, \dots, K,$$

= Anteil der Beobachtungen mit $x_i = a_j$ und $y_i = b_k$.

Absolute Häufigkeiten

- Kontingenztafel der absoluten Häufigkeitsverteilung:

	b_1	$\dots$	b_K	
a_1	h_{11}	$\dots$	h_{1K}	$h_{1\bullet}$
$\vdots$	$\vdots$		$\vdots$	$\vdots$
a_J	h_{J1}	$\dots$	h_{JK}	$h_{J\bullet}$
	$h_{\bullet 1}$	$\dots$	$h_{\bullet K}$	n

mit den Randverteilungen

$$h_{j\bullet} = h_{j1} + \dots + h_{jK} = h(a_j), \quad j = 1, \dots, J, \quad \text{für } X,$$

und

$$h_{\bullet k} = h_{1k} + \dots + h_{Jk} = h(b_k), \quad k = 1, \dots, K, \quad \text{für } Y.$$

Beispiel: Ausbildung vs. Arbeitslosigkeit

- Fragestellung: Gibt es einen Zusammenhang zwischen der Dauer der Arbeitslosigkeit und dem Ausbildungsniveau?
- Datensatz:
 - $n = 447$ männliche, deutsche Arbeitslose
 - Teilstichprobe des sozioökonomischen Panels (SOEP)
- Merkmale und Ausprägungen
 - höchstes erreichtes Ausbildungsniveau
 - Dauer der Arbeitslosigkeit (eingeteilt in 1 – 6 Monate, 7 – 12 Monate, > 12)

- Tabelle der absoluten Häufigkeiten:

	Kurzzeit- arbeitslosigkeit	mittelfristige Arbeitslosigkeit	Langzeit- arbeitslosigkeit	
keine Ausbildung	86	19	18	123
Lehre	170	43	20	233
Fachspez. Ausbildung	40	11	5	56
Hochschulabschluss	28	4	3	35
	324	77	46	447

Relative Häufigkeiten

- Kontingenztafel der relativen Häufigkeitsverteilung:

	b_1	$\cdots$	b_K	
a_1	f_{11}	$\cdots$	f_{1K}	$f_{1\bullet}$
$\vdots$	$\vdots$		$\vdots$	$\vdots$
a_J	f_{J1}	$\cdots$	f_{JK}	$f_{J\bullet}$
	$f_{\bullet 1}$	$\cdots$	$f_{\bullet K}$	

mit den Randverteilungen

$$f_{j\bullet} = \frac{h_{j\bullet}}{n} = f_{j1} + \dots + f_{jK} = f(a_j), \quad j = 1, \dots, J, \quad \text{für } X,$$

und

$$f_{\bullet k} = \frac{h_{\bullet k}}{n} = f_{1k} + \dots + f_{Jk} = f(b_k), \quad k = 1, \dots, K, \quad \text{für } Y.$$

Beispiel: Ausbildung vs. Arbeitslosigkeit

- Tabelle der relativen Häufigkeiten:

	Kurzzeit- arbeitslosigkeit	mittelfristige Arbeitslosigkeit	Langzeit- arbeitslosigkeit	
keine Ausbildung	0.19	0.04	0.04	0.27
Lehre	0.39	0.1	0.04	0.53
Fachspez. Ausbildung	0.09	0.02	0.01	0.12
Hochschulabschluss	0.06	0.01	0.01	0.08
	0.73	0.17	0.1	1

Bedingte Verteilungen

- Wie ist die Verteilung des Merkmals Y unter der Bedingung, dass Ausprägung a_j für Merkmal X beobachtet wurde?
- Wie ist die Verteilung des Merkmals X unter der Bedingung, dass Ausprägung b_k für Merkmal Y beobachtet wurde?
- Solche bedingten Verteilungen erhält man durch zeilen- bzw. spaltenweises Normieren der Kontingenztafel.

- Bedingte Verteilung von Y gegeben $X = a_j$:

$$\begin{array}{cccc}
 & b_1 & \cdots & b_K \\
 a_1 & \frac{h_{11}}{h_{1\bullet}} & \cdots & \frac{h_{1K}}{h_{1\bullet}} & 1 \\
 \vdots & \vdots & & \vdots & \vdots \\
 a_J & \frac{h_{J1}}{h_{J\bullet}} & \cdots & \frac{h_{JK}}{h_{J\bullet}} & 1 \\
 & \frac{h_{\bullet 1}}{n} & \cdots & \frac{h_{\bullet K}}{n} & 1
 \end{array}$$

- Analog: Bedingte Verteilung von X gegeben $Y = b_K$

Beispiel: Ausbildung vs. Arbeitslosigkeit

- Tabelle der bedingten Häufigkeiten:

	Kurzzeit- arbeitslosigkeit	mittelfristige Arbeitslosigkeit	Langzeit- arbeitslosigkeit	
keine Ausbildung	0.699	0.154	0.147	1
Lehre	0.730	0.184	0.086	1
Fachspez. Ausbildung	0.714	0.197	0.089	1
Hochschulabschluss	0.800	0.114	0.086	1
	0.73	0.17	0.1	1

- Die Wahrscheinlichkeit für Kurzarbeitslosigkeit nimmt mit höherem Ausbildungsniveau zu.
- Die Wahrscheinlichkeit für Langzeitarbeitslosigkeit nimmt mit höherem Ausbildungsniveau ab.

Bedingte Verteilungen und Unabhängigkeit

- Sind alle bedingten Verteilungen von Y gegeben $X = a_j$ **unabhängig** von der Bedingung $X = a_j$ gleich, so besteht kein Zusammenhang zwischen X und Y (analog für X gegeben $Y = b_k$).
- Unterscheiden sich die bedingten Verteilungen, dann besteht ein Zusammenhang zwischen X und Y .
- Die Stärke des Zusammenhangs lässt sich beispielsweise durch den χ^2 -Koeffizienten ausdrücken.
- Dieser vergleicht die beobachteten Häufigkeiten mit den bei Unabhängigkeit erwarteten Häufigkeiten.

χ^2 -Koeffizient

- Unter Unabhängigkeit sollten alle bedingten Verteilungen von Y gegeben $X = a_j$ gleich und gleich der entsprechenden Randverteilung sein, also.

$$\frac{h_{jk}}{h_{j\bullet}} = \frac{h_{\bullet k}}{n}, \quad j = 1, \dots, J.$$

- Die unter Unabhängigkeit erwarteten Häufigkeiten ergeben sich dann durch die Multiplikation mit den Randhäufigkeiten $h_{j\bullet}$:

$$\tilde{h}_{jk} = \frac{h_{\bullet k}}{n} h_{j\bullet} = \frac{h_{j\bullet} h_{\bullet k}}{n}.$$

- Als Zusammenhangsmaß betrachtet man den χ^2 -Koeffizienten

$$\chi^2 = \sum_{j=1}^J \sum_{k=1}^K \frac{(h_{jk} - \tilde{h}_{jk})^2}{\tilde{h}_{jk}}.$$

- Der χ^2 -Koeffizient misst die Diskrepanz zwischen den beobachteten Häufigkeiten h_{jk} und den unter Unabhängigkeit erwarteten Häufigkeiten $\tilde{h}_{jk}$.
 - χ^2 groß $\Rightarrow$ starker Zusammenhang zwischen den Merkmalen
 - $\chi^2 \approx 0 \Rightarrow$ die Merkmale sind (näherungsweise) unabhängig

Beispiel: Ausbildung vs. Arbeitslosigkeit

- Tabelle der erwarteten Häufigkeiten (gerundet):

	Kurzzeit- arbeitslosigkeit	mittelfristige Arbeitslosigkeit	Langzeit- arbeitslosigkeit	
keine Ausbildung	89.15	21.19	12.66	123
Lehre	168.89	40.14	23.98	233
Fachspez. Ausbildung	40.59	9.65	5.76	56
Hochschulabschluss	25.37	6.03	3.60	35
	324	77	46	447

- Zum Beispiel:

$$\tilde{h}_{11} = \frac{123 \cdot 324}{447} \approx 89.15$$

- χ^2 -Koeffizient:


$$\chi^2 = \sum_{j=1}^4 \sum_{k=1}^3 \frac{(h_{jk} - \tilde{h}_{jk})^2}{\tilde{h}_{jk}} \approx 4.51$$

Streudiagramm


- Um den Zusammenhang zwischen zwei metrischen Merkmalen graphisch darzustellen, bietet sich das Streudiagramm an.
- Hier werden die Beobachtungen (x_i, y_i) , $i = 1, \dots, n$ durch Punkte in einem entsprechenden Koordinatensystem dargestellt.
- Aus dem Streudiagramm lassen sich direkt unterschiedliche Arten von Zusammenhängen ablesen, z.B:
 - gleich gerichtete vs. gegengerichtete Zusammenhänge,
 - lineare vs. nichtlineare Zusammenhänge.

Beispiel: Mietspiegel

- Streudiagramm für Wohnfläche und Nettomiete:



- Streudiagramme für Nettomiete, Nettomiete/qm, Wohnfläche und Zimmeranzahl:



Kovarianz

- Sind X und Y stetig, so verwenden wir die Kovarianz als Maß für die Stärke des (linearen) Zusammenhangs.
- Betrachte den Mittelpunkt $(\bar{x}, \bar{y})$ der Daten und definiere
 - eine Beobachtung (x_i, y_i) ist konkordant zu $(\bar{x}, \bar{y})$, wenn gilt

$$x_i > \bar{x} \quad \text{und} \quad y_i > \bar{y}$$

oder

$$x_i < \bar{x} \quad \text{und} \quad y_i < \bar{y}.$$

⇒ gleich gerichteter Zusammenhang

- Betrachte den Mittelpunkt $(\bar{x}, \bar{y})$ der Daten und definiere
 - eine Beobachtung (x_i, y_i) ist diskordant zu $(\bar{x}, \bar{y})$, wenn gilt


$$x_i < \bar{x} \quad \text{und} \quad y_i > \bar{y}$$

oder

$$x_i > \bar{x} \quad \text{und} \quad y_i < \bar{y}.$$

$\Rightarrow$ gegengerichteter Zusammenhang

- Grafische Darstellung:





- Zusammengefasst:
 - $(x_i - \bar{x})(y_i - \bar{y}) > 0 \Rightarrow$ konkordant
 - $(x_i - \bar{x})(y_i - \bar{y}) < 0 \Rightarrow$ diskordant
- Die Kovarianz ist dann die durchschnittliche Konkordanz/Diskordanz:

$$\text{Cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}).$$

Eigenschaften der Kovarianz

- Die Kovarianz misst die Stärke des linearen Zusammenhangs zwischen X und Y .
 - $\Rightarrow \text{Cov}(X, Y) = 0 \Leftrightarrow$ kein linearer Zusammenhang
(X und Y sind unkorreliert)
 - $\Rightarrow \text{Cov}(X, Y) > 0 \Leftrightarrow$ positiver linearer Zusammenhang
 - $\Rightarrow \text{Cov}(X, Y) < 0 \Leftrightarrow$ negativer linearer Zusammenhang

- Positiver / negativer linearer Zusammenhang zwischen X und Y :



- Die Kovarianz ist eine Verallgemeinerung der Varianz; genauer gilt:

$$\text{Cov}(X, X) = \text{Var}(X).$$

- Wie die Varianz ist auch die Kovarianz abhängig von der Skalierung der betrachteten Merkmale.
- Nichtlineare Zusammenhänge werden nicht notwendigerweise durch die Kovarianz erkannt.

Korrelation

- Der Wert der Kovarianz hängt von der Varianz der Merkmale X und Y ab und ist damit maßabhängig.
⇒ Interpretation der Stärke des Zusammenhangs schwierig
- Der Korrelationskoeffizient (nach Bravais-Pearson) ergibt sich durch Normierung mit den Standardabweichungen:







$$\begin{aligned}\rho(X, Y) &= \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}} \\ &= \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}\end{aligned}$$

- Für den Korrelationskoeffizienten gilt: $-1 \leq \rho(X, Y) \leq 1$

$\rho(X, Y) = 0 \Leftrightarrow$ kein linearer Zusammenhang
zwischen X und Y

$|\rho(X, Y)| = 1 \Leftrightarrow$ perfekter linearer Zusammenhang
zwischen X und Y

- Stilisierte Beispiele zur Korrelation:



Beispiel: Mietspiegel

- Paarweise Korrelationskoeffizienten:

Nettomiete			
0.721	Wohnfläche		
0.567	0.854	Zimmerzahl	
0.430	-0.255	-0.294	Nettomiete/qm

Rangkorrelation

- Die Bravais-Pearson-Korrelation setzt metrische Merkmale voraus, da Abstände zum Mittelwert berechnet werden.
- Für ordinalskalierte Merkmale kann der Korrelationskoeffizient angewendet werden, wenn anstelle der beobachteten Merkmalsausprägungen die entsprechenden Ränge verwendet werden.
- Der resultierende Rangkorrelationskoeffizient (auch: Spearman-Korrelationskoeffizient) misst die Stärke monotoner (auch nichtlinearer!) Zusammenhänge.
- Bei der Bildung der Ränge können Bindungen entstehen (Beobachtungen mit der gleichen Merkmalsausprägung können nicht eindeutig geordnet werden). In diesem Fall werden in der Regel Durchschnittsränge vergeben.

Beispiel: Mietspiegel

- Paarweise Korrelationskoeffizienten nach Spearman:


Korrelationskoeffizient nach Spearman			
Nettomiete	0.711	0.582	0.425
0.721	Wohnfläche	0.875	−0.255
0.567	0.854	Zimmerzahl	−0.295
0.430	−0.255	−0.294	Nettomiete/qm

Bravais-Pearson-Korrelationskoeffizient

Lineare und nichtlineare Zusammenhänge


Linearer Zusammenhang

Pearson: 0.98 Spearman: 0.97




Monoton nicht-linear

Pearson: 0.48 Spearman: 1



Nicht-monoton nicht-linear

Pearson: -0.36 Spearman: -0.35



Kausalität vs. Korrelation

- Kausalität: Aus der Veränderung des Merkmals X ergibt sich **ursächlich** eine Veränderung im Merkmal Y .
- Zum Nachweis der Kausalität notwendig:
 - gezielte Manipulation der Ursache X im Rahmen der Untersuchung
 - Kontrolle aller möglichen weiteren beeinflussenden Variablen (beispielsweise durch Randomisierung)

- Viele statistische Analysen stellen einen Zusammenhang zwischen X und Y dar, ohne weitere beeinflussende Variablen (vollumfänglich) zu kontrollieren oder zu randomisieren.
⇒ Statistische Analysen liefern i.d.R. den Nachweis eines statistischen Zusammenhangs, aber nicht einer Kausalität!

Ökologischer Fehlschluss

- Der ökologische Fehlschluss ist ein Fehlschluss, bei dem auf Basis von aggregierten Daten, die Merkmale einer Gruppe abbilden, unzulässigerweise auf Individualdaten geschlossen wird.
- „Ökologisch“ bedeutet hier „kollektiv“ und geht auf die Stadtökologie der Chicagoer Schule zurück. Der Begriff wurde 1950 vom US-amerikanischen Statistiker William S. Robinson (1913–1996) geprägt.

Beispiel: EHEC-Infektionen

- Im Mai 2011 gab es in Norddeutschland eine Häufung von Erkrankungen aufgrund von EHEC-Infektionen (enterohämorrhagische *Escherichia coli*).
- In einer in Hamburg durchgeführten epidemiologischen Untersuchung wurde festgestellt, dass in Stadtbezirken mit einem großen Anteil an Grünen-Wählern auch der Anteil an Erkrankungen erhöht war.
- Ökologischer Fehlschluss: Die Parteipräferenz ist ursächlich für ein erhöhtes Erkrankungsrisiko.

- Tatsächlich wurde EHEC durch kontaminierte Lebensmittel übertragen, in diesem Fall Sprossengemüse aus ökologischem Anbau.
- Hier liegen zwei Probleme vor:
 - Aus der Assoziation auf der Makroebene (Anteil Grünen-Wähler, Anteil Erkrankte in Stadtbezirken) kann nicht auf das individuelle Verhalten auf der Mikroebene geschlossen werden (Sind die Erkrankten tatsächlich Grünen-Wähler?).
 - Es gibt weitere Größen, die in der Analyse nicht beachtet werden (hier: Ernährungsverhalten).

Take Home Messages

- Die gemeinsame Verteilung zweier Merkmale enthält mehr Informationen als die Randverteilungen.
- Insbesondere lassen sich Schlüsse über die Abhängigkeit der beiden Merkmale ziehen.
- Die Stärke der Abhängigkeit kann über verschiedene Maßzahlen ausgedrückt werden.
- Die Wahl der Maßzahl hängt vom Skalenniveau der betrachteten Merkmale ab.
- Um kausale Zusammenhänge aufzudecken sind zusätzliche Annahmen notwendig.