

Zufallsvariablen zur Beschreibung zufälliger Vorgänge

Dr. Alexander Silbersdorff

Leiter der Arbeitsgruppe Learning Analytics und Data Literacy

Sommersemester 2026



Voraussetzungen

- Zahlenmengen ($\Rightarrow$ Vorkurs B1)
- Wahrscheinlichkeitsrechnung ($\Rightarrow$ SDS1-V04)
- Merkmale und ihre Eigenschaften ($\Rightarrow$ SDS1-V01)
- Integralrechnung ($\Rightarrow$ M-V11, Vorkurs B8)
- Differentialrechnung ($\Rightarrow$ M-V05, Vorkurs B7)
- Binomialkoeffizient ($\Rightarrow$ M-V01)

Lernziele

- Wie können analog zu den Merkmalen der deskriptiven Statistik Zufallsvariablen als theoretisches Konstrukt definiert werden?
- Wie lässt sich die Verteilung diskreter und stetiger Zufallsvariablen charakterisieren?
- Welche Beispiele für diskrete und stetige Verteilungen gibt es?
- Wie kann das Konzept der Unabhängigkeit von Daten auf Zufallsvariablen übertragen werden?

Merkmale und Zufallsvariablen

- In der deskriptiven Statistik haben wir Merkmale, ihre möglichen Ausprägungen sowie absolute und relative Häufigkeiten behandelt.
- In der Wahrscheinlichkeitsrechnung bilden Zufallsvariablen ein theoretisches Modell für die Beschreibung zufälliger Vorgänge (durch Zahlen).

Deskriptive Statistik	Wahrscheinlichkeitsrechnung
Merkmal	Zufallsvariable
Merkmalsausprägungen	Träger der Zufallsvariablen (mögliche Ausprägungen)
absolute und relative Häufigkeiten	Wahrscheinlichkeiten für (Mengen von) möglichen Ausprägungen

- Beachte: Die möglichen Ausprägungen einer Zufallsvariable müssen Zahlen sein.
- Man unterscheidet (wie bei Merkmalen in der deskriptiven Statistik) zwischen diskreten und stetigen Zufallsvariablen.

Definition Zufallsvariable

- Eine Zufallsvariable X ist eine Funktion, die jedem möglichen Ergebnis $\omega \in \Omega$ eines Zufallsexperiments mit Ergebnisraum Ω eine reelle Zahl zuordnet.
- Beispiel: Zweifacher Würfelwurf

$$\Omega = \{(1, 1), (1, 2), (1, 3), \dots, (1, 6), \\ (2, 1), (2, 2), (2, 3), \dots, (6, 5), (6, 6)\}$$

X = Summe der beiden Würfe

Y = Differenz der beiden Würfe

$$Z = \begin{cases} 1, & \text{gerade Summe der beiden Würfel} \\ 0, & \text{ungerade Summe der beiden Würfel} \end{cases}$$

Diskrete Zufallsvariablen

- Eine Zufallsvariable X heißt diskret, falls sie nur endlich oder abzählbar unendlich viele Werte $x_1, x_2, \dots, x_k, \dots$ annehmen kann.
- Die Wahrscheinlichkeitsverteilung von X ist durch die Wahrscheinlichkeitsfunktion

$$P(X = x_i) = p_i, \quad i = 1, 2, \dots, k, \dots$$

gegeben.

- $\mathcal{T} = \{x_1, x_2, \dots, x_k, \dots\}$ heißt Träger von X .

Eigenschaften

- Alle p_i sind Wahrscheinlichkeiten, d.h.

$$0 \leq p_i \leq 1.$$

- Die Summe aller Wahrscheinlichkeiten ist eins, d.h.

$$\sum_{i \geq 1} p_i = p_1 + p_2 + \dots + p_k + \dots = 1.$$

- Wahrscheinlichkeiten interessierender Ereignisse erhält man durch Summation, d.h.

$$P(X \in A) = \sum_{i: x_i \in A} p_i \quad \text{für } A \subset \mathcal{T}.$$

- Insbesondere gilt

$$P(a \leq X \leq b) = \sum_{i: a \leq x_i \leq b} p_i.$$

Beispiel: Summe der Augenzahlen


- Sei X die Summe der Augenzahlen von zwei fairen Würfeln:

(1,1)	(1,2)	(1,3)	(1,4)	(1,5)	(1,6)
(2,1)	(2,2)	(2,3)	(2,4)	(2,5)	(2,6)
(3,1)	(3,2)	(3,3)	(3,4)	(3,5)	(3,6)
(4,1)	(4,2)	(4,3)	(4,4)	(4,5)	(4,6)
(5,1)	(5,2)	(5,3)	(5,4)	(5,5)	(5,6)
(6,1)	(6,2)	(6,3)	(6,4)	(6,5)	(6,6)


- Wahrscheinlichkeitsfunktion $P(X = x)$:

x	$P(X = x)$
2	1/36
3	2/36
4	3/36
5	4/36
6	5/36
7	6/36
8	5/36
9	4/36
10	3/36
11	2/36
12	1/36
Summe	$36/36 = 1$

- Wahrscheinlichkeitsfunktion $P(X = x)$:



- Verteilungsfunktion $F(x) = P(X \leq x)$:



Binomialkoeffizient

- Der Binomialkoeffizient bezeichnet die Anzahl der Möglichkeiten, aus n Objekten x Objekte ohne Berücksichtigung der Reihenfolge auszuwählen:

$$\begin{aligned}\binom{n}{x} &= \frac{n!}{(n-x)!x!} \\ &= \frac{n \cdot (n-1) \cdot \dots \cdot (n-x+1)}{x \cdot (x-1) \cdot \dots \cdot 1}\end{aligned}$$

- Begründung: Die Anzahl der Möglichkeiten mit Reihenfolge beträgt

$$n \cdot (n-1) \cdot \dots \cdot (n-x+1).$$

Die Anzahl möglicher Vertauschungen beträgt

$$x \cdot (x-1) \cdot \dots \cdot 1.$$

Beispiel: Anzahl Richtiger im Lotto

- Ziel: 6 Richtige aus 49 Zahlen auswählen

1	2	3	4	5	6	7
8	9	10	11	12	13	14
15	16	17	18	19	20	21
22	23	24	25	26	27	28
29	30	31	32	33	34	35
36	37	38	39	40	41	42
43	44	45	46	47	48	49

- Wie viele Möglichkeiten gibt es, genau $x = 0, 1, 2, 3, 4, 5, 6$ von $n = 6$ Richtigen aus $N = 49$ auszuwählen?

$$P(X = x) = \frac{\binom{n}{x} \cdot \binom{N-n}{n-x}}{\binom{N}{n}}$$


- Beispiel: 3 Zahlen aus 6 Richtigen auswählen

$$P(X = 3) = \frac{\binom{6}{3} \cdot \binom{49-6}{6-3}}{\binom{49}{6}} \approx 0.0177$$


- Wahrscheinlichkeitsfunktion für die Anzahl Richtiger:

x	$P(X = x)$
0	0.43596498
1	0.41301945
2	0.13237803
3	0.01765040
4	0.00096862
5	0.00001845
6	0.00000007
Summe	1

- Wahrscheinlichkeitsfunktion $P(X = x)$:



- Verteilungsfunktion $F(x) = P(X \leq x)$:




Stetige Zufallsvariablen

- Stetige Zufallsvariablen können beliebige, reelle Zahlen in einem Intervall $[a, b]$ annehmen.
- Damit ist keine sinnvolle Angabe von Wahrscheinlichkeiten für einzelne Ausprägungen mehr möglich (zu viele mögliche Werte).
- Stattdessen verwenden wir Dichtefunktionen $f(x) \geq 0$ zur Beschreibung der Zufallsvariablen.

- Definition: Eine Zufallsvariable X heißt stetig, wenn es eine Dichte $f(x) \geq 0$ gibt, so dass für jedes Intervall $[a, b]$ gilt:

$$P(a \leq X \leq b) = \int_a^b f(x) dx.$$



- Für stetige Zufallsvariablen X gilt:

$$\begin{aligned}P(a \leq X \leq b) &= P(a < X \leq b) \\&= P(a \leq X < b) \\&= P(a < X < b)\end{aligned}$$

und $P(X = x) = 0$ für jedes $x \in \mathbb{R}$.

- Die Normierungseigenschaft

$$\int_{-\infty}^{+\infty} f(x) dx = 1$$


entspricht $\sum_i p_i = 1$ bei diskreten Zufallsvariablen.

- $f(x) > 1$ ist möglich!
- $\mathcal{T} = \{x \mid f(x) > 0\}$ heißt Träger von X .

Beispiel: Dauer von Anrufen

- X sei die Dauer (in Sekunden) eines Call-Center-Anrufes.
- Wir nehmen an, dass die theoretische Verteilung durch folgende Dichtefunktion beschrieben werden kann:

$$f(x) = \begin{cases} 0.006 e^{-0.006x} & \text{für } x \geq 0, \\ 0 & \text{sonst.} \end{cases}$$



- Überprüfung der Eigenschaften einer Dichtefunktion:

$$\begin{aligned}\int_{-\infty}^{\infty} f(x) dx &= \int_{-\infty}^0 0 dx + \int_0^{\infty} 0.006 e^{-0.006x} dx \\&= 0 + \left[\frac{0.006}{-0.006} e^{-0.006x} \right]_0^{\infty} \\&= [-e^{-0.006 \cdot \infty}] - [-e^{-0.006 \cdot 0}] \\&= 0 - (-1) \\&= 1\end{aligned}$$

⇒ Die Normierungseigenschaft ist erfüllt.

Verteilungsfunktion

- Für eine Zufallsvariable X bezeichnet $F(x) = P(X \leq x)$ die Verteilungsfunktion.
- Mithilfe der Verteilungsfunktion lassen sich Wahrscheinlichkeiten der Form

$$P(a < X \leq b) = F(b) - F(a)$$

berechnen.

- Bei bekannter Verteilungsfunktion müssen wir keine Integrale mehr berechnen!

Beispiel: Dauer von Anrufen


- Bestimmung der Verteilungsfunktion:

$$\begin{aligned} F(x) &= \int_0^x f(t) dt \\ &= \int_0^x 0.006 e^{-0.006t} \\ &= \left[-e^{-0.006t} \right]_0^x \\ &= -e^{-0.006x} - (-e^0) \\ &= 1 - e^{-0.006x} \end{aligned}$$


- Also:

$$F(x) = \begin{cases} 1 - e^{-0.006x} & x \geq 0, \\ 0 & x < 0. \end{cases}$$

• Dichtefunktion



• Verteilungsfunktion



Quantile von Zufallsvariablen

- Für eine Zufallsvariable X bezeichnet q_α mit $0 \leq \alpha \leq 1$ das α -Quantil, wenn gilt:

$$P(X \leq q_\alpha) \geq \alpha$$


und

$$P(X \geq q_\alpha) \geq 1 - \alpha.$$


- Für stetige Zufallsvariablen ist das Quantil eindeutig bestimmt und ergibt sich als Lösung der Gleichung

$$P(X \leq q_\alpha) = \alpha.$$

- Allgemein: Das α -Quantil ist eindeutig, falls $F(x)$ streng monoton wachsend ist.




- Quantile und Dichtefunktion:



Dauer von Anrufen

- Grafische Bestimmung der 95%-Quantils:



- Interpretation:

- Das 95 %- Quantil der Anrufdauern $F(X \leq q_{0.95}) = 0.95$ ist gegeben durch $q_{0.95} \approx 500$.
- Nur 5 % der Anrufe dauern länger als $q_{0.95} = 500$ Minuten.

Unabhängigkeit von Zufallsvariablen

- Zwei Zufallsvariablen X und Y heißen stochastisch unabhängig, wenn

$$P(X \leq x, Y \leq y) = P(X \leq x) \cdot P(Y \leq y)$$

für alle $x \in \mathbb{R}$, $y \in \mathbb{R}$ gilt.

- Allgemeiner heißen n Zufallsvariablen $X_1, \dots, X_n$ stochastisch unabhängig, wenn

$$P(X_1 \leq x_1, \dots, X_n \leq x_n) = P(X_1 \leq x_1) \cdot \dots \cdot P(X_n \leq x_n)$$

für beliebige $x_1 \in \mathbb{R}, \dots, x_n \in \mathbb{R}$ gilt.

- Für diskrete Zufallsvariablen kann man auch

$$P(X = x, Y = y) = P(X = x) \cdot P(Y = y)$$

bzw.

$$P(X_1 = x_1, \dots, X_n = x_n) = P(X_1 = x_1) \cdot \dots \cdot P(X_n = x_n)$$

für beliebige Werte aus den jeweiligen Trägern fordern.

- Für stetige Zufallsvariablen gibt es ein ähnliches Kriterium über die gemeinsame Dichte:

$$f(x, y) = f_X(x) \cdot f_Y(y) \quad \text{bzw.}$$

$$f(x_1, \dots, x_n) = f_{X_1}(x_1) \cdot \dots \cdot f_{X_n}(x_n).$$

→ Mehr in SDS1-V06 und in Statistik und Data Science 2.

Unabhängig und identisch verteilte Zufallsvariablen

- Zufallsvariablen $X_1, \dots, X_n$ heißen unabhängig und identisch verteilt (uiv, auch iid für independent und identically distributed), wenn gilt
 - $X_1, \dots, X_n$ sind stochastisch unabhängig und
 - $X_1, \dots, X_n$ besitzen jeweils die gleiche Verteilung.
- Diese Struktur ergibt sich beispielsweise aus der
 - n -fachen, unabhängigen Wiederholung eines Zufallsexperiments oder
 - der n -fachen Ziehung einer Zufallsstichprobe aus einer Grundgesamtheit (mit Zurücklegen).
- In der Statistik werden unabhängig und identisch verteilte Zufallsvariablen häufig in der statistischen Modellierung eingesetzt ($\Rightarrow$ SDS1-V08).

Take Home Messages

- Zufallsvariablen beschreiben den Ausgang eines Zufallsexperiments durch Zahlen.
- Diskrete und stetige Verteilungen werden unterschiedlich charakterisiert (Wahrscheinlichkeitsfunktion vs. Dichte).
- Die Verteilungsfunktion ist ein einheitliches Konzept, das sowohl für stetige als auch für diskrete Zufallsvariablen angewendet werden kann.
- Unabhängig und identisch verteilte Zufallsvariablen stellen ein wichtiges Modell für die statistische Inferenz dar.