

Parametrische Schätzprobleme und Maximum-Likelihood-Schätzung

Dr. Alexander Silbersdorff

Leiter der Arbeitsgruppe Learning Analytics und Data Literacy

Sommersemester 2026



Voraussetzungen

- Differentialrechnung ($\Rightarrow$ M-V05, Vorkurs B7)
- Logarithmus und Exponentialfunktion ($\Rightarrow$ M-V02, Vorkurs B5)
- Lösen von Gleichungssystemen ($\Rightarrow$ M-V02, Vorkurs B2 und B3)
- Optimierung ($\Rightarrow$ M-V05)
- Wahrscheinlichkeitsrechnung ($\Rightarrow$ SDS1-V05, SDS1-V06 und SDS1-V07)

Lernziele

- Welche Grundprinzipien sind in der induktiven Statistik/der statistischen Inferenz (Schließen von einer Stichprobe auf die Grundgesamtheit) zu beachten?
- Wie werden statistische Modelle formuliert, um Daten zu beschreiben?
- Wie lassen sich Parameter in statistischen Modellen mit parametrischer Verteilungsannahme schätzen?
- Wie funktioniert die Maximum-Likelihood-Schätzung als zentrale Methode der Parameterschätzung?

Ziele der statistischen Inferenz

- Beim Schließen von einer Stichprobe auf die zugehörige Grundgesamtheit liegt uns nur unvollständige Information über die Grundgesamtheit vor.
⇒ Unsicherheit und Risiko fehlerhafter Schlüsse
- Die Unsicherheit kann mithilfe der Wahrscheinlichkeitsrechnung quantifiziert werden.
- Das interessierende Phänomen wird dazu durch ein statistisches Modell beschrieben.

Grundgesamtheit und Stichprobe

- Betrachte ein Merkmal X in einer gegebenen Grundgesamtheit mit N Individuen.
- Ziehe (zufällig) eine Stichprobe vom Umfang n aus dieser Gesamtheit.
- In der Grundgesamtheit existieren die Merkmalsausprägungen $a_1, \dots, a_J$ mit Häufigkeiten $h_1, \dots, h_J$ (Anzahl der Individuen mit Ausprägung $a_j, j = 1, \dots, J$).
- Beachte: Die Grundgesamtheit kann nur hypothetisch existieren, z.B. bei einem physikalischen Experiment zur Bestimmung der Gravitationskonstante. Hier ist die Grundgesamtheit die Menge aller theoretisch durchführbaren Experimente.

- Für ein zufällig für die Stichprobe ausgewähltes Individuum ist die Wahrscheinlichkeit für Ausprägung a_j gegeben durch die relativen Häufigkeiten in der Grundgesamtheit:

$$f_j = \frac{h_j}{N}, \quad j = 1, \dots, J.$$

- Ziel ist nun die Schätzung der Häufigkeiten h_j (bzw. der relativen Häufigkeiten f_j), $j = 1, \dots, J$ aus der Stichprobe.

Beispiel: Lieblingsobst

- Grundgesamtheit: Eine Schule mit $N = 1000$ Schüler*innen.
- Merkmal: Lieblingsobst
- Mögliche Ausprägungen $a_1, \dots, a_J$: Apfel, Banane, Erdbeere.
- In der Schule gilt:
 - $a_1 = \text{Apfel}, h_1 = 500$
 - $a_2 = \text{Banane}, h_2 = 300$
 - $a_3 = \text{Erdbeere}, h_3 = 200$
- Daraus ergeben sich die Wahrscheinlichkeiten für die Ausprägungen:

$$f_1 = \frac{h_1}{N} = \frac{500}{1000} = 0.5, \quad f_2 = \frac{300}{1000} = 0.3, \quad f_3 = \frac{200}{1000} = 0.2$$

- Nun wird eine Stichprobe vom Umfang $n = 50$ gezogen.
- Jede Person in der Stichprobe hat eine Wahrscheinlichkeit von f_j , das jeweilige Lieblingsobst zu haben.
- Beispiel: In der Stichprobe könnte man erwarten, dass etwa $0.5 \times 50 = 25$ Schüler*innen Äpfel als Lieblingsobst haben.

Statistisches Modell

- Approximiere die Verteilung des Merkmals X in der Grundgesamtheit durch eine der Verteilungen der Wahrscheinlichkeitsrechnung, z.B.

$$X \sim N(\mu, \sigma^2).$$

- Wir betrachten die Daten dann nicht mehr als Stichprobe aus der Grundgesamtheit, sondern als Stichprobe aus dem Verteilungsmodell.
- Anstelle der Häufigkeiten h_j , $j = 1, \dots, J$ sind jetzt nur noch die beiden Parameter μ und σ^2 zu schätzen!

- Durch die Annahme einer parametrischen Verteilung (einer durch wenige Parameter charakterisierten Verteilung) sind deutlich weniger Parameter zu schätzen.
- Es ist zudem deutlich einfacher, die mit der Schätzung einhergehende Unsicherheit in weitergehenden Verfahren der statistischen Inferenz zu berücksichtigen (vgl. die folgenden Vorlesungen zu Konfidenzintervallen und statistischen Tests).
- Insbesondere für die Normalverteilung sind viele statistische Verfahren entwickelt und in statistischer Software implementiert.

- Häufig wird angenommen, dass die Daten
 - unabhängig und
 - identisch

gemäß dem statistischen Modell verteilt sind, also z.B.

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2).$$


- Die Abkürzung iid steht dabei für “independent and identically distributed”.

Approximations- und Schätzfehler


- Das statistische Modell ist in der Regel nur eine Approximation der wahren Verteilung in der Grundgesamtheit.
- Dabei entsteht der sogenannte Approximationsfehler: Wie gut stimmt die wahre Verteilung (charakterisiert durch die Häufigkeiten $h_1, \dots, h_J$) mit der angenommenen Verteilung (z.B. $N(\mu, \sigma^2)$) überein?
- Bei der Schätzung der Parameter entsteht darüber hinaus der sogenannte Schätzfehler (durch die unvollständige Information der Stichprobe).

Illustration des Approximationsfehlers

- Betrachte die Verteilung der Körpergröße in einer Grundgesamtheit von 1000 Personen.
- Die wahre Verteilung ist eine diskrete Verteilung basierend auf den 1000 Körpergrößen in der Grundgesamtheit und lässt sich etwa in Form eines Histogramms darstellen:



- In der statistischen Modellierung wird die Grundgesamtheit dann durch eine Normalverteilung approximiert:



- Intuitiv:
 - Komplizierte Modelle führen tendenziell zu einem kleineren Approximationsfehler, da sie mehr Parameter aufweisen.
 - Einfache Modelle führen zu einem kleineren Schätzfehler, da mehr Information pro Parameter zur Verfügung steht.
- Mehr dazu in der nächsten Vorlesung

Statistische Inferenz vs. W'keitsrechnung

- Wahrscheinlichkeitsrechnung: Für gegebene Parameter einer Verteilung soll die Wahrscheinlichkeit für bestimmte Ereignisse bestimmt werden, z.B.

$$X \sim N(0, 5) \Rightarrow P(-1 \leq X \leq 2) = ?$$

- Statistische Inferenz: Für gegebene Realisationen einer Zufallsvariablen sollen Aussagen über die zugrundeliegenden Verteilungsparameter gemacht werden, z.B.


$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2)$$

mit Realisationen (Daten) $x_1, \dots, x_n$.

$\Rightarrow$ Was sind plausible Werte für μ und σ^2 ?


Beispiel: Wahrscheinlichkeitsrechnung

- Sei $X \sim N(0, 5) \Rightarrow P(-1 \leq X \leq 2) = ?$



Beispiel: Statistische Inferenz

- Welche Werte für μ und σ^2 passen zu den Daten?



Maximum-Likelihood-Schätzung

- Gegeben seien Beobachtungen zu $n = 20$ unabhängigen Münzwürfen:

Z Z W Z Z Z W W Z Z Z Z W Z Z Z Z W W Z

$\Rightarrow$ 6 mal Wappen, 14 mal Zahl.

- Wie wahrscheinlich sind die Beobachtungen für eine faire Münze mit

$$P(\text{Zahl}) = P(\text{Wappen}) = \frac{1}{2}?$$

$$\Rightarrow \binom{20}{6} \left(\frac{1}{2}\right)^{20} = 0.037$$

- Wie wahrscheinlich sind die Beobachtungen für unfaire Münzen?

$$\Rightarrow P(\text{Zahl})^{14} \cdot P(\text{Wappen})^6.$$

- Werte für verschiedene Wahrscheinlichkeiten:

P(Wappen)	P(Zahl)	Wkt. der Beobachtung
0.1	0.9	$\binom{20}{6} 0.1^6 \cdot 0.9^{14} = 0.009$
0.2	0.8	$\binom{20}{6} 0.2^6 \cdot 0.8^{14} = 0.109$
0.3	0.7	$\binom{20}{6} 0.3^6 \cdot 0.7^{14} = 0.192$
0.4	0.6	$\binom{20}{6} 0.4^6 \cdot 0.6^{14} = 0.124$
0.5	0.5	$\binom{20}{6} 0.5^6 \cdot 0.5^{14} = 0.037$
0.6	0.4	$\binom{20}{6} 0.6^6 \cdot 0.4^{14} = 0.006$
0.7	0.3	$\binom{20}{6} 0.7^6 \cdot 0.3^{14} = 0.0006$
0.8	0.2	$\binom{20}{6} 0.8^6 \cdot 0.2^{14} = 0.00002$
0.9	0.1	$\binom{20}{6} 0.9^6 \cdot 0.1^{14} = 0.0000002$

⇒ Für $P(\text{Wappen}) = 0.3$ und $P(\text{Zahl}) = 0.7$ sind die Beobachtungen am wahrscheinlichsten!

- Prinzip der Maximum-Likelihood-Schätzung: Wähle die unbekannten Parameter so, dass die beobachteten Daten am plausibelsten (“wahrscheinlichsten”) sind.
- Für Realisationen unabhängig und identisch verteilter Zufallsvariablen $X_1, \dots, X_n$, deren Verteilung von einem Parameter ϑ abhängt, definiere die Likelihood als

$$L(\vartheta) = \begin{cases} \prod_{i=1}^n P_{\vartheta}(X_i = x_i) & \text{für diskrete Verteilungen,} \\ \prod_{i=1}^n f_{\vartheta}(x_i) & \text{für stetige Verteilungen.} \end{cases}$$

- Beachte: Für stetige Verteilungen gilt stets $P_{\vartheta}(X_i = x_i) = 0$ (unabhängig vom gewählten Parameter ϑ), so dass anstelle der Wahrscheinlichkeiten die Dichte der Verteilung verwendet wird.

- Der Maximum-Likelihood-Schätzer wird dann definiert als

$$\hat{\vartheta}_{ML} = \arg \max_{\vartheta} L(\vartheta).$$

- Prinzip zur Maximierung:
 - Ableiten nach ϑ ,
 - Nullsetzen der Ableitung und
 - Auflösen des resultierenden Gleichungssystems nach ϑ .

Beispiel: Rate λ der Poissonverteilung

- Seien $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} Po(\lambda)$ verteilt.
- Dann ist die Likelihood gegeben durch:

$$\begin{aligned} L(\lambda) &= \prod_{i=1}^n P_{\lambda}(X_i = x_i) \\ &= \prod_{i=1}^n \frac{\lambda^{x_i}}{x_i!} e^{-\lambda} \\ &= \left(\prod_{i=1}^n \frac{1}{x_i!} \right) \lambda^{\sum_{i=1}^n x_i} e^{-n\lambda} \rightarrow \max_{\lambda} \end{aligned}$$

- Problem: Die Likelihood ist ein Produkt, so dass zur Ableitung die Produktregel eingesetzt werden muss.

Log-Likelihood

- Definiere die Log-Likelihood als

$$\ell(\vartheta) = \log(L(\vartheta)).$$

- Da der Logarithmus stetig monoton wachsend ist, gilt

$$\arg \max_{\vartheta} L(\vartheta) = \arg \max_{\vartheta} \ell(\vartheta).$$

- Die Maximierung der Log-Likelihood ist also äquivalent zur Maximierung der Likelihood, aber die Bestimmung der Ableitung ist für die Log-Likelihood deutlich einfacher!


- Für iid-Daten ist die Log-Likelihood gegeben durch

$$\ell(\vartheta) = \begin{cases} \sum_{i=1}^n \log(P_{\vartheta}(X_i = x_i)) & \text{für diskrete Verteilungen,} \\ \sum_{i=1}^n \log(f_{\vartheta}(x_i)) & \text{für stetige Verteilungen.} \end{cases}$$

- Die Ableitung der Log-Likelihood ist entsprechend eine Summe von Ableitungen.

Likelihood vs. Log-Likelihood

- Gegeben seien Beobachtungen zu $n = 20$ unabhängigen Münzwürfen mit 6 mal Wappen, 14 mal Zahl.




Beispiel: Poissonverteilung



- Die Log-likelihood ist gegeben durch



$$\begin{aligned}\ell(\lambda) &= \log(L(\lambda)) \\ &= -\sum_{i=1}^n \log(x_i!) + \left(\sum_{i=1}^n x_i\right) \log(\lambda) - n\lambda.\end{aligned}$$

- Ableiten und Nullsetzen ergibt entsprechend

$$\begin{aligned}\frac{\partial}{\partial \lambda} \ell(\lambda) &= \frac{1}{\lambda} \sum_{i=1}^n x_i - n \stackrel{!}{=} 0 \\ \iff \frac{1}{\lambda} \sum_{i=1}^n x_i &= n \quad \text{und damit} \\ \hat{\lambda}_{\text{ML}} &= \frac{1}{n} \sum_{i=1}^n x_i.\end{aligned}$$



Model mit ($\lambda = 1.5$)Model mit ($\lambda = 4.5$)

Model mit ($\lambda = 6$)Model mit ($\lambda = 3.15$)

Beispiel: Normalverteilung mit bekannter Varianz

- Seien $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2)$ verteilt mit bekannter Varianz σ^2 , d.h. die Dichte der Daten ist

$$f(x_i | \mu) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right).$$

- Dann ist die Likelihood für μ gegeben durch

$$\begin{aligned} L(\mu) &= \prod_{i=1}^n f(x_i | \mu) \\ &= \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^n \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right). \end{aligned}$$

- Als Log-Likelihood erhalten wir entsprechend

$$\begin{aligned}\ell(\mu) &= \log(L(\mu)) \\ &= -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2.\end{aligned}$$

- Die erste Ableitung ergibt sich als

$$\begin{aligned}\frac{\partial}{\partial \mu} \ell(\mu) &= -\frac{1}{2\sigma^2} \cdot \frac{\partial}{\partial \mu} \left(\sum_{i=1}^n (x_i - \mu)^2 \right) \\ &= -\frac{1}{2\sigma^2} \cdot \sum_{i=1}^n (-2)(x_i - \mu) \\ &= \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu).\end{aligned}$$

- Nullsetzen und Auflösen ergibt dann den ML-Schätzer:


$$\frac{\partial}{\partial \mu} \ell(\mu) \stackrel{!}{=} 0 \iff \sum_{i=1}^n (x_i - \mu) = 0$$



$$\Rightarrow n\mu = \sum_{i=1}^n x_i$$



$$\Rightarrow \hat{\mu}_{\text{ML}} = \frac{1}{n} \sum_{i=1}^n x_i$$

Beispiel: Normalverteilung

Wahre Verteilung: $\mu = 5$, $\sigma = 1$



Model mit $\mu = 3$ Model mit $\mu = 4$ 

Model mit $\mu = 6$ Model mit $\mu = 4.97$ 

Allgemeines Prinzip der ML-Schätzung

- Wähle ein für die Fragestellung passendes Verteilungsmodell.
- Stelle die entsprechende Log-Likelihood mit Hilfe der Wahrscheinlichkeitsfunktion bzw. Dichte der Verteilung auf.
- Leite nach dem gesuchten Parameter ab und setze das Ergebnis gleich Null.
- Löse die resultierende Gleichung nach dem gesuchten Parameter auf.

Take Home Messages

- Parametrische Verteilungen werden zur Formulierung statistischer Modelle genutzt.
- Ziel ist dann die Schätzung der Parameter dieser Verteilung basierend auf einer Stichprobe.
- Mit Hilfe des Maximum-Likelihood-Ansatzes lassen sich für verschiedene Verteilungen Schätzer konstruieren.
- Rezept zur Bestimmung: Log-Likelihood aufstellen, Ableiten, Nullsetzen und Auflösen.