

Allgemeine Schätzprinzipien und nichtparametrische Schätzprobleme

Dr. Alexander Silbersdorff

Leiter der Arbeitsgruppe Learning Analytics und Data Literacy

Sommersemester 2026



Voraussetzungen

- Wahrscheinlichkeitsrechnung ($\Rightarrow$ SDS1-V05, SDS1-V06 und SDS1-V07)
- Parametrische Schätzansätze ($\Rightarrow$ SDS1-V08)
- Histogramme ($\Rightarrow$ SDS1-V02)

Lernziele

- Wie lassen sich die Güteeigenschaften von Schätzansätzen beurteilen?
- Was sind nichtparametrische Schätzansätze, insbesondere für Dichtefunktionen?
- Wie bestimmen sich Approximations- und Schätzfehler in der statistischen Inferenz?

- Ein guter Schätzer sollte
 - den wahren Wert weder systematisch über- noch unterschätzen,
 - nicht zu stark um den wahren Wert schwanken und
 - für wachsenden Stichprobenumfang tendenziell näher am wahren Wert liegen.
- Im Folgenden lernen wir geeignete Maße zur Beurteilung dieser Eigenschaften kennen.

- Dabei ist zu beachten:
 - Die beobachteten Daten sind Realisationen der Zufallsvariablen $X_1, \dots, X_n$.
 - Entsprechend sind die Daten vor Durchführung der Datenerhebung zufällig.
 - Ein Schätzer $\hat{\vartheta}$ ist eine Funktion der Daten und damit ebenfalls eine Zufallsvariable, deren Verteilung wir betrachten können.
 - Insbesondere lassen sich z.B. Erwartungswert und Varianz des Schätzers berechnen.

Bias/Verzerrung

- Der Bias/die Verzerrung eines Schätzers ist definiert als

$$\text{Bias}(\hat{\vartheta}) = E(\hat{\vartheta}) - \vartheta.$$

- Der Bias misst, wie weit der Schätzer tendenziell vom wahren Wert abweicht.
 - $\text{Bias}(\hat{\vartheta}) > 0 \Rightarrow$ der wahre Wert wird tendenziell überschätzt.
 - $\text{Bias}(\hat{\vartheta}) < 0 \Rightarrow$ der wahre Wert wird tendenziell unterschätzt.
 - $\text{Bias}(\hat{\vartheta}) = 0 \Rightarrow$ der Schätzer ist unverzerrt; Unter- und Überschätzung gleichen sich tendenziell aus.

Varianz eines Schätzers

- Die Varianz eines Schätzers ist definiert als

$$\text{Var}(\hat{\vartheta}) = E \left[(\hat{\vartheta} - E(\hat{\vartheta}))^2 \right]$$

und misst, wie stark sich der Wert des Schätzers bei wiederholter Stichprobenziehung unterscheidet.

- Für unverzernte Schätzer bedeutet eine kleine Varianz, dass der Schätzer üblicherweise nahe am wahren Wert liegt.
- Für verzerrte Schätzer ist eine kleine Varianz nicht generell wünschenswert.

Beispiel: Poissonverteilung

- Neben dem ML-Schätzer betrachten wir auch den (ungeeigneten) Schätzer $\hat{\lambda}_0 = 2 \cdot \frac{1}{n} \sum_{i=1}^n X_i$

	X_1	X_2	X_3	X_4	X_5	$\hat{\lambda}_{ML}$	$\hat{\lambda}_0$
1. Stichprobe	4	1	2	3	1	2.2	4.4
2. Stichprobe	0	1	2	0	3	1.2	2.4
3. Stichprobe	3	3	1	0	3	2.0	4.0
4. Stichprobe	4	5	0	2	2	2.6	5.2
5. Stichprobe	4	1	6	4	0	3.0	6.0
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$

- Beide Schätzer sind nicht für jede Stichprobe gleich, sondern variieren ($\Rightarrow$ Varianz des Schätzers).
- Während $\hat{\lambda}_{ML}$ um den wahren Wert von $\lambda = 2$ zu schwanken scheint, überschätzt $\hat{\lambda}_0$ den wahren Wert konstant ($\Rightarrow$ Erwartungstreue/Bias eines Schätzers).

Mittlerer quadratischer Fehler

- Der mittlere quadratische Fehler (Mean Squared Error) eines Schätzers ist definiert durch

$$\text{MSE}(\hat{\vartheta}) = E \left[(\hat{\vartheta} - \vartheta)^2 \right].$$

- Im Vergleich zur Varianz misst der MSE die Abweichung zum wahren Wert, nicht zum Erwartungswert $E(\hat{\vartheta})$.
- Mit dem MSE lassen sich entsprechend verzerrte und unverzerrte Schätzer vergleichen.

- Der MSE lässt sich auch darstellen als

$$\text{MSE}(\hat{\vartheta}) = \text{Bias}^2(\hat{\vartheta}) + \text{Var}(\hat{\vartheta})$$

d.h. der MSE kombiniert Bias und Varianz in einem gemeinsamen Maß.

- Insbesondere gilt für unverzerzte Schätzer

$$\text{MSE}(\hat{\vartheta}) = \text{Var}(\hat{\vartheta}).$$

Beispiel: Bernoulliverteilung

- Setup:

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Be}(\pi)$$

- Welche Eigenschaften besitzt der ML-Schätzer

$$\hat{\pi}_{ML} = \frac{1}{n} \sum_{i=1}^n X_i?$$

- Bias:

$$E(\hat{\pi}) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \pi \quad \Rightarrow \quad \text{Bias}(\hat{\pi}) = E(\hat{\pi}) - \pi = 0$$

- Varianz:

$$\text{Var}(\hat{\pi}) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{1}{n^2} \cdot n \cdot \pi(1 - \pi) = \frac{\pi(1 - \pi)}{n}$$

- MSE:

$$\text{MSE}(\hat{\pi}) = \text{Var}(\hat{\pi}) + \text{Bias}^2(\hat{\pi}) = \frac{\pi(1 - \pi)}{n}$$

Konsistenz eines Schätzers

- Gilt für einen Schätzer $MSE(\hat{\vartheta}) \rightarrow 0$ für $n \rightarrow \infty$, so nennt man diesen konsistent (im quadratischen Mittel).
- Für wachsenden Stichprobenumfang konvergiert der Schätzer dann gegen den wahren Wert.

Beispiel: Bernoulliverteilung

- Setup:

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Be}(\pi) \quad \Rightarrow \quad \hat{\pi}_{ML} = \frac{1}{n} \sum_{i=1}^n X_i$$

- Konsistenz:

$$\text{MSE}(\hat{\pi}) = \frac{\pi(1 - \pi)}{n} \rightarrow 0$$

für $n \rightarrow \infty$.

Optimalitätseigenschaften ML-Schätzer

- ML-Schätzer sind für iid-Daten (unter gewissen Zusatzannahmen)
 - nicht grundsätzlich erwartungstreu, aber asymptotisch erwartungstreu, d.h.

$$\text{Bias}(\hat{\vartheta}_{ML}) \rightarrow 0 \text{ für } n \rightarrow \infty,$$

- konsistent (tendieren also bei wachsendem Stichprobenumfang zum wahren Wert) und
 - asymptotisch normalverteilt (so dass sich asymptotische Konfidenzintervalle und statistische Tests konstruieren lassen).
- Entsprechend sind ML-Schätzer sehr beliebt, auch in komplexeren statistischen Modellen.

Nichtparametrische Verteilungsschätzung

- Als parametrisches Verteilungsmodell bezeichnen wir ein statistisches Modell, bei dem der Verteilungstyp festgelegt ist, aber der/die Parameter geschätzt werden müssen.
- Soll keine parametrisches Modell für die Daten angenommen werden, so kann man versuchen, die Verteilung nichtparametrisch zu schätzen.
 - Diskretes Merkmal: Schätzen der Wahrscheinlichkeiten $P(X = a_j)$ durch relative Häufigkeiten f_j .
 - Stetiges Merkmal: Schätzen der Dichte über Histogramme.

Histogramme als Dichteschätzer

- Zerlege den Datenbereich in J Intervalle/Klassen

$$[c_0, c_1], \dots, (c_{j-1}, c_j], \dots, (c_{J-1}, c_J]$$

und bestimme die relativen Häufigkeiten $f_1, \dots, f_J$.

- Zeichne über den Intervallen Rechtecke der Höhe

$$\theta_j = \frac{f_j}{c_j - c_{j-1}},$$

so dass die Flächen $\mathcal{F}_j$ der Rechtecke gleich den relativen Häufigkeiten f_j sind.

- Die Gesamtfläche des Histogramms ist 1.
 $\Rightarrow$ Das Histogramm besitzt die Eigenschaften einer Dichtefunktion!


Parameter eines Histogramms

- Die Parameter eines Histogramms sind die Höhen der einzelnen Rechtecke des Histogramms:


$$\hat{f}(x) = \begin{cases} \theta_1 & \text{für } c_0 < x \leq c_1, \\ \theta_2 & \text{für } c_1 < x \leq c_2, \\ \vdots & \vdots \\ \theta_J & \text{für } c_{J-1} < x \leq c_J, \\ 0 & \text{sonst.} \end{cases}$$

- Ein Histogramm mit J Klassen hat $J - 1$ freie Parameter, da die Gesamtfläche 1 ist.

4 Parameter (davon 3 frei wählbar)



2 Parameter (davon 1 frei wählbar)




Approximationsfehler


- Fehler durch Approximation entstehen, weil wir die wahre, komplizierte Verteilung der Daten, durch ein statistisches Modell approximieren.
- Beim Histogramm approximieren wir eine Dichtekurve durch eine stückweise konstante Funktion.
- Je größer die Anzahl der Parameter des Histogramms ist, desto kleiner wird der Fehler durch Approximation.

- Zur Illustration betrachten wir Altersverteilung der Bevölkerung in Göttingen.
- Hier ist die wahre Verteilung bekannt und wird im Folgenden als Dichtefunktion dargestellt.
- Dazu betrachten wir Histogramme mit verschiedenen Parameteranzahlen.


51 Klassen, 50 Parameter




21 Klassen, 20 Parameter



11 Klassen, 10 Parameter




6 Klassen, 5 Parameter




Schätzfehler

- Schätzfehler entstehen, weil uns bei Betrachtung einer Stichprobe nur unvollständige Information über die Grundgesamtheit zur Verfügung steht.
- In unserem Beispiel kennen wir nur das Alter von 100 Personen in der Stichprobe.
- Im Folgenden visualisieren wir die wahre Verteilung bei Verwendung eines Histogramms mit gegebener Parameterzahl mit dem aus der Stichprobe geschätzten Histogramm.
- Je größer die Anzahl der Parameter ist, desto größer wird der Fehler durch Schätzung, da uns weniger Information pro Parameter zur Verfügung steht.


51 Klassen, 50 Parameter




21 Klassen, 20 Parameter



11 Klassen, 10 Parameter



6 Klassen, 5 Parameter



Gesamtfehler

- Je größer die Anzahl der Parameter,
 - desto kleiner wird der Approximationsfehler,
 - desto größer wird der durchschnittliche Schätzfehler.
- Der **gesamte Fehler**, der beim Schätzen entsteht, besteht also aus zwei Komponenten:
 - dem Fehler durch Approximation, sichtbar als Abweichung des Histogramms der Grundgesamtheit vom Grundmodell, und
 - dem Fehler durch Schätzung, sichtbar als Abweichung des Histogramms der Stichprobe vom Histogramm der Grundgesamtheit.

- Beide Fehlerkomponenten müssen ausbalanciert werden, um den Gesamtfehler zu minimieren.
- Übersicht über den Approximations-, Schätz- und den Gesamtfehler in Abhängigkeit von Stichprobenumfang und Parameterzahl:

	Approximationsfehler	Schätzfehler	Gesamtfehler
$n \uparrow$	—	$\downarrow$	$\downarrow$
$n \downarrow$	—	$\uparrow$	$\uparrow$
Anzahl Parameter $\uparrow$	$\downarrow$	$\uparrow$	$\downarrow \uparrow$
Anzahl Parameter $\downarrow$	$\uparrow$	$\downarrow$	$\downarrow \uparrow$

Zusammenfassung

- Der Approximationsfehler sinkt mit wachsender Parameterzahl und hängt nicht vom Stichprobenumfang ab.
- Der Schätzfehler sinkt mit steigendem Stichprobenumfang und wächst mit steigender Parameterzahl.
- Der Gesamtfehler sinkt mit steigendem Stichprobenumfang.
- Die optimale Parameterzahl minimiert den Gesamtfehler.

Kerndichteschätzung

- Ein Histogramm ist eine stückweise konstante Funktion, während viele Dichten eine komplexere funktionale Form aufweisen.
- Mit Hilfe von Kerndichteschätzern lassen sich flexiblere Dichteformen schätzen.
- Als Zwischenschritt betrachten wir ein fließendes Histogramm.

Fließendes Histogramm

- Ein fließendes Histogramm ist gegeben durch:

$$\hat{f}(x) = \frac{1}{2b} \frac{(\text{Anzahl Datenpunkte in } (x - b, x + b])}{n}$$

wobei b die sogenannte Bandweite bezeichnet.

- Begründung:
 - Grundlage sind die relativen Häufigkeiten der Intervalle $(x - b, x + b]$ mit Breite $2b$.
 - Die Normalisierung mit $1/2b$ bewirkt, dass die Fläche unter dem fließenden Histogramm gleich 1 ist:

$$\int_{-\infty}^{\infty} \hat{f}(x) dx = 1.$$


- Das Intervall $(x - b, x + b]$ gleitet über die x -Achse.

- Äquivalente Darstellung des fließenden Histogramms:

$$\hat{f}(x) = \frac{1}{nb} \sum_{i=1}^n K\left(\frac{x - x_i}{b}\right)$$

mit dem sogenannten Rechtecks-Kern

$$K(u) = \begin{cases} \frac{1}{2} & \text{falls } -1 \leq u < 1, \\ 0 & \text{sonst.} \end{cases}$$




⇒ Ein fließendes Histogramm ist der Mittelwert von Kernfunktionen (Kerndichteschätzer).

Beispiel: Temperaturrekonstruktion


- Jährliche Rekonstruktion der Durchschnittstemperatur auf der Nordhalbkugel der Erde
- Daten für die letzten 2000 Jahre
- Stetiges Merkmal mit insgesamt 1739 verschiedenen beobachteten Werten

- Histogramme mit verschiedenen Klassenanzahlen:


10 Klassen




50 Klassen




100 Klassen



200 Klassen



- Fließende Histogramme mit verschiedenen Bandweiten:




- Die Glattheit des Kerndichteschätzers wird durch die Bandweite b gesteuert.
- Für kleine Bandweiten wird die Schätzung sehr rauh.
- Für große Bandweiten entspricht die Schätzung der Form des eingesetzten Rechtecks-Kerns.

Kernfunktionen


- Eine Kernfunktion ist eine um Null symmetrische Dichtefunktion.
- Epanechnikov-Kern

$$K(u) = \begin{cases} \frac{3}{4}(1 - u^2) & -1 \leq u < 1, \\ 0 & \text{sonst.} \end{cases}$$




- Bisquare-Kern

$$K(u) = \begin{cases} \frac{15}{16}(1 - u^2)^2 & -1 \leq u < 1, \\ 0 & \text{sonst.} \end{cases}$$



- Gauß-Kern

$$K(u) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}u^2\right)$$



Kerndichteschätzer

- Allgemein ergibt sich der Kerndichteschätzer als


$$\hat{f}(x) = \frac{1}{nb} \sum_{i=1}^n K\left(\frac{x - x_i}{b}\right)$$

wobei verschiedene Kernfunktionen $K(u)$ eingesetzt werden können.

- Die Glattheit des Kerndichteschätzers hängt von
 - der Bandweite b und
 - dem gewählten Kern $K(u)$ ab.
- Glattere Kerne ergeben auch glattere Funktionen zur Beschreibung der Häufigkeiten.
- Es existieren auch Methoden zur optimalen Bestimmung der Bandweite b .

Beispiel: Temperaturrekonstruktion

N = 1979 Bandweite = 0.04138



Take Home Messages

- Es existieren Maße, mit deren Hilfe sich statistische Schätzer vergleichen lassen.
- Maximum-Likelihood-Schätzer weisen eine Reihe von Güteeigenschaften auf.
- Bei der Schätzung müssen Approximationsfehler (Komplexität des Modells) und Schätzfehler (Schließen von einer Stichprobe auf die Grundgesamtheit) zum Ausgleich gebracht werden.
- Dichten können ohne konkrete Verteilungsannahme mit Hilfe von Histogrammen und Kerndichteschätzern geschätzt werden.