

Prinzipien statistischer Hypothesentests

Dr. Alexander Silbersdorff

Leiter der Arbeitsgruppe Learning Analytics und Data Literacy

Sommersemester 2026



Voraussetzungen

- Wahrscheinlichkeitsrechnung ($\Rightarrow$ SDS1-V05, SDS1-V06 und SDS1-V07)
- Parametrische Schätzansätze ($\Rightarrow$ SDS1-V08)
- Konfidenzintervalle ($\Rightarrow$ SDS1-V10)

Lernziele

- Wie lassen sich mit Hilfe statistischer Tests Hypothesen über die Parameter einer Verteilung empirisch überprüfen?
- Wie kann man solche Testprobleme formal korrekt darstellen?
- Was bedeuten die zentrale Konzepte statistischer Tests (z.B. Fehlerwahrscheinlichkeiten, Teststatistik, Ablehnbereich, p-Wert)?

Motivation: Binomialtest

- Wir betrachten ein bernoulliverteiltes Merkmal $X \sim B(\pi)$ mit unbekannter Erfolgswahrscheinlichkeit π .
- Anhand von beobachteten Daten (Realisationen von n unabhängig und identisch wie X verteilten Zufallsvariablen $X_1, \dots, X_n$) sollen wir entscheiden, ob die Daten der Hypothese

$$H_0 : \pi \leq 0.25$$

widersprechen.

- Intuition:
 - Gilt $\pi = 0.25$, so erwarten wir ca. $0.25 \cdot n$ Erfolge.
 - Gilt $\pi < 0.25$, so erwarten wir weniger als $0.25 \cdot n$ Erfolge.
 - Gilt $\pi > 0.25$, so erwarten wir mehr als $0.25 \cdot n$ Erfolge.

- Ist $Z = \sum_{i=1}^n X_i$ (Anzahl der Erfolge) deutlich größer als $0.25 \cdot n$, so spricht dies gegen die Hypothese H_0 ($\pi \leq 0.25$).
- Ist Z nahe bei $0.25 \cdot n$ oder kleiner als $0.25 \cdot n$, so ist dies mit der Hypothese H_0 vereinbar.
- Lege entsprechend einen Ablehnbereich

$$A = \{a, a + 1, \dots, n\}$$

mit $a > 0.25 \cdot n$ fest, so dass die Hypothese $\pi \leq 0.25$ verworfen wird, wenn $Z \in A$ (also $Z \geq a$) gilt.

- Der Test wird als Binomialtest bezeichnet, da $Z = \sum_{i=1}^n X_i$ binomialverteilt ist mit Parametern n und π .

Irrtumsw'keiten des Binomialtests

- Bei der Anwendung des Binomialtests können zwei Arten von Fehlern auftreten:
 - α -Fehler: Wir verwerfen die Hypothese $H_0 : \pi \leq 0.25$, obwohl sie wahr ist (Fehler 1. Art).
 - β -Fehler: Wir verwerfen die Hypothese $H_0 : \pi \leq 0.25$ nicht, obwohl sie falsch ist (Fehler 2. Art).

	Entscheidung: H_0 verwerfen	Entscheidung: H_0 nicht verwerfen
H_0 wahr	α	✓
H_0 falsch	✓	β

- Intuition:
 - Für kleine Ablehnbereiche $A = \{a, \dots, n\}$ (also große Werte von a) ist die Wahrscheinlichkeit des α -Fehlers klein.
 - Für große Ablehnbereiche A (also kleine Werte von a) ist die Wahrscheinlichkeit des β -Fehlers klein.
- Alternativ:
 - Für kleine Ablehnbereiche ist es schwer, die Hypothese H_0 zu verwerfen, da extremere Beobachtungen notwendig sind, um $Z \in A$ zu beobachten.
 - Für große Ablehnbereiche ist es entsprechend leichter, die Hypothese H_0 zu verwerfen.
- Für ein genaueres Verständnis formalisieren wir zunächst das Testproblem.

Formalisierung des Binomialtests

- Daten: $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} B(\pi)$
- Hypothesen: $H_0 : \pi \leq 0.25$ vs. $H_1 : \pi > 0.25$
 H_0 heißt Nullhypothese, H_1 heißt Alternativhypothese
- Teststatistik: $Z = \sum_{i=1}^n X_i$ (Anzahl der Erfolge)
- Für die Verteilung der Teststatistik gilt

$$Z \sim \text{Bi}(n, \pi).$$

- Aber: π ist unbekannt!

- Ablehnbereich: $A = \{a, \dots, n\}$

- Testentscheidung:

$Z \in A \Rightarrow$ Beweis der Alternativhypothese bzw.
Nullhypothese kann verworfen werden


$Z \notin A \Rightarrow$ Nullhypothese beibehalten bzw.
Nullhypothese kann nicht verworfen werden

Bestimmung der Fehlerwahrscheinlichkeiten


- Die Wahrscheinlichkeiten für Fehler 1. Art und Fehler 2. Art hängen vom wahren Wert der Erfolgswahrscheinlichkeit π ab.
- Da $Z \sim \text{Bi}(n, \pi)$ gilt, lassen sich die Wahrscheinlichkeiten $P_\pi(Z \in A)$ und $P_\pi(Z \notin A)$ für gegebene Werte von π bestimmen.
- Betrachten wir die Wahrscheinlichkeit $P_\pi(Z \in A) = P_\pi(Z \geq a)$, so gilt

$$\begin{aligned} P_\pi(Z \in A) &= P_\pi(H_0 \text{ wird verworfen}) \\ &= \begin{cases} P_\pi(\text{Fehler 1. Art}) & \text{falls } \pi \leq 0.25 \\ P_\pi(\text{richtige Testentscheidung}) & \text{falls } \pi > 0.25. \end{cases} \end{aligned}$$


$$A \geq 25, \alpha_{\max} = 0.54, \beta_{\max} = 0.46$$




$$A \geq 30, \alpha_{\max} = 0.15, \beta_{\max} = 0.85$$



$$A \geq 40, \alpha_{\max} = 0, \beta_{\max} = 1$$




$$A \geq 50, \alpha_{\max} = 0, \beta_{\max} = 1$$




- Betrachten wir nun die Wahrscheinlichkeit $P_\pi(Z \notin A) = P_\pi(Z < a)$, so gilt

$$\begin{aligned} P_\pi(Z \notin A) &= P_\pi(H_0 \text{ wird beibehalten}) \\ &= \begin{cases} P_\pi(\text{richtige Testentscheidung}) & \text{falls } \pi \leq 0.25 \\ P_\pi(\text{Fehler 2. Art}) & \text{falls } \pi > 0.25. \end{cases} \end{aligned}$$


$$A \geq 25, \alpha_{\max} = 0.54, \beta_{\max} = 0.46$$




$$A \geq 30, \alpha_{\max} = 0.15, \beta_{\max} = 0.85$$



$$A \geq 40, \alpha_{\max} = 0, \beta_{\max} = 1$$



$$A \geq 50, \alpha_{\max} = 0, \beta_{\max} = 1$$



Asymmetrie statistischer Tests

- Im Idealfall ließe ein statistischer Test sowohl Fehler 1. als auch Fehler 2. Art nur mit kleinen Wahrscheinlichkeiten zu.
- Die Wahrscheinlichkeiten hängen jedoch vom wahren Wert π ab.
⇒ Betrachte die größtmögliche Wahrscheinlichkeit für Fehler 1. und 2. Art für alle möglichen π , also

$$\alpha_{max} = \max_{\pi \leq 0.25} P(Z \geq a) \quad \rightarrow \text{maximaler Fehler 1. Art,}$$

$$\beta_{max} = \max_{\pi > 0.25} P(Z < a) \quad \rightarrow \text{maximaler Fehler 2. Art.}$$

- Leider gilt nun immer (für alle möglichen Werte von a)

$$\alpha_{max} + \beta_{max} = 1$$

das heißt die maximalen Fehlerwahrscheinlichkeiten addieren sich immer zu 1!

- Sollen α_{max} und β_{max} gleichzeitig möglichst klein sein, so erhält man

$$\alpha_{max} = \beta_{max} = 0.5.$$

- Dies entspricht der Fehlerwahrscheinlichkeit eines Münzwurfs und ist damit kein sinnvoller Weg, eine Entscheidung im Testproblem zu treffen.

- Konsequenz: Wir können nur eine Fehlerwahrscheinlichkeit kontrollieren und damit nur eine Hypothese beweisen.
⇒ Asymmetrische Behandlung der Hypothesen.
- Genauer: Wir geben uns eine kleine Obergrenze für den Fehler 1. Art vor und wählen den Ablehnbereich so, dass α_{max} dieser Obergrenze entspricht.
⇒ Für $Z \in A$ ist es sehr unwahrscheinlich, dass wir H_0 fälschlicherweise verwerfen.
⇒ Die Alternative wurde (statistisch) bewiesen.
- Die Obergrenze für den Fehler 1. Art wird als Signifikanzniveau bezeichnet.
- Typische Werte: 0.05, 0.01 oder 0.001

Allgemeines Vorgehen

- Daten $X_1, \dots, X_n$, häufig $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} F_\theta$ mit einer parametrischen Verteilungsannahme
- Hypothesen: Formuliere zwei sich gegenseitig ausschließende Hypothesen über die Verteilung der Daten (bzw. die Parameter der Verteilung).
- Beispiel:
 - $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2)$

$H_0 : \mu = \mu_0$ vs. $H_1 : \mu \neq \mu_0$ zweiseitiger Test

$H_0 : \mu \leq \mu_0$ vs. $H_1 : \mu > \mu_0$ einseitiger Test

$H_0 : \mu \geq \mu_0$ vs. $H_1 : \mu < \mu_0$ einseitiger Test

mit einem vorgegebenen Wert μ_0

- Weitere Beispiele:

- $X_1, \dots, X_n$ i.i.d. aus einer symmetrischen Verteilung mit Median μ

$$H_0 : \mu = \mu_0 \text{ vs. } H_1 : \mu \neq \mu_0$$

- $X_1, \dots, X_n$ i.i.d. gemäß einer Verteilung mit Verteilungsfunktion F

$$H_0 : F \text{ ist eine Normalverteilung vs. } H_1 : F \text{ ist keine Normalverteilung}$$

- $(X_1, Y_1), \dots, (X_n, Y_n)$ i.i.d. aus einer bivariaten Verteilung

$$H_0 : \text{Die beiden Merkmale } X \text{ und } Y \text{ sind unabhängig vs.}$$

$$H_1 : \text{Die beiden Merkmale } X \text{ und } Y \text{ sind stochastisch abhängig}$$

- Verschiedene spezielle Tests werden in der nächsten Vorlesung behandelt.

- Bestimme eine Teststatistik $Z = Z(X_1, \dots, X_n)$, die misst, wie stark die Daten der Nullhypothese widersprechen bzw. mit dieser in Einklang stehen.
- Konstruiere einen Ablehnbereich A , so dass die Testentscheidung getroffen werden kann:

$Z \in A \Rightarrow$ Verwirf H_0 , H_1 ist statistisch bewiesen

$Z \notin A \Rightarrow H_0$ wird beibehalten (ist aber nicht bewiesen)

- Der Ablehnbereich wird so gewählt, dass α_{max} = größtmögliche Wahrscheinlichkeit für einen Fehler 1. Art $\leq \alpha$ (= Signifikanzniveau) gilt.
 $\Rightarrow$ Ist H_0 richtig, so ist es sehr unwahrscheinlich (höchstens α), H_0 fälschlicherweise zu verwerfen.

Der p-Wert

- Zur praktischen Durchführung ist die bisher beschriebene Vorgehensweise statistischer Tests eher aufwändig und benötigt detailliertes Wissen über die spezifischen Tests.
- p-Werte sind ein praktisches Hilfsmittel, um Tests (insbesondere mit Hilfe statistischer Software) durchführen zu können.
- Vorgehensweise:
 - Bestimme den beobachteten Wert der Teststatistik z_{obs} .
 - Berechne den p-Wert (intuitiv: Wie unwahrscheinlich war z_{obs} unter der Nullhypothese?).
 - Verwirf H_0 falls der p-Wert $\leq \alpha$ ist; andernfalls wird H_0 beibehalten.

- Formaler ist der p-Wert definiert als
 - die Wahrscheinlichkeit, unter H_0 einen noch extremeren Wert für die Teststatistik Z zu erhalten als den beobachteten Wert z_{obs} .

Beispiel Binomialtest

- Wir betrachten die Hypothesen $H_0 : \pi \leq 0.25$ vs. $H_1 : \pi > 0.25$.
- Als Teststatistik verwenden wir $Z \sim \text{Bi}(n, \pi)$.
- Als Signifikanzniveau (Obergrenze für den Fehler 1. Art) wählen wir $\alpha = 0.01$.

- Beobachtet wurden $z_{obs} = 50$ Erfolge (bei einer Stichprobe von $n = 100$ Versuchen).
- Große Werte der Teststatistik Z sprechen gegen die Nullhypothese.
- Entsprechend bestimmt sich der p-Wert als

$$P_{H_0}(Z \geq z_{obs}) = \sum_{z=50}^{100} \binom{100}{z} 0.25^z (1 - 0.25)^{100-z} = 6.64 \times 10^{-8}$$

- Da $P_{H_0}(Z \geq 50) \leq \alpha = 0.01$ gilt, kann H_0 verworfen werden und H_1 wurde (statistisch) bewiesen.

Zweiseitige Tests und Konfidenzintervalle

- Für zweiseitige Tests erhält man die folgende Aussage: Die Nullhypothese


$$H_0 : \vartheta = \vartheta_0$$

wird zum Signifikanzniveau α genau dann verworfen, wenn ein $1 - \alpha$ Konfidenzintervall für ϑ den Wert ϑ_0 nicht enthält.

- Entsprechend kann mit Hilfe eines Konfidenzintervalls auch ein (zweiseitiger) Signifikanztest durchgeführt werden.

Beispiel: Binomialtest mit $X \sim Bi(20, \hat{\pi})$

- Hypothesen: $H_0 : p_0 = 0.3$ vs. $H_0 : p_0 \neq 0.3$



Durchführung statistischer Tests

- Statistische Tests können auf drei verschiedene Arten durchgeführt werden:
 - Bestimmung einer geeigneten Teststatistik und des zugehörigen Ablehnbereichs
 - Berechnung des p-Werts
 - Betrachtung eines Konfidenzintervalls für den interessierenden Parameter (bei zweiseitigen Tests)
- Teststatistik und Ablehnbereich werden vor allem zur theoretischen Konstruktion von Tests verwendet.
- Zur praktischen Durchführung in der Datenanalyse bieten sich p-Wert und Konfidenzintervall an.

Beispiel: Wirksamkeit eines Impfstoffs

- Eine Studie behauptet, dass 50% der geimpften Personen eine bestimmte Antikörperreaktion zeigen.
- Zur Überprüfung der Aussage wird eine Stichprobe von $n = 20$ Personen ausgewählt. Von diesen zeigen $z_{obs} = 15$ die erwünschte Antikörperreaktion.
- Wir testen die Hypothesen

$$H_0 : \pi = 0.5 \quad \text{vs.} \quad H_1 : \pi \neq 0.5$$

wobei π den wahren Anteil der geimpften Personen bezeichnet, die eine Antikörperreaktion zeigen.

- Als Signifikanzniveau wählen wir $\alpha = 0.05$.

1. Teststatistik und Ablehnbereich

- Wir verwenden die Teststatistik $Z \sim \text{Bi}(n, \pi)$.
- Sowohl sehr große als auch sehr kleine Werte der Teststatistik sprechen gegen H_0 .
 $\Rightarrow$ Teile das Signifikanzniveau α symmetrisch auf und bestimme kritische Werte a_1 und a_2 , so dass

$$P_{H_0}(Z \leq a_1) = \sum_{z=0}^{a_1} \binom{20}{z} 0.5^z (1 - 0.5)^{20-z} \leq \alpha/2$$

und

$$P_{H_0}(Z \geq a_2) = \sum_{z=a_2}^n \binom{20}{z} 0.5^z (1 - 0.5)^{20-z} \leq \alpha/2.$$

- Wir erhalten die kritischen Werte
 - $a_1 = 5 \rightarrow P_{H_0}(Z \leq 5) = 0.02 \leq 0.025$
 - $a_2 = 14 \rightarrow P_{H_0}(Z \geq 14) = 0.02 \leq 0.025$
- Der Ablehnbereich ist also $A = \{0, 1, \dots, 5\} \cup \{14, \dots, 19, 20\}$.
- Da $z_{obs} = 15$ im Ablehnbereich liegt, kann H_0 verworfen werden und H_1 ist statistisch bewiesen.

2. p-Wert

- Wir haben $z_{obs} = 15$ Personen mit Antikörperreaktion in einer Stichprobe der Größe $n = 20$ beobachtet.
- Noch stärker als z_{obs} sprechen die Werte $\{16, 17, \dots, 20\}$ gegen H_0
- Unter H_0 gilt $Z \sim \text{Bi}(n, 0.5)$.
- Der p-Wert ergibt sich damit als

$$P_{H_0}(Z \geq z_{obs}) = \sum_{z=15}^{20} \binom{20}{z} 0.5^z (1 - 0.5)^{20-z} = 3.8 \times 10^{-6}$$

- Da $P_{H_0}(Z \geq 15) \leq \alpha/2 = 0.025$, kann H_0 verworfen werden.
- Beachte: Da wir einen zweiseitigen Test verwenden, wird auch für den p-Wert das Signifikanzniveau halbiert (analog zur Aufteilung zur Bestimmung des Ablehnbereichs).
- In der Praxis werden die berichteten p-Werte angepasst, so dass keine Anpassung des Signifikanzniveaus notwendig ist.

3. Konfidenzintervall

- Das (asymptotische) Konfidenzintervall für die Erfolgswahrscheinlichkeit der Binomialverteilung ist gegeben durch

$$\hat{\pi} \pm z_{1-\alpha/2} \cdot \sqrt{\frac{\hat{\pi} (1 - \hat{\pi})}{n}}$$

mit dem Quantil der Standardnormalverteilung $z_{1-\alpha/2} = z_{0.975} = 1.96$

- Basierend auf $z_{obs} = 15$ und $n = 20$ erhalten wir $\hat{\pi} = 0.75$
- Das Konfidenzintervall ist also gegeben durch:

$$\left[0.75 - 1.96 \cdot \sqrt{\frac{0.75 (1 - 0.75)}{20}}; 0.75 + 1.96 \cdot \sqrt{\frac{0.75 (1 - 0.75)}{20}} \right] \\ = [0.56; 0.94]$$

- Da $\pi = 0.5$ nicht im Konfidenzintervall liegt, kann H_0 verworfen werden.
- Insbesondere führen alle drei Verfahren zur gleichen Testentscheidung!

Take Home Messages

- Statistische Tests dienen der Überprüfung der Hypothesen über den unbekannten Parameter ϑ .
- Zwei mögliche Fehler:
 - Verwirf H_0 , obwohl H_0 wahr ist (α -Fehler).
 - Behalte H_0 bei, obwohl H_1 wahr ist (β -Fehler).
- Die Irrtumswahrscheinlichkeiten werden asymmetrisch behandelt:
 - Die Wahrscheinlichkeit für den α -Fehler wird durch das Signifikanzniveau begrenzt,
 - die Wahrscheinlichkeit für den β -Fehler kann dagegen sehr groß sein.

- Tests können entweder mit Hilfe von p-Werten oder einem geeignet konstruierten Ablehnbereich durchgeführt werden.
- Der p-Wert ist die Wahrscheinlichkeit, unter der Nullhypothese einen Wert der Teststatistik zu erhalten, der noch extremer gegen die Nullhypothese spricht als der beobachtete Wert.
- Zweiseitige Tests lassen sich auch mit Hilfe eines Konfidenzintervalls durchführen.