

# Spezielle Testprobleme

Dr. Alexander Silbersdorff

Leiter der Arbeitsgruppe Learning Analytics und Data Literacy

Sommersemester 2026



# Voraussetzungen

- Kontingenztafel ( $\Rightarrow$  SDS1-V03)
- Wahrscheinlichkeitsrechnung ( $\Rightarrow$  SDS1-V05, SDS1-V06 und SDS1-V07)
- Parametrische Schätzansätze ( $\Rightarrow$  SDS1-V08)
- Konfidenzintervalle ( $\Rightarrow$  SDS1-V10)
- Prinzipien statistischer Tests ( $\Rightarrow$  SDS1-V11)

# Lernziele

- Welche Arten von statistischen Tests gibt es?
- Wie werden die Konzepte zu statistischen Tests in diesen speziellen Testproblemen verwendet?
- Wie werden die statistischen Tests in der Praxis angewendet?

# Tests bei Normalverteilung

- Tests für den Erwartungswert bei bekannter Varianz
- Daten  $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2)$ ,  $\sigma^2$  gegeben
- Hypothesen:

$$(a) \quad H_0 : \mu = \mu_0 \quad \text{vs.} \quad H_1 : \mu \neq \mu_0$$

$$(b) \quad H_0 : \mu \geq \mu_0 \quad \text{vs.} \quad H_1 : \mu < \mu_0$$

$$(c) \quad H_0 : \mu \leq \mu_0 \quad \text{vs.} \quad H_1 : \mu > \mu_0$$


- Teststatistik:

$$Z = \frac{\bar{X} - \mu_0}{\sigma / \sqrt{n}}$$


Beachte: Für  $\mu = \mu_0$  („unter der Nullhypothese“) gilt  $Z \sim N(0, 1)$

- Ablehnbereiche:


(a)  $A = (-\infty, -z_{1-\frac{\alpha}{2}}) \cup (z_{1-\frac{\alpha}{2}}, \infty)$



(b)  $A = (-\infty, -z_{1-\alpha})$



$$(c) A = (z_{1-\alpha}, \infty)$$



# Beispiel: Bleistiftlänge

- Es werden Bleistifte produziert, deren Länge 17 cm betragen soll.
- Testproblem:

$$H_0 : \mu_0 = 17 \text{ vs. } H_1 : \mu_0 \neq 17 \quad \text{mit } X \sim N(\mu, \sigma^2 = 2.25)$$

- Es werden fünf Bleistifte gemessen: 19.2, 17.4, 18.5, 16.5, 18.9.  
Daraus ergibt sich  $\bar{x} = 18.1$ .
- Als Signifikanzniveau wählen wir  $\alpha = 0.01$ .

## 1. Teststatistik und Ablehnbereich

- Als Teststatistik erhält man:

$$z = \frac{\bar{x} - \mu_0}{\sigma} \sqrt{n} = \frac{18.1 - 17}{1.5} \sqrt{5} = 1.64.$$

- Für  $\alpha = 0.01$  gilt für den kritischen Wert  $z_{1-\frac{\alpha}{2}} = 2.579$ .
- Da  $|1.64| < 2.579$ , wird  $H_0$  nicht verworfen.

## 2. p-Wert

- Der p-Wert für einen zweiseitigen Test ergibt sich aus

$$p = 2 \cdot P(Z \geq |z_{obs}|) = 2 \cdot P(Z \geq |1.64|) = 0.1$$

- Da  $p = 0.10 > 0.01$ , wird  $H_0$  nicht verworfen.

### 3. Konfidenzintervall

- Das 99%-Konfidenzintervall für  $\mu$  ist gegeben durch

$$\left[ \bar{x} - z_{1-\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}, \bar{x} + z_{1-\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} \right]$$

- Mit  $\bar{x} = 18.1$ ,  $z_{1-\alpha/2} = 2.579$ ,  $\sigma = 1.5$ ,  $n = 5$  ergibt sich:

$$\left[ 18.1 - 2.579 \cdot \frac{1.5}{\sqrt{5}}; 18.1 + 2.579 \cdot \frac{1.5}{\sqrt{5}} \right] = [16.37; 19.83]$$

- Da  $\mu_0 = 17$  innerhalb des Konfidenzintervalls liegt, kann  $H_0$  nicht verworfen werden.

# Tests mit unbekannter Varianz

- Daten  $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2)$ ,  $\sigma^2$  unbekannt
- Ersetze  $\sigma^2$  (bzw.  $\sigma$ ) durch den unverzerrten Schätzer

$$S_*^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

- Teststatistik:

$$T = \frac{\bar{X} - \mu_0}{S_*} \sqrt{n}$$

Für  $\mu = \mu_0$  gilt  $T \sim t(n-1)$ .

- Ablehnbereiche werden wie zuvor berechnet, aber mit Quantilen der t-Verteilung statt der Standardnormalverteilung.

## Beispiel: Bleistiftlänge

- Es werden Bleistifte produziert, deren Länge 17 cm betragen soll.
- Das Testproblem bleibt gleich:

$$H_0 : \mu_0 = 17 \text{ vs. } H_1 : \mu_0 \neq 17 \quad \text{mit } X \sim N(\mu, \sigma^2)$$

- Mit  $\bar{x} = 18.1$  wird die Stichprobenvarianz  $s_*^2 = 1.265$  berechnet.
- Teststatistik:

$$t = \frac{\bar{x} - \mu_0}{s_*} \sqrt{n} = \frac{18.117}{\sqrt{1.265}} \sqrt{5} = 2.186$$

- Für  $\alpha = 0.01$  gilt für den kritischen Wert:  
 $t_{1-\frac{\alpha}{2}}(n-1) = t_{0.995}(4) = 4.604.$
- Da  $|2.186| < 4.604$ , wird  $H_0$  beibehalten.

# Tests für die Varianz

- Daten  $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2)$ ,  $\mu$  (und  $\sigma^2$ ) unbekannt
- Hypothesen:

$$(a) \quad H_0 : \sigma^2 = \sigma_0^2 \quad \text{vs.} \quad H_1 : \sigma^2 \neq \sigma_0^2$$

$$(b) \quad H_0 : \sigma^2 \geq \sigma_0^2 \quad \text{vs.} \quad H_1 : \sigma^2 < \sigma_0^2$$

$$(c) \quad H_0 : \sigma^2 \leq \sigma_0^2 \quad \text{vs.} \quad H_1 : \sigma^2 > \sigma_0^2$$

- Teststatistik:

$$Z = \frac{(n-1)S_*^2}{\sigma_0^2} \quad \text{mit} \quad S_*^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

- Für  $\sigma^2 = \sigma_0^2$  gilt  $Z \sim \chi^2(n-1)$

- Ablehnbereiche:

$$(a) \quad A = [0, \chi_{\frac{\alpha}{2}}^2(n-1)) \cup (\chi_{1-\frac{\alpha}{2}}^2(n-1), \infty)$$

$$(b) \quad A = [0, \chi_{\alpha}^2(n-1))$$

$$(c) \quad A = (\chi_{1-\alpha}^2(n-1), \infty)$$

# Vorzeichen-Test

- Ziel: Durchführung eines statistischen Tests für den Median ohne Annahme über die Verteilung.
- Daten:  $X_1, \dots, X_n$  iid mit stetiger Verteilungsfunktion
- Hypothesen:

|     |                                         |     |                                         |
|-----|-----------------------------------------|-----|-----------------------------------------|
| (a) | $H_0 : x_{\text{med}} = \vartheta_0$    | vs. | $H_1 : x_{\text{med}} \neq \vartheta_0$ |
| (b) | $H_0 : x_{\text{med}} \geq \vartheta_0$ | vs. | $H_1 : x_{\text{med}} < \vartheta_0$    |
| (c) | $H_0 : x_{\text{med}} \leq \vartheta_0$ | vs. | $H_1 : x_{\text{med}} > \vartheta_0$    |

- Konstruktion der Teststatistik: Ist  $\vartheta_0$  der wahre Median, so erwarten wir etwa gleich viele Beobachtungen  $\geq \vartheta_0$  und  $\leq \vartheta_0$ .  
 $\Rightarrow$  Betrachte  $Z = \text{Anzahl der Beobachtungen} \leq \vartheta_0$
- Für  $x_{\text{med}} = \vartheta_0$  gilt  $Z \sim \text{Bi}(n, 0.5)$ ; entsprechend ist der Vorzeichentest ein Binomialtest mit  $\pi = 0.5$

# Beispiel: Genesungsdauer

- In einer klinischen Studie wird die Zeit bis zur Genesung (in Wochen) von 10 Probanden erhoben:

49, 58, 75, 110, 112, 132, 151, 276, 281, 362

- Es soll nun festgestellt werden, ob der Median der Genesungsdauer größer oder kleiner als  $\vartheta_0 = 200$  Wochen ist.
- Testproblem:

$$H_0 : x_{\text{med}} = 200 \text{ vs. } H_1 : x_{\text{med}} \neq 200$$

- Teststatistik:  $Z = \text{Anzahl der Beobachtungen} \leq 200 = 7$

- Für  $Z \sim \text{Bi}(10, 0.5)$  erhält man die Wahrscheinlichkeitsverteilung bzw. die Verteilungsfunktion  $P(Z \leq z)$  durch

| $z$           | 0     | 1      | 2      | 3      | 4      | 5      |
|---------------|-------|--------|--------|--------|--------|--------|
| $P(Z = z)$    | 0.001 | 0.0098 | 0.0439 | 0.1172 | 0.2051 | 0.2461 |
| $P(Z \leq z)$ | 0.001 | 0.0107 | 0.0547 | 0.1719 | 0.377  | 0.623  |

| $z$           | 6      | 7      | 8      | 9      | 10    |
|---------------|--------|--------|--------|--------|-------|
| $P(Z = z)$    | 0.2051 | 0.1172 | 0.0439 | 0.0098 | 0.001 |
| $P(Z \leq z)$ | 0.8281 | 0.9453 | 0.9893 | 0.999  | 1     |

- Für den p-Wert gilt:

$$p = P_{H_0}(\{X \leq 3\} \cup \{X \geq 7\}) \approx 0.3439 > 0.05$$

- Bei einem Signifikanzniveau von  $\alpha = 0.05$  ergibt sich ein p-Wert, der größer ist als  $\alpha$ , damit kann  $H_0$  nicht verworfen werden.

# $\chi^2$ -Unabhängigkeit

- Ziel: Teste die stochastische Unabhängigkeit zweier kategorialer Merkmale.
- Daten:  $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$  iid gemäß einer bivariaten, diskreten Verteilung.
- Die Daten lassen sich in einer Kontingenztafel darstellen:

|   |          | Y               |          |                 |                |
|---|----------|-----------------|----------|-----------------|----------------|
|   |          | $b_1$           | $\dots$  | $b_K$           |                |
| X | $a_1$    | $h_{11}$        | $\dots$  | $h_{1K}$        | $h_{1\bullet}$ |
|   | $\vdots$ | $\vdots$        | $\ddots$ | $\vdots$        | $\vdots$       |
|   | $a_J$    | $h_{J1}$        | $\dots$  | $h_{JK}$        | $h_{J\bullet}$ |
|   |          | $h_{\bullet 1}$ | $\dots$  | $h_{\bullet K}$ | $n$            |

- Hypothese:

$H_0$  :  $X$  und  $Y$  sind stochastisch unabhängig vs.

$H_1$  :  $X$  und  $Y$  sind nicht stochastisch unabhängig.

- Konstruktion der Teststatistik: Unter  $H_0$  gilt:

$$\pi_{jk} = P(X = a_j, Y = b_k) = P(X = a_j)P(Y = b_k) = \pi_{j\bullet} \cdot \pi_{\bullet k}$$

- Als Schätzer verwenden wir die relativen Häufigkeiten

$$\hat{\pi}_{jk} = \frac{h_{jk}}{n}$$

$$\hat{\pi}_{j\bullet} = \frac{h_{j\bullet}}{n}$$

$$\hat{\pi}_{\bullet k} = \frac{h_{\bullet k}}{n}$$

- Daraus ergeben sich die erwarteten Häufigkeiten

$$\tilde{h}_{jk} = n \cdot \hat{\pi}_{j\bullet} \cdot \hat{\pi}_{\bullet k},$$

die wir mit den beobachteten Häufigkeiten vergleichen können:

$$Z = \sum_{j=1}^J \sum_{k=1}^K \frac{(h_{jk} - \tilde{h}_{jk})^2}{\tilde{h}_{jk}}.$$

- Unter  $H_0$  gilt dann approximativ (wenn keine der erwarteten Häufigkeiten  $\tilde{h}_{jk}$  zu klein ist) mit  $\text{df} = (J - 1)(K - 1)$

$$Z \stackrel{a}{\sim} \chi^2(\text{df}).$$

- Ablehnungsbereich:

$$A = (\chi_{1-\alpha}^2(\text{df}), \infty)$$

# Beispiel: Sonntagsfrage

- Besteht ein Zusammenhang zwischen Geschlecht und Parteipräferenz?

|           | CDU/CSU | SPD | FDP | Grüne | Die Linke | AfD | Rest |      |
|-----------|---------|-----|-----|-------|-----------|-----|------|------|
| Männer    | 140     | 80  | 21  | 57    | 43        | 101 | 47   | 489  |
| Frauen    | 144     | 91  | 19  | 64    | 53        | 85  | 55   | 511  |
| Insgesamt | 284     | 171 | 40  | 121   | 96        | 186 | 102  | 1000 |

- Erwartete Häufigkeiten

|        | CDU/CSU | SPD   | FDP   | Grüne | Die Linke | AfD   | Rest  |
|--------|---------|-------|-------|-------|-----------|-------|-------|
| Männer | 138.89  | 83.62 | 19.56 | 59.17 | 46.94     | 90.95 | 49.88 |
| Frauen | 145.12  | 87.38 | 20.44 | 61.83 | 49.06     | 95.05 | 52.12 |

- Hypothese:  $H_0 : P(X = a_j, Y = b_k) = P(X = a_j)P(Y = b_k), j = 1, 2$  und  $k = 1, \dots, 7$ .
- Kritischer Wert für  $\alpha = 0.05$  und  $df = (J - 1)(K - 1) = 6$ :

$$\chi^2_{0.95}(6) = 12.59$$

- Teststatistik:

$$Z = 3.832$$

- $H_0$  kann nicht verworfen werden, da  $3.832 < 12.59$ .
- Es kann nicht auf einen Zusammenhang zwischen Geschlecht und Parteipräferenz geschlossen werden.

# $\chi^2$ -Anpassungstest

- Ziel: Überprüfe, ob gegebene Daten aus einer vorgegebenen Verteilung stammen. Wir betrachten zunächst eine diskrete Verteilung.
- Daten:  $X_1, \dots, X_n$  iid diskret mit möglichen Werten  $a_1, \dots, a_J$
- Hypothesen:

$H_0 : P(X = a_j) = \pi_j$  für  $j = 1, \dots, J$  mit vorgegebenen Wahrscheinlichkeiten  $\pi_j$  vs.

$H_1 : P(X = a_j) \neq \pi_j$  für mindestens ein  $j$

- Konstruktion der Teststatistik: Unter  $H_0$  gilt für die Häufigkeit  $h_j$  der Merkmalsausprägung  $a_j$

$$h_j \sim \text{Bi}(n, \pi_j) \text{ mit } \pi_j = P(X = a_j).$$

- Entsprechend gilt für die (unter  $H_0$ ) erwarteten Häufigkeiten:

$$\tilde{h}_j = n\pi_j$$

- Verwende, ähnlich wie im  $\chi^2$ -Unabhängigkeitstest, die Teststatistik

$$Z = \sum_{j=1}^J \frac{(h_j - n\pi_j)^2}{n\pi_j}.$$

- Unter  $H_0$  gilt dann approximativ (wenn keine der erwarteten Häufigkeiten zu klein ist)

$$Z \stackrel{a}{\sim} \chi^2(J-1).$$

- Ablehnbereich:

$$A = (\chi^2_{1-\alpha}(J-1), \infty)$$

- Für stetige Zufallsvariablen  $X_1, \dots, X_n$  iid mit Dichte  $f$  kann der  $\chi^2$ -Anpassungstest basierend auf diskretisierten Daten durchgeführt werden.
- Teile den Wertebereich in Intervalle

$$c_0 < c_1 < \dots < c_J$$

ein und betrachte

$$H_0 : P(c_{j-1} \leq X \leq c_j) = \pi_j$$

für  $j = 1, \dots, J$

- Enthält die Dichte  $f$  unbekannte Parameter, so werden diese durch Schätzer ersetzt und die Freiheitsgrade der  $\chi^2$ -Verteilung um die Anzahl geschätzter Parameter verringert.

# Beispiel: Absolvent\*innenstudie

- Gibt es Unterschiede in der Wahrscheinlichkeit für das Auftreten der verschiedenen Arten von Masterarbeiten?
- Die möglichen Arten sind:
  - Kategorie 1: „empirische Sekundäranalyse“,
  - Kategorie 2: „empirisch-qualitativ“ und
  - Kategorie 3: „theoretische Arbeit“.
- Hypothesen:

$$H_0 : \pi_1 = \pi_2 = \pi_3 = 1/3 \quad \text{vs.} \quad H_1 : \pi_j \neq 1/3 \quad \text{für mindestens ein } j$$

- Daten:

| $h_1$ | $h_2$ | $h_3$ | $n$ |
|-------|-------|-------|-----|
| 4     | 12    | 18    | 34  |

- Unter der Nullhypothese betragen die erwarteten Häufigkeiten

$$\begin{array}{ccc|c} n\pi_1 & n\pi_2 & n\pi_3 & n \\ \hline 11.33 & 11.33 & 11.33 & 34 \end{array}$$

- kritischer Wert für  $\alpha = 0.05$ :

$$\chi^2_{1-\alpha}(J-1) = \chi^2_{0.95}(2) = 5.99$$

- Teststatistik:

$$Z = \frac{(4 - 11.33)^2}{11.33} + \frac{(12 - 11.33)^2}{11.33} + \frac{(18 - 11.33)^2}{11.33} = 8.706$$

- $H_0$  kann verworfen werden, da  $8.706 > 5.99$ , es lassen sich also unterschiedliche Wahrscheinlichkeiten nachweisen.

# Allgemeines zu Tests

- Wahl von  $H_0$ : Statistische Signifikanztests sind asymmetrisch aufgebaut:
  - $H_1$  kann (statistisch) bewiesen werden  $\Rightarrow$  starke Aussage
  - $H_0$  kann nur beibehalten werden  $\Rightarrow$  schwache Aussage
- Zur praktischen Durchführung werden in der Regel p-Werte oder Konfidenzintervalle verwendet.
- Ein Test heißt konsistent, wenn asymptotisch ( $n \rightarrow \infty$ ) beide Fehlerwahrscheinlichkeiten gegen 0 gehen (der Test also mit Wahrscheinlichkeit 1 die richtige Entscheidung trifft).

# Take Home Messages

- Zentrale Schritte zur Konstruktion eines statistischen Tests:
  - Formulierung der Hypothesen,
  - Bestimmung einer geeigneten Teststatistik sowie der Verteilung der Teststatistik unter der Nullhypothese,
  - Festlegung des Ablehnbereichs entsprechend dieser Verteilung des Signifikanzniveaus.
- Tests lassen sich nicht nur für Parameter einer spezifischen Verteilung der Daten, sondern für verschiedene Arten von Hypothesen formulieren.
- Nur die Alternative kann statistisch bewiesen werden.