

Zusammenfassung und Ausblick

Dr. Alexander Silbersdorff

Leiter der Arbeitsgruppe Learning Analytics und Data Literacy

Sommersemester 2026



Voraussetzungen

- Statistik und Data Science I ($\Rightarrow$ SDS1-V01 bis SDS1-V12)

Lernziele

- Welche zentralen Themen wurden in der Vorlesung Statistik und Data Science I behandelt?
- Welche weiterführenden Themen gibt es?
- In welchen weiterführenden Lehrveranstaltungen werden diese Themen behandelt?

Was haben wir gelernt?

- Deskriptive Statistik beschreibt die beobachteten Daten mit Hilfe von Grafiken und Kennziffern.
- Die Wahrscheinlichkeitsrechnung erlaubt es, zufällige Phänomene mathematisch zu beschreiben und entsprechende Gesetzmäßigkeiten zu formulieren.
- Die induktive Statistik hat das Ziel, von einer Stichprobe auf die dahinterliegende Grundgesamtheit zu schließen.

Deskriptive Statistik

- Häufigkeitsverteilungen
- Maßzahlen für Lage und Variabilität
- Gemeinsame Verteilung zweier Merkmale
- χ^2 -Koeffizient und Korrelationskoeffizient als Zusammenhangsmaße

Wahrscheinlichkeitsrechnung

- Beschreibung von Zufallsexperimenten, Ergebnissen und Ereignissen mit Hilfe der Mengenlehre
- Axiome von Kolmogorov zur mathematischen Charakterisierung von Wahrscheinlichkeiten
- Bedingte Wahrscheinlichkeiten und stochastische Unabhängigkeit
- Satz der totalen Wahrscheinlichkeit und Satz von Bayes
- Zufallsvariablen und ihre Eigenschaften
- Diskrete und stetige Verteilungsmodelle

Induktive Statistik

- Drei zentrale Aufgaben der induktiven Statistik:
 - Punktschätzer,
 - Intervallschätzer (Konfidenzintervalle) und
 - Statistische Hypothesentests.


Wie geht es in der Statistik weiter?

- Statistische Modellierung: Beschreibung von Zusammenhängen zwischen Variablen mit Hilfe von Modellen
- Prädiktion und Modellwahl: Vorhersage neuer Beobachtungen und Auswahl eines passenden Modells
- Bayes-Inferenz: Ein alternativer Ansatz der induktiven Statistik
- Und natürlich gibt es noch viel mehr...

Beispiel: Körpergröße

- Fragestellung: Wie hängen Körpergröße der Eltern und Körpergröße der Kinder zusammen?
- Untersuchung durch Francis Galton (1822 - 1911)
- Datensatz:
 - $n = 928$
 - Zu erklärende Variable: Körpergröße des Kindes in Inch
 - Erklärende Variable: Mittlere Körpergröße der Eltern in Inch
 - Um Männer und Frauen vergleichbar zu machen, multiplizierte Galton die Körpergröße der Frauen mit 1.08.

- Streudiagramm der Daten



Prinzipien Statistischer Modellierung

- Ziel: Vereinfachende Beschreibung (möglicherweise komplexer) Zusammenhänge.
- Gleichzeitige Berücksichtigung der Unsicherheit aufgrund unvollständiger Information (z.B aufgrund der Ziehung einer Stichprobe).
- Schätzung des Modells basierend auf Daten bzw. Anpassung des Modells an die Daten.
- Prognose zukünftiger Beobachtungen aus einem geschätzten Modell.

Statistische Formulierung

- Galton wählte die folgende Form eines statistischen Modells:

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad i = 1, \dots, 928$$

- Das heißt ein lineares Modell mit
 - Zielvariable y_i (Größe des Kindes),
 - Einflussgröße x_i (mittlere Größe der Eltern),
 - Modellabweichung ε_i (Fehler).
- In der induktiven Statistik wird ε_i (und damit auch y_i) als zufällige Größe aufgefasst.
⇒ Stochastische Modellierung

Parametrische Charakterisierung


- Das lineare Modell ist parametrisch und wird charakterisiert durch
 - den Achsenabschnitt β_0 und
 - die Steigung β_1 .
- Im Beispiel ergeben sich die Punktschätzungen:

```
lm_gal <- lm(heightchild ~ midheightp, data = galton)
lm_gal$coef
```

```
## (Intercept)  midheightp
## 23.9415338    0.6462905
```

- $\hat{\beta}_0 = 23.942$
- $\hat{\beta}_1 = 0.646$

Regressionsgerade aus R



Interpretation

- Die geschätzte Steigung $\hat{\beta}_1$ gibt an, um wieviele Einheiten sich die erwartete Körpergröße des Kindes unterscheidet, wenn sich die durchschnittliche Größe der Eltern um eine Einheit unterscheidet.
- $\hat{\beta}_1 < 1$ bedeutet, dass Kinder großer Eltern tendenziell kleiner sind als ihre Eltern während Kinder kleiner Eltern tendenziell größer sind als ihre Eltern.
- Dieses Phänomen bezeichnete Galton als “Regression (Rückkehr) zum Mittelwert” (“Regression towards mediocrity in hereditary stature”).

Allgemeine Ausgangssituation in der Regressionsanalyse

- Y : primär interessierende Variable (Zielgröße, abhängige Variable).
- X : Variable, die Y vorhersagt (erklärende Variable, Kovariable, unabhängige Variable).
- Der Zusammenhang zwischen X und Y ist durch zufällige Störungen überlagert.
- Schätze aus den Beobachtungen (x_i, y_i) , $i = 1, \dots, n$ den Zusammenhang zwischen X und Y .

Lineare Einfachregression

- Allgemeine Annahmen:

$$y_i = f(x_i) + \varepsilon_i$$

Zielgröße = durchschnittlicher Zusammenhang + Störgröße

- Lineare Einfachregression:

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

d.h.

$$f(x_i) = \beta_0 + \beta_1 x_i$$

Gaußsche Methode der kleinsten Fehlerquadrate

- Minimiere die quadrierten Abweichungen $y_i - \beta_0 - \beta_1 x_i$, d.h

$$\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \rightarrow \min_{\beta_0, \beta_1} .$$

- Lösung des Minimierungsproblems:
 1. Ableiten der Quadratsumme nach β_0 und β_1 .
 2. Nullsetzen der resultierenden Ausdrücke.
 3. Auflösen nach β_0 und β_1 .
 4. Überprüfen, dass es sich tatsächlich um ein Minimum handelt.
- Man erhält eine Lösung in geschlossener Form.

KQ-Schätzer

- Die KQ-Schätzer $\hat{\beta}_0$ und $\hat{\beta}_1$ sind gegeben durch:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

- Die geschätzte Regressionsgerade ist dann gegeben als

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x.$$

Residuen

- Die Abweichungen

$$\hat{\varepsilon}_i = y_i - \hat{y}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$$

heißen Residuen.

- Die Residuen $\hat{\varepsilon}_i$ stimmen nicht mit den theoretischen Störgrößen ε_i überein.
- Die Residuen sollen möglichst regellos um Null streuen.

Modellannahmen

- Die Störgrößen sind unabhängig und identisch verteilt mit $E(\varepsilon_i) = 0$ und $\text{Var}(\varepsilon_i) = \sigma^2$ (homoskedastische Varianz).
- Zur Bestimmung von Test- und Konfidenzintervallen nehmen wir zusätzlich an, dass die Störgrößen ε_i normalverteilt sind, d.h. $\varepsilon_i \sim N(0, \sigma^2)$.

$$E(Y_i) = \beta_0 + \beta_1 x_i,$$

$$\text{Var}(Y_i) = \sigma^2,$$

$$Y_i \stackrel{iid}{\sim} N(\beta_0 + \beta_1 x_i, \sigma^2).$$

Induktive Statistik im linearen Modell

- Neben der Bestimmung der Punktschätzer für die Modellparameter sollen im linearen Modell auch
 - Konfidenzintervalle und
 - statistische Tests (insbesondere für die Hypothese $H_0 : \beta_1 = 0$) bestimmt werden.
- Die drei grundsätzlichen Themen der statistischen Inferenz sind also auch hier von zentraler Bedeutung!

Multiple Regressionsmodelle

- Bisher haben wir nur Modelle mit einer erklärenden Variable X betrachtet.
- Im Folgenden: Betrachte p Einflussgrößen $X_1, \dots, X_p$ mit Beobachtungen $x_{i1}, \dots, x_{ip}$, $i = 1, \dots, n$.
- Allgemeine Modellannahmen:

$$y_i = f(x_{i1}, \dots, x_{ip}) + \varepsilon_i$$

Zielgröße = durchschnittlicher Zusammenhang + Störgröße

Modellformulierung

- Lineares Regressionsmodell:

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} + \varepsilon_i$$

d.h.

$$f(x_{i1}, \dots, x_{ip}) = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip}$$

Interpretation der Regressionskoeffizienten

- β_j positiv: Wenn die erklärende Variable X_j sich für zwei Beobachtungen um eine Einheit unterscheidet, so erwarten wir, dass sich die abhängige Variable Y (ceteris paribus) um β_j Einheiten **erhöht**.
- β_j negativ: Wenn die erklärende Variable X_j sich für zwei Beobachtungen um eine Einheit unterscheidet, so erwarten wir, dass sich die abhängige Variable Y (ceteris paribus) um β_j Einheiten **verringert**.

Methode der kleinsten Quadrate

- Schätze die unbekannten Regressionskoeffizienten so, dass die Summe der quadrierten Differenzen zwischen y_i und $\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip}$ möglichst klein wird.
- Minimiere also

$$KQ(\beta_0, \beta_1, \dots, \beta_p) := \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_{i1} - \cdots - \beta_p x_{ip})^2$$

bezüglich $\beta_0, \beta_1, \dots, \beta_p$.

Mietspiegel für München

- Modellgleichung

$$\text{miete}_i = \beta_0 + \beta_1 \cdot \text{flaeche}_i + \beta_2 \cdot \text{bjahr}_i + \varepsilon_i$$

- Geschätzte Regressionsgleichung

$$\begin{aligned}\widehat{\text{miete}} &= \hat{\beta}_0 + \hat{\beta}_1 \cdot \text{flaeche} + \hat{\beta}_2 \cdot \text{bjahr} \\ &= -5030.92 + 5.24 \cdot \text{flaeche} + 2.62 \cdot \text{bjahr}\end{aligned}$$

Interpretation

- Wohnfläche: $\hat{\beta}_1 = 5.24$ ist positiv, d.h mit steigender Wohnfläche steigt auch die durchschnittliche Nettomiete. Wenn sich die Wohnfläche um einen Quadratmeter unterscheidet, dann erwarten wir einen Unterschied von 5.24 Euro in der Nettomiete.
- Baujahr: $\hat{\beta}_2 = 2.62$ ist positiv, d.h neuere Wohnungen sind im Durchschnitt teurer als ältere Wohnungen. Für einen Unterschied von 1 Jahr erwarten wir einen Unterschied von 2.62 Euro in der Nettomiete.
- Achsenabschnitt: $\hat{\beta}_0 = -5030.92$. Dieser Wert gibt an, was eine Wohnung kostet, wenn beide Kovariablen 0 sind. Also eine Wohnung aus dem Jahr 0 mit 0 Quadratmetern. In diesem Fall hat der Achsenabschnitt somit inhaltlich keine Bedeutung.

Prognose

- Geschätzte Regressionsgleichung

$$\begin{aligned}\widehat{\text{miete}} &= \hat{\beta}_0 + \hat{\beta}_1 \cdot \text{flaeche} + \hat{\beta}_2 \cdot \text{bjahr} \\ &= -5030.92 + 5.24 \cdot \text{flaeche} + 2.62 \cdot \text{bjahr}\end{aligned}$$

- Prognose: Die Prognose für eine im Jahr 1998 erbaute Wohnung mit 60 qm Wohnfläche ist

$$\widehat{\text{miete}} = -5030.92 + 5.24 \cdot 60 + 2.62 \cdot 1998 = 518.24$$

Weiterführende Ansätze zur Modellierung

- Generalisierte lineare Modelle zur Modellierung von nicht-normalverteilten Zielgrößen (z.B. binären Zielgrößen oder Zähldaten)
- Additive Modelle zur Modellierung nichtlinearer Zusammenhänge zwischen Kovariablen und Zielgröße
- Zeitreihenanalyse und Räumliche Statistik zur Berücksichtigung von zeitlichen und räumlichen Korrelationen in den Daten
- Multivariate Statistik zur Beschreibung und Analyse der Variation mehrerer interessierender Größen, z.B. mit dem Ziel der Identifikation von Clustern

Prädiktion und Modellwahl

- Zwei neue Aufgaben der Statistik:
 - Vorhersage neuer Beobachtungen (Prädiktion)
 - Auswahl eines passenden Modells aus einer Liste möglicher Modelle

Prädiktion im linearen Modell

- Im linearen Modell können die geschätzten Regressionskoeffizienten genutzt werden, um Vorhersagen für die erwartete Zielgröße bei neuen Kovariablenwerten x_0 zu machen:

$$\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0.$$

- So ließ sich beispielsweise die erwartete Körpergröße eines Kindes bei gegebener Körpergröße der Eltern vorhersagen.

- Neben der Bestimmung von Punktprognosen sollen dann in der Regel auch die Prognoseunsicherheit angegeben oder Prognoseintervalle (in Analogie zu Konfidenzintervallen) konstruiert werden.
- Zur Bewertung der Prognosegüte können verschiedene Maßzahlen, wie etwa der mittlere quadratische Prognosefehler eingesetzt werden.
- Dazu müssen die Daten in einen Trainings- und einen Testdatensatz eingeteilt werden, so dass die Parameter aus den Trainingsdaten geschätzt und anschließend die Prognosegüte für die Testdaten berechnet wird.

Modellwahl im linearen Modell

- Zentrale Fragen der Modellwahl im linearen Modell betreffen beispielsweise
 - die Auswahl relevanter Kovariablen oder
 - die Wahl der genauen Modellierungsform (z.B. linear vs. nichtlinear).
- Zum Vergleich verschiedener Modelle wird dann häufig die Prognosegüte herangezogen, d.h. wir bevorzugen das Modell, dass für neue Beobachtungen (die nicht zur Schätzung verwendet wurden) die besten Vorhersagen liefert.
- Auch hier ist es entscheidend, die Prognosegüte für Testdaten auszuwerten!

Frequentistische Inferenz

- Grundprinzip der statistischen Inferenz (bisher): Wie verhält sich der Ansatz bei wiederholter Stichprobenziehung?
 - Bias eines Schätzers: Bei wiederholter Stichprobenziehung stimmt der Schätzer im Durchschnitt mit dem wahren Wert überein (unterschätzt/überschätzt).
 - Überdeckungswahrscheinlichkeit eines Konfidenzintervalls: Bei wiederholter Stichprobenziehung überdecken ca. 95% der Konfidenzintervalle den wahren Wert.
 - Fehlerwahrscheinlichkeit eines statistischen Tests: Bei wiederholter Stichprobenziehung werden wir in höchstens 5% der Fälle die Nullhypothese fälschlicherweise verwerfen.
- Wir sprechen daher auch vom frequentistischen Ansatz statistischer Inferenz.

- Zentrale Annahmen dabei:
 - Alle Informationen für die statistische Analyse kommen ausschließlich aus den beobachteten Daten.
 - Unsicherheit über den interessierenden Parameter darf nicht probabilistisch ausgedrückt werden, da der wahre Parameter nicht zufällig, sondern fest ist.
- Die Bayesianische Inferenz ist eine andere Schule der statistischen Inferenz, die auf anderen Annahmen beruht.

Bayesianische Inferenz

- Unsicherheit über den interessierenden Parameter kann mit Hilfe von Verteilungen ausgedrückt werden.
- Dies gilt sowohl vor Erhebung der Daten (a priori) als auch nach danach (a posteriori).
- Formaler:
 - Mit $f(\vartheta)$ bezeichnen wir die Dichte der Priori-Verteilung, die unsere Unsicherheit über den Parameter ϑ vor Erhebung der Daten ausdrückt.
 - Die Verteilung der Daten $X_1, \dots, X_n$ bei gegebenem Parameter ϑ bezeichnen wir als Beobachtungsmodell mit der Dichte / Wahrscheinlichkeitsfunktion $f(x_1, \dots, x_n | \vartheta)$.

- Der Satz von Bayes lässt sich dann auch auf Verteilungen anwenden und liefert die Unsicherheit über den Parameter ϑ nachdem die Daten beobachtet wurden:

$$\begin{aligned} f(\vartheta|x_1, \dots, x_n) &= \frac{f(x_1, \dots, x_n|\vartheta)f(\vartheta)}{\int f(x_1, \dots, x_n|\vartheta)f(\vartheta)d\vartheta} \\ &\propto f(x_1, \dots, x_n|\vartheta)f(\vartheta) \end{aligned}$$

- Die Posteriori-Verteilung kombiniert also Informationen über den interessierenden Parameter ϑ aus der Priori-Verteilung und aus den Daten.
- Die Posteriori lässt sich dann ähnlich wie die Likelihood behandeln, um Punktschätzer, Intervallschätzer, etc. abzuleiten und damit die grundlegenden Fragen der statistischen Inferenz zu bearbeiten.

- Dabei müssen zur Bestimmung der Posteriori-Verteilung in der Regel numerische Verfahren eingesetzt werden.
- Gleichzeitig eignen sich diese Verfahren sehr gut, um auch komplexe Modelle schätzen zu können, da die Modelle in kleinere Bestandteile zerlegt werden können.

Beispiel: Erfolgswahrscheinlichkeit

- Seien $X_1, \dots, X_n$ unabhängige und identisch verteilte Zufallsvariablen mit

$$X_i \sim \text{Be}(\pi),$$

wobei π die Erfolgswahrscheinlichkeit bezeichnet.

- Eine geeignete Priori für π ist die Beta-Verteilung mit Parametern $a > 0$ und $b > 0$, d.h. $\pi \sim \text{Beta}(a, b)$ mit Dichte

$$f(\pi) = \frac{1}{B(a, b)} \pi^{a-1} (1 - \pi)^{b-1}$$

wobei $B(a, b)$ die Beta-Funktion bezeichnet.

- Die Beta-Verteilung erlaubt es, unterschiedliche Formen von a priori Wissen auszudrücken. Insbesondere liefert die Wahl $a = b = 1$ die Gleichverteilung, welche das Fehlen spezifischer a priori Präferenzen beschreibt.
- Die Posteriori-Verteilung von π ergibt sich dann als

$$\pi \mid x_1, \dots, x_n \sim \text{Beta} \left(a + \sum_{i=1}^n x_i, b + n - \sum_{i=1}^n x_i \right).$$

- Die Posteriori ist damit wieder eine Beta-Verteilung mit aktualisierten Parametern.
- Sind Priori- und Posteriori-Verteilung vom gleichen Verteilungstyp, so nennt man Prior und Beobachtungsmodell **konjugiert**.

- Beobachtete Daten:

- $n = 20$
- Anzahl der Erfolge: $\sum_{i=1}^n x_i = 14$

- Für die Posteriori

$$\text{Beta} \left(a + \sum_{i=1}^n x_i, b + n - \sum_{i=1}^n x_i \right).$$

ergibt sich also

Priori	Posteriori
Beta(1, 1)	Beta(15, 7)
Beta(2, 5)	Beta(16, 11)
Beta(5, 2)	Beta(19, 8)

Priori: Beta(1,1)




Posteriori: Beta(15,7)




Priori: Beta(2,5)




Posteriori: Beta(16,11)



Priori: Beta(5,2)



Posteriori: Beta(19,8)



Weiterführende Lehrveranstaltungen

- Lineare Modelle [B.WIWI-QMW.0001]: derzeit im Sommersemester / ab Wintersemester 2026/27 im Wintersemester
- Einführung in die Ökonometrie [B.WIWI-VWL.0007]: jedes Semester
- Grundlagen Bayes und statistisches Lernen [B.WIWI-QMW.0012]: Wintersemester
- Praktikum Statistische Modellierung [B.WIWI-QMW.0008.Mp]: Sommersemester

Neue Module ab dem Wintersemester 2026/27

- Statistik und Data Science II
- Statistik und Data Science III
- Advanced Statistical Inference – Likelihood and Bayes
- Introduction to Statistical Programming

Studiengänge im Bereich Statistik

- Master Angewandte Statistik mit Fokus auf Quereinsteiger*innen
- Einführung eines Zwei-Fach-Bachelors Angewandte Statistik zum Wintersemester 2026/27

Take Home Messages

- Statistische Methoden sind eine wesentliche Sprache der empirischen Wissenschaften.
- Mit Hilfe der Statistik können Daten transparent, objektiv und verantwortungsvoll in Erkenntnisse und Wissen übersetzt werden.
- Dabei werden Werkzeuge der Mathematik und der Informatik eingesetzt und mit Wissen der Anwendungswissenschaften zusammengeführt.