

Konfidenzintervalle

- Hinweise -
- Kontrollergebnisse -

1 Konfidenzintervalle

1. KI für den Erwartungswert:

- bei bekannter Varianz:

$$\left[\bar{X} - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$$

- bei unbekannter Varianz (verzerrt):

$$\left[\bar{X} - t_{n-1, 1-\alpha/2} \frac{S}{\sqrt{n}}, \bar{X} + t_{n-1, 1-\alpha/2} \frac{S}{\sqrt{n}} \right]$$

alternativ mit $S_*^2 = \frac{n}{n-1} S^2$ (unverzerrt)

2. KI für Anteilswerte:

$$\left[\hat{\pi} - z_{1-\alpha/2} \sqrt{\frac{\hat{\pi}(1-\hat{\pi})}{n}}, \hat{\pi} + z_{1-\alpha/2} \sqrt{\frac{\hat{\pi}(1-\hat{\pi})}{n}} \right]$$

3. KI für die Varianz:

$$\left[\frac{nS^2}{\chi_{n-1, 1-\alpha/2}^2}, \frac{nS^2}{\chi_{n-1, \alpha/2}^2} \right] \quad (\text{verzerrt})$$

alternativ mit $S_*^2 = \frac{n}{n-1} S^2$ bzw. $nS^2 = (n-1)S_*^2$

$$\left[\frac{(n-1)S_*^2}{\chi_{n-1, 1-\alpha/2}^2}, \frac{(n-1)S_*^2}{\chi_{n-1, \alpha/2}^2} \right] \quad (\text{unverzerrt})$$

Aufgabe 1.

Gegeben sei der folgende R-Output:

```
1 > x_i <- round(rnorm(11, mu, sigma), 2)
2 > x_i
3 [1] 1.02 8.69 1.78 3.50 3.90 0.44 5.35 0.60 1.11 3.87 7.69
4 > sum(x_i)
5 [1] 37.95
6 > var(x_i)
7 [1] 8.07786
```

Berechnen Sie das 90% Konfidenzintervall für μ per Hand.

Kontrollergebnis 1.: $KI : [1.899; 5.001]$.

Lösungsweg:

1. Formel für das Konfidenzintervall für den Parameter μ bei unbekannter Varianz σ^2 :

$$KI : \left[\bar{X} - t_{n-1, 1-\frac{\alpha}{2}} \cdot \frac{S_*}{\sqrt{n}}; \bar{X} + t_{n-1, 1-\frac{\alpha}{2}} \cdot \frac{S_*}{\sqrt{n}} \right]$$

da σ^2 unbekannt ist, muss sie geschätzt werden, dafür wird der unverzernte Schätzer verwendet:

$$\hat{\sigma}^2 = S_*^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

2. Werte der Variablen ermitteln:

$$\bar{x} = \frac{37.95}{11} = 3.4500;$$

$$t_{11-1, 1-\frac{0.10}{2}} = t_{10, 0.95} \approx 1.8125; \quad \rightarrow \text{aus der Verteilungstabelle ablesen oder } R \text{ qt}(0.95, 10) \text{ benutzen.}$$

$$S_* = \sqrt{S_*^2} = \sqrt{8.0779} \approx 2.8422 \quad \rightarrow R \text{ gibt mit } \text{var}(\dots) \text{ den unverzerrten Schätzer an.}$$

$$\sqrt{n} = \sqrt{11} \approx 3.3166$$

3. Werte einsetzen:

$$KI : \left[3.4500 - 1.8125 \cdot \frac{2.8422}{3.3166}; 3.4500 + 1.8125 \cdot \frac{2.8422}{3.3166} \right] \approx [1.897; 5.003]$$

Häufige Fehlerquellen:

- Verwendung der falschen Formel für das Konfidenzintervall (bspw. für gegebene Varianz),
- Verwendung der Varianz anstelle der Standardabweichung.
- Verwendung des verzerrten Schätzers für die Varianz anstelle des unverzerrten Schätzers.
(Hinweis: $(n-1)S_*^2 = nS^2$)

Relevante Folien:

SDS1V10

Aufgabe 2.

Betrachten Sie den folgenden R-Code.

```
1 > ki.sim <- function(n,p1,p2){
2 >   c <- 0
3 >   for(i in 1:n){
4 >     s <- rnorm(100,p1,p2)
5 >     ki <- t.test(s)$conf.int
6 >     if(p1 > ki[1] && p1 < ki[2]) {
7 >       c <- c+1
8 >     }
9 >   }
10 >   res <- (c/n)*100
11 >   cat("KI ueberdeckt den wahren Parameter in",res,"Prozent der Faelle")
12 > }
```

- (a) Überlegen Sie, was bei dieser Funktion durchgeführt wird.
Hinweis: `t.test(s)$conf.int` gibt das 95%-Konfidenzintervall für den Mittelwert bei unbekannter Varianz aus
- (b) Es wird der Befehl `ki.sim(1000,3,2)` ausgeführt. Welche Ausgabe erwarten Sie?
- (c) Wie wird sich die Ausgabe verändern, wenn Sie für die Verteilung der Daten, aus der die Stichproben entnommen werden, eine deutlich höhere Varianz bzw. Standardabweichung angeben?
- (d) Kopieren Sie den R-Code der Funktion und führen Sie ihn in R aus, um die Funktion verwenden zu können. Führen Sie anschließend den Befehl aus Teil (b) aus, um Ihre Vermutung zu bestätigen. Testen Sie auch Ihre Antwort für Teil (c). Probieren Sie auch andere Funktionsargumente aus.

Kontrollergebnis 2.:

- (a) Es werden n zufällige Stichprobenziehungen im Umfang von 100 Beobachtungen aus einer mit den Parametern p_1 und p_2 normalverteilten Grundgesamtheit simuliert. Auf Grundlage jeder dieser Stichproben wird jeweils ein 95%-Konfidenzintervall für den Mittelwert bei unbekannter Varianz gebildet. Es werden also n Konfidenzintervalle für μ aufgestellt. Anschließend wird für jedes dieser Konfidenzintervalle geprüft, ob das Konfidenzintervall den wahren Parameter μ überdeckt. Wenn das der Fall ist, wird dies durch einen Counter vermerkt. Abschließend wird der Anteil der überdeckenden Konfidenzintervalle an der Gesamtanzahl der gebildeten Konfidenzintervalle berechnet. Die Prozentzahl wird in einem ausformulierten Satz ausgegeben.
- (b) Man erwartet, dass der Anteil der den wahren Parameter überdeckenden Konfidenzintervalle ungefähr dem gewählten Konfidenzniveau, also hier 95%, entspricht.
- (c) Die Ausgabe sollte weiterhin bei ca. 95% liegen. Die größere Varianz der Daten wird durch ein breiteres Konfidenzintervall ausgeglichen, sodass das geforderte Konfidenzniveau weiterhin erreicht wird.

Verweis Informationsquellen:

R-Skript

Aufgabe 3.

In der R-Sammeldatei ist der Teildatensatz `brenndauer` enthalten. Dieser enthält 417 Beobachtungen der Brenndauer von Glühbirnen. Gehen Sie davon aus, dass die Zufallsvariable $X = \text{„Brenndauer von Glühbirnen“}$ mit $X \sim N(1045.37, 36229.32)$ ist.

- (a) Ziehen Sie jeweils eine Zufallsstichprobe aus dem Datensatz `brenndauer` der Größe $n = 30$ und $n = 10$ und speichern Sie diese ab.
- (b) Wie lautet der ML-Schätzer für den Erwartungswert bei der Normalverteilung allgemein? Berechnen Sie den Schätzwert für beide Stichproben.
- (c) Bestimmen Sie mit Hilfe der Funktion `konfint()` die Konfidenzintervalle für den Erwartungswert bei unbekannter Varianz für Ihre Stichproben aus (a) auf den üblichen Konfidenzniveaus.
Hinweise zum `konfint()`-Befehl: Die Funktion befindet sich ebenfalls in der R-Sammeldatei. Sie können sich mit einem Klicken auf die Funktion in der Environment mit ihr vertraut machen. Sie ist nicht klausurrelevant. Das bedeutet, dass sie in der R-Klausur nicht zur Verfügung stehen wird! Die Funktion dient hier zur Veranschaulichung von Konfidenzintervallen.
Die Funktion hat die Syntax `konfint(Daten, niveau, plot = ...)`, wobei für das zweite Argument `niveau=c(0.90,0.95,0.99)` default ist und das Konfidenzniveau darstellt. `plot=FALSE` ist ebenfalls die default-Einstellung.
Die Funktion berechnet das Konfidenzintervall für das angegebene Niveau so, wie Sie es auch händisch tun würden. Das `plot`-Argument ist allerdings für die `brenndauer`-Daten optimiert.
- (d) Lassen Sie sich die Konfidenzintervalle aus (c) grafisch darstellen, indem Sie das Argument `plot=TRUE` in der Funktion ergänzen.
- (e) Diskutieren Sie, wann die Konfidenzintervalle länger oder kürzer werden.
- (f) Probieren Sie auch andere Konfidenzniveaus aus. Was passiert, wenn das Konfidenzniveau gegen 1 strebt?

Kontrollergebnis 3.:

- (a)

```
brenndauer10 <- sample(brenndauer,10)
brenndauer30 <- sample(brenndauer,30)
```
- (b) $\hat{\mu}_{ML} = \bar{x}$

```
mean(brenndauer10)
mean(brenndauer30)
```
- (c)

```
konfint(brenndauer10)
konfint(brenndauer30)
```
- (d)

```
konfint(brenndauer10, plot = TRUE)
konfint(brenndauer30, plot = TRUE)
```
- (e) 1) Je größer $1 - \alpha$, desto breiter das Konfidenzintervall.
2) Je größer n , desto schmaler das Konfidenzintervall.
3) Je größer σ , desto breiter das Konfidenzintervall.
- (f)

```
konfint(brenndauer30, niveau = 0.9999, plot = TRUE)
konfint(brenndauer30, niveau = 0.99999999, plot = TRUE)
konfint(brenndauer10, niveau = 0.9999, plot = TRUE)
konfint(brenndauer10, niveau = 0.99999999, plot = TRUE)
```

Das Konfidenzintervall wird immer breiter und strebt gegen unendlich.

Lösungsweg:

- (b) Da Sie zufällige Stichproben aus dem gesamten Datensatz `brenndauer` gezogen haben, sind die genauen numerischen Werte, die Sie als R-Output erhalten, nicht vergleichbar.
- (e) 1) Je sicherer Sie sich sein wollen, dass das Intervall den wahren Parameter überdeckt, desto größer muss dieses Intervall werden.
2) Je größer die Stichprobe ist, desto unempfindlicher wird sie gegen Ausreißer (Gesetz der großen Zahlen). Das Konfidenzintervall wird kleiner, überdeckt aber mit gleicher Wahrscheinlichkeit den wahren Parameter.

- 3) Steigt die Streuung innerhalb der Stichprobe (höhere Varianz) muss bei gleichbleibender Stichprobengröße das Konfidenzintervall wachsen, um den Parameter weiter mit gleicher Wahrscheinlichkeit zu überdecken.
- (f) Die genauen Zahlen und Ausgaben in R sind hier nebensächlich. Wichtig ist Ihr Verständnis für die dahinterstehende Systematik.

Relevante Folien:
SDS1V10

Aufgabe 4.

In Vorbereitung einer medizinischen Studie soll eine repräsentative Stichprobe an Personen auf ihr Körpergewicht untersucht werden. An die erhobenen Daten soll eine Normalverteilung mit bekanntem $\sigma^2 = 100$ angepasst und ein 90% Konfidenzintervall für μ berechnet werden. Leider sind ein paar der Erhebungsdaten verloren gegangen. Gegeben sind Ihnen noch die folgenden Werte:

$$\frac{1}{n} \sum_{i=1}^n x_i = 78.696; \quad \frac{1}{n} \sum_{i=1}^n x_i^2 = 6281.102; \quad C_{0.9}^+ - C_{0.9}^- = 3.6781$$

- (a) Berechnen Sie aus den gegebenen Werten per Hand die Größe der Stichprobe
- (b) Berechnen Sie nun per Hand das 90% Konfidenzintervall für μ .

Hinweise zur Lösung: Es wurde hier mit $z_{1-\frac{\alpha}{2}} = z_{0.95} = \text{qnorm}(0.95) \approx 1.6449$ gerechnet.

Kontrollergebnis 4.:

- (a) $n = 80$
- (b) $KI : [76.862; 80.530]$

Lösungsweg:

- (a) $C_{0.9}^+ - C_{0.9}^- = (\bar{x} + z_{1-\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}}) - (\bar{x} - z_{1-\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}})$
 $3.6781 = (78.6960 + 1.6449 \cdot \frac{10}{\sqrt{n}}) - (78.6960 - 1.64 \cdot \frac{10}{\sqrt{n}})$
 $3.6781 = 2 \cdot 1.6449 \cdot \frac{10}{\sqrt{n}}$
 $3.6781 \cdot \sqrt{n} = 32.8980$
 $\sqrt{n} = 8.9443 \Leftrightarrow n = 80$, denn für den Stichprobenumfang n gilt immer $n \in \mathbb{N}$
- (b) $C_{0.9}^+ - C_{0.9}^- = 3.6781$ ist gegeben, daher:
 $C_{0.9}^{\pm} = \bar{x} \pm \frac{1}{2} \cdot (C_{0.9}^+ - C_{0.9}^-)$
 $C_{0.9}^+ = 78.6960 + 1.8391 \approx 80.535$
 $C_{0.9}^- = 78.6960 - 1.8391 \approx 76.857$
 $KI : [76.857; 80.535]$

Alternativ mit der Formel für das Konfidenzintervall:

$$C_{0.9}^+ = \bar{x} + z_{1-\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}} = 78.6960 + 1.6449 \cdot \frac{10}{\sqrt{80}} \approx 80.535$$
$$C_{0.9}^- = \bar{x} - z_{1-\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}} = 78.6960 - 1.6449 \cdot \frac{10}{\sqrt{80}} \approx 76.857$$
$$KI : [76.857; 80.535]$$

Häufige Fehlerquellen:

Einsetzen von σ^2 anstatt σ in die Formel der Konfidenzintervalle für μ .

Relevante Folien:
SDS1V10.pdf

Aufgabe 5.

Ein Milchbetrieb möchte seinen Produktionsprozess optimieren. Im Rahmen dessen werden die auftretenden Schwankungen in den erbrachten Milchmengen der Kühe näher betrachtet. In R wurde unter dem Namen `Milch` die Milchmenge in kg von 9 Kühen eines Betriebes über eine Laktation (ca. 300 Melktage) gespeichert.

```
1 > Milch
2 [1] 5535 5659 4853 5020 5691 5564 5090 5217 6371
3 > mean(Milch)
4 [1] 5444.444
5 > var(Milch)
6 [1] 211893.0
```

- (a) Berechnen Sie das 98% Konfidenzintervall für die Varianz per Hand. Geben Sie außerdem die Breite des Konfidenzintervalles an.
- (b) Ein Freund von Ihnen hat das folgende Konfidenzintervall berechnet: $[77\,210.105; 1\,260\,880.399]$. Er hat als Konfidenzniveau entweder 0.90, 0.95 oder 0.99 benutzt, weiß aber nicht mehr welches. Welches Konfidenzniveau ist das richtige? Begründen Sie Ihre Antwort.

Hinweise zur Lösung:

Beachten Sie, dass R den unverzerrten Schätzer für die Varianz S_*^2 berechnet. Es gilt: $nS^2 = (n-1)S_*^2$.

Kontrollergebnis 5.:

- (a) $KI : [84\,377.501; 1\,027\,360]$; Breite: 942 982.499.
- (b) Bei dem vorliegenden Intervall handelt es sich um das 99% Konfidenzintervall, da es deutlich breiter ist (1 183 670.294) als das in (a) berechnete. Die 90% bzw. 95% Konfidenzintervalle wären schmäler als das in (a) berechnete.

Lösungsweg:

- (a) 1. Formel für das Konfidenzintervall des Parameters σ^2 :

$$KI : \left[\frac{(n-1)S_*^2}{\chi_{n-1; 1-\frac{\alpha}{2}}^2}; \frac{(n-1)S_*^2}{\chi_{n-1; \frac{\alpha}{2}}^2} \right]$$

2. Werte der Variablen ermitteln:

$$n = 9;$$

$$S_*^2 = 211\,893.000; \rightarrow \text{R gibt mit } \text{var}(\dots) \text{ den unverzerrten Schätzer aus.}$$

$$\chi_{n-1; 1-\frac{\alpha}{2}}^2 = \chi_{8; 0.99}^2 = 20.0902; \quad \chi_{n-1; \frac{\alpha}{2}}^2 = \chi_{8; 0.01}^2 = 1.6465 \rightarrow \text{in der Tabelle ablesen, oder R benutzen: } \text{qchisq}(0.99, 8) \text{ und } \text{qchisq}(0.01, 8)$$

3. Werte einsetzen:

$$KI : \left[\frac{8 \cdot 211\,893.000}{20.0902}; \frac{8 \cdot 211\,893.000}{1.6465} \right] \approx [84\,376.660; 1\,029\,544.000]$$

$$\text{Breite des Konfidenzintervalls: } 1\,029\,544.000 - 84\,376.660 \approx 945\,167.340.$$

Häufige Fehlerquellen:

Falsches Ablesen aus der Verteilungstabelle.

Relevante Folien:

SDS1V10