

Deskriptive Statistik I


- Hinweise -
- Kontrollergebnisse -

Notwendiges Vorwissen

- Kapitel Deskriptive Statistik 1
- Wissen über Stichproben

Aufgabe 1. (knobel)

In einer kleinen Umfrage wurden 20 Personen zu ihrer Körpergröße befragt. Das Ergebnis der Umfrage wurde in einer Grafik dargestellt.



- (a) Schätzen Sie den Anteil von Beobachtungen in der Grundgesamtheit in den folgenden Intervallen mithilfe der Grafik.
- (i) $[160, 172]$
 - (ii) $(167, 185]$
 - (iii) $(173, 184]$
- (b) Nehmen Sie an, Sie sollen aus der Grafik ein (normiertes) Histogramm erstellen. Welche y -Werte würden Sie den einzelnen Säulen zuweisen?
- (c) Ihr Kommilitone behauptet, dass bei einer Grundgesamtheit von 20 000 Personen 7 000 zwischen 175 und 180 cm groß sind. Stimmen Sie zu? Begründen Sie Ihre Entscheidung.

Hinweis zu Aufgabenteil (b): Bei einem (normierten) Histogramm ist die Fläche der einzelnen Säulen proportional zu der relativen oder absoluten Häufigkeit dieser Klasse. Zusätzlich muss der Flächeninhalt aller Säulen zusammen 1 ergeben.

Kontrollergebnis 1.:

- (a) (i) $\frac{1}{20} + \frac{3}{20} + \frac{2}{5} \cdot \frac{5}{20} = 0.30$ (ii) $\frac{3}{5} \cdot \frac{3}{20} + \frac{5}{20} + \frac{7}{20} + \frac{4}{20} = 0.89$ (iii) $\frac{2}{5} \cdot \frac{5}{20} + \frac{7}{20} + \frac{4}{5} \cdot \frac{4}{20} = 0.61$

getroffene Annahme: die Beobachtungen innerhalb der Klassen folgen einer stetigen Gleichverteilung (andere Annahmen zur Verteilung innerhalb der Klassen wären möglich)

- (b) 0.01; 0.03; 0.05; 0.07; 0.04

- (c) Die Stichprobe wurde zufällig gezogen. Es ist daher möglich (und wahrscheinlich), dass die Stichprobe die Grundgesamtheit nicht perfekt abbildet und dementsprechend die Anzahl der Personen in der Grundgesamtheit zwischen 175 und 180 cm von 7 000 abweichen kann.

Lösungsweg

- (a)
- Grundlegend zur Lösung dieser Aufgabe ist, dass man davon ausgeht, dass die Beobachtungen innerhalb der Klassen einer stetigen Gleichverteilung folgen. Das heißt, man geht davon aus, dass in der Grundgesamtheit der Bevölkerung genauso viele Leute 160 cm groß sind wie 161 cm wie 162 cm usw.
 - Außerdem sollte man sich klar machen, dass man die Körpergröße zwar als diskretes Merkmal angibt (man würde z.B. sagen, man ist 170 cm groß oder 171 cm, aber vermutlich würde niemand sagen, dass er 170.358 cm groß ist), dass die Größe aber eigentlich ein stetiges Merkmal ist, weil niemand, wenn man so fein messen könnte, auf die hunderste oder tausendste Nachkommastelle genau gleich groß ist. Deshalb kann man die Körpergröße als ein quasi-stetiges Merkmal behandeln. Wichtig zur Lösung dieser Aufgabe ist diese Schlussfolgerung, weil es bei (quasi-)stetigen Merkmalen egal ist, ob man die Grenzen eines Intervalls einschließt oder nicht.
 - Grundsätzlich geht man an diese Aufgabe heran, indem man sich anguckt, welche Klassen in einem Intervall enthalten sind, wie viele Personen (also wie viele Beobachtungen) in einer Klasse enthalten sind und wie groß der Anteil dieser Personenanzahl am Stichprobenumfang ist.
- (i) Das Intervall $[160; 172]$ enthält die Klassen $[160; 165]$ und $(165; 170]$ vollständig sowie anteilig die Klasse $(170; 175]$. In der Klasse $[160; 165]$ ist genau eine Person enthalten, wie man an der Höhe der entsprechenden Säule sehen kann. Das heißt, dass eine der 20 Personen aus der Stichprobe zwischen 160 cm und 165 cm groß ist, also dass $\frac{1}{20}$ der Stichprobe zwischen 160 cm und 165 cm groß ist. Analog in der Klasse $(165; 170]$: Die Höhe der entsprechenden Säule lässt sich auf der y -Achse als 3 ablesen, also sind 3 Personen aus der Stichprobe bzw. $\frac{3}{20}$ der Stichprobe zwischen 165 cm und 170 cm groß. Bei der Klasse $(170; 175]$ muss man beachten, dass die Obergrenze des Intervalls bei 172 cm liegt, also innerhalb der Klasse. Deshalb muss man die Anzahl der Personen, die in dieser Klasse enthalten sind, anteilig mitberechnen (s. Annahme der Gleichverteilung in den Klassen). Dafür schaut man sich an, wie breit die Klasse ist. Jede Klasse enthält hier die Beobachtungen aus einem 5 cm breiten Intervall, also ist die Klassenbreite 5 cm. Für das Intervall $[160; 172]$ sind in dieser Klasse noch 2 cm „relevant“, nämlich $(170; 172]$. Das entspricht $\frac{2}{5}$ der Klasse $(170; 175]$. Deshalb multipliziert man hier zum Anteil, den die Beobachtungen in dieser Klasse (nämlich 5) an der Stichprobe haben, also $\frac{5}{20}$, noch $\frac{2}{5}$. Zum Schluss werden die Anteile an der Stichprobe aus den drei relevanten Klassen addiert, also $\frac{1}{20}$ aus der Klasse $[160; 165]$ plus $\frac{3}{20}$ aus der Klasse $(165; 170]$ plus $\frac{2}{5} \cdot \frac{5}{20}$ für den Rest des Intervalls $(170; 172]$.
- (ii) Vom Intervall $(167; 185]$ sind 3 cm in der Klasse $(165; 170]$ enthalten, also ist der Anteil dieses Intervalls an der Klasse $\frac{3}{5}$. In der Klasse sind 3 Beobachtungen enthalten bzw. $\frac{3}{20}$ der Stichprobe. Diese beiden Anteile ($\frac{3}{5}$ und $\frac{3}{20}$) werden nun miteinander multipliziert, um den Anteil der im Intervall enthaltenen Beobachtungen zu berechnen, die zwischen 167 cm und 170 cm liegen. Die folgende Klasse $(170; 175]$ ist vollständig im Intervall enthalten. Hier muss nur die Anzahl der Personen, die in dieser Klasse beobachtet werden, durch die Größe der Stichprobe geteilt werden: In dieser Klasse sind $\frac{5}{20}$ der Stichprobe enthalten. Genauso in den Klasse $(175; 180]$ und $(180; 185]$. Es sind 7 Personen zwischen 175 cm und 180 cm groß ($\frac{7}{20}$ der Stichprobe) und 4 Personen zwischen 180 cm und 185 cm ($\frac{4}{20}$ der Stichprobe). Wie bei (i) müssen die entsprechenden Anteile nun noch addiert werden (s. Kontrolllösung).
- (iii) $(173; 175]$: Entspricht $\frac{2}{5}$ des Intervalls $(170; 175]$; 5 Personen sind in dieser Klasse enthalten, also $\frac{5}{20}$ der Stichprobe. D.h. $\frac{2}{5} \cdot \frac{5}{20}$ der Stichprobe sind zwischen 173 cm und 175 cm groß.
 $(175; 180]$: Vollständig im Intervall enthalten. 7 von 20 Personen, also $\frac{7}{20}$.
 $(180; 184]$: Entspricht $\frac{4}{5}$ des Intervalls $(180; 185]$. 4 von 20 Personen in der Klasse enthalten, also $\frac{4}{20}$. Insgesamt somit $\frac{4}{5} \cdot \frac{4}{20}$ zwischen 180 cm und 184 cm. Addieren s. Kontrolllösung.
- (b) Um ein (normiertes) Histogramm zu erhalten, müssen wir die Werte auf der y -Achse wie folgt skalieren:

$$\text{Dichte} = \frac{\text{relative Klassenhäufigkeit}}{\text{Klassenbreite}} = \frac{\text{absolute Klassenhäufigkeit}}{\text{Klassenbreite} \times n}$$

Das bedeutet, dass, wenn die relativen Klassenhäufigkeiten auf der y -Achse stehen, man nur durch die Klassenbreite teilen muss, um die entsprechenden y -Werte der Säulen zu erhalten. Wenn dagegen, wie hier, die

absoluten Klassenhäufigkeiten gegeben sind, muss man diese durch die Klassenbreite und n teilen. n bezeichnet die Anzahl von Beobachtungen (hier 20) und die Klassenbreite beträgt in diesem Fall 5. Also:

- erste Säule: $\frac{1}{5 \cdot 20} = 0.01$
 - zweite Säule: $\frac{3}{5 \cdot 20} = 0.03$
 - dritte Säule: $\frac{5}{5 \cdot 20} = 0.05$ usw.
- (c) Eine Stichprobe von 20 Einheiten ist im Allgemeinen zu klein, um zuverlässige Aussagen über eine sehr viel größere Grundgesamtheit, wie hier z.B. die Bevölkerung, zu machen. Wenn man also die Anteile der Größe in der Bevölkerung anhand dieser Stichprobe schätzt, ist es wahrscheinlich, dass die Güte dieser Schätzung nicht besonders hoch ist.

Häufige Fehlerquellen

- (a) Körpergröße als diskretes Merkmal werten und dabei Intervallgrenzen falsch behandeln. Bei Intervallen, die nur anteilig in einer Klasse sind, dies nicht (richtig) beachten.
- (b) Falsche Klassenbreite einsetzen. Bei absoluten Häufigkeiten nicht durch die Stichprobengröße teilen.

Verweis Informationsquellen

- (a) SDS01V02 Folie: 1 – 19
- (b) SDS01V02 Folie: 1 – 19
- (c) allgemeines Wissen über Stichproben

Aufgabe 2. (basis)

Die folgende Tabelle enthält die Semesterzahlen der Teilnehmer an der Klausur *Fortgeschrittene Mathematik für Wirtschaftswissenschaftler* am 11.02.2009:


Semesterzahl:	2	3	4	5	6	7	Σ
h_j	1	7	5	5	1	4	
$f_j = h_j/n$							
H_j							-
$F_j = H_j/n$							-

Anmerkung:

h_j = absolute Häufigkeit

H_j = absolute Summenhäufigkeit (absolute kumulierte Häufigkeit)


- Vervollständigen Sie die obige Tabelle, indem Sie die relativen Häufigkeiten, absoluten und Summenhäufigkeiten berechnen.
- Zeichnen Sie die empirische Verteilungsfunktion der relativen Summenhäufigkeiten in die folgende Grafik.



- Bestimmen Sie die Anteile der Studierenden, deren Semesterzahl
 - größer als 3,
 - mindestens 3,
 - kleiner als 4,
 - nicht größer als 5 ist.

Kontrollergebnis 2.:

Semesterzahl:	2	3	4	5	6	7	Σ
h_j	1	7	5	5	1	4	23
(a) $f_j = h_j/n$	$1/23$	$7/23$	$5/23$	$5/23$	$1/23$	$4/23$	1
H_j	1	8	13	18	19	23	-
$F_j = H_j/n$	$1/23$	$8/23$	$13/23$	$18/23$	$19/23$	$23/23$	-



(b)

(c) (i) $\frac{15}{23}$, (ii) $\frac{22}{23}$, (iii) $\frac{8}{23}$, (iv) $\frac{18}{23}$.

Lösungsweg

(a) Die relative Häufigkeit f_j berechnet sich durch $f_j = \frac{h_j}{n}$

Somit ergibt sich für:

$$f_2 = \frac{h_2}{n} = \frac{1}{23}$$

$$f_3 = \frac{h_3}{n} = \frac{7}{23}$$

$$f_4 = \frac{h_4}{n} = \frac{5}{23}$$

...

Die absolute Summenhäufigkeit H_j berechnet sich durch $H_j = \sum_{i=1}^j h_i$

Somit ergibt sich für:

$$H_2 = h_2 = 1$$

$$H_3 = h_2 + h_3 = 1 + 7 = 8$$

$$H_4 = h_2 + h_3 + h_4 = 1 + 7 + 5 = 13$$

...

Die relative Summenhäufigkeit F_j berechnet sich durch $F_j = \frac{H_j}{n}$

Somit ergibt sich für:

$$F_2 = \frac{H_2}{n} = \frac{1}{23}$$

$$\begin{aligned} F_3 &= \frac{H_3}{n} = \frac{8}{23} \\ F_4 &= \frac{H_4}{n} = \frac{13}{23} \\ F_5 &= \frac{H_5}{n} = \frac{18}{23} \\ &\dots \end{aligned}$$

$$(c) \quad (i) \quad P(j > 3) = P(j \geq 4) = \frac{5}{23} + \frac{5}{23} + \frac{1}{23} + \frac{4}{23} = \frac{15}{23}$$

Alternative mit Hilfe der Gegenwahrscheinlichkeit: $P(j > 3) = P(j \geq 4) = 1 - P(j \leq 3) = 1 - \frac{8}{23} = \frac{15}{23}$

Erläuterung: Um den Anteil der Studierenden, deren Semesterzahl höher als 3 ist, zu erhalten, muss man den Anteil der Semester 4, 5, 6 und 7 addieren. Alternativ kann mit der Gegenwahrscheinlichkeit auch der Anteil derer, die höchstens drei Semester haben, ausschließen und vom Ganzen abziehen. Somit zieht man den Anteil der Studierenden mit 2 oder 3 Semestern von 1 ab.

$$(ii) \quad P(j \geq 3) = \frac{7}{23} + \frac{5}{23} + \frac{5}{23} + \frac{1}{23} + \frac{4}{23} = \frac{22}{23}$$

$$\text{Alternativ: } P(j \geq 3) = 1 - P(j \leq 2) = 1 - \frac{1}{23}$$

$$(iii) \quad P(j < 4) = P(j \leq 3) = F_3 = \frac{1}{23} + \frac{7}{23} = \frac{8}{23}$$

$$(iv) \quad P(j \leq 5) = F_5 = \frac{1}{23} + \frac{7}{23} + \frac{5}{23} + \frac{5}{23} = \frac{18}{23}$$

Häufige Fehlerquellen

- (b) Punkt wird vergessen. Linien dürfen nicht vertikal verbunden werden. Andeutungen in das Unendliche werden vergessen.
- (c) Handelt es sich um größer als oder größer gleich (kleiner oder kleiner gleich)?

Verweis Informationsquellen

- (a) SDS01V02 Folie: 1 – 7


Aufgabe 3.

Die R-Sammeldatei (R-Sammeldatei.R auf StudIP im Ordner Datensätze) enthält die Teildatensätze `Gewicht_m` und `Gewicht_w`. Diese enthalten Gewichtsangaben von männlichen und weiblichen Studierenden. Für diese Aufgaben wird der Teildatensatz männlicher Studierender benötigt.

- Stellen Sie den Teildatensatz `Gewicht_m` mithilfe des Befehls `hist()` in einem Diagramm mit absoluten Häufigkeiten auf der y -Achse in R dar, ohne Klassenbreiten vorzugeben. Wie breit sind die Klassen?
- Stellen Sie den Teildatensatz `Gewicht_m` in einem Diagramm mit absoluten Häufigkeiten auf der y -Achse in R dar. Geben Sie R die Klassengrenzen („breaks“) 40, 70, 100, 130 und 160 vor. (Beschriften Sie zusätzlich die Achsen und geben Sie der Graphik eine Überschrift.)
- Benutzen Sie folgenden Befehl, nachdem Sie Aufgabe b) ausgeführt haben:
`axis(1, Gewicht_m)`
Beschreiben Sie, was dieser Befehl verändert. Welche Vor- und Nachteile gibt es?
- Lassen Sie sich die Kennzahlen des Diagramms in der R-Konsole ausgeben, ohne das Diagramm grafisch darzustellen. Füllen Sie mithilfe des Outputs folgende Tabelle aus:

Intervall	h_j	$f_j = h_j/n$	H_j	$F_j = H_j/n$
[40, 70]				
(70, 100]				
(100, 130]				
(130, 160]				

- Zeichnen Sie das zugehörige Diagramm mit absoluten Häufigkeiten auf der y -Achse per Hand. Überprüfen Sie ihr Ergebnis mithilfe von R.
- Skalieren Sie die y -Achse so, dass die Gesamtfläche der Säulen 1 ergibt. Was müssen Sie hierfür auf der y -Achse abtragen?
- Bestimmen Sie jeweils den Anteil und die Anzahl von Beobachtungen, die
 - kleiner gleich 100 sind,
 - zwischen 70 und 130 (einschließlich 130) liegen.
- Mit dem Befehl: `hist(Gewicht_m, breaks = c(50, 60, 70, 80, 90, 200), prob=F)` erhält man folgenden Output:



Wieso handelt es sich hierbei nicht um ein (normiertes) Histogramm? Was ist der Nachteil dieser Darstellung?

- Wie könnte der R-Befehl geändert werden, um ein (normiertes) Histogramm zu erhalten?

Kontrollergebnis 3.:


- (a) `hist(Gewicht_m)`, Klassenbreite beträgt je 10.
- (b) `hist(Gewicht_m, main="Diagramm von Gewicht_m", xlab="Gewicht von männlichen Studenten", ylab="Absolute Häufigkeiten", breaks=c(40, 70, 100, 130, 160))`
- (c) Der Befehl `axis(1, Gewicht_m)` führt dazu, dass die tatsächlich beobachteten Werte auf der x -Achse aufgeführt sind. Das Argument 1 steht hierbei für die x -Achse, das Argument `Gewicht_m` für den verwendeten Teildatensatz.

Vorteil: Man kann direkt wichtige Werte wie z.B. Minimum und Maximum im Histogramm ablesen.


Nachteil: Bei vielen Werten kann es schnell unübersichtlich werden.

Intervall	h_j	$f_j = h_j/n$	H_j	$F_j = H_j/n$
[40, 70]	44	0.352	44	0.352
(70, 100]	76	0.608	120	0.96
(100, 130]	4	0.032	124	0.992
(130, 160]	1	0.008	125	1

- (e) `hist(Gewicht_m, breaks=c(40, 70, 100, 130, 160))`



- (f) Auf der y -Achse muss die Dichte= relative Häufigkeit/Klassenbreite stehen.



- (g) (i) Anteil: 0.96, Anzahl: $0.96 \cdot 125 = 120$.
(ii) Anteil: 0.64, Anzahl: 80.
- (h) Säulendiagramm, da absolute Häufigkeiten bei unterschiedlichen Klassenbreiten. Das Säulendiagramm führt zu einer verzerrten Darstellung.
- (i) `hist(Gewicht_m, breaks=c(50, 60, 70, 80, 90, 200), prob=T)` bzw.
`hist(Gewicht_m, breaks=c(50, 60, 70, 80, 90, 200), freq=F)`
geben beide die Dichte = relative Klassenhäufigkeit / Klassenbreite auf der y -Achse aus.

Lösungsweg und Hinweise

- (a) Mit dem Befehl `hist()` wird per default (standardmäßig) ein Diagramm mit absoluten Häufigkeiten auf erstellt.
- (b) R-Befehle:
- `main`: "Titel für die Grafik"
 - `xlab`: "Beschriftung der x -Achse"
 - `ylab`: "Beschriftung der y -Achse"
 - `breaks`: Durch den Befehl können Klassengrenzen definiert werden.
- (d)
- Mit dem Befehl: `hist(Gewicht_m, breaks=c(40, 70, 100, 130, 160), plot=F)` können die absoluten Häufigkeiten h_j ausgegeben werden, ohne die Grafik darzustellen.
 - Die relative Häufigkeit ist $f_j = h_j/n$.
 - Die absolute Summenhäufigkeit (die kumulierte absolute Häufigkeit) ist $H_j = h_1 + h_2 + \dots + h_j$.
 - Die relative Summenhäufigkeit (die kumulierte relative Häufigkeit) ist $F_j = H_j/n$.

Zur Aufgabe:

- $[40, 70] : h_1 = 44, f_1 = \frac{h_1}{n} = \frac{44}{125} = 0.352, H_1 = h_1 = 44, F_1 = \frac{H_1}{n} = \frac{44}{125} = 0.352$
- $(70, 100] : h_2 = 76, f_2 = \frac{h_2}{n} = \frac{76}{125} = 0.608, H_2 = h_1 + h_2 = 44 + 76 = 120, F_2 = \frac{H_2}{n} = \frac{120}{125} = 0.96$
- $(100, 130] : h_3 = 4, f_3 = \frac{h_3}{n} = \frac{4}{125} = 0.032, H_3 = h_1 + h_2 + h_3 = 124, F_3 = \frac{H_3}{n} = \frac{124}{125} = 0.992$
- $(130, 160] : h_4 = 1, f_4 = \frac{h_4}{n} = \frac{1}{125} = 0.008, H_4 = h_1 + h_2 + h_3 + h_4 = 125, F_4 = \frac{H_4}{n} = \frac{125}{125} = 1$

Alternativ auch mit folgende R-Befehlen möglich:

```
gew_m <- hist(Gewicht_m, breaks=c(40, 70, 100, 130, 160), plot=F)
abs <- gew_m$counts und cumsum(abs)
rel <- gew_m$counts/125 und cumsum(rel)
```

- (e) Diagramm per Hand zeichnen. Achsenbeschriftung nicht vergessen!
- (g) Anteil = relative Häufigkeit, Anzahl = absolute Häufigkeit = relative Häufigkeit $\cdot n$.
Diese Aufgabe kann mithilfe der Tabelle aus (d) gelöst und die Ergebnisse mithilfe von R überprüft werden.
- (i) Anzahl: $h_1 + h_2 = 44 + 76 = 120$
Anteil: $\frac{h_1 + h_2}{n} = \frac{120}{125} = 0.96$
In R ohne Grafik:
`hist(Gewicht_m, breaks=c(40, 100, 160), plot=F)`
- (ii) Anzahl: $H_3 - h_1 = 124 - 44 = 80$
Anteil: $\frac{H_3 - h_1}{n} = \frac{80}{125} = 0.64$
In R ohne Grafik: `hist(Gewicht_m, breaks=c(40, 70, 130, 160), plot=F)`

Häufige Fehlerquellen

- (d) / (g) Bei der Berechnung der kumulierten Häufigkeit wird vergessen, die absoluten Häufigkeiten der vorherigen Fälle hinzuzurechnen.
- (h) Verwechslung des Histogramms und des Säulendiagramms. Ein Histogramm ist eine flächenproportionale Darstellung der Häufigkeiten, in der sich die Flächen auf 1 summieren. Ein Säulendiagramm führt zu einer verzerrten Darstellung.

Verweis Informationsquellen

(a–i) SDS01V02 Folie 1 – 19

Aufgabe 4. (basis)

Erinnern Sie sich an Aufgabe 1: Die folgende Tabelle enthält die Semesterzahlen der Teilnehmer an der Klausur Fortgeschrittene Mathematik für Wirtschaftswissenschaftler am 11.02.2009:

Semesterzahl:	2	3	4	5	6	7	Σ
h_j	1	7	5	5	1	4	23
$f_j = h_j/n$	1/23	7/23	5/23	5/23	1/23	4/23	1
H_j	1	8	13	18	19	23	-
$F_j = H_j/n$	1/23	8/23	13/23	18/23	19/23	23/23	-

Anmerkung:

h_j = absolute Häufigkeit

H_j = absolute Summenhäufigkeit (absolute kumulierte Häufigkeit)

Bestimmen Sie die folgenden Kennzahlen: Mittelwert, Median, Modus, Varianz und Standardabweichung.

Kontrollergesult 4.: 4.435, 4, 3, 2.246, 1.498

Lösungsweg

- Mittelwert: $\bar{x} = \frac{1}{n} \cdot \sum_{i=1}^n x_i$
 $\bar{x} = \frac{1}{23} \cdot (1 \cdot 2 + 7 \cdot 3 + 5 \cdot 4 + 5 \cdot 5 + 1 \cdot 6 + 4 \cdot 7) = \frac{102}{23} = 4.4348 \approx 4.435$

- Median: $x_{med} = 4$

$$x_{med} \begin{cases} = x_{(\frac{n+1}{2})} & \text{für } n \text{ ungerade} \\ \in [x_{(\frac{n}{2})}, x_{(\frac{n}{2}+1)}] & \text{für } n \text{ gerade} \end{cases}$$

$n = 23 \rightarrow$ ungerade

Um den Median am einfachsten zu ermitteln, kann man sich die Daten der Stichprobe wie folgt notieren und sich den mittleren Wert markieren:

2 3 3 3 3 3 3 4 4 4 4 4 5 5 5 5 6 7 7 7 7

- Modus: Der Modus ist der Wert der häufigsten Ausprägung

$$x_{mod} = 3$$

Erläuterung: da die Semesterzahl 3 siebenmal vorkommt, während die anderen Semesterzahlen weniger als siebenmal vorkommen.

- Stichprobenvarianz: $s^2 = \frac{1}{n} \cdot \sum_{i=1}^n (x_i - \bar{x})^2$

Verschiebungssatz: $s^2 = \frac{1}{n} \cdot \sum_{i=1}^n x_i^2 - \bar{x}^2$

$$s^2 = \frac{1}{23} \cdot (2^2 + 7 \cdot 3^2 + 5 \cdot 4^2 + 5 \cdot 5^2 + 1 \cdot 6^2 + 4 \cdot 7^2) - 4.4348^2 = \frac{504}{23} - 19.6675 = 21.9130 - 19.6675 = 2.2455 \approx 2.246$$

- Standardabweichung: $s = \sqrt{s^2}$

$$s = \sqrt{2.2455} \approx 1.498$$

Häufige Fehlerquellen

Formel für den unverzerrten Schätzer der Stichprobenvarianz (s_*^2) verwendet.

Verweis Informationsquellen

DS1:

- Für Arithmetische Mittel: SDS01V02 Folie 20
- Für Median: SDS01V02 Folie 20
- Für Modus: SDS01V02 Folie 21
- Für Varianz: SDS01V02 Folie 35 – 36
- Für Standardabweichung: SDS01V02 Folie 35 – 36

Aufgabe 5. (basis)

In der Zeitschrift Forschung und Lehre, Heft 3/09 berichtet Prof. Dr. M. Ferrari, Universität Erlangen-Nürnberg über eine im Zusammenhang mit der elektronisch durchgeführten Evaluation der Lehre durchgeführte Befragung der Studierenden an der Philosophischen Fakultät und am Fachbereich Theologie. Es gab die folgenden Antworten zu den Fragen:

Wie lange arbeiten Sie pro Woche während der Vorlesungszeit?

Wie lange haben Sie pro Woche zuletzt während der vorlesungsfreien Zeit gearbeitet?

Stunden	Vorlesungszeit	Vorlesungsfreie Zeit
[0, 4]	40.2%	25.4%
(4, 8]	19.6%	14.4%
(8, 12]	21.9%	16.5%
(12, 16]	18.3%	43.7%

- (a) Welche Klasse ist jeweils die Modalklasse?
- (b) Bestimmen Sie jeweils näherungsweise das arithmetische Mittel und die Varianz. Nutzen Sie die Mitten der Klassen als Hilfe.

Kontrollergebnis 5.:

- (a) Modalklasse Vorlesungszeit: $[0, 4]$; Modalklasse vorlesungsfreie Zeit: $(12, 16]$.
- (b) Vorlesungszeit: $\bar{x} = 6.732$, $s^2 = 21.112$; Vorlesungsfreie Zeit: $\bar{x} = 9.14$, $s^2 = 24.812$.

Lösungsweg

- (a) Mit der Modalklasse ist die Klasse mit der größten Häufigkeit gemeint.

Vorlesungszeit: $[0, 4]$ mit 40.2%

Vorlesungsfreie Zeit: $(12, 16]$ mit 43.7%

- (b) Hier sollen die Mitten der Klassen als Hilfe benutzt werden:

$[0, 4] : 2$

$(4, 8] : 6$

$(8, 12] : 10$

$(12, 16] : 14$

Nun berechnen wir das arithmetische Mittel und die empirische Varianz, allgemein dazu:

Arithmetisches Mittel für klassierte Daten: $\bar{x}_K = \sum_{i=1}^r f(K_i)m_i$ (Dabei bezeichnet m_i die Klassenmitte)

Varianz für klassierte Daten: $s_K^2 = \sum_{i=1}^r f(K_i)(m_i - \bar{x}_K)^2$

Vorlesungszeit:

$$\bar{x}_K = 0.402 \cdot 2 + 0.196 \cdot 6 + 0.219 \cdot 10 + 0.183 \cdot 14 = 6.732$$

$$s_K^2 = 0.402 \cdot (2 - 6.732)^2 + 0.196 \cdot (6 - 6.732)^2 + 0.219 \cdot (10 - 6.732)^2 + 0.183 \cdot (14 - 6.732)^2 = 21.112$$

Vorlesungsfreie Zeit:

$$\bar{x}_K = 2 \cdot 0.254 + 6 \cdot 0.144 + 10 \cdot 0.165 + 14 \cdot 0.437 = 9.14$$

$$s_K^2 = 0.254 \cdot (2 - 9.14)^2 + 0.144 \cdot (6 - 9.14)^2 + 0.165 \cdot (10 - 9.14)^2 + 0.437 \cdot (14 - 9.14)^2 = 24.812$$

Häufige Fehlerquellen

- (a) Verwechslung mit dem Median oder anderen statistischen Kennzahlen. Korrekte Einprägung der Begrifflichkeiten ist sehr wichtig.
- (b) Achten Sie immer darauf, die richtige Formel anzuwenden.

Verweis Informationsquellen

- (a) SDS01V02 Folie 21
- (b) SDS01V02 Folie 35 – 36

Aufgabe 6. (basis)

Betrachten Sie die folgenden drei Datensätze.

	Datensatz I:	Datensatz II:	Datensatz III:
x_1	7	7	14
x_2	14	9	18
x_3	5	5	10
x_4	8	8	16
x_5	6	6	12

- Berechnen Sie zunächst jeweils das arithmetische Mittel und den Median der Datensätze I und II. Was fällt Ihnen auf? Erklären Sie das Ergebnis kurz.
- Versuchen Sie nun **ohne Berechnung der Varianz** einen Zusammenhang zwischen den Varianzen der Datensätze II und III zu formulieren. Überprüfen Sie diesen Zusammenhang danach rechnerisch, indem Sie die Varianzen ausrechnen.

Kontrollergebnis 6.:

- Für Datensatz II entspricht der Median dem arithmetischen Mittel: $\bar{x} = x_{med} = 7$. Für Datensatz I ist das arithmetische Mittel größer als der Median: $\bar{x} = 8 > 7 = x_{med}$.
Das kann durch den sogenannten *Ausreißer* in Datensatz I erklärt werden. Die beiden Datensätze sind identisch bis auf x_2 , wo bei Datensatz I eine 14 und bei Datensatz II eine 9 beobachtet wurde. Der Median ist robust gegenüber solcher Ausreißer, da er als zentraler Wert der Beobachtungen zwar von der Anzahl der einzelnen Beobachtungen, nicht aber von deren Ausprägung abhängt. Das arithmetische Mittel wiederum ist als Durchschnitt aller Beobachtungen sehr wohl von den einzelnen Ausprägungen abhängig und damit anfällig für solche „extremen Werte“ bzw. Ausreißer.
- Datensatz III ergibt sich aus Datensatz II, multipliziert mit 2. Dadurch „verdoppelt“ sich auch der Abstand der einzelnen Beobachtungen zum arithmetischen Mittel, so dass die Standardabweichung von Datensatz III doppelt so groß ist wie die von Datensatz II. Die Varianz ergibt sich aus der quadrierten Standardabweichung. Dementsprechend ist die Varianz (s^2) von Datensatz III das Vierfache der Varianz von Datensatz II ($2^2 = 4$). Rechnerisch ergibt sich für Datensatz III eine Varianz von 8 und für Datensatz II eine Varianz von 2. Gleiches gilt für die Stichprobenvarianz s_*^2 : Diese ist für Datensatz III (10) vier mal so groß wie für Datensatz II (2.5).

Lösungsweg

- Arithmetisches Mittel:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\text{Datensatz I: } \bar{x} = \frac{1}{5} \cdot (5 + 6 + 7 + 8 + 14) = 8$$

$$\text{Datensatz II: } \bar{x} = \frac{1}{5} \cdot (5 + 6 + 7 + 8 + 9) = 7$$

Median:

$$x_{med} \begin{cases} = x_{(\frac{n+1}{2})} & \text{für } n \text{ ungerade} \\ \in [x_{(\frac{n}{2})}, x_{(\frac{n}{2}+1)}] & \text{für } n \text{ gerade} \end{cases}$$

$$n = 5 \Rightarrow \text{ungerade}$$

$$\text{Datensatz II: } x_{med} = x_{(\frac{5+1}{2})} = x_{(3)} = 7$$

$x_{[3]}$ entspricht hier dem dritten x , wenn diese sortiert sind und ist nicht identisch mit x_3 .

Wir nummerieren: 5 6 7 8 9

Der Median befindet sich an der dritten Stelle.

$$\text{Datensatz I: } x_{med} = x_{(\frac{5+1}{2})} = x_{(3)} = 7$$

Wir nummerieren: 5 6 7 8 14

Der Median befindet sich an der dritten Stelle.

(b) Herleitung:

$$\text{Stichprobenvarianz: } s^2 = \frac{1}{n} \cdot \sum_{i=1}^n (x_i - \bar{x})^2$$

Datensatz III ergibt sich aus Datensatz II, multipliziert mit 2.

Dadurch verdoppelt sich auch der Abstand der einzelnen Beobachtungen zum arithmetischen Mittel.

Das heißt für die Varianz von Datensatz III:

$$s^2 = \frac{1}{n} \cdot \sum_{i=1}^n (2 \cdot x_i - 2 \cdot \bar{x})^2$$

$$s^2 = \frac{1}{n} \cdot \sum_{i=1}^n (2 \cdot (x_i - \bar{x}))^2$$

$$s^2 = \frac{1}{n} \cdot \sum_{i=1}^n (2^2 \cdot (x_i - \bar{x})^2)$$

$$s^2 = \frac{1}{n} \cdot \sum_{i=1}^n (4 \cdot (x_i - \bar{x})^2)$$

$$\text{Regel: Vorziehen konstanter Faktoren: } \sum_{i=1}^n c \cdot x_i = c \cdot \sum_{i=1}^n x_i$$

$$s^2 = 4 \cdot \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Dementsprechend entspricht die Varianz von Datensatz III dem Vierfachen der Varianz von Datensatz II.

Berechnung:

$$\text{Verschiebungssatz: } s^2 = \frac{1}{n} \cdot \sum_{i=1}^n x_i^2 - \bar{x}^2$$

Datensatz II:

$\bar{x} = 7$ (Siehe Aufgabenteil a)

$$s^2 = \frac{1}{5} \cdot (5^2 + 6^2 + 7^2 + 8^2 + 9^2) - 7^2 = 2$$

Datensatz III:

$$\bar{x} = \frac{1}{5} \cdot (14 + 18 + 10 + 16 + 12) = 14$$

$$s^2 = \frac{1}{5} \cdot (14^2 + 18^2 + 10^2 + 16^2 + 12^2) - 14^2 = 8$$

Für die Stichprobenvarianz s_*^2 kann mit der entsprechenden Formel ebenso verfahren werden.

Häufige Fehlerquellen

- (a) Begrifflichkeiten könnten verwechselt werden.
Wenn man den Median bestimmt, sollte beachtet werden, dass die Beobachtungen in der Reihenfolge nummeriert sind.
- (b) Der Verschiebungssatz sollte richtig angewendet werden. Hinweis: Auch die Stichprobenvarianz s_*^2 hat einen Verschiebungssatz.

Verweis Informationsquellen

- (a) SDS01V02 Folie 20
- (b) SDS01V02 Folie 35 – 36

Aufgabe 7.

Auf dem Campus wurden 20 Studierende gefragt, in welchem Semester sie sich aktuell befinden. Die Ergebnisse der Umfrage wurden in einer Tabelle aufbereitet.

i	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
x_i	4	2	1	6	3	1	1	7	13	4	6	6	1	14	5	9	3	2	6	3

- (a) Zeichnen Sie den dazugehörigen Boxplot in R, indem Sie zuerst die Ergebnisse der Stichprobe in der Variablen x speichern und die Ergebnisse dann als Boxplot darstellen.

R benutzt folgende Methode, um die Whiskers zu bestimmen:

Sei $X \in \mathbb{R}^n$ ein Set, für den ein Boxplot erstellt werden soll. Die Whiskers werden dann folgendermaßen in R berechnet:

Obere Grenze:

Richtwert $x_{ROW} = \tilde{x}_{0.75} + 1.5 \cdot \text{IQR}$ (ROW = Richtwert Oberer Whisker)

Oberer Whisker $x_{OW} = \max(\{x \in X : x \leq x_{ROW}\})$

Untere Grenze

Richtwert $x_{RUW} = \tilde{x}_{0.25} - 1.5 \cdot \text{IQR}$ (RUW = Richtwert Unterer Whisker)

Unterer Whisker $x_{UW} = \min(\{x \in X : x \geq x_{RUW}\})$

- (b) Benutzen Sie die von R verwendete Methode, um die Whiskers zu bestimmen. Überprüfen Sie Ihre Ergebnisse in R. Nutzen Sie dazu das optionale Argument `plot = F` in Ihrem Boxplot-Befehl.
- (c) Betrachten Sie den Median im Verhältnis zu dem ersten und dritten Quartil. Was fällt Ihnen auf? Handelt es sich dabei um eine Besonderheit oder zeichnen sich alle Boxplots dadurch aus?


Kontrollergebnis 7.:

- (a)

```
x <- c(1,1,1,1,2,2,3,3,3,4,4,5,6,6,6,6,7,9,13,14)
```



```
boxplot(x, main="Boxplot", ylab="Anzahl Semester")
```



- (b) $x_{ROW} = 6 + 1.5 \cdot (6 - 2) = 12$; $x_{OW} = 9$
 $x_{RUW} = 2 - 1.5 \cdot (6 - 2) = -4$; $x_{UW} = x_{min} = 1$

Kontrolle in R: `boxplot(x, plot = F)`

- (c) In diesem Fall liegt der Median ($\tilde{x}_{0.5} = 4$) genau in der Mitte zwischen dem ersten (2) und dem dritten Quartil (6). Diese Besonderheit ist allerdings rein zufällig. Der Median und die Quartile treffen nur Aussagen über die Verteilung des betrachteten Merkmals. Bei einer anderen Stichprobe könnte der Median zum Beispiel auch bei 3 oder 5 liegen.

Lösungsweg

(b) Sortierte Liste in R ausgeben lassen:

```
> sort(x)
[1] 1 1 1 1 2 2 3 3 3 4 4 5 6 6 6 6 7 9 13 14
> length(x)
[1] 20
```

Bestimme das 25% und 75% Quantil mit der Formel:

$$x_{\alpha} \begin{cases} = x_{(\lfloor n\alpha \rfloor + 1)} & n\alpha \notin \mathbb{N} \\ \in [x_{(n\alpha)}, x_{(n\alpha + 1)}] & n\alpha \in \mathbb{N}. \end{cases}$$

Dabei ist $\lfloor n\alpha \rfloor$ die zu $n\alpha$ nächstkleinere ganze Zahl (Gaußklammer).

Für das 25% Quantil ergibt sich: $n \cdot p = 20 \cdot 0.25 = 5$

np ist somit ganzzahlig. Der 5. und 6. Wert der sortierten Liste bilden das Intervall für das Quantil.

$$x_{0.25} \in [x_{(5)}, x_{(6)}] = [2, 2] = 2$$

Das selbe Vorgehen ergibt für das 75% Quantil:

$$x_{0.75} \in [x_{(15)}, x_{(16)}] = [6, 6] = 6$$

Der Interquartilsabstand (IQR) beschreibt den Abstand zwischen den beiden Quantilen und wird daher berechnet über:

$$\text{IQR} = x_{0.75} - x_{0.25} = 6 - 2 = 4$$

Einfaches Einsetzen in die Formeln aus der Aufgabenstellung ergibt die korrekte Lösung.

Relevante Folien:

SDS01V02 Folie 30 – 31 und 40 – 45