

## Deskriptive Statistik II

- Hinweise -  
- Kontrollergebnisse -

### Aufgabe 1.

Mit dem Befehl:

```
set.seed(5)
```

```
Stichprobe <- sample(0:6, 20, replace=TRUE)
```

wurde eine Stichprobe durchgeführt und abgespeichert.

- Lassen Sie sich mit den obigen Befehlen die gleiche Stichprobe ausgeben und speichern Sie diese ab. Nutzen Sie zur besseren Übersicht ebenfalls die Befehle: `table`, `sort` und `sum`
- Berechnen Sie per Hand die relative Häufigkeit von 3, das arithmetische Mittel, den Median und die empirische Varianz. Überprüfen Sie anschließend Ihre Ergebnisse mithilfe von R. Wieso erhalten Sie mit R ein anderes Ergebnis für die Varianz und den Median?
- Lassen Sie sich mit dem R-Befehl `hist(Stichprobe, breaks=c(0,2,4,6))` ein Diagramm ausgeben. Was müssen Sie tun, um ein (normiertes) Histogramm zu erhalten? Berechnen Sie die  $y$ -Werte der einzelnen Klassen selbst per Hand.

### Kontrollergebnis 1.:

- R-Befehle: `Stichprobe`, `table(Stichprobe)`, `sort(Stichprobe)`, `sum(Stichprobe)`
- relative Häufigkeiten: `prop.table(table(Stichprobe))`  
arithmetisches Mittel: `mean(Stichprobe)`  
Median: `median(Stichprobe)`  
Varianz: `var(Stichprobe)`

Da  $n = 20$  handelt es sich beim Median um ein Intervall. R gibt aber nicht dieses Intervall sondern den Mittelwert davon an. Dies wird zum Beispiel zur Zeichnung eines Boxplots benötigt.

Der Unterschied in der Varianz besteht darin, dass R die unverzerzte Varianz  $s_*^2$  berechnet. Händisch wird meist der verzerzte Schätzer für die Varianz  $s^2$  berechnet. Die Umrechnung ist mit folgender Formel möglich:

$$s^2 = s_*^2 \cdot \frac{n-1}{n}$$

- `hist(Stichprobe, breaks=c(0,2,4,6), prob=T)` oder `hist(Stichprobe, breaks=c(0,2,4,6), freq=F)`  
 $y\text{-Achse} = \text{Dichte} = \frac{\text{relative Häufigkeit}}{\text{Klassenbreite}}$

### Lösungsweg und Hinweise

*Hinweis:* Der Befehl `set.seed(5)` in Kombination mit dem `sample()`-Befehl und dem Abspeichern in `Stichprobe` führt i.d.R. dazu, dass eine Stichprobe mit identischen Werten erzeugt wird, so dass jeder die gleiche Stichprobe beim Ausführen der Befehle erhält. Aufgrund anderer Versionen von RStudio kann es jedoch dazu kommen, dass Stichproben mit anderen Werten erzeugt werden. Daher hier einmal die Werte der Stichprobe, die für die Kontrolllösung der Aufgabe verwendet wurden:

1 2 0 6 2 0 0 4 5 6 6 2 2 5 1 6 4 3 1 4

Falls Sie eine andere Stichprobe erhalten haben, aber lieber mit diesen Werten arbeiten möchten, können Sie die Werte selbst abspeichern: `Stichprobe <- c(1,2,0,6,2,0,0,4,5,6,6,2,2,5,1,6,4,3,1,4)`

- Der R-Befehl `Stichprobe` gibt die Werte der Stichprobe aus, wenn die Stichprobe unter dem Namen `Stichprobe` abgespeichert wurde.
  - Der R-Befehl `table()` gibt die absoluten Häufigkeiten in Tabellenform aus.
  - Der R-Befehl `sort()` sortiert die Werte aufsteigend.
  - Der R-Befehl `sum()` liefert die Summe der Werte.
- relative Häufigkeit von 3:*  
$$f(3) = \frac{h_3}{n} = \frac{1}{20} = 0.05.$$

Dabei lässt sich  $h_3$  (absolute Häufigkeit von 3) aus der Tabelle von Aufgabenteil a) ablesen

*Hinweis zum R-Befehl:* `table()` liefert die absoluten Häufigkeiten, `prop.table(table())` liefert die relativen Häufigkeiten.

▪ *Arithmetisches Mittel:*

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{60}{20} = 3.$$

Dabei wurde  $\sum_{i=1}^n x_i$  bereits in a) mit dem Befehl `sum()` berechnet.

▪ *Median:*

Für die Ermittlung des Medians ist es hilfreich, die Werte aufsteigend zu sortieren (Urliste):

0 0 0 1 1 1 2 2 2 2 3 4 4 4 5 5 6 6 6 6

Für  $n$  gerade ist der Median  $x_{med} \in [x_{(\frac{n}{2})}, x_{(\frac{n}{2}+1)}] = [x_{10}, x_{11}] = [2, 3]$

R berechnet aus diesem Intervall den Mittelwert für den Median. Daher ist  $x_{med} = \frac{2+3}{2} = 2.5$ .

▪ *Varianz:*

$$s^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2 = \frac{1}{20} (1^2 + 2^2 + \dots + 1^2 + 4^2) - 3^2 = 4.5$$

Alternativ über  $s^2 = s_*^2 \cdot \frac{n-1}{n}$ . Dann kann für die unverzerzte Varianz  $s_*^2$  das Ergebnis des R-Befehls `(var(Stichprobe) = 4.736842)` verwendet werden.

- (c) Damit in R ein (normiertes) Histogramm gezeichnet wird, kann entweder `prob=T` oder `freq=F` angegeben werden. Alternativ zu T und F kann auch TRUE bzw. FALSE geschrieben werden. Die R-Befehle lauten dann `hist(Stichprobe, breaks=c(0,2,4,6), prob=T)` oder `hist(Stichprobe, breaks=c(0,2,4,6), freq=F)`.

Bei einem (normierten) Histogramm ist die  $y$ -Achse =  $\frac{\text{relative Häufigkeit}}{\text{Klassenbreite}}$ , wobei rel. Häufigkeit =  $\frac{\text{absolute Häufigkeit}}{n}$  ist.

- für die Klasse  $[0, 2]$ : rel. Häufigkeit =  $\frac{10}{20} = 0.5$  und  $\frac{\text{relative Häufigkeit}}{\text{Klassenbreite}} = \frac{0.5}{2} = 0.25$
- für die Klasse  $(2, 4]$ : rel. Häufigkeit =  $\frac{4}{20} = 0.2$  und  $\frac{\text{relative Häufigkeit}}{\text{Klassenbreite}} = \frac{0.2}{2} = 0.1$
- für die Klasse  $(4, 6]$ : rel. Häufigkeit =  $\frac{6}{20} = 0.3$  und  $\frac{\text{relative Häufigkeit}}{\text{Klassenbreite}} = \frac{0.3}{2} = 0.15$

*Hinweis:* Die absoluten Häufigkeiten kann man am Diagramm ablesen, wenn man das Diagramm mit dem R-Befehl `hist(Stichprobe, breaks = c(0,2,4,6))` zeichnet, oder aus der mit dem `table()`-Befehl erzeugten Tabelle.

### Häufige Fehler

- (b) Verwechslung der verzerrten Varianz  $s^2$  und der unverzerzten Varianz  $s_*^2$ .  
R berechnet immer die unverzerzte Varianz mit dem Befehl `var()`.
- (c) Bei einem (normierten) Histogramm steht auf der  $y$ -Achse die  $\frac{\text{relative Häufigkeit}}{\text{Klassenbreite}}$  und nicht  $\frac{\text{absolute Häufigkeit}}{\text{Klassenbreite}}$ .

### Verweis Informationsquellen

- (a) R-Skript S. 40 für `table()`, S. 32 für `sum()`
- (b) relative Häufigkeit: SDS1V02 1 – 7; Arithmetisches Mittel: SDS01V02: Folie 20 und R-Skript S. 32 ; Median: SDS01V02: Folie 20 und R-Skript S. 32; Varianz: SDS01V02: Folie 35 – 36 und R-Skript S. 32
- (c) SDS01V02 Folie: 1 – 19

### Aufgabe 2.

Von 1000 Verkehrsunfällen waren 380 mit tödlichem Ausgang. Bei 160 Unfällen mit Todesfolge war der Fahrer alkoholisiert. Insgesamt gab es 720 Verkehrsunfälle, bei denen der Fahrer nicht alkoholisiert war.

- (a) Erstellen Sie eine Kontingenztafel der absoluten Häufigkeitsverteilung mit Hilfe der im Text angegebenen Informationen.
- (b) Berechnen Sie in den folgenden Szenarien jeweils den Anteil an der Gesamtzahl der Unfälle:
- (i) Die Unfälle, die nicht tödlich endeten.
  - (ii) Die Unfälle mit Todesfolge, bei denen der Fahrer nicht alkoholisiert war.

**Hinweise zur Lösung:**  $T$  = Unfall endete tödlich,  $A$  = Fahrer war alkoholisiert.  $\bar{A}$  stellt das Komplementärereignis von  $A$  dar.

### Kontrollergebnis 2.:

(a)

|           | $A$ | $\bar{A}$ |      |
|-----------|-----|-----------|------|
| $T$       | 160 | 220       | 380  |
| $\bar{T}$ | 120 | 500       | 620  |
|           | 280 | 720       | 1000 |

- (b) (i) 0.62, (ii) 0.22.

### Lösungsweg:

(a)

|           | $A$        | $\bar{A}$  |             |
|-----------|------------|------------|-------------|
| $T$       | <b>160</b> | 220        | <b>380</b>  |
| $\bar{T}$ | 120        | 500        | 620         |
|           | 280        | <b>720</b> | <b>1000</b> |

**Fett** markierte Zahlen stammen aus dem Text. Die übrigen wurden durch Aufsummierung berechnet.  
*Beispiel:*  $380 - 160 = 220$ .

- (b) (i)  $f(\bar{T}) = \frac{620}{1000} = 0.62$
- (ii)  $f(T \cap \bar{A}) = \frac{220}{1000} = 0.22$

### Relevante Folien:

SDS01V03 Folie: 8 – 19

### Aufgabe 3.

Anne und Bobo stehen vor einer neuen Aufgabe. Im Rahmen eines Forschungsprojektes wurden von fünf Männern Gewicht (in kg) und Größe (in cm) erfasst. Im Laufe des Projektes soll unter anderem der Zusammenhang zwischen Gewicht und Größe einer Person untersucht werden. Anne und Bobo wollen mithilfe der empirischen Kovarianz ein Maß für die Stärke des linearen Zusammenhangs berechnen.

- (a) Anne hat ein Ergebnis von 153.88 kg·cm für die empirische Kovarianz zwischen Gewicht und Größe, Bobo ein Ergebnis von 1.5388 kg·m. Liegt einer der beiden falsch? Wodurch ließe sich der Unterschied in den Ergebnissen erklären?
- (b) Mit welcher Größe könnten die beiden den linearen Zusammenhang zwischen zwei Merkmalen noch überprüfen? Warum würde man bei der gleichen Stichprobe damit unabhängig von der Skalierung auf dasselbe Ergebnis kommen?
- (c) Berechnen Sie die Größe aus (b) aus den Rohdaten:

| Person  | 1   | 2   | 3   | 4   | 5   |
|---------|-----|-----|-----|-----|-----|
| Gewicht | 93  | 72  | 83  | 104 | 76  |
| Größe   | 198 | 160 | 167 | 199 | 182 |

**Hinweis:** Die Formel für die Kovarianz lautet:  $\widehat{Cov}(X, Y) = s_{XY} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}) \cdot (y_i - \bar{y})$

Auch hier ist die Anwendung des Verschiebungssatzes möglich:  $s_{XY} = \frac{1}{n} \sum_{i=1}^n (x_i y_i) - \bar{x} \bar{y}$

### Kontrollergebnis 3.:

- (a) Anne liegt "richtiger" als Bobo: Anne hat die Kovarianz mit der Größe in cm berechnet, während Bobo mit der Größe in Metern gerechnet hat. Inhaltlich sind beide Ergebnisse richtig. Allerdings lässt sich die Einheit der Kovarianz schlecht interpretieren.
- (b) Der Pearson'sche Korrelationskoeffizient ist eine auf das Intervall  $[-1; 1]$  standardisierte Größe zur Messung eines linearen Zusammenhangs zwischen zwei Merkmalen. Der Pearson'sche Korrelationskoeffizient ist dimensionslos, er hat also keine Einheit. Durch die Standardisierung erhält man unabhängig von der Skalierung hier das gleiche Ergebnis.
- (c)  $\hat{\rho}_{\text{Größe Gewicht}} = 0.836$ .

### Lösungsweg

- (a) Um zu erkennen, ob Annes oder Bobos Ergebnis falsch ist, berechnen wir zunächst die empirische Kovarianz.

$$\text{Formel für die Kovarianz: } s_{XY} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}) \cdot (y_i - \bar{y})$$

Wir sehen nun, dass der Mittelwert in der Formel enthalten ist. Also berechnen wir als erstes den Mittelwert von  $X$  und  $Y$ . Hierbei ist das Gewicht das Merkmal  $X$  und die Größe das Merkmal  $Y$ .

$$\text{Gewicht: } \bar{x} = \frac{1}{5} \cdot (93 + 72 + 83 + 104 + 76) = 85.6 \text{ kg}$$

$$\text{Größe: } \bar{y} = \frac{1}{5} \cdot (198 + 160 + 167 + 199 + 182) = 181.2 \text{ cm}$$

Nun berechnen wir mit der entsprechenden Formel die empirische Kovarianz („langer Weg“):

$$s_{XY} = \frac{1}{5} \cdot [(93 - 85.6) \cdot (198 - 181.2) + (72 - 85.6) \cdot (160 - 181.2) + (83 - 85.6) \cdot (167 - 181.2) + (104 - 85.6) \cdot (199 - 181.2) + (76 - 85.6) \cdot (182 - 181.2)] = 153.88 \text{ kg·cm}$$

Die berechnete Kovarianz nimmt einen Wert von 153.88 an. Somit haben wir das gleiche Ergebnis wie Anne, also ist ihr Ergebnis auf jeden Fall korrekt. Anne hat die Kovarianz wie wir mit der Größe in cm berechnet. Bobo hingegen hat die Kovarianz mit der Größe in m berechnet. Bobos Ergebnis ist an sich nicht inkorrekt, jedoch auf die Aufgabenstellung bezogen fehlerhaft. In der Aufgabe wird explizit erwähnt, dass die Größe in cm erfasst wurde, somit ist eine Veränderung des Index nicht korrekt und sollte vermieden werden.

(b) Die Stärke des negativen oder positiven linearen Zusammenhangs wird wie folgt interpretiert:

|                                       |         |
|---------------------------------------|---------|
| $0.0 <  \hat{\rho}_{XY}  < 0.3$       | schwach |
| $0.3 \leq  \hat{\rho}_{XY}  < 0.7$    | mittel  |
| $0.7 \leq  \hat{\rho}_{XY}  \leq 1.0$ | stark   |

(c) Hier sollen wir nun den Pearson'schen Korrelationskoeffizienten ausrechnen.

Formel für den Pearson'schen Korrelationskoeffizienten:  $\hat{\rho}_{XY} = \widehat{Cor}(X, Y) = \frac{s_{XY}}{s_X s_Y}$

Wir sehen, dass die Varianz in dieser Formel enthalten ist:  $s^2 = \frac{1}{n} \cdot \sum_{i=1}^n x_i^2 - \bar{x}^2$

Gewicht:  $\widehat{Var}(X) = s_X^2 = \frac{1}{5} \cdot (93^2 + 72^2 + 83^2 + 104^2 + 76^2) - 85.6^2 = 135.44$

Größe:  $\widehat{Var}(Y) = s_Y^2 = \frac{1}{5} \cdot (198^2 + 160^2 + 167^2 + 199^2 + 182^2) - 181.2^2 = 250.16$

Nun setzen wir die ausgerechneten Varianzen in die Formel für den Pearson'schen Korrelationskoeffizienten ein:

$$\hat{\rho}_{XY} = \widehat{Cor}(X, Y) = \frac{153.88}{\sqrt{135.44} \cdot \sqrt{250.16}} = 0.836$$

Der Pearson'sche Korrelationskoeffizient nimmt einen Wert von 0.836 an. Es existiert eine starke Korrelation zwischen Gewicht und Größe.

### Häufige Fehlerquellen

- (a) Häufig fehlerhafte Anwendung der Formel.
- (b) -
- (c) Häufig fehlerhafte Anwendung der Formel und inkorrekte Interpretation des Wertes.

### Verweis Informationsquellen

Kovarianz: SDS01V03 Folie: 27 – 33

Korrelation: SDS01V03 Folie: 34 – 39

#### Aufgabe 4.

Betrachten Sie die folgende Tabelle, in der die Bewertungen von 10 Filmen aus den Jahren 2015 und 2016 der Portale *Metacritic* und *Rotten Tomatoes* zusammengetragen wurden. Die Filme wurden auf einer Skala von 1 bis 10 bewertet:

| Film \ Portal                     | Metacritic | Rotten Tomatoes |
|-----------------------------------|------------|-----------------|
| Star Wars: Rogue One              | 6.5        | 8.5             |
| Hacksaw Ridge                     | 7.1        | 8.6             |
| Arrival                           | 8.1        | 9.4             |
| La La Land                        | 9.3        | 9.2             |
| Zoomania                          | 7.8        | 9.8             |
| Star Wars: Das Erwachen der Macht | 8.1        | 9.2             |
| Raum                              | 8.6        | 9.4             |
| Spotlight                         | 9.3        | 9.6             |
| Alles steht Kopf                  | 9.4        | 9.8             |
| Mad Max: Fury Road                | 9.0        | 9.7             |

- Stellen Sie die Daten in R graphisch dar. Lässt die Abbildung auf einen Zusammenhang zwischen den Bewertungen der Filme auf den beiden Portalen schließen?
- Berechnen Sie den Pearson'schen Korrelationskoeffizienten und den Spearman'schen Rangkorrelationskoeffizienten der Stichprobe per Hand und mit Hilfe von R.
- Bestätigt Ihr Ergebnis aus (b) Ihre Vermutung aus (a)? Über welche Art von Zusammenhängen trifft der Korrelationskoeffizient eine Aussage?

#### Kontrollergesult 4.:

- Es kann ein Zusammenhang vermutet werden. Filme, die auf einem Portal hoch bewertet werden, werden tendenziell auch auf dem anderen Portal hoch bewertet.
- Pearson'scher Korrelationskoeffizient:  $\hat{\rho}_{meta, rotten} = 0.752$   
Spearman'scher Rangkorrelationskoeffizient:  $\hat{\rho}_{rk(meta), rk(rotten)} = 0.551$
- Da der berechnete Korrelationskoeffizient (nach Pearson) mit 0.752 einen *starken* Zusammenhang aufzeigt, lässt sich die Vermutung eines Zusammenhanges bestätigen. Es handelt sich hierbei um einen positiven linearen Zusammenhang. Im Hinblick auf andere Zusammenhänge (z.B. quadratische) lässt der Korrelationskoeffizient keine Interpretation zu.

#### Lösungsweg

- Um die Daten in R graphisch darzustellen, kann man die Daten der Datensätze Metacritic und Rotten Tomatoes als Vektoren speichern.

```
Metacritic <- c(6.5,7.1,8.1,9.3,7.8,8.1,8.6,9.3,9.4,9.0)
RottenTomatoes <- c(8.5,8.6,9.4,9.2,9.8,9.2,9.4,9.6,9.8,9.7)
```

Nun ist es möglich, diese Daten mithilfe von `plot()` darzustellen:

```
plot(Metacritic, RottenTomatoes, xlab="Metacritic", ylab="RottenTomatoes")
```

Durch den Einsatz von `xlab` und `ylab` lassen sich die Achsen beschriften.  
Bewertung: siehe Lösung

- Hinweis:** In dieser Aufgabe sind immer Stichproben gegeben. Das heißt, dass alle Größen geschätzt werden. Daher werden Korrelationskoeffizienten, bedingte Häufigkeiten und empirische Kovarianzen bestimmt, da dies die Schätzer der tatsächlichen Größen (Korrelation zwischen zwei Zufallsvariablen  $Cor(X, Y)$ , die Wahrscheinlichkeiten  $P(X|Y)$ , oder Kovarianzen  $Cov(X, Y)$ ) sind. Gekennzeichnet werden Schätzer durch ein „Dach“ (z.B.  $\widehat{Var(X)}$ ) über dem jeweiligen Zeichen.

- (i) Pearson'scher Korrelationskoeffizient in R:  
`cor(Metacritic, RottenTomatoes, method = "pearson")`

Rechenweg per Hand:

$$(1) \hat{\rho}_{(X,Y)} = \widehat{Cor}(X, Y) = \frac{\widehat{Cov}(X, Y)}{\sqrt{\widehat{Var}(X) \cdot \widehat{Var}(Y)}}$$

$$\text{wobei: } \widehat{Cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n x_i y_i - \bar{x} \bar{y}$$

$$\text{mit: } \widehat{Var}(X) = s_x^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$$

$$\text{und: } \bar{x} = \frac{\sum_{i=1}^n x_i}{n}$$

$$(2) \bar{x} = \frac{6.5 + 7.1 + 8.1 + \dots + 9.0}{10} = 8.32$$

$$\bar{y} = \frac{8.5 + 8.6 + 9.4 + \dots + 9.7}{10} = 9.32$$

- (3) Mit den Werten  $\bar{x}$  und  $\bar{y}$  lassen sich nun die empirischen Varianzen errechnen.

$$\begin{aligned} \widehat{Var}(X) &= \frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_{10} - \bar{x})^2}{n} \\ &= \frac{(6.5 - 8.32)^2 + (7.1 - 8.32)^2 + \dots + (9.0 - 8.32)^2}{10} = 0.8796 \end{aligned}$$

$$\begin{aligned} \widehat{Var}(Y) &= \frac{(y_1 - \bar{y})^2 + (y_2 - \bar{y})^2 + \dots + (y_{10} - \bar{y})^2}{n} \\ &= \frac{(8.5 - 9.32)^2 + (8.6 - 9.32)^2 + \dots + (9.7 - 9.32)^2}{10} = 0.1916 \end{aligned}$$

alternativ mit dem Verschiebungssatz

- (4) Nun  $\widehat{Cov}(X, Y)$  bestimmen :

$$\begin{aligned} \widehat{Cov}(X, Y) &= \frac{1}{n} (x_1 \cdot y_1 + x_2 \cdot y_2 + \dots + x_{10} \cdot y_{10}) - (\bar{x} \cdot \bar{y}) \\ &= \frac{1}{10} (6.5 \cdot 8.5 + 7.1 \cdot 8.6 + \dots + 9.0 \cdot 9.7) - (8.32 \cdot 9.32) = 0.3086 \end{aligned}$$

- (5) Die errechneten Werte für die empirischen Varianzen und der empirischen Kovarianz nun in die Formel für den Pearson'schen Korrelationskoeffizienten einsetzen:

$$\widehat{Cor}(X, Y) = \frac{0.3086}{\sqrt{0.8796 \cdot 0.1916}} = 0.752$$

- (ii) Spearman'scher Rangkorrelationskoeffizient in R:  
`cor(Metacritic, RottenTomatoes, method = "spearman")`

Rechenweg per Hand:

$$(1) \hat{\rho}_{rk(X), rk(Y)} = \widehat{Cor}(rk(X), rk(Y)) = \frac{\widehat{Cov}(rk(x), rk(y))}{s_{rk(x)} s_{rk(y)}} = \frac{\frac{1}{n} \sum_{i=1}^n (rk(x_i) - \overline{rk(x)})(rk(y_i) - \overline{rk(y)})}{s_{rk(x)} s_{rk(y)}}$$

$$\text{alternativ: } = \frac{\sum_{i=1}^n (rk(x_i) - \overline{rk(x)})(rk(y_i) - \overline{rk(y)})}{\sqrt{(\sum_{i=1}^n rk(x_i)^2 - n \cdot \overline{rk(x)}^2)(\sum_{i=1}^n rk(y_i)^2 - n \cdot \overline{rk(y)}^2)}}$$

- (2) Zunächst müssen die Ränge der Filme gebildet werden. Das bedeutet, dass der schlechteste Film auf Platz 1 platziert wird, der nächste auf Platz 2 usw. Teilen sich zwei Filme einen Platz, so wird der Mittelwert der nächsten beiden Plätze gebildet. (vgl. Bindungen)

| Film \ Portal        | Metacritic Rang | Rotten Rang | Meta · Rotten | Meta <sup>2</sup> | Rotten <sup>2</sup> |
|----------------------|-----------------|-------------|---------------|-------------------|---------------------|
| Star Wars: Rogue One | 1               | 1           | 1             | 1                 | 1                   |
| Hacksaw Ridge        | 2               | 2           | 4             | 4                 | 4                   |
| Arrival              | 4.5             | 5.5         | 24.75         | 20.25             | 30.25               |
| La La Land           | 8.5             | 3.5         | 29.75         | 72.25             | 12.25               |
| Zoomania             | 3               | 9.5         | 28.5          | 9                 | 90.25               |
| Star Wars: VII       | 4.5             | 3.5         | 15.75         | 20.25             | 12.25               |
| Raum                 | 6               | 5.5         | 33            | 36                | 30.25               |
| Spotlight            | 8.5             | 7           | 59.5          | 72.25             | 49                  |
| Alles steht Kopf     | 10              | 9.5         | 95            | 100               | 90.25               |
| Mad Max: Fury Road   | 7               | 8           | 56            | 49                | 64                  |
| Summe                | 55              | 55          | 347.25        | 384               | 383.5               |

$$(3) \overline{rk(x)} = \overline{rk(y)} = \frac{55}{10} = 5.5$$

$$\text{alternativ: } \bar{R} = \frac{\sum_{i=1}^n R_i}{n} = \frac{\frac{n(n+1)}{2}}{n} = \frac{n+1}{2} = \frac{10+1}{2} = 5.5$$

Begründung: Wenn man die Summe aller Ränge berechnet, ist dies äquivalent zur Gauß'schen Summenformel:

$$\sum_{i=1}^n R_i = \sum_{i=1}^n i = \frac{n(n+1)}{2}$$

daraus ergibt sich:

$$n\bar{R}^2 = n \cdot \overline{rk(x)}^2 = n \cdot \overline{rk(y)}^2 = n \cdot \overline{rk(x)} \cdot \overline{rk(y)} = 10 \cdot 5.5^2 = 302.5$$

- (4) Nun müssen die Werte nur noch in die Formel für  $\widehat{Cor(rk(X), rk(Y))}$  eingesetzt werden:  
(Im Zähler jetzt ebenfalls Verschiebungssatz verwendet)

$$\begin{aligned} \hat{\rho}_{rk(X), rk(Y)} &= \frac{\sum_{i=1}^n (rk(x_i)rk(y_i)) - n \cdot \overline{rk(x)} \cdot \overline{rk(y)}}{\sqrt{(\sum_{i=1}^n rk(x_i)^2 - n \cdot \overline{rk(x)}^2)(\sum_{i=1}^n rk(y_i)^2 - n \cdot \overline{rk(y)}^2)}} \\ &= \frac{347.25 - 302.5}{\sqrt{(384 - 302.5)(383.5 - 302.5)}} = 0.551 \end{aligned}$$

(c) siehe Kontrolllösung

### Häufige Fehlerquellen

- (a) -
- (b) Formel wird falsch verwendet oder es werden falsche Werte eingesetzt. Aufgrund vieler Rechenschritte und vieler Zahlen können Fehler beim Eintippen in den Taschenrechner geschehen.
- (c) -

### Verweis Informationsquellen

- SDS01V03 Folie: 38 zur Berechnung des Korrelationskoeffizient nach Spearman
- SDS01V03 Folie: 34 – 35 zur Berechnung des Korrelationskoeffizient nach Pearson
- SDS01V03 Folie: 35, 29 zur Interpretation des Korrelationskoeffizienten.

### Aufgabe 5.

Gegeben seien zwei Maschinen  $X$  und  $Y$ , deren Ausfallhäufigkeit an 100 Tagen beobachtet wird.

Jede Maschine kann pro Tag maximal zweimal ausfallen, da durch die hierdurch bedingten Verzögerungen der Reparatur eine weitere Produktion am jeweiligen Tag und damit weitere Ausfälle nicht möglich sind.

Jede der beiden Maschinen weist folglich die Merkmalsausprägungen „0-mal ausgefallen“, „1-mal ausgefallen“ und „2-mal ausgefallen“ auf. Also können sowohl Merkmal  $X$  (Ausfallhäufigkeit der Maschine  $X$ /Tag) als auch Merkmal  $Y$  (Ausfallhäufigkeit der Maschine  $Y$ /Tag) die Ausprägungen „0“, „1“ und „2“ annehmen.

Die gemeinsamen absoluten und relativen Häufigkeiten, mit denen die oben angeführten Merkmalsausprägungen der konkreten Ausfallhäufigkeiten für Maschine  $X$  bzw. Maschine  $Y$  auftreten, ergeben sich aus folgender Häufigkeitstabelle.

- $X$  = Anzahl der Ausfälle pro Tag bei  $X$
- $Y$  = Anzahl der Ausfälle pro Tag bei  $Y$

| Maschine $X \setminus$ Maschine $Y$ | $Y = 0$ | $Y = 1$ | $Y = 2$ | $\sum$ |
|-------------------------------------|---------|---------|---------|--------|
| $X = 0$                             | 30      | 14      | 2       | 46     |
| $X = 1$                             | 18      | 10      | 2       | 30     |
| $X = 2$                             | 12      | 6       | 6       | 24     |
| $\sum$                              | 60      | 30      | 10      | 100    |

- Bestimmen Sie in R die relative Häufigkeitstabelle.
- Bestimmen Sie (händisch) die nachfolgenden Größen:  $f_{22}$ ,  $f_{2\bullet}$ ,  $\bar{X}$ ,  $\bar{Y}$ ,  $s_Y^2$ ,  $s_Y$ ,  $s_X^2$ ,  $s_X$   
Nach Vorlesungsnotation gilt:  $f$  = relative Häufigkeit.
- Berechnen Sie die empirische Kovarianz der Ausfallhäufigkeiten der beiden Maschinen. Was bedeutet das Vorzeichen bei der ermittelten Kovarianz? Kann der Wert der Kovarianz interpretiert werden?
- Berechnen Sie die Stärke des geschätzten Zusammenhangs mit einer geeigneten Größe.

### Kontrollergebnis 5.:

| Maschine $X \setminus$ Maschine $Y$ | $Y = 0$ | $Y = 1$ | $Y = 2$ | $\sum$ |
|-------------------------------------|---------|---------|---------|--------|
| $X = 0$                             | 0.30    | 0.14    | 0.02    | 0.46   |
| $X = 1$                             | 0.18    | 0.10    | 0.02    | 0.30   |
| $X = 2$                             | 0.12    | 0.06    | 0.06    | 0.24   |
| $\sum$                              | 0.60    | 0.30    | 0.10    | 1.0    |

- $f_{22} = 0.1$   
 $f_{2\bullet} = 0.3$   
 $\bar{X} = 0.78$   
 $\bar{Y} = 0.5$   
 $s_Y^2 = 0.45$   
 $s_Y \approx 0.671$   
 $s_X^2 \approx 0.652$   
 $s_X \approx 0.807$

- $\widehat{Cov}(X, Y) = 0.11$

Das positive Vorzeichen der empirischen Kovarianz impliziert, dass eine positive lineare Abhängigkeit zwischen den Ausfallhäufigkeiten beider Maschinen bestehen könnte. Allerdings kann von der Höhe der empirischen Kovarianz nicht auf die Stärke des Zusammenhangs der Merkmale  $X$  und  $Y$  geschlossen werden. Eine nähere Interpretation der empirischen Kovarianz ist somit nicht gegeben. Das Ergebnis ist mit Vorsicht zu betrachten, da der Zufall diese positive empirische Kovarianz hervorgerufen haben kann. Dies gilt für alle Schätzer.

- $\hat{\rho}_{X,Y} = 0.203$

Die Merkmale  $X$  und  $Y$  weisen eine positive Beziehung auf. Der Pearson Korrelationskoeffizient ( $\hat{\rho}_{X,Y}$ ) bewegt sich bei positiver linearer Abhängigkeit von  $X$  und  $Y$  grundsätzlich im Intervall ( $0 < \hat{\rho}_{X,Y} \leq 1$ ). Im gegebenen Beispiel liegt der Wert von  $\hat{\rho}_{X,Y}$  im unteren Bereich des Intervalls, so dass eine schwache positive, lineare Korrelation zwischen den Ausfällen/Tag der Maschine  $X$  und den Ausfällen/Tag der Maschine  $Y$  besteht.

### Lösungsweg

- (a) Siehe R-Lösung  
(b) benötigte Formeln für die relativen Häufigkeiten:

$$f_{jk} = f(a_j, b_k) = \frac{h_{jk}}{n} \text{ und } f_{j\bullet} = \frac{h_{j\bullet}}{n}$$

$f_{22} = f(X_2, Y_2)$  und  $X_2$  entspricht  $X = 1$ , da es das zweite  $X$  ist, das erste  $X$  ( $X_1$ ) wäre  $X = 0$ ,  $Y_2$  analog

$f_{2\bullet}$  entspricht der relativen Häufigkeit der Randverteilung von  $X_2$  ( $X = 1$ )

Zur Berechnung von  $\bar{X}$  werden die Randhäufigkeiten von  $X$  sowie die Anzahl der Ausfälle benötigt.

$$\bar{X} = \frac{1}{100} \cdot (0 \cdot 46 + 1 \cdot 30 + 2 \cdot 24) = 0 \cdot 0.46 + 1 \cdot 0.30 + 2 \cdot 0.24 = 0.78$$

$\bar{Y}$  analog

Zur Berechnung von  $s_X^2$  werden ebenfalls die Randhäufigkeiten von  $X$  sowie  $\bar{X}$  benötigt. Mit dem Verschiebungssatz und den relativen Randhäufigkeiten folgt:

$$s_X^2 = (0^2 \cdot 0.46 + 1^2 \cdot 0.30 + 2^2 \cdot 0.24) - 0.78^2 = 0.6516 \approx 0.652$$

$s_Y^2$  analog

$$s_X = \sqrt{s_X^2}$$

$s_Y$  analog

- (c) Die Formel für die Kovarianz lautet:

$$\widehat{Cov}(X, Y) = s_{XY} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}) \cdot (y_i - \bar{y}) = \frac{1}{n} \sum_{i=1}^n (x_i y_i) - \bar{x} \bar{y}$$

Für Häufigkeitstabellen mit den Ausprägungen  $a_i$  von  $X$ ,  $b_j$  von  $Y$  und relativen Häufigkeiten  $h_{ij}$  (also  $h_{ij} = \frac{n_{ij}}{n}$ ), lautet die äquivalente Formel:

$$\widehat{Cov}(X, Y) = s_{XY} = \sum_{i=1}^k \sum_{j=1}^l a_i b_j \cdot h_{ij} - \bar{x} \bar{y}$$

Berechnung mit relativen Häufigkeiten (dadurch fällt das  $\frac{1}{n}$  weg):

$$\begin{aligned} \widehat{Cov}(X, Y) &= [(0 \cdot 0 \cdot 0.30) + (0 \cdot 1 \cdot 0.14) + (0 \cdot 2 \cdot 0.02) + (1 \cdot 0 \cdot 0.18) + \dots] - 0.78 \cdot 0.5 \\ &= [(1 \cdot 1 \cdot 0.1) + (1 \cdot 2 \cdot 0.02) + (2 \cdot 1 \cdot 0.06) + (2 \cdot 2 \cdot 0.06)] - 0.78 \cdot 0.5 = 0.11 \end{aligned}$$

- (d)  $\widehat{Cor}(X, Y) = \hat{\rho}_{X,Y} = \frac{\widehat{Cov}(X,Y)}{s_X s_Y}$   
 $= \frac{0.11}{0.807 \cdot 0.671} = 0.203$

### Häufige Fehlerquellen

Formel für den Mittelwert, den Korrelationskoeffizienten und die empirische Kovarianz falsch anwenden.

### Verweis Informationsquellen

- (a) SDS01V03 Folie: 12 – 20  
(b) SDS01V03 Folie: 12 – 20  
(c) SDS01V03 Folie: 27 – 33  
(d) SDS01V03 Folie: 34 – 39

### Aufgabe 6.

Drei Teildatensätze aus der R-Sammeldatei finden in dieser Aufgabe Verwendung.

- Der Datensatz `groegewicht` enthält die Größe und Gewicht von 227 Studierenden aus dem Jahr 2000.
  - Der Datensatz `schein` enthält die Anzahl an Neuzulassungen von Personenkraftwagen und die Anzahl an Gefangenen in Deutschland von den Jahren 1998 – 2007.
  - Der Datensatz `QF` enthält 1000 Zufallszahlen einer Rechteckverteilung im Intervall  $[-1, 1]$  und deren Quadrate.
- (a) Stellen Sie die Punktwolken der drei Datensätze dar. Was sagt der Korrelationskoeffizient aus? Raten Sie die jeweiligen Korrelationskoeffizienten.
- (b) Bestimmen Sie für die drei Datensätze die Korrelationskoeffizienten mit Hilfe von R. Welche Schlüsse können Sie ziehen? Gehen Sie auf Korrelation vs. Kausalität ein.

**Hinweis:** Mit dem R-Befehl: `par(mfrow=c(nr, nc))` bzw. `par(mfcol=c(nr, nc))` können mehrere Plots in einer einzelnen Grafik abgebildet werden. `mfrow` bewirkt dabei eine Darstellung in Zeilen, `mfcol` in Spalten. Der Vektor `c(nr, nc)` gibt die Anzahl an Zeilen (`r`) und Spalten (`c`) an. Mit dem Befehl `dev.off()` kann diese Einstellung wieder gelöscht werden. Dadurch werden aber auch die zuvor erstellten Plots wieder gelöscht.

### Kontrollergesult 6.:

- (a) `par(mfrow=c(3,1))`  
`plot(schein)`  
`plot(groegewicht)`  
`plot(QF)`  
(`dev.off()` um die Einstellung "3 Plots untereinander" wieder zu löschen)

Korrelationskoeffizient: normiertes Maß für die Stärke des linearen Zusammenhangs

- Datensatz `schein`: Vermutlich geringe bis keine Korrelation, kleiner Korrelationskoeffizient
- Datensatz `groegewicht`: vermutlich Korrelation, großer Korrelationskoeffizient
- Datensatz `QF`: keine Korrelation, da kein linearer Zusammenhang, Korrelationskoeffizient um 0

- (b) `cor(schein)`  
`cor(groegewicht)`  
`cor(QF)`

Man kann nicht von unkorreliert auf unabhängig schließen. Datensatz `QF` hat eine sehr geringe Korrelation. Da der  $y$ -Wert aber das Quadrat des  $x$ -Wertes ist, sind  $x$  und  $y$  nicht unabhängig. Hier besteht ein quadratischer Zusammenhang.

Datensatz `schein` hat eine mittlere Korrelation, allerdings haben die Anzahl Neuzulassung PKW und die Anzahl Gefangene kaum direkten Einfluss aufeinander.

### Lösungsweg

- (a) siehe R-Lösung für zusätzliche Hinweise zum Zeichnen der Plots

### Häufige Fehlerquellen

- (a) Vergessen, `dev.off()` zu benutzen und sich bei den nächsten Plots wundern, warum sie wieder in der 3x1 Art dargestellt werden.
- (b) Hier werden die Korrelationskoeffizienten in Matrixform dargestellt. Relevant für die Aufgabe sind die Werte auf der Nebendiagonale.

### Verweis Informationsquellen

- (a) Intro2R Kapitel 8 (S.49-60)
- (b) SDS01V03 Folie: 34 – 39

### Aufgabe 7.

Installieren Sie das Paket dslabs in R.

```
install.packages("dslabs")  
library("dslabs")
```

Sie haben nun Zugriff auf den Teildatensatz `divorce_margarine`. Dieser enthält Informationen über den Margarineverbrauch und die Scheidungsrate im US-Bundesstaat Maine in den Jahren 2000 bis 2009.

- (a) Lassen Sie sich die Namen der Merkmale von `divorce_margarine` ausgeben.
- (b) Lassen Sie sich in einer Grafik die Daten als Punktwolke ausgeben, mit Margarineverbrauch auf der  $x$ - und Scheidungsrate auf der  $y$ -Achse
- (c) Berechnen Sie mit R den Pearson- und den Spearman- Korrelationskoeffizienten
- (d) Wie würden Sie den Zusammenhang der beiden Variablen anhand der Korrelationskoeffizienten beschreiben?
- (e) Der Gouverneurin von Maine wurde die von Ihnen erstellte Statistik mit der geschätzten Korrelation zugestellt. Als Verfechterin der wahren Liebe würde sie gerne die Scheidungsrate in ihrem Bundesstaat senken. Auf Grundlage der Statistik erlässt sie ein Margarineverbot. Für wie sinnvoll halten Sie den neuen Erlass? Denken Sie das Margarineverbot verringert die Scheidungsrate?
- (f) Haben Sie eine mögliche Erklärung für den Zusammenhang zwischen Margarineverbrauch und Scheidungsrate? Denken Sie auch über eine andere Variable nach, die sowohl den Margarineverbrauch als auch die Scheidungsrate beeinflussen könnte.

### Kontrollergesult 7.:

- (a) `names(divorce_margarine)`
- (b) `plot(divorce_margarine$margarine_consumption_per_capita, divorce_margarine$divorce_rate_maine)`
- (c) `cor(divorce_margarine$margarine_consumption_per_capita, divorce_margarine$divorce_rate_maine)`  
= 0.9925585

*Hinweis:* Im Befehl `cor` ist die Methode Pearson die default-Einstellung und muss daher nicht explizit aufgeschrieben werden.

```
cor(divorce_margarine$margarine_consumption_per_capita,  
divorce_margarine$divorce_rate_maine, method="spearman")  
= 0.9847319
```

- (d) Die beiden Korrelationskoeffizienten sind beide sehr nah an 1, somit würde man auf einen starken positiven linearen Zusammenhang schließen.
- (e) Trotz der hohen Korrelation zwischen Margarineverbrauch und Scheidungsrate ist es sehr unwahrscheinlich, dass es einen kausalen Zusammenhang zwischen beiden Variablen gibt.
- (f) Ein direkter kausaler Zusammenhang ist sehr unwahrscheinlich (Scheinkorrelation). Häufig gibt es bei einer Scheinkorrelation eine dritte Variable, von der die anderen beiden abhängig sind. Dies wäre in diesem Fall denkbar. Z.B. wird in wirtschaftlich schlechten Zeiten mehr Margarine gekauft, da sie günstiger ist als Butter, und in wirtschaftlich schlechten Zeiten gibt es mehr Scheidungen. Es ist bei Scheinkorrelationen allerdings auch genauso gut möglich, dass der Zusammenhang reiner Zufall ist.

### Lösungsweg

siehe R-Lösung für zusätzliche Hinweise

### Häufige Fehlerquellen

Man könnte fälschlicherweise denken, dass ein kausaler Zusammenhang zwischen Margarinekonsum und der Scheidungsrate besteht aufgrund des positiven Wertes des Korrelationskoeffizientens. Versuchen Sie zu überlegen, ob ein solcher Zusammenhang im Allgemeinen Sinn ergibt.