

Parameterschätzung

- Hinweise -
- Kontrollergebnisse -

Aufgabe 1.

Betrachten Sie die geometrisch verteilte Zufallsvariable X mit der für $p \in (0, 1)$ die folgende Wahrscheinlichkeitsfunktion gilt:

$$P(X = x) = \begin{cases} (1-p)^x p & \text{für } x = 0, 1, 2, \dots, \\ 0 & \text{sonst.} \end{cases}$$

Es wurden aus einer unabhängig und identisch wie X verteilten Zufallsstichprobe die Stichprobe $x_{11}, \dots, x_{1n}$ gezogen:

i	1	2	3	4	5
x_{1i}	11	15	77	17	12

- Berechnen Sie die jeweiligen Wahrscheinlichkeiten für die Ausprägungen aus der vorliegenden Stichprobe in Abhängigkeit von p .
- Verwenden Sie Ihre Ergebnisse aus Teil (a), um die Likelihood-Funktion für die vorliegende Stichprobe aufzustellen. Vereinfachen Sie soweit wie möglich.
- Berechnen Sie nun den Maximum-Likelihood-Schätzer $\hat{p}_{ML_1}$ auf Grundlage der Stichprobe.
- Leiten Sie den allgemeinen Maximum-Likelihood-Schätzer $\hat{p}_{ML}$ her (unabhängig von der Stichprobe). Überprüfen Sie Ihr Ergebnis aus Teil (c).

Kontrollergebnis 1.:

- $P(X = 11) = (1-p)^{11}p$,
 $P(X = 15) = (1-p)^{15}p$,
 $P(X = 77) = (1-p)^{77}p$,
 $P(X = 17) = (1-p)^{17}p$,
 $P(X = 12) = (1-p)^{12}p$
- $L(p) = (1-p)^{11}p \cdot (1-p)^{15}p \cdot (1-p)^{77}p \cdot (1-p)^{17}p \cdot (1-p)^{12}p = (1-p)^{132}p^5$
- $\hat{p} = 0.036$
- $\hat{p} = \frac{1}{1 + \bar{x}}$

Lösungsweg:

$$(c) \ln(L(p)) = \ln(1-p)^{132} + \ln p^5 = 132 \ln(1-p) + 5 \ln p$$

$$\Rightarrow \frac{d \ln(L(p))}{dp} = -\frac{132}{1-\hat{p}} + \frac{5}{\hat{p}} \stackrel{!}{=} 0$$

$$\frac{5}{\hat{p}} = \frac{132}{1-\hat{p}} \Leftrightarrow 5 - 5\hat{p} = 132\hat{p} \Leftrightarrow 5 = 137\hat{p} \Leftrightarrow \hat{p} = 0.036.$$

$$(d) L(p) = \prod_{i=1}^n (1-p)^{x_i} p = p^n (1-p)^{\sum_{i=1}^n x_i}$$

$$\ln(L(p)) = \ln p^n + \ln (1-p)^{\sum_{i=1}^n x_i} = n \ln p + \sum_{i=1}^n x_i \ln(1-p)$$

$$\frac{d \ln(L(p))}{dp} = \frac{n}{\hat{p}} + \sum_{i=1}^n x_i \frac{1}{1-\hat{p}} \cdot (-1) \stackrel{!}{=} 0$$

$$\frac{\sum_{i=1}^n x_i}{1-\hat{p}} = \frac{n}{\hat{p}}$$

$$\begin{aligned}\sum_{i=1}^n (x_i) \hat{p} &= n(1 - \hat{p}) \\ \sum_{i=1}^n (x_i) \hat{p} &= n - n\hat{p} \\ \sum_{i=1}^n (x_i) \hat{p} + n\hat{p} &= n \\ \hat{p} \left(\sum_{i=1}^n x_i + n \right) &= n \\ \hat{p} &= \frac{n}{\sum_{i=1}^n x_i + n} = \frac{\frac{n}{n}}{\frac{\sum_{i=1}^n x_i}{n} + \frac{n}{n}} \\ \hat{p} &= \frac{1}{1 + \bar{x}}\end{aligned}$$

Relevante Folien:
SDS1V08

Aufgabe 2.

Betrachten Sie die folgende, mit R generierte Zufallsstichprobe:

```
1 > rpois(5,3)
2 [1] 2 3 2 5 7
```

- Leiten Sie den Maximum-Likelihood-Schätzer $\hat{\lambda}_{ML}$ allgemein her und berechnen Sie den Schätzwert basierend auf der Stichprobe. Überprüfen Sie abschließend, ob es sich bei dem ermittelten Extrempunkt tatsächlich um ein Maximum handelt.
- Berechnen Sie die Abweichung des Schätzers $\hat{\lambda}_{ML}$ vom wahren Parameter λ .

Kontrollerggebnis 2.:

$$\begin{aligned}(a) \quad L(\lambda) &= \prod_{i=1}^n \frac{\lambda^{x_i}}{x_i!} e^{-\lambda} = \lambda^{\sum_{i=1}^n x_i} \cdot e^{-n\lambda} \cdot \prod_{i=1}^n \frac{1}{x_i!} \\ \Rightarrow \ln(L(\lambda)) &= \sum_{i=1}^n x_i \cdot \ln(\lambda) - n\lambda + \sum_{i=1}^n \ln\left(\frac{1}{x_i!}\right) \\ \Rightarrow \frac{d \ln(L(\lambda))}{d\lambda} &= \frac{\sum_{i=1}^n x_i}{\hat{\lambda}_{ML}} - n \stackrel{!}{=} 0 \Leftrightarrow \hat{\lambda}_{ML} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}.\end{aligned}$$

Stichprobe: $\hat{\lambda}_{ML} = 3.8$.

$$(b) \quad \hat{\lambda}_{ML} - \lambda = 3.8 - 3 = 0.8.$$

Lösungsweg:

- (a) 1. Likelihood-Funktion $L(\lambda)$ aufstellen. Dazu Wahrscheinlichkeitsfunktion für die entsprechende Verteilung identifizieren und n -mal multiplikativ verknüpfen:

$$L(\lambda) = \prod_{i=1}^n \frac{\lambda^{x_i}}{x_i!} e^{-\lambda} = \lambda^{\sum_{i=1}^n x_i} \cdot e^{-n\lambda} \cdot \prod_{i=1}^n \frac{1}{x_i!}$$

$$\text{Rechenregel: } \prod_{i=1}^n a^{x_i} = a^{\sum_{i=1}^n x_i}$$

2. Falls die Ableitung der Likelihood-Funktion $L(\lambda)$ aufgrund der multiplikativen Verknüpfung sehr schwer erscheint, wird $L(\lambda)$ zunächst logarithmiert:

$$\ln(L(\lambda)) = \sum_{i=1}^n (x_i) \cdot \ln(\lambda) - n\lambda + \sum_{i=1}^n \ln\left(\frac{1}{x_i!}\right)$$

$$\text{Logarithmusregel: } \ln\left(\prod_{i=1}^n x_i!\right) = \ln(x_1! \cdot x_2! \cdot \dots \cdot x_n!) = \ln(x_1!) + \ln(x_2!) + \dots + \ln(x_n!) = \sum_{i=1}^n \ln(x_i!)$$

3. Ableitung der Log-Likelihood-Funktion $\ln(L(\lambda))$ und Extrempunktbestimmung durch Nullsetzen:

$$\frac{d \ln(L(\lambda))}{d\lambda} = \frac{\sum_{i=1}^n x_i}{\hat{\lambda}_{ML}} - n \stackrel{!}{=} 0 \Leftrightarrow \hat{\lambda}_{ML} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$$

4. Überprüfen, ob Extrempunkt ein Hochpunkt ist:

$$\frac{d^2 \ln(L(\lambda))}{d^2 \lambda} = -\frac{\sum_{i=1}^n x_i}{\hat{\lambda}_{ML}^2} < 0$$

Relevante Folien:
SDS1V08

Aufgabe 3.

Gehen Sie auf finance.yahoo.com und suchen Sie nach der Sartorius Aktiengesellschaft (SRT3.DE). Über den Reiter Historical Data können Sie die Preise vom 18. Mai 2015 bis 18. Mai 2020 einsehen und als .csv Datei herunterladen.

- (a) Lesen Sie die Daten ein und speichern Sie sie als `srt` ab. Verschaffen Sie sich anschließend über den `head()`-Befehl einen Überblick über den Datensatz.
Empfehlung: Verwenden Sie beim Einlesen der Daten den `read.csv()`-Befehl.
- (b) Wählen Sie die Spalte mit den `adjusted closing prices` aus und berechnen Sie ihre tägliche prozentuale Änderung (log-returns) $x_t = \log(y_t/y_{t-1})$ und speichern diese ab. Verwenden Sie dazu den Befehl `logr <- diff(log(srt[,6]))`.
- (c) Stellen Sie die log-returns in einem normierten Histogramm mit 20 Klassen dar.

Nach Sicht können Sie für die log-returns eine Normalverteilung annehmen. Des Weiteren schätzen Sie nach Sicht für den Verteilungsparameter μ den Wert Null. Nun wollen Sie anhand der Maximum-Likelihood-Methode aus den Daten einen Schätzer für die Varianz der log-returns herleiten.

- (d) Schreiben Sie eine Funktion für die log-Likelihoodfunktion der vorliegenden log-returns. Verwenden Sie dabei die Annahme einer Normalverteilung mit $\mu = 0$. Also $\log r \sim N(0, \sigma^2)$

Hilfestellungen:

- Die Funktion soll einen variablen Funktionsparameter, nämlich den Verteilungsparameter σ , besitzen.
- Definieren Sie in der Funktion zunächst die Dichtefunktion auf Grundlage der Daten der log-returns und der vorgenommenen Annahmen.
- Definieren Sie anschließend die log-Likelihoodfunktion, indem Sie folgende Beziehung ausnutzen:
 $\log \prod_i^n x_i = \sum_1^n \log x_i$.
- Die Funktion soll zuletzt die log-Likelihoodfunktion zurückgeben.

- (e) Führen Sie eine Optimierung Ihrer Funktion aus Teil (d) durch. Verwenden Sie dazu den Befehl `optimize()`. Die Syntax lautet `optimize(Funktion, Vektor für Wertebereich, ...)`.

Hilfestellungen:

- Es muss ein Intervall angegeben werden, in welchem das Optimum bestimmt wird. Wählen Sie das Intervall passend zu den Daten aus, dies bedeutet: wählen Sie die Untergrenze für den Wertebereich von σ anhand Ihrer statistischen Kenntnisse und die Obergrenze anhand der Grafik aus Teil (c).
- Die Funktion `optimize()` führt als Default-Einstellung immer eine Minimierung durch. Mit dem optionalen Argument `maximum = TRUE` kann jedoch auch eine Maximierung erfolgen.
- In `$maximum` der Ausgabe der `optimize()`-Funktion wird die Stelle des Maximums angegeben.
- Nähere Informationen zum `optimize()`-Befehl finden Sie in der Hilfe in R-Studio

- (f) Geben Sie den Schätzwert für die Varianz an. Beachten Sie: in dem Befehl `dnorm` ist der Verteilungsparameter σ anzugeben, Sie möchten aber einen Schätzer für σ^2 .
- (g) Ein Kommilitone bittet Sie um Hilfe. Er hat dieselbe Untersuchung noch für den Aktienkurs eines anderen Unternehmens durchgeführt. Dort erhielt er einen Schätzwert für die Varianz in Höhe von 0.00083468. Ihr Kommilitone beschreibt sich selbst als eher risikoavers. Er fragt Sie nun, welche der beiden Investitionsmöglichkeiten besser für ihn geeignet sei. Begründen Sie.

Kontrollergesult 3.:

- (a) Beispielhaft mit Pfad der Datei: `srt <- read.csv("C:/Users/Name/Desktop/Ordner/SRT3.DE.csv", header=TRUE)`
- (c) `hist(logr,breaks=21,prob=TRUE)`
Aber hier stellt `breaks` nur einen Vorschlag dar, R verwendet komplexe Berechnungen, wodurch es nicht $21 - 1 = 20$ Klassen sein müssen. Daher folgenden Befehl benutzen:
`hist(logr, breaks = seq(min(logr), max(logr), length.out = 21), prob = TRUE)`
Hier wird R gezwungen im Bereich der Daten $n = 20$ Klassen zu setzen, da $n + 1 = 20 + 1 = 21$ Grenzen gesetzt werden. (Auch "unsichtbare" Klassen, also leere Klassen, müssen mitgezählt werden.)
- (d) Lösungsvorschlag:

```
logL <- function(sigma){
  f <- dnorm(logr,0,sigma)
  l <- sum(log(f))
  return(l)
}
```

(e) `max_l <- optimize(logL,c(0,0.1), maximum = TRUE)`

(f) Lösungsvorschlag:

```
sigma_hat <- max_l$maximum  
sigma_hat^2  
[1] 0.0004957461
```

(*Hinweis:* Da hier ein numerisches Optimierungsverfahren angewandt wird, kann Ihr Ergebnis leicht abweichen. Es sollte allerdings ein Wert um 0.000496 herauskommen.)

(g) Der Schätzwert der Varianz für den zweiten Kurs ist höher. Dies deutet darauf hin, dass die Preise dort stärker schwanken. Für einen risikoaversen Investor ist eher der stabilere Kurs zu empfehlen, also hier die erste Investitionsmöglichkeit (Sartorius).

Häufige Fehlerquellen:

Stellen Sie sicher, dass Sie die Daten von SRT3.DE und nicht SRT.DE verwenden. Stellen Sie zudem sicher, dass Sie die richtigen Daten (18.05.2015 bis 18.05.2020) verwenden.

(d) Falls Sie sich an dem Lösungsvorschlag orientieren, beachten Sie, dass 1 hier ein kleines L und nicht die Zahl 1 bezeichnet.

Verweis Informationsquellen: enumitem

(a) Intro2R: S. 40–41

(b) Intro2R: S. 42

(d) Intro2R: S. 37–39

(e) Intro2R: S. 37–39