

Regression

- Hinweise -
- Kontrollergebnisse -

Aufgabe 1.

Im R-Datensatz sind der Teildatensätze BIP und Einkommen hinterlegt. Die Datensätze sind in der Matrix ProKopf zusammengefasst. Sie stellen das Bruttoinlandsprodukt pro Kopf und das Bruttonationaleinkommen pro Kopf in den einzelnen Bundesländer jeweils in Tausend Euro dar.

- Stellen Sie die Punktwolke mit dem Bruttonationaleinkommen auf der Abszisse (x -Achse) und das Bruttoinlandsprodukt auf der Ordinate (y -Achse) dar.
Beschriften Sie zusätzlich die einzelnen Punkte mit den Bundesländern. (Hinweis: Die Namen der Bundesländer sind im Vektor Land gespeichert.)
- Passen Sie eine Gerade mit Hilfe der Methode der kleinsten Quadrate an die Daten an und lassen Sie sich die geschätzte Gerade in die bestehende Zeichnung mit einzeichnen.
- Lassen Sie sich eine Zusammenfassung der Regression ausgeben und erklären Sie die folgenden Komponenten:
 - Residuals
 - Estimate
 - Std. Error
 - t-value und p-value
 - Significance codes
 - degrees of freedom
 - R-squared
 - F-Statistic
- Bestimmen Sie für den Steigungsparameter ein Konfidenzintervall zum Konfidenzniveau 0.99. Lassen Sie sich dafür die benötigten Quantile mit R berechnen. Überprüfen Sie Ihre Ergebnisse mit der `confint()`-Funktion.
- Welche Nullhypothese wird mit t-value geprüft? Wie wird der t-value berechnet?
- Bestimmen Sie den p -Wert zum t -Test des Steigungsparameters selbst und führen Sie anhand dessen die Testentscheidung durch. Welchen Zusammenhang gibt es zu dem in d) bestimmten Konfidenzintervall?
- Rufen Sie die Residuen auf. Bestimmen Sie: Minimum, Maximum, Median, 1. und 3. Quartil.

Kontrollergebnis 1.:

- ```
plot(Einkommen,BIP)
text(Einkommen,BIP,Land,pos=2)
```
- ```
lm(BIP ~Einkommen)
abline(lm(BIP~Einkommen),col= "turquoise4",lwd=2)
```
- ```
summary(lm(BIP~Einkommen))
```

  - Residuals: Lagemaße der Residuenverteilung
  - Estimate: Koeffizienten, geschätzte Werte für die  $\beta_i$  (Achsenabschnitt und Steigungsparameter)
  - Std. Error: Standardabweichungen der Koeffizienten
  - t-value und p-value: Teststatistik und zugehöriger  $p$ -Wert für die Hypothesen:  
 $H_0 : \beta_i = 0$   
 $H_1 : \beta_i \neq 0$
  - Significance codes: Markierte Werte liegen immer im angegebenen Intervall, z.B.:  
‘\*\*\*’:  $p$ -Wert liegt zwischen 0 und 0.001
  - degrees of freedom: Freiheitsgrade mit  $n - k = n - p - 1$
  - R-squared =  $R^2$ : Anteil der Streuung in  $y$ , die durch das Modell erklärt wird
  - F-Statistic: Prüft die Hypothese: Alle Steigungsparameter (ohne  $\beta_0$ ) sind gleich 0 (haben keinen Einfluss)
- ```
Untergrenze <- 1.299 - qt(0.995,14) * 0.1435
Obergrenze <- 1.299 + qt(0.995,14) * 0.1435
c(Untergrenze,Obergrenze)
confint(lm(BIP~Einkommen), level=0.99)
```

- (e) Nullhypothese $H_0 : \beta_i = 0$
Alternativhypothese $H_1 : \beta_i \neq 0$

$$T = \frac{\hat{\beta}_i - b}{\hat{\sigma}_{\hat{\beta}_i}} \text{ mit } b = 0 \rightarrow \text{daher } T = \frac{\hat{\beta}_i}{\hat{\sigma}_{\hat{\beta}_i}}$$

für den Achsenabschnitt: $T_{\hat{\beta}_0} = \frac{-9.6615}{4.6013} = -2.100$

für die Steigung: $T_{\hat{\beta}_1} = \frac{1.299}{0.1435} = 9.052$

- (f) $p\text{-Wert} = 2 * (1 - \text{pt}(9.05, 14))$
Konfidenzintervalle und Hypothesentests beruhen alle auf der gleichen Information, deshalb führen beide zu gleichen Schlussfolgerungen. Wenn wir für eine Regression z.B. die Nullhypothese $H_0 : \beta_i = 0$ testen möchten und das entsprechende empirische Konfidenzintervall den Nullpunkt überdeckt, dann folgt daraus, dass wir obige Nullhypothese nicht ablehnen können. Dies gilt jedoch nur bei zweiseitigen Hypothesentests mit gleichem α .
- (g) `residuen <- residuals(lm(BIP ~ Einkommen))`
`min(residuen)`
`quantile(residuen, probs = 0.25)`
`median(residuen)`
`quantile(residuen, probs = 0.75)`
`max(residuen)`

Schneller geht es mit dem Befehl: `summary(residuen)`

Lösungsweg

- (a) Mit `ProKopf` wird zunächst der Teildatensatz aus dem allgemeinen R-Datensatz aufgerufen. Eine (2D-)Grafik zeichnet R zu den gegebenen Daten mit dem `plot(x,y)`-Befehl. Mit dem BNE pro Kopf (hier Einkommen genannt) auf der Abzisse und dem BIP pro Kopf (hier BIP genannt) auf der Ordinate ergibt sich `plot(Einkommen,BIP)`. Mit `text(Einkommen,BIP,Land,pos=2)` lassen sich die Datenpunkte zusätzlich mit dem Namen der jeweiligen Bundesländern beschriften, wobei 'pos=' die Position der Beschriftung relativ zum Datenpunkt angibt (1: unterhalb des Punktes, 2: links, 3: oberhalb, 4: rechts).
- (b) Die Gerade bzw. das lineare Regressionsmodell passt R automatisch mit dem `lm(y~x)`-Befehl an und erzeugt einen Output mit Schätzern für β_0 (Intercept) sowie alle weiteren β_i . Da das BIP durch das BNE erklärt werden soll, lautet der Befehl in diesem Fall `lm(BIP ~ Einkommen)`. Der Output liefert $\hat{\beta}_0 = -9.661$ und $\hat{\beta}_1 = 1.299$. Mit diesen beiden Werten kann nun mit `abline(a=-9.661, b=1.299)` eine Gerade in die bestehende Graphik eingezeichnet werden.
- (c) Mit dem `summary(lm(BIP ~ Einkommen))`-Befehl gibt R eine Zusammenfassung der Regression aus. Die abgefragten Komponenten lassen sich wie folgt erklären:
- `Residuals` gibt die Residuenverteilungslagemaße an: Minimum und Maximum (Extrema) sowie Quartile. Es sind also beispielsweise 75% der Residuen ≤ 0.9573 .
 - `Estimate` gibt den Schätzwert für β_0 sowie alle weiteren β_i an (in diesem Fall $\hat{\beta}_0$ und $\hat{\beta}_1$).
 - `Std. Error` nennt die Standardabweichung der Koeffizienten, d.h. die Streuung der geschätzten Regressionsgeradenkoeffizienten $\hat{\beta}_0$ und $\hat{\beta}_1$ um die „wahren“ β_0 und β_1 (allgemein: die Streuung einer Schätzfunktion $\hat{\vartheta}$ um den „wahren“ ϑ der jeweiligen Grundgesamtheit).
 - `t-value` ist die Prüfgröße bzw. Teststatistik des Hypothesentests, mit der auf Signifikanz des jeweiligen Koeffizienten ($H_0: \beta_i = 0$ vs. $H_1: \beta_i \neq 0$) getestet werden kann (zur Berechnung s. Aufgabenteil (e)). Der `p-value` ist der zu der jeweiligen Hypothese (also $\beta_0 = 0$ vs. $\beta_0 \neq 0$ und $\beta_1 = 0$ vs. $\beta_1 \neq 0$) gehörige `p-Wert`, d.h. das kleinste Signifikanzniveau, zu dem die jeweilige H_0 verworfen und H_1 als statistisch bewiesen erachtet werden kann.
 - `Significance codes` sind visuelle Codes/Marker für den `p-Wert`: '***' bspw. bedeutet „hat `p-Wert` von < 0.001 “, '**' wiederum „hat `p-Wert` von < 0.01 “ usw. Der Signifikanzcodebereich ist also eine Legende für die sich neben den Schätzern befindlichen Sterne.
 - `degrees of freedom/DF/df/dof`, im deutschen Freiheitsgrade, können durch $n - k = n - p - 1$ berechnet werden und meinen die Werte, die in der Berechnungsformel frei variiert werden dürfen (deshalb verringert sich ihre Anzahl mit jedem festen Parameter um 1 bzw. es muss von n die Anzahl k der Parameter abgezogen werden).

- R-squared bzw. R^2 (auch Bestimmtheitsmaß) gibt den Anteil der erklärten y -Streuung an der Gesamtstreuung des Modells an. Es ist somit ein Modellgütekriterium bzw. Modellselektionsrichtwert.
- Die F-statistic ist die Prüfgröße bzw. Teststatistik des sogenannten overall-F-Tests, dem Test auf Einfluss wenigstens bzw. mindestens eines ϑ . Getestet wird also $H_0 : \beta_1 = \beta_2 = \dots = \beta_n = 0$ vs. $H_1 : \exists \beta_i$ mit $\beta_i \neq 0$. Wichtig zu beachten ist hier, dass sich der overall-F-Test nur auf die Steigungsparameter und nicht auf den Achsenabschnitt (β_0 bzw. Intercept) bezieht.

(d) Es gelten folgende Berechnungsformeln für ein $(1 - \alpha)$ -Konfidenzintervall für β_0 und β_1 :

- $\beta_0 : \hat{\beta}_0 \pm \hat{\sigma}_{\hat{\beta}_0} t_{1-\frac{\alpha}{2}, n-2}$
- $\beta_1 : \hat{\beta}_1 \pm \hat{\sigma}_{\hat{\beta}_1} t_{1-\frac{\alpha}{2}, n-2}$

→ Konfidenzintervall ober- und -untergrenze für den Steigungsparameter = $1.299 \pm 0.1435 \cdot t_{0.995, 14}$

Das benötigte Quantil, ein $(1 - \alpha) - t$ -Quantil mit df Freiheitsgraden (s. (c)), errechnet R über:

$qt(1 - \frac{\alpha}{2}, df) = qt(0.995, 14) = 2.976843$.

Somit ergibt sich ein Konfidenzintervall von $[0.872, 1.726]$.

Überprüfen lässt sich das Ergebnis ganz einfach mit dem `confint(lm(y ~ x), level = ...)`-Befehl, wobei `level` dem Konfidenzniveau entspricht. Hier:

`confint(lm(BIP ~ Einkommen), level=0.99) = [0.8717581, 1.726322]`,

was gerundet dem händischen Ergebnis entspricht.

(e) Es handelt sich um einen t -Test (Überprüfung eines Koeffizientens mithilfe der t -Verteilung). Das Hypothesenpaar lautet:

$$H_0 : \beta_i = b \text{ vs. } H_1 : \beta_i \neq b, \text{ wobei } T = \frac{\hat{\beta}_i - b}{\sqrt{\text{Var}(\hat{\beta}_i)}}.$$

Die Wurzel der Varianz ergibt allgemein die Standardabweichung. Im vorliegenden Fall wird die Wurzel aus der

Varianz der Koeffizientenschätzer gezogen. Es ergibt sich also $T = \frac{\hat{\beta}_i - b}{\hat{\sigma}_{\hat{\beta}_i}} = \frac{\text{Estimate} - b}{\text{Std. Error}}$.

Da im vorliegenden Fall auf Signifikanz der Koeffizienten getestet wird ($H_0 : \beta_i = 0$ vs. $H_1 : \beta_i \neq 0$), gilt $b = 0$

und entsprechend $T = \frac{\hat{\beta}_i}{\hat{\sigma}_{\hat{\beta}_i}}$. Demnach ergeben sich $T_{\hat{\beta}_0} = \frac{-9.6615}{4.6013} = -2.100$ und $T_{\hat{\beta}_1} = \frac{1.299}{0.1435} = 9.052$.

(f) $p\text{-Wert} = P(\text{Beobachtungen} \in \text{Ablehnungsbereich} | H_0) = \text{Fläche jenseits der Prüfgröße des Hypothesentests.}$

Der vorliegende Hypothesentest ist beidseitig, die Prüfgröße beträgt 9.05 und die t -Verteilung hat 14 Freiheitsgrade. Dementsprechend erhalten wir die Fläche rechts und links von der Prüfgröße in R mit:

$$1 - pt(9.05, 14) + pt(-9.05, 14) = 2(1 - pt(9.05, 14)) = \frac{3.169158}{107} \approx 0.000.$$

Je nach gewähltem Signifikanzniveau α kann die Testentscheidung ($|T| > t_{1-\frac{\alpha}{2}, n-2} \Rightarrow H_0$ verwerfen) grundsätzlich unterschiedlich ausfallen. Da der p -Wert, also das kleinste mögliche Signifikanzniveau, zu dem H_0 gerade noch abgelehnt werden kann, hier jedoch ≈ 0.000 ist, kann H_0 erst recht zu den viel größeren Signifikanzniveaus von $\alpha = 0.01$, $\alpha = 0.05$ und $\alpha = 0.1$ abgelehnt werden (also zu allen gängigen Signifikanzniveaus).

Zusammenhang mit dem in (d) bestimmten Konfidenzintervall:

In (d) haben wir bestimmt, dass β_1 mit einer Wahrscheinlichkeit von (durchschnittlich) 99%, also zum Signifikanzniveau von 0.01, $\in [0.872, 1.726]$. Somit gilt, dass zu einem Signifikanzniveau von 0.01 $\beta_1 \neq 0$ gilt und damit beim Hypothesentest $H_0 : \beta_1 = 0$ zum Signifikanzniveau von 0.01 abgelehnt werden muss.

(g) Residuen können in R mit dem `residuals()`-Befehl aufgerufen werden.

Hier also: `residuals(lm(BIP ~ Einkommen))`

Um diesen Befehl nicht bei jeder Berechnung der einzelnen Lagemaße wiederholen zu müssen, wird der Befehl von Anfang an dem Objekt "residuen" zugeordnet:

`residuen <- residuals(lm(BIP ~ Einkommen))`.

Danach werden die jeweiligen Befehle mit "residuen" als Argument ausgeführt (s. Kontrollerggebnis).

Hinweise

- Bei den Residuals im Output des `summary(lm(BIP ~ Einkommen))`-Befehls handelt es sich um die Residuenverteilungslagemaße, was nicht mit den Residuen selbst, also der Vorhersage-Beobachtungs-Differenz $y_i - \hat{y}_i = y_i - \hat{\beta}_0 + \hat{\beta}_1 x_1$, verwechselt werden darf.

- R^2 ist kein besonders gutes Modellgütekriterium, da es automatisch mit der Anzahl der Einflussvariablen wächst (vgl. Kapitel SM1 F96)
- Da in dieser Aufgabe nur ein einziger β_i mit $i \geq 1$ vorliegt, handelt es sich hier bei dem overall- F -Test, dessen Prüfgröße R im Allgemeinen im summary-Output unter F -statistic listet, tatsächlich wie beim t -Test, dessen Prüfgröße unter t -value gelistet wird, um einen Test auf die Signifikanz von β_1 .
- Bei der in (d) verwendeten Formel zur Konfidenzintervallbestimmung ersetzt man die t -Verteilung durch die Standardnormalverteilung sofern $n - 2 > 30$ ist (vgl. Kapitel SM1 F43).
- Statt in (g) alle Lagemaße einzeln zu berechnen, kann man auch alle fünf auf einmal via `quantile(residuen)` abrufen.

Verweis Informationsquellen SDS1V13

Aufgabe 2.

Aus dem Datensatz `bodyfat` wurde ein kleines, zufälliges Sample entnommen. An die Datenpaare (x_i, y_i) soll das Modell $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ mit $E(\varepsilon_i) = 0$ und $Var(\varepsilon_i) = \sigma^2$ angepasst werden. X beschreibt den Handgelenkumfang und Y den Körperfettanteil.

i	1	2	3	4	5
x_i	18.7	16.5	18.8	19.0	18.5
y_i	29.6	25.3	13.5	12.9	22.1

- Schätzen Sie die Parameter nach der Methode der kleinsten Quadrate und geben Sie die Gleichung für die geschätzte beste Gerade in der Form $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ an.
- Prognostizieren Sie $\hat{y}_i$ für alle Beobachtungen.
- Berechnen und interpretieren Sie das Bestimmtheitsmaß R^2 .
- Berechnen Sie die Residuen.
- Rufen Sie den gesamten Datensatz in R auf (zusätzliche .csv-Datei) und vergleichen Sie Ihre Ergebnisse. Wie erklären Sie sich die Unterschiede?

Hinweis: Beachten Sie das Dezimaltrennzeichen in der .csv-Datei und passen Sie das Argument `dec` im `read.csv()`-Befehl entsprechend an.

Kontrollergebnis 2.:

$$(a) \hat{\beta}_1 = \frac{1878.72 - \frac{1}{5} \cdot (91.5 \cdot 103.4)}{1678.63 - 5 \cdot 18.3^2} = -3.230$$

$$\hat{\beta}_0 = \frac{103.4}{5} + 3.22967 \cdot \frac{91.5}{5} = 79.783$$

$$\hat{y}_i = 79.783 - 3.230 \cdot x_i$$

$$(b) \hat{y} = [19.388, 26.493, 19.065, 18.419, 20.034]$$

$$(c) R^2 = 0.203$$

Interpretation:

- Es gilt $0 \leq R^2 \leq 1$.
- Je näher R^2 bei 1 liegt, desto kleiner $\sum (y_i - \hat{y}_i)^2$, d.h. desto besser die Anpassung. Für $R^2 = 1$ liegen alle Punkte auf der Regressionsgeraden.
- Je näher R^2 bei 0 liegt, desto größer $\sum (y_i - \hat{y}_i)^2$, d.h. desto schlechter die Anpassung. Für $R^2 = 0$ gilt $\hat{y}_i = \bar{y}$, d.h. die Vorhersage $\hat{y}_i$ ist unabhängig von X .

Das R^2 liegt hier bei 0.203, das heißt, dass 20.3% der Varianz erklärt werden kann.

$$(d) \varepsilon = [10.212, -1.193, -5.565, -5.519, 2.066]$$

(e)

```
data <- read.csv("Bodyfat.csv", dec = ",")
plot(bodyfat ~ Wrist, data=data, xlab="Wrist circumference", ylab="Bodyfat")
mod2 <- lm(bodyfat ~ Wrist, data=data)
```

summary(mod2)

Da nur eine sehr kleine Stichprobe aus dem ursprünglichen Datensatz entnommen wurde, ist die Schätzung der Parameter aus (a) - (d) ungenauer. Die Stichprobe wurde zufällig entnommen, daher wurde statt der positiven Beziehung zwischen Handgelenksumfang und Körperfettanteil im Gesamtdatensatz ein negatives $\hat{\beta}_1$ mit dem Sample berechnet.

Lösungsweg

(a)

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n x_i y_i - \frac{1}{n} (\sum_{i=1}^n x_i \cdot \sum_{i=1}^n y_i)}{\sum_{i=1}^n x_i^2 - n \bar{x}^2} = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$$

$$\sum_{i=1}^5 x_i y_i = 18.7 \cdot 29.6 + \dots + 18.5 \cdot 22.1 = 1878.72$$

$$\bar{x} = \frac{1}{5} \cdot \sum_{i=1}^5 x_i = \frac{1}{5} \cdot (18.7 + \dots + 18.5) = \frac{1}{5} \cdot 91.5 = 18.3$$

$$\bar{y} = \frac{1}{5} \cdot \sum_{i=1}^5 y_i = \frac{1}{5} \cdot (29.6 + \dots + 22.1) = \frac{1}{5} \cdot 103.4 = 20.68$$

$$\sum_{i=1}^5 x_i^2 = 18.7^2 + \dots + 18.5^2 = 1678.63$$

$$\hat{\beta}_1 = \frac{1878.72 - 5 \cdot 18.3 \cdot 20.68}{1678.63 - 5 \cdot 18.3^2} = \frac{-13.5}{4.18} = -3.229665072 \approx -3.230$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \cdot \bar{x} = 20.68 - (-3.229665072) \cdot 18.3 = 79.78287082 \approx 79.783$$

$$\hat{y}_i = 79.783 - 3.230 \cdot x_i$$

(b) Berechnung mit ungerundeten Werten, also: $\hat{y}_i = 79.78287082 - 3.229665072 \cdot x_i$

$$\hat{y}_1 = 79.78287082 - 3.229665072 \cdot 18.7 = 19.38815024 \approx 19.388$$

$$\hat{y}_2 = 79.78287082 - 3.229665072 \cdot 16.5 = 26.49341339 \approx 26.493$$

analog für $\hat{y}_3, \hat{y}_4, \hat{y}_5$

$$\hat{y} = [19.388, 26.493, 19.065, 18.419, 20.034]$$

(c) Allgemeine Formel: $R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$

Berechnung mit ungerundeten Werten:

$$R^2 = \frac{\sum_{i=1}^5 (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^5 (y_i - \bar{y})^2} = \frac{(19.38815024 - 20.68)^2 + \dots + (20.03408325 - 20.68)^2}{(29.6 - 20.68)^2 + \dots + (22.1 - 20.68)^2} \approx 0.203$$

(d) Allgemeine Formel: $\hat{\epsilon}_i = y_i - \hat{y}_i$

$$\hat{\epsilon}_1 = 29.6 - 19.38815024 \approx 10.212$$

$$\hat{\epsilon}_2 = 25.3 - 26.49341339 \approx -1.193$$

analog für $\hat{\epsilon}_3, \hat{\epsilon}_4, \hat{\epsilon}_5$

$$\hat{\epsilon} = [10.212, -1.193, -5.565, -5.519, 2.066]$$

(e) s. Kontrollergebnis

Hinweise

Immer mit ungerundeten Werten weiterrechnen und nicht mit den gerundeten, da es sonst teilweise zu anderen Ergebnissen kommt wie es bspw. der Fall bei (b) wäre.

Verweis Informationsquellen SDS1V13

Aufgabe 3.

Die Piggy Bank möchte den Einfluss verschiedener Faktoren auf das Sparverhalten ihrer Kunden untersuchen. Dazu hat sie eine anonymisierte Zufallsstichprobe ihrer Kunden gezogen. Für die Stichprobenbeobachtungen wurden die folgenden Variablen in R gespeichert:

Sparen das Sparguthaben in Euro,
Kredit ein Score (0 bis 100 Punkte), der die Kreditwürdigkeit beschreibt,
Einkommen das monatliche Durchschnittseinkommen in Euro,
Bildung die Bildung in Jahren,
Geschlecht = 1 für einen Mann, = 0 für eine Frau.

Mit R wurde der folgende Output erzeugt.

```
1 Call:
2 lm(formula = Sparen ~ Kredit + Einkommen + Bildung + Geschlecht)
3
4 Residuals:
5      Min       1Q   Median       3Q      Max
6 -40.959 -10.137   0.909   9.732  41.681
7
8 Coefficients:
9             Estimate Std. Error t value Pr(>|t|)
10 (Intercept) 16.592685   5.113326   3.245  0.00134 **
11 Kredit       3.010589   0.302367   9.957 < 2e-16 ***
12 Einkommen   5.398822   0.001695 3185.685 < 2e-16 ***
13 Bildung     0.763068   0.346278   2.204  0.02848 *
14 Geschlecht  -3.483219   1.922599  -1.812  0.07125 .
15 ---
16 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
17
18 Residual standard error: 14.99 on 245 degrees of freedom
19 Multiple R-squared:  1, Adjusted R-squared:  1
20 F-statistic: 2.632e+06 on 4 and 245 DF, p-value: < 2.2e-16
```

- (a) Interpretieren Sie den Koeffizienten von Kredit.
- (b) Prognostizieren Sie mit dem Modell das Sparguthaben für eine Frau (Geschlecht = 0) mit einem Kreditscore von 70, einem monatlichen Durchschnittseinkommen von 2500 Euro und 16 Jahren Bildung.
- (c) Führen Sie einen Test auf Signifikanz des Koeffizienten Bildung durch.
 - (i) Stellen Sie das zu testende Hypothesenpaar auf.
 - (ii) Geben Sie die Prüfgröße und ihre Verteilung an.
 - (iii) Geben Sie den R-Befehl an, mit dem aus der Prüfgröße der p -Wert bestimmt werden kann.
 - (iv) Treffen Sie die Testentscheidung für $\alpha = 0.05$.

Kontrollergebnis 3.:

- (a) Steigt der Kreditscore um einen Punkt, dann steigt das Sparguthaben im Durchschnitt um 3.011 Euro c.p..
- (b) 13736.598 Euro.
- (c)
 - (i) $H_0 : \beta_{\text{Bildung}} = 0$ und $H_1 : \beta_{\text{Bildung}} \neq 0$
 - (ii) $T = 2.204 \sim t(245)$.
 - (iii) $2 \cdot (1 - \text{pt}(2.204, 245))$.
 - (iv) Da $p\text{-Wert} = 0.02848 < 0.05$, kann für $\alpha = 0.05$ die Nullhypothese verworfen werden. Die Alternativhypothese und damit die Signifikanz des Koeffizienten Bildung sind statistisch abgesichert für $\alpha = 0.05$.

Lösungsweg

- (a) Im vorliegenden Fall betrachten wir ein multiples lineares Regressionsmodell, also eines der Form $y_i = \beta_0 + \sum_{j=1}^p \beta_j x_{ij} + \varepsilon_i$, mit $\beta_0 =$ Ordinatenschnittpunkt und $\beta_j =$ Steigungsparameter der p unabhängigen Variablen (Faktoren, Regressoren, Einflussgrößen).

Da es sich um geschätzte Parameter handelt, ergibt sich die Form: $\hat{y}_i = \hat{\beta}_0 + \sum_{j=1}^p \hat{\beta}_j x_{ij}$.

Bei einer Erhöhung von x_j um eine Einheit verändert sich y (laut Modell, mit einer Irrtumswahrscheinlichkeit i.H.v. $\Pr(>|\tau|)$) unter sonst gleichen Umständen (c.p.) im Durchschnitt um $\hat{\beta}_j$.

Der geschätzte Steigungsparameter bzw. Koeffizient von $x_1 =$ Kreditwürdigkeit $\hat{\beta}_1$ beträgt 3.010589. Bei einer zusätzlichen Einheit von x_1 verändert sich y also laut Modell, alles Andere gleichbleibend, im Durchschnitt um $\hat{\beta}_1$.

Dabei gilt:

- y ist das Sparguthaben eines/r Piggybankkunden/in in Euro und
- eine Einheit Kredit entspricht einem Punkt auf einer Kreditwürdigkeitsskala von 0 bis 100.

Daher verändert sich das Sparguthaben eines/r Piggybankkunden/in bei einem Punkt mehr als zuvor auf der Kreditwürdigkeitsskala, wenn alles andere gleich bleibt, im Mittel um +3.011 Euro.

Die Interpretation lautet somit: Steigt der Kreditscore um einen Punkt, dann steigt das Sparguthaben im Durchschnitt c.p. um 3.011 Euro.

- (b) Aus dem R-Output lässt sich folgende Regressionsgerade ablesen:

$$\hat{y}_i = 16.592685 + 3.010589x_1 + 5.398822x_2 + 0.763068x_3 - 3.483219x_4$$

$$\hookrightarrow \hat{y}_i(70, 2500, 16, 0) = 16.592685 + 3.010589 \cdot 70 + 5.398822 \cdot 2500 + 0.763068 \cdot 16 - 3.483219 \cdot 0 = 13736.598$$

- (c) (i) Ein Signifikanztest ist ein Test auf Bedeutsamkeit eines Parameters i.S.v. Einfluss auf y ($\Leftrightarrow \beta_i \neq 0$). H_1 ist die zu beweisende Hypothese, H_0 die Gegenhypothese, also:
 $H_0 : \beta_3 = 0$ vs. $H_1 : \beta_3 \neq 0$.

$$(ii) T = \frac{\hat{\beta}_i}{\hat{\sigma}_{\hat{\beta}_i}} \sim t_{n-k} = t_{n-p-1} \Rightarrow T = \frac{0.763068}{0.346278} \approx 2.204 \sim t_{245}$$

$$(iii) P(\text{Daten} \in \text{Ablehnungsbereich} | H_0) \\ = P(\text{Beobachtungen rechts von } + \text{ Prüfgröße und links von } - \text{ Prüfgröße}) \\ = 2(1 - \text{pt}(2.204, 245)) \approx 0.028$$

- (iv) p -Wert = kleinstes Signifikanzniveau, zu dem H_0 - gegebenen Beobachtungen - verworfen werden kann. Wenn H_0 zu ≈ 0.028 verworfen werden kann, dann erst recht zu 0.05.
 $\hookrightarrow$ Lehne H_0 zu $\alpha = 0.05$ ab und erachte H_1 für $\alpha = 0.05$ als statistisch bewiesen.

Hinweise

- Bei der Interpretation beachten:
 - Was genau verändert sich?
 - Um wie viel? (Auf richtige Einheiten achten!)
 - Die Veränderung ist ein Durchschnitt (den das Modell aus mehreren beobachteten Werten zur Prognose gebildet hat).
 - Die Veränderung beträgt nur ceteris paribus $\hat{\beta}_i$.
- In (b) gilt wie im Allgemeinen: Mit exakten Werten rechnen, erst das (jeweilige) Ergebnis runden.
- Für Genaueres zu Aufgabenteil (c) (ii)-(iv) siehe Aufgabe 1 TUT 12
- Berechnen Sie n für dieses multiple Regressionsmodell. Wie anhand der Freiheitsgrade in (c) (ii) erkennbar ist, ist $n = df + p + 1 = df + k = 245 + 5 = 250$
- Der Ablehnungsbereich für $\alpha = 5\%$ wird, da es sich um einen zweiseitigen Test handelt, wie folgt bestimmt: $(-\infty, t_{\frac{\alpha}{2}; df}] \cup [t_{1-\frac{\alpha}{2}; df}, \infty)$. Es werden also zwei kritische Werte benötigt:
 $t_{1-\frac{\alpha}{2}, n-k} = t_{1-\frac{\alpha}{2}, n-p-1} = t_{1-\frac{0.05}{2}, 245} = t_{0.975, 245}$
 $t_{0.975, 245}$ ist das 97.5%-Quantil der t -Verteilung bei 245 Freiheitsgraden. Es entspricht 1.97.
Weiterhin wird für den Ablehnungsbereich das 2.5%-Quantil benötigt.
 $t_{\frac{\alpha}{2}, n-p-1} = t_{\frac{0.05}{2}, 245} = t_{0.025, 245} = -1.97$.
Der zweiseitige Ablehnungsbereich für $\alpha = 5\%$ entspricht damit: $(-\infty, -1.97] \cup [1.97, \infty)$
Die Prüfgröße ($T = 2.204$) liegt im Ablehnungsbereich, damit kann H_0 verworfen werden.
- Sowohl die F -Statistik als auch das R^2 sind unrealistisch. Es handelt sich hier um fabrizierte Daten.

Verweis Informationsquellen SDS1V13