

## Testat 1: Daten- und Merkmalstypen & Deskriptive Statistik zur Beschreibung von Merkmalen

Das Studierendenwerk Göttingen möchte eine Umfrage zu den Essgewohnheiten der Studierenden der Universität durchführen, um das Angebot in den Mensen zu verbessern. Aufgrund Ihrer Expertise im Bereich deskriptive Statistik fragt es Sie um Rat.

### Aufgabe 1.

Das Studierendenwerk plant, die folgenden Merkmale in der Umfrage zu erheben. Wählen Sie jeweils das korrekte Skalenniveau aus (nominal, ordinal, kardinal). Entscheiden Sie außerdem, ob es sich um ein diskretes oder stetiges Merkmal handelt.

1. Alter (in ganzen Jahren)
2. Anzahl der Mensabesuche in der vergangenen Woche
3. Präferierter Mensastandort (Zentralmensa, Nordmensa, Mensa am Turm)
4. Zufriedenheit mit dem Essensangebot auf einer ganzzahligen Skala von 1 (gar nicht zufrieden) bis 7 (sehr zufrieden)
5. Monatseinkommen (in Euro)

### Aufgabe 2.

Der Anteil der Befragten aus jedem Studiengang soll dem Anteil dieser Studierenden an der gesamten Studierendenschaft entsprechen. Welche Methode zum Ziehen der Stichprobe sollte angewandt werden?

- (a) Einfache Zufallsstichprobe
- (b) Geschichtete Stichprobe/Quotenverfahren
- (c) Klumpenstichprobe
- (d) Keines dieser Verfahren ist geeignet

### Aufgabe 3.

Welches Lagemaß oder welche Lagemaße können benutzt werden, um die Präferenzen und Zufriedenheit der Göttinger Studierenden zu beschreiben?

1. Präferierter Mensastandort (Zentralmensa, Nordmensa, Mensa am Turm)
2. Zufriedenheit (ganzzahlige Skala von 1 bis 7)

### Aufgabe 4.

In einer Pilotstudie wird der Fragebogen getestet. Betrachten Sie die folgende Häufigkeitstabelle für das Merkmal  $X$  = Anzahl der Mensabesuche in der vergangenen Woche mit Ausprägungen  $a_i$  und entsprechenden absoluten Häufigkeiten  $h_i$  mit  $i = 1, \dots, 5$ .

|       |   |   |   |   |    |
|-------|---|---|---|---|----|
| $a_i$ | 1 | 3 | 4 | 5 | 10 |
| $h_i$ | 1 | 2 | 5 | 3 | 1  |

1. Wie viele Studierende wurden im Rahmen der Pilotstudie befragt? Bestimmen Sie die Stichprobengröße  $n$ .
2. Bestimmen Sie den Modus  $x_{\text{mod}}$ , den Median  $x_{\text{med}}$  und das arithmetische Mittel  $\bar{x}$  des Merkmals in der Stichprobe.

**Aufgabe 5.**


Ihnen wird die folgende Stichprobe zur Variable  $X = \text{Monatseinkommen in Euro}$ , die ebenfalls aus der Pilotstudie stammt, vorgelegt. Dabei bezeichnet  $x_i$  den beobachteten Wert für die  $i$ -te Beobachtung,  $i = 1, \dots, 12$ .

| $i$   | 1    | 2   | 3   | 4    | 5   | 6   | 7   | 8    | 9   | 10   | 11   | 12  |
|-------|------|-----|-----|------|-----|-----|-----|------|-----|------|------|-----|
| $x_i$ | 1400 | 750 | 900 | 1100 | 900 | 550 | 800 | 1600 | 900 | 7500 | 1000 | 600 |

- Bestimmen Sie den Modus  $x_{\text{mod}}$ , den Median  $x_{\text{med}}$  und das arithmetische Mittel  $\bar{x}$  des Merkmals in der Stichprobe.
- Mit welchem R-Befehl können Sie die Standardabweichung für die Stichprobe berechnen, wenn die obigen Werte im Vektor  $x$  gespeichert sind?
  - `exp(var(x))`
  - `sd(x)`
  - `1/(n-1)*sd(x)`
  - `sqrt(var(x))`
- Welchen Vorteil bietet die Standardabweichung verglichen mit der Varianz?
  - Die Standardabweichung wird durch Ausreißer nicht verzerrt.
  - Die Standardabweichung ist unabhängig von der Stichprobengröße.
  - Die Standardabweichung hat die gleiche Maßeinheit wie das von ihr beschriebene Merkmal.
  - Keine der Antworten ist korrekt.

### Aufgabe 6.


Nach der erfolgreichen Pilotstudie führt das Studierendenwerk die Umfrage durch. Aus den Ergebnissen erstellen Sie folgenden Boxplot für das Merkmal  $X$  = Zufriedenheit mit der Auswahl in der Mensa, das auf einer ganzzahligen Skala von 1 (gar nicht zufrieden) bis 7 (sehr zufrieden) erhoben wurde. Da Sie daran interessiert sind, mit welchen Merkmalen die Zufriedenheitswerte zusammenhängen, stellen Sie diese pro Ausprägung des Merkmals  $Y$  = Präferierter Mensastandort dar.



- Bestimmen Sie mithilfe des Boxplots folgende Werte der Zufriedenheit mit dem Essensangebot für die Ausprägung Zentralmensa: Median  $x_{med}$ , 25%-Quantil  $x_{0.25}$ , Maximalwert  $x_{max}$ .
- Eine Mitarbeiterin des Studierendenwerkes betrachtet den Boxplot und sagt: „Offensichtlich wird die Zufriedenheit der Besucher\*innen mit dem Essensangebot davon bestimmt, in welcher Mensa sie am liebsten essen.“ Welche der folgenden Aussagen sind korrekt?
  - Ohne ein experimentelles Design oder Kontrolle relevanter Störvariablen kann man keine kausale Schlussfolgerung ziehen.
  - Der Mensastandort determiniert die Zufriedenheit, weil die dargestellten Medianwerte unterschiedlich sind.
  - Da in der Umfrage mehrere Störvariablen berücksichtigt wurden, ist eine Ursache-Wirkung-Aussage in diesem Fall zulässig.
  - Die statistische Analyse der Umfragedaten kann lediglich eine Korrelation zwischen der Zufriedenheit und dem Mensastandort feststellen.
- Liegen in der zugrundeliegenden Stichprobe Ausreißer vor?
  - Ja, der lange untere Whisker bei der Ausprägung Nordmensa deutet auf einen Ausreißer hin.
  - Nein, es sind keine Ausreißer eingezeichnet.
  - Ja, der Median bei der Ausprägung Mensa am Turm reißt nach oben hin aus.
  - Nein, bei ordinalskalierten Variablen kann es keine Ausreißer geben.

### Aufgabe 7.

Im Rahmen der Hauptumfrage hat das Studierendenwerk 500 Personen befragt. Für das Merkmal  $X = \text{Alter in ganzen Jahren}$  erstellen Sie folgendes (normiertes) Histogramm, wobei die Beobachtung  $x_i$  zur Klasse  $j$  gehört, wenn  $c_{j-1} < x_i \leq c_j$ .



- Bestimmen Sie die Anzahl der Beobachtungen mit  $25 < x \leq 30$ .
- Benutzen Sie das Histogramm, um den Anteil von Beobachtungen mit  $21 < x \leq 24$  in der Grundgesamtheit zu schätzen.
- Welche Klasse ist die Modalklasse?
- Ist die Behauptung „Die Modalklasse für ein Merkmal ist immer die Klasse, über die das Kästchen im Histogramm am höchsten ist“ im Allgemeinen korrekt?
- Mit welchem R-Befehl lässt sich ein normiertes Histogramm für die im Vektor  $x$  gespeicherten Daten erstellen?
  - `hist(x, prob = TRUE)`
  - `hist(x, prob = FALSE)`
  - `hist(x, freq = TRUE)`
  - `hist(x, freq = FALSE)`