

Testat 2: Deskriptive Statistik zur Beschreibung von Zusammenhängen

Aufgabe 1.

Sie überlegen, ob es sinnvoll ist, sich intensiv auf die Klausur im Fach *Statistik für Wirtschaftswissenschaften* vorzubereiten, oder ob der Klausurerfolg ohnehin eher vom Zufall abhängt. Sie befragen demnach Kommiliton*innen, die diese Klausur bereits in vorigen Semestern geschrieben haben, zu ihrer Klausurvorbereitung und dem resultierenden Klausurerfolg. Sie erheben die metrischen Merkmale X = ins Lernen investierte Stunden und Y = in der Klausur erreichte Punkte. Die Ergebnisse der Umfrage speichern Sie in R in den Objekten x und y ab.

1. Um den Zusammenhang der beiden Merkmale zu untersuchen, möchten Sie ihre empirische Kovarianz berechnen. Dazu ist Ihnen die Formel

$$\text{Cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

gegeben. Wie lautet die äquivalente Darstellung, die sich mittels des Verschiebungssatzes erreichen lässt?


Hinweis: Vereinfachen Sie die Kovarianz-Formel so weit wie möglich.

- (a) $\text{Cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i y_i - \bar{x} \bar{y})$
 - (b) $\text{Cov}(X, Y) = \frac{1}{n^2} \sum_{i=1}^n x_i y_i - \bar{x} \bar{y}$
 - (c) $\text{Cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i y_i) - \bar{x} - \bar{y}$
 - (d) $\text{Cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i y_i) - \bar{x} \bar{y}$
2. Nutzen Sie die folgenden Zwischenergebnisse aus R, um die empirische (unkorrigierte) Kovarianz sowie den Pearson'schen Korrelationskoeffizienten zwischen X und Y zu berechnen.

Hinweis: Nutzen Sie dazu das Ergebnis der Teilaufgabe (a).

```
> length(x)
[1] 50
> sum(x)
[1] 2019
> sum(y)
[1] 3733
> sum(x^2)
[1] 87611
> sum(y^2)
[1] 301695
> sum(x*y)
[1] 160064
```

3. Zur Visualisierung des Zusammenhangs erstellen Sie aus den erhobenen Daten folgende Punktwolke.



Punktwolke: Vorbereitung und Klausurerfolg

Die Grafik hat Sie dermaßen überrascht, dass Sie aus Versehen Teile Ihres R-Codes gelöscht haben. Kompletieren Sie ihn wieder.

```
1 png("klausur_scatter.png", width = 2000, height = 2000, res = 400)
2   (x, y,
3     pch = 16,
4     cex = 0.8,
5     xlab = "Ins Lernen investierte Stunden",
6     ylab = "Erreichte Punkte",
7     main = ,
8     panel.first = grid())
9 dev.off()
```

4. Welche Aussage lässt sich anhand der Punktwolke über den Korrelationskoeffizienten $\hat{\rho}$ der beiden uns interessierenden Merkmalen treffen?
- (a) $\rho < 0$
 - (b) $\rho \approx 0$
 - (c) $\rho > 0$
 - (d) Anhand der Abbildung lässt sich keine eindeutige Aussage treffen
5. Mittels welches R-Befehls lässt sich der Pearson'sche Korrelationskoeffizient zwischen X und Y berechnen?
6. Basierend auf Ihren bislang durchgeführten Analysen: Welche der folgenden Aussagen sind korrekt, welche falsch?
- (a) Wenn man mehr als 60 Stunden ins Lernen investiert, erreicht man auf jeden Fall mehr als 100 Punkte.
 - (b) Es besteht ein positiver Zusammenhang zwischen der erreichten Punktzahl und der ins Lernen investierten Zeit.
 - (c) Die Klausurnoten werden vom Zufall bestimmt, sodass intensives Lernen nicht sinnvoll ist.
 - (d) Die Punktwolke stellt einen stochastischen Zusammenhang dar.

Aufgabe 2.

Die folgenden Aussagen befassen sich mit der Analyse von Zusammenhängen. Betrachten Sie dabei die metrischen Zufallsvariablen X und Y , wobei ρ_{XY} den Pearson'schen Korrelationskoeffizienten für diese zwei Variablen bezeichnet. Wählen Sie alle korrekten Aussagen aus.

- (a) Wenn $\rho_{XY} \neq 0$, sind X und Y niemals unabhängig.
- (b) Wenn $Y = -X^2$, kann ρ_{XY} annähernd 0 sein.
- (c) Wenn $X = Y$, gilt immer $\rho_{XY} = 1$.
- (d) Wenn $\rho_{XY} \neq 0$, kann man stets davon ausgehen, dass zwischen X und Y ein kausaler Zusammenhang besteht.
- (e) Wenn $\text{Cov}(X, Y) \geq 0.8$, spricht man immer von einem starken Zusammenhang zwischen X und Y .

Aufgabe 3.

In dem Lied „Toss A Coin To Your Witcher“ zu der Netflix-Serie „The Witcher“ versucht der Barde Jaskier, der die Hauptcharaktere Geralt von Riva und Yennefer von Vengerberg begleitet, mit der Strophe „Toss a coin to your Witcher, Oh Valley of Plenty“ wiederholt, die Bewohner*innen eines der Täler der mystischen Welt der Serie zu motivieren, ihm bzw. „dem Witcher“ Geralt von Riva eine Münze zuzuwerfen.

Neben seinem künstlerischen Engagement ist Jaskier auch ein begeisterter angewandter Statistiker und sammelt entsprechend für jeden Tavernenbesuch Daten über den Ertrag seiner Performance. Der Datensatz enthält folgende Variablen:

Variable	Erläuterung
Taverne	Chiffre der Taverne gemäß der Systematisierung des Barden
Tal	Verortung des Tals der Taverne
Monster	Beschreibung des durch den Witcher besiegtten Monsters
Muenzen	Anzahl der erhaltenen Münzen
Kampfzeit	Zeit (in Minuten) zur Besiegung des Monsters

- Die Daten sind in der Datei `WitcherData2.csv` auf Ihrem lokalen Laufwerk in dem Ordner **Dokumente** hinterlegt. Setzen Sie mittels `setwd(path.expand("~/"))` Ihr Working Directory fest, um mit R in diesem lokalen Ordner zu arbeiten. Speichern Sie anschließend die in der Datei hinterlegten Daten als Data-Frame-Objekt `d` in R ab und geben Sie die ersten sechs Zeilen des Data-Frame-Objektes wieder. Vervollständigen Sie den R-Befehl zum Lösen dieser Aufgabe.

```
1 setwd(path.expand("~/"))
2 d <- read.csv("WitcherData2.csv", sep = ", ", as.is = TRUE, header = TRUE)
3 d
```

- Der erstellte Data Frame ist eine spezielle Form der Liste, welche wiederum eine Sammlung potentiell verschiedener Objekttypen darstellt. Ermitteln Sie unter Einbezug eines passenden R-Befehls die Objekttypen der zwei im gespeicherten Objekt `d` enthaltenen Variablen `Taverne` und `Kampfzeit`.

Hinweis: Falls Sie keine spezifischen Befehle zu diesem Zwecke kennen, können Sie sich von R die Struktur des Datensatzes mittels des `str()`-Befehls ausgeben lassen.


(i) Taverne: ☐ numeric ☐ character ☐ logical ☐ factor ☐ date

(ii) Kampfzeit: ☐ numeric ☐ character ☐ logical ☐ factor ☐ date

- Berechnen Sie den Median und den Interquartilsabstand für die Variable `Kampfzeit`. Runden Sie Ihr Ergebnis auf zwei Nachkommastellen.

Hinweis: Falls Sie keine spezifischen Befehle zu diesem Zwecke kennen, können Sie sich von R die Zusammenfassung des Datensatzes mittels des `summary()`-Befehls ausgeben lassen.

4. Der Barde hat folgendes Streudiagramm erstellt. Nachdem der letzte Tavernenbesuch länger ausfiel als geplant, ist seine Erinnerung an den dazugehörigen R-Code lückenhaft. Vervollständigen Sie den Befehl, der die grafische Darstellung erzeugt hat.



```
1 pdf("Streudiagramm.pdf")
2   (
3     pch = 16,
4     cex = 0.3,
5     = "Streudiagramm",
6     = "Kampfzeit (min.)",
7     ylab =
8     .off()
```

5. Ergänzen Sie Ihren Datensatz um die folgenden zwei Variablen:

- (i) Die Variable `Kampfzeit.3` stellt eine vereinfachte Darstellung der Variable `Kampfzeit` mit drei Ausprägungen dar: {Weniger als 5 Minuten, 5 Minuten bis weniger als eine Stunde, Eine Stunde oder mehr}. Die Variable sollte als Factor-Object abgespeichert und als 6. Spalte dem Datensatz `d` hinzugefügt werden.
- (ii) Die Variable `Muenzen.4` stellt eine vereinfachte Darstellung der Variable `Muenzen` mit vier Ausprägungen dar: {Bis zu 10 Münzen, Mehr als 10 aber maximal 20 Münzen, Mehr als 20 aber maximal 30 Münzen, Mehr als 30 Münzen}. Die Variable sollte als Factor-Object abgespeichert und als 7. Spalte dem Datensatz `d` hinzugefügt werden.

Wie muss der R-Code zur Erstellung der beiden neuen Variablen korrekt lauten?

```
1 d$Kampfzeit.3 <- (d$Kampfzeit, = c( ), right = )
2 d$Muenzen.4 <- (d$Muenzen, = c( ), right = )
```

6. Erstellen Sie nun eine Kontingenztafel für die zwei gerade hinzugefügten Variablen `Muenzen.4` und `Kampfzeit.3` und nutzen Sie diese, um zu bestimmen, wie häufig bei einer Kampfzeit zwischen 5 Minuten und einer Stunde die Anzahl der Münzen zwischen 10 und 20 lag.

(i) Wie lautet der korrekte Code zur Erstellung der Kontingenztafel?

```
1 Kontingenz.Tafel <- (d$Muenzen.4, d$Kampfzeit.3)
```

(ii) Wie häufig kommt das oben beschriebene Ereignis im Datensatz vor?

7. Betrachten Sie nun nur jene Beobachtungen im Datensatz, bei welchen die Kampfzeit mindestens 5 Minuten, jedoch weniger als 60 Minuten betrug. Ermitteln Sie für diese Beobachtungen die Randverteilung für die Variable `Muenzen.4`. Geben Sie die Wahrscheinlichkeitsmasse (relative Häufigkeit) jeder Ausprägung auf zwei Dezimalstellen gerundet an.

Ausprägung <code>Muenzen.4</code> (x_i)	(0, 10]	(10, 20]	(20, 30]	(30, Inf)
$P(\text{Muenzen.4} = x_i)$				

Tabelle 1: Empirische Randverteilung von `Muenzen.4`